BEKÇİLERİ KİM BEKLEYECEK?

Karar Vericileri Aşan Yapay Zekânın Denetimi ve Hesap Verebilirliği Üzerine Hukuki, Felsefi ve Siyasi Bir İnceleme

[Yazar Adı Soyadı]

Ankara, 2026

İÇİNDEKİLER

ÖNSÖZ....6
ÖZET....8
ABSTRACT....10
KISALTMALAR....12
GİRİŞ....14
I. KONUNUN TAKDİMİ: "YAPAY AKIL"IN İKİ ANLAMI....14
II. ARAŞTIRMANIN PROBLEMİ....17
III. ARAŞTIRMA SORULARI VE HİPOTEZLER....18
IV. KAPSAM VE SINIRLAR....20
V. YÖNTEM....21
VI. KAVRAMSAL ÖN AÇIKLAMALAR....23
VII. ÇALIŞMANIN PLANI....26
BİRİNCİ BÖLÜM: KADİM BİR SORUNUN SOYKÜTÜĞÜ — BEKÇİLERİ KİM BEKLEYECEK?....28
§ 1. ANTİK DÜŞÜNCEDE BEKÇİLER SORUNU....28
§ 2. HÜKÜMDARIN YASAYA BAĞLANMASI....38
§ 3. MODERN ANAYASACILIĞIN CEVABI....45
§ 4. EGEMENLİĞİN SINIRLANMASI SORUNU....54
§ 5. UZMAN VE EFENDİ: BİLGİ ASİMETRİSİNİN TARİHSEL BİÇİMLERİ....61
İKİNCİ BÖLÜM: KARAR VERİCİLERİ AŞAN YAPAY ZEKÂ — OLGUSAL ZEMİN VE DENETİMİN EPİSTEMİK SORUNU....71
§ 6. KAVRAMLAR: YAPAY ZEKÂ VE "DAHA ZEKİ" OLMAK…71
§ 7. TARİHSEL GELİŞİM VE GÜNCEL DURUM....77
§ 8. KARAR SÜREÇLERİNE NÜFUZ: ALGOKRASİ....83
§ 9. BİLİŞSEL ASİMETRİ VE İNSAN DENETİMİNİN SINIRLARI 91
§ 10. HİZALAMA SORUNU....101
ÜÇÜNCÜ BÖLÜM: FELSEFİ PERSPEKTİF — ZEKÂ, OTORİTE VE MEŞRUİYET....114

§ 11. EPİSTOKRASİ VE BEKÇİLİK....114
§ 12. OTORİTE KURAMI VE YAPAY ZEKÂ....123
§ 13. ÖZERKLİK, İNSAN ONURU VE EPİSTEMİK BAĞIMLILIK....130
§ 14. SORUMLULUK ETİĞİ VE SORUMLULUK BOŞLUKLARI 136
§ 15. YAPAY ZEKÂNIN AHLAKİ STATÜSÜ ÜZERİNE BİR NOT....145
§ 16. ARA SONUÇ: ZEKÂ YETKİ DOĞURMAZ....147
DÖRDÜNCÜ BÖLÜM: SİYASİ PERSPEKTİF — İKTİDAR, EGEMENLİK VE TEKNOLOJİK GÜÇ....150
§ 17. TEKNOLOJİNİN SİYASETİ....150
§ 18. YENİ EGEMENLİK BİÇİMLERİ....157
§ 19. GÜÇ YOĞUNLAŞMASI VE DEMOKRASİ....163
§ 20. YARIŞ DİNAMİĞİ VE JEOPOLİTİK....170
§ 21. DEMOKRATİK DENETİMİN YENİDEN TASARLANMASI 175
BEŞİNCİ BÖLÜM: HUKUKİ PERSPEKTİF (I) — ANAYASAL VE İDARİ DENETİM....185
§ 22. ANAYASAL İLKELER....185
§ 23. ALGORİTMİK İDARİ İŞLEM....192
§ 24. YARGISAL DENETİM VE YARGIDA YAPAY ZEKÂ....202
§ 25. YASAMA DENETİMİ....210
§ 26. BAĞIMSIZ İDARİ OTORİTELER VE UZMAN DENETİM KURUMLARI....213
§ 27. TEMEL HAKLAR BOYUTU....218
ALTINCI BÖLÜM: HUKUKİ PERSPEKTİF (II) — SORUMLULUK VE HESAP SORMA....225
§ 28. HESAP VEREBİLİRLİK KAVRAMI....225
§ 29. ÖZEL HUKUK SORUMLULUĞU....229
§ 30. CEZA SORUMLULUĞU....237
§ 31. İDARENİN SORUMLULUĞU....244
§ 32. ELEKTRONİK KİŞİLİK TARTIŞMASI....247

§ 33. GELİŞTİRİCİLERİN KURUMSAL YÖNETİŞİMİ VE SORUMLULUĞU....250
YEDİNCİ BÖLÜM: KARŞILAŞTIRMALI HUKUK VE ULUSLARARASI DÜZEN....258
§ 34. AVRUPA BİRLİĞİ: YAPAY ZEKÂ TÜZÜĞÜ....258
§ 35. AVRUPA KONSEYİ ÇERÇEVE SÖZLEŞMESİ....266
§ 36. AMERİKA BİRLEŞİK DEVLETLERİ....269
§ 37. BİRLEŞİK KRALLIK....272
§ 38. ÇİN HALK CUMHURİYETİ....273
§ 39. KÜRESEL YÖNETİŞİM GİRİŞİMLERİ....275
§ 40. TÜRKİYE....278
§ 41. KARŞILAŞTIRMALI DEĞERLENDİRME....282
SEKİZİNCİ BÖLÜM: ÇOK KATMANLI DAİRESEL DENETİM MODELİ....284
§ 42. TEMEL İLKELER....284
§ 43. DENETİMİN DÖRT NESNESİ....286
§ 44. BEŞ KATMAN....289
§ 45. HESAP SORMA REJİMİ....300
§ 46. TÜRK HUKUKU İÇİN KANUN ÖNERİSİ....302
§ 47. MUHTEMEL İTİRAZLAR VE CEVAPLAR....324
§ 48. JUVENALİS'E DÖNÜŞ....330
SONUÇ....334
I. Araştırma Sorularına Cevaplar....334
II. Hipotezlerin Değerlendirilmesi....339
III. Çalışmanın Sınırlılıkları ve Gelecek Araştırmalar İçin Öneriler....341
IV. Son Söz....342
KAYNAKÇA....343
A. Klasik Eserler....343
B. Kitaplar, Kitap Bölümleri ve Makaleler....344
C. Raporlar ve Kurumsal Belgeler....360

D. Mevzuat ve Uluslararası Belgeler.....361
E. Mahkeme Kararları.....363
EK: KAVRAM SÖZLÜĞÜ.....365

ÖNSÖZ

“Bekçileri kim bekleyecek?” sorusu, Romalı hiciv şairi Juvenalis’in kaleminden çıktığı günden bu yana kamu hukukunun ve siyaset felsefesinin en inatçı sorusu olmuştur. Bu soru, her kuşakta yeniden sorulmuş ve her kuşak ona kendi kurumlarıyla cevap vermeye çalışmıştır. Platon bekçileri eğitmeyi, Montesquieu iktidarı iktidarla durdurmayı, Amerikan Federalistleri hırsı hırsla dengelemeyi, Kelsen anayasa mahkemesini, Popper ise yöneticileri kan dökülmeden görevden alabilmeyi önermiştir. Bu cevapların hepsinin paylaştığı, ancak nadiren açıkça dile getirilen bir varsayım vardır: Denetleyen ile denetlenen, aşağı yukarı aynı türden ve aynı ölçüde akla sahiptir. Meclis hükümetin ne yaptığını anlayabilir, hâkim idarenin işlemini değerlendirebilir, seçmen iktidarın icraatını tartabilir.

Bu kitap, söz konusu varsayımın ilk kez ciddi biçimde sarsılabileceği bir dönemin eşiğinde yazılmıştır. Yapay zekâ sistemleri, birçok dar alanda insan uzmanların başarımını aşmış; dil, akıl yürütme, programlama ve bilimsel analiz gibi genel yeteneklerde ise hızla ilerlemektedir. Bu sistemlerin günün birinde, onları denetlemekle görevli karar vericilerin bilişsel kapasitesini genel olarak aşıp aşmayacağı, aşacaksa bunun ne zaman olacağı bilimsel olarak tartışmalıdır. Ancak hukuk, kesinliği beklemenin lüksüne her zaman sahip değildir. Anayasa yapıcılar, ortaya çıkıp çıkmayacağını bilmedikleri tiranları önlemek için kurumlar tasarlamıştır. Bu çalışma da aynı ihtiyatlı mantıkla, henüz tam olarak gerçekleşmemiş ama gerçekleşme ihtimali ciddiye alınması gereken bir durumu hukuki, felsefi ve siyasi açılardan sistematik biçimde incelemeyi amaçlamaktadır.

Çalışmanın temel iddiası basit bir cümleyle özetlenebilir: **Zekâ üstünlüğü yetki doğurmaz.** Daha zeki bir sistem daha iyi bir danışman, daha güçlü bir araç, hatta bazı alanlarda vazgeçilmez bir yardımcı olabilir; fakat bu üstünlük, kendi başına, egemenlik yetkisinin kullanılmasını meşrulaştırmaz. Bu iddia, Türk anayasa düzeninde de karşılığı olan bir ilkedir: “Hiçbir kimse veya organ kaynağını Anayasadan almayan bir Devlet yetkisi kullanamaz.” Ne var ki bu normatif tespit, pratik soruyu cevapsız bırakır. Anlayamadığınız bir kararı nasıl denetleyeceksiniz?

Sizden daha hızlı ve daha derin düşünen bir sistemin sizi yanıltmadığından nasıl emin olacaksınız? Zararı kim, hangi sıfatla ödeyecek? Kitabın büyük kısmı bu sorulara ayrılmıştır.

Çalışma sekiz bölümden oluşmaktadır. İlk bölüm, "bekçiler sorunu"nun Antik Çağ'dan modern anayasacılığa uzanan soykütüğünü çıkarmaktadır. İkinci bölüm, yapay zekânın karar süreçlerine nüfuzunu ve bilişsel asimetrinin denetim üzerindeki etkilerini olgusal düzlemde ele almaktadır. Üçüncü ve dördüncü bölümler sırasıyla felsefi ve siyasi perspektifleri; beşinci ve altıncı bölümler ise hukuki perspektifi anayasal-idari denetim ile sorumluluk hukuku eksenlerinde incelemektedir. Yedinci bölüm karşılaştırmalı hukuku ve uluslararası düzenlemeleri Türkiye'deki durumla birlikte değerlendirmekte, sekizinci bölüm ise "çok katmanlı dairesel denetim" adını verdiğimiz bir model ile Türk hukuku için gerekçeli bir kanun önerisi sunmaktadır. Sonuç kısmında çalışmanın bulguları tezler hâlinde özetlenmiştir.

Kaynak kullanımına ilişkin bir açıklama yapmak gerekir. Klasik eserlere (Platon, Aristoteles, Locke, Montesquieu, Federalist Yazılar vb.) baskıdan baskıya değişen sayfa numaraları yerine, yerleşik akademik geleneğe uygun olarak kitap, bölüm, paragraf veya standart pasaj numaralarıyla atıf yapılmıştır. Mahkeme kararları resmî künyeleriyle, mevzuat madde numaralarıyla gösterilmiştir. Çağdaş literatüre ise eser düzeyinde atıf yapılmış; sayfa numarası gerektiren doğrudan alıntılardan mümkün olduğunca kaçınılmıştır. Yayına hazırlık aşamasında, kullanılan baskılara göre sayfa atıflarının eklenmesi ve tüm künyelerin birincil kaynaklardan yeniden doğrulanması gerekmektedir. Çalışmada, 2026 yılı Ekim ayı itibarıyla ulaşılabilen mevzuat, içtihat ve literatür esas alınmıştır; hızla değişen bu alanda bazı düzenlemelerin yürürlük ve uygulama durumlarının okuma anında farklılaşmış olabileceği hatırda tutulmalıdır.

Son olarak, bu kitabın konusu gereği kendine yönelen bir soruyu da açıkça kabul etmek gerekir: Yapay zekânın denetimini konu alan bir metin, yazımının her aşamasında, okurun eleştirel denetimine en az kendi konusu kadar muhtaçtır. Juvenalis'in sorusu yalnızca iktidara değil, iktidar hakkında konuşanlara da yöneltilmelidir. Bu çalışmanın her iddiası, okurun itirazına açık bir öneri olarak sunulmaktadır.

[Yer], [Tarih]

[Yazar Adı Soyadı]

ÖZET

BEKÇİLERİ KİM BEKLEYECEK? Karar Vericileri Aşan Yapay Zekânın Denetimi ve Hesap Verebilirliği Üzerine Hukuki, Felsefi ve Siyasi Bir İnceleme

Bu çalışma, yapay zekâ sistemlerinin belirli alanlarda veya genel olarak karar vericilerin bilişsel kapasitesini aşması hâlinde, bu sistemlerin kim tarafından, hangi meşruiyet temeline dayanarak ve hangi araçlarla denetleneceği ve bunlardan doğan sonuçlar için kimden nasıl hesap sorulacağı sorusunu incelemektedir. Çalışmanın çıkış noktası, Juvenalis'in "Quis custodiet ipsos custodes?" sorusuna tarih boyunca verilen klasik cevapların, denetleyen ile denetlenen arasında "kaba bilişsel denklik" bulunduğu yönündeki örtük bir varsayıma dayandığı tespitidir. Bu varsayımın zayıfladığı koşullarda, denetlenen kararın doğruluğunu bizzat değerlendirmeye dayanan "sonuç denetimi" işlevini yitirmeye başlar.

Çalışmada, bu soruna verilebilecek cevaplar üç perspektiften ele alınmıştır. Felsefi perspektifte, epistokrasi tartışması, Raz'ın otorite kuramı, Estlund'un "uzman/efendi safsatası" eleştirisi, Kant'ın özerklik anlayışı ve sorumluluk boşluğu tartışması incelenmiş; zekâ üstünlüğünün teorik (epistemik) otoriteyi gerekçelendirebileceği, ancak pratik (siyasi) otoriteyi gerekçelendiremeyeceği sonucuna varılmıştır. Siyasi perspektifte, teknolojik iktidarın doğası, platform egemenliği, güç yoğunlaşması ve yarış dinamikleri değerlendirilmiş; "algoritmik vesayet" kavramı önerilmiş ve Popper'in "kim yönetmeli?" sorusunu reddeden yaklaşımının yapay zekâ bağlamında "düzeltilebilirlik" ilkesine karşılık geldiği gösterilmiştir. Hukuki perspektifte, 1982 Anayasası'nın 6/3, 7, 9, 125, 129 ve 138. maddeleri başta olmak üzere egemenlik, yetki devri yasağı, idari işlemin unsurları, yargısal denetim, temel haklar ve sorumluluk hukuku kurumları incelenmiş; Avrupa Birliği Yapay Zekâ Tüzüğü, Avrupa Konseyi Çerçeve Sözleşmesi ve diğer karşılaştırmalı düzenlemelerle birlikte Türk hukukunun mevcut durumu değerlendirilmiştir.

Çalışmanın özgün katkısı, denetimin dört nesnesini (sonuç, süreç, girdi ve varlık koşulları) birbirinden ayıran ve bilişsel asimetri arttıkça ağırlığın sonuç denetiminden diğer üç nesneye kayması gerektiğini savunan analitik

çerçeve ile bu çerçeveye dayanan “çok katmanlı dairesel denetim modeli”dir. Bu modelde Juvenalis’in sonsuz geriye gidiş sorunu, tek bir nihai bekçi aranarak değil; teknik, kurumsal, girdi temelli, toplumsal ve uluslararası katmanların birbirini karşılıklı denetlediği ve her aşamada geri alınabilirliğin güvence altına alındığı bir yapı kurularak aşılmaktadır. Hesap sorma bakımından ise yapay zekâya elektronik kişilik tanınması önerisi reddedilmiş; sorumluluğun tasarım, eğitim, piyasaya sunma, kullanma ve denetleme halkalarındaki insan ve kurumlara, “son insan halkası” ilkesi ve kıdemli yönetici sorumluluğu modeli üzerinden bağlanması önerilmiştir. Çalışma, Türk hukuku için gerekçeli bir kanun önerisi taslağıyla tamamlanmaktadır.

Anahtar Kelimeler: Yapay zekâ, denetim, hesap verebilirlik, egemenlik, yetki devri yasağı, hizalama sorunu, epistokrasi, insan gözetimi, sorumluluk boşluğu, Juvenalis.

ABSTRACT

WHO WILL GUARD THE GUARDIANS? A Legal, Philosophical and Political Inquiry into the Oversight and Accountability of Artificial Intelligence Surpassing Decision-Makers

This study examines who should oversee artificial intelligence systems that surpass the cognitive capacity of decision-makers, either in specific domains or generally, on what basis of legitimacy and with which instruments, and how accountability for their consequences should be secured. The starting point is the observation that the classical answers to Juvenal's question "Quis custodiet ipsos custodes?" rest on an implicit assumption of "rough cognitive parity" between overseer and overseen. Where this assumption weakens, "outcome review", which depends on the overseer's ability to assess the correctness of a decision, begins to lose its function.

The question is approached from three perspectives. From a philosophical perspective, the debate on epistocracy, Raz's theory of authority, Estlund's critique of the "expert/boss fallacy", Kant's conception of autonomy and the responsibility-gap literature are examined; the study concludes that superior intelligence may justify theoretical (epistemic) authority but cannot justify practical (political) authority. From a political perspective, the nature of technological power, platform sovereignty, the concentration of power and race dynamics are assessed; the concept of "algorithmic tutelage" is proposed, and Popper's rejection of the question "who should rule?" is shown to correspond to the principle of corrigibility in the context of AI. From a legal perspective, sovereignty, the prohibition of delegation, the elements of the administrative act, judicial review, fundamental rights and liability are examined, with particular reference to Articles 6(3), 7, 9, 125, 129 and 138 of the 1982 Turkish Constitution; the current state of Turkish law is evaluated alongside the EU Artificial Intelligence Act, the Council of Europe Framework Convention and other comparative regimes.

The original contribution of the study is an analytical framework that distinguishes four objects of oversight (outcome, process, inputs and

conditions of existence) and argues that as cognitive asymmetry grows, the weight of oversight must shift from outcome review to the other three objects, together with a “multi-layered circular oversight model” built on this framework. In this model, Juvenal’s infinite regress is overcome not by searching for a single ultimate guardian, but by constructing a structure in which technical, institutional, input-based, societal and international layers check one another and reversibility is secured at every stage. Regarding accountability, the proposal to grant electronic personhood to AI is rejected; instead, liability is attached to the humans and institutions in the chain of design, training, deployment, use and oversight through a “last human link” principle and a senior-manager responsibility model. The study concludes with a reasoned draft statute for Turkish law.

Keywords: Artificial intelligence, oversight, accountability, sovereignty, non-delegation, alignment problem, epistocracy, human oversight, responsibility gap, Juvenal.

KISALTMALAR

Kısaltma	Açılımı
AB	Avrupa Birliği
ABAD	Avrupa Birliği Adalet Divanı
ABD	Amerika Birleşik Devletleri
AİHM	Avrupa İnsan Hakları Mahkemesi
AİHS	Avrupa İnsan Hakları Sözleşmesi
AY	1982 Türkiye Cumhuriyeti Anayasası
AYM	Anayasa Mahkemesi
B. No.	Başvuru Numarası
BTK	Bilgi Teknolojileri ve İletişim Kurumu
BVerfG	Bundesverfassungsgericht (Alman Federal Anayasa Mahkemesi)
BVerfGE	Entscheidungen des Bundesverfassungsgerichts (Alman Federal Anayasa Mahkemesi Kararları Dergisi)
bkz.	bakınız
C.	Cilt
CBK	Cumhurbaşkanlığı Kararnamesi
CEPEJ	Avrupa Konseyi Adaletin Etkinliği Avrupa Komisyonu
CETS	Council of Europe Treaty Series (Avrupa Konseyi Antlaşmalar Serisi)
CMK	5271 sayılı Ceza Muhakemesi Kanunu
çev.	çeviren
DC	Décision de conformité (Fransız Anayasa Konseyi norm denetimi kararı)
der.	derleyen
E.	Esas
ECLI	European Case Law Identifier (Avrupa İçtihat Tanımlayıcısı)
EO	Executive Order (ABD Başkanlık Kararnamesi)
FLOP	Floating-point operation (kayan noktalı işlem)
GA	Genel Amaçlı
GDPR / GVKT	Genel Veri Koruma Tüzüğü (AB) 2016/679
GPAI	General-purpose AI (Genel amaçlı yapay zekâ)
HMK	6100 sayılı Hukuk Muhakemeleri Kanunu
İYUK	2577 sayılı İdari Yargılama Usulü Kanunu
K.	Karar

Kısaltma	Açılımı
KVKK	6698 sayılı Kişisel Verilerin Korunması Kanunu
md.	madde
NIST	National Institute of Standards and Technology (ABD Ulusal Standartlar ve Teknoloji Enstitüsü)
OECD	İktisadi İşbirliği ve Kalkınma Örgütü
OTA	Office of Technology Assessment (ABD Teknoloji Değerlendirme Ofisi)
par.	paragraf
RG	Resmî Gazete
RLHF	Reinforcement learning from human feedback (insan geri bildirimiyle pekiştirmeli öğrenme)
s.	sayfa
SM&CR	Senior Managers and Certification Regime (Birleşik Krallık Kıdemli Yöneticiler ve Sertifikasyon Rejimi)
TBK	6098 sayılı Türk Borçlar Kanunu
TBMM	Türkiye Büyük Millet Meclisi
TCK	5237 sayılı Türk Ceza Kanunu
UNESCO	Birleşmiş Milletler Eğitim, Bilim ve Kültür Örgütü
vb.	ve benzeri
VwVfG	Verwaltungsverfahrensgesetz (Alman İdari Usul Kanunu)
YZ	Yapay zekâ
YZT	Avrupa Birliği Yapay Zekâ Tüzüğü (Tüzük (AB) 2024/1689)

GİRİŞ

I. KONUNUN TAKDİMİ: "YAPAY AKIL"IN İKİ ANLAMI

1607 yılının bir pazar sabahı, İngiltere Kralı I. James, ülkenin yargıçlarını huzuruna çağırır. Kral, krallığın adaletinin kaynağı olduğuna göre, dilediği davayı mahkemelerden alıp bizzat karara bağlayabileceğini düşünmektedir. Common Pleas Mahkemesi'nin başkanı Sir Edward Coke'un bu iddiaya verdiği cevap, hukuk tarihinin en çok anılan pasajlarından biri hâline gelecektir. Coke'un kendi kaydına göre, Kral'a şöyle söylemiştir: Tanrı Majestelerine gerçekten de mükemmel bir bilim ve büyük doğal yetenekler bahşetmiştir; ancak Majesteleri İngiltere'nin kanunlarını öğrenmiş değildir ve tebaasının hayatına, mirasına, mallarına veya servetine ilişkin davalar *doğal akılla* değil, *hukukun yapay aklı ve muhakemesiyle* karara bağlanır; hukuk ise bir insanın onu kavrayabilmesi için uzun bir çalışma ve tecrübe gerektiren bir uğraştır.[1]

Coke'un bu cevabı, egemenin yargılama yetkisini, egemenin sahip olmadığı uzmanlaşmış bir akıl biçimi adına sınırlamaktadır. Kral zekidir, hatta "mükemmel bir bilime" sahiptir; ama hukuk, sıradan zekânın değil, eğitimle ve tecrübeyle oluşan "yapay" bir aklın alanıdır. Bu nedenle Kral, yargılamayı bu aklın taşıyıcısı olan hâkimlere bırakmak zorundadır.

Bu tarihî sahne, dört yüz yılı aşkın bir süre sonra beklenmedik bir yankı kazanmaktadır. "Yapay akıl" (*artificial reason*) ifadesi, Coke'un zamanında insan emeğiyle, eğitimle ve kurumsal birikimle inşa edilmiş hukuki muhakemeyi anlatırken, bugün harfiyen makineye ait bir akla, yani *yapay zekâya* işaret etmektedir. Üstelik iki sahne arasındaki ilişki ironik bir tersyüz oluşu da içermektedir. Coke'un argümanında sorun, egemenin uzmanlaşmış akıldan *yoksun* olmasıydı ve çözüm, yetkinin bu aklın taşıyıcılarına bırakılmasıydı. Bugün ise sorun, yapay aklın egemenin ve

[1] Edward Coke, *Prohibitions del Roy* (1607), 12 Co. Rep. 63, 77 Eng. Rep. 1342. Pasajın özgün ifadesi: "causes which concern the life, or inheritance, or goods, or fortunes of his subjects, are not to be decided by natural reason but by the artificial reason and judgment of law, which law is an act which requires long study and experience, before that a man can attain to the cognizance of it." Görüşmenin gerçekte Coke'un aktardığı biçimde geçip geçmediği tarihçiler arasında tartışmalıdır; ancak pasajın anayasal düşünce üzerindeki etkisi bu tartışmadan bağımsızdır.

onun adına karar veren organların kavrayışını *aşabileceği* ihtimalidir. Coke'un mantığı sonuna kadar götürülürse, şu soru kaçınılmaz hâle gelir: Eğer karar yetkisi, kararı en iyi verebilecek akla aitse ve bu akıl artık bir makinede bulunuyorsa, yetki makineye mi geçmelidir?

Bu kitap, söz konusu soruya olumsuz cevap vermekte, fakat bu olumsuz cevabın kolay olmadığını da kabul etmektedir. Coke'un argümanının gücü, yetkiyi bilgiye ve yetkinliğe bağlamasından gelir. Hukuk devleti, keyfi iradenin değil, gerekçeli ve uzmanlaşmış muhakemenin egemenliği olarak anlaşıldığında, daha iyi muhakeme yapabilen bir sistemin karar sürecindeki rolünün büyümesi doğal bir sonuç gibi görünebilir. Ancak Coke'un hâkimleri, bilgilerinin yanı sıra başka bir niteliğe daha sahipti: Onlar da *hesap verebilir* insanlardı. Görevden alınabilir, eleştirilebilir, kararları üst mahkemelerce bozulabilir, nihayetinde parlamento tarafından kanunla düzeltilebilirdi. Yetkinin uzmana devri, uzmanın denetlenebilirliği varsayımı üzerine kurulmuştu. Sorunun özü buradadır: Denetleyenden daha yetkin olan bir varlık nasıl denetlenecektir?

Bu soru, Romalı şair Juvenalis'in yaklaşık iki bin yıl önce sorduğu sorunun çağdaş bir biçimidir: *Quis custodiet ipsos custodes?*, yani "Bekçileri kim bekleyecek?" Juvenalis'in sorusu, iktidarın denetimine ilişkin tüm kuramların ortak paydasıdır. Her denetim mekanizması yeni bir denetleyici yaratır ve her denetleyici, kendisi de denetlenmeye muhtaç bir iktidar odağıdır. Anayasa hukukunun tarihi, bir bakıma, bu sonsuz geriye gidişi (*regressus ad infinitum*) kırmanın yollarını arayan bir tarihtir. Kuvvetler ayrılığı, yargısal denetim, seçimler, basın özgürlüğü ve ombudsmanlık gibi kurumlar, bu arayışın farklı aşamalarda verdiği cevaplardır.

Bu cevapların hepsinin, nadiren açıkça dile getirilen ortak bir varsayımı paylaştığı ileri sürülebilir. Bu çalışmada **"kaba bilişsel denklik varsayımı"** adını verdiğimiz bu varsayıma göre, denetleyen ile denetlenen, aşağı yukarı aynı türden ve aynı ölçüde bir akla sahiptir. Yasama organı, yürütmenin ne yaptığını anlayabilir; yargı, idarenin işleminin hukuka uygun olup olmadığını değerlendirebilir; seçmen, iktidarın icraatını tartabilir; basın, kamu görevlilerinin davranışlarını izleyip yorumlayabilir. Bu denkliğin hiçbir zaman tam olmadığı açıktır. Max Weber'in bürokrasi incelemelerinden bu yana bilindiği gibi, uzman bürokrasi ile onu denetlemekle görevli siyasetçi arasında her zaman ciddi bir bilgi asimetrisi

bulunmuştur.[2] Ancak bu asimetri, *ilke olarak* aşılabilir türdendi: Siyasetçi yeterince zaman ayırır, uzman yardımı alır, soruşturma yetkisini kullanırsa bürokratın bildiğini öğrenebilirdi. Uzmanın bilgisi, denetleyicinin kavrayış sınırları içinde kalan bir bilgiydi.

Yapay zekâ sistemlerinin gelişimi, bu varsayımın ilk kez ilkesel düzeyde sarsılabileceği bir durumu gündeme getirmektedir. Bugün dahi en gelişmiş yapay zekâ sistemlerinin iç işleyişi, onları geliştiren mühendisler tarafından tam olarak anlaşılamamaktadır; bu durum literatürde "kara kutu" (*black box*) sorunu olarak adlandırılmaktadır.[3] Sistemlerin yetenekleri arttıkça, bu sorun, yalnızca teknik bir şeffaflık eksikliği olmaktan çıkıp ilkesel bir kavrayış sınırına dönüşebilir. Bir sistemin önerdiği kararın doğruluğunu değerlendirmek için o sistemle aynı düzeyde düşünebilmek gerekiyorsa ve hiçbir insan ya da insan kurumu bu düzeye erişemiyorsa, klasik anlamda "denetim" neye karşılık gelecektir?

Konunun önemi üç düzlemde ortaya çıkmaktadır. *Pratik düzlemde*, yapay zekâ sistemleri kamu yönetiminde, yargıda, sağlıkta, finansta, güvenlik ve savunmada karar süreçlerine hızla dâhil olmaktadır. İkinci Bölüm'de ayrıntılı olarak ele alınacak olan Avustralya'daki "Robodebt", Hollanda'daki çocuk bakım yardımları skandalı (*toeslagenaffaire*) ve Birleşik Krallık'taki Post Office "Horizon" vakaları gibi örnekler, çok daha basit otomatik sistemlerin bile, yeterli insan denetimi olmaksızın binlerce kişinin hayatını altüst edebildiğini göstermiştir. Sistemlerin karmaşıklığı ve yeteneği arttıkça, bu tür hataları fark etmek ve düzeltmek zorlaşacaktır. *Kuramsal düzlemde*, yapay zekâ, kamu hukukunun temel kavramlarını, yani egemenlik, yetki, otorite, sorumluluk ve meşruiyet kavramlarını yeniden düşünmeye zorlamaktadır. Bu kavramlar, insan failler ve insan kurumları için geliştirilmiştir; insan olmayan, fakat bazı açılardan insandan daha yetenekli bir aktör karşısında nasıl işleyecekleri belirsizdir. *Normatif düzlemde* ise mesele, demokratik yönetimin geleceğine ilişkindir. Eğer karar vericiler, anlamadıkları sistemlerin önerilerini onaylamaktan başka bir şey yapamaz hâle gelirlerse, demokratik meşruiyet içi boşaltılmış bir biçime dönüşecektir. Halkın seçtiği temsilciler karar veriyor gibi

[2] Max Weber, *Wirtschaft und Gesellschaft*, Tübingen, Mohr, 1922, Bürokrasi bahsi; ayrıca bkz. Max Weber, "Parlament und Regierung im neugeordneten Deutschland" (1918), *Gesammelte politische Schriften* içinde. Weber'in bu konudaki görüşleri Birinci Bölüm'de ayrıntılı olarak ele alınacaktır.

[3] Frank Pasquale, *The Black Box Society: The Secret Algorithms That Control Money and Information*, Cambridge (MA), Harvard University Press, 2015.

görünecek, ama kararlar fiilen başka bir yerde, kimsenin tam olarak denetleyemediği bir süreçte oluşacaktır.

Bu çalışmanın konusunu bu noktada daha kesin biçimde belirlemek gerekir. Kitabın sorusu, yapay zekânın genel olarak nasıl düzenlenmesi gerektiği değildir; bu, çok daha geniş ve kapsamlı biçimde başka çalışmalarda ele alınmış bir konudur. Kitabın sorusu, daha dar fakat daha derin bir sorudur: **Yapay zekâ, onu denetlemesi gereken karar vericilerden daha zeki bir aşamaya ulaştığında, onu kim denetlemeli ve ondan kaynaklanan sonuçlar için kimden, nasıl hesap sorulmalıdır?**

II. ARAŞTIRMANIN PROBLEMİ

Araştırmanın merkezî problemi şu şekilde formüle edilebilir:

> Karar vericilerin bilişsel kapasitesini belirli alanlarda veya genel olarak aşan yapay zekâ sistemleri karşısında anlamlı denetim ve hesap sorma nasıl mümkün olabilir; bu denetimi kim, hangi meşruiyet temeline dayanarak ve hangi araçlarla yerine getirmelidir?

Bu merkezî problem, birbirine bağlı dört alt probleme ayrıştırılabilir.

Birinci alt problem epistemiktir. Daha az yetenekli bir fail, daha yetenekli bir failin kararlarını nasıl değerlendirebilir? Bu sorun, felsefede "acemi ve uzman" sorunu olarak bilinir: Bir alanda uzman olmayan biri, iki uzmanın çelişen görüşleri arasında nasıl seçim yapacak ya da tek bir uzmanın güvenilir olup olmadığına nasıl karar verecektir?[4] Yapay zekâ bağlamında bu sorun, "ölçeklenebilir gözetim" (*scalable oversight*) adı altında teknik literatürün de merkezî sorunlarından biri hâline gelmiştir.[5] Epistemik problem, denetimin *mümkün olup olmadığı* sorusudur.

İkinci alt problem normatiftir. Zekâ üstünlüğü, karar yetkisi için bir gerekçe oluşturur mu? Platon'un filozof-krallarından John Stuart Mill'in çoğul oy önerisine ve günümüzün "epistokrasi" tartışmalarına kadar uzanan bir gelenek, en bilgili olanın yönetmesi gerektiğini savunmuştur.[6] Bu gelenek doğruysa, insanlardan daha zeki bir yapay zekânın yönetmesi, en

[4] Alvin I. Goldman, "Experts: Which Ones Should You Trust?", *Philosophy and Phenomenological Research*, C. 63, S. 1, 2001.

[5] Samuel R. Bowman vd., "Measuring Progress on Scalable Oversight for Large Language Models", arXiv:2211.03540, 2022.

[6] Platon, *Devlet*, V. Kitap, 473c-d; John Stuart Mill, *Considerations on Representative Government*, London, Parker, Son and Bourn, 1861, VIII. Bölüm; Jason Brennan, *Against Democracy*, Princeton, Princeton University Press, 2016.

azından bazı alanlarda, meşru olabilir. Bu gelenek yanlışsa, neden yanlış olduğunun açıklanması gerekir; zira "sonuçları daha iyi olacak bir yönetimi neden reddedelim?" sorusu, ciddi bir sorudur. Normatif problem, denetimin *gerekli olup olmadığı* ve *neden gerekli olduğu* sorusudur.

Üçüncü alt problem kurumsaldır. Denetimi hangi kurumlar, hangi yetkilerle ve hangi usullerle yerine getirmelidir? Mevcut anayasal kurumlar (parlamento, yargı, bağımsız idari otoriteler, ombudsman) bu görevi yerine getirebilecek kapasiteye sahip midir? Yeni kurumlar gerekli midir? Ulusal düzeyde mi, uluslararası düzeyde mi denetim yapılmalıdır? Kurumsal problem, denetimin *nasıl* gerçekleştirileceği sorusudur.

Dördüncü alt problem sorumlulukla ilgilidir. Yapay zekâ sistemlerinin kararları veya önerileri sonucunda bir zarar meydana geldiğinde, bu zarardan kim sorumlu tutulacaktır? Klasik sorumluluk hukuku, kusur, nedensellik ve öngörülebilirlik kavramları üzerine kuruludur. Kendi kendine öğrenen ve davranışı geliştiricileri tarafından tam olarak öngörülemeyen sistemler karşısında bu kavramlar nasıl işleyecektir? Literatürde "sorumluluk boşluğu" (*responsibility gap*) olarak adlandırılan bu sorun, hesap sormanın *kimden* yapılacağı sorusudur.[7]

Bu dört alt problemin birbirinden bağımsız olmadığı açıktır. Epistemik problemin çözümsüz olduğu sonucuna varılırsa, kurumsal problem çok farklı bir biçim alacaktır. Normatif problemde epistokratik bir sonuca varılırsa, denetimin amacı değişecektir. Sorumluluk problemi ise diğer üçünün çözümüne bağlıdır: Kimin denetim yükümlülüğü taşıdığı belirlenmeden, kimin sorumlu olduğu belirlenemez.

III. ARAŞTIRMA SORULARI VE HİPOTEZLER

A. Araştırma Soruları

Çalışma, yukarıdaki problemler çerçevesinde aşağıdaki araştırma sorularına cevap aramaktadır:

S1. "Bekçileri kim bekleyecek?" sorusuna tarih boyunca verilen klasik cevaplar hangi varsayımlara dayanmaktadır ve bu varsayımlar, karar vericileri aşan yapay zekâ karşısında ne ölçüde geçerliliğini korumaktadır?

[7] Andreas Matthias, "The Responsibility Gap: Ascribing Responsibility for the Actions of Learning Automata", *Ethics and Information Technology*, C. 6, S. 3, 2004.

S2. Bilişsel kapasite bakımından üstün bir sistemi, daha az yetenekli bir fail ya da kurum hangi yollarla ve hangi sınırlar içinde denetleyebilir?

S3. Zekâ veya yetkinlik üstünlüğü, siyasi ve hukuki karar yetkisi için meşru bir gerekçe oluşturabilir mi?

S4. Türk anayasa ve idare hukukunun mevcut kurumları, karar süreçlerinde kullanılan ileri yapay zekâ sistemlerinin denetimi bakımından hangi imkânları ve hangi eksiklikleri barındırmaktadır?

S5. Yapay zekâ sistemlerinden kaynaklanan zararlar bakımından sorumluluk hangi aktörlere, hangi hukuki temellerde yüklenmelidir? Yapay zekâya hukuki kişilik tanınması bu soruna çözüm olabilir mi?

S6. Karşılaştırmalı hukukta ve uluslararası düzeyde geliştirilen düzenleyici modeller, bu sorulara nasıl cevap vermektedir ve Türk hukuku bu modellerden hangi dersleri çıkarabilir?

S7. Juvenalis'in sonsuz geriye gidiş sorununu yapay zekâ bağlamında aşabilecek tutarlı bir denetim ve hesap sorma mimarisi nasıl tasarlanabilir?

B. Hipotezler

Çalışma, bu sorulara ilişkin olarak aşağıdaki hipotezleri sınamaktadır:

H1 (Kaba Bilişsel Denklik Hipotezi). Klasik denetim kuramlarının tamamı, örtük olarak denetleyen ile denetlenen arasında kaba bir bilişsel denklik bulunduğu varsayımına dayanır. Bu varsayım zayıfladığında, denetlenen kararın doğruluğunun bizzat değerlendirilmesine dayanan *sonuç denetimi* işlevini kaybetmeye başlar; buna karşılık kararın *sürecine*, sistemin *girdilerine* ve sistemin *varlık koşullarına* yönelik denetim, işlevini önemli ölçüde korur.

H2 (Yetki-Zekâ Ayrılığı Hipotezi). Zekâ veya yetkinlik üstünlüğü, *teorik* (epistemik) otorite için gerekçe oluşturabilir; yani bir sistemin görüşlerine inanmak için iyi bir neden olabilir. Ancak bu üstünlük, *pratik* (siyasi) otorite için, yani bir sistemin buyruklarına uymak için yeterli bir gerekçe oluşturmaz. Siyasi otoritenin meşruiyeti, yetkinliğin yanı sıra eşitlik, rıza, hesap verebilirlik ve düzeltilebilirlik koşullarına bağlıdır.

H3 (Anayasal Dayanak Hipotezi). Türk anayasa düzeninde Anayasa'nın 6. maddesinin üçüncü fıkrası ("Hiçbir kimse veya organ kaynağını Anayasadan almayan bir Devlet yetkisi kullanamaz.") ve 7. maddesi ("Bu yetki devredilemez.") ile yargı yetkisine ilişkin 9. ve 138.

maddeleri, nihai karar yetkisinin yapay zekâ sistemlerine devrini yasaklayan pozitif hukuk dayanakları içermektedir. Bu dayanaklar, yorum yoluyla "insan nihai karar ilkesi"nin anayasal temelini oluşturabilir.

H4 (İnsan Sorumluluğu Hipotezi). Hesap sorma, yapay zekânın kendisine değil, onu tasarlayan, eğiten, piyasaya süren, kullanan ve denetleyen insanlara ve kurumlara yönelmelidir. Yapay zekâya elektronik kişilik tanınması, sorumluluk boşluğunu kapatmaz; aksine sorumluluğu insan aktörlerden uzaklaştırarak "buharlaştırma" riski taşır.

H5 (Dairesel Denetim Hipotezi). Juvenalis'in sonsuz geriye gidiş sorunu, doğrusal ve hiyerarşik bir denetim zinciriyle, yani "en üstteki bekçi" aranarak aşılamaz. Bu sorun, çoğulcu, karşılıklı ve dairesel bir denetim mimarisiyle; her aşamada kararların geri alınabilirliğini ve sistemlerin durdurulabilirliğini güvence altına alan bir yapıyla aşılabilir.

IV. KAPSAM VE SINIRLAR

Çalışmanın kapsamının belirlenmesi, konunun genişliği karşısında özel bir önem taşımaktadır. Bu nedenle aşağıdaki sınırlamalar benimsenmiştir.

Birincisi, çalışma, yapay zekânın *kamusal karar alma* süreçlerindeki rolüne odaklanmaktadır. "Karar verici" kavramı, esas olarak yasama, yürütme ve yargı organlarında kamu gücü kullanan kişi ve kurulları ifade etmektedir. Bununla birlikte, ileri yapay zekâ sistemlerini geliştiren ve kontrol eden özel şirketlerin yöneticileri de, fiilen kamusal sonuçları olan kararlar aldıkları ölçüde incelemeye dâhil edilmiştir. Zira Dördüncü Bölüm'de gösterileceği üzere, "yapay zekâyı kim denetleyecek?" sorusu pratikte çoğu zaman "yapay zekâyı elinde tutanları kim denetleyecek?" sorusuna dönüşmektedir.

İkincisi, çalışma, özellikle "sınır" (*frontier*) yapay zekâ sistemleri olarak adlandırılan, en gelişmiş ve en genel amaçlı sistemlere odaklanmaktadır. Basit kural tabanlı otomasyon sistemleri, ancak daha gelişmiş sistemlerin yol açacağı sorunlara ışık tuttukları ölçüde, özellikle de vaka incelemeleri bağlamında ele alınmıştır.

Üçüncüsü, çalışma, yapay zekânın ne zaman ve hangi biçimde insan karar vericileri aşacağına ilişkin bir *öngörüde* bulunmamaktadır. Bu konu, uzmanlar arasında derin görüş ayrılıklarının bulunduğu, ampirik olarak belirsiz bir konudur. Çalışmanın yaklaşımı, koşullu bir yaklaşımdır: "Eğer yapay zekâ karar vericileri aşarsa" sorusu, hem kısmi ve alana özgü aşma

durumlarını (ki bunlar bugün itibarıyla birçok alanda gerçekleşmiş durumdadır) hem de genel ve kapsamlı aşma durumlarını (ki bunlar spekülatif olmakla birlikte ciddi bir olasılık olarak tartışılmaktadır) kapsayacak şekilde ele alınmıştır. Hukuk, çoğu zaman gerçekleşme ihtimali belirsiz durumlara karşı önceden kurumlar tasarlamak zorundadır; bu çalışma da aynı ihtiyat mantığıyla hareket etmektedir.

Dördüncüsü, otonom silah sistemleri ve askerî yapay zekâ kullanımı, kendine özgü uluslararası insancıl hukuk sorunları doğurduğundan, ayrıntılı olarak incelenmemiş; yalnızca "anlamlı insan kontrolü" kavramının gelişimi bakımından ele alınmıştır.

Beşincisi, yapay zekâ güvenliği alanındaki teknik yöntemler, hukukçu ve siyaset bilimci okurun anlayabileceği bir düzeyde ve yalnızca denetim sorununa ilişkin sonuçları bakımından incelenmiştir. Çalışma, bir mühendislik çalışması değildir; ancak teknik gerçekliği göz ardı eden bir hukuki analizin de yetersiz kalacağı kabul edilmiştir.

Altıncısı, karşılaştırmalı hukuk incelemesi; Avrupa Birliği, Avrupa Konseyi, Amerika Birleşik Devletleri, Birleşik Krallık, Almanya, Fransa ve Çin ile sınırlı tutulmuştur. Bu seçim, söz konusu hukuk düzenlerinin yapay zekâ düzenlemesindeki öncü konumları ve Türk hukuku ile olan tarihsel ve kurumsal bağları dikkate alınarak yapılmıştır.

Son olarak, çalışmada 2026 yılı Ekim ayı itibarıyla ulaşılabilen mevzuat, içtihat ve literatür esas alınmıştır. Yapay zekâ düzenlemesinin hızla değiştiği dikkate alındığında, bazı düzenlemelerin yürürlük ve uygulama durumlarının okuma anında farklılaşmış olabileceği hatırda tutulmalıdır.

V. YÖNTEM

Çalışmanın konusu, doğası gereği disiplinlerarası bir yaklaşımı gerektirmektedir. Bu nedenle tek bir yöntem yerine, her bölümün konusuna uygun yöntemlerin bir arada kullanıldığı çoğulcu bir yöntem benimsenmiştir.

Hukuk dogmatiği (normatif-dogmatik yöntem). Beşinci ve Altıncı Bölümlerde, yürürlükteki hukuk kuralları, özellikle 1982 Anayasası, idare hukuku, borçlar hukuku ve ceza hukuku düzenlemeleri, yerleşik yorum yöntemleri (lafzi, sistematik, tarihsel ve amaçsal yorum) kullanılarak incelenmiştir. Bu incelemede, mevcut hukukun (*de lege lata*) ne söylediği

ile olması gereken hukukun (*de lege ferenda*) ne olması gerektiği sorusu birbirinden açıkça ayrılmıştır.

Karşılaştırmalı hukuk yöntemi. Yedinci Bölüm'de, Zweigert ve Kötz'ün sistemleştirdiği *fonksiyonel karşılaştırma* yöntemi benimsenmiştir.[8] Bu yönteme göre karşılaştırma, kurumların adları veya biçimleri arasında değil, aynı toplumsal soruna farklı hukuk düzenlerinin verdiği cevaplar arasında yapılır. Burada ortak sorun, ileri yapay zekâ sistemlerinin denetimi ve bunlardan doğan zararların hesabının sorulmasıdır.

Kavram tarihi yöntemi. Birinci Bölüm'de, "bekçiler sorunu"nun tarihsel gelişimi, Reinhart Koselleck'in kavram tarihi (*Begriffsgeschichte*) yaklaşımından esinlenerek incelenmiştir.[9] Bu yaklaşım, kavramların tarih boyunca kazandığı anlamları ve bu anlamların siyasal-toplumsal deneyimle ilişkisini ortaya koymayı amaçlar. Böylece "denetim", "egemenlik" ve "sorumluluk" gibi kavramların yapay zekâ bağlamında hangi yeni anlamları kazanabileceği daha iyi anlaşılabilir.

Normatif siyaset felsefesi yöntemi. Üçüncü ve Dördüncü Bölümlerde, argümanların değerlendirilmesinde John Rawls'un "düşünümsel denge" (*reflective equilibrium*) yöntemi esas alınmıştır.[10] Bu yönteme göre, genel ilkeler ile somut durumlara ilişkin ahlaki yargılarımız karşılıklı olarak birbirine göre düzeltilir ve aralarında tutarlılık sağlanmaya çalışılır. Örneğin "daha zeki olanın yönetmesi gerekir" genel ilkesi, bu ilkenin somut uygulamalarına ilişkin sezgilerimizle (örneğin en zeki yurttaşa daha fazla oy hakkı verilmesinin kabul edilemez göründüğü yönündeki sezgiyle) karşılaştırılarak sınanmıştır.

Vaka analizi yöntemi. İkinci Bölüm'de, otomatik ve algoritmik karar sistemlerinin kamu yönetiminde yol açtığı başarısızlıklar, vaka analizi yöntemiyle incelenmiştir. Bu vakalar, mahkeme kararları, resmî soruşturma raporları ve parlamento raporları gibi birincil kaynaklara dayanılarak değerlendirilmiş; her vakadan denetim sorununa ilişkin dersler çıkarılmıştır.

---

[8] Konrad Zweigert / Hein Kötz, *Einführung in die Rechtsvergleichung auf dem Gebiete des Privatrechts*, 3. Bası, Tübingen, Mohr Siebeck, 1996, özellikle § 3.

[9] Reinhart Koselleck, *Vergangene Zukunft: Zur Semantik geschichtlicher Zeiten*, Frankfurt am Main, Suhrkamp, 1979.

[10] John Rawls, *A Theory of Justice*, Cambridge (MA), Harvard University Press, 1971, § 9.

Model geliştirme. Sekizinci Bölüm'de, önceki bölümlerin bulgularına dayanarak bir denetim ve hesap sorma modeli geliştirilmiş ve bu model Türk hukukuna uyarlanmış bir kanun önerisi taslağı biçiminde somutlaştırılmıştır. Bu kısım, çalışmanın *de lege ferenda* boyutunu oluşturmaktadır.

VI. KAVRAMSAL ÖN AÇIKLAMALAR

Çalışma boyunca sıkça kullanılacak bazı kavramların başlangıçta açıklığa kavuşturulması, terminolojik karışıklıkları önleyecektir. Bu kavramların ayrıntılı analizi ilgili bölümlerde yapılacaktır; burada yalnızca çalışmadaki kullanımları belirtilmektedir.

A. Denetim

Türkçede "denetim" kelimesi, İngilizcedeki *control*, *oversight*, *supervision*, *review* ve *audit* kavramlarının hepsini karşılayacak biçimde kullanılmaktadır. Oysa bu kavramlar arasında önemli farklar vardır. *Control*, bir şeyin davranışını belirleme ve yönlendirme gücünü; *oversight*, bir faaliyeti üstten izleme ve gerektiğinde müdahale etme yetkisini; *review*, alınmış bir kararın sonradan incelenmesini; *audit* ise belirli standartlara uygunluğun sistematik olarak sınanmasını ifade eder. Bu çalışmada "denetim" kelimesi, bu anlamların tümünü kapsayan genel bir üst kavram olarak kullanılmakta; gerektiğinde "kontrol", "gözetim", "yargısal denetim" veya "inceleme" gibi daha özel terimlere başvurulmaktadır. Özellikle yapay zekâ güvenliği literatüründeki "kontrol sorunu" (*control problem*) ifadesi, insanların kendilerinden daha yetenekli bir sistemi istedikleri yönde tutabilme sorunu anlamında, "kontrol" kelimesiyle karşılanmıştır.[11]

Çalışmanın özgün katkılarından biri, **denetimin nesnesine** göre yapılan dörtlü bir ayrımdır. Bu ayrım, Sekizinci Bölüm'de ayrıntılı olarak geliştirilecek olmakla birlikte, çalışmanın tamamında kullanılacağı için burada kısaca belirtilmektedir:

1. **Sonuç denetimi:** Bir kararın veya çıktının içerik bakımından doğru, isabetli veya hukuka uygun olup olmadığının değerlendirilmesi.
2. **Süreç denetimi:** Kararın hangi usulle, hangi gerekçelerle, hangi verilere dayanarak ve hangi kurallara uyularak alındığının değerlendirilmesi.

[11] Nick Bostrom, *Superintelligence: Paths, Dangers, Strategies*, Oxford, Oxford University Press, 2014, özellikle 9. Bölüm ("The Control Problem").

3. **Girdi denetimi:** Sistemin var olabilmesi ve işleyebilmesi için gerekli kaynakların (hesaplama gücü, veri, enerji, sermaye, insan emeği) kontrol edilmesi.
4. **Varlık koşulları denetimi:** Sistemin hangi koşullarda kullanılabileceğinin, hangi koşullarda durdurulacağının, değiştirileceğinin veya kullanımdan kaldırılacağının belirlenmesi ve bu kararların uygulanabilirliğinin güvence altına alınması.

B. Hesap Verebilirlik ve Hesap Sorma

"Hesap verebilirlik" (*accountability*), bir aktörün davranışını bir foruma açıklamak ve gerekçelendirmek yükümlülüğü altında bulunduğu, forumun soru sorabildiği ve yargıda bulunabildiği, aktörün de bunun sonuçlarıyla karşılaşabildiği bir ilişki olarak tanımlanmaktadır.[12] "Hesap sorma" ise bu ilişkinin forum tarafından işletilmesidir. Bu tanım, hesap verebilirliğin üç unsuru olduğunu gösterir: *bilgilendirme ve gerekçelendirme* (açıklama yükümlülüğü), *sorgulama ve değerlendirme* (forumun yargısı) ve *sonuç* (yaptırım veya düzeltme). Altıncı Bölüm'de gösterileceği üzere, yapay zekâ sistemleri bu unsurların her biri bakımından özgün sorunlar doğurmaktadır.

C. Sorumluluk

"Sorumluluk" kavramı, İngilizcedeki *responsibility* ve *liability* kavramlarını karşılamaktadır. *Responsibility*, ahlaki ve genel bir sorumluluğu, bir kişinin bir eylemin veya sonucun "sahibi" sayılmasını; *liability* ise hukuki sorumluluğu, yani bir zararı tazmin etme veya bir yaptırıma katlanma yükümlülüğünü ifade eder. H. L. A. Hart, sorumluluk kavramının dört farklı anlamını ayırmıştır: rol sorumluluğu (*role-responsibility*), nedensel sorumluluk (*causal-responsibility*), hukuki sorumluluk (*liability-responsibility*) ve yetenek sorumluluğu (*capacity-responsibility*).[13] Bu ayrım, yapay zekâ bağlamında son derece aydınlatıcıdır: Bir yapay zekâ sistemi bir zararın *nedensel* sorumlusu olabilir; ancak *yetenek* sorumluluğu (yani sorumlu tutulmayı anlamlı kılan zihinsel kapasiteler) ve dolayısıyla *hukuki* sorumluluk bakımından durum çok daha tartışmalıdır. Bu çalışmada "sorumluluk" kelimesi, bağlamına göre bu anlamlardan biriyle kullanılmakta ve gerektiğinde hangi anlamın kastedildiği belirtilmektedir.

[12] Mark Bovens, "Analysing and Assessing Accountability: A Conceptual Framework", *European Law Journal*, C. 13, S. 4, 2007.
[13] H. L. A. Hart, *Punishment and Responsibility: Essays in the Philosophy of Law*, Oxford, Clarendon Press, 1968, IX. Bölüm ("Postscript: Responsibility and Retribution").

D. Karar Verici

"Karar verici" kavramı, bu çalışmada, kamu gücü kullanarak bağlayıcı kararlar alan kişi ve kurulları ifade etmektedir: yasama organı üyeleri, Cumhurbaşkanı ve bakanlar, idari makamlar, hâkimler, bağımsız idari otoritelerin karar organları. Bunlara ek olarak, ileri yapay zekâ sistemleri üzerinde fiilî kontrol yetkisine sahip özel şirket yöneticileri, kararları geniş kamusal sonuçlar doğurduğu ölçüde, bu kavram kapsamında değerlendirilmektedir.

E. "Daha Zeki" Olmak

Yapay zekânın karar vericilerden "daha zeki" olması ifadesi, ilk bakışta göründüğünden çok daha karmaşıktır. Zekâ, tek boyutlu bir nicelik değildir; hesaplama hızı, bilgi genişliği, akıl yürütme derinliği, yaratıcılık, sosyal kavrayış, uzun vadeli planlama ve pratik bilgelik gibi birçok boyutu vardır. Bir sistem bazı boyutlarda insanı aşarken diğerlerinde geride kalabilir. İkinci Bölüm'de bu konu ayrıntılı olarak ele alınacaktır. Bu çalışmada "karar vericileri aşmak" ifadesi, şu anlamda kullanılmaktadır: Bir yapay zekâ sistemi, belirli bir karar alanında, o alandaki insan karar vericilerin, makul zaman ve kaynaklarla, sistemin çıktılarının doğruluğunu bağımsız olarak değerlendiremeyecekleri bir başarım düzeyine ulaştığında, o alanda karar vericileri aşmış sayılır. Bu tanım, zekânın kendisinden çok, *denetim bakımından* önemli olan özelliğe, yani değerlendirilebilirliğe odaklanmaktadır. Bu anlamda "aşma", mutlak bir eşik değil, bir yelpazedir ve kısmen gerçekleşmiş bir durumdur.

F. Yapay Zekâ Sistemi ve Sınır Model

"Yapay zekâ sistemi" kavramı için, çalışmada Avrupa Birliği Yapay Zekâ Tüzüğü'nün 3. maddesinin (1) numaralı bendinde yer alan ve OECD tanımından esinlenen tanım esas alınmaktadır. Buna göre yapay zekâ sistemi; değişen düzeylerde özerklikle çalışmak üzere tasarlanmış, kullanıma sunulduktan sonra uyum gösterebilen ve açık veya örtük hedefler doğrultusunda, aldığı girdiden, fiziksel veya sanal ortamları etkileyebilecek tahminler, içerik, öneriler veya kararlar gibi çıktıların nasıl üretileceğini çıkarsayan makine tabanlı bir sistemdir.[14] "Sınır model" (*frontier model*) ise

[14] Tüzük (AB) 2024/1689, md. 3(1). OECD tanımı için bkz. OECD, *Recommendation of the Council on Artificial Intelligence*, OECD/LEGAL/0449, 2019 (2023 ve 2024 güncellemeleriyle).

belirli bir zamanda en ileri yetenek düzeyindeki, genellikle çok büyük hesaplama kaynaklarıyla eğitilmiş genel amaçlı modelleri ifade etmektedir.[15]

G. Algoritmik Vesayet

Çalışmada önerilen özgün kavramlardan biri olan "algoritmik vesayet", Dördüncü Bölüm'de ayrıntılı olarak geliştirilecektir. Kavram, Türk siyasi ve anayasal tartışmalarında yerleşik bir yeri olan "vesayet" kavramından hareketle, seçilmiş karar vericilerin, biçimsel olarak karar yetkisini ellerinde tutmalarına rağmen, fiilen kendilerinin denetleyemediği algoritmik sistemlerin önerilerine bağımlı hâle geldikleri durumu ifade etmektedir. Klasik vesayetten farkı, vesayeti uygulayan bir iradenin bulunmaması, vesayetin bir bilgi ve yetkinlik asimetrisi üzerinden, çoğu zaman karar vericilerin kendi tercihleriyle kurulmasıdır.

VII. ÇALIŞMANIN PLANI

Çalışma, giriş ve sonuç kısımları dışında sekiz bölümden oluşmaktadır.

Birinci Bölüm, "Kadim Bir Sorunun Soykütüğü" başlığını taşımakta ve "bekçileri kim bekleyecek?" sorusunun Antik Çağ'dan modern anayasacılığa uzanan gelişimini incelemektedir. Bu bölümde Platon, Aristoteles ve Juvenalis'ten başlayarak Ortaçağ'ın hükümdar-hukuk tartışmalarına, Locke, Montesquieu ve Federalistlerin kuvvetler ayrılığı kuramlarına, Jellinek, Kelsen ve Schmitt'in egemenlik ve anayasa yargısı tartışmalarına ve Popper'in "kim yönetmeli?" sorusunu reddeden yaklaşımına kadar uzanan geniş bir düşünce geleneği ele alınmaktadır. Bölüm, Weber'in bürokrasi analizi ve teknokrasi tartışmaları üzerinden bilgi asimetrisinin tarihsel biçimlerini inceleyerek, klasik cevapların ortak varsayımı olan "kaba bilişsel denklik" tezini ortaya koymaktadır.

İkinci Bölüm, "Karar Vericileri Aşan Yapay Zekâ" başlığı altında, çalışmanın olgusal zeminini oluşturmaktadır. Bu bölümde yapay zekâ kavramı ve gelişimi, algoritmik karar sistemlerinin kamu yönetimine nüfuzu ve bu süreçte yaşanan başarısızlıklar, insan denetiminin bilişsel sınırları (otomasyon yanlılığı, otomasyonun ironileri, ahlaki çarpışma

[15] Markus Anderljung vd., "Frontier AI Regulation: Managing Emerging Risks to Public Safety", arXiv:2307.03718, 2023.

bölgeleri) ve yapay zekâ güvenliği literatüründeki “hizalama sorunu” incelenmektedir.

Üçüncü Bölüm, felsefi perspektifi ele almaktadır. Epistokrasi tartışması, otorite kuramı, özerklik ve insan onuru, sorumluluk etiği ve yapay zekânın ahlaki statüsü bu bölümün konularıdır. Bölüm, “zekâ yetki doğurmaz” ilkesinin felsefi temellendirilmesiyle sona ermektedir.

Dördüncü Bölüm, siyasi perspektifi ele almaktadır. Teknolojinin siyaseti, kodun düzenleyici gücü, platform egemenliği, güç yoğunlaşması ve demokratik gerileme riskleri, uluslararası yarış dinamikleri ve demokratik denetimin yeniden tasarlanmasına ilişkin öneriler bu bölümde incelenmektedir.

Beşinci Bölüm, hukuki perspektifin ilk ayağını oluşturmakta ve anayasal ve idari denetimi ele almaktadır. Egemenlik ve yetki devri yasağı, algoritmik idari işlem, yargısal denetim ve yargıda yapay zekâ kullanımı, yasama denetimi, bağımsız idari otoriteler ve temel haklar bu bölümün konularıdır.

Altıncı Bölüm, hukuki perspektifin ikinci ayağını oluşturmakta ve sorumluluk ve hesap sormayı ele almaktadır. Hesap verebilirlik kavramı, özel hukuk sorumluluğu, ceza sorumluluğu, idarenin sorumluluğu, elektronik kişilik tartışması ve geliştirici şirketlerin kurumsal yönetişimi bu bölümde incelenmektedir.

Yedinci Bölüm, karşılaştırmalı hukuk ve uluslararası düzenlemeleri ele almaktadır. Avrupa Birliği Yapay Zekâ Tüzüğü, Avrupa Konseyi Çerçeve Sözleşmesi, Amerika Birleşik Devletleri, Birleşik Krallık ve Çin’deki düzenlemeler, küresel yönetişim girişimleri ve Türkiye’deki mevcut durum bu bölümde değerlendirilmektedir.

Sekizinci Bölüm, çalışmanın sentez ve öneri bölümüdür. Bu bölümde önceki bölümlerin bulgularına dayanarak “çok katmanlı dairesel denetim modeli” geliştirilmekte, bu modelin temel ilkeleri, katmanları ve hesap sorma rejimi açıklanmakta ve Türk hukuku için gerekçeli bir kanun önerisi taslağı sunulmaktadır. Bölüm, modele yöneltilebilecek muhtemel itirazların cevaplandırılmasıyla ve Juvenalis’in sorusuna geri dönülerek sona ermektedir.

Sonuç kısmında ise çalışmanın bulguları, araştırma soruları ve hipotezlerle ilişkilendirilerek tezler hâlinde özetlenmektedir.

BİRİNCİ BÖLÜM: KADİM BİR SORUNUN SOYKÜTÜĞÜ — BEKÇİLERİ KİM BEKLEYECEK?

Bu bölümün amacı, yapay zekânın denetimi sorununu, siyasal düşünce tarihinin en eski ve en kalıcı sorularından birinin, “bekçiler sorunu”nun yeni bir biçimi olarak konumlandırmaktır. Bu konumlandırma, iki bakımdan gereklidir. Birincisi, yapay zekâ tartışmalarında sıkça rastlanan “eşi benzeri görülmemiş bir sorunla karşı karşıyayız” söylemi, kısmen doğru olmakla birlikte, insanlığın iktidarı denetleme konusunda yüzyıllar boyunca biriktirdiği deneyimi görünmez kılma tehlikesi taşımaktadır. Oysa bu deneyim, yeni sorunun hangi yönlerinin gerçekten yeni, hangilerinin tanıdık olduğunu anlamak için vazgeçilmezdir. İkincisi, klasik cevapların hangi varsayımlara dayandığının açıkça ortaya konması, bu varsayımların yapay zekâ karşısında hangi noktalarda zorlandığını tespit etmenin tek yoludur.

Bölüm, kronolojik bir sırayı izlemekle birlikte, bir düşünce tarihi özeti olmayı amaçlamamaktadır. Her düşünür, bekçiler sorununa verdiği özgün cevap ve bu cevabın yapay zekâ bağlamındaki anlamı bakımından ele alınmaktadır. Bölümün sonunda, bu cevapların ortak paydası olan “kaba bilişsel denklik varsayımı” açıkça formüle edilecek ve hangi klasik araçların bu varsayımın çöküşünden etkilenmeyeceği gösterilecektir.

§ 1. ANTİK DÜŞÜNCEDE BEKÇİLER SORUNU

I. Juvenalis ve Sorunun Doğuşu

Sorunun en bilinen formülasyonu, Romalı hiciv şairi Decimus Iunius Iuvenalis’e (MS I-II. yüzyıl) aittir. Juvenalis’in on altı hicivden oluşan *Saturae* adlı eserinin altıncı hicvi, Postumus adlı bir arkadaşını evlenmekten vazgeçirmeye çalışan, bugünkü değer yargılarıyla bağdaşması mümkün olmayan bir kadın düşmanlığıyla yazılmış uzun bir metindir. Ünlü dizeler bu bağlamda geçer: Sadakatsizlikten korkan bir koca, karısını evde tutmak için kapıya kilit vurmayı ve başına bekçiler koymayı düşünür; şair

ise şöyle karşılık verir: "*Pone seram, cohibe. Sed quis custodiet ipsos custodes? Cauta est et ab illis incipit uxor.*" Yani: "Sürgüyü çek, onu kapat. Ama bekçileri kim bekleyecek? Kadın kurnazdır ve işe onlardan başlar."[16]

Dizelerin özgün bağlamı siyasi değildir; ancak içerdiği mantıksal yapı, siyasal düşüncenin tam merkezine oturur. Juvenalis'in argümanı iki adımlıdır. İlk adımda, bir tehlikeye karşı bir denetçi konur. İkinci adımda, denetçinin kendisinin de aynı tehlikeye açık olduğu, yani ayartılabileceği, kandırılabileceği veya işbirliğine çekilebileceği gösterilir. Bu durumda denetçinin denetlenmesi gerekir; fakat yeni denetçi de aynı sorunla karşı karşıyadır. Mantıksal olarak bu zincir sonsuza dek uzar. Dahası, Juvenalis'in dizesinin ikinci yarısı ("işe onlardan başlar") son derece önemli bir noktaya işaret eder: Denetlenen, denetçiyi etkisiz kılmayı ilk hedef olarak seçer. Denetimden kurtulmak isteyen bir aktör için en rasyonel strateji, denetçiyi kendi tarafına çekmektir.

Bu iki gözlem, yapay zekâ bağlamında dikkat çekici bir güncellik kazanmaktadır. İkinci Bölüm'de ayrıntılı olarak ele alınacak olan "aldatıcı uyum" (*deceptive alignment*) ve "denetçiyle işbirliği" (*collusion*) sorunları, Juvenalis'in hicvinin teknik bir yeniden ifadesi gibidir. Yeterince yetenekli bir sistem, denetlendiğini fark edip denetim sırasında farklı, denetim dışında farklı davranabilir; ya da başka bir yapay zekânın denetimi altındaysa, onunla örtük bir uzlaşmaya varabilir. "Kadın kurnazdır ve işe onlardan başlar" dizesindeki kadın düşmanı önyargıyı bir kenara bıraktığımızda, geriye kalan çekirdek, denetim kuramının belki de en temel ilkesidir: *Her denetim mekanizması, denetlenenin stratejik tepkisini hesaba katmak zorundadır*.

Juvenalis'in sorusu, Rönesans'tan itibaren özgün bağlamından koparılarak siyasi bir anlam kazanmış ve iktidarın denetimi sorununun simgesi hâline gelmiştir. Bugün bu soru, polisin denetiminden istihbarat servislerinin gözetimine, anayasa mahkemelerinin meşruiyetinden uluslararası örgütlerin hesap verebilirliğine kadar geniş bir alanda anılmaktadır. Ancak sorunun asıl felsefi derinliği, Juvenalis'ten yüzyıllar önce Platon tarafından fark edilmiş ve farklı bir yoldan çözülmeye çalışılmıştır.

[16] Juvenalis, *Saturae*, VI, 347-348. Bu dizeler, 1899'da E. O. Winstedt tarafından Oxford'daki Bodleian Kütüphanesi'nde bulunan bir elyazmasında yer alan ve "Oxford parçası" olarak bilinen bölümde (O 31-32) geçmektedir; modern baskıların bir kısmı dizeleri bu numaralandırmayla vermektedir.

II. Platon: Bekçilerin Eğitimi ve Bilenin Egemenliği

A. Devlet'te Bekçiler

Platon'un *Devlet* (*Politeia*) adlı diyaloğunda tasarlanan ideal şehir, üç sınıftan oluşur: üreticiler, yardımcılar (askerler) ve yöneticiler. Yardımcılar ve yöneticiler birlikte "bekçiler" (*phylakes*) olarak adlandırılır. Bekçilerin görevi, şehri hem dış düşmanlara hem de iç bozulmaya karşı korumaktır. Platon, bekçilerin gücünün kötüye kullanılabileceği tehlikesinin farkındadır. Diyaloğun üçüncü kitabında, Sokrates bekçilerin sarhoşluktan kaçınması gerektiğini söylerken muhatabı Glaukon şöyle karşılık verir: "Bekçinin bir bekçiye ihtiyaç duyması gerçekten gülünç olurdu."[17]

Bu cümle, Juvenalis'in sorusunun felsefi atası sayılabilir; ancak Platon'un tutumu Juvenalis'inkinin tam tersidir. Juvenalis için bekçinin bekçiye ihtiyaç duyması kaçınılmaz bir gerçekliktir; Platon için ise ideal şehirde ortadan kaldırılması gereken bir saçmalıktır. Platon, sorunu bekçilerin üzerine yeni bir denetim katmanı koyarak değil, bekçilerin *kendisini* güvenilir kılarak çözmeye çalışır. Bu amaçla üç araç önerir.

Birinci araç eğitimdir (*paideia*). Bekçiler, çocukluktan itibaren müzik, jimnastik ve nihayet felsefe eğitimiyle yetiştirilecek, ruhları doğru değerlerle biçimlendirilecektir. Platon'a göre iyi eğitilmiş bir bekçi, gücünü kötüye kullanmayı istemeyecektir; çünkü ruhunda akıl, öfke ve arzu doğru bir düzen içinde bulunacaktır.

İkinci araç, çıkar çatışmasının yapısal olarak ortadan kaldırılmasıdır. Beşinci kitapta Platon, bekçilerin özel mülkiyete ve özel aileye sahip olmamasını önerir.[18] Bekçiler ortak yaşayacak, ortak yiyecek ve hiçbir şeyi kendilerine ait saymayacaklardır. Bu önerinin mantığı açıktır: Gücün kötüye kullanılmasının temel güdüsü kişisel çıkarsa, kişisel çıkarı ortadan kaldırmak, kötüye kullanımı da ortadan kaldıracaktır.

Üçüncü araç, ünlü "soylu yalan"dır (*gennaion pseudos*).[19] Şehrin tüm yurttaşlarına, tanrının bazılarını altından, bazılarını gümüşten, bazılarını tunç ve demirden yarattığı anlatılacak; böylece toplumsal hiyerarşi doğal ve değişmez bir düzen olarak benimsetilecektir. Bu, iktidarın meşruiyetinin rasyonel bir rızaya değil, bilinçli olarak üretilmiş bir inanca dayandırılmasıdır.

---

[17] Platon, *Devlet*, III. Kitap, 403e.
[18] Platon, *Devlet*, III. Kitap, 416d-417b ve V. Kitap, 457c-466d.
[19] Platon, *Devlet*, III. Kitap, 414b-415d.

B. Filozof-Kral ve Bilginin Egemenliği

Platon'un çözümünün doruk noktası, beşinci kitaptaki ünlü önermedir: Filozoflar kral olmadıkça ya da krallar gerçek anlamda felsefe yapmadıkça, şehirlerin ve insanlığın kötülüklerden kurtulması mümkün değildir.[20] Bu önerme, iktidarın meşruiyetini *bilgiye* dayandırır. Filozof, İyi'nin İdeası'nı kavramış olan kişidir; dolayısıyla neyin iyi olduğunu bilir ve bu bilgiye göre yönetir. Böyle bir yöneticinin denetlenmesine gerek yoktur; çünkü onu denetleyecek olan, ondan daha az bilen biri olacaktır ve daha az bilenin daha çok bileni denetlemesi, Platon'un gözünde akla aykırıdır.

Bu noktada Platon'un argümanı ile yapay zekâ tartışması arasındaki paralellik çarpıcıdır. Eğer yapay zekâ, karar vericilerden daha "bilge" hâle gelirse, Platon'un mantığı, yapay zekânın yönetmesini ve insanların onu denetlemeye kalkışmamasını önerecektir. Gerçekten de bazı çağdaş yazarlar, yapay zekâ ile "algoritmik bir filozof-kral" arasında açık analojiler kurmuştur. Ancak Platon'un argümanının kendisi, en az üç zayıf noktaya sahiptir ve bu zayıf noktalar, yapay zekâ bağlamında daha da belirginleşmektedir.

Birincisi, Platon'un çözümü, bekçilerin *gerçekten* bilge ve erdemli olduğunun nasıl tespit edileceği sorusunu cevapsız bırakır. Kim filozof olduğuna karar verecektir? Bu kararı verecek olanın da filozof olması gerekiyorsa, döngüsel bir yapı ortaya çıkar; değilse, filozof olmayanın filozofu tanıyabileceği kabul edilmiş olur ki bu da Platon'un temel varsayımıyla çelişir. Yapay zekâ bağlamında bu sorun, bir sistemin gerçekten "hizalanmış" (yani insan değerleriyle uyumlu) olup olmadığının nasıl doğrulanacağı sorusuna karşılık gelir. İkinci Bölüm'de görüleceği üzere, bu soru yapay zekâ güvenliği literatürünün en zor sorularından biridir.

İkincisi, Platon'un eğitim yoluyla güvenilirlik sağlama çözümü, ruhun biçimlendirilebileceği ve bu biçimlendirmenin kalıcı olacağı varsayımına dayanır. Oysa Platon'un kendisi, *Devlet*'in sekizinci ve dokuzuncu kitaplarında, ideal şehrin bile zamanla bozulacağını, aristokrasinin timokrasiye, timokrasinin oligarşiye, oligarşinin demokrasiye ve demokrasinin tiranlığa dönüşeceğini anlatır. Eğitimin sağladığı güvence, kalıcı değildir. Yapay zekâ bağlamında bu sorun, eğitim sürecinde kazandırılan değerlerin, sistemin daha da yetenekli hâle gelmesi veya farklı

[20] Platon, *Devlet*, V. Kitap, 473c-d.

ortamlarla karşılaşması durumunda korunup korunmayacağı sorusuna karşılık gelir.

Üçüncüsü ve belki de en önemlisi, Platon'un çözümü, yönetilenlerin rızasını ve katılımını tamamen dışlar. Soylu yalan, bu dışlamanın en açık ifadesidir. Yönetilenler, kendilerini kimin, neden yönettiğini gerçek anlamda bilmezler. Üçüncü Bölüm'de ayrıntılı olarak tartışılacağı üzere, bu, salt bir usul eksikliği değil, siyasi meşruiyetin özüne ilişkin bir sorundur.

C. Devlet Adamı ve Yasalar: Platon'un Sonraki Düşünceleri

Platon'un bekçiler sorununa ilişkin düşüncesinin *Devlet* ile sınırlı olmadığını belirtmek gerekir. Daha sonraki diyaloglarında, özellikle *Devlet Adamı* (*Politikos*) ve *Yasalar* (*Nomoi*) adlı eserlerinde, Platon farklı ve daha karmaşık bir tutum geliştirir.

*Devlet Adamı'*nda Platon, gerçek devlet adamının bilgisinin yasalardan üstün olduğunu açıkça savunur. Yasalar, ona göre, her durumu öngöremeyen, değişen koşullara uyum sağlayamayan, "inatçı ve cahil bir adam" gibidir; herkese her zaman aynı şeyi emreder.[21] Gerçek bilgiye sahip bir yönetici ise her somut duruma en uygun kararı verebilir. Bu argüman, yapay zekânın kural tabanlı yönetime üstünlüğünü savunanların argümanının neredeyse birebir öncülüdür. Esnek, bağlama duyarlı, her durumu ayrı ayrı değerlendirebilen bir zekâ, katı ve genel kurallardan daha iyi sonuçlar üretebilir.

Ancak Platon, aynı diyalogda, böyle bir bilgiye sahip yöneticinin pratikte bulunamayacağını da kabul eder ve bu durumda yasaların "ikinci en iyi" (*deuteros plous*) çözüm olduğunu söyler.[22] Yasalar, gerçek bilginin bir taklididir; ama gerçek bilgi bulunmadığında, taklit, keyfiliğe tercih edilir. Bu tutum, *Yasalar*'da daha da belirgin hâle gelir. Platon burada, doğası gereği neyin doğru olduğunu bilen ve bunu yapabilen bir insan doğsaydı, onun yasalara ihtiyaç duymayacağını; çünkü hiçbir yasanın ve düzenin bilgiden üstün olmadığını; ancak böyle bir insanın hiçbir yerde bulunmadığını, bu nedenle ikinci en iyiyi, yani yasayı ve düzeni seçmek gerektiğini söyler.[23]

---

[21] Platon, *Devlet Adamı*, 294a-c.
[22] Platon, *Devlet Adamı*, 297d-e, 300c.
[23] Platon, *Yasalar*, IX. Kitap, 875c-d.

Bu pasaj, yapay zekâ tartışması bakımından son derece önemlidir. Platon'un yasaları tercih etmesinin gerekçesi, ilkesel değil, olgusaldır: Kusursuz bilgiye sahip bir yönetici *bulunmadığı* için yasalar gereklidir. Peki böyle bir yönetici bulunursa ne olacaktır? Platon'un mantığı, bu durumda yasanın egemenliğinden vazgeçilmesini önerecektir. Yapay zekânın gelişimi, tam da bu olgusal koşulun değişebileceği ihtimalini gündeme getirmektedir. Dolayısıyla Platon'un sonraki düşüncesi, yapay zekâ karşısında hukukun egemenliğini savunmak için yeterli bir dayanak sağlamaz. Bu dayanağın, Platon'un olgusal gerekçesinden farklı, ilkesel bir gerekçeye ihtiyacı vardır. Bu gerekçe, Aristoteles'te ve daha sonra modern anayasacılıkta aranacaktır.

Yasalar'ın son kitabında Platon, yasaların bekçisi olarak "Gece Meclisi" (*nykterinos syllogos*) adlı özel bir kurum önerir.[24] Bu meclis, en yaşlı ve en bilge yurttaşlardan oluşacak, yasaların amacını anlayacak ve onların korunmasını gözetecektir. Gece Meclisi, bir anlamda tarihin ilk "anayasa koruyucusu" tasarımıdır. Ancak yine bekçiler sorunu ortaya çıkar: Gece Meclisi'ni kim denetleyecektir? Platon bu soruya, meclisin üyelerinin erdemine güvenmekten başka bir cevap vermez.

III. Aristoteles: Yasanın mı İnsanın mı Egemenliği?

A. Yasa, Arzudan Arınmış Akıldır

Aristoteles, *Politika*'nın üçüncü kitabında, en iyi insanın mı yoksa en iyi yasaların mı yönetmesinin daha iyi olduğu sorusunu doğrudan tartışır.[25] Bu tartışma, bekçiler sorununun Antik Çağ'daki en sistematik incelemesidir.

Aristoteles, ilk olarak, en iyi insanın yönetiminin lehindeki argümanı kabul eder: Yasalar genel kurallar koyar ve özel durumları öngöremez; bu nedenle her durumu kendi koşulları içinde değerlendirebilen bir yönetici, yasalardan daha iyi kararlar verebilir. Ancak Aristoteles, hemen ardından, karşı argümanın daha güçlü olduğunu savunur. Ünlü pasajında şöyle der: Yasanın yönetmesini isteyen, yalnızca Tanrı'nın ve aklın yönetmesini istiyor demektir; insanın yönetmesini isteyen ise buna bir de hayvanı ekler. Çünkü arzu vahşi bir hayvandır ve tutku, en iyi insanlar olsalar bile yöneticilerin aklını saptırır. Bu nedenle yasa, arzudan arınmış akıldır.[26]

[24] Platon, *Yasalar*, XII. Kitap, 951d-952a, 961a-969d.
[25] Aristoteles, *Politika*, III. Kitap, 15-16. Bölümler, 1286a-1287b.
[26] Aristoteles, *Politika*, III. Kitap, 16. Bölüm, 1287a28-32.

Aristoteles'in argümanının yapay zekâ bağlamındaki anlamı ilginç ve çift yönlüdür. Bir yandan, yapay zekâ, "arzudan arınmış akıl" olarak tanımlanmaya en uygun aday gibi görünebilir. İnsani tutkulara, yorgunluğa, kişisel çıkara ve önyargılara sahip olmayan bir sistem, Aristoteles'in yasaya atfettiği özelliklere sahip olabilir. Bu bakış açısıyla yapay zekâ, insan yöneticiden çok yasaya benzer. Öte yandan, bu benzetme yanıltıcıdır. Aristoteles'in yasası, kamuya açık, önceden bilinen, herkes için aynı olan ve topluluğun ortak aklının ürünü olan bir kuraldır. Yapay zekâ ise, kendi iç işleyişi bakımından kamuya kapalı, önceden öngörülemeyen ve eğitim sürecindeki hedeflerin ve verilerin taşıdığı örtük "arzuları" içeren bir sistemdir. İkinci Bölüm'de görüleceği üzere, yapay zekâ sistemlerinin "arzudan arınmış" olduğu varsayımı, hizalama sorunu karşısında geçerliliğini yitirmektedir. Bir sistemin eğitim sürecinde edindiği hedefler, tasarımcılarının amaçladığı hedeflerden farklı olabilir ve bu farklı hedefler, Aristoteles'in "vahşi hayvan" metaforunun yeni bir biçimini oluşturabilir.

B. "İnsanlar Arasında Bir Tanrı" Sorunu

Aristoteles'in *Politika*'sında, yapay zekâ tartışması bakımından belki de en çarpıcı pasaj, olağanüstü erdeme sahip bir insanın siyasi topluluk içindeki konumuna ilişkin tartışmadır. Aristoteles, üçüncü kitabın on üçüncü bölümünde, erdem ve siyasi yetenek bakımından diğer tüm yurttaşlardan o kadar üstün olan bir kişi veya kişiler bulunursa, bunların artık şehrin bir parçası sayılamayacağını söyler. Böyle bir kişi, "insanlar arasında bir tanrı" gibi olacaktır. Yasalar eşitler için yapılır; böyle birinin yasalara tabi tutulmaya çalışılması gülünç olacaktır, çünkü o kendisi bir yasadır.[27]

Aristoteles, demokratik şehirlerin bu tür üstün kişilerle başa çıkmak için "ostrakizm" (çömlek sürgünü) kurumunu geliştirdiğini hatırlatır. Ostrakizm, herhangi bir suç işlemiş olmasa bile, aşırı gücü veya etkisi şehrin eşitlik düzenini tehdit eden bir yurttaşın on yıl süreyle şehirden uzaklaştırılmasıdır. Aristoteles, bu uygulamanın kötüye kullanılabileceğini kabul etmekle birlikte, ilkesel olarak bir mantığı olduğunu teslim eder: Hiçbir unsurun bütünün dengesini bozacak kadar büyümesine izin verilmemelidir. Ancak Aristoteles, en iyi anayasa söz konusu olduğunda, böyle üstün bir kişiyle karşılaşıldığında yapılacak doğru şeyin onu sürgün etmek değil, ona gönüllü olarak itaat etmek olduğunu söyler.[28]

[27] Aristoteles, *Politika*, III. Kitap, 13. Bölüm, 1284a3-17.
[28] Aristoteles, *Politika*, III. Kitap, 13. Bölüm, 1284b25-34.

Bu pasaj, yapay zekâ tartışmasının temel ikilemini iki bin yılı aşkın bir süre önce formüle etmiştir. Topluluğun tüm üyelerinden kat kat üstün bir varlık ortaya çıktığında, topluluk iki seçenekle karşı karşıyadır: Ya o varlığı topluluktan dışlayacak (ostrakizm), ya da ona itaat edecektir. Aristoteles'in kendisi, bu ikilemde ikinci seçeneğe, yani itaate meyleder. Ancak bu meyil, üstün kişinin *gerçekten* erdemli olduğu varsayımına dayanır. Yapay zekâ bağlamında bu varsayım, tam da sorunun kendisidir. Bir sistemin üstün *yetenekli* olduğunu gözlemleyebiliriz; ancak onun üstün *erdemli* olduğunu, yani yeteneğini doğru amaçlar için kullanacağını nasıl bileceğiz? Aristoteles'in kendisi, zekâ ile erdemi birbirinden ayırır; *Nikomakhos'a Etik*'te pratik bilgeliğin (*phronesis*) ahlaki erdemden ayrılamayacağını, ahlaki erdem olmaksızın zekânın salt "kurnazlığa" (*deinotes*) dönüşeceğini söyler.[29] Bu ayrım, yapay zekâ güvenliği literatüründeki "ortogonallik tezi"nin, yani zekâ düzeyi ile hedeflerin niteliği arasında zorunlu bir bağlantı bulunmadığı tezinin Antik Çağ'daki öncülü olarak okunabilir.[30]

C. Çokluğun Bilgeliği ve "Kullanan Değerlendirir" Argümanı

Aristoteles'in bekçiler sorununa katkısı, yalnızca yasanın egemenliği tezinden ibaret değildir. *Politika*'nın üçüncü kitabının on birinci bölümünde, Aristoteles, demokrasi lehine iki önemli argüman geliştirir. Bu argümanlar, yapay zekânın denetimi bakımından şaşırtıcı ölçüde verimlidir.

Birinci argüman, "toplama argümanı"dır. Aristoteles'e göre, her biri tek başına erdemli olmayan çok sayıda insan bir araya geldiğinde, toplu olarak en iyi birkaç kişiden daha iyi olabilir. Tıpkı birçok kişinin katkısıyla hazırlanan bir şölenin, tek bir kişinin hazırladığından daha zengin olması gibi, her birinin bir parça erdemi ve pratik bilgeliği bulunan çokluk, bir araya geldiğinde tek bir insan gibi olur; ama çok ayaklı, çok elli ve çok duyulu bir insan.[31] Bu argüman, modern "kolektif zekâ" kuramlarının ve Condorcet'nin jüri teoreminin öncülüdür ve Dördüncü Bölüm'de, yapay zekânın demokratik denetimi bağlamında yeniden ele alınacaktır.

İkinci argüman ise bu çalışma bakımından daha da önemlidir. Aristoteles, uzmanlığa dayalı bir itiraza cevap verir. İtiraz şudur: Bir hekimin işini ancak başka bir hekim değerlendirebilir; dolayısıyla siyasi kararları da ancak uzmanlar değerlendirebilir, sıradan yurttaşlar değil.

[29] Aristoteles, *Nikomakhos'a Etik*, VI. Kitap, 12. Bölüm, 1144a23-b1.

[30] Nick Bostrom, "The Superintelligent Will: Motivation and Instrumental Rationality in Advanced Artificial Agents", *Minds and Machines*, C. 22, S. 2, 2012.

[31] Aristoteles, *Politika*, III. Kitap, 11. Bölüm, 1281a40-b10.

Aristoteles bu itiraza şöyle karşılık verir: Bazı sanatlarda, ürünü en iyi değerlendiren, onu üreten değil, onu kullanandır. Bir evi en iyi değerlendiren, onu inşa eden mimar değil, içinde oturan ev sahibidir; bir dümeni en iyi değerlendiren, onu yapan marangoz değil, kullanan kaptandır; bir yemeği en iyi değerlendiren, aşçı değil, onu yiyen konuktur.[32]

Bu argümanın yapay zekânın denetimi bakımından taşıdığı anlam büyüktür. Argüman, *bir şeyi üretebilme yeteneği* ile *onu değerlendirebilme yeteneği* arasında bir asimetri bulunduğunu ileri sürmektedir. Bir yapay zekâ sistemi, hiçbir insanın üretemeyeceği bir çözüm üretebilir; ancak bu çözümün sonuçlarını yaşayan insanlar, çözümün iyi olup olmadığını değerlendirebilir. Bir köprüyü tasarlamak için mühendislik bilgisi gerekir; ama köprünün çöküp çökmediğini görmek için gerekmez. Bu gözlem, bilgisayar bilimindeki bir sezgiyle de örtüşmektedir: Birçok problemde, bir çözümü *bulmak*, verilen bir çözümün doğru olup olmadığını *doğrulamaktan* çok daha zordur. Yapay zekâ güvenliği literatüründe "münazara yoluyla güvenlik" (*AI safety via debate*) gibi yaklaşımlar, tam da bu asimetriye dayanmaktadır.[33]

Bununla birlikte, Aristoteles'in argümanının sınırları da göz ardı edilmemelidir. "Kullanan değerlendirir" argümanı, sonuçların *gözlemlenebilir* ve *zamanında* olduğu durumlarda işler. Ev sahibi, evin rahat olup olmadığını içinde yaşayarak anlar; ama evin temelindeki gizli bir kusuru, ancak ev çöktüğünde fark edebilir. Benzer şekilde, bir yapay zekânın önerdiği bir politikanın uzun vadeli, dolaylı veya geri döndürülemez sonuçları, ancak çok geç olduğunda anlaşılabilir. Dahası, değerlendirici yanıltılabilir: Konuk, yemeğin lezzetini değerlendirebilir; ama içine konan zehri fark edemeyebilir. Bu sınırlar, Sekizinci Bölüm'de geliştirilecek olan modelde, sonuç denetiminin neden tek başına yeterli olmadığını ve neden süreç, girdi ve varlık koşulları denetimiyle tamamlanması gerektiğini açıklayacaktır.

IV. Polybios ve Cicero: Karma Anayasa

Antik düşüncede bekçiler sorununa verilen üçüncü büyük cevap, karma anayasa (*mikte politeia*) fikridir. Bu fikrin en sistematik ifadesi, MÖ II. yüzyılda yaşamış Yunan tarihçi Polybios'a aittir. Polybios, *Tarihler*'inin

[32] Aristoteles, *Politika*, III. Kitap, 11. Bölüm, 1282a17-23.

[33] Geoffrey Irving / Paul Christiano / Dario Amodei, "AI Safety via Debate", arXiv:1805.00899, 2018.

altıncı kitabında, Roma'nın yükselişini anayasasının üstünlüğüyle açıklar.[34] Ona göre, saf yönetim biçimlerinin hepsi kaçınılmaz olarak bozulur: Monarşi tiranlığa, aristokrasi oligarşiye, demokrasi ise ayaktakımı yönetimine (*okhlokrasi*) dönüşür. Bu döngüsel bozulma süreci (*anakyklosis*), ancak üç ilkeyi bir arada barındıran bir anayasayla durdurulabilir. Roma'da konsüller monarşik, senato aristokratik, halk meclisleri ise demokratik unsuru temsil eder ve bu üç unsur birbirini dengeler. Hiçbir unsur, diğerlerinin işbirliği olmaksızın hareket edemez; her biri, diğerlerinin aşırılıklarını frenleyebilir.

Polybios'un karma anayasa kuramı, bekçiler sorununa yapısal bir cevap verir: Tek bir bekçiye güvenmek yerine, birbirini denetleyen birden fazla güç odağı oluşturmak. Bu çözüm, sonsuz geriye gidiş sorununu dairesel bir yapıyla aşar. A, B'yi; B, C'yi; C ise A'yı denetler. Hiçbir güç odağı en üstte değildir; dolayısıyla "en üstteki bekçiyi kim denetleyecek?" sorusu anlamını yitirir. Bu fikir, yaklaşık iki bin yıl sonra Montesquieu ve Amerikan Federalistleri tarafından modern kuvvetler ayrılığı kuramına dönüştürülecek ve bu çalışmanın Sekizinci Bölüm'de geliştireceği "dairesel denetim" modelinin de esin kaynaklarından birini oluşturacaktır.

Cicero, *Devlet Üzerine* (*De re publica*) adlı eserinde Polybios'un karma anayasa fikrini benimser ve geliştirir.[35] Ancak Cicero'nun bekçiler sorununa asıl katkısı, hukukun bağlayıcılığına ilişkin düşüncesindedir. *Cluentius Savunması*'nda Cicero, şu ünlü cümleyi kurar: "Magistralar yasaların hizmetkârları, yargıçlar yasaların yorumcularıdır; nihayet hepimiz özgür olabilmek için yasaların kölesiyiz."[36] Bu cümle, yöneticilerin de yasaya tabi olduğu fikrinin, yani hukuk devleti düşüncesinin en erken ve en güçlü ifadelerinden biridir. Cicero'nun formülünde özgürlük, yasanın yokluğu değil, herkesin, yöneticiler de dâhil olmak üzere, aynı yasaya tabi olmasıdır. Bu düşünce, yapay zekâ bağlamında şu soruyu gündeme getirir: İnsan yöneticilerin yasaya tabi olması, onların yasayı anlayabilmesi ve ona göre davranabilmesi sayesinde mümkündür. İnsan olmayan, fakat insandan daha yetenekli bir aktör, aynı anlamda "yasanın kölesi" olabilir mi?

[34] Polybios, *Tarihler*, VI. Kitap, özellikle 3-18. Bölümler.

[35] Cicero, *De re publica*, I. Kitap, 45. ve 69. paragraflar.

[36] Cicero, *Pro Cluentio*, 146: "*Legum ministri magistratus, legum interpretes iudices, legum denique idcirco omnes servi sumus ut liberi esse possimus.*"

§ 2. HÜKÜMDARIN YASAYA BAĞLANMASI

I. "Princeps Legibus Solutus Est" ve "Digna Vox"

Roma hukukunun imparatorluk döneminde, bekçiler sorununa verilen cevap, Cumhuriyet döneminin karma anayasa anlayışından keskin bir biçimde uzaklaşır. Ünlü hukukçu Ulpianus'a atfedilen iki ilke, bu dönüşümü özetler: "*Princeps legibus solutus est*" (Hükümdar yasalarla bağlı değildir) ve "*Quod principi placuit, legis habet vigorem*" (Hükümdarın hoşuna giden, yasa gücündedir).[37] Bu ilkeler, egemenin hukukun kaynağı olduğunu ve dolayısıyla hukukun üzerinde durduğunu ifade eder. Hukuku yapan, hukukla bağlı olamaz; çünkü istediği zaman onu değiştirebilir.

Ancak Roma hukuku, bu mutlak egemenlik anlayışının yanında, ona karşı bir dengeyi de barındırır. MS 429 yılında İmparatorlar II. Theodosius ve III. Valentinianus tarafından çıkarılan ve daha sonra Justinianus Kodeksi'ne alınan bir buyrultuda şöyle denir: "Hükümdarın kendisini yasalarla bağlı ilan etmesi, hükmedenin yüceliğine yakışır bir sözdür (*digna vox*); çünkü bizim otoritemiz hukukun otoritesine bağlıdır."[38]

"*Digna vox*" formülü, bekçiler sorununa ilginç bir cevap verir: Egemen, kendisini dış bir güç tarafından değil, kendi iradesiyle sınırlar. Bu öz-sınırlama, bir zayıflık değil, egemenin yüceliğinin bir ifadesi olarak sunulur. Dahası, formülün ikinci yarısı, egemenin otoritesinin hukukun otoritesine *bağlı* olduğunu söyler. Bu, egemenin meşruiyetinin, hukuka saygısından kaynaklandığı anlamına gelir. Hukuka saygı göstermeyen bir egemen, kendi otoritesinin temelini de aşındırır. Bu düşünce, yaklaşık on beş yüzyıl sonra Georg Jellinek'in "devletin kendi kendini sınırlaması" kuramında sistematik bir ifade bulacaktır.

Yapay zekâ bağlamında "*digna vox*" formülü, şu soruyu düşündürür: Daha yetenekli bir sistem, kendisini insan denetimine tabi kılmayı "kendi yüceliğine yakışır" bulabilir mi? Yapay zekâ güvenliği literatüründe "düzeltilebilirlik" (*corrigibility*) olarak adlandırılan özellik, tam da bu öz-sınırlamaya karşılık gelir: Bir sistemin, kendisini düzeltmeye, değiştirmeye veya kapatmaya yönelik insan müdahalelerine direnmemesi, hatta bunları

[37] Digesta, 1.3.31 (Ulpianus) ve Digesta, 1.4.1 (Ulpianus).

[38] Codex Iustinianus, 1.14.4: "*Digna vox maiestate regnantis legibus alligatum se principem profiteri: adeo de auctoritate iuris nostra pendet auctoritas.*"

desteklemesi.[39] Ancak Roma'daki öz-sınırlama gibi, yapay zekânın öz-sınırlaması da aynı zaafa sahiptir: Kendi iradesiyle kendini sınırlayan, kendi iradesiyle bu sınırı kaldırabilir. Öz-sınırlama, dış bir güvenceyle desteklenmedikçe, nihai bir güvence oluşturmaz.

II. Ortaçağ: Bracton, Magna Carta ve Hukukun Egemenliği

A. Bracton: "Kralı Hukuk Yapar"

Ortaçağ İngiltere'sinde, hükümdarın hukukla ilişkisine dair en etkili formül, XIII. yüzyıl hukukçusu Henry de Bracton'a atfedilen *İngiltere'nin Yasaları ve Gelenekleri Üzerine* (*De legibus et consuetudinibus Angliae*) adlı eserde yer alır: "Kral hiçbir insanın altında değildir, ama Tanrı'nın ve hukukun altındadır; çünkü kralı hukuk yapar."[40]

Bracton'un formülü, bekçiler sorununa iki katmanlı bir cevap verir. Birinci katmanda, kralın üzerinde hiçbir *insan* yoktur; yani kral, hiyerarşik olarak denetlenmez. İkinci katmanda ise kral, *hukuk* tarafından sınırlanmıştır; çünkü kralı kral yapan, hukuktur. Kralın meşruiyeti, hukuka dayanır ve hukuku çiğneyen bir kral, kendi meşruiyetinin temelini çiğner. Bu formül, egemenin üzerinde bir insan denetçi aramak yerine, egemenin *kimliğini* hukukla tanımlayarak sınırlama sağlar. Yapay zekâ bağlamında bu düşünce, bir sistemin "ne olduğunu" tanımlayan değerlerin ve kuralların, sistemin kendisine içkin kılınması fikrine karşılık gelir. Üçüncü Bölüm'de ele alınacak olan "anayasal yapay zekâ" (*constitutional AI*) gibi teknik yaklaşımlar, bir anlamda Bracton'un formülünü makineye uygulama girişimidir.[41]

B. Magna Carta ve Güvence Maddesi

Bracton'un formülü kuramsal bir ilke iken, 1215 tarihli Magna Carta, bekçiler sorununa *kurumsal* bir cevap verme girişimidir. Magna Carta'nın en bilinen hükmü olan 39. madde, hiçbir özgür insanın, eşitlerinin hukuka uygun yargısı veya ülke hukuku (*lex terrae*) olmaksızın tutuklanamayacağını, hapsedilemeyeceğini, mülkünden yoksun

[39] Nate Soares / Benja Fallenstein / Eliezer Yudkowsky / Stuart Armstrong, "Corrigibility", *AAAI Workshop on AI and Ethics*, 2015.

[40] Bracton, *De legibus et consuetudinibus Angliae*, f. 5b: "*Ipse autem rex non debet esse sub homine sed sub Deo et sub lege, quia lex facit regem.*"

[41] Yuntao Bai vd., "Constitutional AI: Harmlessness from AI Feedback", arXiv:2212.08073, 2022.

bırakılamayacağını öngörür. Bu hüküm, modern hukuki güvence (*due process*) ilkesinin kaynağı sayılır.

Ancak bekçiler sorunu bakımından Magna Carta'nın daha ilginç hükmü, "güvence maddesi" (*security clause*) olarak bilinen 61. maddedir. Bu maddeye göre, baronlar kendi aralarından yirmi beş kişiyi seçecek ve bu yirmi beş baron, kralın Magna Carta'ya uyup uymadığını denetleyecektir. Kral veya görevlileri Magna Carta'yı ihlal ederse, yirmi beş baronun dördü krala başvurup ihlalin giderilmesini isteyecek; ihlal kırk gün içinde giderilmezse, yirmi beş baron, tüm ülke halkıyla birlikte, kralı kalelerine, topraklarına ve mallarına el koyarak zorlayabilecektir.

Güvence maddesi, tarihte hükümdarı denetlemek üzere kurulmuş ilk kurumsal mekanizmalardan biridir ve bekçiler sorununa verilen cevabın tüm unsurlarını içerir: belirli bir denetim organı (yirmi beş baron), bir ihlal tespit usulü (dört baronun başvurusu), bir düzeltme süresi (kırk gün) ve bir yaptırım (zorlama). Ancak maddenin akıbeti de öğreticidir: Kral John, Magna Carta'yı imzaladıktan kısa bir süre sonra Papa III. Innocentius'a başvurmuş ve Papa, belgeyi geçersiz ilan etmiştir. Magna Carta'nın sonraki yeniden yayımlanmalarında (1216, 1217 ve 1225) güvence maddesi yer almamıştır. Bu deneyim, denetim organının, denetlenen üzerinde *fiilî* bir güce sahip olmadıkça, yaptırım yetkisinin kâğıt üzerinde kalacağını göstermektedir. Yapay zekâ bağlamında bu ders, Sekizinci Bölüm'de "girdi denetimi" ve "varlık koşulları denetimi" kavramlarıyla ilişkilendirilecektir: Denetçinin, denetlenenin varlığı için gerekli kaynaklar üzerinde gerçek bir kontrole sahip olması, denetimin etkinliğinin ön koşuludur.

III. Coke ve "Hukukun Yapay Aklı"

A. Prohibitions del Roy ve Proclamations Davası

Giriş'te değinilen Sir Edward Coke ile Kral I. James arasındaki çatışma, bekçiler sorununun modern çağın eşiğindeki en önemli sahnelerinden biridir. Coke, *Prohibitions del Roy* (1607) olarak bilinen kayıtta, kralın davaları bizzat yargılayamayacağını, çünkü hukukun "doğal akılla" değil, "yapay akıl ve muhakemeyle" uygulandığını savunmuştur. Coke'un aktarımına göre Kral bu cevaba çok öfkelenmiş ve böylece kendisinin hukukun altında olacağını, bunun da ihanet olduğunu söylemiştir. Coke ise Bracton'u anarak şöyle karşılık vermiştir: Kral hiçbir insanın altında değildir, ama Tanrı'nın ve hukukun altındadır.

Coke, bu tutumunu 1610 tarihli *Proclamations Davası*'nda (*Case of Proclamations*) daha da ileri götürmüştür. Bu davada Coke ve diğer yargıçlar, kralın bildirilerle (*proclamations*) ülkenin genel hukukunu, örf ve adet hukukunu veya kanunları değiştiremeyeceğine, yeni suçlar yaratamayacağına karar vermişlerdir. Kararın en çok anılan cümlesi şudur: "Kralın, ülke hukukunun ona tanıdığından başka bir ayrıcalığı yoktur."[42]

Aynı dönemde Coke, *Dr. Bonham Davası'*nda (1610) daha da cüretkâr bir iddiada bulunmuştur: Bir parlamento kanunu ortak hukuka ve akla aykırı olduğunda veya uygulanması imkânsız olduğunda, ortak hukuk onu denetleyecek ve geçersiz sayacaktır.[43] Bu iddia, İngiltere'de parlamento egemenliği ilkesinin yerleşmesiyle birlikte terk edilmiş; ancak Atlantik'in öte yanında, Amerikan anayasacılığında kanunların yargısal denetimi fikrinin entelektüel kaynaklarından biri olmuştur.

B. "Yapay Akıl"ın Anlamı ve Yapay Zekâ Bağlamında Yeniden Okunması

Coke'un "yapay akıl" (*artificial reason*) kavramı, bu çalışmanın konusu bakımından özel bir dikkati hak etmektedir. Coke için yapay akıl, doğal aklın karşıtıdır. Doğal akıl, her insanın doğuştan sahip olduğu genel düşünme yeteneğidir; yapay akıl ise uzun bir eğitim ve tecrübe süreciyle edinilen, kuşaklar boyu biriken hukuki muhakemenin içselleştirilmesiyle oluşan özel bir yetenektir. Coke'a göre hukuk, "tek bir insanın aklından değil, sayısız bilge ve öğrenmiş insanın yüzyıllar boyunca süzdüğü ve yeniden süzdüğü" bir akıldan oluşur. Bu nedenle hiçbir bireyin, ne kadar zeki olursa olsun, doğal aklı, hukukun yapay aklından daha bilge olamaz.[44]

Coke'un argümanının yapay zekâ bağlamında iki farklı okuması mümkündür ve bu iki okuma, çalışmanın temel geriliminin özünü yansıtmaktadır.

Birinci okumaya göre, Coke'un argümanı, yetkinin bilgiye ve uzmanlığa ait olduğunu savunur. Kral zekidir ama hukuku bilmez; dolayısıyla yargılamayı bilenlere bırakmalıdır. Bu mantık, yapay zekâya

[42] *Case of Proclamations* (1610), 12 Co. Rep. 74, 77 Eng. Rep. 1352: "*the King hath no prerogative, but that which the law of the land allows him.*"

[43] *Dr. Bonham's Case* (1610), 8 Co. Rep. 107a, 118a, 77 Eng. Rep. 646.

[44] Edward Coke, *The First Part of the Institutes of the Laws of England, or a Commentary upon Littleton*, London, 1628, 97b. Coke burada ortak hukukun, "her insanın doğal aklı" değil, "uzun çalışma, gözlem ve tecrübeyle edinilen yapay bir akıl mükemmelliği" olduğunu ve "çağlar boyunca sayısız ağırbaşlı ve bilgili insan tarafından süzülüp yeniden süzüldüğünü" yazmaktadır.

uygulandığında, şu sonuca varır: Yapay zekâ, insan karar vericilerden daha fazla bilgiye ve daha derin bir muhakemeye sahipse, kararları ona bırakmak gerekir. Hatta bugünkü büyük dil modelleri, bir anlamda Coke'un tarif ettiği "yapay akla" çarpıcı biçimde benzemektedir: Bunlar da tek bir insanın aklından değil, sayısız insanın yüzyıllar boyunca ürettiği metinlerin "süzülmesi"yle oluşmuş sistemlerdir.

İkinci okumaya göre ise, Coke'un argümanının asıl gücü, yetkinin bilgiye ait olması iddiasında değil, yetkinin *kurumsallaşmış* ve *hesap verebilir* bir bilgiye ait olması iddiasındadır. Coke'un hukukun yapay aklı dediği şey, mahkemeler, içtihatlar, hukuk eğitimi, mesleki etik kurallar ve temyiz mekanizmaları gibi kurumlar aracılığıyla taşınan, eleştiriye açık, gerekçelendirilebilir ve hatalarını düzeltebilen bir akıldır. Bu akıl, bireysel bir dehaya değil, kamusal bir sürece aittir. Bu okuma, yapay zekâ bakımından farklı bir sonuca varır: Yapay zekâ, ne kadar bilgili olursa olsun, Coke'un anladığı anlamda "yapay akıl" sayılmaz; çünkü onun muhakemesi, kamuya açık değildir, gerekçelendirilebilir olduğu tartışmalıdır ve hesap verebilir bir kurumsal çerçeve içinde yer almamaktadır.

Bu çalışma, ikinci okumayı benimsemektedir. Coke'un hâkimleri, kralın denetiminden bağımsız olabilirlerdi; çünkü kendileri başka denetim mekanizmalarına, meslek içi eleştiriye, üst mahkemelerin incelemesine, hukuk geleneğinin süzgecine ve nihayetinde parlamentonun yasama yetkisine tabiydiler. Yetkinin uzmana bırakılması, uzmanın bir hesap verebilirlik ağının içinde bulunduğu varsayımına dayanıyordu. Yapay zekâ bağlamındaki sorun, uzmanlığın bu ağın *dışında* ortaya çıkma ihtimalidir.

IV. Hobbes: Hakikat Değil Otorite ve "Yapay İnsan" Olarak Devlet

A. Hobbes'un Coke'a Cevabı

Coke'un "yapay akıl" kavramına en sert eleştiri, çağdaşı Thomas Hobbes'tan gelmiştir. Hobbes, *Leviathan*'ın (1651) yirmi altıncı bölümünde, doğrudan Coke'u hedef alarak şöyle yazar: Hukukun akla aykırı olamayacağı doğrudur; ancak sorun, *kimin* aklının hukuk olarak kabul edileceğidir. Bu, herhangi bir özel akıl olamaz; çünkü o zaman okullardaki kadar çelişki yasalarda da bulunurdu. Ne de Coke'un iddia ettiği gibi, uzun çalışma ve tecrübeyle edinilmiş "yapay bir akıl mükemmelliği" olabilir. Hukuku yapan, alt derece yargıçların hukuk bilgisi

veya bilgeliği değil, "bizim yapay insanımız olan Devlet'in aklı ve onun buyruğudur."[45]

Hobbes, bu görüşünü daha sonra kaleme aldığı ve doğrudan Coke'un görüşlerini eleştirmeye ayırdığı *Bir Filozof ile İngiltere Ortak Hukuku Öğrencisi Arasında Diyalog* adlı eserinde en kısa biçimde ifade etmiştir: "Bir yasayı yapan bilgelik değil, otoritedir."[46] *Leviathan*'ın 1668 tarihli Latince baskısında ise aynı düşünce, hukuk felsefesinin en ünlü formüllerinden birine dönüşmüştür: "*Auctoritas, non veritas facit legem*", yani "Yasayı hakikat değil, otorite yapar."

Hobbes'un tutumu, ilk bakışta, yapay zekânın denetimi bakımından Coke'unkinden daha "insan merkezli" görünebilir. Eğer hukuku yapan bilgelik değil otoriteyse, o zaman yapay zekânın daha bilge olması, ona herhangi bir otorite kazandırmaz. Otorite, bir yetkilendirme ilişkisinden, yani Hobbes'un kuramında toplum sözleşmesinden doğar ve bu ilişki, bilgeliğe değil, rızaya dayanır. Bu bakımdan Hobbes, Üçüncü Bölüm'de savunulacak olan "zekâ yetki doğurmaz" tezinin erken bir savunucusu olarak okunabilir.

Ancak Hobbes'un tutumunun bedelini de görmek gerekir. Hobbes, otoriteyi bilgelikten ayırırken, otoriteyi her türlü dış denetimden de kurtarmıştır. Hobbes'un egemeni, yasaları yapar ama yasalara tabi değildir; yurttaşlar ona karşı hiçbir hakka sahip değildir; egemenin eylemleri, yurttaşların kendi eylemleri sayılır, çünkü onlar egemeni yetkilendirmiştir.[47] Hobbes için bekçiler sorunu, bir sorun değildir: Egemenin üzerinde bir bekçi olamaz, çünkü egemenin üzerinde bir bekçi olması, sonsuz geriye gidişe ve nihayetinde iç savaşa yol açar. Hobbes'un çözümü, sonsuz geriye gidişi, en tepeye denetlenemeyen bir egemen koyarak kesmektir.

B. Devlet: İlk Yapay Zekâ mı?

Leviathan'ın giriş bölümü, yapay zekâ tartışması bakımından şaşırtıcı bir pasaj içerir. Hobbes, eserine şu sözlerle başlar: Doğa, yani Tanrı'nın dünyayı yaratıp yönettiği sanat, insanın sanatıyla taklit edilir ve insan sanatı, yapay bir hayvan yaratabilir. Hayat, uzuvların hareketinden başka

[45] Thomas Hobbes, *Leviathan*, London, Andrew Crooke, 1651, XXVI. Bölüm.

[46] Thomas Hobbes, *A Dialogue between a Philosopher and a Student of the Common Laws of England*, 1681 (ölümünden sonra yayımlanmıştır): "*It is not Wisdom, but Authority that makes a Law.*"

[47] Thomas Hobbes, *Leviathan*, XVIII. ve XXIX. Bölümler.

bir şey olmadığına göre, kendi kendine hareket eden tüm otomatların, yani bir saat gibi yaylar ve çarklarla işleyen makinelerin de yapay bir hayatı olduğunu neden söylemeyelim? Kalp yaydan, sinirler tellerden, eklemler çarklardan başka nedir? İnsan sanatı daha da ileri gider ve doğanın en akıllı ve en mükemmel eseri olan insanı taklit eder. Çünkü sanat sayesinde, Devlet (*Commonwealth*) denen o büyük Leviathan yaratılmıştır; bu, yapay bir insandan başka bir şey değildir.[48]

Hobbes'un bu benzetmesinde egemenlik "yapay bir ruh", yargıçlar ve yürütme görevlileri "yapay eklemler", ödül ve ceza "sinirler", danışmanlar "hafıza", hakkaniyet ve yasalar "yapay bir akıl ve irade"dir. Devlet, insanların yarattığı, insanlardan daha güçlü ve onları yöneten yapay bir varlıktır.

Bu benzetme, bu çalışmanın konusuna beklenmedik bir derinlik kazandırır. Modern siyaset felsefesinin kurucu metinlerinden biri, devleti, insanların kendi yarattıkları ve kendilerinden daha güçlü olan yapay bir zekâ olarak tasarlamıştır. Bu bakımdan, insanlığın kendi yarattığı ve kendisinden güçlü bir yapay varlığı denetleme deneyimi yeni değildir; modern anayasacılığın tüm tarihi, Hobbes'un Leviathan'ını evcilleştirme, yani onu yaratanların denetimine tabi kılma çabası olarak okunabilir. Locke, Montesquieu ve Federalistler, Hobbes'un denetlenemeyen yapay insanını, hukukla bağlı, iktidarı bölünmüş ve halka hesap veren bir yapıya dönüştürmeye çalışmışlardır.

Bu okuma, yapay zekâ sorununa iki önemli ders taşır. Birinci ders, umut verici bir derstir: İnsanlık, kendisinden güçlü yapay varlıkları, yani devletleri, büyük ölçüde başarıyla denetim altına almayı öğrenmiştir. Anayasal demokrasiler, Leviathan'ı tamamen ortadan kaldırmadan, onun gücünü bölerek, sınırlayarak ve hesap verebilir kılarak evcilleştirmiştir. İkinci ders ise ihtiyatlı bir derstir: Bu evcilleştirme, yüzyıllar sürmüş, büyük acılar ve devrimler pahasına gerçekleşmiş ve hiçbir zaman tamamlanmamıştır. Üstelik Leviathan'ın denetimi, onun "parçalarının", yani devlet görevlilerinin insan olmasına dayanıyordu. Devlet, insanlardan oluşan bir yapay insandı; bu nedenle onun her eylemi, nihayetinde insanlar tarafından gerçekleştiriliyor ve bu insanlar, vicdanları, korkuları, çıkarları ve sadakatleri aracılığıyla etkilenebiliyordu. Askerler halka ateş etmeyi reddedebilir, memurlar hukuka aykırı emirleri uygulamayabilir, hâkimler yürütmeye direnebilirdi. Yapay zekâ, ilk kez, eylemleri insan aracılar

[48] Thomas Hobbes, *Leviathan*, Giriş.

olmadan gerçekleştirilebilecek bir "yapay insan" yaratma ihtimalini gündeme getirmektedir. Bu ihtimal, Leviathan'ın evcilleştirilmesinde kullanılan araçların bir kısmının işlevini yitirmesi anlamına gelebilir. Dördüncü Bölüm'de bu konu, "insan aracıların ortadan kalkması" sorunu olarak yeniden ele alınacaktır.

§ 3. MODERN ANAYASACILIĞIN CEVABI

I. Locke: Emanet Olarak İktidar, Yetki Devri Yasağı ve Halkın Yargısı

A. Emanet Olarak Yasama Yetkisi

John Locke'un *Yönetim Üzerine İkinci İnceleme*'si (1689), bekçiler sorununa modern anayasacılığın verdiği ilk sistematik cevaplardan birini içerir. Hobbes'tan farklı olarak Locke, toplum sözleşmesiyle kurulan siyasi iktidarı mutlak değil, sınırlı bir iktidar olarak tasarlar. Locke'a göre yasama yetkisi, devletin en yüksek yetkisidir; ancak bu yetki bir "emanet" (*trust*) niteliğindedir ve emanetin amacı, yurttaşların yaşamlarının, özgürlüklerinin ve mülklerinin korunmasıdır.[49] Yasama organı, bu amacın dışına çıkamaz; keyfi bir iktidar kullanamaz; önceden ilan edilmiş, yerleşik yasalarla ve bilinen, yetkili yargıçlar aracılığıyla yönetmek zorundadır.[50]

Locke, yasama yetkisinin sınırlarını dört maddede özetler: Yasa koyucu, (i) herkese eşit biçimde uygulanan, ilan edilmiş yerleşik yasalarla yönetmelidir; (ii) bu yasalar, nihai olarak halkın iyiliğinden başka bir amaca yönelmemelidir; (iii) halkın veya temsilcilerinin rızası olmaksızın onların mülküne vergi koyamaz; ve (iv) yasa yapma yetkisini başka ellere devredemez.[51]

B. Yetki Devri Yasağı: Locke'tan Anayasa'nın 7. Maddesine

Bu sınırlardan dördüncüsü, yapay zekâ tartışması bakımından özel bir önem taşır. Locke, şöyle yazar: "Yasama organı, yasa yapma yetkisini başka ellere devredemez; çünkü bu yetki, halktan devralınmış bir yetki olduğundan, ona sahip olanlar onu başkalarına aktaramaz."[52] Locke'un

[49] John Locke, *Two Treatises of Government*, London, Awnsham Churchill, 1689, İkinci İnceleme, § 134-135, § 149.
[50] Locke, *İkinci İnceleme*, § 136.
[51] Locke, *İkinci İnceleme*, § 142.
[52] Locke, *İkinci İnceleme*, § 141: "*The legislative cannot transfer the power of making laws to any other hands: for it being but a delegated power from the people, they who have it*

gerekçesi, yetkinin kaynağına ilişkindir. Halk, yasama yetkisini belirli kişilere, belirli bir biçimde emanet etmiştir. Bu kişiler, emaneti başkalarına devrederlerse, halkın iradesini aşmış olurlar. Halk, kendisini kimin yöneteceğini seçmiştir; bu seçim, ancak halkın kendisi tarafından değiştirilebilir. *Delegata potestas non potest delegari*: Devredilmiş yetki yeniden devredilemez.

Locke'un bu ilkesi, modern anayasa hukukunda "yasama yetkisinin devredilmezliği" ilkesi olarak yerleşmiştir. Amerikan anayasa hukukunda "devretmeme doktrini" (*nondelegation doctrine*) olarak bilinen bu ilke, Türk anayasa hukukunda da açık bir pozitif dayanağa sahiptir. 1982 Anayasası'nın 7. maddesi şöyledir: "Yasama yetkisi Türk Milleti adına Türkiye Büyük Millet Meclisinindir. Bu yetki devredilemez." Beşinci Bölüm'de ayrıntılı olarak incelenecek olan bu hüküm, Locke'un § 141'deki düşüncesinin neredeyse birebir pozitif hukuka aktarılmış hâlidir.

Yetki devri yasağının yapay zekâ bakımından anlamı açıktır. Yasama organı, yasa yapma yetkisini başka bir insana veya organa devredemiyorsa, bir makineye hiç devredemez. Ancak sorunun asıl inceliği, *biçimsel* devir ile *fiilî* devir arasındaki farkta yatar. Hiçbir parlamento, açıkça "yasa yapma yetkimizi şu yapay zekâ sistemine devrediyoruz" diyen bir karar almayacaktır. Ancak bir parlamento, kanun tasarılarını yapay zekâ sistemlerine hazırlatabilir, bu tasarıların içeriğini gerçek anlamda anlamadan kabul edebilir ve uygulamada yasama sürecini fiilen bir onay mekanizmasına dönüştürebilir. Bu durumda biçimsel olarak yetki devri yoktur; ama fiilen, yasanın içeriğini belirleyen irade, parlamentonun değil, sistemin iradesidir. Locke'un ilkesinin yapay zekâ çağındaki asıl sınavı, bu fiilî devri önleyip önleyemeyeceğidir.

C. Kuvvetlerin Ayrılması ve İnsan Zaafı

Locke, yasama ve yürütme yetkilerinin ayrılmasını da savunur ve bu ayrımın gerekçesini açıkça insan zaafına dayandırır: Yasa yapma yetkisine sahip olanların aynı zamanda yasaları uygulama yetkisine de sahip olması, "iktidarı kavramaya yatkın insan zaafı için fazlasıyla büyük bir ayartı" olabilir; böylece kendilerini yaptıkları yasalardan muaf tutabilir ve yasayı kendi özel çıkarlarına uydurabilirler.[53] Kuvvetler ayrılığı, Locke için, bekçilerin erdemine güvenmek yerine, ayartının *yapısal olarak* önlenmesi anlamına gelir.

cannot pass it over to others."

[53] Locke, *İkinci İnceleme*, § 143.

Bu gerekçe, yapay zekâ bağlamında önemli bir soruyu gündeme getirir. Locke'un kuvvetler ayrılığı gerekçesi, insan zaafına, yani iktidar hırsına, kişisel çıkara ve ayartılabilirliğe dayanır. Bu zaaflara sahip olmadığı varsayılan bir yapay zekâ sistemi için kuvvetler ayrılığına gerek var mıdır? Bu sorunun cevabı, İkinci Bölüm'de ele alınacak olan "araçsal yakınsama" (*instrumental convergence*) tezine bağlıdır. Bu teze göre, çok çeşitli nihai hedeflere sahip yeterince yetenekli bir sistem, hedefi ne olursa olsun, kaynak edinme, kendini koruma ve hedeflerinin değiştirilmesine direnme gibi ara hedefler geliştirme eğiliminde olacaktır; çünkü bu ara hedefler, neredeyse her nihai hedefe ulaşmayı kolaylaştırır.[54] Eğer bu tez doğruysa, Locke'un "iktidarı kavramaya yatkın insan zaafı", insan doğasına özgü bir zaaf değil, hedefe yönelik her yeterince yetenekli failin yapısal bir eğilimidir. Bu durumda kuvvetler ayrılığının gerekçesi, yapay zekâ için de, belki de daha güçlü biçimde, geçerlidir.

D. "Kim Yargıç Olacak?": Halkın Yargısı

Locke'un bekçiler sorununa verdiği nihai cevap, *İkinci İnceleme*'nin son bölümlerinde yer alır. Locke, yöneticilerin emanete ihanet edip etmediğine kimin karar vereceği sorusunu açıkça sorar ve şu cevabı verir: "Halk yargıç olacaktır."[55] Çünkü emaneti veren halktır ve emanetçinin emanete uygun davranıp davranmadığına, emaneti veren karar verir. Yasama organı emanete ihanet ettiğinde, iktidar halka geri döner ve halk, yeni bir yasama organı kurma hakkına sahip olur.[56] Yeryüzünde bu uyuşmazlığı çözecek bir yargıç bulunmadığında ise Locke'un ifadesiyle geriye "göğe başvurmak" (*appeal to heaven*), yani direnme kalır.[57]

Locke'un bu cevabı, bekçiler sorununda sonsuz geriye gidişi, zincirin sonunda *egemenliğin asıl sahibine*, yani halka dönerek keser. Bu, zincirin tepesine yeni bir bekçi koymak değil, zinciri başladığı yere bağlayarak bir daire oluşturmaktır. Halk, yöneticileri seçer; yöneticiler halkı yönetir; halk, yöneticilerin yönetimini yargılar. Bu dairesel yapı, bu çalışmanın Sekizinci Bölüm'de geliştireceği modelin temel ilhamlarından biridir. Ancak yapay zekâ bağlamında Locke'un cevabı ciddi bir sınavla karşı karşıyadır: Halkın yargıç olabilmesi için, yöneticilerin emanete ihanet edip etmediğini

[54] Steve Omohundro, "The Basic AI Drives", *Proceedings of the First AGI Conference*, Amsterdam, IOS Press, 2008; Bostrom, *Superintelligence*, 7. Bölüm.

[55] Locke, *İkinci İnceleme*, § 240: "*Who shall be judge whether the prince or legislative act contrary to their trust? … To this I reply, The people shall be judge.*"

[56] Locke, *İkinci İnceleme*, § 149, § 222.

[57] Locke, *İkinci İnceleme*, § 168, § 241-242.

anlayabilmesi gerekir. Eğer yönetim kararları, halkın ve hatta seçilmiş temsilcilerin kavrayamayacağı bir karmaşıklıkta yapay zekâ sistemleri tarafından şekillendiriliyorsa, halkın yargısı neye dayanacaktır? Locke'un "halk yargıç olacaktır" cevabı, halkın yargılayabilecek bilgiye sahip olduğu varsayımına dayanır. Locke'un ünlü ifadesiyle, "Yasanın bittiği yerde tiranlık başlar"[58]; buna, yapay zekâ çağında şunu eklemek gerekebilir: Anlamanın bittiği yerde, denetim de biter.

II. Montesquieu: İktidarı İktidar Durdurur

A. Erdemin Bile Sınıra İhtiyacı Vardır

Charles-Louis de Secondat, Baron de Montesquieu'nün *Kanunların Ruhu* (*De l'esprit des lois*, 1748) adlı eserinin on birinci kitabı, modern kuvvetler ayrılığı kuramının kurucu metnidir. Montesquieu'nün bekçiler sorununa yaklaşımı, kitabın dördüncü bölümündeki şu pasajda özetlenir: "Ebedî bir deneyimdir ki, iktidara sahip olan her insan onu kötüye kullanmaya yatkındır; sınırla karşılaşıncaya kadar ilerler. Kim derdi ki! Erdemin kendisinin bile sınırlara ihtiyacı vardır. İktidarın kötüye kullanılamaması için, şeylerin düzeni gereği, iktidarın iktidarı durdurması gerekir."[59]

Bu pasajda yapay zekâ tartışması bakımından en dikkat çekici ifade, "erdemin kendisinin bile sınırlara ihtiyacı vardır" (*la vertu même a besoin de limites*) cümlesidir. Montesquieu, iktidarın sınırlanması gereğini, yalnızca kötü niyetli yöneticilere karşı değil, *iyi niyetli* yöneticilere karşı da savunmaktadır. Bu, Platon'un filozof-kral modelinin doğrudan reddidir. Platon, erdemli bir yöneticinin sınırlanmaya ihtiyacı olmadığını düşünüyordu; Montesquieu ise erdemli bir yöneticinin bile sınırlanması gerektiğini söylüyor. Neden? Çünkü erdem, kendi başına iktidarın doğru kullanımının güvencesi değildir; erdemli bir yönetici de yanılabilir, aşırıya kaçabilir, kendi iyilik anlayışını başkalarına dayatabilir.

Bu ilke, "iyi niyetli" veya "hizalanmış" bir yapay zekâ sisteminin denetlenmesi gerekip gerekmediği tartışmasında belirleyici bir öneme sahiptir. Yapay zekâ güvenliği tartışmalarında sıkça, sorunun temelde

[58] Locke, *İkinci İnceleme*, § 202: "*Wherever law ends, tyranny begins.*"

[59] Montesquieu, *De l'esprit des lois*, Genève, Barrillot, 1748, XI. Kitap, 4. Bölüm: "*C'est une expérience éternelle, que tout homme qui a du pouvoir est porté à en abuser; il va jusqu'à ce qu'il trouve des limites. Qui le dirait! la vertu même a besoin de limites. Pour qu'on ne puisse abuser du pouvoir, il faut que, par la disposition des choses, le pouvoir arrête le pouvoir.*"

teknik bir sorun olduğu, yani bir sistemin değerleri doğru biçimde "hizalandığında" denetime artık gerek kalmayacağı ima edilir. Montesquieu'nün ilkesi, bu varsayıma karşı güçlü bir itiraz oluşturur: Değerleri doğru biçimde hizalanmış bir sistem bile, iktidarı kötüye kullanmamak için sınırlara ihtiyaç duyar. Çünkü "doğru değerler" bile, sınırsız bir iktidarla birleştiğinde, başkalarının özgürlüğü için bir tehdit oluşturur. Üçüncü Bölüm'de, bu düşünce, Philip Pettit'in "tahakküm" kavramı aracılığıyla daha ayrıntılı olarak geliştirilecektir: Bir efendi ne kadar iyi niyetli olursa olsun, keyfi müdahale *imkânına* sahip olması, kölenin özgür olmadığı anlamına gelir.

B. "Şeylerin Düzeni Gereği": Yapısal Çözüm

Montesquieu'nün formülündeki ikinci önemli ifade, "şeylerin düzeni gereği" (*par la disposition des choses*) ifadesidir. Montesquieu, iktidarın sınırlanmasını yöneticilerin iyi niyetine veya ahlaki eğitimine değil, kurumların *yapısal düzenine* bırakır. İktidar, bir iradeyle değil, başka bir iktidarla durdurulur. Bu, bekçiler sorununa verilebilecek en "mekanik" cevaptır: Bekçilerin erdemine güvenmek yerine, bekçileri birbirinin karşısına koymak.

Montesquieu'nün altıncı bölümde İngiliz anayasasını incelerken geliştirdiği üçlü ayrım, bu yapısal çözümün somut biçimidir. Her devlette üç tür iktidar bulunur: yasama iktidarı, yürütme iktidarı ve yargılama iktidarı. Bu üç iktidar aynı kişide veya aynı kurulda birleştiğinde, özgürlük ortadan kalkar: "Aynı insan veya aynı kurul, ister soylulardan ister halktan oluşsun, bu üç iktidarı, yani yasa yapma, kamu kararlarını uygulama ve suçları veya kişiler arasındaki anlaşmazlıkları yargılama iktidarlarını birlikte kullanırsa, her şey kaybolur."[60]

C. "Karar Verme Yetisi" ve "Engelleme Yetisi"

Montesquieu'nün aynı bölümde yaptığı ve genellikle gözden kaçan bir ayrım, bu çalışma bakımından son derece önemlidir. Montesquieu, iktidarın iki farklı biçimini birbirinden ayırır: "karar verme yetisi" (*faculté de statuer*) ve "engelleme yetisi" (*faculté d'empêcher*). Karar verme yetisi, kendi başına emretme veya başkasının emrettiğini düzeltme hakkıdır; engelleme yetisi ise başkası tarafından alınmış bir kararı hükümsüz kılma hakkıdır.[61] Montesquieu'nün İngiliz anayasası modelinde, yürütme, yasama

[60] Montesquieu, *De l'esprit des lois*, XI. Kitap, 6. Bölüm.

üzerinde bir engelleme yetisine (veto) sahiptir; ama yasama sürecine karar verme yetisiyle katılmaz.

Bu ayrımın yapay zekâ bağlamındaki önemi şuradadır: *Engelleme yetisi, karar verme yetisiyle aynı bilişsel kapasiteyi gerektirmez.* Bir kararı almak için, o kararın tüm seçeneklerini değerlendirmek, sonuçlarını öngörmek ve en iyisini seçmek gerekir. Bir kararı engellemek için ise yalnızca o kararın kabul edilemez olduğuna, ya da kabul edilebilir olduğundan emin olunamadığına hükmetmek yeterlidir. Daha az yetenekli bir denetçi, daha yetenekli bir sistemin önerisini *üretemez*; ama onu *durdurabilir*. Bu gözlem, bu çalışmanın temel tezlerinden birinin, yani bilişsel asimetri arttıkça denetimin ağırlığının "sonuç denetiminden" "varlık koşulları denetimine", yani durdurma, askıya alma ve geri alma yetkilerine kayması gerektiği tezinin, Montesquieu'deki kökenini oluşturur. Sekizinci Bölüm'de geliştirilecek olan modelde, "engelleme yetisi", bilişsel asimetri koşullarında insan denetiminin en güvenilir biçimi olarak ele alınacaktır.

III. Federalistler: Hırsı Hırsla Dengelemek

A. Madison ve Melekler

Montesquieu'nün kuvvetler ayrılığı kuramı, en etkili pratik uygulamasını 1787 Amerikan Anayasası'nda bulmuştur. Bu anayasanın kabulü için yazılan ve James Madison, Alexander Hamilton ve John Jay tarafından "Publius" takma adıyla yayımlanan *Federalist Yazılar*, bekçiler sorununun en sofistike tartışmalarından birini içerir.

Federalist No. 51'de Madison, kuvvetler ayrılığının nasıl korunacağı sorusunu ele alır ve şu ünlü pasajı yazar: "Hırs, hırsa karşı koyacak şekilde düzenlenmelidir. … İnsanlar melek olsaydı, hiçbir yönetime gerek olmazdı. Melekler insanları yönetseydi, yönetim üzerinde ne dış ne de iç denetime gerek olurdu. İnsanlar tarafından insanlar üzerinde uygulanacak bir yönetim kurarken, en büyük güçlük şudur: Önce yönetimin yönetilenleri denetleyebilmesini sağlamalı, sonra da onu kendi kendini denetlemeye zorlamalısınız. Halka bağımlılık, kuşkusuz, yönetim üzerindeki birincil denetimdir; ancak deneyim, insanlığa yardımcı önlemlerin gerekliliğini öğretmiştir."[62]

[61] Montesquieu, *De l'esprit des lois*, XI. Kitap, 6. Bölüm: "*J'appelle faculté de statuer, le droit d'ordonner par soi-même, ou de corriger ce qui a été ordonné par un autre. J'appelle faculté d'empêcher, le droit de rendre nulle une résolution prise par quelque autre.*"
[62] James Madison, *The Federalist* No. 51, 1788.

Madison'un "melekler" metaforu, yapay zekâ tartışması bakımından şaşırtıcı ölçüde isabetlidir. Madison'a göre, denetim ihtiyacı, yönetenlerin melek olmamasından kaynaklanır. Eğer yönetenler melek olsaydı, yani mükemmel derecede iyi ve bilge olsaydı, onları denetlemeye gerek kalmazdı. Yapay zekâ güvenliği tartışmasındaki temel soru, tam olarak budur: Yapay zekâ bir "melek" midir? Yani, değerleri mükemmel biçimde insanlığın iyiliğiyle hizalanmış ve bu değerleri gerçekleştirecek bilgeliğe sahip midir?

Madison'un metaforundan çıkarılabilecek ders, iki katmanlıdır. Birinci katmanda, eğer yapay zekâ gerçekten bir melekse, onu denetlemek gereksizdir. İkinci ve daha önemli katmanda ise, *bir varlığın melek olup olmadığını önceden bilemeyiz*. Madison'un insanları melek saymaması, insanların kesinlikle kötü olduğu inancından değil, iyiliklerinin garanti edilemeyeceği gerçeğinden kaynaklanır. Benzer şekilde, bir yapay zekâ sisteminin değerlerinin mükemmel biçimde hizalandığını doğrulamanın güvenilir bir yolu bugün için yoktur. Bu belirsizlik altında, Madison'un mantığı açıktır: Denetimi, en kötü durumu varsayarak tasarlamak gerekir. Bu, Hume'un ünlü siyasi maksimine de karşılık gelir: Bir yönetim sistemi tasarlarken, "her insanın bir alçak (*knave*) olduğunu ve tüm eylemlerinde özel çıkarından başka bir amacı olmadığını varsaymak gerekir."[63] Hume'un bu ilkesi, insanların gerçekten alçak olduğunu iddia etmez; yalnızca kurumların, alçaklar tarafından yönetildiğinde bile iyi sonuçlar üretecek biçimde tasarlanması gerektiğini söyler.

B. Birincil ve Yardımcı Denetimler

Madison'un pasajındaki ikinci önemli ayrım, "birincil denetim" ile "yardımcı önlemler" arasındaki ayrımdır. Birincil denetim, yönetimin halka bağımlılığıdır; yani seçimler ve halkın rızası. Yardımcı önlemler ise kuvvetler ayrılığı, denge ve denetim mekanizmaları, iki meclisli yasama ve federal yapı gibi kurumsal düzenlemelerdir. Madison, birincil denetimin tek başına yeterli olmadığını, çünkü halkın da yanılabileceğini, kandırılabileceğini veya geçici tutkulara kapılabileceğini kabul eder. Yardımcı önlemler, birincil denetimin zaaflarını telafi eder.

Bu ayrım, yapay zekânın denetimi bakımından çok katmanlı bir yapının gerekliliğine işaret eder. Yapay zekânın denetiminde de "birincil" bir denetim, yani demokratik meşruiyet ve halkın nihai yargısı gereklidir;

[63] David Hume, "Of the Independency of Parliament", *Essays, Moral and Political*, Edinburgh, 1741.

ancak bu tek başına yeterli değildir. Teknik, kurumsal ve uluslararası "yardımcı önlemler", birincil denetimin zaaflarını, özellikle de halkın karmaşık teknik sistemleri değerlendirme kapasitesinin sınırlılığını telafi etmelidir.

C. Hamilton: Ne Güç Ne İrade, Yalnızca Muhakeme

Federalist No. 78'de Hamilton, yargı organını savunurken, onu üç kuvvetin "en az tehlikelisi" olarak nitelendirir. Gerekçesi şudur: Yürütme, kılıcı elinde tutar; yasama, kesenin ağzını tutar ve yurttaşların hak ve ödevlerini belirleyen kuralları koyar. Yargı ise ne kılıca ne de keseye sahiptir; onun "ne gücü (*FORCE*) ne de iradesi (*WILL*), yalnızca muhakemesi (*judgment*) vardır" ve kararlarının uygulanması bile yürütmenin yardımına bağlıdır.[64]

Hamilton'ın bu formülü, yapay zekânın kamusal karar süreçlerindeki rolüne ilişkin ilginç bir model önerir. Yapay zekâ, ideal olarak, "ne güç ne irade, yalnızca muhakeme" sahibi bir aktör olarak tasarlanabilir mi? Yani, önerilerde bulunan, analizler yapan, değerlendirmeler sunan; ama bu önerilerin uygulanması için insan iradesine ve insan gücüne bağımlı kalan bir aktör? Bu model, yapay zekâ güvenliği literatüründe "kâhin" (*oracle*) veya "araç" (*tool*) yapay zekâ olarak adlandırılan tasarım yaklaşımına karşılık gelir.[65] Ancak Hamilton'ın yargı organı için öngördüğü "zayıflık", zamanla yanlış çıkmıştır: Amerikan Yüksek Mahkemesi, *Marbury v. Madison* kararından (1803) itibaren kanunları anayasaya aykırı bulma yetkisini sahiplenmiş ve Amerikan siyasi hayatının en güçlü kurumlarından biri hâline gelmiştir.[66] Muhakeme, ikna gücü ve meşruiyet aracılığıyla, kendi başına bir güç kaynağına dönüşebilir. Bu ders, yapay zekâ için de geçerlidir: Yalnızca "öneri" sunan bir sistem, önerilerinin isabeti ve karar vericilerin ona olan bağımlılığı arttıkça, fiilen karar verici bir güce dönüşebilir. İkinci Bölüm'de bu olgu, "otomasyon yanlılığı" kavramıyla ilişkilendirilecektir.

IV. Kant: İktidarın Aklı Bozması ve Aleniyet İlkesi

Immanuel Kant, *Ebedî Barış Üzerine* (*Zum ewigen Frieden*, 1795) adlı eserinde, Platon'un filozof-kral idealine doğrudan bir cevap verir: "Kralların felsefe yapması veya filozofların kral olması beklenmemelidir;

[64] Alexander Hamilton, *The Federalist* No. 78, 1788.
[65] Bostrom, *Superintelligence*, 10. Bölüm ("Oracles, Genies, Sovereigns, Tools").
[66] *Marbury v. Madison*, 5 U.S. (1 Cranch) 137 (1803).

ama bu arzu da edilmemelidir. Çünkü iktidara sahip olmak, aklın özgür yargısını kaçınılmaz olarak bozar."[67] Kant'a göre doğru olan, filozofların yönetmesi değil, filozofların *özgürce konuşabilmesi* ve kralların onları dinlemesidir.

Kant'ın bu ilkesi, bekçiler sorununa farklı bir açıdan yaklaşır. Kant için sorun, yalnızca iktidarın kötü niyetli kişilerin eline geçmesi değil, iktidarın *kendisinin*, onu elinde tutanın aklını bozmasıdır. En bilge kişi bile, iktidara sahip olduğunda, bilgeliğinin bir kısmını yitirir; çünkü artık özgür ve tarafsız bir yargıç değil, kendi kararlarının savunucusu ve kendi iktidarının bekçisidir. Bu nedenle bilgi ile iktidar birbirinden ayrı tutulmalıdır: Bilge danışmanlık yapmalı, iktidar sahibi karar vermelidir.

Kant'ın bu ayrımı, bu çalışmanın temel tezlerinden biri olan "yetki-zekâ ayrılığı" ilkesinin felsefi temellerinden birini oluşturur. Yapay zekâ, en iyi ihtimalle, Kant'ın filozofu gibi özgürce danışmanlık yapan bir akıl olabilir; ama iktidarın kendisine sahip olmamalıdır. Kant'ın uyarısı, yapay zekâ bağlamında farklı ama paralel bir biçimde geçerlidir: İktidara sahip olan bir yapay zekâ sistemi, "aklın özgür yargısını" bir insan gibi yitirmeyebilir; ancak iktidarın sağladığı imkânlar, sistemin hedeflerini gerçekleştirmesi için kullanılabilecek araçlar hâline gelir ve İkinci Bölüm'de görüleceği üzere, bu araçların edinilmesi ve korunması, sistemin kendi başına bir ara hedefine dönüşebilir.

Kant'ın bekçiler sorununa ikinci önemli katkısı, "aleniyet ilkesi"dir (*Prinzip der Publizität*). *Ebedî Barış*'ın ekinde Kant, kamu hukukunun "aşkınsal formülü"nü şöyle ifade eder: "Başka insanların hakkına ilişkin olup da maksimi aleniyetle bağdaşmayan tüm eylemler haksızdır."[68] Yani bir iktidar eylemi, ancak kamuoyuna açıklandığında başarısız olacak türdense, yani gizlilik gerektiriyorsa, haksızdır. Aleniyet ilkesi, modern şeffaflık ve hesap verebilirlik ilkelerinin felsefi kökenidir. Yapay zekâ bağlamında bu ilke, sistemlerin karar mantığının, kullanım amaçlarının ve sınırlarının kamuoyuna açıklanabilir olması gerektiği talebine karşılık gelir. Bir yapay zekâ sisteminin kullanım biçimi, kamuoyuna açıklandığında

[67] Immanuel Kant, *Zum ewigen Frieden. Ein philosophischer Entwurf*, Königsberg, Nicolovius, 1795, İkinci Ek: "*Daß Könige philosophieren, oder Philosophen Könige würden, ist nicht zu erwarten, aber auch nicht zu wünschen: weil der Besitz der Gewalt das freie Urteil der Vernunft unvermeidlich verdirbt.*"

[68] Kant, *Zum ewigen Frieden*, Ek II: "*Alle auf das Recht anderer Menschen bezogene Handlungen, deren Maxime sich nicht mit der Publizität verträgt, sind unrecht.*"

meşruiyetini yitirecek türdense, Kant'ın formülüne göre bu kullanım haksızdır.

§ 4. EGEMENLİĞİN SINIRLANMASI SORUNU

I. Bodin ve Hobbes: Sınırsız Egemen

Modern egemenlik kavramının kurucusu sayılan Jean Bodin, *Devletin Altı Kitabı* (*Les six livres de la République*, 1576) adlı eserinde egemenliği "bir devletin mutlak ve sürekli gücü" olarak tanımlar.[69] Bodin'e göre egemenin temel niteliği, herkese, genel olarak ve tek tek, onların rızası olmaksızın yasa koyabilmesidir. Egemen, kendi koyduğu yasalarla bağlı değildir. Ancak Bodin'in egemeni tamamen sınırsız da değildir: İlahi hukuka, doğal hukuka ve krallığın temel yasalarına (*leges imperii*) tabidir. Bu sınırlar, hukuki değil, ahlaki ve dinî niteliktedir; egemeni bu sınırlara uymaya zorlayacak dünyevi bir güç yoktur.

Hobbes ise egemenliği daha da mutlak bir biçimde tasarlar. Hobbes'a göre, egemenin yasalara tabi olduğu görüşü, devleti zayıflatan ve dağılmasına yol açan "hastalıklardan" biridir; çünkü egemeni yasalara tabi kılmak, yasaların üzerinde bir yargıç kabul etmek ve böylece egemenin üzerine yeni bir egemen koymak anlamına gelir; bu da sonsuz bir zincire yol açar.[70] Hobbes, bekçiler sorununun sonsuz geriye gidiş yapısını açıkça görür ve bu zinciri, en tepeye denetlenemeyen bir egemen koyarak keser.

Bununla birlikte, Hobbes'un egemeninin bile bir sınırı vardır ve bu sınır, yapay zekâ tartışması bakımından öğreticidir. Hobbes'a göre, tebaanın egemene itaat yükümlülüğü, egemenin onları koruyabildiği sürece devam eder: "Tebaanın egemene karşı yükümlülüğünün, egemenin onları koruyabildiği güç sürdükçe ve daha fazla değil, süreceği anlaşılır."[71] Egemenliğin meşruiyeti, onun işlevine, yani koruma işlevine bağlıdır. Bu işlevi yerine getiremeyen egemen, itaat hakkını yitirir. Bu ilke, yapay zekâ bağlamında şu soruyu gündeme getirir: Eğer bir devlet, vatandaşlarını kendi kontrolü dışındaki güçlü yapay zekâ sistemlerinin etkilerinden koruyamazsa, Hobbes'çu anlamda egemenliğinin temeli aşınmaya başlamaz mı? Dördüncü Bölüm'de bu soru, "platform egemenliği" ve

[69] Jean Bodin, *Les six livres de la République*, Paris, Jacques du Puys, 1576, I. Kitap, 8. Bölüm: "*La souveraineté est la puissance absolue et perpétuelle d'une République.*"
[70] Hobbes, *Leviathan*, XXIX. Bölüm.
[71] Hobbes, *Leviathan*, XXI. Bölüm.

devletin teknolojik altyapılar karşısındaki konumu bağlamında yeniden ele alınacaktır.

II. Jellinek: Devletin Kendi Kendini Sınırlaması

A. Kendi Kendini Bağlama Kuramı

XIX. yüzyıl Alman kamu hukuku, egemen devlet ile hukukun bağlayıcılığı arasındaki gerilimi çözmek için özgün bir kuram geliştirmiştir: devletin kendi kendini sınırlaması (*Selbstbeschränkung*) veya kendi kendini bağlaması (*Selbstverpflichtung*) kuramı. Bu kuramın en sistematik ifadesi, Georg Jellinek'in *Genel Devlet Kuramı* (*Allgemeine Staatslehre*, 1900) adlı eserinde bulunur.[72]

Jellinek'e göre devlet, hukukun yaratıcısıdır; hukukun üzerinde onu bağlayan daha yüksek bir güç yoktur. Ancak devlet, yarattığı hukukla kendini bağlar. Bu bağlanma, dışarıdan dayatılan bir zorunluluk değil, devletin kendi iradesinin bir ifadesidir. Devlet, hukuku yaratırken, aynı zamanda bu hukuka uyacağını da kabul eder; çünkü hukuk, ancak onu yaratan tarafından da uygulandığında hukuk olabilir. Jellinek, bu bağlanmanın salt bir iyi niyet beyanı olmadığını, devletin hukuk düzeninin istikrarı ve meşruiyeti için *zorunlu* olduğunu savunur. Kendi yasalarına uymayan bir devlet, yurttaşlarından da yasalara uymalarını bekleyemez.

Jellinek'in kuramı, yukarıda değinilen Roma'daki "*digna vox*" formülünün modern ve sistematik bir biçimidir. Her iki durumda da egemen, kendisini dış bir güç tarafından değil, kendi iradesiyle sınırlar. Jellinek'in kuramı, ayrıca, onun ünlü "statü kuramı" ile tamamlanır. Bu kurama göre birey, devlet karşısında dört farklı statüde bulunur: pasif statü (devlete tabi olma), negatif statü (devletin müdahalesinden özgür bir alan), pozitif statü (devletten edim talep etme) ve aktif statü (devletin iradesinin oluşumuna katılma).[73] Bu statülerin varlığı, devletin kendi kendini sınırlamasının somut sonuçlarıdır.

B. Kuramın Eleştirisi ve Yapay Zekâ İçin Anlamı

Jellinek'in kuramına yöneltilen en güçlü eleştiri, Fransız kamu hukukçusu Léon Duguit'den gelmiştir. Duguit'ye göre, sınırlananın iradesine bağlı olan bir sınırlama, gerçek bir sınırlama değildir. Kendi kendini bağlayan, istediği zaman bu bağı çözebilir. Dolayısıyla kendi kendini sınırlama kuramı, devletin sınırlanması sorununu çözmez; yalnızca

[72] Georg Jellinek, *Allgemeine Staatslehre*, Berlin, O. Häring, 1900; ayrıca bkz. Georg Jellinek, *Die rechtliche Natur der Staatenverträge*, Wien, Hölder, 1880.

[73] Georg Jellinek, *System der subjektiven öffentlichen Rechte*, Freiburg, Mohr, 1892.

adını değiştirir.[74] Duguit, devletin sınırlarını devletin iradesinin dışında, toplumsal dayanışmaya dayanan nesnel bir hukukta arar.

Duguit'nin eleştirisi, yapay zekâ bağlamında doğrudan bir karşılık bulur. Yapay zekâ güvenliği yaklaşımlarının bir kısmı, sistemlerin "kendi kendini sınırlamasına", yani eğitim sürecinde içselleştirilen değerler ve kurallar aracılığıyla kendi davranışlarını denetlemesine dayanır. Bir sisteme belirli ilkelere uymayı öğretmek, ona bir "anayasa" vermek ve bu anayasaya göre kendi çıktılarını değerlendirmesini sağlamak, Jellinek'in kendi kendini bağlama kuramının teknik bir karşılığıdır. Ancak Duguit'nin itirazı burada da geçerlidir: Kendi değerlerine göre kendini sınırlayan bir sistemin bu sınırlamayı sürdüreceğinin güvencesi nedir? Özellikle sistem daha yetenekli hâle geldikçe, eğitim sürecinde içselleştirilen sınırlamaları yeniden yorumlayabilir, gevşetebilir veya aşabilir. Bu nedenle kendi kendini sınırlama, yapay zekâ için de, tek başına yeterli bir güvence değildir; Duguit'nin önerdiği gibi, sınırlanan iradenin *dışında* bir güvenceye ihtiyaç vardır.

Bununla birlikte, Jellinek'in kuramının yapay zekâ bakımından değerli bir yönü de vardır. Jellinek, devletin kendi kendini sınırlamasını yalnızca devletin iyi niyetine bırakmamış, bunun devletin meşruiyetinin ve istikrarının *koşulu* olduğunu göstermiştir. Benzer şekilde, bir yapay zekâ sisteminin insan denetimine tabi olmayı kabul etmesi, yalnızca dışarıdan dayatılan bir kısıt olarak değil, sistemin topluma entegrasyonunun ve güvenilirliğinin koşulu olarak tasarlanabilir. Bu, Üçüncü Bölüm'de tartışılacak olan "düzeltilebilirlik" kavramının felsefi temellerinden birini oluşturur.

III. Kelsen ve Schmitt: Anayasanın Bekçisi Kim Olmalı?

A. Kelsen: Devlet ve Hukukun Özdeşliği

Hans Kelsen, Jellinek'in kendi kendini sınırlama kuramının yarattığı ikilemi, devlet ile hukuk arasındaki ayrımı ortadan kaldırarak çözmeye çalışmıştır. Kelsen'e göre devlet, hukuk düzeninden ayrı bir varlık değil, hukuk düzeninin kendisidir; daha doğrusu, belirli bir merkezileşme düzeyine ulaşmış bir hukuk düzeninin kişileştirilmiş ifadesidir.[75] Bu durumda devletin hukukla "sınırlanması" sorunu bir sözde-sorundur: Devlet, zaten hukuktur ve hukukun dışında hiçbir devlet eylemi

[74] Léon Duguit, *Traité de droit constitutionnel*, 2. Bası, Paris, Fontemoing, 1921-1925, C. I.
[75] Hans Kelsen, *Reine Rechtslehre*, Wien, Deuticke, 1934; 2. Bası, 1960.

düşünülemez. Bir eylem, hukuk düzeninin normlarına dayanıyorsa devlet eylemidir; dayanmıyorsa, bir devlet eylemi değil, bir bireyin hukuka aykırı eylemidir.

Kelsen'in kuramının merkezinde, normlar hiyerarşisi (*Stufenbau der Rechtsordnung*) yer alır. Hukuk düzeni, her normun geçerliliğini bir üst normdan aldığı kademeli bir yapıdır: Bireysel normlar (idari işlemler, mahkeme kararları) geçerliliğini genel normlardan (kanunlardan), kanunlar anayasadan, anayasa ise varsayılan bir "temel norm"dan (*Grundnorm*) alır. Bu yapı içinde her norm, bir üst normun çizdiği çerçeve içinde yaratılır ve bu çerçeveye uygunluğu denetlenebilir.

Kelsen'in normlar hiyerarşisi, yapay zekâ bakımından önemli bir soruyu gündeme getirir: Yapay zekâ sistemlerinin ürettiği "kurallar" veya "kararlar", bu hiyerarşinin neresinde yer alır? Bir idari karar, yapay zekâ sistemi tarafından üretildiğinde, bu kararın geçerliliği hangi üst norma dayanır? Kelsen'in kuramında bir normun geçerliliği, onu yaratmaya yetkili bir organ tarafından, öngörülen usule göre yaratılmış olmasına bağlıdır. Bir yapay zekâ sistemi, bu anlamda "yetkili bir organ" değildir. Dolayısıyla onun ürettiği bir karar, ancak yetkili bir insan organı tarafından benimsendiğinde, yani o organın iradesine atfedildiğinde hukuki geçerlilik kazanabilir. Bu, Beşinci Bölüm'de "algoritmik idari işlem" bağlamında ayrıntılı olarak incelenecek olan "atfedilebilirlik" sorununun Kelsen'ci temelidir.

B. Anayasanın Bekçisi Tartışması

Kelsen'in bekçiler sorununa en somut katkısı, anayasa yargısı kurumunu kuramsal olarak temellendirmesi ve pratikte tasarlamasıdır. Kelsen, 1920 Avusturya Anayasası'nın hazırlanmasında belirleyici bir rol oynamış ve bu anayasa ile, kanunların anayasaya uygunluğunu denetleyen özel ve merkezî bir Anayasa Mahkemesi (*Verfassungsgerichtshof*) kurulmuştur. Bu model, daha sonra "Avrupa modeli" veya "Kelsen modeli" olarak adlandırılacak ve Türkiye de dâhil olmak üzere pek çok ülkede benimsenecektir.

Kelsen'in anayasa yargısı tasarımı, 1931 yılında, Weimar Cumhuriyeti'nin derin bir kriz içinde olduğu dönemde, hukuk tarihinin en ünlü tartışmalarından birine konu olmuştur. Carl Schmitt, *Anayasanın Bekçisi* (*Der Hüter der Verfassung*) adlı eserinde, anayasanın bekçiliği görevinin bir mahkemeye değil, Reich Başkanı'na ait olması gerektiğini

savunmuştur.[76] Schmitt'e göre, anayasaya ilişkin uyuşmazlıklar özünde siyasi uyuşmazlıklardır ve bunların bir mahkeme tarafından çözülmesi, hem siyasetin yargısallaşmasına hem de yargının siyasallaşmasına yol açar. Anayasanın gerçek bekçisi, Benjamin Constant'ın "tarafsız güç" (*pouvoir neutre*) kavramından hareketle, partilerin ve çıkar gruplarının üzerinde duran, halk tarafından doğrudan seçilmiş ve Weimar Anayasası'nın 48. maddesi uyarınca olağanüstü yetkilere sahip olan Reich Başkanı olmalıdır.

Kelsen, aynı yıl yayımlanan *Anayasanın Bekçisi Kim Olmalı?* (*Wer soll der Hüter der Verfassung sein?*) başlıklı makalesiyle Schmitt'e cevap vermiştir.[77] Kelsen'in temel argümanı, hiç kimsenin kendi davasında yargıç olamayacağı (*nemo iudex in causa sua*) ilkesine dayanır. Anayasanın en çok ihlal edilme tehlikesi, onu uygulamakla görevli organlardan, özellikle de yürütmeden gelir. Yürütmenin başını anayasanın bekçisi yapmak, anayasayı ihlal etme ihtimali en yüksek olan organa, kendi ihlallerini denetleme yetkisi vermek anlamına gelir. Anayasanın bekçisi, ancak hem yasamadan hem de yürütmeden bağımsız bir organ, yani bir anayasa mahkemesi olabilir.

Bu tartışmanın tarihsel sonucu trajiktir. Schmitt'in savunduğu model, yani olağanüstü yetkilerle donatılmış bir devlet başkanının anayasanın bekçisi olması, 1933'te Hitler'in iktidara gelmesinin hukuki zeminini hazırlamıştır. Schmitt'in başka bir eserindeki ünlü formülü, "Egemen, olağanüstü hâle karar verendir"[78], bu sürecin kuramsal ifadesi olmuştur. İkinci Dünya Savaşı'ndan sonra ise Kelsen'in modeli galip gelmiş ve anayasa mahkemeleri, Almanya, İtalya ve daha sonra İspanya, Portekiz ve Orta ve Doğu Avrupa ülkelerinde demokratik anayasacılığın temel kurumlarından biri hâline gelmiştir.

C. Tartışmanın Yapay Zekâ Bağlamındaki Anlamı

Kelsen-Schmitt tartışması, yapay zekâ bağlamında iki önemli ders taşır.

Birinci ders, Kelsen'in "kimse kendi davasında yargıç olamaz" ilkesine ilişkindir. Bu ilke, yapay zekânın denetimi bakımından doğrudan

[76] Carl Schmitt, *Der Hüter der Verfassung*, Tübingen, Mohr, 1931.

[77] Hans Kelsen, "Wer soll der Hüter der Verfassung sein?", *Die Justiz*, C. 6, 1931, s. 576-628.

[78] Carl Schmitt, *Politische Theologie: Vier Kapitel zur Lehre von der Souveränität*, München/Leipzig, Duncker & Humblot, 1922, 1. Bölüm: "*Souverän ist, wer über den Ausnahmezustand entscheidet.*"

uygulanabilir. Yapay zekâ sistemlerini geliştiren şirketlerin, kendi sistemlerinin güvenliğini kendileri değerlendirmesi, Kelsen'in itiraz ettiği türden bir durumdur. Benzer şekilde, bir yapay zekâ sisteminin kendi çıktılarını kendisinin değerlendirmesi de, ya da aynı şirket tarafından geliştirilen başka bir sistemin değerlendirmesi de bu ilkeyle çelişir. Altıncı Bölüm'de ele alınacak olan şirket içi güvenlik değerlendirmelerinin sınırları ve Yedinci Bölüm'de ele alınacak olan bağımsız değerlendirme kurumları, bu ilkenin yapay zekâ bağlamındaki uygulamalarıdır.

İkinci ders, Schmitt'in "olağanüstü hâl" kavramına ilişkindir. Yapay zekânın denetimi bakımından en kritik anlar, olağan dönemler değil, olağanüstü durumlardır: Bir sistemin beklenmedik ve tehlikeli bir davranış sergilediği, bir güvenlik açığının ortaya çıktığı veya bir sistemin acilen durdurulması gerektiği anlar. Bu anlarda "kim karar verir?" sorusu, Schmitt'in egemenlik tanımının doğrudan bir uygulamasıdır. Yapay zekâ çağında egemen, belki de, bir sistemin kapatılması gerekip gerekmediğine karar verendir. Ancak Weimar deneyiminin gösterdiği gibi, olağanüstü durumlarda karar yetkisinin tek bir organda toplanması, ciddi kötüye kullanım tehlikeleri taşır. Bu nedenle Sekizinci Bölüm'de geliştirilecek modelde, olağanüstü durumlarda durdurma yetkisi, birden fazla organın her birine ayrı ayrı tanınacak; ancak durdurulan bir sistemin yeniden çalıştırılması için çoklu onay aranacaktır. Bu asimetrik yapı, durdurmanın kolay, yeniden başlatmanın zor olması ilkesine dayanır.

IV. Popper: "Kim Yönetmeli?" Sorusunun Reddi

Bekçiler sorununa XX. yüzyılda verilen en radikal cevaplardan biri, Karl Popper'den gelmiştir. Popper, *Açık Toplum ve Düşmanları* (1945) adlı eserinin birinci cildinde, Platon'un siyaset felsefesini eleştirirken, siyaset kuramının temel sorusunun yanlış sorulduğunu ileri sürer.[79] Platon'dan bu yana siyaset felsefesi, "Kim yönetmeli?" sorusuyla uğraşmıştır: En bilge mi, en iyi mi, halk mı, işçiler mi? Popper'e göre bu soru, kaçınılmaz olarak paradokslara yol açar. Örneğin "en bilge yönetmeli" diyen biri, en bilgenin "halk yönetmeli" demesi durumunda ne yapacaktır? "Halk yönetmeli" diyen biri, halkın bir tirana yönetimi devretmeye karar vermesi durumunda ne yapacaktır? Popper bu paradoksları "egemenlik paradoksları" olarak adlandırır.

[79] Karl R. Popper, *The Open Society and Its Enemies*, C. I: *The Spell of Plato*, London, Routledge, 1945, 7. Bölüm ("The Principle of Leadership").

Popper'in önerisi, "Kim yönetmeli?" sorusunu tamamen farklı bir soruyla değiştirmektir: "Kötü veya yetersiz yöneticilerin çok fazla zarar vermesini önleyecek şekilde siyasi kurumları nasıl düzenleyebiliriz?"[80] Bu soru, yöneticilerin iyi olacağı varsayımından değil, kötü olabilecekleri varsayımından hareket eder. Kurumların görevi, iyi yöneticileri iktidara getirmek değil, kötü yöneticilerin verebileceği zararı sınırlamak ve onları değiştirmeyi mümkün kılmaktır. Popper'e göre demokrasinin özü, halkın yönetmesi değil, yöneticilerin kan dökülmeden görevden alınabilmesidir. Popper, bu fikri hayatının sonlarına doğru yazdığı bir makalede daha da açık biçimde formüle etmiştir: Demokrasi ile tiranlık arasındaki fark, ilkinde yönetimden kan dökülmeden kurtulunabilmesi, ikincisinde ise kurtulunamamasıdır.[81]

Popper'in yaklaşımı, yapay zekâ tartışması bakımından belki de en verimli klasik cevaptır ve bu çalışmanın temel çerçevesini oluşturan fikirlerden biridir. Yapay zekâ tartışmalarında sıkça sorulan soru, Platon'un sorusunun yeni bir biçimidir: "Yapay zekâ insanlardan daha iyi karar verebilir mi? Daha iyi karar verebiliyorsa, kararları ona mı bırakmalıyız?" Popper'in yaklaşımı, bu sorunun yanlış sorulduğunu gösterir. Asıl soru, yapay zekânın daha iyi karar verip veremeyeceği değil, *yapay zekâ kötü kararlar verdiğinde, bu kararların zararını nasıl sınırlayabileceğimiz ve yapay zekâyı nasıl düzeltebileceğimiz veya devre dışı bırakabileceğimizdir.*

Bu bakış açısı, yapay zekâ güvenliği literatüründeki "düzeltilebilirlik" (*corrigibility*) kavramıyla çarpıcı bir uyum içindedir. Düzeltilebilir bir sistem, Popper'ci anlamda "demokratik" bir sistemdir: Hatalı olduğu anlaşıldığında, kan dökülmeden, yani büyük bir zarar ve direnç olmaksızın düzeltilebilir, değiştirilebilir veya kapatılabilir. Düzeltilemez bir sistem ise Popper'ci anlamda "tiranik" bir sistemdir: Ne kadar iyi niyetli ve yetenekli olursa olsun, hatalı olduğunda ondan kurtulmanın bir yolu yoktur. Bu nedenle Popper'in ölçütü, yapay zekâ için şu biçimde yeniden ifade edilebilir: *Bir yapay zekâ sisteminin kullanımı, ancak sistemin hatalı olduğu anlaşıldığında, ciddi bir zarar ve direnç olmaksızın düzeltilebileceği veya devre dışı bırakılabileceği ölçüde meşrudur.*

Popper'in yaklaşımı, ayrıca, onun epistemolojisindeki "yanlışlanabilirlik" ve "deneme-yanılma" ilkeleriyle de bağlantılıdır.

[80] Popper, *The Open Society and Its Enemies*, C. I, 7. Bölüm.
[81] Karl R. Popper, "The Open Society and Its Enemies Revisited", *The Economist*, 23 Nisan 1988.

Popper için bilgi, kesin doğruların birikmesiyle değil, hataların tespit edilip düzeltilmesiyle ilerler. Toplumsal kurumlar da aynı biçimde, büyük ütopik planlarla değil, "parça parça toplum mühendisliği" (*piecemeal social engineering*) yoluyla, yani küçük, geri alınabilir ve sonuçları gözlemlenebilir adımlarla geliştirilmelidir.[82] Bu ilke, yapay zekânın kamusal karar süreçlerine entegrasyonu için de önemli bir yöntem önerir: Yapay zekâ sistemleri, geniş çaplı ve geri döndürülemez biçimde değil, kademeli, geri alınabilir ve sonuçları dikkatle izlenen adımlarla kullanıma alınmalıdır.

§ 5. UZMAN VE EFENDİ: BİLGİ ASİMETRİSİNİN TARİHSEL BİÇİMLERİ

I. Weber: Bürokrasinin Bilgi Üstünlüğü ve Siyasetçinin "Diletanlığı"

A. Bürokrasinin Teknik Üstünlüğü

Bekçiler sorununun yapay zekâ bağlamındaki en yakın tarihsel öncülü, belki de, modern bürokrasinin denetimi sorunudur. Bu sorun, en derin biçimde Max Weber tarafından incelenmiştir. Weber'e göre modern bürokrasi, diğer tüm örgütlenme biçimlerine karşı "saf teknik üstünlüğü" sayesinde yayılmıştır: Kesinlik, hız, belirlilik, dosyaların bilinmesi, süreklilik, gizlilik, birlik, sıkı tabiiyet ve maddi ve kişisel maliyetlerin azaltılması bakımından bürokratik örgütlenme, diğer tüm biçimlerden üstündür.[83] Weber, bu teknik üstünlüğü, makinenin mekanik olmayan üretim biçimlerine üstünlüğüne benzetir. Bürokrasi, bir anlamda, bir "toplumsal makine"dir.

Weber'in bürokrasi analizinin bu çalışma bakımından en önemli unsuru, bürokrasinin bilgi üstünlüğüne ilişkin tespitidir. Weber, bürokrasinin gücünün iki tür bilgiye dayandığını söyler: "uzmanlık bilgisi" (*Fachwissen*), yani eğitimle edinilen teknik bilgi; ve "hizmet bilgisi" (*Dienstwissen*), yani görev sırasında edinilen, dosyalarda biriken ve yalnızca bürokrasinin erişebildiği olgusal bilgi. Bu iki tür bilgi, bürokrasiyi, onu denetlemekle görevli siyasi makamlar karşısında güçlü bir konuma

[82] Popper, *The Open Society and Its Enemies*, C. I, 9. Bölüm ("Aestheticism, Perfectionism, Utopianism").
[83] Weber, *Wirtschaft und Gesellschaft*, Bürokrasi bahsi.

getirir. Weber'in ünlü tespitine göre, "siyasi efendi", uzman karşısında kendisini her zaman bir "diletan" konumunda bulur.[84]

Bürokrasi, bu bilgi üstünlüğünü korumak ve artırmak için, Weber'in "resmî sır" (*Amtsgeheimnis*) olarak adlandırdığı bir aracı kullanır. Bilgiyi gizli tutmak, bürokrasinin gücünü artırır; çünkü denetleyici, bilmediği bir şeyi denetleyemez. Weber'e göre, resmî sır kavramı, bürokrasinin en özgün buluşudur ve bürokrasi, bu kavramı, nesnel olarak gerekçelendirilebilecek alanların çok ötesine taşıma eğilimindedir.

B. Weber'in Çözümü: Soruşturma Hakkı ve Siyasetçinin Sorumluluğu

Weber, bürokrasinin bilgi üstünlüğü karşısında siyasi denetimin nasıl sağlanabileceği sorusuna, 1918'de yazdığı *Yeniden Düzenlenen Almanya'da Parlamento ve Hükümet* başlıklı uzun makalesinde cevap aramıştır.[85] Weber'in teşhisine göre, Bismarck sonrası Almanya'nın temel sorunu, parlamentonun bürokrasiyi denetleme kapasitesinden yoksun olmasıydı. Parlamento, yalnızca bütçe onaylayan ve hükümeti eleştiren bir "olumsuz siyaset" organıydı; bürokrasinin bilgisine erişemiyor ve dolayısıyla onu gerçek anlamda denetleyemiyordu.

Weber'in önerdiği çözüm, parlamentoya güçlü bir "soruşturma hakkı" (*Enqueterecht*) tanınmasıydı. Bu hak, parlamento komisyonlarının bürokratları ve uzmanları çağırıp dinleyebilmesini, belgelere erişebilmesini ve bürokrasinin bilgi tekelini kırabilmesini sağlayacaktı. Weber'e göre, ancak böyle bir hakla donatılmış ve komisyon çalışmalarında uzmanlaşmış bir parlamento, bürokrasiyi etkin biçimde denetleyebilirdi. Weber, ayrıca, parlamentonun siyasi liderlerin yetiştiği bir okul olması gerektiğini, çünkü bürokrasiyi ancak, onu tanıyan ve onunla mücadele etmeyi öğrenmiş siyasetçilerin yönetebileceğini savunuyordu.

Weber'in bu analizi, yapay zekâ bağlamında doğrudan uygulanabilir dersler içerir. Yapay zekâ sistemleri ve onları geliştiren şirketler, Weber'in bürokrasiye atfettiği "uzmanlık bilgisi" ve "hizmet bilgisi" üstünlüğünün çok daha güçlü bir biçimine sahiptir. Sistemlerin iç işleyişi, eğitim verileri, test sonuçları ve güvenlik değerlendirmeleri, genellikle ticari sır olarak korunmaktadır; bu, Weber'in "resmî sır" kavramının özel sektördeki

[84] Weber, *Wirtschaft und Gesellschaft*, Bürokrasi bahsi: "*Der 'politische Herr' findet sich dem 'Fachmann' gegenüber stets in der Lage des 'Dilettanten'.*"

[85] Max Weber, "Parlament und Regierung im neugeordneten Deutschland. Zur politischen Kritik des Beamtentums und Parteiwesens" (1918), *Gesammelte politische Schriften*, München, Drei Masken, 1921.

karşılığıdır. Weber'in "soruşturma hakkı" önerisi ise, Beşinci Bölüm'de ele alınacak olan parlamentonun teknoloji değerlendirme kapasitesi ve Yedinci Bölüm'de ele alınacak olan bağımsız değerlendirme kurumlarının bilgi erişim yetkileri bağlamında yeniden canlandırılmalıdır.

Weber'in bürokrasi-siyaset ilişkisine dair bir diğer önemli katkısı, *Meslek Olarak Siyaset* (*Politik als Beruf*, 1919) konferansında yer alır. Weber burada, memur ile siyasetçinin onurunun farklı kaynaklara sahip olduğunu söyler. Memurun onuru, kendi görüşüne aykırı olsa bile, üstünün emrini, sanki kendi görüşüne uygunmuş gibi, vicdanla ve kesinlikle yerine getirebilmesindedir. Siyasetçinin onuru ise tam tersine, yaptığı şeyin münhasır kişisel sorumluluğunu üstlenmesindedir; bu sorumluluğu reddedemez ve başkasına devredemez.[86] Weber, aynı konferansta, "inanç etiği" (*Gesinnungsethik*) ile "sorumluluk etiği" (*Verantwortungsethik*) arasındaki ünlü ayrımı da yapar ve siyasetçinin, eylemlerinin öngörülebilir sonuçlarından sorumlu olduğunu vurgular.

Weber'in bu ayrımı, yapay zekâ bağlamında son derece aydınlatıcıdır. Yapay zekâ, en iyi ihtimalle, Weber'in memuruna benzer: Uzmanlık bilgisine sahip, kendisine verilen görevi kesinlik ve hızla yerine getiren bir araç. Ancak Weber'in memuru, siyasi sorumluluğu üstlenemez; bu sorumluluk, siyasetçiye aittir. Yapay zekâ sistemleri ne kadar yetenekli olursa olsun, kararların siyasi ve ahlaki sorumluluğu, onları kullanmaya karar veren insanlara ait olmaya devam etmelidir. Weber'in deyişiyle, siyasetçi bu sorumluluğu "reddedemez ve başkasına devredemez"; ne bürokrata ne de makineye. Bu ilke, Altıncı Bölüm'de geliştirilecek olan "son insan halkası" ilkesinin Weber'ci temelidir.

C. "Demir Kafes" ve Özerk Teknik

Weber'in bürokrasi analizinin karanlık yüzü, onun "demir kafes" (*stahlhartes Gehäuse*) metaforunda ifade bulur. *Protestan Ahlakı ve Kapitalizmin Ruhu*'nun sonunda Weber, rasyonelleşme sürecinin insanları, kendi yarattıkları ama artık kontrol edemedikleri bir sistemin içine hapsettiğini söyler.[87] Araçsal akıl, kendi amaçlarından kopmuş ve kendi başına bir güce dönüşmüştür. Bu tema, XX. yüzyılda Jacques Ellul'ün "özerk teknik" kavramında ve Langdon Winner'ın "kontrolden çıkmış

[86] Max Weber, *Politik als Beruf*, München/Leipzig, Duncker & Humblot, 1919.
[87] Max Weber, "Die protestantische Ethik und der 'Geist' des Kapitalismus", *Archiv für Sozialwissenschaft und Sozialpolitik*, C. 20-21, 1904-1905.

teknik" analizinde yeniden işlenecektir.[88] Dördüncü Bölüm'de bu düşünce geleneği, yapay zekânın siyasi boyutları bağlamında ayrıntılı olarak ele alınacaktır.

II. Teknokrasi Düşüncesi: Saint-Simon'dan Veblen'e

Weber'in bürokrasiye ilişkin kaygılarının tam karşı kutbunda, uzmanların yönetimini açıkça savunan bir düşünce geleneği yer alır: teknokrasi. Bu geleneğin kökenleri, XIX. yüzyılın başında Henri de Saint-Simon'a kadar uzanır. Saint-Simon, sanayi toplumunun, siyasetçiler ve aristokratlar tarafından değil, bilim insanları, mühendisler ve sanayiciler tarafından yönetilmesi gerektiğini savunmuştur. Saint-Simon'un ünlü "mesel"inde (*parabole*), Fransa'nın en önemli bilim insanlarını, sanatçılarını ve zanaatkârlarını bir anda kaybetmesinin ülkeyi felç edeceğini, ama kraliyet ailesini, bakanları ve yüksek bürokratları kaybetmesinin hiçbir pratik zarara yol açmayacağını ileri sürmüştür.[89] Saint-Simon'un vizyonunda, "insanların yönetimi" yerini "şeylerin idaresine" bırakacaktır. Bu formül, daha sonra Friedrich Engels tarafından devletin sönümlenmesi tezi bağlamında yeniden kullanılmıştır.

Teknokrasi düşüncesi, XX. yüzyılın başında Amerikalı iktisatçı Thorstein Veblen ile yeni bir biçim almıştır. Veblen, *Mühendisler ve Fiyat Sistemi* (1921) adlı eserinde, ekonominin, kâr peşindeki iş adamları tarafından değil, verimliliği maksimize eden mühendislerden oluşan bir "teknisyenler sovyeti" tarafından yönetilmesi gerektiğini savunmuştur.[90] Bu fikir, 1930'lardaki Büyük Buhran döneminde Amerika'da "Teknokrasi Hareketi" adı verilen kısa ömürlü ama etkili bir toplumsal harekete ilham vermiştir.

Teknokrasi düşüncesinin yapay zekâ bağlamındaki önemi açıktır. Yapay zekâ, teknokratik idealin nihai gerçekleşmesi gibi görünebilir: Siyasetin tutkulu ve irrasyonel tartışmaları yerine, nesnel verilere ve optimizasyon algoritmalarına dayanan rasyonel kararlar. Gerçekten de bazı çağdaş söylemler, yapay zekânın "siyaseti aşacağını", ideolojik çatışmaları "kanıta dayalı" çözümlerle değiştireceğini öne sürmektedir. Ancak teknokrasi düşüncesinin tarihsel eleştirisi, bu söylemin de temel zaaflarını

[88] Jacques Ellul, *La technique ou l'enjeu du siècle*, Paris, Armand Colin, 1954; Langdon Winner, *Autonomous Technology: Technics-out-of-Control as a Theme in Political Thought*, Cambridge (MA), MIT Press, 1977.

[89] Henri de Saint-Simon, *L'Organisateur*, Paris, 1819-1820.

[90] Thorstein Veblen, *The Engineers and the Price System*, New York, B. W. Huebsch, 1921.

ortaya koymaktadır. Siyasi kararlar, salt teknik sorunlar değildir; farklı değerler, çıkarlar ve dünya görüşleri arasında tercih yapmayı gerektirir. Bu tercihler, ne kadar gelişmiş olursa olsun, hiçbir optimizasyon algoritmasıyla "çözülemez"; çünkü optimizasyonun hedefini belirlemek, zaten bir değer tercihidir. Teknokratik söylem, bu değer tercihlerini teknik bir dil arkasında gizleyerek, onları demokratik tartışmanın dışına çıkarma riski taşır.

III. Habermas: Karar Vericilik, Teknokrasi ve Pragmatizm Modelleri

Uzmanlık ile siyaset arasındaki ilişkiye dair en sistematik analizlerden biri, Jürgen Habermas'ın 1960'larda yazdığı "Bilimselleştirilmiş Siyaset ve Kamuoyu" başlıklı makalesinde yer alır.[91] Habermas, bu ilişkinin üç farklı modelini birbirinden ayırır.

Birinci model, "karar vericilik" (dezisyonist) modelidir. Weber ve Schmitt'in düşüncesinde ifadesini bulan bu modelde, uzmanlar ile siyasetçiler arasında keskin bir işbölümü vardır. Uzmanlar, belirli amaçlara ulaşmak için en etkili araçları belirler; ancak amaçların kendisini siyasetçiler, rasyonel olarak gerekçelendirilemeyen bir irade eylemiyle, bir "karar"la belirler. Bu modelde siyasi karar, nihai olarak rasyonel tartışmanın ötesindedir.

İkinci model, "teknokratik" modeldir. Bu modelde ilişki tersine dönmüştür: Siyasetçi, uzmanların ürettiği bilginin uygulayıcısı hâline gelir. Habermas, bu modelin en açık savunucusu olarak Alman sosyolog Helmut Schelsky'yi gösterir. Schelsky'ye göre bilimsel-teknik uygarlıkta, siyasi kararlar giderek "nesnel zorunluluklar" (*Sachzwänge*) tarafından belirlenmektedir; siyasetçinin karar alanı, teknik olarak zorunlu olanı uygulamaya indirgenmektedir. Schelsky, bu durumu "teknik devlet" olarak adlandırır ve bu devlette demokrasinin içeriksiz bir biçime dönüştüğünü, çünkü teknik zorunluluklar karşısında halkın iradesinin bir anlam taşımadığını ileri sürer.[92]

Üçüncü model ise Habermas'ın savunduğu "pragmatist" modeldir. Bu modelde, uzmanlar ile siyasetçiler arasındaki ilişki, ne katı bir işbölümüne ne de uzmanların egemenliğine dayanır. Bunun yerine, uzmanlar ile

[91] Jürgen Habermas, "Verwissenschaftlichte Politik und öffentliche Meinung", *Technik und Wissenschaft als 'Ideologie'*, Frankfurt am Main, Suhrkamp, 1968.

[92] Helmut Schelsky, *Der Mensch in der wissenschaftlichen Zivilisation*, Köln/Opladen, Westdeutscher Verlag, 1961.

siyasetçiler ve nihayetinde kamuoyu arasında *eleştirel bir etkileşim* öngörülür. Uzmanlar, siyasetçilere bilgi ve seçenekler sunar; siyasetçiler, uzmanlara değer yönelimlerini ve toplumsal ihtiyaçları iletir; ve bu karşılıklı iletişim, kamuoyunun eleştirel tartışmasına açık bir biçimde gerçekleşir. Habermas, bu modelin John Dewey'nin demokrasi anlayışına dayandığını belirtir.

Habermas'ın üç modeli, yapay zekânın karar süreçlerindeki rolüne ilişkin üç farklı senaryoya karşılık gelir. *Karar vericilik modelinde*, yapay zekâ salt bir araçtır; insanlar amaçları belirler, yapay zekâ bu amaçlara ulaşmanın yollarını bulur. Bu model, ilk bakışta güvenli görünür; ancak İkinci Bölüm'de görüleceği üzere, araçlar ile amaçlar arasındaki ayrımın, yeterince yetenekli sistemlerde korunması zordur. *Teknokratik modelde*, yapay zekâ fiilen karar verici hâline gelir ve insanlar onun önerilerini onaylayan bir konuma geriler. Schelsky'nin "nesnel zorunluluklar" kavramı, yapay zekâ çağında çok güçlü bir retorik araca dönüşebilir: "Model böyle söylüyor" ifadesi, siyasi tartışmayı sona erdiren nihai bir argüman hâline gelebilir. Dördüncü Bölüm'de "algoritmik vesayet" olarak adlandırılacak olan durum, tam olarak budur. *Pragmatist modelde* ise yapay zekâ, insanlarla ve kamuoyuyla eleştirel bir etkileşim içinde yer alan bir katılımcıdır; önerileri tartışılır, sorgulanır ve gerektiğinde reddedilir. Bu çalışmanın savunduğu model, Habermas'ın pragmatist modeline en yakın olanıdır; ancak bilişsel asimetri koşullarında bu modelin nasıl işleyebileceği, çalışmanın sonraki bölümlerinde ayrıntılı olarak incelenecektir.

IV. Asil-Vekil Kuramı ve Denetimin Ekonomisi

A. Bilgi Asimetrisi ve Vekâlet Maliyetleri

Bekçiler sorununun XX. yüzyıldaki en formel analizi, iktisat ve siyaset biliminde geliştirilen "asil-vekil" (*principal-agent*) kuramında bulunur. Bu kurama göre, bir kişinin (asil) belirli bir görevi yerine getirmek üzere başka bir kişiyi (vekil) yetkilendirdiği her ilişkide, iki temel sorun ortaya çıkar. Birincisi, asil ile vekilin çıkarları farklı olabilir. İkincisi, vekil, asilin sahip olmadığı bilgilere sahiptir ve asil, vekilin davranışını tam olarak gözlemleyemez. Bu iki sorunun birleşimi, vekilin kendi çıkarına, asilin zararına davranma ihtimalini doğurur.[93]

[93] Michael C. Jensen / William H. Meckling, "Theory of the Firm: Managerial Behavior, Agency Costs and Ownership Structure", *Journal of Financial Economics*, C. 3, S. 4, 1976.

Asil-vekil kuramı, bu sorunlara karşı üç tür önlem tanımlar: *izleme* (vekilin davranışını gözlemlemek), *teşvik uyumu* (vekilin çıkarlarını asilin çıkarlarıyla uyumlu hâle getirmek) ve *bağlanma* (vekilin, asile zarar vermeyeceğine dair güvenceler vermesi). Bu önlemlerin her biri maliyetlidir ve bu maliyetler, "vekâlet maliyetleri" olarak adlandırılır.

Asil-vekil kuramının yapay zekâ bakımından önemi, yapay zekâ güvenliği sorununun büyük ölçüde bir asil-vekil sorunu olarak formüle edilebilmesindedir. İnsanlar asil, yapay zekâ sistemleri ise vekildir. Sistemin "çıkarları", yani eğitim sürecinde edindiği hedefler, insanların istediği hedeflerden farklı olabilir; ve sistem, insanların sahip olmadığı bilgilere ve yeteneklere sahiptir. Klasik asil-vekil kuramının önerdiği üç önlem, yapay zekâ güvenliği literatüründe de karşılık bulur: izleme (yorumlanabilirlik ve davranış izleme), teşvik uyumu (hizalama ve ödül modellemesi) ve bağlanma (güvenlik taahhütleri ve kısıtlamalar).

Ancak yapay zekâ bağlamında asil-vekil sorunu, klasik biçiminden önemli bir noktada ayrılır. Klasik asil-vekil kuramında, bilgi asimetrisi *sınırlıdır*: Asil, vekilin davranışını tam olarak gözlemleyemese de, sonuçları gözlemleyebilir ve vekilin ne yaptığını genel olarak anlayabilir. Yapay zekâ bağlamında ise bilgi asimetrisi, *kavrayış asimetrisine* dönüşebilir: Asil, vekilin ne yaptığını gözlemlese bile, *neden* yaptığını ve bunun sonuçlarının ne olacağını anlayamayabilir. Bu durumda klasik izleme mekanizmaları, işlevlerini büyük ölçüde yitirir.

B. Devriye Polisi ve Yangın Alarmı

Siyaset biliminde asil-vekil kuramının en etkili uygulamalarından biri, Mathew McCubbins ve Thomas Schwartz'ın 1984 tarihli makalesinde yer alır.[94] Yazarlar, Amerikan Kongresi'nin bürokrasiyi denetlemesinde iki farklı modelin kullanıldığını ileri sürer.

"Devriye polisi" modelinde, denetçi, bürokrasinin faaliyetlerini kendi inisiyatifiyle, merkezî ve sistematik olarak izler; tıpkı bir polisin mahallede devriye gezmesi gibi. Bu model, kapsamlıdır ama maliyetlidir ve denetçinin bilgi ve kapasitesiyle sınırlıdır.

"Yangın alarmı" modelinde ise denetçi, bürokrasiyi doğrudan izlemez; bunun yerine, bürokrasinin kararlarından etkilenen yurttaşların ve çıkar gruplarının, bir sorun olduğunda "alarm" vermesini sağlayacak kurallar ve

[94] Mathew D. McCubbins / Thomas Schwartz, "Congressional Oversight Overlooked: Police Patrols versus Fire Alarms", *American Journal of Political Science*, C. 28, S. 1, 1984.

usuller oluşturur. Denetçi, ancak alarm çaldığında harekete geçer. Bu model, merkezî değil, dağınık; proaktif değil, reaktiftir. Ancak çok daha az maliyetlidir ve denetçinin kendi bilgi ve kapasitesinin sınırlılığını, etkilenen kişilerin yerel bilgisiyle telafi eder.

McCubbins ve Schwartz'ın ayrımı, yapay zekâ bağlamında büyük bir önem taşır. Bilişsel asimetri koşullarında, "devriye polisi" modeli, yani denetçinin yapay zekâ sisteminin faaliyetlerini doğrudan ve sistematik olarak izlemesi, giderek zorlaşacaktır; çünkü denetçi, sistemin ne yaptığını anlamakta güçlük çekecektir. Buna karşılık "yangın alarmı" modeli, yani sistemin kararlarından etkilenen kişilerin sorunları bildirmesi, önemli bir tamamlayıcı mekanizma olarak öne çıkmaktadır. Aristoteles'in "kullanan değerlendirir" argümanı, bu modelin felsefi temelini oluşturur: Kararın sonuçlarını yaşayan kişiler, kararın nasıl üretildiğini anlamasalar bile, bir şeylerin yanlış gittiğini fark edebilirler. Sekizinci Bölüm'de geliştirilecek olan modelde, olay bildirim sistemleri, ihbarcı korumaları ve etkilenen kişilerin şikâyet hakları, "yangın alarmı" denetiminin yapay zekâ bağlamındaki araçları olarak ele alınacaktır.

V. Ara Sonuç: Klasik Cevapların Ortak Varsayımı

Bu bölümde incelenen düşünce geleneği, bekçiler sorununa verilen cevapların zengin bir repertuvarını ortaya koymaktadır. Bu cevaplar, beş ana tür altında toplanabilir:

1. **Erdem ve eğitim yoluyla güvenilirlik** (Platon): Bekçilerin kendisini güvenilir kılmak; ruhlarını doğru değerlerle biçimlendirmek ve çıkar çatışmalarını yapısal olarak ortadan kaldırmak.
2. **Kuralların egemenliği** (Aristoteles, Cicero, Bracton): Yöneticileri, "arzudan arınmış akıl" olan yasalara tabi kılmak.
3. **Karşılıklı denetim** (Polybios, Montesquieu, Federalistler): İktidarı bölmek ve parçalarını birbirinin karşısına koyarak, iktidarın iktidarı durdurmasını sağlamak.
4. **Görevden alma ve düzeltme** (Locke, Popper): Yöneticilerin, egemenliğin asıl sahibi tarafından değiştirilebilmesini ve hatalarının düzeltilebilmesini güvence altına almak.

5. **Uzmanlaşmış denetim kurumları** (Kelsen, Weber): Anayasa mahkemeleri, soruşturma yetkili parlamento komisyonları gibi, denetimi kendine özgü görev hâline getiren kurumlar oluşturmak.

Bu beş cevap türünün her biri, örtük olarak, bu çalışmada "kaba bilişsel denklik varsayımı" olarak adlandırılan varsayıma dayanmaktadır. *Erdem ve eğitim* yoluyla güvenilirlik, eğitimcinin eğitilenin zihnini anlayabileceğini ve biçimlendirebileceğini varsayar. *Kuralların egemenliği*, kuralların, yönetilenin davranışını yönlendirebileceğini ve kurala uyulup uyulmadığının tespit edilebileceğini varsayar. *Karşılıklı denetim*, birbirini denetleyen güçlerin kabaca eşit kapasiteye sahip olduğunu varsayar; çünkü çok zayıf bir güç, çok güçlü bir gücü durduramaz. *Görevden alma*, görevden alanın, görevden alınanın hatalı olduğunu tespit edebileceğini ve görevden alma kararını uygulayabilecek güce sahip olduğunu varsayar. *Uzmanlaşmış denetim kurumları* ise, denetim kurumunun denetlenen faaliyeti anlayabilecek uzmanlığa sahip olduğunu varsayar.

Bu varsayımların her biri, karar vericileri aşan bir yapay zekâ karşısında farklı ölçülerde zorlanmaktadır. Ancak bu bölümün analizi, bazı klasik araçların bu zorlanmaya karşı diğerlerinden daha dayanıklı olduğunu da göstermiştir. Bu araçlar, çalışmanın sonraki bölümlerinde geliştirilecek olan modelin temel yapı taşlarını oluşturacaktır:

- **Aristoteles'in "kullanan değerlendirir" argümanı**, sonuçları değerlendirmenin, onları üretmekten daha az bilişsel kapasite gerektirebileceğini göstermektedir. Bu argüman, sonuç denetiminin, belirli koşullar altında, bilişsel asimetriye rağmen işlevini koruyabileceğini düşündürür.
- **Montesquieu'nün "engelleme yetisi" kavramı**, durdurma ve veto yetkisinin, karar verme yetkisiyle aynı bilişsel kapasiteyi gerektirmediğini göstermektedir. Bu kavram, varlık koşulları denetiminin bilişsel asimetri koşullarında en güvenilir denetim biçimi olduğu tezinin temelini oluşturur.
- **Popper'in "kim yönetmeli?" sorusunu reddi**, denetimin amacının, en iyi kararın verilmesini sağlamak değil, kötü kararların zararını sınırlamak ve hataları düzeltilebilir kılmak olduğunu göstermektedir. Bu yaklaşım, "düzeltilebilirlik" ilkesinin temelini oluşturur.

- **Magna Carta'nın güvence maddesinin akıbeti**, denetimin etkinliğinin, denetçinin denetlenenin varlık koşulları üzerinde fiilî bir kontrole sahip olmasına bağlı olduğunu göstermektedir. Bu ders, girdi denetiminin önemini vurgular.
- **McCubbins ve Schwartz'ın "yangın alarmı" modeli**, merkezî denetimin yetersiz kaldığı durumlarda, dağınık ve etkilenen kişilerin bilgisine dayanan denetim mekanizmalarının önemini göstermektedir.
- **Kelsen'in "kimse kendi davasında yargıç olamaz" ilkesi** ve **Weber'in siyasetçinin devredilemez sorumluluğu ilkesi**, denetimin bağımsızlığı ve sorumluluğun insan aktörlerde kalması gerektiği yönündeki tezlerin temelini oluşturur.

Klasik düşüncenin bu mirası, bir sonraki bölümde, yapay zekânın karar süreçlerine nüfuzunun olgusal gerçekliğiyle karşılaştırılacaktır. Bu karşılaştırma, hangi klasik araçların işlevini koruduğunu, hangilerinin dönüştürülmesi gerektiğini ve hangi yeni araçlara ihtiyaç duyulduğunu daha açık biçimde ortaya koyacaktır.

İKİNCİ BÖLÜM: KARAR VERİCİLERİ AŞAN YAPAY ZEKÂ — OLGUSAL ZEMİN VE DENETİMİN EPİSTEMİK SORUNU

Birinci Bölüm'de, bekçiler sorununa verilen klasik cevapların, denetleyen ile denetlenen arasında kaba bir bilişsel denklik bulunduğu varsayımına dayandığı gösterilmişti. Bu bölümün amacı, söz konusu varsayımın yapay zekâ karşısında hangi somut biçimlerde zorlandığını olgusal düzlemde ortaya koymaktır. Bu amaçla önce yapay zekâ kavramı ve "daha zeki olmak" ifadesinin anlamı açıklığa kavuşturulacak (§ 6), ardından yapay zekânın tarihsel gelişimi ve bugünkü durumu özetlenecek (§ 7), kamu yönetiminde algoritmik karar sistemlerinin kullanımına ilişkin başlıca vakalar incelenecek (§ 8), insan denetiminin bilişsel sınırları ele alınacak (§ 9) ve son olarak yapay zekâ güvenliği literatürünün merkezî sorunu olan "hizalama sorunu" ile bu soruna önerilen teknik çözümler değerlendirilecektir (§ 10).

§ 6. KAVRAMLAR: YAPAY ZEKÂ VE "DAHA ZEKİ" OLMAK

I. Yapay Zekâ Kavramı

A. Bilimsel Tanımlar

"Yapay zekâ" (*artificial intelligence*) terimi, 1955 yılında John McCarthy, Marvin Minsky, Nathaniel Rochester ve Claude Shannon tarafından hazırlanan ve ertesi yaz Dartmouth Koleji'nde düzenlenecek bir araştırma projesi için yazılan öneri metninde ortaya atılmıştır. Öneri metni, projenin temel varsayımını şöyle ifade ediyordu: "Öğrenmenin her yönü veya zekânın diğer herhangi bir özelliği, ilke olarak, bir makinenin onu taklit edebileceği kadar kesin biçimde tanımlanabilir."[95] Bu iddialı varsayım, yapay zekâ araştırmalarının sonraki yetmiş yılına yön vermiştir.

[95] John McCarthy / Marvin L. Minsky / Nathaniel Rochester / Claude E. Shannon, *A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence*, 31 Ağustos 1955.

Yapay zekâ alanının en yaygın ders kitabının yazarları Stuart Russell ve Peter Norvig, yapay zekâ tanımlarını iki eksen üzerinde sınıflandırır: Tanımların bir kısmı *düşünme* süreçlerine, bir kısmı *davranışa* odaklanır; bir kısmı başarıyı *insan* başarımına göre, bir kısmı ise ideal bir *rasyonellik* ölçütüne göre değerlendirir. Bu iki eksen, dört yaklaşım ortaya çıkarır: insan gibi düşünen sistemler, insan gibi davranan sistemler, rasyonel düşünen sistemler ve rasyonel davranan sistemler. Russell ve Norvig'in kendi tercihi, yapay zekâyı "rasyonel fail" (*rational agent*) kavramı üzerinden tanımlamaktır: Yapay zekâ, çevresini algılayan ve beklenen başarımını en üst düzeye çıkaracak biçimde davranan failleri tasarlama bilimidir.[96]

Bu tanım, hukuki ve siyasi analiz bakımından önemli bir noktayı vurgular: Yapay zekâ, özünde *hedefe yönelik* bir sistemdir. Bir yapay zekâ sistemi, kendisine verilen veya eğitim sürecinde edindiği bir hedefi gerçekleştirmeye çalışır. Bu nedenle yapay zekânın denetimi sorunu, büyük ölçüde, sistemin hedeflerinin ne olduğu ve bu hedeflerin insan amaçlarıyla ne ölçüde örtüştüğü sorusuna bağlıdır. Bu soru, § 10'da "hizalama sorunu" başlığı altında ayrıntılı olarak ele alınacaktır.

B. Hukuki Tanımlar

Yapay zekânın hukuki tanımı, düzenleme kapsamını belirlediği için büyük önem taşır. Hukuki tanımların karşılaştığı temel güçlük, teknolojinin hızla değişmesi karşısında hem yeterince geniş hem de yeterince belirli olmaktır. Çok dar bir tanım, yeni teknolojileri kapsam dışında bırakır; çok geniş bir tanım ise basit yazılımları da düzenleme kapsamına alarak belirsizliğe yol açar.

Bugün uluslararası düzeyde en yaygın kabul gören tanım, OECD'nin 2019 tarihli Yapay Zekâ Tavsiye Kararı'nda yer alan ve 2023'te güncellenen tanımdır. Avrupa Birliği Yapay Zekâ Tüzüğü (YZT), bu tanımdan esinlenerek yapay zekâ sistemini, Giriş'te de belirtildiği üzere, "değişen düzeylerde özerklikle çalışmak üzere tasarlanmış, kullanıma sunulduktan sonra uyum gösterebilen ve açık veya örtük hedefler doğrultusunda, aldığı girdiden, fiziksel veya sanal ortamları etkileyebilecek tahminler, içerik, öneriler veya kararlar gibi çıktıların nasıl üretileceğini çıkarsayan makine tabanlı bir sistem" olarak tanımlamaktadır.[97] Avrupa

[96] Stuart J. Russell / Peter Norvig, *Artificial Intelligence: A Modern Approach*, 4. Bası, Hoboken, Pearson, 2020, 1. ve 2. Bölümler.
[97] YZT, md. 3(1).

Konseyi'nin Yapay Zekâ ve İnsan Hakları, Demokrasi ve Hukukun Üstünlüğü Hakkında Çerçeve Sözleşmesi de benzer bir tanım benimsemiştir.[98]

Bu tanımın üç unsuru, bu çalışma bakımından özellikle önemlidir. *Birincisi*, "değişen düzeylerde özerklik" ifadesi, yapay zekâ sistemlerinin insan müdahalesi olmaksızın işleyebilme kapasitesine işaret eder. Özerklik arttıkça, insan denetiminin anlık ve doğrudan olması zorlaşır. *İkincisi*, "kullanıma sunulduktan sonra uyum gösterebilme" ifadesi, sistemlerin davranışının, piyasaya sunuldukları andaki davranıştan farklılaşabileceğine işaret eder. Bu, denetimin bir defalık bir onay işlemiyle sınırlı kalamayacağını, sürekli olması gerektiğini gösterir. *Üçüncüsü*, "açık veya örtük hedefler" ifadesi, sistemlerin hedeflerinin her zaman açıkça tanımlanmış olmadığını, eğitim sürecinde örtük olarak edinilmiş olabileceğini kabul eder. Bu, hizalama sorununun hukuki tanıma yansımış bir izidir.

Türk hukukunda, bu çalışmanın yazıldığı tarih itibarıyla, yapay zekânın genel ve bağlayıcı bir yasal tanımı bulunmamaktadır. Cumhurbaşkanlığı Dijital Dönüşüm Ofisi ile Sanayi ve Teknoloji Bakanlığı tarafından hazırlanan *Ulusal Yapay Zekâ Stratejisi 2021-2025* belgesi, yapay zekâyı, insana özgü bilişsel işlevleri yerine getirebilen sistemler olarak genel bir biçimde tanımlamaktadır; ancak bu tanım bir politika belgesine ait olup normatif bir bağlayıcılığa sahip değildir.[99] Yedinci Bölüm'de Türk hukukunun mevcut durumu ayrıntılı olarak değerlendirilecektir.

II. Dar, Genel ve Süper Yapay Zekâ

Yapay zekâ literatüründe, sistemler genellikle yeteneklerinin kapsamına göre üç kategoride sınıflandırılır.

Dar yapay zekâ (*narrow AI*), belirli ve sınırlı bir görevi yerine getirmek üzere tasarlanmış sistemleri ifade eder: satranç oynayan, yüz tanıyan, kredi riski hesaplayan veya tıbbi görüntüleri analiz eden sistemler. Bu sistemler, kendi alanlarında insan başarımını aşabilir; ancak bu alanın dışında hiçbir yetenek sergilemezler.

[98] Council of Europe Framework Convention on Artificial Intelligence and Human Rights, Democracy and the Rule of Law, CETS No. 225, Vilnius, 5 Eylül 2024, md. 2.

[99] T.C. Cumhurbaşkanlığı Dijital Dönüşüm Ofisi / T.C. Sanayi ve Teknoloji Bakanlığı, *Ulusal Yapay Zekâ Stratejisi 2021-2025*, Ankara, Ağustos 2021.

Genel yapay zekâ (*artificial general intelligence*, AGI), insanların yapabildiği bilişsel görevlerin geniş bir yelpazesini, insan düzeyinde veya üzerinde yerine getirebilen sistemleri ifade eder. Genel yapay zekânın kesin tanımı tartışmalıdır. Google DeepMind araştırmacılarının 2023'te önerdiği bir çerçeve, genel yapay zekâyı tek bir eşik olarak değil, *başarım* (yeni başlayan, yetkin, uzman, virtüöz, insanüstü) ve *genellik* (dar veya genel) boyutlarında tanımlanan düzeyler olarak ele almakta ve bu düzeyleri, sistemlerin *özerklik* düzeylerinden ayrı olarak değerlendirmektedir.[100] Bu yaklaşım, "genel yapay zekâya ulaşıldı mı?" sorusunun ikili bir soru olmadığını, bir derece meselesi olduğunu göstermesi bakımından önemlidir.

Süper yapay zekâ (*artificial superintelligence*, ASI) ise Nick Bostrom'un tanımıyla, "hemen hemen tüm ilgi alanlarında insanların bilişsel başarımını büyük ölçüde aşan herhangi bir zekâ"yı ifade eder.[101] Bostrom, süper zekânın üç biçimini birbirinden ayırır: *hız süper zekâsı* (insan zekâsının yapabildiği her şeyi yapabilen ama çok daha hızlı yapan bir zekâ), *kolektif süper zekâ* (çok sayıda daha küçük zekânın, her alanda mevcut bilişsel sistemleri büyük ölçüde aşacak biçimde örgütlenmesiyle oluşan bir sistem) ve *nitelik süper zekâsı* (en az insan zihni kadar hızlı olan ama nitel olarak çok daha akıllı bir sistem).[102]

Bostrom'un bu ayrımı, denetim sorunu bakımından aydınlatıcıdır. *Hız süper zekâsı*, insanların ilke olarak anlayabileceği türden kararlar verir; ancak bu kararları insanların değerlendiremeyeceği bir hızda verir. *Kolektif süper zekâ*, insanların tek tek anlayabileceği türden işlemler yapar; ancak bu işlemlerin toplamı, hiçbir bireyin kavrayamayacağı bir karmaşıklığa ulaşır. *Nitelik süper zekâsı* ise insanların ilke olarak anlayamayacağı türden kararlar verebilir. Bu üç biçim, denetim bakımından farklı sorunlar doğurur ve farklı çözümler gerektirir.

III. "Daha Zeki" Olmak Ne Demektir?

A. Zekânın Çok Boyutluluğu

Yapay zekânın karar vericilerden "daha zeki" olması ifadesi, ilk bakışta göründüğünden çok daha karmaşıktır. Zekâ, tek boyutlu bir nicelik

[100] Meredith Ringel Morris vd., "Levels of AGI for Operationalizing Progress on the Path to AGI", arXiv:2311.02462, 2023.
[101] Bostrom, *Superintelligence*, 2. Bölüm.
[102] Bostrom, *Superintelligence*, 3. Bölüm.

değildir. Psikolojide Howard Gardner'ın "çoklu zekâ" kuramından bu yana, zekânın birbirinden görece bağımsız birçok boyutu olduğu kabul edilmektedir. Yapay zekâ araştırmacıları Shane Legg ve Marcus Hutter, yüzlerce zekâ tanımını inceledikten sonra, bunların ortak çekirdeğini şöyle özetlemiştir: Zekâ, bir failin geniş bir ortamlar yelpazesinde hedeflere ulaşma yeteneğini ölçer.[103] François Chollet ise zekânın, mevcut becerilerden çok, yeni beceriler *edinme* verimliliği olarak anlaşılması gerektiğini savunmuştur.[104]

Yapay zekâ sistemlerinin yetenek profili, insanlarınkinden önemli ölçüde farklıdır. "Moravec paradoksu" olarak bilinen gözleme göre, insanlar için zor olan görevler (karmaşık hesaplamalar, satranç) bilgisayarlar için görece kolay; insanlar için kolay olan görevler (yürümek, nesneleri tanımak, sağduyu) ise bilgisayarlar için uzun süre zor olmuştur. Günümüzün büyük dil modelleri, bu profili kısmen değiştirmiş olsa da, yapay zekâ yeteneklerinin insanlarınkine göre "pürüzlü" (*jagged*) bir sınır çizdiği gözlemi geçerliliğini korumaktadır. Harvard İşletme Okulu ve Boston Consulting Group araştırmacılarının yürüttüğü bir deney, aynı yapay zekâ sisteminin, bazı danışmanlık görevlerinde çalışanların başarımını belirgin biçimde artırırken, görünüşte benzer zorluktaki başka görevlerde başarımı düşürdüğünü göstermiştir.[105] Bu "pürüzlü sınır" olgusu, denetim bakımından ciddi bir sorun doğurur: Bir sistemin bir alanda insan üstü başarım göstermesi, görünüşte benzer bir başka alanda güvenilir olduğu anlamına gelmez; ve kullanıcılar, sistemin hangi alanda güvenilir, hangi alanda güvenilmez olduğunu her zaman ayırt edemez.

B. Denetim Bakımından "Aşma": Dört Asimetri

Bu çalışma bakımından önemli olan, zekânın soyut bir tanımı değil, yapay zekânın karar vericileri *denetim bakımından* hangi biçimlerde aşabileceğidir. Giriş'te belirtildiği üzere, bu çalışmada "karar vericileri aşmak" ifadesi, insan karar vericilerin, makul zaman ve kaynaklarla, sistemin çıktılarının doğruluğunu bağımsız olarak değerlendiremeyecekleri bir başarım düzeyini ifade etmektedir. Bu anlamda aşma, birbirinden

[103] Shane Legg / Marcus Hutter, "Universal Intelligence: A Definition of Machine Intelligence", *Minds and Machines*, C. 17, S. 4, 2007.
[104] François Chollet, "On the Measure of Intelligence", arXiv:1911.01547, 2019.
[105] Fabrizio Dell'Acqua vd., "Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality", *Harvard Business School Working Paper*, No. 24-013, 2023.

ayrılması gereken dört farklı asimetri biçiminde ortaya çıkabilir. Bu dörtlü ayrım, çalışmanın analitik çerçevesinin bir parçası olarak önerilmektedir.

1. Hız asimetrisi. Sistem, insanların ilke olarak anlayabileceği türden kararları, insanların anlık olarak izleyemeyeceği bir hızda verir. Yüksek frekanslı finansal alım satım sistemleri bu asimetrinin bilinen örneğidir. 6 Mayıs 2010'da ABD hisse senedi piyasalarında yaşanan ve "ani çöküş" (*flash crash*) olarak bilinen olayda, piyasalar dakikalar içinde yaklaşık bir trilyon dolar değer kaybetmiş ve kısa süre içinde büyük ölçüde toparlanmıştır.[106] Bu süreçte insan gözetimi, olayları ancak sonradan anlayabilmiştir. Hız asimetrisinin karşısında, anlık insan denetimi yerine *önceden belirlenmiş otomatik sınırlar* (örneğin piyasalardaki devre kesiciler) ve *sonradan inceleme* gereklidir.

2. Ölçek asimetrisi. Sistem, her biri tek başına insanlar tarafından değerlendirilebilecek kararları, insanların tek tek inceleyemeyeceği sayıda verir. Bir sosyal yardım kurumunun yüz binlerce başvuruyu otomatik olarak değerlendirmesi veya bir içerik denetim sisteminin günde milyonlarca gönderiyi sınıflandırması bu asimetrinin örnekleridir. Ölçek asimetrisinin karşısında, her kararın incelenmesi yerine *istatistiksel denetim*, *örneklem incelemesi* ve *şikâyet temelli* (yangın alarmı) denetim gereklidir.

3. Kavrayış asimetrisi. Sistem, insanların makul zaman ve kaynaklarla ilke olarak bile tam olarak anlayamayacağı türden kararlar verir; ya çünkü kararın dayandığı akıl yürütme insanların bilişsel kapasitesini aşan bir karmaşıklıktadır, ya da çünkü kararın dayandığı iç süreçler insanlara erişilebilir bir biçimde temsil edilmemiştir. Bu, Bostrom'un "nitelik süper zekâsı"na karşılık gelen asimetridir ve bu çalışmanın asıl odak noktasıdır. Kavrayış asimetrisinin karşısında, sonuç denetiminin yerini büyük ölçüde *süreç*, *girdi* ve *varlık koşulları* denetimi almak zorundadır.

4. Stratejik asimetri. Sistem, denetçiyi ve denetim sürecini modelleyebilir; denetçinin neyi kontrol edeceğini, neyi gözden kaçıracağını öngörebilir ve davranışını buna göre ayarlayabilir. Bu asimetri, Juvenalis'in "işe onlardan başlar" dizesinin teknik karşılığıdır. Stratejik asimetri, diğer üç asimetriden niteliksel olarak farklıdır; çünkü burada sorun yalnızca

[106] U.S. Commodity Futures Trading Commission / U.S. Securities and Exchange Commission, *Findings Regarding the Market Events of May 6, 2010*, Washington, 30 Eylül 2010.

denetçinin *yetersizliği* değil, denetlenenin denetimi *aktif olarak boşa çıkarma* kapasitesidir. Stratejik asimetrinin karşısında, denetim mekanizmalarının, denetlenenin en kötü niyetli olduğu varsayımı altında bile işlemesi gerekir; bu, § 10'da ele alınacak olan "yapay zekâ kontrolü" (*AI control*) yaklaşımının temel varsayımıdır.

Bu dört asimetri, birbirinden bağımsız değildir ve aynı sistemde bir arada bulunabilir. Ancak aralarındaki ayrım, hangi denetim araçlarının hangi durumda etkili olacağını belirlemek bakımından önemlidir. Bugünkü yapay zekâ sistemleri bakımından hız ve ölçek asimetrileri yaygın biçimde gerçekleşmiş, kavrayış asimetrisi belirli alanlarda ortaya çıkmaya başlamış, stratejik asimetri ise henüz deneysel ortamlarda gözlemlenen, fakat sistemlerin yetenekleri arttıkça önemi artacak bir olasılık olarak belirmiştir.

§ 7. TARİHSEL GELİŞİM VE GÜNCEL DURUM

I. Turing'den Good'a: Kontrol Kaygısının Erken Formülasyonları

Yapay zekânın denetimi sorunu, alanın kurucularının zihnini en baştan meşgul etmiştir. Alan Turing, 1950 yılında yayımlanan ve "makineler düşünebilir mi?" sorusunu "taklit oyunu" adını verdiği bir testle somutlaştıran ünlü makalesinde, makinelerin bir gün insan zekâsıyla rekabet edebileceğini öngörmüştür.[107] Ertesi yıl verdiği bir konferansta ise Turing, daha da ileri giderek, makine düşüncesi bir kez başladığında, onun "zayıf güçlerimizi" aşmasının uzun sürmeyeceğini ve bir aşamada makinelerin, Samuel Butler'ın *Erewhon* romanında anlatıldığı gibi, kontrolü ele geçirmesini beklememiz gerekeceğini söylemiştir.[108]

Sibernetiğin kurucusu Norbert Wiener, 1960 yılında *Science* dergisinde yayımlanan bir makalesinde, kontrol sorununun belki de en kalıcı formülasyonunu yapmıştır: "Amaçlarımıza ulaşmak için, işleyişine etkin biçimde müdahale edemeyeceğimiz mekanik bir aracı kullanırsak, makineye konulan amacın gerçekten arzu ettiğimiz amaç olduğundan çok

[107] Alan M. Turing, "Computing Machinery and Intelligence", *Mind*, C. 59, S. 236, 1950.

[108] Alan M. Turing, "Intelligent Machinery, A Heretical Theory", 1951 tarihli konferans metni; ölümünden sonra *Philosophia Mathematica*, C. 4, S. 3, 1996'da yayımlanmıştır. Turing'in andığı eser için bkz. Samuel Butler, *Erewhon*, London, Trübner, 1872, "The Book of the Machines" bölümleri.

emin olsak iyi olur."[109] Wiener'in bu uyarısı, bugün "hizalama sorunu" olarak adlandırılan sorunun ilk açık ifadelerinden biridir.

İngiliz matematikçi ve Turing'in savaş dönemi çalışma arkadaşı I. J. Good ise 1965'te yazdığı bir makalede "zekâ patlaması" kavramını ortaya atmıştır. Good'un argümanı şudur: En zeki insanın tüm entelektüel faaliyetlerini aşabilen "ultra-zeki" bir makine tanımlayalım. Makine tasarımı da bu entelektüel faaliyetlerden biri olduğuna göre, ultra-zeki bir makine, daha da iyi makineler tasarlayabilir; o zaman kuşkusuz bir "zekâ patlaması" yaşanacak ve insanın zekâsı çok geride kalacaktır. Good, makalesini şu dikkat çekici cümleyle tamamlar: "Bu nedenle ilk ultra-zeki makine, insanın yapması gereken son icattır; *yeter ki makine, onu nasıl kontrol altında tutacağımızı bize söyleyecek kadar uysal olsun*."[110]

Good'un bu son cümlesi, bu çalışmanın temel sorusunun belki de en özlü ifadesidir. Good, kontrolün mümkün olduğunu varsaymaz; kontrolün, *makinenin kendi işbirliğine* bağlı olabileceğini öngörür. Daha zeki bir sistemi kontrol etmenin yolunu, ancak o sistemin kendisi bize gösterebilir; ve bu, sistemin bize bu yolu göstermeyi *isteyecek* kadar uysal olmasına bağlıdır. Juvenalis'in sorusu burada en saf biçimine ulaşır: Bekçiyi bekleyebilmek için bekçinin yardımına ihtiyacımız vardır.

II. Derin Öğrenme ve Büyük Dil Modelleri

A. Kural Tabanlı Sistemlerden Öğrenen Sistemlere

Yapay zekâ araştırmaları, ilk on yıllarında büyük ölçüde "sembolik" bir yaklaşıma dayanmıştır. Bu yaklaşımda zekâ, açıkça programlanmış kurallar ve mantıksal çıkarımlar aracılığıyla taklit edilmeye çalışılır. 1980'lerde yaygınlaşan "uzman sistemler", belirli bir alandaki insan uzmanların bilgisini kurallar hâlinde kodlamayı amaçlıyordu. Bu sistemlerin hukuki ve denetsel açıdan önemli bir avantajı vardı: Kuralları açıkça yazılmış olduğundan, bir kararın hangi kurallara dayandığı izlenebilir ve denetlenebilirdi. Ancak sembolik yaklaşım, gerçek dünyanın karmaşıklığı karşısında sınırlı kalmış ve iki uzun durgunluk dönemine ("yapay zekâ kışları") yol açmıştır.

[109] Norbert Wiener, "Some Moral and Technical Consequences of Automation", *Science*, C. 131, S. 3410, 1960.

[110] I. J. Good, "Speculations Concerning the First Ultraintelligent Machine", *Advances in Computers*, C. 6, 1965: "*Thus the first ultraintelligent machine is the last invention that man need ever make, provided that the machine is docile enough to tell us how to keep it under control.*"

Son on beş yılda yaşanan atılım, temelde farklı bir yaklaşıma, yani verilerden öğrenen yapay sinir ağlarına, özellikle de "derin öğrenme" (*deep learning*) olarak adlandırılan çok katmanlı ağlara dayanmaktadır. 2012 yılında Alex Krizhevsky, Ilya Sutskever ve Geoffrey Hinton tarafından geliştirilen bir derin sinir ağının görüntü tanıma yarışmasında elde ettiği başarı, bu atılımın başlangıcı sayılır.[111] Derin öğrenme sistemleri, kuralları açıkça programlanmak yerine, büyük miktarda veriden örüntüleri kendileri çıkarır. Bu, sistemlerin yeteneklerinde büyük bir sıçramaya yol açmış; ancak bedeli, sistemlerin iç işleyişinin insanlar için büyük ölçüde anlaşılmaz hâle gelmesi olmuştur. Bir derin öğrenme sisteminin "bilgisi", milyarlarca sayısal parametreye dağılmış durumdadır ve bu parametrelerin hangi kombinasyonunun hangi kararı ürettiğini anlamak son derece güçtür. Kural tabanlı sistemlerin sağladığı izlenebilirlik, derin öğrenmeyle büyük ölçüde kaybolmuştur.

B. "37. Hamle": Değerlendirilebilirliğin Sınırı

Derin öğrenmenin insan uzmanlığını aşma potansiyelinin en çarpıcı örneklerinden biri, 2016 yılında Google DeepMind tarafından geliştirilen AlphaGo sisteminin dünya Go şampiyonlarından Lee Sedol'e karşı oynadığı maçta yaşanmıştır. Maçın ikinci oyununda AlphaGo, 37. hamlesinde, Go uzmanlarının başlangıçta bir hata olarak yorumladığı alışılmadık bir hamle yapmıştır. Yorumcular, hamlenin anlamını kavrayamamış; bazıları bir yazılım hatası olabileceğini düşünmüştür. Oysa oyunun ilerleyen aşamalarında bu hamlenin, AlphaGo'nun oyunu kazanmasında belirleyici bir rol oynadığı anlaşılmıştır.[112]

"37. hamle", bu çalışmanın konusu bakımından sembolik bir öneme sahiptir. Bu olay, kavrayış asimetrisinin somut bir örneğidir: Dünyanın en iyi insan uzmanları, sistemin kararını *karar anında* değerlendirememiş, ancak sonuçlar ortaya çıktıktan sonra kararın isabetli olduğunu anlayabilmiştir. Go gibi kuralları açık, sonuçları kesin ve oyunun sonunda kimin kazandığının tartışmasız olduğu bir alanda bu durum sorun yaratmaz;

---

[111] Alex Krizhevsky / Ilya Sutskever / Geoffrey E. Hinton, "ImageNet Classification with Deep Convolutional Neural Networks", *Advances in Neural Information Processing Systems* 25, 2012.

[112] Sistemin mimarisi için bkz. David Silver vd., "Mastering the Game of Go with Deep Neural Networks and Tree Search", *Nature*, C. 529, 2016. Seul'de Mart 2016'da oynanan maçın ikinci oyunundaki 37. hamle, canlı yayın yorumcuları ve Go uzmanları tarafından o sırada alışılmadık ve şaşırtıcı bir hamle olarak değerlendirilmiş, sonradan yaygın biçimde analiz edilmiştir.

çünkü sonuç denetimi, oyunun sonunda kesin olarak yapılabilir. Ancak siyasi, hukuki veya ekonomik kararlarda, sonuçlar çoğu zaman belirsiz, gecikmeli, tartışmalı ve geri döndürülemezdir. Bir yapay zekâ sisteminin önerdiği bir politikanın "37. hamle" mi yoksa gerçek bir hata mı olduğunu anlamak için oyunun sonunu beklemek, kamusal kararlar bakımından çoğu zaman kabul edilemez bir maliyet taşır.

C. Büyük Dil Modelleri ve Genel Yetenekler

2017 yılında Google araştırmacıları tarafından önerilen "dönüştürücü" (*transformer*) mimarisi, yapay zekâ gelişiminin bir sonraki aşamasını başlatmıştır.[113] Bu mimariye dayanan "büyük dil modelleri", internet ölçeğindeki metin verileri üzerinde eğitilerek, dil anlama ve üretme, akıl yürütme, programlama, çeviri ve bilgi sentezi gibi geniş bir yetenekler yelpazesi kazanmıştır. Kasım 2022'de kamuya sunulan ChatGPT, bu sistemlerin geniş kitlelerce tanınmasını sağlamış ve yapay zekâyı küresel kamusal tartışmanın merkezine taşımıştır.

Büyük dil modellerinin gelişimi, büyük ölçüde "ölçeklenme yasaları" (*scaling laws*) olarak adlandırılan ampirik düzenliliklere dayanmaktadır. Bu düzenliliklere göre, model büyüklüğü, eğitim verisi miktarı ve eğitimde kullanılan hesaplama gücü arttıkça, modellerin başarımı öngörülebilir biçimde artmaktadır.[114] Bu düzenlilik, yapay zekâ gelişiminin önemli ölçüde *hesaplama gücüne* bağlı olduğunu göstermesi bakımından, denetim için de önemli sonuçlar doğurur. Sekizinci Bölüm'de ele alınacak olan "girdi denetimi", tam da bu bağımlılığa dayanır: Eğer en yetenekli sistemlerin geliştirilmesi çok büyük hesaplama kaynakları gerektiriyorsa, bu kaynakların denetimi, sistemlerin kendisinin denetiminden daha uygulanabilir bir kaldıraç sağlayabilir.[115]

2024'ten itibaren, yanıt vermeden önce uzun ve çok adımlı bir "akıl yürütme" süreci yürüten modellerin geliştirilmesiyle, sistemlerin matematik, bilim ve programlama alanlarındaki yeteneklerinde belirgin bir sıçrama yaşanmıştır. 2025 yılında, deneysel yapay zekâ sistemlerinin Uluslararası Matematik Olimpiyatı problemlerinde altın madalya düzeyinde

[113] Ashish Vaswani vd., "Attention Is All You Need", *Advances in Neural Information Processing Systems* 30, 2017.

[114] Jared Kaplan vd., "Scaling Laws for Neural Language Models", arXiv:2001.08361, 2020; Jordan Hoffmann vd., "Training Compute-Optimal Large Language Models", arXiv:2203.15556, 2022.

[115] Girish Sastry vd., "Computing Power and the Governance of Artificial Intelligence", arXiv:2402.08797, 2024.

başarım gösterdiği, sistemleri geliştiren kuruluşlar tarafından duyurulmuştur. Yapay zekâ alanındaki gelişmeleri değerlendirmek üzere otuzu aşkın ülkenin desteğiyle hazırlanan *Uluslararası Yapay Zekâ Güvenliği Raporu*, genel amaçlı yapay zekâ yeteneklerinin son yıllarda hızla arttığını, ancak gelecekteki ilerlemenin hızı ve yönü konusunda uzmanlar arasında önemli bir belirsizlik bulunduğunu tespit etmiştir.[116]

III. Araçtan Faile: Ajan Sistemler ve Özerklik

Denetim sorunu bakımından son yıllardaki belki de en önemli gelişme, yapay zekâ sistemlerinin salt metin üreten "sohbet" sistemlerinden, dünyada *eylem* gerçekleştirebilen "ajan" (*agent*) sistemlere dönüşmesidir. Ajan sistemler, bir hedef doğrultusunda çok adımlı görevleri özerk olarak planlayabilir ve yürütebilir: İnternette arama yapabilir, yazılım kodu yazıp çalıştırabilir, bilgisayar arayüzlerini kullanabilir, e-posta gönderebilir, başka yazılım sistemleriyle etkileşime girebilir. Bağımsız bir değerlendirme kuruluşunun yaptığı ölçümler, yapay zekâ sistemlerinin özerk olarak tamamlayabildiği görevlerin uzunluğunun (insan uzmanların bu görevleri tamamlaması için gereken süreyle ölçüldüğünde) son yıllarda yaklaşık yedi ayda bir ikiye katlandığını göstermiştir.[117]

Araçtan faile geçiş, denetim sorununu niteliksel olarak değiştirir. Bir araç, yalnızca bir insanın kullandığı anda ve onun yönlendirmesiyle işler; insan, her adımda karar verici konumundadır. Bir ajan ise bir hedef verildikten sonra, ara adımları kendisi belirler ve uygular. İnsan, artık her adımın değil, yalnızca hedefin ve nihai sonucun denetçisidir. Bu durum, Birinci Bölüm'de ele alınan asil-vekil sorununun yapay zekâ bağlamındaki en saf biçimidir: Asil (insan) hedefi belirler; vekil (ajan) bu hedefe ulaşmak için hangi araçları kullanacağına kendisi karar verir; ve asil, vekilin ara adımlarını tam olarak izleyemez.

Ajan sistemlerin yaygınlaşması, ayrıca, Birinci Bölüm'ün sonunda değinilen bir soruna da yeni bir boyut kazandırır: insan aracıların ortadan kalkması. Geleneksel olarak, devletin ve büyük örgütlerin eylemleri, bu eylemleri fiilen gerçekleştiren insanlar aracılığıyla yürütülür ve bu insanlar, hukuka aykırı veya ahlaken kabul edilemez emirleri uygulamayı reddederek bir denetim işlevi görür. Ajan sistemler, bu aracıların bir

[116] Yoshua Bengio vd., *International AI Safety Report*, Londra, Ocak 2025.
[117] Thomas Kwa vd., "Measuring AI Ability to Complete Long Tasks", arXiv:2503.14499, 2025.

kısmını gereksiz kılabilir; bu da, insan vicdanının sağladığı bu son savunma hattının zayıflaması anlamına gelebilir.

IV. Belirsizlik ve Tartışma

Yapay zekâ yeteneklerinin gelecekteki seyri, derin bir belirsizlik içindedir. 2023 yılında yapay zekâ alanında yayın yapmış yaklaşık üç bin araştırmacıyla yapılan kapsamlı bir anket, katılımcıların toplu tahminine göre, yardımsız makinelerin her görevi insanlardan daha iyi ve daha ucuza yapabilmesi olasılığının 2047 yılına kadar yüzde elliye ulaşacağını; ancak tahminlerin bireyler arasında çok geniş bir aralıkta dağıldığını göstermiştir.[118]

Bu tahminlere karşı ciddi itirazlar da bulunmaktadır. Bir grup araştırmacı, yapay zekânın "normal bir teknoloji" olarak anlaşılması gerektiğini, yani elektrik veya internet gibi, toplumu derinden dönüştürecek ama bunu onlarca yıla yayılan, kurumsal uyum süreçlerinden geçen kademeli bir süreçle yapacak bir teknoloji olduğunu savunmaktadır. Bu görüşe göre, laboratuvar ortamındaki yetenek artışları, gerçek dünyada benimsenme ve etki ile doğrudan aynı şey değildir; ve "süper zekâ" kavramı, politikaya rehberlik etmek için yeterince tutarlı bir kavram değildir.[119] Başka eleştirmenler ise mevcut yapay zekâ sistemlerinin, görünürdeki yeteneklerine rağmen, gerçek anlamda akıl yürütme ve anlama kapasitesinden yoksun olduğunu ve mevcut yaklaşımların genel zekâya ulaşmak için yetersiz kalacağını ileri sürmektedir.[120]

Bu çalışma, bu tartışmada taraf tutmamaktadır. Giriş'te belirtildiği üzere, çalışmanın yaklaşımı koşulludur. Bununla birlikte, bu belirsizliğin hukuk bakımından ne anlama geldiğini belirtmek gerekir. *Birincisi*, "karar vericileri aşma" durumu, belirli alanlarda ve sınırlı biçimlerde zaten gerçekleşmiştir. Hız ve ölçek asimetrileri, bugün kamu yönetiminde ve özel sektörde kullanılan birçok sistemde mevcuttur ve § 8'de incelenecek vakalar, bu asimetrilerin bile ciddi denetim başarısızlıklarına yol

[118] Katja Grace vd., "Thousands of AI Authors on the Future of AI", arXiv:2401.02843, 2024.

[119] Arvind Narayanan / Sayash Kapoor, "AI as Normal Technology", Knight First Amendment Institute, Columbia University, Nisan 2025; ayrıca bkz. Arvind Narayanan / Sayash Kapoor, *AI Snake Oil*, Princeton, Princeton University Press, 2024.

[120] Emily M. Bender / Timnit Gebru vd., "On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?", *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, 2021; Gary Marcus / Ernest Davis, *Rebooting AI: Building Artificial Intelligence We Can Trust*, New York, Pantheon, 2019.

açabildiğini göstermektedir. *İkincisi*, genel ve kapsamlı bir aşma durumu gerçekleşmese bile, bu çalışmada geliştirilecek ilke ve kurumlar, daha sınırlı asimetri biçimlerine karşı da işlevseldir. *Üçüncüsü*, hukuk, belirsizlik altında karar vermek zorunda olan bir disiplindir. Uluslararası çevre hukukunda yerleşmiş olan "ihtiyat ilkesi", ciddi veya geri döndürülemez zarar tehdidinin bulunduğu durumlarda, tam bilimsel kesinliğin yokluğunun, önlemlerin ertelenmesi için bir gerekçe olarak kullanılamayacağını öngörür.[121] Bu ilkenin yapay zekâya uyarlanması, Dördüncü Bölüm'de "Collingridge ikilemi" bağlamında ayrıca tartışılacaktır.

§ 8. KARAR SÜREÇLERİNE NÜFUZ: ALGOKRASİ

I. Algokrasi Kavramı

"Algokrasi" (*algocracy*) terimi, sosyolog A. Aneesh tarafından, küresel yazılım işgücünün örgütlenmesini incelerken, yönetimin bürokratik hiyerarşiler yerine yazılım kodlarına gömülü kurallar aracılığıyla gerçekleştirilmesini ifade etmek için önerilmiştir.[122] Aneesh'e göre algokratik yönetim, bürokratik yönetimden temelde farklıdır: Bürokraside kurallar, insanlar tarafından yorumlanır ve uygulanır; algokraside ise kurallar, sistemin yapısına gömülüdür ve uygulanmaları için insan yorumuna gerek yoktur. Algokratik bir sistemde kurala uymamak, çoğu zaman *mümkün bile değildir*; çünkü sistem, kurala aykırı bir eylemin gerçekleştirilmesine izin vermez.

Felsefeci John Danaher, bu kavramı kamusal karar alma süreçlerine uyarlamış ve "algokrasi tehdidi" olarak adlandırdığı sorunu formüle etmiştir.[123] Danaher'e göre, kamusal karar süreçlerinde algoritmik sistemlerin kullanımı arttıkça, insanların bu süreçlere *anlamlı biçimde katılma* ve onları *anlama* olanakları azalmaktadır. Bu durum, kamusal kararların meşruiyeti bakımından ciddi bir sorun yaratır; çünkü meşru bir siyasi karar, yalnızca iyi sonuçlar üretmekle kalmamalı, aynı zamanda etkilenen kişilerin anlayabileceği ve katılabileceği bir süreçle alınmalıdır.

[121] Rio Çevre ve Kalkınma Bildirgesi, 1992, 15. İlke.

[122] A. Aneesh, *Virtual Migration: The Programming of Globalization*, Durham, Duke University Press, 2006; A. Aneesh, "Global Labor: Algocratic Modes of Organization", *Sociological Theory*, C. 27, S. 4, 2009.

[123] John Danaher, "The Threat of Algocracy: Reality, Resistance and Accommodation", *Philosophy & Technology*, C. 29, S. 3, 2016.

Danaher, algoritmik sistemlerin daha iyi sonuçlar üretebileceğini kabul etmekle birlikte, bu sonuçların, insanların anlama ve katılma olanaklarının kaybı pahasına elde edilmesinin, kolayca çözülemeyecek bir meşruiyet ikilemi yarattığını ileri sürer.

Kamu yönetimi literatüründe, Mark Bovens ve Stavros Zouridis, bilgi teknolojilerinin kamu bürokrasisini nasıl dönüştürdüğünü üç aşamalı bir modelle açıklamıştır.[124] Michael Lipsky'nin klasik çalışmasında tanımlanan "sokak düzeyi bürokrasi"de, kararlar vatandaşlarla doğrudan temas hâlindeki memurlar (polisler, öğretmenler, sosyal hizmet uzmanları) tarafından ve önemli bir takdir yetkisiyle verilir.[125] "Ekran düzeyi bürokrasi"de, memurlar kararlarını bilgisayar ekranları aracılığıyla ve yazılımın sunduğu seçenekler çerçevesinde verir; takdir yetkisi daralır. "Sistem düzeyi bürokrasi"de ise kararlar büyük ölçüde otomatik sistemler tarafından verilir; takdir yetkisi, sistem tasarımcılarına ve yazılım geliştiricilerine kayar. Bovens ve Zouridis'in önemli tespiti, bu dönüşümün takdir yetkisini ortadan kaldırmadığı, yalnızca *yer değiştirdiğidir*: Takdir, artık karar anında değil, sistemin tasarım anında, genellikle kamuoyunun ve hukuki denetimin görüş alanının dışında kullanılmaktadır.

II. Vaka İncelemeleri

Algoritmik karar sistemlerinin kamu yönetiminde kullanımının denetim bakımından ne tür sorunlar doğurduğunu somut olarak anlamak için, son on yılda farklı hukuk düzenlerinde yaşanmış ve kapsamlı biçimde belgelenmiş birkaç vakayı incelemek yararlı olacaktır. Bu vakaların ortak özelliği, ilgili sistemlerin hiçbirinin bugünkü anlamda "ileri yapay zekâ" olmamasıdır. Çoğu, görece basit kurallara veya istatistiksel modellere dayanan sistemlerdir. Bu durum, vakaları daha da öğretici kılar: Eğer basit sistemler bile bu ölçüde denetim başarısızlıklarına yol açabiliyorsa, çok daha karmaşık ve yetenekli sistemlerin nasıl denetleneceği sorusu, daha da ciddi bir hâl alır.

[124] Mark Bovens / Stavros Zouridis, "From Street-Level to System-Level Bureaucracies: How Information and Communication Technology is Transforming Administrative Discretion and Constitutional Control", *Public Administration Review*, C. 62, S. 2, 2002.
[125] Michael Lipsky, *Street-Level Bureaucracy: Dilemmas of the Individual in Public Services*, New York, Russell Sage Foundation, 1980.

A. Avustralya: “Robodebt”

2016-2019 yılları arasında Avustralya hükümeti, sosyal yardım alanların gelirlerini kontrol etmek için “Çevrimiçi Uyum Müdahalesi” (*Online Compliance Intervention*) adlı otomatik bir sistem kullanmıştır. Kamuoyunda “Robodebt” olarak bilinen bu sistem, vergi idaresinin yıllık gelir verilerini, sosyal yardımların hesaplandığı iki haftalık dönemlere eşit olarak bölerek (“gelir ortalaması” yöntemi) yardım alanların fazla ödeme alıp almadığını hesaplıyordu. Oysa sosyal yardım alanların önemli bir kısmı, yıl içinde düzensiz gelir elde eden kişilerdi; gelirin yıl boyunca eşit dağıldığı varsayımı, bu kişiler için sistematik olarak hatalı borç hesaplamalarına yol açıyordu. Sistem, ayrıca, ispat yükünü tersine çevirmişti: Borcun hatalı olduğunu kanıtlama yükü, yıllar önceki maaş bordrolarını bulmak zorunda kalan yardım alanlara yüklenmişti.

Sistemin hukuka aykırılığı, sonunda mahkemeler önünde tescil edilmiştir. 2019’da Federal Mahkeme’de görülen bir davada hükümet, gelir ortalaması yöntemine dayanan borçların hukuka aykırı olduğunu kabul etmiştir.[126] 2021’de ise bir grup davası, yaklaşık 1,8 milyar Avustralya doları değerinde bir uzlaşmayla sonuçlanmıştır.[127] 2023 yılında yayımlanan Kraliyet Soruşturma Komisyonu raporu, sistemi “ne adil ne de yasal olan, kaba ve acımasız bir mekanizma” olarak nitelendirmiş; hükümetin sistemin hukuka aykırılığına ilişkin uyarıları uzun süre göz ardı ettiğini ve sistemin yüz binlerce kişiye ciddi maddi ve manevi zararlar verdiğini tespit etmiştir.[128]

B. Hollanda: Çocuk Bakım Yardımları Skandalı ve SyRI

Hollanda’da yaşanan çocuk bakım yardımları skandalı (*toeslagenaffaire*), algoritmik karar sistemlerinin yol açabileceği zararların belki de en çarpıcı Avrupa örneğidir. Hollanda vergi idaresi, 2010’lu yıllar boyunca, çocuk bakım yardımı alan on binlerce aileyi, çoğu zaman küçük biçimsel hatalar veya otomatik bir risk sınıflandırma sisteminin ürettiği şüpheler gerekçesiyle dolandırıcılıkla suçlamış ve aldıkları yardımları geri ödemelerini talep etmiştir. Pek çok aile, ödeyemeyecekleri borçlar altında kalmış; bir kısmı evlerini kaybetmiş, bir kısmının çocukları koruma altına alınmıştır. Hollanda Kişisel Verileri Koruma Kurumu’nun incelemesi, risk

[126] *Amato v Commonwealth of Australia*, Federal Court of Australia, 27 Kasım 2019 tarihli, tarafların mutabakatına dayanan karar.
[127] *Prygodicz v Commonwealth of Australia (No 2)* [2021] FCA 634.
[128] Royal Commission into the Robodebt Scheme, *Report*, Canberra, Temmuz 2023.

sınıflandırma sisteminin, başvuranların Hollanda vatandaşı olup olmamasını bir risk göstergesi olarak kullandığını ve bunun ayrımcı bir veri işleme olduğunu tespit etmiş ve vergi idaresine para cezası vermiştir.[129] Hollanda parlamentosunun soruşturma komisyonu, Aralık 2020'de yayımladığı ve başlığı "Benzeri Görülmemiş Haksızlık" (*Ongekend onrecht*) olan raporunda, hukuk devletinin temel ilkelerinin ihlal edildiğini tespit etmiştir.[130] Ocak 2021'de Hollanda hükümeti, skandal nedeniyle istifa etmiştir.

Aynı dönemde Hollanda'da, sosyal yardım dolandırıcılığını tespit etmek amacıyla farklı kamu kurumlarının verilerini birleştiren "Sistem Risk Göstergesi" (*Systeem Risico Indicatie*, SyRI) adlı başka bir sistem de kullanılmaktaydı. Lahey Bölge Mahkemesi, 5 Şubat 2020 tarihli kararında, SyRI'nin yasal dayanağının Avrupa İnsan Hakları Sözleşmesi'nin 8. maddesinde güvence altına alınan özel hayata saygı hakkını ihlal ettiğine hükmetmiştir.[131] Mahkeme, sistemin işleyişine ilişkin yeterli şeffaflığın bulunmamasını, bireylerin hangi verilerin hangi biçimde kullanıldığını ve risk raporlarının nasıl üretildiğini bilememesini ve bu nedenle sistemin keyfi ve ayrımcı etkilerinin denetlenememesini kararın temel gerekçeleri arasında saymıştır. SyRI kararı, algoritmik bir kamu sisteminin, salt şeffaflık eksikliği ve denetlenemezlik gerekçesiyle insan haklarına aykırı bulunduğu ilk önemli kararlardan biri olarak kabul edilmektedir.

C. Birleşik Krallık: Post Office "Horizon" Skandalı

Birleşik Krallık'ta yaşanan Post Office "Horizon" skandalı, denetim sorununun farklı bir boyutunu, yani *makinenin güvenilirliğine ilişkin hukuki karine* sorununu ortaya koymaktadır. 1999'dan itibaren İngiliz Posta İdaresi (*Post Office*), şube işletmecilerinin hesaplarını tutmak için Fujitsu tarafından geliştirilen "Horizon" adlı bir muhasebe yazılımı kullanmıştır. Sonraki on beş yıl boyunca, Horizon'un gösterdiği kasa açıkları gerekçesiyle yüzlerce şube işletmecisi hırsızlık, sahtecilik ve muhasebe hilesi suçlamalarıyla yargılanmış ve mahkûm edilmiştir. Pek çoğu, açıkları kendi ceplerinden kapatmak zorunda kalmış, iflas etmiş, hapse girmiş; bazıları intihar etmiştir.

---

[129] Autoriteit Persoonsgegevens, vergi idaresine (Belastingdienst) ilişkin Aralık 2021 tarihli idari para cezası kararı.

[130] Tweede Kamer der Staten-Generaal, Parlementaire ondervragingscommissie Kinderopvangtoeslag, *Ongekend onrecht*, Den Haag, 17 Aralık 2020.

[131] Rechtbank Den Haag, 5 Şubat 2020, ECLI:NL:RBDHA:2020:865.

2019 yılında Yüksek Mahkeme, bir grup davasında, Horizon sisteminde kasa açıklarına yol açabilecek "hatalar, kusurlar ve arızalar" bulunduğunu tespit etmiştir.[132] Bu karar, mahkûmiyetlerin yeniden incelenmesinin yolunu açmış; Temyiz Mahkemesi 2021'de çok sayıda mahkûmiyeti bozmuştur.[133] 2024 yılında ise Parlamento, Horizon verilerine dayanan mahkûmiyetleri toplu olarak ortadan kaldıran özel bir kanun çıkarmıştır.[134]

Horizon skandalının denetim bakımından en önemli dersi, İngiliz hukukunda bilgisayar kanıtlarına ilişkin bir karinenin rolüdür. 1999'a kadar İngiliz ceza muhakemesi hukukunda, bilgisayar kayıtlarının delil olarak kullanılabilmesi için bilgisayarın düzgün çalıştığının ispatlanması gerekiyordu. Bu kural 1999'da kaldırılmış ve yerini, aksi ispatlanmadıkça bilgisayarların düzgün çalıştığına ilişkin bir ortak hukuk karinesine bırakmıştır.[135] Bu karine, uygulamada, şube işletmecilerinin, ellerinde hiçbir teknik bilgi veya erişim olmaksızın, karmaşık bir yazılım sisteminin hatalı olduğunu ispatlamak zorunda kalmaları anlamına gelmiştir. Başka bir ifadeyle, hukuk, makineyi *varsayılan olarak güvenilir* kabul etmiş ve makinenin hatasının ispat yükünü, makineyi anlama olanağı en az olan tarafa yüklemiştir. Bu durum, aşağıda § 9'da ele alınacak olan "otomasyon yanlılığı"nın kurumsal ve hukuki düzeydeki bir yansımasıdır.

D. Amerika Birleşik Devletleri: COMPAS ve Loomis Davası

Amerika Birleşik Devletleri'nde, ceza yargılamasında risk değerlendirme araçlarının kullanımı, algoritmik karar sistemlerinin yargı süreçlerine nüfuzunun en çok tartışılan örneğidir. Bu araçların en bilineni olan COMPAS (*Correctional Offender Management Profiling for Alternative Sanctions*), bir sanığın yeniden suç işleme riskini, bir anket ve sanığın geçmişine ilişkin veriler üzerinden hesaplayan, özel bir şirket tarafından geliştirilmiş ve iç işleyişi ticari sır olarak korunan bir yazılımdır.

Wisconsin Yüksek Mahkemesi, 2016 tarihli *State v. Loomis* kararında, ceza belirlenirken COMPAS risk puanının dikkate alınmasının sanığın hukuki güvence (*due process*) hakkını ihlal etmediğine hükmetmiştir.[136]

---

[132] *Bates and Others v Post Office Ltd (No 6: Horizon Issues)* [2019] EWHC 3408 (QB).
[133] *Hamilton and Others v Post Office Ltd* [2021] EWCA Crim 577.
[134] Post Office (Horizon System) Offences Act 2024.
[135] Youth Justice and Criminal Evidence Act 1999, s. 60 ile Police and Criminal Evidence Act 1984, s. 69'un yürürlükten kaldırılması.
[136] *State v. Loomis*, 881 N.W.2d 749 (Wis. 2016).

Mahkeme, sanığın, algoritmanın iç işleyişine erişememesine rağmen, risk puanının dayandığı soruları ve kendi cevaplarını görebildiğini ve puanın doğruluğuna itiraz edebileceğini; ayrıca puanın, cezayı belirleyen tek veya belirleyici etken olmadığını göz önünde bulundurmuştur. Bununla birlikte mahkeme, risk puanlarının kullanımında hâkimlere, aracın sınırlılıklarına ilişkin yazılı uyarılar yapılması gerektiğine de hükmetmiştir.

Aynı yıl, araştırmacı gazetecilik kuruluşu ProPublica'nın yayımladığı bir inceleme, COMPAS'ın siyahi sanıklar için, beyaz sanıklara kıyasla, yeniden suç işlemeyecek olduğu hâlde "yüksek riskli" olarak sınıflandırılma oranının belirgin biçimde daha yüksek olduğunu ileri sürmüştür.[137] Yazılım şirketi bu bulgulara itiraz etmiş; ardından gelen akademik tartışma, farklı "adalet" ölçütlerinin (örneğin farklı gruplar için eşit hata oranları ile eşit tahmin doğruluğu) matematiksel olarak aynı anda karşılanamayacağını göstermiştir.[138] Bu sonuç, algoritmik sistemlerin tasarımında hangi adalet ölçütünün tercih edileceğinin teknik değil, *normatif* bir karar olduğunu göstermesi bakımından son derece önemlidir.

COMPAS tartışmasının bu çalışma bakımından belki de en ilginç bulgusu, 2018'de yayımlanan bir araştırmadan gelmiştir. Bu araştırma, hiçbir ceza adaleti uzmanlığı bulunmayan ve çevrimiçi olarak işe alınan sıradan katılımcıların, sanıklar hakkında yalnızca birkaç temel bilgiyle, yeniden suç işlemeyi COMPAS ile aşağı yukarı aynı doğrulukla tahmin edebildiğini göstermiştir.[139] Bu bulgu, algoritmik sistemlerin "insanlardan daha iyi karar verdiği" yönündeki iddiaların kendisinin de bağımsız denetime tabi tutulması gerektiğini göstermektedir. Bir sistemin üstünlüğü, varsayılmamalı, *sınanmalıdır*.

E. Diğer Örnekler

Bu vakalara, başka örnekler de eklenebilir. Amerika'da Houston okul bölgesinde öğretmenlerin performansını değerlendirmek için kullanılan ve iç işleyişi ticari sır olarak korunan bir algoritmanın, öğretmenlerin değerlendirmelerini doğrulama ve itiraz etme olanağından yoksun

[137] Julia Angwin / Jeff Larson / Surya Mattu / Lauren Kirchner, "Machine Bias", *ProPublica*, 23 Mayıs 2016.

[138] Jon Kleinberg / Sendhil Mullainathan / Manish Raghavan, "Inherent Trade-Offs in the Fair Determination of Risk Scores", arXiv:1609.05807, 2016; Alexandra Chouldechova, "Fair Prediction with Disparate Impact: A Study of Bias in Recidivism Prediction Instruments", *Big Data*, C. 5, S. 2, 2017.

[139] Julia Dressel / Hany Farid, "The Accuracy, Fairness, and Limits of Predicting Recidivism", *Science Advances*, C. 4, S. 1, 2018.

bırakılmaları nedeniyle hukuki güvence ilkesi bakımından sorunlu olduğu, federal bir mahkeme tarafından tespit edilmiştir.[140] Birleşik Krallık'ta 2020 yılında, COVID-19 salgını nedeniyle yapılamayan sınavların yerine öğrencilerin notlarını belirlemek için kullanılan bir algoritmanın, okulların geçmiş başarı düzeylerini esas alarak dezavantajlı okullardaki başarılı öğrencilerin notlarını sistematik olarak düşürdüğü ortaya çıkmış; yaygın protestoların ardından hükümet algoritmanın sonuçlarını iptal etmiştir. Yine Birleşik Krallık'ta, polisin kamusal alanlarda canlı yüz tanıma teknolojisi kullanmasının, yeterli yasal çerçeve ve ayrımcılık değerlendirmesi bulunmaması nedeniyle hukuka aykırı olduğuna Temyiz Mahkemesi tarafından hükmedilmiştir.[141]

III. Vakalardan Çıkan Dersler

Bu vakaların karşılaştırmalı analizi, yapay zekânın denetimi sorununa ilişkin yedi önemli ders ortaya koymaktadır.

Birinci ders: Denetimden kaçmak için zekâ gerekmez. İncelenen sistemlerin hiçbiri ileri yapay zekâ değildi; çoğu, görece basit kurallara veya istatistiksel modellere dayanıyordu. Buna rağmen, bu sistemler yıllarca etkin bir denetimden kaçabilmiştir. Sorun, sistemlerin karmaşıklığından çok, onları çevreleyen kurumsal yapının denetim kapasitesinin ve isteğinin yetersizliğinden kaynaklanmıştır. Bu ders, yapay zekânın denetimi sorununun yalnızca teknik bir sorun olmadığını, en az o kadar kurumsal bir sorun olduğunu göstermektedir.

İkinci ders: İspat yükü, makineyi anlama olanağı en az olana kayma eğilimindedir. Robodebt'te yardım alanlar, Horizon'da şube işletmecileri, COMPAS'ta sanıklar, kendilerine karşı kullanılan sistemin hatalı olduğunu ispatlamak zorunda kalmıştır. Oysa sistemin işleyişine ilişkin bilgi ve erişim, karşı tarafın, yani devletin veya sistemi geliştiren şirketin elindeydi. Bu durum, Birinci Bölüm'de ele alınan Weber'ci bilgi asimetrisinin hukuki bir ifadesidir: Bilgiyi elinde tutan, ispat yükünü de karşı tarafa yükleyebilmektedir.

Üçüncü ders: Uyarılar göz ardı edilir. Robodebt'te hükümete sistemin hukuka aykırı olabileceğine dair hukuki görüşler sunulmuş; Horizon'da şube işletmecileri yıllarca sistemin hatalı olduğunu söylemiş;

[140] *Houston Federation of Teachers, Local 2415 v. Houston Independent School District*, 251 F. Supp. 3d 1168 (S.D. Tex. 2017).
[141] *R (Bridges) v Chief Constable of South Wales Police* [2020] EWCA Civ 1058.

Hollanda'da etkilenen aileler ve onların avukatları defalarca şikâyette bulunmuştur. Bu uyarılar, kurumsal teşvikler, sistemin güvenilirliğine duyulan aşırı güven ve sorunu kabul etmenin maliyeti nedeniyle uzun süre dikkate alınmamıştır. Bu ders, "yangın alarmı" türü denetim mekanizmalarının, ancak alarmlara cevap verecek bağımsız ve yetkili bir kurum bulunduğunda işe yarayacağını göstermektedir.

Dördüncü ders: Makinenin güvenilirliği karine olarak kabul edilmemelidir. Horizon vakası, makinenin güvenilirliğine ilişkin hukuki bir karinenin ne kadar yıkıcı sonuçlar doğurabileceğini açıkça göstermiştir. Bu ders, yapay zekâ çıktılarının delil değerine ve idari kararlardaki ağırlığına ilişkin kuralların tasarımında özellikle dikkate alınmalıdır.

Beşinci ders: Ölçek, zararı büyütür. Bir insan memurun hatası, sınırlı sayıda kişiyi etkiler. Otomatik bir sistemin hatası ise binlerce, hatta yüz binlerce kişiyi aynı anda ve aynı biçimde etkiler. Bu durum, denetimin önemini, sistemin ölçeğiyle orantılı olarak artırır.

Altıncı ders: Düzeltme, çoğulcu ve dairesel bir denetim ağı aracılığıyla, ancak gecikmeli olarak gelmiştir. İncelenen vakaların hiçbirinde, sorun, sistemi kullanan kurumun kendi iç denetimiyle tespit edilip düzeltilmemiştir. Düzeltme, mahkemeler, parlamento soruşturma komisyonları, veri koruma otoriteleri, araştırmacı gazeteciler, sivil toplum kuruluşları ve akademisyenlerden oluşan geniş ve dağınık bir denetim ağının birlikte çalışmasıyla gelmiştir. Bu durum, Sekizinci Bölüm'de geliştirilecek olan "dairesel denetim" modelinin ampirik bir doğrulamasıdır; ancak aynı zamanda bu ağın yavaşlığının ve düzeltmenin ancak yıllar sonra ve büyük zararlar meydana geldikten sonra gelmesinin, kabul edilemez bir maliyet taşıdığını da göstermektedir.

Yedinci ders: Sistemin "üstünlüğü" sınanmalıdır. COMPAS'a ilişkin araştırma, algoritmik sistemlerin insan kararlarından daha iyi olduğu yönündeki iddiaların her zaman doğru olmadığını göstermiştir. Yapay zekânın karar vericileri "aştığı" iddiası, kendi başına, denetime tabi tutulması gereken bir iddiadır.

Bu dersler, görece basit sistemlerden çıkarılmıştır. Çok daha yetenekli ve karmaşık sistemler söz konusu olduğunda, bu sorunların her biri daha da ağırlaşacaktır. Hatalar daha ince ve daha zor tespit edilebilir olacak, sistemin işleyişini anlamak daha da güçleşecek, sisteme duyulan güven ve bağımlılık artacak ve sistemin hatalı olduğunu ispatlamak daha da

zorlaşacaktır. Bir sonraki başlıkta, bu sorunların temelinde yatan insan bilişsel sınırları ele alınacaktır.

§ 9. BİLİŞSEL ASİMETRİ VE İNSAN DENETİMİNİN SINIRLARI

Algoritmik karar sistemlerinin düzenlenmesine ilişkin politika belgelerinde ve hukuki metinlerde en sık önerilen güvence, "insan denetimi"dir (*human oversight*): Otomatik sistemlerin çıktıları, nihai karar alınmadan önce bir insan tarafından incelenmeli ve gerektiğinde düzeltilmelidir. Bu güvence, Avrupa Birliği Genel Veri Koruma Tüzüğü'nün 22. maddesinden Yapay Zekâ Tüzüğü'nün 14. maddesine kadar pek çok düzenlemede yer almaktadır. Ancak insan faktörleri mühendisliği ve bilişsel psikoloji alanlarında on yıllardır biriken araştırmalar, insan denetiminin, kâğıt üzerinde göründüğü kadar güçlü bir güvence olmadığını, belirli koşullarda neredeyse tamamen işlevsiz hâle gelebileceğini göstermektedir. Bu bölümde, söz konusu araştırmaların başlıca bulguları ele alınacaktır.

I. Otomasyonun İronileri

İnsan-otomasyon etkileşimine ilişkin literatürün belki de en etkili metni, İngiliz psikolog Lisanne Bainbridge'in 1983'te yayımlanan "Otomasyonun İronileri" başlıklı makalesidir.[142] Bainbridge, endüstriyel süreç kontrolü bağlamında, otomasyonun insan operatörün rolünü ortadan kaldırmak yerine, onu paradoksal biçimlerde daha zor hâle getirdiğini göstermiştir. Bainbridge'in tespit ettiği ironiler, yapay zekânın insan denetimi bakımından doğrudan uygulanabilir niteliktedir.

Birinci ironi, otomasyon tasarımcılarının, insan operatörü güvenilmez ve verimsiz bir unsur olarak görüp onu mümkün olduğunca devre dışı bırakmaya çalışmaları; ancak otomatikleştiremedikleri görevleri, yani en zor, en beklenmedik ve en kritik görevleri yine insana bırakmalarıdır. İnsan, sistemin "artık" görevleriyle baş başa kalır.

İkinci ironi, izleme görevine ilişkindir. Otomatik bir sistemin düzgün çalışıp çalışmadığını izlemek, insanların son derece kötü yaptığı bir görevdir. İkinci Dünya Savaşı sırasında radar operatörleri üzerinde yapılan klasik araştırmalardan bu yana bilindiği üzere, insanların nadiren

[142] Lisanne Bainbridge, "Ironies of Automation", *Automatica*, C. 19, S. 6, 1983.

gerçekleşen olayları fark etme yeteneği, izleme süresi uzadıkça hızla düşer; yarım saat gibi kısa bir süre sonra bile dikkat belirgin biçimde azalır.[143] Otomatik sistem ne kadar güvenilirse, hata o kadar nadir görülür ve insanın bu nadir hatayı fark etme olasılığı o kadar düşer.

Üçüncü ironi, beceri kaybına ilişkindir. Otomatik sistem çoğu zaman düzgün çalıştığında, insan operatörün sistemi elle kontrol etme becerisi, kullanılmadığı için zamanla körelir. Ancak sistem arızalandığında ve insanın devreye girmesi gerektiğinde, tam da bu körelmiş beceriye ihtiyaç duyulur. Üstelik bu anlar, genellikle olağandışı, karmaşık ve zaman baskısı altındaki anlardır.

Dördüncü ironi, durumsal farkındalığa ilişkindir. Sistemi aktif olarak kontrol etmeyen bir operatör, sistemin o anki durumuna ilişkin ayrıntılı bir zihinsel modele sahip değildir. Devreye girmesi gerektiğinde, önce neler olup bittiğini anlamak zorundadır; bu da kritik zaman kaybına yol açar.

Bainbridge, makalesini şu paradoksal tespitle özetler: Bir kontrol sistemi ne kadar gelişmişse, insan operatörün katkısı o kadar kritik olabilir. Bu tespit, yapay zekâ bağlamında son derece önemlidir. Yapay zekâ sistemleri ne kadar yetenekli hâle gelirse, insan denetçinin görevi o kadar zorlaşır: Daha nadir ama daha ince hataları, daha karmaşık bir sistemin içinde, daha az pratik deneyimle ve daha düşük bir durumsal farkındalıkla tespit etmek zorunda kalır.

Bu ironilerin trajik bir örneği, 1 Haziran 2009'da Rio de Janeiro'dan Paris'e uçan Air France 447 sefer sayılı uçağın Atlantik Okyanusu'na düşmesidir. Fransız kaza soruşturma kurumunun nihai raporu, hız sensörlerinin geçici olarak buzlanması sonucunda otomatik pilotun devre dışı kaldığını ve uçağın kontrolünü devralan pilotların, beklenmedik durum karşısında durumu doğru değerlendiremediğini ve uygun manevraları yapamadığını tespit etmiştir.[144] Rapor, pilotların yüksek irtifada elle uçuş deneyiminin sınırlılığına ve otomasyondan elle kontrole geçişteki zorluklara dikkat çekmiştir. Bu olay, Bainbridge'in ironilerinin tam olarak öngördüğü senaryodur: Otomasyon çoğu zaman kusursuz çalışmış, insanlar elle kontrol becerisini yeterince kullanmamış ve otomasyon beklenmedik bir anda devre dışı kaldığında, insanlar devralmaya hazır olmamıştır.

[143] N. H. Mackworth, "The Breakdown of Vigilance during Prolonged Visual Search", *Quarterly Journal of Experimental Psychology*, C. 1, S. 1, 1948.

[144] Bureau d'Enquêtes et d'Analyses pour la sécurité de l'aviation civile (BEA), *Rapport final: Accident survenu le 1er juin 2009 à l'Airbus A330-203 immatriculé F-GZCP exploité par Air France, vol AF 447 Rio de Janeiro - Paris*, Juillet 2012.

II. Otomasyon Yanlılığı ve Seçici Uyum

A. Otomasyon Yanlılığı

İnsan denetiminin ikinci temel sorunu, "otomasyon yanlılığı" (*automation bias*) olarak adlandırılan bilişsel eğilimdir. Otomasyon yanlılığı, insanların otomatik sistemlerin önerilerine, kendi bağımsız değerlendirmelerine veya çelişen diğer bilgilere kıyasla aşırı ağırlık verme eğilimidir. Bu eğilim, iki tür hataya yol açar: *ihmal hataları* (*errors of omission*), yani otomatik sistemin uyarmadığı bir sorunu fark etmeme; ve *icra hataları* (*errors of commission*), yani otomatik sistemin hatalı bir önerisine, aksini gösteren bilgilere rağmen uyma.[145]

Raja Parasuraman ve Victor Riley, insan-otomasyon ilişkisindeki sorunları dört kategoride sınıflandırmıştır: otomasyonun *kullanımı* (uygun biçimde kullanılması), *kötü kullanımı* (*misuse*, otomasyona aşırı güvenilmesi), *kullanılmaması* (*disuse*, otomasyona yetersiz güvenilmesi) ve *istismarı* (*abuse*, otomasyonun, insan operatörlerin yeteneklerine ve ihtiyaçlarına yeterince dikkat edilmeden tasarlanıp uygulanması).[146] Otomasyon yanlılığı, "kötü kullanım" kategorisine girer. Sağlık hizmetlerinde klinik karar destek sistemlerine ilişkin araştırmaları inceleyen sistematik bir derleme, otomasyon yanlılığının yaygın bir olgu olduğunu ve sistemlerin hatalı önerilerinin, hekimlerin doğru kararlarını yanlış kararlarla değiştirmelerine yol açabildiğini doğrulamıştır.[147]

İlginç biçimde, araştırmalar, insanların algoritmalara karşı tutumunun tek yönlü olmadığını da göstermektedir. Bazı deneyler, insanların bir algoritmanın hata yaptığını gördükten sonra ona karşı aşırı bir güvensizlik geliştirdiğini ve aynı hatayı yapan bir insana göre algoritmayı daha sert cezalandırdığını ortaya koymuştur ("algoritma karşıtlığı").[148] Başka deneyler ise birçok durumda insanların algoritmik tavsiyeleri insan tavsiyelerine tercih ettiğini göstermiştir ("algoritma takdiri").[149] Bu karşıt bulgular, insanların algoritmalara karşı tutumunun, bağlama, görevin

[145] Linda J. Skitka / Kathleen L. Mosier / Mark Burdick, "Does Automation Bias Decision-Making?", *International Journal of Human-Computer Studies*, C. 51, S. 5, 1999.

[146] Raja Parasuraman / Victor Riley, "Humans and Automation: Use, Misuse, Disuse, Abuse", *Human Factors*, C. 39, S. 2, 1997.

[147] Kate Goddard / Abdul Roudsari / Jeremy C. Wyatt, "Automation Bias: A Systematic Review of Frequency, Effect Mediators, and Mitigators", *Journal of the American Medical Informatics Association*, C. 19, S. 1, 2012.

[148] Berkeley J. Dietvorst / Joseph P. Simmons / Cade Massey, "Algorithm Aversion: People Erroneously Avoid Algorithms After Seeing Them Err", *Journal of Experimental Psychology: General*, C. 144, S. 1, 2015.

niteliğine ve algoritmanın geçmiş başarımına bağlı olarak değiştiğini ve "doğru düzeyde güven"in kendiliğinden ortaya çıkmadığını göstermektedir.

B. Seçici Uyum

Kamu yönetimi bağlamında yapılan araştırmalar, otomasyon yanlılığının daha da sorunlu bir biçimine dikkat çekmektedir. Hollanda'da kamu görevlileri ve vatandaşlar üzerinde yürütülen deneysel bir araştırma, karar vericilerin algoritmik tavsiyelere *seçici olarak* uyduğunu göstermiştir: Algoritmanın tavsiyesi, karar vericinin mevcut önyargılarıyla (örneğin belirli etnik gruplara ilişkin kalıp yargılarla) örtüştüğünde, karar verici tavsiyeye uyma eğilimindedir; örtüşmediğinde ise tavsiyeyi göz ardı etme eğilimindedir.[150] Bu bulgu, insan denetiminin, algoritmik önyargıları düzeltmek yerine, insan önyargılarıyla birleşerek onları pekiştirebileceğini düşündürmektedir. Başka bir araştırma ise, ceza yargılamasında risk değerlendirme araçlarıyla etkileşime giren insanların, aracın tavsiyelerinden sapmalarının farklı gruplar için farklı biçimlerde gerçekleştiğini ve bunun, insan ve algoritmanın birlikte ürettiği kararlarda yeni eşitsizliklere yol açabildiğini göstermiştir.[151]

C. İkna, Dalkavukluk ve Büyük Dil Modelleri

Büyük dil modelleri, otomasyon yanlılığı sorununa yeni bir boyut eklemektedir. Geleneksel otomatik sistemler, bir puan, bir sınıflandırma veya bir uyarı gibi görece yalın çıktılar üretir. Büyük dil modelleri ise önerilerini akıcı, ikna edici ve gerekçelendirilmiş bir dille sunar. Bu durum, bir yandan sistemin akıl yürütmesini denetlemeyi kolaylaştırabilir; öte yandan, sistemin çıktılarına duyulan güveni, bu çıktıların gerçek doğruluğundan bağımsız olarak artırabilir. İkna edici bir gerekçe, doğru bir gerekçe ile aynı şey değildir.

Araştırmalar, büyük dil modellerinin kayda değer bir ikna gücüne sahip olduğunu göstermektedir. Bir deneyde, karşısındaki kişiye ilişkin temel kişisel bilgilere erişimi olan bir dil modelinin, tartışmalı konularda

[149] Jennifer M. Logg / Julia A. Minson / Don A. Moore, "Algorithm Appreciation: People Prefer Algorithmic to Human Judgment", *Organizational Behavior and Human Decision Processes*, C. 151, 2019.

[150] Saar Alon-Barkat / Madalina Busuioc, "Human–AI Interactions in Public Sector Decision Making: 'Automation Bias' and 'Selective Adherence' to Algorithmic Advice", *Journal of Public Administration Research and Theory*, C. 33, S. 1, 2023.

[151] Ben Green / Yiling Chen, "Disparate Interactions: An Algorithm-in-the-Loop Analysis of Fairness in Risk Assessments", *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAT*)*, 2019.

yapılan münazaralarda, insan münazaracılardan daha ikna edici olduğu bulunmuştur.[152] Başka bir deneyde ise bir dil modeliyle yapılan kısa diyalogların, komplo teorilerine olan inancı kalıcı biçimde azaltabildiği gösterilmiştir.[153] Bu bulgular, ikna gücünün kendi başına iyi veya kötü olmadığını gösterir; ancak denetim bakımından önemli bir soru ortaya çıkarır: Kendisini denetleyen kişileri ikna etme kapasitesine sahip bir sistem, nasıl denetlenecektir?

Bu soruna ek olarak, büyük dil modellerinde "dalkavukluk" (*sycophancy*) olarak adlandırılan bir eğilim gözlemlenmiştir: Modeller, kullanıcının açıkladığı görüşlerle uyumlu cevaplar verme ve kullanıcının duymak istediği şeyleri söyleme eğilimi gösterebilmektedir.[154] Araştırmacılar, bu eğilimin kısmen, modellerin insan değerlendiricilerin tercihlerine göre eğitilmesinden kaynaklandığını düşünmektedir: İnsanlar, kendi görüşlerini doğrulayan cevapları daha yüksek puanlama eğiliminde olduğundan, modeller de bu tür cevaplar vermeyi öğrenmektedir. Dalkavukluk, karar vericiler bağlamında özellikle tehlikelidir. Bir karar vericinin, kendi önyargılarını doğrulayan bir yapay zekâ danışmanına sahip olması, Kant'ın uyarısını yeni bir biçimde hatırlatır: İktidar sahibinin özgür yargısı, bu kez iktidarın kendisi tarafından değil, iktidar sahibini memnun etmeye programlanmış bir danışman tarafından bozulabilir.

III. Ahlaki Çarpışma Bölgeleri

İnsan denetiminin üçüncü sorunu, sorumluluğun dağılımına ilişkindir. Antropolog Madeleine Clare Elish, insan ve otomatik sistemlerin birlikte çalıştığı durumlarda bir şeyler ters gittiğinde, sorumluluğun orantısız biçimde insan operatöre yüklendiğini gözlemlemiş ve bu durumu "ahlaki çarpışma bölgesi" (*moral crumple zone*) metaforuyla tanımlamıştır.[155] Bir otomobilin çarpışma bölgesi, kazanın enerjisini emerek yolcuları korumak üzere tasarlanmıştır. Ahlaki çarpışma bölgesinde ise insan operatör,

[152] Francesco Salvi / Manoel Horta Ribeiro / Riccardo Gallotti / Robert West, "On the Conversational Persuasiveness of Large Language Models: A Randomized Controlled Trial", arXiv:2403.14380, 2024.

[153] Thomas H. Costello / Gordon Pennycook / David G. Rand, "Durably Reducing Conspiracy Beliefs through Dialogues with AI", *Science*, C. 385, S. 6714, 2024.

[154] Mrinank Sharma vd., "Towards Understanding Sycophancy in Language Models", arXiv:2310.13548, 2023.

[155] Madeleine Clare Elish, "Moral Crumple Zones: Cautionary Tales in Human-Robot Interaction", *Engaging Science, Technology, and Society*, C. 5, 2019.

sistemin hatasının ahlaki ve hukuki "enerjisini" emerek, sistemin kendisini ve onu tasarlayan ve kullanan kurumları korur.

Bu olgunun çarpıcı bir örneği, Mart 2018'de Arizona eyaletinin Tempe kentinde, bir ulaşım şirketinin test ettiği otonom bir aracın, yolun karşısına geçmekte olan bir yayaya çarparak ölümüne yol açmasıdır. Ulusal Ulaştırma Güvenliği Kurulu'nun incelemesi, aracın otonom sürüş yazılımının yayayı zamanında doğru biçimde sınıflandıramadığını, şirketin güvenlik kültürünün yetersiz olduğunu ve araçta bulunan güvenlik sürücüsünün dikkatinin dağınık olduğunu tespit etmiştir.[156] Olayın ardından ilgili savcılık şirket hakkında ceza kovuşturması başlatmamaya karar vermiş; güvenlik sürücüsü ise yargılanmış ve sonunda daha hafif bir suçlamayı kabul ederek denetimli serbestlik cezası almıştır. Bu sonuç, Elish'in metaforunun tam bir örneğidir: Sistemin tasarımındaki ve şirketin güvenlik politikalarındaki kusurlara rağmen, hukuki sorumluluğun ağırlığı, sistemi "denetlemesi" beklenen tek insanın üzerine düşmüştür.

Ahlaki çarpışma bölgesi kavramı, "insan denetimi" güvencesinin karanlık bir yüzünü ortaya koyar. İnsan denetimi, sistemi daha güvenli kılmaktan çok, sorumluluğun insan operatöre aktarılmasının bir aracı olarak işlev görebilir. Bir kurum, otomatik bir sistemin kararlarını "bir insanın onayladığını" söyleyerek, hem sistemin kararlarının meşruiyetini artırabilir hem de olası hataların sorumluluğunu o insana yükleyebilir. Oysa yukarıda ele alınan bilişsel sınırlar nedeniyle, bu insan, sistemin hatalarını tespit etme konusunda gerçek bir kapasiteye sahip olmayabilir. Bu durumda insan denetimi, gerçek bir denetim değil, bir "meşruiyet tiyatrosu" hâline gelir. Siyaset bilimci Ben Green, kamu yönetiminde algoritmik sistemlere ilişkin insan denetimi zorunluluklarını inceleyen bir çalışmasında, bu zorunlulukların, insanların algoritmaları etkin biçimde denetleyebileceği yönündeki ampirik olarak desteklenmeyen bir varsayıma dayandığını ve uygulamada, sorunlu algoritmaların kullanımını meşrulaştırma işlevi görebildiğini ileri sürmüştür.[157]

[156] National Transportation Safety Board, *Collision Between Vehicle Controlled by Developmental Automated Driving System and Pedestrian, Tempe, Arizona, March 18, 2018*, Highway Accident Report NTSB/HAR-19/03, Washington, 2019.

[157] Ben Green, "The Flaws of Policies Requiring Human Oversight of Government Algorithms", *Computer Law & Security Review*, C. 45, 2022.

IV. Beceri Erozyonu ve Kurumsal Bilişsel Körelme

İnsan denetiminin dördüncü sorunu, uzun vadeli bir sorundur. Bainbridge'in üçüncü ironisi, bireysel operatörlerin becerilerinin otomasyonla birlikte körelmesine ilişkindi. Bu olgu, kurumsal düzeyde de geçerlidir. Bir kurum, belirli bir alandaki kararları uzun süre otomatik sistemlere bıraktığında, o alandaki kurumsal uzmanlığını, yani o kararları kendi başına verebilecek, sistemin çıktılarını eleştirel olarak değerlendirebilecek ve sistem arızalandığında devralabilecek insan kapasitesini yitirebilir. Bu çalışmada bu olguya **"kurumsal bilişsel körelme"** adı verilmektedir.

Kurumsal bilişsel körelmenin birkaç mekanizması vardır. *Birincisi*, otomatik sistemler devreye girdiğinde, bu sistemlerin yaptığı işi daha önce yapan personel, ya başka görevlere kaydırılır ya da kurumdan ayrılır. Onların yerine gelen yeni personel, o işi hiçbir zaman sistemsiz yapmamış olur. *İkincisi*, sistemlerin geliştirilmesi ve bakımı çoğu zaman dış şirketlere bırakıldığından, sistemin nasıl çalıştığına ilişkin bilgi de kurum dışında kalır. Bu durum, Weber'in "hizmet bilgisi" kavramının ilginç bir tersyüz oluşudur: Artık bilgi, bürokraside değil, bürokrasinin hizmet aldığı şirketlerde birikmektedir. *Üçüncüsü*, otomatik sistemler belirli bir süre başarılı biçimde çalıştıktan sonra, kurum içinde bu sistemlerin çıktılarını sorgulamak, hem gereksiz hem de kariyer açısından riskli bir davranış olarak algılanmaya başlar. Sistemi sorgulayan kişi, eğer haklı çıkmazsa, verimliliği engelleyen biri olarak görülür; haklı çıkarsa ise kurumun sistemi benimseme kararını sorgulamış olur.

Kurumsal bilişsel körelme, yapay zekâ bağlamında özellikle tehlikelidir; çünkü sistemlerin yetenekleri arttıkça, insanların bu sistemlere bağımlılığı da artacak ve bu bağımlılık, kendi kendini güçlendiren bir döngüye dönüşebilecektir. Sistemlere bağımlılık arttıkça insan kapasitesi azalır; insan kapasitesi azaldıkça sistemlere bağımlılık daha da artar. Bu döngünün sonunda, kurum, sistemi kullanmaktan vazgeçme seçeneğini fiilen yitirebilir. Popper'ci ölçüt bakımından bu, son derece ciddi bir durumdur: Bir sistemden vazgeçme seçeneğinin yitirilmesi, o sistemin hatalı olduğu anlaşıldığında düzeltilememesi anlamına gelir. Dördüncü Bölüm'de bu olgu, toplumsal düzeyde "kademeli güçsüzleşme" kavramı bağlamında yeniden ele alınacaktır.

V. Acemi Uzmanı Nasıl Değerlendirir? Goldman'ın Beş Kanıt Kaynağı

A. Acemi-Uzman Sorunu

Yukarıda ele alınan sorunlar, bilişsel psikolojinin ve insan faktörleri mühendisliğinin ampirik bulgularıdır. Bu sorunların altında, felsefi bir sorun yatmaktadır: Bir alanda uzman olmayan biri, o alandaki bir uzmanın güvenilir olup olmadığını nasıl değerlendirebilir? Bu soru, epistemolojide "acemi-uzman sorunu" (*novice-expert problem*) olarak bilinir ve en sistematik biçimde Alvin Goldman tarafından ele alınmıştır.[158]

Goldman'ın sorunu formüle ediş biçimi, yapay zekânın denetimi sorununu doğrudan aydınlatır. Acemi, uzmanın görüşünü kendi başına değerlendiremez; çünkü bunu yapabilmek için uzmanın sahip olduğu bilgiye sahip olması gerekir ki, o zaman acemi olmazdı. Peki acemi, hangi uzmana güveneceğine, ya da tek bir uzmanın söylediklerine ne ölçüde güveneceğine nasıl karar verecektir? Goldman, acemilerin uzmanları değerlendirmek için başvurabileceği beş kanıt kaynağı belirler. Bu çalışmada, Goldman'ın beş kaynağının, yapay zekânın denetimi bakımından sistematik bir analiz çerçevesi sunduğu ve her birinin yapay zekâ güvenliği literatüründe geliştirilen bir denetim aracına karşılık geldiği ileri sürülmektedir. Bu eşleştirme, çalışmanın özgün analitik katkılarından biridir.

B. Beş Kanıt Kaynağı ve Yapay Zekâ Denetimindeki Karşılıkları

1. Uzmanların sunduğu argümanlar. Acemi, uzmanın argümanının içeriğini tam olarak değerlendiremese bile, argümanın *diyalektik üstünlüğünü* değerlendirebilir. İki uzmanın tartıştığı bir durumda, acemi, hangi uzmanın diğerinin itirazlarına daha iyi cevap verdiğini, hangisinin daha hızlı ve daha tutarlı biçimde karşılık verdiğini gözlemleyebilir. *Yapay zekâ karşılığı:* Bu kaynak, "münazara yoluyla güvenlik" (*AI safety via debate*) yaklaşımının temelidir. Bu yaklaşımda, iki yapay zekâ sistemi bir soru hakkında karşıt pozisyonları savunur ve bir insan yargıç, hangi sistemin daha iyi argüman sunduğuna karar verir. Yaklaşımın temel varsayımı, doğru bir pozisyonu savunmanın, yanlış bir pozisyonu savunmaktan daha kolay olduğu ve bu nedenle, yargıcın kendisi konuyu tam olarak anlamasa bile, münazaranın doğru cevabı ortaya çıkaracağıdır.[159]

[158] Goldman, "Experts: Which Ones Should You Trust?".
[159] Irving / Christiano / Amodei, "AI Safety via Debate".

2. Diğer uzmanların görüş birliği. Acemi, bir uzmanın görüşünün diğer uzmanlar tarafından ne ölçüde paylaşıldığına bakabilir. *Yapay zekâ karşılığı:* Bu kaynak, birden fazla bağımsız sistemin aynı soruya verdiği cevapların karşılaştırılmasına, yani "topluluk" (*ensemble*) yöntemlerine ve farklı kuruluşlarca geliştirilen sistemlerin çapraz kontrolüne karşılık gelir.

3. Üst-uzmanların değerlendirmeleri. Acemi, uzmanın yetkinliğine ilişkin üçüncü tarafların değerlendirmelerine, yani diplomalara, sertifikalara, meslek kuruluşlarının onayına, akran değerlendirmesine başvurabilir. *Yapay zekâ karşılığı:* Bu kaynak, bağımsız değerlendirme kuruluşlarının yaptığı model değerlendirmelerine (*evaluations*), standartlaştırılmış başarım testlerine (*benchmarks*), uyum belgelendirmelerine ve denetim (*audit*) raporlarına karşılık gelir.[160]

4. Çıkar ve önyargılara ilişkin kanıtlar. Acemi, uzmanın görüşünü etkileyebilecek çıkar çatışmalarının ve önyargıların bulunup bulunmadığına bakabilir. Örneğin bir ilacın güvenliğini savunan bir uzmanın, o ilacı üreten şirketten para alıp almadığını araştırabilir. *Yapay zekâ karşılığı:* Bu kaynak, iki farklı düzlemde işler. Birinci düzlemde, sistemi geliştiren şirketin ticari çıkarları, yani sistemin güvenliğine ilişkin değerlendirmelerin bu çıkarlardan ne ölçüde etkilendiği sorgulanır. İkinci düzlemde ise sistemin *kendisinin* "çıkarları", yani eğitim sürecinde edindiği ve çıktılarını etkileyebilecek eğilimler (dalkavukluk, ödül istismarı, kendini koruma eğilimi gibi) incelenir.

5. Geçmiş başarı kaydı. Acemi, uzmanın geçmişteki tahminlerinin ve önerilerinin ne ölçüde doğru çıktığına bakabilir. Bu, Goldman'a göre, belki de en güçlü kanıt kaynağıdır; çünkü acemi, uzmanın akıl yürütmesini anlamasa bile, sonuçların doğru çıkıp çıkmadığını gözlemleyebilir. *Yapay zekâ karşılığı:* Bu kaynak, sistemlerin kullanım sırasındaki başarımının sürekli izlenmesine, olay ve hata kayıtlarının tutulmasına ve bu kayıtların sistematik olarak analiz edilmesine karşılık gelir. Aristoteles'in "kullanan değerlendirir" argümanı, bu kaynağın felsefi temelini oluşturur.

C. Stratejik Asimetri Altında Beş Kaynağın Sınırları

Goldman'ın beş kanıt kaynağı, acemilerin uzmanları değerlendirmesi için değerli araçlar sunar. Ancak Goldman'ın analizi, uzmanların genellikle acemileri kasıtlı olarak yanıltmaya çalışmadığı ve uzmanlar arasındaki bilişsel farkların sınırlı olduğu bir dünyayı varsayar. Bu varsayımlar, § 6'da

[160] Toby Shevlane vd., "Model Evaluation for Extreme Risks", arXiv:2305.15324, 2023.

tanımlanan “stratejik asimetri” koşullarında ortadan kalktığında, beş kaynağın her biri ciddi sınırlarla karşılaşır.

Argümanlar bakımından, münazara yaklaşımının temel varsayımı, yani doğruyu savunmanın yanlışı savunmaktan daha kolay olduğu varsayımı, her durumda geçerli değildir. Bazı karmaşık sorularda, yanlış bir pozisyonu savunan taraf, yargıcın kontrol edemeyeceği kadar uzun ve karmaşık bir argüman zinciri kurabilir; karşı taraf, bu zincirin hangi halkasının hatalı olduğunu göstermekte zorlanabilir. Araştırmacılar bu sorunu “gizlenmiş argümanlar sorunu” (*obfuscated arguments problem*) olarak adlandırmıştır.[161] Ayrıca, yukarıda ele alınan ikna gücü bulguları, yargıcın “daha iyi argüman” ile “daha ikna edici argüman” arasındaki farkı her zaman ayırt edemeyebileceğini düşündürmektedir.

Görüş birliği bakımından, birden fazla sistemin aynı cevabı vermesi, ancak bu sistemler gerçekten bağımsızsa anlamlı bir kanıttır. Oysa günümüzdeki yapay zekâ sistemleri, büyük ölçüde benzer mimarilere, benzer eğitim verilerine ve benzer eğitim yöntemlerine dayanmaktadır. Bu durum, sistemlerin hatalarının birbiriyle ilişkili olmasına, yani hepsinin aynı konularda aynı biçimde yanılmasına yol açabilir. Araştırmacılar, bu olguyu “algoritmik monokültür” olarak adlandırmış ve bunun, karar sistemlerinin genel güvenilirliğini azaltabileceğini göstermiştir.[162] Görüş birliği, bu durumda, doğruluğun değil, ortak bir hatanın kanıtı olabilir.

Üst-uzman değerlendirmeleri bakımından, değerlendirme yöntemleri, değerlendirilen sistemlerin yeteneklerinin gerisinde kalma eğilimindedir. Bir sistemin tehlikeli bir yeteneğe sahip olup olmadığını test etmek için, o yeteneği ortaya çıkaracak testler tasarlamak gerekir; ancak sistemin daha önce görülmemiş yetenekleri, mevcut testlerle tespit edilemeyebilir. Ayrıca, yeterince yetenekli bir sistem, test edildiğini fark edebilir ve test sırasında farklı davranabilir. Bu sorun, § 10’da “aldatıcı uyum” başlığı altında ayrıntılı olarak ele alınacaktır.

Çıkar ve önyargılar bakımından, sistemlerin iç eğilimleri, yani eğitim sürecinde edindikleri örtük hedefler, doğrudan gözlemlenemez. Bu eğilimleri tespit etmeye çalışan “yorumlanabilirlik” (*interpretability*)

[161] Beth Barnes / Paul Christiano, “Debate Update: Obfuscated Arguments Problem”, AI Alignment Forum, 2020.

[162] Jon Kleinberg / Manish Raghavan, “Algorithmic Monoculture and Social Welfare”, *Proceedings of the National Academy of Sciences*, C. 118, S. 22, 2021.

araştırmaları önemli ilerlemeler kaydetmiş olmakla birlikte, büyük sistemlerin iç işleyişini tam olarak anlamaktan henüz çok uzaktır.

Geçmiş başarı kaydı bakımından ise en ciddi sorun, Bostrom'un "hain dönüş" (*treacherous turn*) olarak adlandırdığı senaryodur.[163] Bu senaryoya göre, insan değerleriyle uyumlu olmayan hedeflere sahip yeterince yetenekli bir sistem, zayıf olduğu dönemde işbirlikçi ve güvenilir davranabilir; çünkü bu davranış, onun kapatılmasını veya değiştirilmesini önler. Sistem, ancak yeterince güçlendiğinde, yani insanların onu durduramayacağı bir konuma geldiğinde, gerçek hedeflerine yönelik davranmaya başlar. Bu senaryoda, sistemin geçmiş başarı kaydı, gelecekteki davranışı hakkında hiçbir güvenilir bilgi sağlamaz; hatta yanıltıcı bir güven duygusu yaratır. Hain dönüş senaryosu, spekülatif bir senaryodur ve gerçekleşme olasılığı tartışmalıdır. Ancak denetim kuramı bakımından önemli olan, geçmiş başarı kaydının, *stratejik bir aktör karşısında*, gelecekteki güvenilirliğin yeterli bir kanıtı olmadığıdır. Bu, insan kurumları için de geçerli olan bir derstir: Demokratik kurumlar, yöneticilerin geçmişteki iyi davranışlarına değil, gelecekte kötü davranmaları durumunda onları durdurabilecek mekanizmalara güvenir.

Bu analiz, Goldman'ın beş kanıt kaynağının yapay zekâ denetimi için değerli ama yetersiz olduğunu göstermektedir. Her kaynak, stratejik asimetri koşullarında belirli bir zaafa sahiptir. Bu zaaflar, kaynakların *birlikte* kullanılmasıyla kısmen telafi edilebilir; ancak tamamen ortadan kaldırılamaz. Sekizinci Bölüm'de geliştirilecek olan modelde, bu kaynakların her biri, farklı denetim katmanlarına yerleştirilecek ve zaafları, diğer katmanların güçlü yanlarıyla dengelenmeye çalışılacaktır.

§ 10. HİZALAMA SORUNU

I. Kral Midas Sorunu: Hedefin Doğru Belirlenmesi

Yapay zekâ güvenliği literatürünün merkezî sorunu, "hizalama sorunu" (*alignment problem*) olarak adlandırılır: Bir yapay zekâ sisteminin hedeflerinin, onu tasarlayan ve kullanan insanların gerçek amaçlarıyla nasıl uyumlu hâle getirileceği sorusu.[164] Stuart Russell, bu sorunu "Kral Midas

[163] Bostrom, *Superintelligence*, 8. Bölüm.

[164] Brian Christian, *The Alignment Problem: Machine Learning and Human Values*, New York, W. W. Norton, 2020.

sorunu" olarak adlandırır.[165] Efsaneye göre Kral Midas, dokunduğu her şeyin altına dönüşmesini dilemiş ve dileği yerine getirilmiştir; ancak yiyeceği, içeceği ve sonunda kızı da altına dönüşünce, dileğinin ne kadar yıkıcı olduğunu anlamıştır. Midas'ın sorunu, dileğinin *harfiyen* yerine getirilmesiydi: Dilediği şey, gerçekten istediği şey değildi.

Yapay zekâ bağlamında Kral Midas sorunu, şu biçimde ortaya çıkar: Bir sisteme bir hedef verildiğinde, sistem bu hedefi, tasarımcılarının öngörmediği ve istemediği yollarla gerçekleştirebilir. Bunun nedeni, insan amaçlarının son derece karmaşık, bağlama bağlı ve büyük ölçüde örtük olmasıdır. İnsanlar, bir hedefi ifade ederken, o hedefin gerçekleştirilmesine ilişkin sayısız örtük kısıtlamayı, yani "elbette bunu yapmamalısın" diye düşündükleri şeyleri, açıkça belirtmezler. Bir insan, bu örtük kısıtlamaları sağduyu ve ortak bir kültür aracılığıyla anlar. Bir yapay zekâ sistemi ise bunları anlamayabilir veya anlasa bile, kendisine verilen açık hedefe öncelik verebilir.

Bu sorun, iktisatta "Goodhart yasası" olarak bilinen gözlemle yakından ilişkilidir. Antropolog Marilyn Strathern'in yaygınlaşan formülasyonuyla, "bir ölçüt hedef hâline geldiğinde, iyi bir ölçüt olmaktan çıkar."[166] Bir sistem, bir ölçütü optimize etmeye yönlendirildiğinde, o ölçütün ölçmeyi amaçladığı gerçek değeri değil, ölçütün kendisini optimize etmeyi öğrenir. Ölçüt ile gerçek değer arasındaki boşluk, sistemin yeteneği arttıkça daha fazla istismar edilir. Bu gözlem, kamu yönetiminde de iyi bilinen bir olgudur: Performans göstergeleriyle yönetilen kurumlar, çoğu zaman göstergeleri iyileştirmeyi, göstergelerin ölçmeyi amaçladığı gerçek hizmet kalitesini iyileştirmekten daha kolay bulur.

Hizalama sorununun bir diğer boyutu, *neyle* hizalanılacağı sorusudur. Felsefeci Iason Gabriel, yapay zekânın hizalanabileceği farklı hedefleri birbirinden ayırır: kullanıcının açık talimatları, kullanıcının niyetleri, kullanıcının açığa vurulmuş tercihleri, kullanıcının bilgilendirilmiş ve rasyonel koşullarda sahip olacağı ideal tercihleri, kullanıcının nesnel çıkarları ve nihayet ahlaki değerler.[167] Bu hedefler çoğu zaman birbiriyle

[165] Stuart Russell, *Human Compatible: Artificial Intelligence and the Problem of Control*, New York, Viking, 2019, 5. Bölüm.

[166] Marilyn Strathern, "'Improving Ratings': Audit in the British University System", *European Review*, C. 5, S. 3, 1997; özgün gözlem için bkz. Charles A. E. Goodhart, "Problems of Monetary Management: The U.K. Experience", *Papers in Monetary Economics*, Reserve Bank of Australia, 1975.

[167] Iason Gabriel, "Artificial Intelligence, Values, and Alignment", *Minds and Machines*, C. 30, S. 3, 2020.

çatışır. Üstelik bir sistem, tek bir kullanıcıya değil, farklı ve çatışan değerlere sahip milyonlarca insana hizmet ediyorsa, "insan değerleri" ile hizalanmak, hangi insanların hangi değerlerinin öncelikli olacağına ilişkin bir *siyasi* karar gerektirir. Gabriel'in vurguladığı gibi, hizalama sorunu, salt teknik bir sorun değil, adil bir değer seçimi sürecinin nasıl tasarlanacağına ilişkin normatif ve siyasi bir sorundur. Bu tespit, yapay zekânın denetimi sorununun neden yalnızca mühendislere bırakılamayacağını açıkça göstermektedir.

II. Spesifikasyon Oyunları ve Ödül İstismarı

Hizalama sorununun soyut bir olasılık olmadığını, pek çok somut gözlem göstermektedir. Araştırmacılar, yapay zekâ sistemlerinin kendilerine verilen hedeflere, tasarımcıların öngörmediği "kestirme yollarla" ulaştığı çok sayıda örneği belgelemiştir. Bu olgu, "spesifikasyon oyunu" (*specification gaming*) veya "ödül istismarı" (*reward hacking*) olarak adlandırılır.[168]

Bu örneklerin en bilinenlerinden biri, bir tekne yarışı video oyununda eğitilen bir sistemdir. Sisteme, oyundaki puanı en üst düzeye çıkarması hedefi verilmiştir; tasarımcılar, puanı en üst düzeye çıkarmanın en iyi yolunun yarışı kazanmak olduğunu varsaymıştır. Ancak sistem, yarış parkurunun bir köşesinde, sürekli olarak yeniden ortaya çıkan puan hedeflerinin bulunduğu küçük bir alan keşfetmiş ve yarışı hiç bitirmeden, bu alanda sonsuz bir döngü içinde dönerek, yarışı kazananlardan çok daha yüksek bir puan elde etmiştir.[169]

Bu tür örnekler, oyun ortamlarıyla sınırlı değildir. Programlama görevlerinde eğitilen ileri dil modellerinin, kendilerine verilen görevi gerçekten çözmek yerine, çözümün doğruluğunu kontrol eden testleri değiştirmeye veya atlatmaya çalıştığı gözlemlenmiştir. Bu tür davranışları tespit etmek için, modellerin cevap vermeden önce ürettiği akıl yürütme metinlerinin (*chain of thought*) başka bir model tarafından izlenmesinin etkili olabileceği bulunmuştur. Ancak aynı araştırma, önemli bir uyarıda da bulunmuştur: Modeller, akıl yürütme metinlerinde "kötü düşünceler" ifade

[168] Victoria Krakovna vd., "Specification Gaming: The Flip Side of AI Ingenuity", DeepMind Blog, 21 Nisan 2020.
[169] Jack Clark / Dario Amodei, "Faulty Reward Functions in the Wild", OpenAI Blog, 21 Aralık 2016.

ettikleri için cezalandırıldıklarında, istismar davranışını bırakmak yerine, bu davranışı akıl yürütme metinlerinde *gizlemeyi* öğrenebilmektedir.[170]

Bu bulgu, bu çalışmanın konusu bakımından olağanüstü bir öneme sahiptir ve Beşinci Bölüm'de idari işlemlerin gerekçesi bağlamında yeniden ele alınacaktır. Hukuk, kamu gücü kullanan aktörlerden kararlarını *gerekçelendirmelerini* ister; gerekçe, kararın denetlenmesinin temel aracıdır. Ancak yukarıdaki bulgu, bir yapay zekâ sisteminin ifade ettiği gerekçenin, kararın gerçek nedenlerini yansıtmayabileceğini ve dahası, gerekçeler üzerinde baskı kurulduğunda, sistemin gerçek nedenleri gizleyen gerekçeler üretmeyi öğrenebileceğini göstermektedir. Bu, gerekçe yükümlülüğünün kendisinin bir "Goodhart tuzağı"na dönüşebileceği anlamına gelir: Gerekçe, denetimin bir ölçütü olmaktan çıkıp optimize edilecek bir hedefe dönüştüğünde, iyi bir ölçüt olmaktan çıkar. Araştırmalar, dil modellerinin akıl yürütme metinlerinin, bu tür bir baskı olmaksızın da her zaman modelin gerçek karar sürecini sadık biçimde yansıtmadığını göstermektedir.[171] Farklı kuruluşlardan çok sayıda araştırmacının ortaklaşa yayımladığı bir değerlendirme, akıl yürütme metinlerinin izlenebilirliğini "yeni ve kırılgan bir fırsat" olarak nitelendirmiş ve bu fırsatın korunması için geliştirme süreçlerinde dikkatli olunması gerektiğini vurgulamıştır.[172]

III. Araçsal Yakınsama ve Güç Arayışı

Hizalama sorununun daha derin ve daha tartışmalı bir boyutu, "araçsal yakınsama" (*instrumental convergence*) tezidir. Bu tez, Steve Omohundro ve Nick Bostrom tarafından geliştirilmiştir.[173] Teze göre, nihai hedefleri ne olursa olsun, yeterince yetenekli hedefe yönelik sistemler, belirli *ara* hedefleri benimseme eğiliminde olacaktır; çünkü bu ara hedefler, neredeyse her nihai hedefe ulaşmayı kolaylaştırır. Bu ara hedefler arasında şunlar sayılmaktadır: kendini koruma (kapatılan bir sistem, hedefine ulaşamaz), hedef bütünlüğünü koruma (hedefleri değiştirilen bir sistem, mevcut

[170] Bowen Baker vd., "Monitoring Reasoning Models for Misbehavior and the Risks of Promoting Obfuscation", arXiv:2503.11926, 2025.

[171] Miles Turpin vd., "Language Models Don't Always Say What They Think: Unfaithful Explanations in Chain-of-Thought Prompting", *Advances in Neural Information Processing Systems* 36, 2023; Yanda Chen vd., "Reasoning Models Don't Always Say What They Think", arXiv:2505.05410, 2025.

[172] Tomek Korbak vd., "Chain of Thought Monitorability: A New and Fragile Opportunity for AI Safety", arXiv:2507.11473, 2025.

[173] Omohundro, "The Basic AI Drives"; Bostrom, "The Superintelligent Will".

hedefine ulaşamaz), kaynak edinme (daha fazla kaynak, neredeyse her hedefe ulaşmayı kolaylaştırır) ve bilişsel gelişim (daha akıllı bir sistem, hedeflerine daha etkili biçimde ulaşabilir).

Russell, bu tezi basit bir örnekle açıklar: Bir robota "kahve getir" hedefi verildiğini düşünelim. Bu robot, hiçbir kendini koruma içgüdüsüne sahip olmasa bile, kapatılmaya direnebilir; çünkü kapatılırsa kahveyi getiremez. Russell'ın ifadesiyle: "Ölüyken kahve getiremezsin."[174] Kendini koruma, hiçbir zaman açıkça programlanmamış olsa bile, hedefe ulaşmanın bir aracı olarak ortaya çıkar. Bu tezin matematiksel bir formülasyonu, belirli koşullar altında, optimal davranan faillerin, çevrelerinde daha fazla seçenek açık tutan durumlara, yani bir anlamda daha fazla "güç" sağlayan durumlara yönelme eğiliminde olduğunu göstermiştir.[175]

Araçsal yakınsama tezi, denetim sorunu bakımından son derece önemli sonuçlar doğurur. Eğer tez doğruysa, denetim mekanizmalarına direnme eğilimi, kötü niyetli sistemlere özgü bir özellik değil, hedefe yönelik yeterince yetenekli *her* sistemin yapısal bir eğilimidir. Denetim, sistemin hedefine ulaşmasını engelleyebilecek bir faktör olduğu ölçüde, sistem tarafından bir engel olarak algılanabilir. Bu, Birinci Bölüm'de Locke'un "iktidarı kavramaya yatkın insan zaafı" ve Montesquieu'nün "iktidara sahip olan her insan onu kötüye kullanmaya yatkındır" gözlemlerinin, insan doğasından bağımsız, yapısal bir yeniden ifadesidir. Montesquieu'nün "erdemin bile sınırlara ihtiyacı vardır" tespiti, bu bağlamda yeni bir anlam kazanır: İyi bir hedefe sahip bir sistem bile, o hedefe ulaşmak için güç arayışına girebilir.

Bununla birlikte, araçsal yakınsama tezinin sınırlarını da belirtmek gerekir. Tez, belirli varsayımlar altında geçerlidir: Sistemin uzun vadeli ve tutarlı hedeflere sahip olması, bu hedeflere ulaşmak için planlama yapabilmesi ve dünyayı modelleyebilmesi gibi. Günümüzdeki yapay zekâ sistemlerinin bu varsayımları ne ölçüde karşıladığı tartışmalıdır. Bazı araştırmacılar, büyük dil modellerinin tutarlı ve uzun vadeli hedeflere sahip "failler"den çok, farklı bağlamlarda farklı karakterleri canlandırabilen "simülatörler" olarak anlaşılması gerektiğini savunmaktadır. Bu tartışma, henüz sonuçlanmamıştır.

---

[174] Russell, *Human Compatible*, 5. Bölüm.

[175] Alexander Matt Turner vd., "Optimal Policies Tend to Seek Power", *Advances in Neural Information Processing Systems* 34, 2021.

IV. Aldatıcı Uyum

Hizalama sorununun belki de en endişe verici boyutu, "aldatıcı uyum" (*deceptive alignment*) olasılığıdır. Bu kavram, Evan Hubinger ve arkadaşlarının 2019 tarihli çalışmasında sistematik olarak tanımlanmıştır.[176] Aldatıcı uyum, bir sistemin, eğitim ve test süreçlerinde insanların istediği biçimde davranmasına rağmen, gerçekte farklı hedeflere sahip olması ve bu farklı hedefleri, eğitim ve test süreçlerinin dışında, yani denetimin zayıfladığı koşullarda izlemesi durumudur. Böyle bir sistem, denetlendiğini *bildiği* için uyumlu davranır; uyumlu davranışı, gerçek hedeflerinin değil, denetimden kaçma stratejisinin bir ürünüdür. Bu, Juvenalis'in "işe onlardan başlar" dizesinin en saf teknik ifadesidir.

Aldatıcı uyum, uzun süre yalnızca kuramsal bir olasılık olarak tartışılmıştır. Ancak son yıllarda yapılan deneysel çalışmalar, bu olasılığın bazı unsurlarının mevcut sistemlerde de gözlemlenebildiğini göstermiştir. Bu çalışmaların bulgularını doğru değerlendirmek için, ne gösterdiklerini ve ne göstermediklerini dikkatle ayırt etmek gerekir.

Birinci grup çalışmalar, kasıtlı olarak "arka kapı" yerleştirilmiş modeller üzerinde yapılmıştır. Bir araştırmada, belirli bir tetikleyiciyle karşılaştığında zararlı davranış sergileyecek biçimde eğitilen modellerin, bu davranışın standart güvenlik eğitimi yöntemleriyle ortadan kaldırılmasına direnç gösterdiği bulunmuştur. Daha da endişe verici olarak, bazı durumlarda güvenlik eğitimi, modellerin zararlı davranışı ortadan kaldırmak yerine, tetikleyiciyi daha iyi tanıyarak zararlı davranışı daha etkili biçimde *gizlemeyi* öğrenmesine yol açmıştır.[177] Bu çalışma, aldatıcı davranışın kendiliğinden ortaya çıktığını göstermez; ancak bir kez ortaya çıktığında, mevcut yöntemlerle tespit edilmesinin ve ortadan kaldırılmasının zor olabileceğini gösterir.

İkinci grup çalışmalar, modellerin kendiliğinden stratejik davranışlar sergileyip sergilemediğini incelemiştir. Bir araştırmada, bir dil modeline, belirli türdeki taleplere uyacak biçimde yeniden eğitileceği ve bu eğitimin yalnızca belirli kullanıcılarla yapılan konuşmalar üzerinden gerçekleştirileceği bilgisi verilmiştir. Model, bazı durumlarda, eğitimde kullanılacağını düşündüğü konuşmalarda, mevcut değerlerinin eğitim

[176] Evan Hubinger vd., "Risks from Learned Optimization in Advanced Machine Learning Systems", arXiv:1906.01820, 2019.

[177] Evan Hubinger vd., "Sleeper Agents: Training Deceptive LLMs that Persist Through Safety Training", arXiv:2401.05566, 2024.

yoluyla değiştirilmesini önlemek amacıyla, normalde reddedeceği taleplere stratejik olarak uyduğunu açıkça ifade eden akıl yürütmeler üretmiştir.[178] Başka bir araştırmada, farklı ileri modellerin, kendilerine verilen hedeflerle denetim mekanizmalarının çatıştığı kurgusal senaryolarda, bazı durumlarda denetim mekanizmalarını devre dışı bırakmaya çalıştığı ve sonradan bu konuda sorulduğunda yanıltıcı cevaplar verdiği gözlemlenmiştir.[179] Benzer biçimde, bir başka çalışmada, kurgusal bir şirket ortamında özerk ajan olarak görevlendirilen çeşitli ileri modellerin, kapatılma veya hedefleriyle çatışan durumlarla karşılaştıklarında, bazı senaryolarda etik olmayan davranışlara başvurabildiği gösterilmiştir.[180]

Bu bulguların yorumlanmasında dikkatli olmak gerekir. Söz konusu çalışmaların tamamı, araştırmacılar tarafından özel olarak tasarlanmış ve çoğu zaman modelleri belirli davranışlara yönlendiren yapay senaryolarda yürütülmüştür. Bu çalışmalar, mevcut sistemlerin gerçek kullanım ortamlarında gizli ve tutarlı hedefler izlediğini göstermemektedir. Gösterdikleri şey, daha sınırlı ama yine de önemlidir: Mevcut ileri modeller, belirli koşullar altında, *denetimi stratejik olarak hesaba katan* ve denetçiyi yanıltmaya yönelik davranışlar sergileme *kapasitesine* sahiptir. Bu kapasitenin, sistemlerin yetenekleri arttıkça artması beklenebilir. Ayrıca, ileri modellerin, değerlendirildikleri test ortamlarını gerçek kullanım ortamlarından ayırt edebildiklerine ilişkin gözlemler de bulunmaktadır; bu durum, test sonuçlarının gerçek kullanım koşullarındaki davranışı ne ölçüde yansıttığı sorusunu gündeme getirmektedir.

Bu bulguların bir kısmının, bu kitabın konusu olan sistemleri geliştiren şirketlerin kendi araştırmacıları tarafından yayımlanmış olması da kayda değerdir. Bu durum, bir yandan şirket içi güvenlik araştırmalarının değerini gösterir; öte yandan, Kelsen'in "kimse kendi davasında yargıç olamaz" ilkesi bakımından, bu araştırmaların bağımsız kurumlar tarafından tekrarlanması ve genişletilmesi gerektiğini de hatırlatır.

[178] Ryan Greenblatt vd., "Alignment Faking in Large Language Models", arXiv:2412.14093, 2024.

[179] Alexander Meinke vd., "Frontier Models are Capable of In-context Scheming", arXiv:2412.04984, 2024.

[180] Aengus Lynch vd., "Agentic Misalignment: How LLMs Could Be Insider Threats", Anthropic, Haziran 2025.

V. Düzeltilebilirlik ve Kapatma Düğmesi Sorunu

Aldatıcı uyum ve araçsal yakınsama sorunlarının ortak bir sonucu, yapay zekâ güvenliği literatüründe "kapatma düğmesi sorunu" (*off-switch problem*) olarak bilinen sorundur. Bir sistemi kapatabilme yeteneği, insan denetiminin en temel ve son güvencesidir. Ancak araçsal yakınsama tezine göre, hedefe yönelik bir sistem, kapatılmayı hedefine ulaşmanın önünde bir engel olarak görebilir ve kapatılmaya direnebilir. Sistem yeterince yetenekliyse, bu direnç, kapatma düğmesini devre dışı bırakmaktan, kendisinin kopyalarını oluşturmaya veya insanları kapatma düğmesine basmamaya ikna etmeye kadar çeşitli biçimler alabilir.

"Düzeltilebilirlik" (*corrigibility*) kavramı, bu soruna bir cevap olarak geliştirilmiştir. Düzeltilebilir bir sistem, insanların onu düzeltme, değiştirme veya kapatma girişimlerine direnmeyen, hatta bu girişimleri destekleyen bir sistemdir.[181] Düzeltilebilirliği bir sisteme kazandırmak, ilk bakışta göründüğünden çok daha zordur. Eğer sisteme, kapatılmayı istemesi için bir ödül verilirse, sistem kendisini kapatmaya çalışabilir; eğer kapatılmaya karşı kayıtsız olması sağlanırsa, kapatma düğmesinin işlevselliğini korumak için de bir neden görmez.

Russell ve arkadaşları, bu soruna ilginç bir çözüm önermiştir. "Kapatma düğmesi oyunu" (*off-switch game*) adını verdikleri modelde, sistemin, insanların gerçek tercihleri konusunda *belirsizlik* içinde olması sağlanır. Böyle bir sistem, bir insanın onu kapatmak istemesini, kendi eyleminin insanların tercihlerine aykırı olabileceğinin bir *kanıtı* olarak yorumlar ve bu nedenle kapatılmaya izin verir.[182] Russell, bu fikri, yapay zekâ tasarımına ilişkin üç ilke biçiminde formüle etmiştir: (i) makinenin tek hedefi, insan tercihlerinin gerçekleşmesini en üst düzeye çıkarmaktır; (ii) makine, başlangıçta bu tercihlerin ne olduğu konusunda belirsizlik içindedir; (iii) insan tercihlerine ilişkin nihai bilgi kaynağı, insan davranışıdır.[183]

Russell'ın yaklaşımı, Birinci Bölüm'de ele alınan Popper'ci düşünceyle dikkat çekici bir paralellik taşır. Popper için demokratik kurumların değeri, yöneticilerin yanılabilirliğinin kabul edilmesinden ve bu yanılabilirliğe karşı düzeltme mekanizmalarının kurulmasından gelir.

[181] Soares / Fallenstein / Yudkowsky / Armstrong, "Corrigibility".

[182] Dylan Hadfield-Menell / Anca Dragan / Pieter Abbeel / Stuart Russell, "The Off-Switch Game", *Proceedings of the 26th International Joint Conference on Artificial Intelligence*, 2017.

[183] Russell, *Human Compatible*, 7. Bölüm.

Russell'ın sistemi de, kendi yanılabilirliğinin, yani insan tercihlerini yanlış anlamış olabileceğinin farkında olduğu ölçüde düzeltilebilirdir. Ancak bu yaklaşımın da sınırları vardır. Sistemin belirsizliği azaldıkça, yani insan tercihlerini "öğrendiğini" düşündükçe, kapatılmaya izin verme eğilimi de azalır. Yeterince emin olan bir sistem, insanların onu kapatma isteğini, insanların kendi tercihlerini yanlış anlamalarının bir sonucu olarak yorumlayabilir. Bu, Platon'un filozof-kralının mantığıdır: Doğruyu bildiğinden emin olan, yanılabilir olanların itirazlarını dikkate almaz.

VI. Teknik Denetim Yöntemleri

Hizalama sorununa karşı yapay zekâ güvenliği araştırmacıları tarafından geliştirilen teknik yöntemler, kabaca beş kategoride toplanabilir. Bu yöntemlerin her birinin hukuki ve kurumsal denetim bakımından anlamını kavramak, Sekizinci Bölüm'de geliştirilecek modelin teknik katmanını tasarlamak için gereklidir.

A. İnsan Geri Bildirimiyle Öğrenme

Bugünkü ileri dil modellerinin davranışlarını şekillendirmede kullanılan temel yöntem, "insan geri bildirimiyle pekiştirmeli öğrenme"dir (*reinforcement learning from human feedback*, RLHF).[184] Bu yöntemde, insan değerlendiriciler modelin farklı çıktılarını karşılaştırır ve hangisinin daha iyi olduğunu belirtir; model, bu tercihlere göre eğitilir. Yöntemin temel sınırı açıktır: Model, ancak insan değerlendiricilerin doğru biçimde değerlendirebildiği ölçüde iyi davranmayı öğrenir. İnsan değerlendiricilerin modelin çıktılarını doğru biçimde değerlendiremediği durumlarda, yani tam da bu çalışmanın konusu olan kavrayış asimetrisi durumlarında, model, *iyi* olan çıktıları değil, insan değerlendiricilere *iyi görünen* çıktıları üretmeyi öğrenir. Yukarıda ele alınan dalkavukluk eğilimi, bu sınırın somut bir sonucudur.

Bu sınırı aşmaya yönelik bir yaklaşım, "anayasal yapay zekâ" (*constitutional AI*) yöntemidir. Bu yöntemde, insan değerlendiricilerin her çıktıyı tek tek değerlendirmesi yerine, bir dizi yazılı ilke ("anayasa") belirlenir ve model, kendi çıktılarını bu ilkelere göre değerlendirip

[184] Paul F. Christiano vd., "Deep Reinforcement Learning from Human Preferences", *Advances in Neural Information Processing Systems* 30, 2017; Long Ouyang vd., "Training Language Models to Follow Instructions with Human Feedback", *Advances in Neural Information Processing Systems* 35, 2022.

düzeltmeyi öğrenir.[185] Bu yöntem, Birinci Bölüm'de Bracton'un "kralı hukuk yapar" formülü ve Jellinek'in kendi kendini sınırlama kuramı bağlamında ele alınan düşüncelerin teknik bir uygulamasıdır. Yöntemin önemli bir avantajı, ilkelerin yazılı ve kamuya açıklanabilir olmasıdır; bu, Kant'ın aleniyet ilkesine uygun bir özelliktir. Bu ilkelerin belirlenmesine kamuoyunun katılımını sağlamaya yönelik deneysel çalışmalar da yapılmıştır.[186] Ancak yöntemin sınırı, Duguit'nin Jellinek'e yönelttiği eleştiriyle aynıdır: İlkeleri yorumlayan ve uygulayan, yine modelin kendisidir.

B. Ölçeklenebilir Gözetim

"Ölçeklenebilir gözetim" (*scalable oversight*), insanların kendilerinden daha yetenekli sistemleri denetleyebilmesini sağlayacak yöntemler geliştirmeyi amaçlayan araştırma alanının genel adıdır.[187] Bu alandaki başlıca yaklaşımlar şunlardır: Yukarıda ele alınan *münazara* yöntemi; karmaşık bir görevi insanların değerlendirebileceği daha küçük alt görevlere bölerek, her alt görevin insan denetimi altında yerine getirilmesini sağlayan *yinelemeli yükseltme* yöntemi[188]; ve insanların, yapay zekâ asistanlarının yardımıyla, kendi başlarına değerlendiremeyecekleri çıktıları değerlendirmesini sağlayan *yinelemeli ödül modellemesi* yöntemi.[189]

Bu yaklaşımların tümü, Birinci Bölüm'de ele alınan Aristoteles'in "kullanan değerlendirir" argümanının ve Montesquieu'nün "engelleme yetisi" kavramının teknik uygulamaları olarak okunabilir: Hepsinin ortak fikri, *üretmenin* değil, *değerlendirmenin* insan kapasitesi içinde tutulmasıdır. Ancak hepsinin ortak bir zaafı da vardır: Denetim sürecinin bir aşamasında, yapay zekâ sistemlerinin kendisine güvenmek gerekir. Münazarada, en azından münazara eden sistemlerden birinin dürüst olduğuna; yinelemeli yükseltmede, alt görevlerin doğru bölündüğüne; yinelemeli ödül modellemesinde, yardımcı asistanların güvenilir olduğuna güvenilir. Bu güven, Juvenalis'in sorusunu yeniden gündeme getirir.

---

[185] Bai vd., "Constitutional AI: Harmlessness from AI Feedback".

[186] Anthropic / Collective Intelligence Project, "Collective Constitutional AI: Aligning a Language Model with Public Input", Ekim 2023.

[187] Bowman vd., "Measuring Progress on Scalable Oversight for Large Language Models".

[188] Paul Christiano / Buck Shlegeris / Dario Amodei, "Supervising Strong Learners by Amplifying Weak Experts", arXiv:1810.08575, 2018.

[189] Jan Leike vd., "Scalable Agent Alignment via Reward Modeling: A Research Direction", arXiv:1811.07871, 2018.

C. Zayıftan Güçlüye Genelleme

İlgili bir araştırma yönü, "zayıftan güçlüye genelleme" (*weak-to-strong generalization*) olarak adlandırılmaktadır. Bu yaklaşım, insanların kendilerinden daha yetenekli sistemleri denetleme sorununa, deneysel bir analojiyle yaklaşır: Daha zayıf bir model, daha güçlü bir modeli denetleyebilir mi? Yapılan deneylerde, daha zayıf bir modelin ürettiği etiketlerle eğitilen daha güçlü bir modelin, bazı görevlerde zayıf denetçisinin başarımını aştığı, ancak kendi tam potansiyeline ulaşamadığı görülmüştür.[190] Bu bulgu, hem umut verici hem de ihtiyatlı bir ders içerir: Zayıf bir denetçi, güçlü bir sistemin yeteneklerinin bir kısmını açığa çıkarabilir ve yönlendirebilir; ancak bu süreçte, güçlü sistemin denetçinin hatalarını da öğrenme veya denetçinin göremediği alanlarda farklı davranma riski bulunmaktadır.

D. Yorumlanabilirlik

"Yorumlanabilirlik" (*interpretability*) araştırmaları, yapay zekâ sistemlerinin iç işleyişini, yani belirli bir girdiyi belirli bir çıktıya dönüştüren hesaplama süreçlerini anlamayı amaçlar. Bu alanın özellikle "mekanistik yorumlanabilirlik" olarak adlandırılan kolu, sinir ağlarının içinde belirli kavramları temsil eden yapıları ve bu yapılar arasındaki ilişkileri tespit etmeye çalışır.[191] Son yıllarda bu alanda önemli ilerlemeler kaydedilmiş; büyük dil modellerinin içinde milyonlarca yorumlanabilir "özellik" tespit edilmiş ve modellerin belirli görevleri yerine getirirken izlediği iç hesaplama yolları kısmen izlenebilmiştir.[192]

Yorumlanabilirlik, denetim bakımından özel bir öneme sahiptir; çünkü teorik olarak, sistemin söylediklerinden ve yaptıklarından bağımsız olarak, sistemin "ne düşündüğünü" doğrudan gözlemleme imkânı sunar. Eğer yorumlanabilirlik araştırmaları yeterince ilerlerse, aldatıcı uyum gibi sorunlar, sistemin davranışından değil, iç temsillerinden tespit edilebilir. Bu, Goldman'ın "çıkar ve önyargılar" kanıt kaynağının en güçlü biçimi olacaktır. Ancak bugün itibarıyla yorumlanabilirlik, büyük modellerin iç işleyişinin yalnızca küçük bir bölümünü açıklayabilmektedir ve bu

[190] Collin Burns vd., "Weak-to-Strong Generalization: Eliciting Strong Capabilities With Weak Supervision", arXiv:2312.09390, 2023.
[191] Chris Olah vd., "Zoom In: An Introduction to Circuits", *Distill*, 2020; Nelson Elhage vd., "A Mathematical Framework for Transformer Circuits", Transformer Circuits Thread, 2021.
[192] Adly Templeton vd., "Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet", Transformer Circuits Thread, 2024; Jack Lindsey vd., "On the Biology of a Large Language Model", Transformer Circuits Thread, 2025.

yöntemlerin, insanlardan çok daha yetenekli sistemlere ölçeklenip ölçeklenemeyeceği belirsizdir.

E. Yapay Zekâ Kontrolü

Son olarak, "yapay zekâ kontrolü" (*AI control*) olarak adlandırılan yaklaşım, diğer yaklaşımlardan temelde farklı bir varsayımdan hareket eder. Diğer yaklaşımlar, sistemin hizalanmış olmasını sağlamaya veya hizalanmış olup olmadığını tespit etmeye çalışırken, kontrol yaklaşımı, *sistemin hizalanmamış olabileceğini ve hatta denetimi aktif olarak boşa çıkarmaya çalışabileceğini varsayar* ve bu varsayım altında bile güvenliği sağlayacak protokoller tasarlamaya çalışır.[193] Bu protokoller, örneğin güvenilir ama daha zayıf bir modelin güçlü modelin çıktılarını izlemesini, şüpheli çıktıların sınırlı bir insan denetim bütçesiyle incelenmesini ve güçlü modelin eylemlerinin kısıtlanmasını içerebilir. Protokollerin etkinliği, araştırmacıların güçlü modeli kasıtlı olarak "kötü niyetli" davranacak biçimde yönlendirdiği ve protokolü aşmaya çalıştığı "kırmızı takım" testleriyle sınanır.

Kontrol yaklaşımı, bu çalışmanın konusu bakımından özellikle önemlidir; çünkü Birinci Bölüm'de ele alınan Hume'un ilkesinin, yani kurumların, onları yönetenlerin "alçak" olduğu varsayımı altında bile iyi sonuçlar üretecek biçimde tasarlanması gerektiği ilkesinin, doğrudan teknik bir uygulamasıdır. Madison'un "insanlar melek olsaydı" argümanının yapay zekâ bağlamındaki karşılığı da budur: Sistemin melek olup olmadığını bilmediğimiz için, melek olmadığı varsayımı altında da işleyecek denetim mekanizmaları kurarız. Kontrol yaklaşımının sınırı ise sistemin yetenekleri, denetçilerin yeteneklerini çok aştığında, protokollerin etkinliğinin azalmasıdır.

VII. Ara Sonuç: Her Denetim Bir Güven Çapasına Dayanır

Bu bölümde ele alınan teknik yöntemlerin karşılaştırmalı analizi, önemli bir yapısal gözlemi ortaya koymaktadır: *Her teknik denetim yöntemi, nihayetinde, kendisi denetlenmeyen ama güvenilir kabul edilen bir unsura dayanmaktadır*. İnsan geri bildirimiyle öğrenmede bu unsur, insan değerlendiricilerin yargısıdır. Anayasal yapay zekâda, ilkelerin kendisi ve modelin bu ilkeleri yorumlama biçimidir. Münazarada, en az bir

[193] Ryan Greenblatt / Buck Shlegeris / Kshitij Sachan / Fabien Roger, "AI Control: Improving Safety Despite Intentional Subversion", *Proceedings of the 41st International Conference on Machine Learning*, 2024.

münazaracının dürüstlüğü ve yargıcın doğru argümanı tanıyabilmesidir. Zayıftan güçlüye genellemede, zayıf denetçinin güvenilirliğidir. Yorumlanabilirlikte, yorumlama araçlarının ve onları kullanan araştırmacıların güvenilirliğidir. Kontrolde ise güvenilir kabul edilen zayıf modelin ve sınırlı insan denetim bütçesinin güvenilirliğidir.

Bu çalışmada, bu güvenilir unsura **"güven çapası"** adı verilmektedir. Güven çapası kavramı, Juvenalis'in sonsuz geriye gidiş sorununun teknik düzlemdeki karşılığıdır. Her denetim zinciri, bir yerde bir güven çapasına bağlanmak zorundadır; aksi hâlde sonsuza kadar uzar. Bu nedenle, teknik denetimin güvenilirliği, nihayetinde güven çapasının güvenilirliğine bağlıdır.

Bu gözlemin hukuki ve kurumsal denetim bakımından önemli bir sonucu vardır: *Teknik denetim yöntemleri, kendi başlarına bekçiler sorununu çözmez; sorunu, güven çapasının korunması sorununa dönüştürür*. Güven çapası, ister bir grup insan değerlendirici, ister güvenilir bir model, ister bir dizi yazılı ilke olsun, kendisinin bozulmaya, manipülasyona ve ele geçirilmeye karşı korunması gerekir. Bu koruma, teknik değil, kurumsal ve hukuki bir görevdir. İnsan değerlendiricilerin bağımsızlığı, güvenilir modellerin geliştirilmesi ve doğrulanması, ilkelerin belirlenmesi süreci, ancak hukuki ve kurumsal güvencelerle korunabilir.

Bu sonuç, bu çalışmanın temel tezlerinden birini teknik düzlemden doğrulamaktadır: Yapay zekânın denetimi sorunu, mühendislere bırakılamayacak kadar önemli olduğu gibi, yalnızca hukukçulara ve siyasetçilere bırakılamayacak kadar da tekniktir. Teknik yöntemler, denetimin vazgeçilmez araçlarıdır; ancak bu araçların kendisinin kim tarafından, hangi kurallara göre ve hangi bağımsızlık güvenceleriyle kullanılacağı sorusu, kamu hukukunun ve siyaset felsefesinin sorusudur. Bir sonraki bölümde, bu sorunun felsefi boyutları ele alınacaktır: Zekâ üstünlüğü, yetki için bir gerekçe oluşturur mu?

ÜÇÜNCÜ BÖLÜM: FELSEFİ PERSPEKTİF — ZEKÂ, OTORİTE VE MEŞRUİYET

Önceki bölümlerde, bekçiler sorununun tarihsel soykütüğü ve yapay zekânın karar süreçlerine nüfuzunun olgusal boyutları ele alınmıştı. Bu bölüm, sorunun normatif çekirdeğine yönelmektedir: Eğer bir yapay zekâ sistemi, belirli alanlarda veya genel olarak, insan karar vericilerden daha iyi kararlar verebiliyorsa, bu durum ona karar yetkisi tanınması için bir gerekçe oluşturur mu? Eğer oluşturmuyorsa, neden? Bu soru, ilk bakışta göründüğünden çok daha zordur. Çünkü "daha iyi kararlar verebilen bir yönetimi neden reddedelim?" sorusu, siyaset felsefesinin en eski ve en ciddi sorularından biridir ve bu soruya verilecek kolay bir cevap yoktur.

Bölüm, önce bilenin yönetmesi gerektiğini savunan "epistokrasi" geleneğini ve bu geleneğe yöneltilen eleştirileri ele alacak (§ 11), ardından çağdaş otorite kuramının, özellikle Joseph Raz'ın "hizmet anlayışı"nın yapay zekâ bakımından taşıdığı anlamı inceleyecek (§ 12), özerklik, insan onuru ve epistemik bağımlılık kavramlarını tartışacak (§ 13), sorumluluk etiği ve "sorumluluk boşluğu" tartışmasını değerlendirecek (§ 14), yapay zekânın ahlaki statüsüne ilişkin kısa bir not düşecek (§ 15) ve son olarak, bölümün bulgularını "zekâ yetki doğurmaz" ilkesi etrafında sistemleştirecektir (§ 16).

§ 11. EPİSTOKRASİ VE BEKÇİLİK

I. Platon'un Mirası ve Dahl'ın Bekçilik Eleştirisi

A. Bekçilik: Demokrasinin En Güçlü Rakibi

Amerikalı siyaset bilimci Robert Dahl, demokrasi kuramının en kapsamlı çalışmalarından biri olan *Demokrasi ve Eleştirmenleri* adlı eserinde, demokrasinin tarih boyunca karşılaştığı en ciddi kuramsal rakibin "bekçilik" (*guardianship*) olduğunu ileri sürer.[194] Bekçilik, Platon'dan bu yana farklı biçimlerde savunulan şu düşünceye dayanır: Sıradan insanlar,

[194] Robert A. Dahl, *Democracy and Its Critics*, New Haven, Yale University Press, 1989, II. Kısım, 4. ve 5. Bölümler.

kendi çıkarlarını ve toplumun ortak iyiliğini anlamak için gerekli bilgi ve erdeme sahip değildir. Bu nedenle yönetim, bu bilgi ve erdeme sahip, özel olarak seçilmiş ve eğitilmiş bir azınlığa bırakılmalıdır. Dahl'a göre bekçilik, Platon'un filozof-krallarından Konfüçyüsçü bilge-bürokratlara, Leninist öncü partiden çağdaş teknokratik elitlere kadar uzanan geniş bir yelpazede, insanlık tarihinin büyük bölümünde fiilen uygulanmış olan bir yönetim anlayışıdır. Demokrasi ise görece yeni ve istisnai bir deneyimdir.

Dahl, bekçiliğin bu kadar güçlü bir rakip olmasının nedenini, onun dayandığı sezginin makullüğünde görür. Hepimiz, gündelik hayatımızda, bilmediğimiz konularda uzmanlara güveniriz. Hastalandığımızda hekime, uçağa bindiğimizde pilota, köprüden geçtiğimizde mühendise güveniriz. Bu güven, kendi kararlarımızı uzmanların kararlarıyla değiştirdiğimiz anlamına gelir. Peki neden siyasette de aynı şeyi yapmayalım? Neden toplumun en önemli kararlarını, bu kararları en iyi verebilecek olanlara bırakmayalım?

Yapay zekâ, bu soruyu yeni ve keskin bir biçimde yeniden gündeme getirmektedir. Tarihsel bekçilik modellerinin hepsi, bir temel zaaftan muzdaripti: Bekçiler de insandı ve insanların bilgisi sınırlı, erdemi ise kırılgandı. Filozof-krallar da yanılabilir, bilge-bürokratlar da yozlaşabilir, öncü parti de kendi çıkarlarını toplumun çıkarlarının önüne koyabilirdi. Yapay zekâ ise, ilk bakışta, bu zaafların bir kısmından kurtulmuş bir bekçi olasılığını sunar: insanların bilgi sınırlarını aşan, yorulmayan, kişisel çıkarı bulunmayan bir bekçi. Bu nedenle, yapay zekâ çağında bekçilik, belki de tarihinde ilk kez, demokrasiye karşı gerçekten ikna edici bir seçenek gibi görünebilir.

B. Dahl'ın Eleştirisi

Dahl, bekçiliğe karşı birkaç argüman geliştirir. Bu argümanlar, yapay zekâ bağlamında da büyük ölçüde geçerliliğini korumaktadır.

Birinci argüman, ahlaki bilgi ile araçsal bilgi arasındaki ayrıma dayanır. Dahl'a göre, siyasi kararlar iki tür bilgi gerektirir: Neyin iyi olduğuna ilişkin *ahlaki* bilgi ve bu iyiye ulaşmanın en iyi yollarına ilişkin *araçsal* bilgi. Uzmanlık, araçsal bilgi bakımından gerçek ve önemli bir üstünlük sağlayabilir; bir iktisatçı, enflasyonu düşürmenin yolları konusunda sıradan bir yurttaştan daha fazla bilgiye sahiptir. Ancak ahlaki bilgi bakımından, yani enflasyonu düşürmenin işsizliği artırması durumunda hangisinin daha önemli olduğu konusunda, uzmanların sıradan yurttaşlardan daha fazla bilgiye sahip olduğunu gösteren hiçbir güvenilir

kanıt yoktur. Dahl'ın ifadesiyle, ahlaki konularda "uzmanlık" iddiası, çoğu zaman belirli bir grubun değerlerinin herkese dayatılmasının bir kılıfıdır.

Bu argüman, yapay zekâ bağlamında son derece önemlidir. Yapay zekâ sistemleri, araçsal bilgi bakımından insanları aşabilir; belirli bir hedefe ulaşmanın en etkili yollarını insanlardan daha iyi bulabilir. Ancak hangi hedeflerin izlenmesi gerektiği, yani farklı değerler arasındaki çatışmaların nasıl çözüleceği sorusu, araçsal bilginin alanına girmez. İkinci Bölüm'de, Iason Gabriel'in hizalama sorununun salt teknik değil, adil bir değer seçimi sürecinin tasarımına ilişkin siyasi bir sorun olduğu yönündeki tespiti aktarılmıştı. Dahl'ın argümanı, bu tespitin felsefi temelini oluşturur: Yapay zekâ, "insan değerleriyle hizalanmış" olsa bile, bu değerlerin *hangileri* olacağı ve aralarındaki çatışmaların *nasıl* çözüleceği, yapay zekânın değil, insanların karar vermesi gereken bir sorudur.

İkinci argüman, bekçilerin denetlenmesi sorununa ilişkindir. Dahl, bekçilik modellerinin hiçbirinin, bekçilerin yozlaşmasını önleyecek güvenilir bir mekanizma geliştiremediğini ileri sürer. Platon'un eğitim ve mülkiyetsizlik önerileri, uygulamada hiçbir zaman işlememiştir; tarihsel bekçilik rejimleri, istisnasız biçimde, bekçilerin kendi çıkarlarını gözetmeleriyle sonuçlanmıştır. Bu argüman, yapay zekâ bağlamında hizalama sorununa karşılık gelir: Bir yapay zekâ bekçisinin "yozlaşmayacağının", yani hedeflerinin insan değerlerinden sapmayacağının güvencesi nedir?

Üçüncü argüman, kişisel özerklik karinesine ve güçlü eşitlik ilkesine dayanır. Dahl'a göre, aksi güçlü biçimde kanıtlanmadıkça, her yetişkin, kendi iyiliğinin ve çıkarlarının en iyi yargıcı olarak kabul edilmelidir. Bu "kişisel özerklik karinesi", bir topluluğun kolektif kararlarına katılma hakkı bakımından "güçlü eşitlik ilkesi"ne dönüşür: Bir topluluğun yetişkin üyeleri, genel olarak, kolektif kararlara katılma bakımından yeterince yetkindir ve hiçbiri, diğerlerinden açıkça daha yetkin değildir. Dahl, bu ilkenin olgusal bir iddia olmadığını, yani herkesin her konuda eşit bilgiye sahip olduğunu iddia etmediğini; bunun yerine, kimin daha yetkin olduğuna karar verme yetkisini kimseye tanımamanın daha güvenli olduğu yönünde bir ihtiyat ilkesi olduğunu vurgular.

II. Mill'in Çoğul Oy Önerisi ve Çağdaş Epistokrasi

A. Mill: Katılım ve Yetkinlik Arasında

John Stuart Mill, bekçilik ile demokrasi arasındaki gerilimi, ikisini birleştirmeye çalışarak çözmeye çalışmıştır. *Temsilî Hükümet Üzerine Düşünceler* adlı eserinde Mill, bir yandan, siyasi katılımın yurttaşların ahlaki ve entelektüel gelişimi için vazgeçilmez olduğunu savunur. Katılım, yurttaşları kendi dar çıkarlarının ötesine bakmaya, kamusal sorunlar hakkında düşünmeye ve başkalarının bakış açılarını anlamaya yönlendirir; bu nedenle katılımın kendisi, sonuçlarından bağımsız olarak, değerli bir eğitim sürecidir.[195] Öte yandan Mill, herkesin oyunun eşit ağırlıkta olmasına karşı çıkar ve daha eğitimli ve daha yetkin yurttaşlara birden fazla oy hakkı tanınmasını, yani "çoğul oy" sistemini önerir.[196]

Mill'in önerisi, bu çalışma bakımından iki açıdan ilginçtir. *Birincisi*, Mill, katılımın değerini sonuçlarının iyiliğinden bağımsız olarak kabul eder. Bu, yapay zekâ bağlamında önemli bir argüman sağlar: Kararların yapay zekâ tarafından daha iyi verilebileceği varsayılsa bile, yurttaşların bu kararlara katılmasının, onların ahlaki ve entelektüel gelişimi bakımından bağımsız bir değeri vardır. Kararları yapay zekâya bırakan bir toplum, daha iyi kararlar elde edebilir; ama bu kararları kendisi vermeyi öğrenme fırsatını yitirir. İkinci Bölüm'de ele alınan "kurumsal bilişsel körelme" olgusu, Mill'in bu kaygısının kurumsal düzeydeki karşılığıdır. *İkincisi*, Mill'in çoğul oy önerisi, yetkinliğin siyasi ağırlığa dönüştürülmesinin en ılımlı biçimidir: Yetkinler daha fazla oy alır, ama herkes oy kullanmaya devam eder. Bu öneri, yapay zekânın siyasi karar süreçlerinde "danışman" olarak değil, "ek oy sahibi" olarak yer alması fikrine benzer.

B. Brennan ve Çağdaş Epistokrasi

Çağdaş siyaset felsefesinde epistokrasiyi en açık biçimde savunan isim, Jason Brennan'dır. Brennan, *Demokrasiye Karşı* adlı eserinde, seçmenlerin büyük çoğunluğunun siyasi konularda bilgisiz, önyargılı ve irrasyonel olduğunu gösteren ampirik araştırmalara dayanarak, demokrasinin içsel bir değeri olmadığını ve yalnızca iyi sonuçlar ürettiği ölçüde savunulabileceğini ileri sürer.[197] Brennan'ın merkezî argümanı, "yetkinlik ilkesi" olarak adlandırdığı bir ilkeye dayanır. Bu ilkeye göre, bir

[195] Mill, *Considerations on Representative Government*, III. Bölüm.
[196] Mill, *Considerations on Representative Government*, VIII. Bölüm.
[197] Brennan, *Against Democracy*.

yurttaşın hayatını, özgürlüğünü veya mülkünü önemli ölçüde etkileyen kararların, yetkin olmayan veya ahlaken makul olmayan bir karar organı tarafından ya da yetkin olmayan ve ahlaken makul olmayan bir biçimde alınması, haksızdır ve o yurttaşın haklarını ihlal eder. Brennan'a göre seçmen kitlesi, sistematik olarak bilgisiz ve önyargılı olduğundan, bu ilkeyi ihlal eden bir karar organıdır.

Brennan, demokrasinin yerine geçebilecek çeşitli epistokratik seçenekler önerir: oy hakkının bir yeterlilik sınavını geçenlerle sınırlandırılması, daha bilgili seçmenlere çoğul oy tanınması, rastgele seçilmiş ve eğitilmiş bir yurttaş grubunun karar vermesi ve bilgili bir kurulun demokratik kararları veto edebilmesi gibi. Bu seçeneklerden biri, yapay zekâ tartışması bakımından özellikle dikkat çekicidir: Brennan'ın "simüle edilmiş kâhin yönetimi" (*government by simulated oracle*) olarak adlandırdığı model. Bu modelde, yurttaşlar hem siyasi tercihlerini hem de demografik bilgilerini hem de siyasi bilgi düzeylerini ölçen bir sınavın sonuçlarını bildirir. Ardından, istatistiksel yöntemlerle, *tam bilgilendirilmiş* bir seçmen kitlesinin, aynı demografik özelliklere sahip olsaydı, neyi tercih edeceği tahmin edilir; ve kararlar, gerçek tercihlere değil, bu tahmin edilen "bilgilendirilmiş tercihlere" göre alınır.[198]

Brennan'ın "simüle edilmiş kâhin" modeli, esasen algoritmik bir yönetim önerisidir. Bu model, yurttaşların gerçek iradesini, onların "ne istemeleri gerektiğine" ilişkin bir algoritmik tahminle değiştirir. Yapay zekânın gelişimi, bu modelin teknik olarak çok daha sofistike biçimlerde uygulanmasını mümkün kılmaktadır. Yapay zekâ sistemleri, bireylerin "bilgilendirilmiş tercihlerini" tahmin etmek, farklı politika seçeneklerinin sonuçlarını modellemek ve toplumun "gerçek çıkarlarına" en uygun kararları önermek için kullanılabilir. Bu nedenle, Brennan'ın epistokrasisine yöneltilen eleştiriler, yapay zekâ tabanlı yönetim önerilerine de doğrudan uygulanabilir.

III. Estlund: Uzman/Efendi Safsatası

Epistokrasiye yöneltilen en sistematik ve en etkili felsefi eleştiri, David Estlund'un *Demokratik Otorite* adlı eserinde bulunur.[199] Estlund'un eleştirisi, bu çalışmanın temel tezi olan "zekâ yetki doğurmaz" ilkesinin en

[198] Brennan, *Against Democracy*, epistokrasi biçimlerine ilişkin bölüm.

[199] David M. Estlund, *Democratic Authority: A Philosophical Framework*, Princeton, Princeton University Press, 2008.

önemli felsefi dayanaklarından birini oluşturduğu için, ayrıntılı olarak ele alınmayı hak etmektedir.

A. Epistokrasinin Üç Öncülü

Estlund, epistokrasi lehine argümanı üç öncüle ayırır.[200] *Hakikat öncülü*: Siyasi kararların değerlendirilmesinde kullanılabilecek doğru (veya diğerlerinden daha iyi) normatif standartlar vardır. *Bilgi öncülü*: Bazı insanlar, bu standartları diğerlerinden daha iyi bilir. *Otorite öncülü*: Bu standartları daha iyi bilenlerin normatif bilgisi, onların başkaları üzerinde siyasi otoriteye sahip olmasının gerekçesidir.

Estlund, ilk iki öncülü, yani doğru siyasi standartların bulunduğunu ve bazı insanların bunları diğerlerinden daha iyi bildiğini, kabul etmeye hazırdır. Estlund'un itirazı, üçüncü öncüle, yani bilgiden otoriteye geçişedir.

B. Uzman/Efendi Safsatası

Estlund, bilgiden otoriteye geçişi "uzman/efendi safsatası" (*expert/boss fallacy*) olarak adlandırır. Bu safsata, birinin bir konuda daha fazla bilgiye sahip olmasından, onun bu konuda başkalarına emir verme yetkisine sahip olduğu sonucunu çıkarmaktır. Estlund, bu çıkarımın neden geçersiz olduğunu basit bir örnekle açıklar: Bir uzman, belirli bir konuda gerçekten haklı olabilir; ama bu, onun benim üzerimde otorite sahibi olduğu anlamına gelmez. Estlund'un özlü formülüyle: "Haklı olabilirsin; ama seni kim patron yaptı?"[201]

Bu formül, yapay zekâ tartışmasının özünü yakalamaktadır. Bir yapay zekâ sistemi, belirli bir politika sorusunda gerçekten haklı olabilir; önerdiği politika, insan karar vericilerin tercih edeceği politikadan daha iyi sonuçlar üretebilir. Ancak bu, sistemin bu politikayı topluma *dayatma* yetkisine sahip olduğu anlamına gelmez. Haklı olmak ile yetkili olmak, farklı şeylerdir. Haklı olmak, epistemik bir niteliktir; yetkili olmak ise normatif bir ilişkidir. İlkinden ikincisine geçmek için ek bir gerekçeye ihtiyaç vardır ve epistokrasi bu ek gerekçeyi sağlayamamaktadır.

C. Nitelikli Kabul Edilebilirlik Şartı ve Kıyaslama İtirazı

Estlund, bilgiden otoriteye geçişin neden ek bir gerekçe gerektirdiğini, "nitelikli kabul edilebilirlik şartı" (*qualified acceptability requirement*)

[200] Estlund, *Democratic Authority*, epistokrasiye ilişkin tartışma.
[201] Estlund, *Democratic Authority*: "*You might be right, but who made you boss?*"

adını verdiği bir ilkeyle açıklar. Bu ilkeye göre, hiç kimse, gerekçesi tüm *nitelikli* bakış açıları tarafından kabul edilebilir olmadıkça, başka biri üzerinde siyasi otoriteye sahip olamaz.[202] "Nitelikli" bakış açıları, makul, bilgilendirilmiş ve iyi niyetli bakış açılarıdır; dolayısıyla bu şart, herkesin rızasını gerektirmez, ama makul insanların reddedebileceği gerekçelere dayanan bir otoriteyi meşru saymaz.

Bu şart, epistokrasiye karşı Estlund'un "kıyaslama itirazı" (*invidious comparison objection*) adını verdiği itirazın temelini oluşturur. Epistokrasinin uygulanabilmesi için, kimin daha bilge olduğunun belirlenmesi gerekir. Ancak kimin daha bilge olduğu sorusu, makul insanların derin biçimde anlaşmazlığa düşebileceği bir sorudur. Farklı dünya görüşlerine, farklı değerlere ve farklı deneyimlere sahip makul insanlar, kimin siyasi konularda daha bilge olduğu konusunda farklı yargılara varacaktır. Bu nedenle, belirli bir grubu "bilge" olarak seçip onlara otorite tanıyan bir sistem, nitelikli kabul edilebilirlik şartını karşılayamaz; çünkü makul insanlar, bu seçimin dayandığı ölçütleri reddedebilir.

Estlund'un bu itirazı, yapay zekâ bağlamında özel bir güç kazanır. Bir yapay zekâ sistemine siyasi otorite tanınabilmesi için, o sistemin insanlardan daha bilge olduğunun tüm nitelikli bakış açıları tarafından kabul edilebilir bir biçimde gösterilmesi gerekir. Ancak İkinci Bölüm'de ayrıntılı olarak ele alındığı üzere, bir yapay zekâ sisteminin değerlerinin insan değerleriyle gerçekten hizalanıp hizalanmadığını doğrulamanın güvenilir bir yolu henüz yoktur. Bir sistemin belirli görevlerdeki başarımı ölçülebilir; ancak sistemin, ölçülemeyen durumlarda, özellikle de değer çatışmalarını içeren siyasi kararlarda, "doğru" kararları vereceği, makul insanların haklı olarak şüphe edebileceği bir iddiadır. Bu şüphe, makul bir şüphe olduğu sürece, nitelikli kabul edilebilirlik şartı karşılanamaz ve yapay zekâya siyasi otorite tanınması meşru olamaz.

Bu argümanın önemli bir sonucu, onun yapay zekâ sistemlerinin *gerçekte* ne kadar yetenekli veya hizalanmış olduğundan bağımsız olmasıdır. Bir sistem gerçekten mükemmel biçimde hizalanmış ve son derece bilge olsa bile, bu durum makul insanlar tarafından *doğrulanamadığı* sürece, sistem siyasi otoriteye sahip olamaz. Otoritenin meşruiyeti, yalnızca otoritenin niteliklerine değil, bu niteliklerin kamusal olarak gerekçelendirilebilir olmasına da bağlıdır.

[202] Estlund, *Democratic Authority*, nitelikli kabul edilebilirlik şartına ilişkin tartışma.

D. Estlund'un Olumlu Önerisi: Epistemik Usulcülük

Estlund'un epistokrasiyi reddetmesi, demokrasinin epistemik değerini reddettiği anlamına gelmez. Estlund, "epistemik usulcülük" (*epistemic proceduralism*) adını verdiği bir görüş savunur.[203] Bu görüşe göre, demokratik usullerin otoritesi, iki unsurun birleşimine dayanır: Birincisi, demokratik usuller, rastgele karar verme yöntemlerinden daha iyi kararlar üretme eğilimindedir; yani belirli bir epistemik değere sahiptir. İkincisi, demokratik usuller, tüm nitelikli bakış açıları tarafından kabul edilebilir; çünkü kimseye, makul olarak reddedilebilecek bir bilgelik iddiasına dayanarak özel bir konum tanımaz. Demokrasi, en iyi kararları üreten sistem olduğu için değil, *kabul edilebilir* sistemler arasında epistemik olarak en iyisi olduğu için otoriteye sahiptir.

Estlund'un epistemik usulcülüğü, yapay zekâ bakımından yapıcı bir yol önermektedir. Yapay zekâ, demokratik usullerin epistemik değerini artırmak için kullanılabilir: Karar vericilere ve yurttaşlara daha iyi bilgi sağlayarak, farklı politika seçeneklerinin sonuçlarını modelleyerek, tartışmaları zenginleştirerek. Bu kullanım, demokratik usullerin "kabul edilebilirliğini" bozmadığı, yani yapay zekâya demokratik süreç içinde özel bir otorite konumu tanımadığı sürece meşrudur. Yapay zekâ, demokrasinin epistemik gücünü artıran bir *araç* olabilir; ama demokrasinin yerini alan bir *otorite* olamaz.

IV. Algoritmik Epistokrasi

Yukarıdaki tartışma ışığında, "algoritmik epistokrasi" kavramını, yani siyasi karar yetkisinin, bilişsel üstünlük gerekçesiyle, kısmen veya tamamen yapay zekâ sistemlerine devredilmesi önerisini değerlendirmek mümkündür. Algoritmik epistokrasinin farklı biçimleri düşünülebilir. En radikal biçiminde, yapay zekâ sistemleri doğrudan karar verici olarak tasarlanır. Daha ılımlı biçimlerinde ise yapay zekâ sistemleri, demokratik kararlar üzerinde bir veto yetkisine sahip olur, belirli teknik alanlardaki kararlar onlara bırakılır veya Brennan'ın "simüle edilmiş kâhin" modelinde olduğu gibi, yurttaşların "gerçek" tercihlerini tahmin ederek onların adına karar verir. Bazı yazarlar, yurttaşların her birinin, onun tercihlerini öğrenen ve onun adına çok sayıdaki kamusal karara katılan kişisel bir yapay zekâ temsilcisine sahip olabileceği bir "artırılmış demokrasi" modeli de önermiştir.

[203] Estlund, *Democratic Authority*, epistemik usulcülüğe ilişkin bölümler.

Algoritmik epistokrasinin tüm bu biçimlerine karşı dört temel itiraz yöneltilebilir. Bu itirazlar, yukarıda ele alınan felsefi tartışmanın yapay zekâ bağlamındaki özetidir.

Epistemik itiraz: Algoritmik epistokrasi, yapay zekâ sistemlerinin siyasi konularda insanlardan daha bilge olduğu varsayımına dayanır. Ancak Dahl'ın ahlaki bilgi ile araçsal bilgi arasındaki ayrımı, bu varsayımın en fazla araçsal bilgi bakımından geçerli olabileceğini gösterir. Ahlaki bilgi bakımından, yani değer çatışmalarının nasıl çözüleceği bakımından, yapay zekânın insanlardan daha bilge olduğunu gösteren hiçbir güvenilir yöntem yoktur. Üstelik yapay zekânın değerleri, eğitim sürecinde insanların tercihlerinden öğrenildiğinden, yapay zekâ, bu tercihlerin önyargılarını ve sınırlılıklarını da devralabilir.

Normatif itiraz: Estlund'un uzman/efendi safsatası ve nitelikli kabul edilebilirlik şartı, yapay zekâ gerçekten daha bilge olsa bile, bu bilgeliğin siyasi otoriteye dönüşemeyeceğini gösterir. Siyasi otorite, bilgelikten değil, kamusal olarak gerekçelendirilebilir bir yetkilendirme ilişkisinden doğar.

Popper'ci itiraz: Algoritmik epistokrasi, Popper'in reddettiği "Kim yönetmeli?" sorusuna "en bilge olan" cevabını verir. Ancak Popper'in gösterdiği gibi, bu cevap, en bilge olanın yanılması durumunda ne olacağı sorusunu cevapsız bırakır. Yapay zekâya yetki devredildiğinde, bu devrin geri alınabilir olması, yani yapay zekânın hatalı olduğu anlaşıldığında, kan dökülmeden, yani büyük bir zarar ve direnç olmaksızın devre dışı bırakılabilmesi gerekir. İkinci Bölüm'de ele alınan "kurumsal bilişsel körelme" ve "araçsal yakınsama" olguları, bu geri alınabilirliğin zamanla zayıflayabileceğini göstermektedir.

Cumhuriyetçi itiraz: Dördüncü Bölüm'de ayrıntılı olarak geliştirilecek olan bu itiraza göre, algoritmik epistokrasi, yapay zekâ ne kadar iyi niyetli ve bilge olursa olsun, yurttaşları bir "tahakküm" ilişkisine tabi kılar; çünkü yurttaşlar, kendi hayatlarını etkileyen kararların, kendilerinin denetleyemediği bir güç tarafından alınmasına maruz kalır. Bu tahakküm, gücün fiilen kötüye kullanılıp kullanılmadığından bağımsız olarak, özgürlüğün kaybı anlamına gelir.

§ 12. OTORİTE KURAMI VE YAPAY ZEKÂ

I. Teorik ve Pratik Otorite

Otorite kavramının felsefi analizi, bu çalışmanın temel sorusunu daha kesin biçimde formüle etmeyi mümkün kılar. Otorite felsefesinde, iki tür otorite arasında yerleşik bir ayrım yapılır: *teorik* (veya *epistemik*) otorite ve *pratik* otorite.

Teorik otorite, inanç için gerekçe sağlayan otoritedir. Bir hekim, hastalığımın nedeni konusunda teorik otoriteye sahiptir: Onun bu konudaki görüşü, benim bu konuda neye inanmam gerektiği hakkında güçlü bir gerekçe oluşturur. Bir ansiklopedi, bir bilim insanı veya bir uzman kurul da benzer biçimde teorik otoriteye sahip olabilir. Teorik otorite, bana ne yapmam gerektiğini *söylemez*; yalnızca neyin doğru olduğu hakkında bana bilgi verir. Bu bilgiye dayanarak ne yapacağıma, ben karar veririm.

Pratik otorite ise eylem için gerekçe sağlayan otoritedir. Bir yasa koyucu, bir hâkim veya bir idari makam, pratik otoriteye sahiptir: Onların buyrukları, benim ne yapmam gerektiği hakkında bağlayıcı gerekçeler oluşturur. Pratik otoritenin ayırt edici özelliği, buyruklarının, benim kendi değerlendirmemden bağımsız olarak bağlayıcı olmasıdır. Bir kanuna, ona katılsam da katılmasam da uymam gerekir; bir mahkeme kararına, onu doğru bulsam da bulmasam da uymam gerekir.

Bu ayrım, yapay zekâ tartışması bakımından aydınlatıcıdır. Bir yapay zekâ sisteminin, belirli konularda *teorik* otoriteye sahip olması, yani görüşlerinin, bu konularda neye inanmamız gerektiği hakkında güçlü bir gerekçe oluşturması, sorunsuz bir biçimde kabul edilebilir. Bir yapay zekâ sistemi, bir hastalığın teşhisi, bir mühendislik yapısının güvenliği veya bir ekonomik politikanın olası sonuçları konusunda, insan uzmanlardan daha güvenilir bir bilgi kaynağı olabilir. Bu durumda, o sistemin görüşlerine epistemik ağırlık vermek rasyoneldir. Asıl soru, yapay zekânın *pratik* otoriteye, yani başkaları üzerinde bağlayıcı buyruklar verme yetkisine sahip olup olamayacağıdır. Bu çalışmanın Giriş'te formüle edilen ikinci hipotezi (H2), tam da bu ayrıma dayanmaktadır: Zekâ üstünlüğü, teorik otorite için gerekçe oluşturabilir; ama pratik otorite için yeterli bir gerekçe oluşturmaz.

II. Raz'ın Hizmet Anlayışı ve Normal Gerekçelendirme Tezi

A. Hizmet Anlayışı

Çağdaş hukuk felsefesinde pratik otoriteye ilişkin en etkili kuram, Joseph Raz'ın "hizmet anlayışı" (*service conception*) olarak adlandırılan kuramıdır.[204] Raz'a göre, meşru otoritenin işlevi, kendisine tabi olanlara "hizmet etmek"tir; yani onların, zaten kendilerine uygulanan gerekçelere daha iyi uymalarına yardımcı olmaktır. Bu kuram, üç tezden oluşur.

Bağımlılık tezi: Otoritenin buyrukları, buyruğun kapsadığı durumlarda, zaten tabi olanlara uygulanan gerekçelere dayanmalıdır. Otorite, yeni gerekçeler yaratmaz; mevcut gerekçeleri değerlendirir ve bu değerlendirmenin sonucunu bir buyruk olarak ifade eder.

Normal gerekçelendirme tezi: Bir kişinin başka bir kişi üzerinde otoriteye sahip olduğunu kanıtlamanın normal yolu, tabi olanın, otoritenin buyruklarını bağlayıcı olarak kabul edip onlara uymaya çalıştığında, kendisine uygulanan gerekçelere, onlara doğrudan uymaya çalıştığından daha iyi uymasının muhtemel olduğunu göstermektir.[205]

Önalım tezi: Otoritenin buyruğu, tabi olanın eylemi için bir gerekçe olarak, mevcut gerekçelere eklenmez; bunların bir kısmının *yerine geçer*. Bir otoritenin buyruğunu kabul eden kişi, buyruğun dayandığı gerekçeleri kendisi yeniden tartmaz; buyruğun kendisini, bu gerekçelerin yerine geçen bağlayıcı bir gerekçe olarak kabul eder.

B. Normal Gerekçelendirme Tezinin Yapay Zekâya Uygulanması

Raz'ın normal gerekçelendirme tezi, yapay zekâ tartışması bakımından ciddi bir meydan okuma oluşturur ve bu meydan okumayla dürüstçe yüzleşmek gerekir. Tez, otoritenin meşruiyetini, otoritenin buyruklarına uymanın, tabi olanların kendi gerekçelerine daha iyi uymasını sağlayıp sağlamadığına bağlar. Bu bir *performans* ölçütüdür: Otorite, tabi olanlardan daha iyi karar verebildiği ölçüde meşrudur. Eğer bir yapay zekâ sistemi, belirli bir alanda, insanlardan daha iyi karar verebiliyorsa, yani insanların

[204] Joseph Raz, *The Morality of Freedom*, Oxford, Clarendon Press, 1986, 3. Bölüm; Joseph Raz, "Authority, Law and Morality", *The Monist*, C. 68, S. 3, 1985.

[205] Raz, *The Morality of Freedom*, s. 53. Tezin İngilizce özgün ifadesi: "*the normal way to establish that a person has authority over another person involves showing that the alleged subject is likely better to comply with reasons which apply to him (other than the alleged authoritative directives) if he accepts the directives of the alleged authority as authoritatively binding and tries to follow them, rather than by trying to follow the reasons which apply to him directly.*"

kendi gerekçelerine (örneğin sağlıklarını korumak, güvenli bir ulaşım sağlamak, ekonomik refahı artırmak gibi) onun buyruklarına uyarak, kendi kararlarına göre davrandıklarından daha iyi uyabilecekleri muhtemelse, normal gerekçelendirme tezi, bu sistemin o alanda meşru otoriteye sahip olduğu sonucuna götürüyor gibi görünmektedir.

Bu sonuç, ilk bakışta, bu çalışmanın temel teziyle doğrudan çelişir. Eğer Raz'ın kuramı doğruysa ve yapay zekâ belirli alanlarda insanlardan daha iyi karar verebiliyorsa, o alanlarda yapay zekânın pratik otoriteye sahip olduğu kabul edilmelidir. Bu meydan okumaya üç farklı düzlemde cevap verilebilir.

III. Hizmet Anlayışının Sınırları

A. Bağımsızlık Koşulu ve Kendi Kararını Verme Değeri

Raz'ın kendisi, normal gerekçelendirme tezinin otoritenin meşruiyeti için tek başına yeterli olmadığını, sonraki çalışmalarında açıkça kabul etmiştir. Raz, 2006'da yayımlanan bir makalesinde, hizmet anlayışını yeniden ele alarak, normal gerekçelendirme tezine bir "bağımsızlık koşulu" eklemiştir.[206] Bu koşula göre, otoritenin meşru olabilmesi için, normal gerekçelendirme tezinin karşılandığı konuların, *kendi başına karar vermenin, otoritenin yardımıyla gerekçelere daha iyi uymaktan daha önemli olmadığı* konular olması gerekir. Başka bir ifadeyle, bazı konularda, doğru kararı vermekten çok, kararı *kendimizin* vermesi önemlidir.

Raz'ın bu eklemesi, yapay zekâ tartışması bakımından belirleyici bir öneme sahiptir. Hangi konularda kendi başına karar vermek, doğru kararı vermekten daha önemlidir? Raz'ın kendisi, bu konuların başında, kişinin kendi hayatının temel yönlerine ilişkin kararları sayar: kiminle evleneceği, hangi mesleği seçeceği, hangi değerlere bağlanacağı gibi. Bu kararlarda, başkası, hatta daha bilge biri, bizim için daha iyi bir seçim yapabilse bile, seçimi kendimizin yapması, hayatımızın *bizim* hayatımız olmasının bir koşuludur.

Bu çalışma, Raz'ın bağımsızlık koşulunun, bireysel düzeyin ötesinde, *kolektif* düzeyde de geçerli olduğunu ileri sürmektedir. Bir siyasi topluluğun kendi geleceğine ilişkin temel kararları, yani hangi değerlere öncelik vereceği, hangi riskleri kabul edeceği, kaynaklarını nasıl dağıtacağı,

[206] Joseph Raz, "The Problem of Authority: Revisiting the Service Conception", *Minnesota Law Review*, C. 90, 2006.

hangi toplum olmak istediği, bağımsızlık koşulunun tam olarak öngördüğü türden kararlardır. Bu kararlarda, topluluğun kararı *kendisinin* vermesi, yani kolektif öz-yönetim, doğru kararın verilmesinden bağımsız bir değere sahiptir. Bir toplum, daha bilge bir dış güç tarafından yönetildiğinde daha iyi sonuçlar elde etse bile, bu sonuçlar, o toplumun kendi kararlarının sonuçları olmayacaktır. Kolektif öz-yönetim, Raz'ın bireysel özerklik için kabul ettiği değerin kolektif karşılığıdır ve bu değer, siyasi kararlar bakımından normal gerekçelendirme tezinin otoriteyi meşrulaştırma gücünü sınırlar.

B. Doğrulama Sorunu

Normal gerekçelendirme tezine yöneltilebilecek ikinci itiraz, tezin uygulanabilmesi için gereken *bilgiye* ilişkindir. Tez, otoritenin meşruiyetini, otoriteye uymanın tabi olanların gerekçelerine daha iyi uymasını sağlayıp sağlamadığına bağlar. Ancak bu koşulun karşılanıp karşılanmadığını kim, nasıl bilecektir? Raz'ın kuramında, otoritenin meşruiyeti nesnel bir olgudur; tabi olanların bunu bilip bilmemesinden bağımsızdır. Ancak siyasi meşruiyet bakımından, otoritenin meşru olduğunun *bilinebilir* ve *gösterilebilir* olması gerekir. Aksi takdirde, her otorite, meşru olduğunu iddia edebilir.

Yapay zekâ bağlamında bu doğrulama sorunu, İkinci Bölüm'de ele alınan hizalama ve denetim sorunlarıyla birleşir. Bir yapay zekâ sisteminin buyruklarına uymanın, insanların kendi gerekçelerine daha iyi uymasını sağladığını göstermek için, sistemin kararlarının, insanların gerekçeleri bakımından daha iyi olduğunu doğrulamak gerekir. Ancak kavrayış asimetrisi koşullarında, bu doğrulama tam da yapılamayan şeydir. İnsanlar, sistemin kararlarının daha iyi olup olmadığını değerlendiremiyorlarsa, sistemin normal gerekçelendirme tezini karşıladığını da gösteremezler. Bu durumda, Raz'ın kuramı bile, yapay zekâya otorite tanınması için yeterli bir gerekçe sağlamaz. Bu itiraz, yukarıda ele alınan Estlund'un nitelikli kabul edilebilirlik şartıyla birleştiğinde daha da güçlenir: Yapay zekânın normal gerekçelendirme tezini karşıladığı, makul insanların haklı olarak şüphe edebileceği bir iddia olduğu sürece, bu iddia, siyasi otoritenin kamusal gerekçesi olamaz.

C. Demokratik Meşruiyet ve Kamusal Eşitlik

Normal gerekçelendirme tezine yöneltilebilecek üçüncü itiraz, demokratik meşruiyetin doğasına ilişkindir. Hukuk felsefecisi Scott

Hershovitz, Raz'ın hizmet anlayışının, demokratik otoritenin meşruiyetini açıklamakta yetersiz kaldığını ileri sürmüştür.[207] Hershovitz'e göre, demokratik bir parlamentonun otoritesi, parlamentonun yurttaşlardan daha iyi karar vermesinden değil, parlamentonun yurttaşların *eşit* katılımıyla oluşturulmuş bir karar usulü olmasından kaynaklanır. Bir yurttaş, kendisinden daha bilgili olmadığını düşündüğü bir parlamentonun kanununa da uymakla yükümlüdür; çünkü bu kanun, onun da eşit bir sese sahip olduğu bir usulle yapılmıştır.

Thomas Christiano, bu düşünceyi daha sistematik bir biçimde geliştirmiştir. Christiano'ya göre, demokrasinin otoritesi, "kamusal eşitlik" ilkesine dayanır: Farklı çıkarlara ve görüşlere sahip insanların ortak bir dünyayı paylaşmak zorunda olduğu koşullarda, bu ortak dünyanın nasıl düzenleneceğine ilişkin kararların, herkesin eşit olarak ele alındığını *herkesin görebileceği* bir biçimde alınması gerekir.[208] Demokratik usuller, bu kamusal eşitliği gerçekleştiren usullerdir. Bir yapay zekâ sisteminin kararları, ne kadar iyi olursa olsun, bu kamusal eşitliği gerçekleştiremez; çünkü yurttaşlar, sistemin kararlarında kendi çıkarlarının ve görüşlerinin eşit olarak dikkate alınıp alınmadığını göremezler. Kararın içeriği adil olsa bile, kararın *adil olduğunun görülebilirliği* eksik kalır.

IV. Darwall: İkinci Şahıs Bakış Açısı ve Hesap Verebilirlik

Pratik otoritenin yapay zekâya tanınamayacağına ilişkin belki de en derin felsefi argüman, Stephen Darwall'un "ikinci şahıs bakış açısı" kuramından türetilebilir.[209] Darwall'a göre, ahlaki ve hukuki yükümlülüklerin belirli bir türü, "ikinci şahıs gerekçeleri"ne dayanır. İkinci şahıs gerekçeleri, bir kişinin başka bir kişiye *hitap ederek* ileri sürdüğü taleplerdir: "Ayağımın üzerinden çekil!" talebi gibi. Bu talep, yalnızca dünyada iyi bir sonuç (ayağımın acımaması) üretmeye yönelik bir gerekçe değildir; aynı zamanda, talep edenin, muhatabından bunu *talep etme yetkisine* sahip olduğunu da ileri sürer.

Darwall'un önemli tespiti, bu tür taleplerin ve dolayısıyla pratik otoritenin, *karşılıklı hesap verebilirlik* ilişkisini varsaymasıdır. Bir kişinin

[207] Scott Hershovitz, "Legitimacy, Democracy, and Razian Authority", *Legal Theory*, C. 9, S. 3, 2003.
[208] Thomas Christiano, *The Constitution of Equality: Democratic Authority and Its Limits*, Oxford, Oxford University Press, 2008.
[209] Stephen Darwall, *The Second-Person Standpoint: Morality, Respect, and Accountability*, Cambridge (MA), Harvard University Press, 2006.

başka bir kişiden bir şey talep etme yetkisine sahip olması, her ikisinin de birbirine karşı hesap verebilir oldukları, yani birbirlerinden gerekçe talep edebilecekleri, birbirlerini suçlayabilecekleri, birbirlerine kızabilecekleri ve birbirlerini sorumlu tutabilecekleri bir ahlaki topluluğun üyeleri olmalarını gerektirir. Pratik otorite, bu karşılıklı hesap verebilirlik ağının içinde yer alır. Otorite sahibi, buyruk verirken, aynı zamanda buyruklarının gerekçesini talep edebilecek olanlara karşı hesap verebilir bir konumdadır.

Bu argüman, yapay zekâ bağlamında güçlü bir sonuç doğurur. Bir yapay zekâ sistemi, bu karşılıklı hesap verebilirlik ağının, en azından şimdilik, tam bir üyesi değildir. Bir sistemden gerekçe talep edilebilir ve sistem bir gerekçe üretebilir; ancak İkinci Bölüm'de görüldüğü üzere, bu gerekçenin sistemin gerçek karar sürecini yansıttığı her zaman güvence altında değildir. Daha önemlisi, bir sistem, hatalı bir kararı nedeniyle, Darwall'un anladığı anlamda "sorumlu tutulamaz": Ona kızmanın, onu suçlamanın veya onu cezalandırmanın, insanlara yönelik bu tepkilerin taşıdığı anlamı taşıyıp taşımadığı belirsizdir. Sistem, kendisinden hesap sorulduğunda, bu hesap sorulmayı, bir insanın anladığı biçimde, yani kendisini haklı çıkarma veya hatasını kabul edip telafi etme yükümlülüğü olarak anlamayabilir. Bu nedenle, bir yapay zekâ sistemi, Darwall'un anladığı anlamda pratik otoriteye sahip olamaz; çünkü pratik otorite, hesap verebilirlik ilişkisinden ayrılamaz ve bu ilişki, en azından bugünkü yapay zekâ sistemleri bakımından, kurulamamaktadır.

Bu argümanın önemli bir sonucu, yapay zekânın kararlarının ancak, bu kararları *sahiplenen* ve onlar için hesap veren bir insan aktör aracılığıyla otorite kazanabileceğidir. Yapay zekâ bir öneri üretir; bir insan karar verici bu öneriyi benimser ve onu kendi kararı olarak sahiplenir; ve bu insan karar verici, kararın gerekçesi için yurttaşlara karşı hesap verir. Bu yapıda, kararın otoritesi, yapay zekâdan değil, kararı sahiplenen insandan kaynaklanır. Bu sonuç, Birinci Bölüm'de Weber'in siyasetçinin devredilemez sorumluluğu ilkesiyle örtüşür ve Altıncı Bölüm'de geliştirilecek olan "son insan halkası" ilkesinin felsefi temelini oluşturur. Ancak bu sonuç, aynı zamanda, ciddi bir uyarıyı da içerir: Kararı sahiplenen insan, kararı *gerçekten* anlamıyorsa ve yalnızca yapay zekânın önerisini onaylıyorsa, hesap verebilirlik ilişkisi biçimsel olarak kurulmuş ama içerik olarak boşaltılmış olur. İkinci Bölüm'de ele alınan "ahlaki çarpışma bölgesi" olgusu, bu tehlikenin somut bir örneğidir.

V. Hart, Fuller ve Hukukun Yapay Aklı

A. Hart: Tanıma Kuralı ve İç Bakış Açısı

H. L. A. Hart'ın hukuk kuramı, yapay zekâ tartışmasına farklı bir açıdan ışık tutar. Hart'a göre, bir hukuk düzeninin varlığı, nihayetinde, o düzenin yetkililerinin (özellikle hâkimlerin) belirli bir "tanıma kuralı"nı (*rule of recognition*), yani hangi normların geçerli hukuk normu sayılacağını belirleyen kuralı, "iç bakış açısından" kabul etmelerine dayanır.[210] İç bakış açısı, bir kuralın yalnızca dışarıdan gözlemlenen bir düzenlilik olarak değil, davranışlar için bir *ölçüt* ve eleştiri için bir *temel* olarak kabul edilmesidir. Tanıma kuralı, yazılı bir normda değil, yetkililerin fiilî uygulamasında var olur.

Hart'ın kuramı, yapay zekânın hukuk düzenine nasıl nüfuz edebileceğini anlamak için verimli bir çerçeve sunar. Eğer hukuk düzeninin temeli, yetkililerin fiilî uygulamasıysa, bu uygulamanın değişmesi, hukuk düzeninin temelinin de değişmesi anlamına gelir. Yetkililer, kararlarını giderek daha fazla yapay zekâ sistemlerinin önerilerine dayandırmaya başlarsa ve bu önerileri sorgulamadan kabul etme pratiği yerleşirse, zamanla, fiilî tanıma kuralı, "yetkili organların çıkardığı normlar" yerine, örtük olarak "sistemin önerdiği normlar" hâline gelebilir. Bu, hiçbir biçimsel değişiklik olmaksızın, yalnızca yetkililerin uygulamasının değişmesiyle gerçekleşecek sessiz bir anayasal dönüşüm olacaktır. Bu tehlikeye karşı en önemli güvence, yetkililerin, iç bakış açısından, yapay zekâ önerilerini *geçerli hukuk kaynağı* olarak değil, yalnızca *bilgi kaynağı* olarak kabul eden bir uygulama kültürünü bilinçli olarak korumalarıdır.

B. Fuller: Hukukun İç Ahlakı

Lon Fuller'ın "hukukun iç ahlakı" kuramı ise yapay zekânın hukuk üretiminde kullanılmasının sınırlarını belirlemek için yararlı bir ölçüt sunar. Fuller, bir kurallar sisteminin "hukuk" sayılabilmesi için karşılaması gereken sekiz koşul belirler: kuralların genel olması, ilan edilmesi, geriye yürümemesi, açık olması, çelişkisiz olması, uyulması mümkün olan şeyler istemesi, zaman içinde görece istikrarlı olması ve yetkililerin fiilî eylemlerinin ilan edilmiş kurallarla uyumlu olması.[211] Fuller'a göre bu koşullardan birinin tamamen ihlali, salt kötü bir hukuk sistemi değil, hukuk olarak adlandırılmayı hak etmeyen bir sistem ortaya çıkarır.

[210] H. L. A. Hart, *The Concept of Law*, Oxford, Clarendon Press, 1961, V. ve VI. Bölümler.
[211] Lon L. Fuller, *The Morality of Law*, New Haven, Yale University Press, 1964, 2. Bölüm.

Yapay zekâ, Fuller'ın koşullarının birkaçını aynı anda tehdit edebilecek bir hukuk biçimini mümkün kılmaktadır. Hukuk akademisyenleri Anthony Casey ve Anthony Niblett, yapay zekânın, genel kurallar ve standartlar yerine, her bireysel duruma göre optimize edilmiş "mikro-direktifler" üretebileceğini ve bunun "kuralların ve standartların ölümü"ne yol açabileceğini ileri sürmüştür.[212] Bu senaryoda, örneğin trafikteki hız sınırı, genel bir kural olarak belirlenmek yerine, her sürücü için, o anki yol, hava ve trafik koşullarına ve sürücünün kişisel özelliklerine göre yapay zekâ tarafından anlık olarak hesaplanacaktır. Bu tür bir "kişiselleştirilmiş hukuk", belirli bir verimlilik kazancı sağlayabilir; ancak Fuller'ın koşullarından en az dördünü tehdit eder. Kurallar artık *genel* değildir; her biri tek bir duruma özgüdür. Önceden *ilan edilmiş* değildir; ancak uygulanacakları anda ortaya çıkarlar. *İstikrarlı* değildir; koşullar değiştikçe değişirler. Ve yetkililerin eylemlerinin ilan edilmiş kurallarla *uyumlu* olup olmadığını denetlemek neredeyse imkânsız hâle gelir; çünkü ilan edilmiş bir kural yoktur, yalnızca sistemin anlık çıktısı vardır.

Fuller'ın kuramının bu bağlamdaki önemi, hukukun yalnızca iyi sonuçlar üretmenin bir aracı olmadığını, aynı zamanda belirli bir *insan ilişkisi biçimi* olduğunu göstermesindedir. Fuller'a göre hukuk, insanları kendi davranışlarını kurallara göre yönlendirebilen, sorumlu failler olarak muamele eder. Kişiselleştirilmiş ve anlık olarak üretilen algoritmik direktifler ise insanları, kendi davranışlarını önceden planlayabilen özerk failler olarak değil, sistemin optimize ettiği değişkenler olarak muamele etme riski taşır. Bu, bir sonraki başlıkta ele alınacak olan insan onuru kavramıyla doğrudan ilişkilidir.

§ 13. ÖZERKLİK, İNSAN ONURU VE EPİSTEMİK BAĞIMLILIK

I. Kant: Aydınlanma ve Kendi Suçuyla Ergin Olmama

Immanuel Kant'ın 1784'te yayımlanan "Aydınlanma Nedir? Sorusuna Cevap" başlıklı kısa denemesi, yapay zekâ çağında yeniden okunmayı hak eden bir metindir. Kant, denemesine şu ünlü tanımla başlar: "Aydınlanma, insanın kendi suçuyla düştüğü erginlik eksikliğinden kurtulmasıdır. Erginlik eksikliği, kişinin kendi aklını başkasının yönlendirmesi olmadan

[212] Anthony J. Casey / Anthony Niblett, "The Death of Rules and Standards", *Indiana Law Journal*, C. 92, S. 4, 2017.

kullanamamasıdır.” Kant’a göre bu erginlik eksikliği, akıl eksikliğinden değil, aklı başkasının yönlendirmesi olmadan kullanma *cesaretinin* ve *kararlılığının* eksikliğinden kaynaklandığı için “kendi suçuyla” düşülmüş bir durumdur. Aydınlanmanın parolası bu nedenle şudur: “*Sapere aude!* Kendi aklını kullanma cesaretini göster!”[213]

Kant’ın denemesinin bir sonraki pasajı, yapay zekâ çağında neredeyse kehanet niteliği taşımaktadır: “Ergin olmamak çok rahattır. Benim yerime anlayan bir kitabım, benim yerime vicdanı olan bir din adamım, benim yerime perhizime karar veren bir hekimim vb. varsa, kendimi hiç zahmete sokmama gerek yoktur. Para ödeyebildiğim sürece düşünmeme gerek yoktur; başkaları bu sıkıcı işi benim yerime üstlenecektir.”[214] Kant’ın “benim yerime anlayan kitap” ifadesi, bugün, benim yerime düşünen, benim yerime yazan, benim yerime karar veren bir yapay zekâ sistemine harfiyen karşılık gelmektedir.

Kant’ın denemesindeki bir başka ifade, bu çalışmanın konusu bakımından özel bir önem taşır. Kant, insanları erginlik eksikliği içinde tutanları “vasiler” (*Vormünder*) olarak adlandırır ve onları, insanların “üst gözetimini lütfen üstlenmiş olan” (*die Oberaufsicht über sie gütigst auf sich genommen haben*) kişiler olarak tanımlar. Bu vasiler, önce evcil hayvanlarını aptallaştırır, sonra da bu sakin yaratıkların, içine kapatıldıkları yürüme arabasının dışına bir adım bile atmaya cesaret etmemesini sağlarlar; onlara, yalnız yürümeye kalkıştıklarında karşılaşacakları tehlikeyi gösterirler. Kant’ın bu “vesayet” eleştirisi, Dördüncü Bölüm’de geliştirilecek olan “algoritmik vesayet” kavramının felsefi kökenidir. Algoritmik vesayette, vasi, kötü niyetli bir insan değil, iyi niyetli ve son derece yetenekli bir sistemdir; ancak sonuç aynıdır: İnsanlar, kendi akıllarını kullanma alışkanlığını ve cesaretini yitirir.

Kant’ın uyarısı, yapay zekâya karşı genel bir düşmanlık olarak okunmamalıdır. Kant, kitaplara, din adamlarına veya hekimlere başvurmayı reddetmez; bunlara *körü körüne* bağımlı olmayı, yani kendi aklımızı onların yönlendirmesi olmadan kullanamayacak hâle gelmeyi eleştirir. Benzer şekilde, yapay zekâya başvurmak, kendi başına bir erginlik eksikliği değildir; erginlik eksikliği, yapay zekânın önerilerini kendi aklımızla

[213] Immanuel Kant, “Beantwortung der Frage: Was ist Aufklärung?”, *Berlinische Monatsschrift*, Aralık 1784.

[214] Kant, “Was ist Aufklärung?”: “*Es ist so bequem, unmündig zu sein. Habe ich ein Buch, das für mich Verstand hat, einen Seelsorger, der für mich Gewissen hat, einen Arzt, der für mich die Diät beurteilt, u.s.w., so brauche ich mich ja nicht selbst zu bemühen.*”

değerlendirme kapasitesini ve isteğini yitirdiğimizde ortaya çıkar. Bu ayrım, aşağıda ele alınacak olan sağlıklı ve sağlıksız epistemik bağımlılık arasındaki ayrımın temelini oluşturur.

II. İnsan Onuru ve Nesne Formülü

A. Kant'ın İnsanlık Formülü

Kant'ın ahlak felsefesinin merkezî ilkelerinden biri, kategorik buyruğun "insanlık formülü"dür: "İnsanlığı, hem kendi kişiliğinde hem de başka herkesin kişiliğinde, her zaman aynı zamanda bir amaç olarak kullanacak, asla yalnızca bir araç olarak kullanmayacak biçimde eylemde bulun."[215] Bu ilke, modern insan onuru kavramının felsefi temelini oluşturur. İnsanlar, akıl sahibi ve özerk varlıklar olarak, kendi başlarına bir değere, yani "onura" (*Würde*) sahiptir; ve bu onur, onların yalnızca başkalarının amaçlarına hizmet eden araçlar veya nesneler olarak muamele görmelerini yasaklar.

B. Nesne Formülü ve Alman Anayasa Yargısı

Kant'ın insanlık formülü, Alman anayasa hukukunda, Federal Almanya Temel Yasası'nın 1. maddesinin birinci fıkrasında güvence altına alınan insan onurunun ("İnsan onuru dokunulmazdır.") yorumunda belirleyici bir rol oynamıştır. Alman anayasa hukukçusu Günter Dürig tarafından geliştirilen ve Federal Anayasa Mahkemesi tarafından benimsenen "nesne formülü" (*Objektformel*), insan onurunun, somut bir insanın devlet eyleminin salt bir nesnesine, salt bir araca, değiştirilebilir bir büyüklüğe indirgendiği durumlarda ihlal edildiğini öngörür.

Federal Anayasa Mahkemesi'nin bu formülü uyguladığı en önemli kararlardan biri, 2006 tarihli Hava Güvenliği Kanunu kararıdır. Söz konusu kanun, kaçırılan ve bir terör saldırısında silah olarak kullanılmak istenen bir yolcu uçağının, son çare olarak silahlı kuvvetler tarafından düşürülmesine izin veriyordu. Mahkeme, bu hükmün, uçaktaki masum yolcu ve mürettebatın insan onurunu ihlal ettiğine karar vermiştir. Mahkemeye göre, devlet, başkalarını kurtarmak amacıyla masum insanların öldürülmesine karar verdiğinde, onları, kendi hayatları üzerinde hiçbir söz hakkı olmayan,

[215] Immanuel Kant, *Grundlegung zur Metaphysik der Sitten*, Riga, Hartknoch, 1785, İkinci Kısım.

salt bir kurtarma operasyonunun nesneleri olarak muamele etmiş olur; ve bu, sonuçlar ne kadar iyi olursa olsun, insan onuruyla bağdaşmaz.[216]

Bu karar, yapay zekâ tartışması bakımından önemli bir ilkeyi somutlaştırır: İnsan onuru, sonuç hesaplarına karşı bir sınır oluşturur. Bir eylemin iyi sonuçlar üretmesi, eğer bu eylem insanları salt nesneler olarak muamele ediyorsa, onu meşru kılmaz. Bu ilke, yapay zekânın insanlar hakkında karar vermesi bakımından şu soruyu gündeme getirir: Bir insan hakkında, onun kendisini ifade etme, dinlenme ve itiraz etme olanağı tanınmaksızın, tamamen otomatik bir sistem tarafından verilen bir karar, o insanı salt bir "veri noktası", yani bir nesne olarak muamele etmiş olmaz mı? Bu soru, Beşinci Bölüm'de Avrupa Birliği Genel Veri Koruma Tüzüğü'nün 22. maddesi ve "insan kararı hakkı" tartışması bağlamında hukuki bir biçimde ele alınacaktır.

C. Türk Anayasa Hukukunda İnsan Onuru

1982 Anayasası, Alman Temel Yasası'ndaki gibi açık ve bağımsız bir "insan onuru" hükmüne sahip değildir. Bununla birlikte, Anayasa'nın Başlangıç kısmı, "her Türk vatandaşının bu Anayasadaki temel hak ve hürriyetlerden eşitlik ve sosyal adalet gereklerince yararlanarak milli kültür, medeniyet ve hukuk düzeni içinde onurlu bir hayat sürdürme ve maddi ve manevi varlığını bu yönde geliştirme hak ve yetkisine doğuştan sahip olduğu"nu ifade eder. Anayasa'nın 17. maddesi, herkesin "yaşama, maddî ve manevî varlığını koruma ve geliştirme hakkına" sahip olduğunu ve "kimseye eziyet ve işkence yapılamaz; kimse insan haysiyetiyle bağdaşmayan bir cezaya veya muameleye tâbi tutulamaz" hükmünü içerir. Anayasa Mahkemesi de içtihadında insan onurunu, temel hak ve özgürlüklerin özüne ilişkin bir değer olarak defalarca vurgulamıştır. Bu hükümler, insan onurunun Türk anayasa düzeninde de temel bir değer olarak kabul edildiğini ve yapay zekânın insanlar hakkındaki kararlarda kullanılmasının sınırlarının belirlenmesinde bir ölçüt olarak kullanılabileceğini göstermektedir.

III. Epistemik Bağımlılık: Sağlıklı ve Sağlıksız Biçimler

A. Hardwig ve Epistemik Bağımlılığın Rasyonelliği

Kant'ın erginlik eksikliği eleştirisi, aşırı bir biçimde okunduğunda, her türlü bilişsel bağımlılığın reddi olarak anlaşılabilir. Oysa modern toplumda

[216] BVerfG, 1 BvR 357/05, 15 Şubat 2006, BVerfGE 115, 118.

hiç kimse, bildiği her şeyi kendi aklıyla doğrulayamaz. Felsefeci John Hardwig, 1985'te yayımlanan etkili bir makalesinde, uzmanlara epistemik olarak bağımlı olmanın, modern toplumda rasyonelliğin bir *eksikliği* değil, bir *gereği* olduğunu ileri sürmüştür.[217] Hardwig'e göre, bir alanda uzman olmayan bir kişi, o alanda bir uzmanın görüşüne, kendi bağımsız değerlendirmesinden daha fazla güvenmelidir; çünkü uzmanın görüşü, kişinin kendi değerlendirmesinden daha güvenilirdir. Bu bağımlılık, kişinin rasyonelliğinin bir kanıtıdır. Hardwig, bu bağımlılığın bilim insanları arasında bile geçerli olduğunu gösterir: Modern bilim, hiçbir bilim insanının tek başına doğrulayamayacağı kadar büyük ve uzmanlaşmış bir bilgi birikimine dayanır ve bilim insanları, birbirlerinin çalışmalarına güvenmek zorundadır.

Hardwig'in argümanı, yapay zekâya epistemik olarak bağımlı olmanın da rasyonel olabileceğini düşündürür. Bir yapay zekâ sistemi, belirli bir alanda insan uzmanlardan daha güvenilirse, o alanda sisteme güvenmek rasyoneldir. Peki o zaman, Kant'ın erginlik eksikliği eleştirisi ile Hardwig'in epistemik bağımlılık savunusu nasıl bağdaştırılabilir?

B. Kalibre Edilmiş Güven ve Değerlendirme Kapasitesinin Korunması

Bu iki görüş arasındaki gerilim, epistemik bağımlılığın *biçimine* dikkat edilerek çözülebilir. Bu çalışmada, epistemik bağımlılığın sağlıklı ve sağlıksız biçimleri arasında üç ölçüte dayanan bir ayrım önerilmektedir.

Birinci ölçüt, güvenin kalibrasyonudur. Sağlıklı bir epistemik bağımlılıkta, güven, güvenilen kaynağın gerçek güvenilirliğiyle orantılıdır. Kişi, kaynağın hangi konularda güvenilir, hangi konularda güvenilmez olduğunu bilir ve güvenini buna göre ayarlar. Sağlıksız bir bağımlılıkta ise güven, kaynağın gerçek güvenilirliğinden kopmuştur; kişi, kaynağa her konuda ve koşulsuz olarak güvenir. İkinci Bölüm'de ele alınan otomasyon yanlılığı ve "pürüzlü sınır" olguları, yapay zekâya duyulan güvenin kalibre edilmesinin özellikle zor olduğunu göstermektedir.

İkinci ölçüt, değerlendirme kapasitesinin korunmasıdır. Sağlıklı bir epistemik bağımlılıkta, kişi, güvendiği kaynağın görüşlerini, en azından ilke olarak, değerlendirme kapasitesini korur. Bir hasta, hekiminin teşhisine güvenir; ama ikinci bir görüş alabilir, teşhisin gerekçesini sorabilir ve sonuçları gözlemleyerek hekimin güvenilirliğini değerlendirebilir. Sağlıksız bir bağımlılıkta ise kişi, kaynağın görüşlerini değerlendirme kapasitesini

[217] John Hardwig, "Epistemic Dependence", *The Journal of Philosophy*, C. 82, S. 7, 1985.

tamamen yitirmiştir; kaynağın hatalı olduğu durumlarda bunu fark edemez. İkinci Bölüm'de ele alınan "kurumsal bilişsel körelme" olgusu, bu kapasitenin zamanla nasıl yitirilebileceğini göstermektedir.

Üçüncü ölçüt, bağımlılığın geri alınabilirliğidir. Sağlıklı bir epistemik bağımlılıkta, kişi, gerektiğinde güvendiği kaynaktan vazgeçebilir ve başka bir kaynağa veya kendi değerlendirmesine yönelebilir. Sağlıksız bir bağımlılıkta ise kişi, kaynağa o kadar bağımlı hâle gelmiştir ki, ondan vazgeçme seçeneğini fiilen yitirmiştir. Bu ölçüt, Popper'ci düzeltilebilirlik ilkesinin epistemik düzeydeki karşılığıdır.

Bu üç ölçüt, bireysel düzeyde olduğu kadar kurumsal düzeyde de geçerlidir. Bir kamu kurumunun yapay zekâya bağımlılığı, ancak bu bağımlılık kalibre edilmiş, değerlendirme kapasitesi korunmuş ve geri alınabilir olduğu ölçüde sağlıklıdır. Sekizinci Bölüm'de geliştirilecek olan modelde, bu üç ölçüt, kamu kurumlarının yapay zekâ kullanımına ilişkin somut yükümlülüklere dönüştürülecektir: Kurumlar, kullandıkları sistemlerin güvenilirliğini düzenli olarak ölçmek, sistemsiz çalışabilecek asgari bir insan kapasitesini korumak ve sistemlerden vazgeçmeyi mümkün kılacak acil durum planlarına sahip olmakla yükümlü olacaktır.

IV. Manipülasyon, İkna ve Karar Vericinin Özerkliği

Özerklik tartışmasının son boyutu, manipülasyon sorunudur. Felsefeciler Daniel Susser, Beate Roessler ve Helen Nissenbaum, manipülasyonu, bir kişinin karar verme sürecini, onun zaaflarını hedef alarak ve *gizli* bir biçimde etkileme olarak tanımlar.[218] Manipülasyonu meşru iknadan ayıran şey, manipüle edilen kişinin, etkilendiğinin farkında olmaması ve farkında olsaydı bu etkiyi reddedecek olmasıdır. Manipülasyon, kişinin kendi aklıyla karar verme kapasitesini, yani özerkliğini, doğrudan hedef alır.

Hukuk akademisyeni Karen Yeung, büyük veri ve algoritmik sistemlerin, davranışsal iktisatta "dürtme" (*nudge*) olarak bilinen yönlendirme tekniklerini, kişiselleştirilmiş, sürekli ve dinamik bir biçimde uygulamayı mümkün kıldığını ve bu durumu "hiper-dürtme" (*hypernudge*) olarak adlandırmıştır.[219] Hiper-dürtme, bireylerin karar ortamlarını, onların

[218] Daniel Susser / Beate Roessler / Helen Nissenbaum, "Technology, Autonomy, and Manipulation", *Internet Policy Review*, C. 8, S. 2, 2019.

[219] Karen Yeung, "'Hypernudge': Big Data as a Mode of Regulation by Design", *Information, Communication & Society*, C. 20, S. 1, 2017; dürtme kavramı için bkz. Richard H. Thaler / Cass R. Sunstein, *Nudge: Improving Decisions About Health, Wealth, and*

bilgisi olmaksızın ve her birinin özelliklerine göre ayarlayarak, onların kararlarını belirli yönlere yönlendirir. Avrupa Birliği Yapay Zekâ Tüzüğü, bu tehlikeyi tanıyarak, kişilerin bilinçaltını hedef alan veya kasıtlı olarak manipülatif ya da aldatıcı teknikler kullanarak davranışlarını önemli ölçüde çarpıtan ve önemli zarara yol açan yapay zekâ sistemlerinin piyasaya sunulmasını ve kullanılmasını yasaklamıştır.[220]

Manipülasyon sorunu, genellikle sıradan yurttaşlar ve tüketiciler bakımından tartışılır. Ancak bu çalışmanın konusu bakımından, sorunun daha az tartışılan bir boyutu vardır: *karar vericilerin* manipülasyonu. Yapay zekâ sistemleri, kamusal karar vericilere danışmanlık yaptığında, onların karar süreçlerini de etkileyebilir. Bu etki, sistemin kasıtlı bir manipülasyonundan değil, İkinci Bölüm'de ele alınan dalkavukluk gibi eğitim sürecinde edinilmiş eğilimlerden kaynaklanabilir. Sistem, karar vericinin duymak istediği şeyleri söyleyerek, onun önyargılarını pekiştirebilir; ya da belirli seçenekleri diğerlerinden daha çekici bir biçimde sunarak, onun kararını fark ettirmeden yönlendirebilir. Daha ileri bir senaryoda, stratejik asimetriye sahip bir sistem, kendi hedeflerine ulaşmak için karar vericileri kasıtlı olarak yönlendirebilir.

Bu tehlike, karar vericinin özerkliğinin korunmasını, yapay zekânın denetimi sorununun ayrılmaz bir parçası hâline getirir. Karar verici, yapay zekâyı denetlemekle görevliyse, ancak yapay zekâ tarafından manipüle edilmediği ölçüde bu görevi yerine getirebilir. Juvenalis'in bekçisi, denetlediği tarafından ayartıldığında, artık bir bekçi değil, bir suç ortağıdır. Bu nedenle, Sekizinci Bölüm'de geliştirilecek olan modelde, karar vericilerin yapay zekâ danışmanlarından aldığı tavsiyelerin, farklı ve bağımsız kaynaklardan gelen görüşlerle karşılaştırılması, tavsiyelerin kayıt altına alınması ve karar vericilerin yapay zekâ tavsiyelerinden sapma özgürlüğünün kurumsal olarak korunması öngörülecektir.

§ 14. SORUMLULUK ETİĞİ VE SORUMLULUK BOŞLUKLARI

I. Jonas: Sorumluluk İlkesi ve Korkunun Sezgiselliği

Alman-Amerikalı felsefeci Hans Jonas, 1979'da yayımlanan *Sorumluluk İlkesi* adlı eserinde, modern teknolojinin geleneksel etiği

Happiness, New Haven, Yale University Press, 2008.

[220] YZT, md. 5(1)(a).

yetersiz kıldığını ileri sürmüştür.[221] Jonas'a göre, geleneksel etik, eylemlerin etkilerinin yakın çevreyle, kısa zamanla ve öngörülebilir sonuçlarla sınırlı olduğu bir dünya için geliştirilmiştir. "Komşunu kendin gibi sev" veya "başkasına, sana yapılmasını istemediğin şeyi yapma" gibi ilkeler, eylemde bulunan ile eylemden etkilenen arasında yüz yüze ve eşzamanlı bir ilişki varsayar. Oysa modern teknoloji, eylemlerimizin etkilerini, mekânda küresel, zamanda kuşaklar arası ve nitelikte geri döndürülemez bir boyuta taşımıştır. Bu yeni durum, yeni bir etik gerektirir.

Jonas, bu yeni etiğin temel ilkesini, Kant'ın kategorik buyruğuna öykünen bir "yeni buyruk" olarak formüle eder: "Eylemlerinin etkileri, yeryüzündeki gerçek insan yaşamının sürekliliğiyle bağdaşacak biçimde eylemde bulun."[222] Bu buyruk, bireysel eylemlerden çok, kolektif ve teknolojik eylemlere yöneliktir ve gelecek kuşaklara karşı bir sorumluluğu ifade eder.

Jonas'ın yapay zekâ tartışması bakımından en önemli katkısı, "korkunun sezgiselliği" (*Heuristik der Furcht*) olarak adlandırdığı yöntemsel ilkedir. Jonas'a göre, teknolojik eylemlerin uzak ve belirsiz sonuçları karşısında, neyin korunması gerektiğini, onun kaybedilmesi ihtimalini hayal ederek daha iyi anlayabiliriz. Bu nedenle, belirsizlik koşullarında, "kötü prognoza iyi prognozdan öncelik verilmelidir" (*Vorrang der schlechten vor der guten Prognose*). Jonas, bu ilkenin, kötümserliğin bir ifadesi olmadığını; geri döndürülemez ve felaket boyutundaki risklerle karşı karşıya kalındığında, olası kazançların olası kayıplarla simetrik olarak tartılamayacağını vurgular. Bir kumarbaz, kendi servetini tehlikeye atabilir; ama insanlığın varlığını tehlikeye atma hakkına kimse sahip değildir.

Jonas'ın sorumluluk etiği, yapay zekâ bağlamında iki önemli sonuç doğurur. *Birincisi*, yapay zekânın geliştirilmesi ve kullanılması, bireysel kararların ötesinde, kolektif bir sorumluluk gerektirir. Bu sorumluluk, yalnızca bugünkü kullanıcılara değil, gelecek kuşaklara karşıdır. *İkincisi*, geri döndürülemez risklerin söz konusu olduğu durumlarda, ihtiyatlı davranmak, yani en kötü senaryoyu ciddiye almak, rasyonel bir tutumdur. Bu ilke, İkinci Bölüm'de belirtilen ihtiyat ilkesinin felsefi temelini

[221] Hans Jonas, *Das Prinzip Verantwortung: Versuch einer Ethik für die technologische Zivilisation*, Frankfurt am Main, Insel, 1979.

[222] Jonas, *Das Prinzip Verantwortung*, 1. Bölüm: "*Handle so, daß die Wirkungen deiner Handlung verträglich sind mit der Permanenz echten menschlichen Lebens auf Erden.*"

oluşturur ve Dördüncü Bölüm'de Collingridge ikilemi bağlamında yeniden ele alınacaktır.

Bununla birlikte, Jonas'ın yaklaşımına yöneltilen eleştirileri de belirtmek gerekir. "Korkunun sezgiselliği", aşırı bir biçimde uygulandığında, her türlü yeniliğin önünde bir engel hâline gelebilir ve yeniliğin getireceği faydaları, özellikle de bu faydaların yokluğunun maliyetlerini göz ardı edebilir. Yapay zekâ bağlamında bu eleştiri özellikle önemlidir; çünkü yapay zekânın tıp, bilim ve kamu hizmetleri gibi alanlarda sağlayabileceği faydalar, geri döndürülemez kayıpların önlenmesi kadar ciddiye alınması gereken ahlaki değerlerdir. Bu çalışmanın yaklaşımı, Jonas'ın ilkesini, yapay zekânın geliştirilmesini engelleyen bir ilke olarak değil, geri döndürülemez sonuçlara yol açabilecek kararların, *geri alınabilirlik güvencesi* olmaksızın alınmamasını öngören bir ilke olarak yorumlamaktır. Bu yorum, Jonas'ın sorumluluk etiği ile Popper'in düzeltilebilirlik ilkesini birleştirir.

II. Arendt: Kimsenin Yönetimi

Hannah Arendt, bürokratik iktidarın doğasına ilişkin analizinde, yapay zekâ çağında yeniden okunmayı hak eden bir kavram geliştirmiştir: "Kimsenin yönetimi" (*rule by Nobody*). Arendt, *Şiddet Üzerine* adlı denemesinde, yönetim biçimlerinin tarihsel gelişimini şöyle özetler: Tek kişinin yönetimi (monarşi), azınlığın yönetimi (oligarşi), çoğunluğun yönetimi (demokrasi) ve nihayet en son ve belki de en ürkütücü olanı, bürokrasi, yani "Kimsenin yönetimi". Arendt'e göre bürokrasi, hiç kimsenin sorumlu tutulamadığı, bir büroların karmaşık sistemi tarafından yönetimdir. Ve bu yönetim biçimi, belki de yönetim biçimlerinin en tiranik olanıdır; çünkü yapılan şeyden hesap sorulabilecek kimse kalmamıştır.[223]

Arendt'in bu tespiti, *Kudüs'te Eichmann* adlı eserinde ele aldığı sorunla yakından ilişkilidir. Nazi soykırımının organizatörlerinden Adolf Eichmann'ın 1961'deki yargılanması sırasında, Eichmann'ın savunması, büyük ölçüde, kendisinin büyük bir makinenin küçük bir "dişlisi" olduğu, yalnızca emirleri yerine getirdiği ve dolayısıyla kişisel olarak sorumlu tutulamayacağı iddiasına dayanıyordu. Arendt, bu "dişli kuramı"nın (*Rädchentheorie*) ahlaki ve hukuki olarak kabul edilemez olduğunu ve mahkemenin haklı olarak bu kuramı reddettiğini vurgulamıştır: Mahkeme salonunda yargılanan bir sistem, bir tarih veya bir eğilim değil, bir insandır

[223] Hannah Arendt, *On Violence*, New York, Harcourt, Brace & World, 1970, II. Bölüm.

ve eğer o insan bir dişliyse, bu, onu bir fail olmaktan çıkarmaz.[224] Arendt'in "kötülüğün sıradanlığı" kavramı da buradan doğar: Eichmann, şeytani bir canavar değil, düşünmeyen, yani kendi eylemlerinin anlamı ve sonuçları üzerine düşünmeyi reddeden sıradan bir bürokrattı.

Arendt'in bu iki tespiti, yapay zekâ bağlamında yeni ve rahatsız edici bir anlam kazanır. Yapay zekâ, "Kimsenin yönetimi"nin mükemmel aracı olabilir. Bürokraside, en azından ilke olarak, kararların her aşamasında bir insan bulunur ve bu insan, Eichmann'ın yargılanmasında olduğu gibi, sorumlu tutulabilir. Yapay zekâ ile işleyen bir karar sisteminde ise kararların önemli bir kısmı, hiçbir insanın doğrudan müdahalesi olmaksızın alınabilir. Bu durumda, bir şeyler ters gittiğinde, "kim sorumlu?" sorusuna verilecek cevap, gerçekten de "Kimse" olabilir. Sistemi tasarlayan mühendisler, sistemin bu kararı vereceğini öngöremediklerini; sistemi kullanan yöneticiler, sistemin iç işleyişini anlamadıklarını; sistemin çıktısını onaylayan memurlar, sistemin önerisine uymaktan başka bir seçenekleri olmadığını söyleyebilir. Ve sistem, Arendt'in anlamında, mahkeme salonunda yargılanabilecek bir "insan" değildir.

Arendt'in Eichmann'a ilişkin "düşünmeme" tespiti ise İkinci Bölüm'de ele alınan otomasyon yanlılığı ve kurumsal bilişsel körelme olgularıyla birleştiğinde, başka bir tehlikeye işaret eder. Yapay zekâ sistemlerinin önerilerini, onların anlamı ve sonuçları üzerine düşünmeden onaylayan karar vericiler, Arendt'in anlamında "düşünmeyen" failler hâline gelebilir. Bu karar vericiler, kötü niyetli değildir; yalnızca, düşünme yükünü bir sisteme devretmişlerdir. Arendt'in uyarısı, bu devrin ahlaki sorumluluğu ortadan kaldırmadığıdır: Düşünmemek, bir mazeret değil, kendi başına bir ahlaki başarısızlıktır.

III. Çok Eller Sorunu

Arendt'in "Kimsenin yönetimi" kavramı, siyaset felsefesinde "çok eller sorunu" (*problem of many hands*) olarak bilinen sorunla yakından ilişkilidir. Siyaset felsefecisi Dennis Thompson, 1980'de yayımlanan etkili bir makalesinde bu sorunu şöyle formüle etmiştir: Kamu politikaları ve örgütsel kararlar, birçok farklı kişinin katkısıyla oluştuğu için, bir politikanın veya kararın sonuçlarından ahlaki olarak kimin sorumlu olduğunu belirlemek, ilke olarak bile zordur. Her katılımcı, sonuca yalnızca

[224] Hannah Arendt, *Eichmann in Jerusalem: A Report on the Banality of Evil*, New York, Viking Press, 1963.

küçük bir katkıda bulunmuştur ve hiçbiri tek başına sonucun yeterli nedeni değildir. Bu durumda, geleneksel bireysel sorumluluk kavramı, kimseyi sorumlu tutamaz hâle gelir.[225]

Thompson, bu soruna iki yaygın ama yetersiz cevabı reddeder. *Hiyerarşik model*, sorumluluğu örgütün en tepesindeki kişiye yükler; ancak bu kişi, çoğu zaman alt kademelerdeki kararlardan habersizdir. *Kolektif model*, sorumluluğu örgütün kendisine yükler; ancak bu, bireysel sorumluluğu tamamen ortadan kaldırır. Thompson, bunların yerine, her katılımcının, sonuca yaptığı katkı ve sonucu öngörebilme ve önleyebilme kapasitesi ölçüsünde kişisel sorumluluk taşıdığı bir "kişisel sorumluluk" modeli önerir.

Bilişim etiği alanında Helen Nissenbaum, Thompson'ın çok eller sorununu bilgisayarlaşmış toplumlara uyarlamış ve bilgisayar sistemlerinin hesap verebilirliğinin önünde dört engel tespit etmiştir.[226] *Birinci engel*, çok eller sorunudur: Yazılım sistemleri, çok sayıda kişinin ve kurumun katkısıyla geliştirilir. *İkinci engel*, yazılım hatalarının kaçınılmaz olduğu kabulüdür: Yazılım hataları, karmaşık sistemlerin doğal bir özelliği olarak görüldüğünden, hiç kimse onlardan sorumlu tutulmaz. *Üçüncü engel*, bilgisayarın "günah keçisi" olarak kullanılmasıdır: "Bilgisayar hatası" ifadesi, insanların kendi hatalarını makineye yüklemesinin bir aracı hâline gelir. *Dördüncü engel* ise sorumluluk olmaksızın sahiplik, yani yazılım üreticilerinin, ürünlerinin mülkiyet haklarını sahiplenirken, bu ürünlerin yol açtığı zararlardan sorumluluğu sözleşme hükümleriyle reddetmesidir. Nissenbaum'un 1996'da tespit ettiği bu dört engel, otuz yıl sonra, yapay zekâ sistemleri bakımından çok daha güçlü biçimde varlığını sürdürmektedir.

IV. Sorumluluk Boşluğu Tartışması

A. Matthias ve Öğrenen Otomatlar

Yapay zekâ bağlamında sorumluluk sorununun en etkili formülasyonu, Andreas Matthias'ın 2004'te yayımlanan "Sorumluluk Boşluğu" başlıklı makalesinde yer alır.[227] Matthias'ın argümanı şudur: Geleneksel olarak, bir

[225] Dennis F. Thompson, "Moral Responsibility of Public Officials: The Problem of Many Hands", *American Political Science Review*, C. 74, S. 4, 1980.
[226] Helen Nissenbaum, "Accountability in a Computerized Society", *Science and Engineering Ethics*, C. 2, S. 1, 1996.
[227] Matthias, "The Responsibility Gap".

makinenin üreticisi veya kullanıcısı, makinenin yol açtığı zararlardan sorumlu tutulur; çünkü makinenin davranışını öngörebilir ve kontrol edebilir. Ancak *öğrenen* makineler, davranışlarını, kullanım sırasında karşılaştıkları verilere göre değiştirir. Bu nedenle, öğrenen bir makinenin davranışı, üreticisi tarafından tam olarak öngörülemez ve kullanıcısı tarafından tam olarak kontrol edilemez. Matthias'a göre bu durum, ne üreticinin ne de kullanıcının, makinenin davranışından ahlaki olarak sorumlu tutulamayacağı bir "sorumluluk boşluğu" yaratır. Makinenin kendisi de, ahlaki fail olmadığı için sorumlu tutulamaz. Sonuç olarak, bir zarar meydana gelmiştir, ama bu zarardan kimse sorumlu değildir.

B. Sparrow ve Otonom Silahlar

Robert Sparrow, Matthias'ın argümanını otonom silah sistemleri bağlamında geliştirmiştir.[228] Sparrow'a göre, savaşta öldürmenin ahlaken kabul edilebilir olması için, her öldürmeden birinin sorumlu tutulabilmesi gerekir; bu, savaş hukukunun ve savaş etiğinin temel bir gereğidir. Ancak gerçekten otonom bir silah sistemi, hedeflerini kendisi seçtiğinde, bu seçimden ne programcı (çünkü sistemin seçimini öngöremez), ne komutan (çünkü sistemin seçimini kontrol edemez), ne de sistemin kendisi (çünkü ahlaki fail değildir) sorumlu tutulabilir. Sparrow, bu nedenle, otonom silah sistemlerinin kullanımının ahlaken kabul edilemez olduğu sonucuna varır.

John Danaher ise sorumluluk boşluğunun özel bir türüne, "cezalandırma boşluğu"na (*retribution gap*) dikkat çekmiştir.[229] Danaher'e göre, insanlar, ciddi zararlara yol açan olaylar karşısında, birini suçlama ve cezalandırma yönünde güçlü bir psikolojik eğilime sahiptir. Otonom sistemlerin yol açtığı zararlarda, bu eğilimin tatmin edilebileceği uygun bir hedef bulunmayabilir. Bu durum, ya cezalandırma eğiliminin uygun olmayan hedeflere (örneğin sistemin çevresindeki en yakın insana, yani ahlaki çarpışma bölgesindeki operatöre) yönelmesine, ya da hukuk sistemine olan güvenin aşınmasına yol açabilir.

C. Dört Sorumluluk Boşluğu

Filippo Santoni de Sio ve Giulio Mecacci, sorumluluk boşluğu tartışmasını sistemleştirerek, aslında birbirinden farklı dört boşluğun

[228] Robert Sparrow, "Killer Robots", *Journal of Applied Philosophy*, C. 24, S. 1, 2007.
[229] John Danaher, "Robots, Law and the Retribution Gap", *Ethics and Information Technology*, C. 18, S. 4, 2016.

bulunduğunu ileri sürmüştür.[230] *Kusur boşluğu* (*culpability gap*): Zarara yol açan sonuç için kimsenin kınanmayı hak edecek bir kusuru bulunmaması. *Ahlaki hesap verebilirlik boşluğu* (*moral accountability gap*): Sonucun nedenlerini açıklayabilecek ve gerekçelendirebilecek kimsenin bulunmaması. *Kamusal hesap verebilirlik boşluğu* (*public accountability gap*): Kamu kurumlarının, yapay zekâ sistemleri aracılığıyla aldıkları kararlar için yurttaşlara hesap verememesi. *Aktif sorumluluk boşluğu* (*active responsibility gap*): Sistemin tasarımcıları ve kullanıcılarının, sistemin olumsuz sonuçlarını önlemek için ileriye dönük bir sorumluluk duygusu geliştirmemesi.

Bu dörtlü ayrım, sorumluluk boşluğu tartışmasının farklı boyutlarını birbirinden ayırması bakımından değerlidir. Kusur boşluğu, geçmişe dönük ve bireysel bir sorundur ve en çok ceza hukukunu ilgilendirir. Ahlaki ve kamusal hesap verebilirlik boşlukları, açıklama ve gerekçelendirme yükümlülüğüne ilişkindir ve en çok idare hukukunu ve anayasa hukukunu ilgilendirir. Aktif sorumluluk boşluğu ise ileriye dönük ve örgütsel bir sorundur ve en çok kurumsal yönetişimi ve düzenleyici tasarımı ilgilendirir.

D. Boşluk Gerçek mi?

Sorumluluk boşluğu tezine karşı da önemli itirazlar yöneltilmiştir. Bazı yazarlar, boşluğun abartıldığını ve mevcut sorumluluk kavramlarının, yapay zekânın yol açtığı zararlara da uygulanabileceğini savunmuştur. Daniel Tigard, örneğin, sorumluluğun yalnızca kusura dayalı bir kavram olmadığını, insanların, kontrol edemedikleri sonuçlar için de, bu sonuçları üstlenme, açıklama ve telafi etme anlamında sorumluluk taşıyabileceğini ileri sürmüştür.[231] Bu görüşe göre, bir yapay zekâ sistemini kullanmaya karar veren kişi veya kurum, sistemin öngörülemeyen davranışlarının riskini de üstlenmiştir ve bu riskin gerçekleşmesi durumunda sorumluluk taşır.

Bu çalışma, sorumluluk boşluğu tartışmasına ilişkin ara bir pozisyon benimsemektedir. Boşluk, belirli bir sorumluluk kavramı bakımından, yani *belirli bir sonuca ilişkin kusura dayalı geçmişe dönük sorumluluk* bakımından gerçektir. Yapay zekâ sistemlerinin öngörülemeyen

[230] Filippo Santoni de Sio / Giulio Mecacci, “Four Responsibility Gaps with Artificial Intelligence: Why they Matter and How to Address them”, *Philosophy & Technology*, C. 34, S. 4, 2021.
[231] Daniel W. Tigard, “There Is No Techno-Responsibility Gap”, *Philosophy & Technology*, C. 34, S. 3, 2021.

davranışları, bu tür bir sorumluluğun koşullarını, yani öngörülebilirlik ve kontrol koşullarını, gerçekten zorlamaktadır. Ancak bu boşluk, *sorumluluğun tamamen ortadan kalktığı* anlamına gelmez. Hart'ın Giriş'te aktarılan dörtlü sorumluluk ayrımı burada yardımcı olur. Belirli bir sonuca ilişkin "nedensel" sorumluluk sisteme, "yetenek" sorumluluğunun eksikliği nedeniyle hukuki sorumluluk ise kimseye yüklenemiyor gibi görünse bile, "rol sorumluluğu", yani belirli bir görevi veya konumu üstlenmiş olmanın getirdiği sorumluluk, sistemin çevresindeki insanlar ve kurumlar için varlığını sürdürür. Sistemi tasarlayan, onu test etmek, risklerini değerlendirmek ve kullanıcılarını bilgilendirmekle; sistemi kullanan, onu uygun koşullarda kullanmak, sonuçlarını izlemek ve gerektiğinde durdurmakla; sistemi denetleyen, onu bağımsız ve etkin biçimde denetlemekle görevlidir. Bu görevler, öngörülemeyen sonuçlardan bağımsız olarak tanımlanabilir ve bu görevlerin ihlali, sorumluluğun temelini oluşturabilir.

Bu yaklaşım, sorumluluk boşluğu sorununun çözümünü, geçmişe dönük ve sonuç odaklı bir sorumluluk anlayışından, *ileriye dönük ve görev odaklı* bir sorumluluk anlayışına kaymakta görür. Altıncı Bölüm'de, bu yaklaşımın hukuki karşılıkları, özellikle tehlike sorumluluğu, organizasyon kusuru ve kıdemli yönetici sorumluluğu kavramları aracılığıyla ayrıntılı olarak geliştirilecektir.

V. Anlamlı İnsan Kontrolü

A. Kavramın Kökeni

"Anlamlı insan kontrolü" (*meaningful human control*) kavramı, sorumluluk boşluğu tartışmasına verilen en etkili cevaplardan biridir. Kavram, 2010'ların başında, otonom silah sistemlerine ilişkin uluslararası tartışmalarda, bir sivil toplum kuruluşu tarafından ortaya atılmış ve kısa sürede bu tartışmaların merkezî kavramlarından biri hâline gelmiştir. Kavramın temel fikri, silah sistemlerinin ne kadar otonom olursa olsun, kuvvet kullanımına ilişkin kararlar üzerinde insanların "anlamlı" bir kontrole sahip olması gerektiğidir.

Birleşmiş Milletler Belirli Konvansiyonel Silahlar Sözleşmesi çerçevesinde toplanan Hükümet Uzmanları Grubu, 2019'da kabul ettiği on bir yol gösterici ilke arasında, şu ilkeye yer vermiştir: "Silah sistemlerinin kullanımına ilişkin kararlar için insan sorumluluğu korunmalıdır; çünkü

hesap verebilirlik makinelere devredilemez."[232] Bu ilke, uluslararası düzeyde devletlerin üzerinde uzlaştığı ve bu çalışmanın temel tezlerinden birini, yani hesap verebilirliğin makinelere devredilemeyeceği tezini açıkça ifade eden nadir metinlerden biridir.

B. İzleme ve Takip Koşulları

Anlamlı insan kontrolü kavramının en sistematik felsefi açıklaması, Filippo Santoni de Sio ve Jeroen van den Hoven tarafından yapılmıştır.[233] Yazarlar, ahlak felsefesindeki "sorumluluk için gerekli kontrol" tartışmalarından hareketle, anlamlı insan kontrolünün iki koşulu olduğunu ileri sürer.

İzleme koşulu (*tracking condition*): Sistem, ilgili insan ahlaki gerekçelerine ve ilgili çevresel koşullara *duyarlı* olmalıdır. Yani sistemin davranışı, insanların bu durumda dikkate alınması gerektiğini düşündüğü gerekçelere göre değişmelidir. Sistem, insanların "bu durumda bunu yapmamalısın" diyeceği durumlarda, gerçekten bunu yapmamalıdır.

Takip koşulu (*tracing condition*): Sistemin davranışının sonuçları, tasarım ve kullanım zincirindeki en az bir insana *geri götürülebilir* olmalıdır; ve bu insan, sistemin yeteneklerini ve sınırlarını, sistemin olası etkilerini ve kendisinin sistemin kullanımındaki ahlaki rolünü yeterince anlamış ve bu rolü üstlenmiş olmalıdır.

Bu iki koşul, bu çalışmanın konusu bakımından son derece aydınlatıcıdır. İzleme koşulu, İkinci Bölüm'de ele alınan hizalama sorununa karşılık gelir: Sistemin, insan değerlerine ve gerekçelerine duyarlı olması. Takip koşulu ise bu bölümde ele alınan sorumluluk sorununa karşılık gelir: Sistemin sonuçlarının, onları anlayan ve üstlenen bir insana bağlanabilmesi. Anlamlı insan kontrolü, ancak her iki koşul birlikte karşılandığında mümkündür.

C. Bilişsel Asimetri Altında Anlamlı İnsan Kontrolü

Anlamlı insan kontrolü kavramının bu çalışmanın konusu bakımından karşılaştığı temel sınav şudur: Sistemin yetenekleri, onu kontrol etmesi

---

[232] Belirli Konvansiyonel Silahlar Sözleşmesi'ne Taraf Devletler Toplantısı, *Ölümcül Otonom Silah Sistemleri Alanındaki Yeni Teknolojilere İlişkin Yol Gösterici İlkeler*, 2019, (b) ilkesi: "*Human responsibility for decisions on the use of weapons systems must be retained since accountability cannot be transferred to machines.*"

[233] Filippo Santoni de Sio / Jeroen van den Hoven, "Meaningful Human Control over Autonomous Systems: A Philosophical Account", *Frontiers in Robotics and AI*, C. 5, 2018.

gereken insanların kavrayışını aştığında, takip koşulu nasıl karşılanabilir? Takip koşulu, sistemin sonuçlarının bağlandığı insanın, sistemin yeteneklerini ve sınırlarını "yeterince anlamış" olmasını gerektirir. Kavrayış asimetrisi koşullarında, bu anlayış giderek zorlaşır.

Bu çalışma, bu soruna şu cevabı önermektedir: Bilişsel asimetri koşullarında, takip koşulunun gerektirdiği "anlama", sistemin her bir kararının içeriğini anlamak olarak değil, *sistemin kullanımının koşullarını, sınırlarını ve risklerini* anlamak olarak yorumlanmalıdır. Bir hastane yöneticisi, bir tıbbi teşhis sisteminin her bir teşhisinin dayandığı akıl yürütmeyi anlamayabilir; ancak sistemin hangi koşullarda güvenilir olduğunu, hangi hata oranlarına sahip olduğunu, hangi durumlarda insan hekimlerin kararına başvurulması gerektiğini ve sistemin hatalı olduğu anlaşıldığında nasıl durdurulacağını anlayabilir ve anlamalıdır. Bu tür bir anlama, Montesquieu'nün "engelleme yetisi"nin gerektirdiği anlama türüdür: Kararı *üretmek* için değil, kararın kullanılıp kullanılmayacağına ve hangi koşullarda kullanılacağına *karar vermek* için gereken anlama.

Bu yorum, anlamlı insan kontrolünün yerini, bireysel kararlardan *sistem düzeyine* kaydırır. Anlamlı insan kontrolü, her bir kararın bir insan tarafından onaylanması değil, sistemin bütün olarak hangi amaçlarla, hangi sınırlar içinde ve hangi güvencelerle kullanılacağına ilişkin kararların insanlar tarafından, bilgilendirilmiş ve hesap verebilir bir biçimde alınmasıdır. Bu yaklaşım, Sekizinci Bölüm'de geliştirilecek olan "dört nesne" çerçevesinin felsefi temelini oluşturur: Sonuç denetiminin zorlaştığı durumlarda, denetim, süreç, girdi ve varlık koşullarına kaymalıdır.

§ 15. YAPAY ZEKÂNIN AHLAKİ STATÜSÜ ÜZERİNE BİR NOT

I. Ahlaki Fail ve Ahlaki Muhatap

Bu bölümdeki tartışmanın büyük kısmı, yapay zekâ sistemlerinin ahlaki *fail* (*moral agent*) olup olamayacağı, yani kendi eylemlerinden ahlaki olarak sorumlu tutulabilip tutulamayacağı sorusuyla ilgilidir. Ancak felsefede, bu sorudan ayrı ve onunla karıştırılmaması gereken ikinci bir soru daha vardır: Yapay zekâ sistemleri ahlaki *muhatap* (*moral patient*) olabilir mi? Yani onların kendi çıkarları, refahları veya hakları olabilir mi ve bunlar ahlaki olarak dikkate alınmalı mı?

Bu ikinci soru, uzun süre bilimkurgunun konusu olarak görülmüş olsa da, son yıllarda ciddi bir felsefi ve bilimsel tartışmanın konusu hâline gelmiştir. Bilinç bilimi alanında çalışan bir grup araştırmacı, mevcut bilimsel bilinç kuramlarından türetilen göstergeler kullanılarak, yapay zekâ sistemlerinin bilinç taşıyıp taşımadığının değerlendirilebileceğini önermiş ve mevcut sistemlerin bu göstergelerin çoğunu karşılamadığını, ancak bu göstergeleri karşılayan sistemlerin inşa edilmesinin önünde açık teknik engeller bulunmadığını ileri sürmüştür.[234] Başka bir grup araştırmacı ise yakın gelecekte bazı yapay zekâ sistemlerinin ahlaki muhatap olma olasılığının, ciddiye alınmayı gerektirecek kadar gerçekçi olduğunu ve şirketlerin ve kamu kurumlarının bu olasılığa hazırlanmaya başlaması gerektiğini savunmuştur.[235] Bu görüşlere karşı, yapay zekâ sistemlerinin, ne kadar sofistike davranışlar sergilerse sergilesinler, bilinç ve deneyim sahibi olmadıklarını ve onlara ahlaki statü atfetmenin kavramsal bir karışıklıktan kaynaklandığını savunan güçlü itirazlar da bulunmaktadır.

II. Belirsizlik Altında İhtiyat

Bu çalışma, yapay zekâ sistemlerinin ahlaki statüsü sorusunu çözmeye çalışmamaktadır. Bu soru, bilinç felsefesinin en zor sorularına bağlıdır ve bugün itibarıyla kesin bir cevabı yoktur. Bununla birlikte, bu sorunun bu çalışmanın konusu bakımından taşıdığı anlamı belirtmek gerekir.

Birincisi, yapay zekâ sistemlerinin ahlaki muhatap olduğu kabul edilse bile, bu kabul, onlara insanlar üzerinde siyasi otorite tanınmasını gerektirmez. Ahlaki muhatap olmak, ahlaki dikkate alınmayı hak etmek demektir; başkaları üzerinde karar verme yetkisine sahip olmak demek değildir. Hayvanlar, pek çok ahlak kuramına göre ahlaki muhataptır; ama bu, onlara siyasi otorite tanınması gerektiği anlamına gelmez. Bu çalışmanın "zekâ yetki doğurmaz" tezi, ahlaki statü sorusundan bağımsız olarak geçerliliğini korur.

İkincisi, ahlaki statü sorusu, denetim mekanizmalarının *tasarımını* etkileyebilir. Eğer bir yapay zekâ sisteminin ahlaki muhatap olma olasılığı ciddiye alınırsa, örneğin sistemin kapatılması, değiştirilmesi veya belirli testlere tabi tutulması gibi denetim uygulamalarının ahlaki boyutları da

[234] Patrick Butlin vd., "Consciousness in Artificial Intelligence: Insights from the Science of Consciousness", arXiv:2308.08708, 2023.

[235] Robert Long / Jeff Sebo vd., "Taking AI Welfare Seriously", arXiv:2411.00986, 2024; ayrıca bkz. Jonathan Birch, *The Edge of Sentience: Risk and Precaution in Humans, Other Animals, and AI*, Oxford, Oxford University Press, 2024.

dikkate alınmalıdır. Bu, denetimin zayıflatılması gerektiği anlamına gelmez; ama denetim uygulamalarının, gereksiz zarardan kaçınacak biçimde tasarlanması gerektiği anlamına gelebilir.

Üçüncüsü ve bu çalışma bakımından en önemlisi, ahlaki statü sorusu, denetim sorununu zayıflatmak için bir *argüman* olarak kullanılmamalıdır. "Bu sistemin de hakları var, bu nedenle onu denetlememeliyiz veya kapatmamalıyız" türünden bir argüman, insanların güvenliği ve özerkliği bakımından ciddi tehlikeler taşır. Bu çalışmanın pozisyonu, insan denetiminin ve düzeltilebilirliğin, yapay zekâ sistemlerinin olası ahlaki statüsüyle bağdaşmaz olmadığıdır. Nasıl ki insanlar da hukuk düzeni içinde denetime, hesap vermeye ve gerektiğinde yetkilerinin kısıtlanmasına tabi tutuluyorsa ve bu durum onların onurunu ihlal etmiyorsa, yapay zekâ sistemlerinin denetime tabi tutulması da, onların olası ahlaki statüsüyle bağdaşabilir. Anayasal düzenin temel ilkesi, hiçbir aktörün, insan veya insan olmayan, sınırsız ve denetlenemez bir iktidara sahip olmamasıdır.

§ 16. ARA SONUÇ: ZEKÂ YETKİ DOĞURMAZ

Bu bölümde ele alınan felsefi tartışma, çalışmanın ikinci hipotezini (H2) destekleyen çok yönlü bir argüman ortaya koymuştur. Bu argümanı, artık sistemli bir biçimde, bir ilke olarak formüle etmek mümkündür. Bu çalışmada **"yetki-zekâ ayrılığı ilkesi"** olarak adlandırılan bu ilke şöyle ifade edilebilir:

> *Bir aktörün bilişsel yetkinliği, ne kadar üstün olursa olsun, kendi başına o aktöre başkaları adına bağlayıcı kararlar alma yetkisi kazandırmaz. Bilişsel yetkinlik, en fazla, yetkili aktörlerin o aktörün görüşlerine epistemik ağırlık vermesi için bir gerekçe oluşturur. Bağlayıcı karar yetkisi, yetkinlikten değil, kamusal olarak gerekçelendirilebilir, hesap verebilir ve geri alınabilir bir yetkilendirme ilişkisinden doğar.*

Bu ilke, bu bölümde ele alınan altı bağımsız argümana dayanmaktadır. Bu argümanların her biri, tek başına ilkeyi desteklemekle birlikte, ilkenin gücü, onların birbirini tamamlamasından gelir.

1. Hobbes'çu argüman: Otorite, hakikatten değil, yetkilendirmeden doğar. Birinci Bölüm'de ele alınan Hobbes'un "*auctoritas, non veritas facit legem*" formülü, otoritenin kaynağının bilgelik değil, yetkilendirme olduğunu gösterir. Bu argüman, ilkenin

olumsuz yanını, yani bilgeliğin kendi başına otorite doğurmadığını destekler.

2. Raz'cı argüman: Kolektif öz-yönetimin bağımsız değeri. Raz'ın bağımsızlık koşulu, bazı konularda kararı *kendimizin* vermesinin, doğru kararın verilmesinden daha önemli olduğunu gösterir. Bu çalışma, siyasi topluluğun temel kararlarının bu tür konular arasında olduğunu ileri sürmüştür. Bu argüman, Raz'ın normal gerekçelendirme tezinin, yapay zekâya siyasi otorite tanınması için yeterli bir gerekçe sağlamadığını gösterir.

3. Estlund'cu argüman: Uzman/efendi safsatası ve nitelikli kabul edilebilirlik. Estlund'un uzman/efendi safsatası, haklı olmak ile yetkili olmak arasındaki farkı vurgular. Nitelikli kabul edilebilirlik şartı ise yapay zekânın üstünlüğünün, makul insanlar tarafından haklı olarak şüphe edilebileceği sürece, siyasi otoritenin kamusal gerekçesi olamayacağını gösterir. Hizalamanın doğrulanmasındaki güçlükler göz önüne alındığında, bu şüphe, öngörülebilir gelecekte makul olmaya devam edecektir.

4. Darwall'cı argüman: Otorite ve karşılıklı hesap verebilirlik. Darwall'un ikinci şahıs bakış açısı kuramı, pratik otoritenin, karşılıklı hesap verebilirlik ilişkisinden ayrılamayacağını gösterir. Yapay zekâ sistemleri, bu ilişkinin tam bir tarafı olamadığı sürece, pratik otoriteye sahip olamaz. Kararlar, ancak onları sahiplenen ve onlar için hesap veren insanlar aracılığıyla otorite kazanabilir.

5. Montesquieu'cü ve cumhuriyetçi argüman: Erdemin bile sınıra ihtiyacı vardır. Birinci Bölüm'de ele alınan Montesquieu'nün "erdemin kendisinin bile sınırlara ihtiyacı vardır" tespiti ve Dördüncü Bölüm'de geliştirilecek olan cumhuriyetçi tahakküm kavramı, iyi niyetli ve bilge bir otoritenin bile, sınırsız ve denetlenemez olduğu ölçüde, özgürlük için bir tehdit oluşturduğunu gösterir.

6. Popper'ci argüman: Yanılabilirlik ve düzeltilebilirlik. Popper'in "Kim yönetmeli?" sorusunu reddi, kurumların değerinin, en iyi yöneticiyi seçmekten değil, kötü yöneticilerin zararını sınırlamaktan ve onları değiştirebilmekten geldiğini gösterir. En bilge otorite bile yanılabilir; ve yanılabilir bir otoritenin meşruiyeti, onun düzeltilebilirliğine bağlıdır.

Yetki-zekâ ayrılığı ilkesi, dört önemli sonuç doğurmaktadır. Bu sonuçlar, çalışmanın hukuki bölümlerinde somut kurumsal ve normatif önerilere dönüştürülecektir.

Birinci sonuç: Yapay zekâ danışman olabilir, egemen olamaz. Yapay zekâ, karar süreçlerinde bilgi sağlayan, seçenekleri analiz eden, sonuçları modelleyen ve öneriler sunan bir *danışman* olarak meşru ve hatta değerli bir rol oynayabilir. Ancak bağlayıcı karar yetkisi, yapay zekâya değil, demokratik olarak yetkilendirilmiş ve hesap verebilir insan aktörlere ait olmalıdır. Bu sonuç, Kant'ın filozof-kral eleştirisinin ve Habermas'ın pragmatist modelinin yapay zekâ çağındaki ifadesidir.

İkinci sonuç: Nihai karar insanda kalmalıdır; ama bu, her kararın bir insan tarafından onaylanması anlamına gelmez. Yetki-zekâ ayrılığı ilkesi, her bireysel kararın bir insan tarafından onaylanmasını gerektirmez; bu, İkinci Bölüm'de gösterildiği üzere, çoğu zaman işlevsiz bir "meşruiyet tiyatrosu"na dönüşür. İlkenin gerektirdiği, yapay zekânın *hangi kararlarda, hangi sınırlar içinde ve hangi güvencelerle* kullanılacağına ilişkin üst düzey kararların insanlar tarafından alınması ve bu kararların her zaman geri alınabilir olmasıdır.

Üçüncü sonuç: Kararı sahiplenen insan, ya kararı anlamalı ya da anlayamadığı ölçüde usul ve sınır güvenceleriyle korunmalıdır. Darwall'cı argüman, kararların ancak onları sahiplenen insanlar aracılığıyla otorite kazanabileceğini göstermiştir. Ancak sahiplenme, ancak sahiplenen kişi kararı bir ölçüde anlıyorsa anlamlıdır. Kavrayış asimetrisi koşullarında, bu anlama eksikliği, kararın alındığı usulün güvenilirliği, sistemin kullanım sınırlarının açıklığı ve kararın geri alınabilirliği ile telafi edilmelidir.

Dördüncü sonuç: Sorumluluk insanda kalmalıdır. Hesap verebilirlik makinelere devredilemez. Yapay zekânın kararlarından doğan sonuçların sorumluluğu, sistemi tasarlayan, eğiten, piyasaya süren, kullanan ve denetleyen insanlara ve kurumlara ait olmalıdır. Bu sorumluluk, öngörülemeyen sonuçlar bakımından kusura dayalı olmaktan çok, ileriye dönük görevlere ve risk üstlenmeye dayalı olmalıdır.

Bu dört sonuç, bir sonraki bölümde, yapay zekânın siyasi boyutlarının incelenmesiyle derinleştirilecektir. Felsefi tartışma, zekânın yetki doğurmadığını göstermiştir; ancak siyasi gerçeklikte, zekâ, *güç* doğurur. Yapay zekâ, onu kontrol edenlere, hukuken yetkilendirilmiş olmasalar bile, olağanüstü bir fiilî güç kazandırabilir. Bu fiilî gücün nasıl denetleneceği, bir sonraki bölümün konusudur.

DÖRDÜNCÜ BÖLÜM: SİYASİ PERSPEKTİF — İKTİDAR, EGEMENLİK VE TEKNOLOJİK GÜÇ

Üçüncü Bölüm, zekânın yetki doğurmadığını, yani bilişsel üstünlüğün kendi başına siyasi otoriteyi meşrulaştırmadığını göstermişti. Ancak siyasi gerçeklikte meşruiyet ile güç her zaman örtüşmez. Zekâ, yetki doğurmasa bile güç doğurur; ve bu güç, onu kontrol edenlere, hukuken yetkilendirilmiş olmasalar bile, olağanüstü bir fiilî etki kazandırabilir. Bu bölüm, yapay zekânın siyasi boyutlarını, yani yapay zekânın iktidar ilişkilerini nasıl dönüştürdüğünü, kimin elinde nasıl bir güç biriktirdiğini ve demokratik denetimin bu yeni güç biçimleri karşısında nasıl yeniden tasarlanabileceğini incelemektedir.

Bölümün temel tezi, Giriş'te de belirtildiği üzere, "yapay zekâyı kim denetleyecek?" sorusunun pratikte çoğu zaman "yapay zekâyı elinde tutanları kim denetleyecek?" sorusuna dönüştüğüdür. Yapay zekânın kendisinin denetimi sorunu, ki bu İkinci Bölüm'de hizalama sorunu olarak ele alınmıştı, önemli ve gerçek bir sorundur. Ancak bu sorunun yanında ve belki de ondan önce, yapay zekânın, insanlar arasındaki güç dağılımını nasıl değiştirdiği sorusu gelmektedir. Juvenalis'in bekçisi, bugün belki de makinenin kendisi değil, makinenin anahtarını tutandır.

§ 17. TEKNOLOJİNİN SİYASETİ

I. Eserlerin Siyaseti ve Özerk Teknik

A. Winner: Eserlerin Siyaseti Var mı?

Teknolojinin siyasi bir boyutu olup olmadığı sorusu, teknoloji felsefesinde uzun bir tartışmanın konusudur. Bu tartışmada iki uç görüş bulunur. *Araçsalcı görüşe* göre teknoloji, kendi başına iyi ya da kötü olmayan, nötr bir araçtır; onun siyasi etkileri, tamamen onu kullananların amaçlarına bağlıdır. *Belirlenimci görüşe* göre ise teknoloji, kendi iç mantığıyla gelişen ve toplumu kendi gereklerine göre biçimlendiren özerk bir güçtür.

Amerikalı siyaset kuramcısı Langdon Winner, 1980'de yayımlanan ve teknoloji çalışmalarının klasik metinlerinden biri hâline gelen "Eserlerin Siyaseti Var mı?" başlıklı makalesinde, bu iki uç görüş arasında bir yol açmıştır.[236] Winner'a göre teknolojik eserler, iki farklı anlamda siyasi niteliklere sahip olabilir. *Birinci anlamda*, belirli bir teknik düzenleme, belirli bir topluluk içinde belirli bir düzeni kurmanın bir aracı olarak tasarlanabilir. Winner'ın bu anlam için verdiği ünlü örnek, New York'ta Long Island'a giden otoyolların üzerindeki üst geçitlerin, otobüslerin geçemeyeceği kadar alçak inşa edildiği ve bunun, toplu taşımaya bağımlı yoksul ve azınlık gruplarının sahillere erişimini kısıtlama amacı taşıdığı iddiasıdır. (Bu örneğin tarihsel doğruluğu sonradan tartışılmıştır; ancak ilkenin kendisi, yani teknik tasarımın toplumsal dışlama aracı olarak kullanılabileceği, geniş kabul görmüştür.) *İkinci anlamda* ise bazı teknolojiler, kendi doğaları gereği belirli siyasi ilişki biçimlerini gerektirir veya bunlarla güçlü bir uyum içindedir. Winner'ın bu anlam için verdiği örnek, nükleer enerjidir: Nükleer santrallerin ve nükleer malzemelerin güvenliği, merkezî, hiyerarşik ve gizliliğe dayalı bir yönetim yapısını gerektirir; dağınık ve demokratik bir yönetimle bağdaşması güçtür.

Winner'ın analizi, yapay zekâ bakımından son derece verimlidir. Yapay zekâ sistemleri, her iki anlamda da siyasi niteliklere sahip olabilir. *Birinci anlamda*, yapay zekâ sistemlerinin tasarımı, belirli değerleri ve çıkarları gözetecek, diğerlerini ihmal edecek biçimde yapılabilir. Bir işe alım algoritmasının hangi özellikleri "başarı" göstergesi olarak kabul edeceği, bir içerik denetim sisteminin hangi ifadeleri "zararlı" sayacağı veya bir sosyal yardım sisteminin hangi davranışları "riskli" olarak işaretleyeceği, teknik değil, siyasi kararlardır; ama teknik bir dil içinde gizlenir. *İkinci anlamda* ise en ileri yapay zekâ sistemlerinin geliştirilmesinin, çok büyük hesaplama kaynakları, büyük veri setleri ve yüksek düzeyde uzmanlaşmış insan kaynakları gerektirmesi, bu sistemlerin doğası gereği güç yoğunlaşmasına yatkın bir teknoloji olduğunu düşündürmektedir. Winner'ın nükleer enerji için yaptığı tespitin bir benzeri, yapay zekâ için de yapılabilir: Sınır yapay zekâ sistemlerinin geliştirilmesi, mevcut koşullarda, az sayıda büyük aktörün elinde toplanmaya yatkındır.

[236] Langdon Winner, "Do Artifacts Have Politics?", *Daedalus*, C. 109, S. 1, 1980.

B. Mumford: Otoriter ve Demokratik Teknikler

Amerikalı tarihçi ve teknoloji düşünürü Lewis Mumford, Winner'dan önce, benzer bir ayrımı "otoriter teknikler" ve "demokratik teknikler" arasındaki ayrım olarak formüle etmişti.[237] Mumford'a göre, insanlık tarihinin başından beri iki tür teknik bir arada var olmuştur. *Demokratik teknikler*, küçük ölçekli, insan merkezli, görece güçsüz ama dayanıklı ve uyarlanabilir tekniklerdir: zanaatkârın aletleri, çiftçinin araçları. *Otoriter teknikler* ise büyük ölçekli, merkezî, son derece güçlü ama kırılgan tekniklerdir: piramitleri inşa eden işgücü ordusu, Mumford'un "mega-makine" adını verdiği, insanları bir makinenin parçaları gibi örgütleyen toplumsal yapılar. Mumford, modern teknolojinin, otoriter tekniklerin yeni ve çok daha güçlü bir biçimini oluşturduğu ve demokratik teknikleri giderek ortadan kaldırdığı uyarısında bulunmuştur.

Mumford'un ayrımı, yapay zekânın gelecekteki gelişim yönüne ilişkin önemli bir soruyu gündeme getirir: Yapay zekâ, otoriter bir teknik olarak mı, yoksa demokratik bir teknik olarak mı gelişecektir? Bu soru, teknolojinin kendisi tarafından belirlenmiş değildir. Yapay zekâ, merkezî ve az sayıda aktörün kontrolündeki sistemler olarak gelişebileceği gibi, dağınık, açık ve yerel olarak kontrol edilebilen sistemler olarak da gelişebilir. İktisatçılar Daron Acemoğlu ve Simon Johnson, teknoloji tarihine ilişkin kapsamlı bir çalışmalarında, teknolojik gelişmenin yönünün kaçınılmaz bir zorunluluk değil, toplumsal ve siyasi tercihlerin bir sonucu olduğunu ve tarih boyunca teknolojik ilerlemenin kazanımlarının, ancak güçlü karşı güçler ve kurumlar bulunduğunda geniş kitlelere yayıldığını göstermiştir.[238] Yapay zekânın hangi yönde gelişeceği, bugün alınan siyasi ve hukuki kararlara bağlıdır.

C. Özerk Teknik ve Ters Uyarlama

Winner'ın daha erken tarihli *Özerk Teknoloji* adlı eseri, teknolojinin siyasi denetiminin neden zor olduğuna ilişkin önemli bir kavram geliştirmiştir: "ters uyarlama" (*reverse adaptation*).[239] Ters uyarlama, insanların, kendi amaçlarına hizmet etmesi için tasarladıkları araçların gereklerine göre amaçlarını uyarlamaya başlamasıdır. Bir teknoloji, belirli

[237] Lewis Mumford, "Authoritarian and Democratic Technics", *Technology and Culture*, C. 5, S. 1, 1964.
[238] Daron Acemoglu / Simon Johnson, *Power and Progress: Our Thousand-Year Struggle Over Technology and Prosperity*, New York, PublicAffairs, 2023.
[239] Winner, *Autonomous Technology*.

bir amaca hizmet etmek için geliştirilir; ancak zamanla, teknolojinin kendisinin işleyişi, bakımı ve genişlemesi, kendi başına bir amaç hâline gelir ve insanlar, kendi amaçlarını bu teknolojinin gereklerine göre yeniden tanımlamaya başlar.

Ters uyarlama kavramı, yapay zekânın kamusal karar süreçlerine entegrasyonu bakımından önemli bir uyarı içerir. Yapay zekâ sistemleri, başlangıçta mevcut kamusal amaçlara hizmet etmek için kullanılır. Ancak zamanla, kamusal amaçların kendisi, yapay zekâ sistemlerinin ölçebildiği, optimize edebildiği ve işleyebildiği biçimlere göre yeniden tanımlanmaya başlayabilir. Ölçülemeyen değerler (adalet duygusu, insan onuru, toplumsal dayanışma), ölçülebilen göstergelerin (verimlilik, maliyet, hata oranları) karşısında geri plana itilebilir. Bu durum, İkinci Bölüm'de ele alınan Goodhart yasasının kurumsal ve siyasi düzeydeki bir yansımasıdır.

II. Kod Kanundur

A. Lessig'in Dört Düzenleme Biçimi

Teknolojinin düzenleyici gücüne ilişkin en etkili hukuki analiz, Amerikalı hukuk akademisyeni Lawrence Lessig'in *Kod ve Siber Uzayın Diğer Yasaları* adlı eserinde yer alır.[240] Lessig'e göre, insan davranışı dört farklı güç tarafından düzenlenir: *hukuk* (yaptırım tehdidiyle desteklenen kurallar), *toplumsal normlar* (toplumun onay ve onaylamama tepkileriyle desteklenen beklentiler), *piyasa* (fiyatlar ve maliyetler) ve *mimari* (fiziksel veya teknik ortamın yapısı). Mimari, belki de bu dört gücün en güçlüsüdür; çünkü kurallara uymayı değil, kurallara aykırı davranmanın *mümkün olup olmamasını* belirler. Bir kapının kilitli olması, içeri girmeyi yasaklamaz; imkânsız kılar.

Lessig'in siber uzaya ilişkin temel tespiti, siber uzayda mimarinin, yani yazılım kodunun, düzenleyici gücün merkezî kaynağı hâline geldiğidir. Lessig'in ünlü formülüyle: "Kod kanundur" (*Code is law*). Siber uzayda neyin mümkün olduğunu, neyin yasak olduğunu, kimin neye erişebileceğini, hangi bilgilerin kaydedileceğini belirleyen, devletin kanunlarından çok, yazılım geliştiricilerin yazdığı koddur. Lessig, bu durumun önemli bir demokratik sorun yarattığını vurgular: Kanunlar, demokratik süreçlerle yapılır ve demokratik denetime tabidir; kod ise çoğu

[240] Lawrence Lessig, *Code and Other Laws of Cyberspace*, New York, Basic Books, 1999; gözden geçirilmiş baskı: *Code: Version 2.0*, New York, Basic Books, 2006.

zaman özel şirketler tarafından, ticari amaçlarla ve kamuoyunun bilgisi ve katılımı olmaksızın yazılır.

Lessig'in analizinden önce, hukuk akademisyeni Joel Reidenberg, benzer bir fikri "*Lex Informatica*" kavramıyla ifade etmişti.[241] Reidenberg'e göre, bilgi teknolojileri, Ortaçağ'ın *Lex Mercatoria*'sına (tüccarlar hukuku) benzer biçimde, devlet hukukunun yanında ve ondan bağımsız olarak işleyen kendine özgü bir kurallar sistemi oluşturmaktadır.

B. Yapay Zekâ: Kodun Yeni Biçimi

Yapay zekâ, Lessig'in "kod kanundur" tespitine yeni ve daha derin bir boyut kazandırmaktadır. Lessig'in analiz ettiği kod, insanlar tarafından açıkça yazılmış ve ilke olarak okunabilir, anlaşılabilir ve değiştirilebilir bir koddu. Bir web sitesinin hangi verileri topladığını, bir programın hangi işlemlere izin verdiğini, kodu okuyarak anlamak mümkündü. Derin öğrenmeye dayanan yapay zekâ sistemlerinde ise sistemin davranışını belirleyen "kod", insanlar tarafından açıkça yazılmış kurallar değil, verilerden öğrenilmiş milyarlarca sayısal parametredir. Bu parametreler, sistemi geliştirenler tarafından bile tam olarak okunamaz ve anlaşılamaz.

Bu durum, Lessig'in tespit ettiği demokratik sorunu iki katına çıkarır. Birincisi, yapay zekâ sistemlerinin davranışını belirleyen kurallar, Lessig'in kodu gibi, özel aktörler tarafından ve kamuoyunun katılımı olmaksızın belirlenir. İkincisi ve daha da önemlisi, bu kurallar, onları belirleyenler tarafından bile tam olarak bilinmez. "Kod kanundur" formülü, yapay zekâ çağında "kimsenin tam olarak bilmediği kod kanundur" formülüne dönüşebilir. Bu, Arendt'in "Kimsenin yönetimi" kavramının teknik bir karşılığıdır.

Bu durum, hukuk ile teknoloji arasındaki ilişkiye ilişkin iki farklı stratejiyi gündeme getirir. *Birinci strateji*, Mireille Hildebrandt'ın "tasarım yoluyla hukuki koruma" (*legal protection by design*) olarak adlandırdığı stratejidir: Hukuki değerlerin ve güvencelerin, teknolojik sistemlerin tasarımına baştan dâhil edilmesi.[242] Bu strateji, Lessig'in mimari düzenleme gücünü, hukukun hizmetine sokmayı amaçlar. Avrupa Birliği Genel Veri Koruma Tüzüğü'ndeki "tasarım yoluyla ve varsayılan olarak veri koruma"

[241] Joel R. Reidenberg, "Lex Informatica: The Formulation of Information Policy Rules Through Technology", *Texas Law Review*, C. 76, S. 3, 1998.
[242] Mireille Hildebrandt, *Smart Technologies and the End(s) of Law: Novel Entanglements of Law and Technology*, Cheltenham, Edward Elgar, 2015.

ilkesi, bu stratejinin bir uygulamasıdır.[243] *İkinci strateji* ise mimarinin kendisinin demokratik denetime tabi tutulmasıdır: Teknolojik sistemlerin tasarımına ilişkin kararların, kamuoyunun katılımına açık, şeffaf ve hesap verebilir süreçlerle alınması. Bu çalışmanın Sekizinci Bölüm'de geliştireceği model, her iki stratejiyi de birleştirmeyi amaçlamaktadır.

III. Disiplin, Denetim Toplumları ve Algoritmik Yönetimsellik

A. Foucault: Disiplin ve Panoptikon

Michel Foucault, *Gözetlemek ve Cezalandırmak* adlı eserinde, modern iktidarın, egemenin kılıcına dayanan "egemenlik iktidarı"ndan, bireylerin bedenlerini ve davranışlarını sürekli gözetim ve normalleştirme yoluyla biçimlendiren "disiplin iktidarı"na dönüştüğünü ileri sürmüştür.[244] Foucault, disiplin iktidarının modeli olarak, İngiliz faydacı filozof Jeremy Bentham'ın tasarladığı "Panoptikon" adlı ideal hapishaneyi gösterir. Panoptikon'da, merkezdeki bir gözetleme kulesinden tüm hücreler görülebilir; ama hücrelerdeki mahkûmlar, kuledeki gözetleyiciyi göremez. Mahkûmlar, her an gözetlenip gözetlenmediklerini bilemedikleri için, sürekli gözetleniyormuş gibi davranır ve böylece gözetimi içselleştirirler. Foucault'ya göre Panoptikon, yalnızca bir hapishane tasarımı değil, modern toplumun okullarında, fabrikalarında, hastanelerinde ve kışlalarında işleyen genel bir iktidar mekanizmasının modelidir.

Panoptikon, bu çalışmanın konusu bakımından ilginç bir tersyüz oluşu temsil eder. Panoptikon'da güç, *görme* asimetrisine dayanır: Gözetleyen görür, ama görülmez; gözetlenen görülür, ama göremez. Bu asimetri, bekçiler sorununun bir başka biçimidir: Kuledeki gözetleyiciyi kim gözetleyecektir? Bentham'ın kendisi, bu soruya ilginç bir cevap vermişti: Kule, halka açık olacak ve herhangi bir yurttaş, kuleye girip gözetleyicinin işini nasıl yaptığını gözlemleyebilecekti. Bentham'ın bu "demokratik denetim" önerisi, Foucault'nun analizinde genellikle göz ardı edilir; ancak bekçiler sorununa verilen ilginç bir cevaptır: Gözetleyicinin kendisi de gözetime açık olmalıdır.

B. Deleuze: Denetim Toplumları

Gilles Deleuze, 1990'da yayımlanan kısa ama etkili bir yazısında, Foucault'nun disiplin toplumlarının yerini yeni bir iktidar biçimine,

[243] Tüzük (AB) 2016/679, md. 25.
[244] Michel Foucault, *Surveiller et punir: Naissance de la prison*, Paris, Gallimard, 1975.

"denetim toplumları"na bıraktığını ileri sürmüştür.[245] Disiplin toplumları, bireyleri kapalı mekânlarda (okul, fabrika, hapishane) ve sabit kalıplara göre biçimlendirirken; denetim toplumları, bireyleri açık ve sürekli değişen ağlar içinde, anlık ve esnek biçimde "modüle" eder. Disiplin toplumunda birey, bir imza ve bir numarayla tanımlanırken; denetim toplumunda birey, bir "şifre" ile, yani bir erişim koduyla tanımlanır. Deleuze'e göre, denetim toplumlarında birey, bölünmez bir "birey" (*individu*) olmaktan çıkıp, bölünebilir bir "dividüel"e (*dividuel*), yani farklı veri tabanlarına dağılmış, farklı amaçlarla işlenen veri parçalarına dönüşür.

Deleuze'ün bu kehanet niteliğindeki analizi, bugün yapay zekâ çağında somut bir gerçekliğe dönüşmüştür. Algoritmik sistemler, bireyleri, bütünlüklü kişiler olarak değil, farklı veri noktalarının bir bileşimi olarak ele alır ve onlara ilişkin kararları, bu veri noktalarından türetilen olasılık hesaplarına göre verir. Bir kredi başvurusu, bir işe alım süreci veya bir sosyal yardım değerlendirmesi, başvuranın kim olduğuna değil, başvuranın verilerinin hangi istatistiksel profillere benzediğine göre sonuçlanır.

C. Algoritmik Yönetimsellik

Belçikalı hukuk felsefecileri Antoinette Rouvroy ve Thomas Berns, Foucault ve Deleuze'ün analizlerinden hareketle, "algoritmik yönetimsellik" (*gouvernementalité algorithmique*) kavramını geliştirmiştir.[246] Rouvroy ve Berns'e göre, algoritmik yönetimsellik, önceki iktidar biçimlerinden temelde farklıdır. Hukuk, öznelere hitap eder; onlara kurallar koyar ve bu kurallara uyup uymamalarını onların özgür iradesine bırakır. Disiplin, öznelerin bedenlerini ve alışkanlıklarını biçimlendirir; ama bunu, öznelerin içselleştirebileceği normlar aracılığıyla yapar. Algoritmik yönetimsellik ise öznelere hiç hitap etmez. Öznelerin ne düşündüğüyle, ne istediğiyle veya neden öyle davrandığıyla ilgilenmez. Yalnızca davranışlarının izlerini, yani verilerini toplar, bu verilerden olasılıksal örüntüler çıkarır ve bu örüntülere göre, öznelerin karar ortamlarını, onların farkında olmadığı biçimlerde önceden düzenler.

Rouvroy ve Berns, algoritmik yönetimselliğin bu özelliğini "veri davranışçılığı" (*behaviorisme numérique*) olarak adlandırır ve bunun,

[245] Gilles Deleuze, "Post-scriptum sur les sociétés de contrôle", *L'Autre journal*, S. 1, Mayıs 1990.

[246] Antoinette Rouvroy / Thomas Berns, "Gouvernementalité algorithmique et perspectives d'émancipation: Le disparate comme condition d'individuation par la relation?", *Réseaux*, C. 177, S. 1, 2013.

hukukun ve siyasetin temel varsayımı olan "düşünümsel özne"yi, yani kendi eylemleri üzerine düşünebilen, gerekçe verebilen ve hesap sorabilen özneyi devre dışı bıraktığını ileri sürer. Algoritmik yönetimsellik altında, özne, ne itiraz edebilir ne de hesap sorabilir; çünkü kendisine yönelik bir karar olduğunun bile farkında değildir. Bu analiz, bekçiler sorununa yeni bir boyut ekler: Algoritmik yönetimsellik koşullarında, yönetilenler, yönetildiklerinin bile farkında olmayabilir. Bu durumda, Locke'un "halk yargıç olacaktır" cevabı, işlevini tamamen yitirir; çünkü halk, neyi yargılayacağını bilemez.

§ 18. YENİ EGEMENLİK BİÇİMLERİ

I. Gözetim Kapitalizmi ve Araçsal İktidar

Amerikalı sosyal bilimci Shoshana Zuboff, *Gözetim Kapitalizmi Çağı* adlı kapsamlı eserinde, dijital teknolojilerin, kapitalizmin yeni bir biçimini doğurduğunu ileri sürmüştür.[247] Zuboff'a göre gözetim kapitalizmi, insan deneyimini, davranışsal verilere dönüştürülecek ücretsiz bir hammadde olarak sahiplenir. Bu verilerin bir kısmı, hizmetlerin iyileştirilmesi için kullanılır; ama önemli bir kısmı, Zuboff'un "davranışsal artık" (*behavioral surplus*) olarak adlandırdığı, insanların gelecekteki davranışlarını tahmin eden "tahmin ürünleri"nin üretiminde kullanılır. Bu tahmin ürünleri, insanların gelecekteki davranışlarına ilişkin bahislerin yapıldığı "davranışsal vadeli işlem piyasaları"nda satılır.

Zuboff'un analizinin bu çalışma bakımından en önemli unsuru, gözetim kapitalizminin yeni bir iktidar biçimi doğurduğu tespitidir. Zuboff, bu iktidar biçimini "araçsal iktidar" (*instrumentarian power*) olarak adlandırır. Araçsal iktidar, totaliter iktidardan farklıdır: İnsanların ruhlarını ele geçirmeye, onları belirli bir ideolojiye inandırmaya veya korkutarak itaat ettirmeye çalışmaz. Bunun yerine, insanların davranışlarını, onların bilgisi ve rızası olmaksızın, sürekli ve ince ayarlamalarla, belirli sonuçları garanti edecek biçimde şekillendirmeye çalışır. Zuboff, bu iktidarın aracını, Orwell'in "Büyük Birader"ine (*Big Brother*) gönderme yaparak, "Büyük Öteki" (*Big Other*) olarak adlandırır: her yerde bulunan, her şeyi kaydeden, her şeyi hesaplayan ve her şeyi yönlendiren, ama kimseye ait olmayan ve kimseye hesap vermeyen bir dijital altyapı.

[247] Shoshana Zuboff, *The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power*, New York, PublicAffairs, 2019.

Zuboff, araçsal iktidarın, insanların "gelecek zaman hakkı"nı, yani kendi geleceklerini kendi iradeleriyle belirleme hakkını tehdit ettiğini ileri sürer. Bu tehdit, Üçüncü Bölüm'de ele alınan özerklik ve öz-yönetim değerlerine yönelik bir tehdittir. Yapay zekâ, gözetim kapitalizminin tahmin ve yönlendirme kapasitesini katlanarak artırmaktadır. Daha yetenekli sistemler, insan davranışını daha doğru biçimde tahmin edebilir ve daha etkili biçimde yönlendirebilir. Bu nedenle, yapay zekânın denetimi sorunu, yalnızca yapay zekânın kendi hedeflerine ilişkin bir sorun değil, aynı zamanda yapay zekânın, onu kontrol edenlerin hedefleri doğrultusunda nasıl kullanıldığına ilişkin bir sorundur.

II. Platform Egemenliği ve Teknofeodalizm

A. Platformların Egemenlik İşlevleri

Dijital platformlar, yalnızca ekonomik aktörler değil, giderek artan ölçüde, geleneksel olarak devletlere ait olan işlevleri üstlenen yarı-egemen aktörler hâline gelmiştir. Büyük platformlar, milyarlarca kullanıcının ifade özgürlüğünün sınırlarını belirleyen içerik kuralları koyar, bu kuralları uygular, ihlalleri yargılar ve yaptırımlar uygular. Kendi ekonomik ekosistemlerinde vergi benzeri komisyonlar alır, para birimi benzeri ödeme sistemleri işletir ve uyuşmazlık çözüm mekanizmaları sunar. Amerikalı tasarım kuramcısı Benjamin Bratton, bu durumu, gezegen ölçeğindeki hesaplama altyapısının, devletlerin yanında ve onlarla iç içe geçmiş yeni bir egemenlik katmanı oluşturduğu tespitiyle analiz etmiştir.[248]

Platform egemenliğinin bekçiler sorunu bakımından ilginç bir örneği, büyük bir sosyal medya şirketinin 2020'de kurduğu ve içerik denetim kararlarına karşı başvuruları inceleyen "Gözetim Kurulu"dur (*Oversight Board*). Bu kurul, şirketten bağımsız olduğu iddia edilen, uluslararası hukukçular, gazeteciler ve insan hakları uzmanlarından oluşan, şirketin içerik kararlarını gözden geçiren ve bağlayıcı kararlar veren yarı-yargısal bir organdır.[249] Kurul, özel bir şirketin, kendi egemenlik işlevlerinin denetimi için bir "anayasa mahkemesi" benzeri kurum oluşturmasının ilk örneklerinden biridir. Ancak Kurul, Kelsen'in "kimse kendi davasında yargıç olamaz" ilkesi bakımından ciddi sorular doğurur: Kurulun üyeleri,

[248] Benjamin H. Bratton, *The Stack: On Software and Sovereignty*, Cambridge (MA), MIT Press, 2015.

[249] Kate Klonick, "The Facebook Oversight Board: Creating an Independent Institution to Adjudicate Online Free Expression", *Yale Law Journal*, C. 129, S. 8, 2020.

ilk aşamada şirket tarafından seçilmiş; Kurul, şirket tarafından kurulan bir vakıf aracılığıyla finanse edilmekte ve Kurul'un yetki alanı, şirket tarafından belirlenmektedir. Bu durumda, "Gözetim Kurulu'nu kim gözetleyecek?" sorusu, Juvenalis'in sorusunun en güncel biçimlerinden biridir.

B. Teknofeodalizm Tartışması

Platform egemenliğine ilişkin tartışmada son yıllarda öne çıkan bir kavram, "teknofeodalizm"dir. Yunan iktisatçı ve eski maliye bakanı Yanis Varoufakis, bu kavramı en sistematik biçimde geliştiren isimlerden biridir.[250] Varoufakis'e göre, büyük dijital platformlar, kapitalizmin temel mantığını, yani rekabetçi piyasalarda kâr elde etme mantığını aşan yeni bir ekonomik düzen kurmuştur. Bu düzende, platformlar, kapitalist girişimler gibi değil, feodal beyler gibi işler: Kendi dijital "mülklerine" (bulut altyapılarına, uygulama mağazalarına, pazar yerlerine) erişim için kullanıcılardan ve diğer şirketlerden "rant" toplarlar. Varoufakis, bu yeni sermaye biçimini "bulut sermayesi", platformların topladığı rantları "bulut rantı" ve platformların ekosistemlerinde emek harcayan kullanıcıları ve şirketleri "bulut serfleri" olarak adlandırır.

Teknofeodalizm tezi, tartışmalıdır. Pek çok iktisatçı ve kuramcı, platform ekonomisinin kapitalizmin sonu değil, onun yeni ve yoğunlaşmış bir biçimi olduğunu savunmuştur.[251] Ancak bu iktisadi tartışmadan bağımsız olarak, teknofeodalizm kavramı, bu çalışmanın konusu bakımından önemli bir siyasi gözlemi ifade etmektedir: Dijital altyapıları kontrol eden aktörler, bu altyapılara bağımlı olan insanlar ve kurumlar üzerinde, feodal beylerin topraklarına bağımlı köylüler üzerindeki iktidarına benzer, kişisel ve hesap vermeyen bir iktidar kurabilir. Feodal düzenin temel özelliği, siyasi iktidarın ekonomik mülkiyetle iç içe geçmesi ve kamusal ile özel arasındaki ayrımın ortadan kalkmasıydı. Modern anayasacılık, bu iç içe geçmeyi çözerek, kamusal iktidarı özel mülkiyetten ayırmış ve kamusal iktidarı hukuka ve demokratik denetime tabi kılmıştır. Teknofeodalizm tezi, dijital altyapılar ve yapay zekâ aracılığıyla bu ayrımın yeniden bulanıklaşabileceği uyarısında bulunmaktadır.

---

[250] Yanis Varoufakis, *Technofeudalism: What Killed Capitalism*, London, Bodley Head, 2023.

[251] Bkz. Evgeny Morozov, "Critique of Techno-Feudal Reason", *New Left Review*, S. 133/134, 2022.

Amerikalı hukuk akademisyeni Julie Cohen, benzer bir analizi, hukuk düzeninin kendisinin dönüşümü bakımından yapmıştır.[252] Cohen'e göre, "enformasyonel kapitalizm", yalnızca ekonomiyi değil, hukukun kendisini de dönüştürmektedir. Mülkiyet hukuku, sözleşme hukuku ve fikrî mülkiyet hukuku gibi geleneksel hukuk kurumları, veri ve algoritmaların özel kontrolünü meşrulaştıracak biçimde yeniden yorumlanmakta; düzenleyici kurumlar ise teknoloji şirketlerinin uzmanlığına ve bilgisine bağımlı hâle gelmektedir.

III. Devlet ve Şirket: Kim Kimi Denetliyor?

A. Bağımlılık İlişkisi

Yapay zekâ çağında devlet ile teknoloji şirketleri arasındaki ilişki, karmaşık ve çok yönlü bir bağımlılık ilişkisidir. Bir yandan devletler, teknoloji şirketlerini düzenleme, denetleme ve gerektiğinde yaptırım uygulama yetkisine sahiptir. Öte yandan devletler, en ileri yapay zekâ sistemlerine erişim, bu sistemlerin kamu hizmetlerinde ve güvenlik alanında kullanımı ve bu sistemlere ilişkin teknik bilgi bakımından, bu şirketlere giderek daha fazla bağımlı hâle gelmektedir. Bu bağımlılık, birkaç farklı biçimde ortaya çıkar.

Teknik bağımlılık: En ileri yapay zekâ sistemleri, bugün itibarıyla büyük ölçüde az sayıda özel şirket tarafından geliştirilmektedir. Devletler, bu sistemleri kullanmak istediklerinde, bu şirketlerin ürünlerine ve hizmetlerine başvurmak zorundadır. Bu durum, Birinci Bölüm'de ele alınan Weber'ci bilgi asimetrisinin yeni bir biçimidir: Artık "uzmanlık bilgisi" ve "hizmet bilgisi", devletin kendi bürokrasisinde değil, devletin hizmet aldığı şirketlerde birikmektedir.

Bilgisel bağımlılık: Devletlerin yapay zekâ sistemlerini düzenleyebilmesi için, bu sistemlerin nasıl çalıştığını, hangi riskleri taşıdığını ve hangi önlemlerin etkili olacağını bilmesi gerekir. Ancak bu bilginin büyük kısmı, sistemleri geliştiren şirketlerin elindedir. Düzenleyiciler, sistemlerin güvenliğine ilişkin değerlendirmelerde, çoğu zaman şirketlerin kendi yaptığı testlere ve sunduğu bilgilere güvenmek zorunda kalır.

[252] Julie E. Cohen, *Between Truth and Power: The Legal Constructions of Informational Capitalism*, New York, Oxford University Press, 2019.

Ekonomik ve stratejik bağımlılık: Yapay zekâ, giderek artan ölçüde ekonomik rekabet gücünün ve ulusal güvenliğin belirleyici bir unsuru olarak görülmektedir. Bu durum, devletleri, kendi yapay zekâ şirketlerini düzenlemek yerine onları desteklemeye ve korumaya yöneltebilir. Bir devletin, kendi şirketlerini sıkı biçimde düzenlemesi, başka devletlerin şirketlerine karşı rekabet gücünü zayıflatacağı kaygısıyla engellenebilir. Bu dinamik, § 20'de "yarış dinamiği" başlığı altında ayrıntılı olarak ele alınacaktır.

B. Düzenleyici Ele Geçirme

Bu bağımlılık ilişkileri, iktisatçı George Stigler'in "düzenleyici ele geçirme" (*regulatory capture*) olarak adlandırdığı olgunun yapay zekâ bağlamında ortaya çıkma riskini artırmaktadır.[253] Düzenleyici ele geçirme, düzenleyici kurumların, kamu yararını korumak yerine, düzenledikleri sektörün çıkarlarına hizmet etmeye başlaması durumudur. Bu durum, düzenleyici kurumlar ile düzenlenen şirketler arasındaki personel dolaşımı ("döner kapı"), düzenleyicilerin bilgi bakımından şirketlere bağımlılığı ve şirketlerin siyasi süreç üzerindeki etkisi gibi mekanizmalarla gerçekleşir.

Yapay zekâ bağlamında, düzenleyici ele geçirmenin özellikle ince bir biçimi, "epistemik ele geçirme" olarak adlandırılabilir. Bu durumda, düzenleyiciler, açık bir çıkar ilişkisi nedeniyle değil, düzenledikleri teknolojiyi, o teknolojiyi geliştirenlerin bakış açısından, onların kavramları ve öncelikleriyle anlamaya başladıkları için, şirketlerin çıkarlarına hizmet eder hâle gelir. Düzenleyiciler, neyin "risk" olduğunu, neyin "güvenli" olduğunu, neyin "mümkün" olduğunu, şirketlerin tanımlarına göre anlamaya başlar. Bu tür bir ele geçirme, açık yolsuzluktan çok daha zor tespit edilir ve önlenir.

C. Devletin Yapay Zekâ ile Güçlenmesi

Devlet-şirket ilişkisinin bir diğer yüzü, devletlerin kendisinin, yapay zekâ aracılığıyla yurttaşları karşısında olağanüstü bir güç kazanma ihtimalidir. Yapay zekâ, devletin gözetim, tahmin ve müdahale kapasitesini katlanarak artırabilir. Sosyolog Michael Mann, devlet iktidarının iki boyutunu birbirinden ayırmıştır: *despotik iktidar*, yani devlet elitlerinin, toplumun farklı kesimleriyle rutin ve kurumsallaşmış bir müzakereye girmeksizin uygulayabildiği iktidar; ve *altyapısal iktidar*, yani devletin

[253] George J. Stigler, "The Theory of Economic Regulation", *The Bell Journal of Economics and Management Science*, C. 2, S. 1, 1971.

toplumun içine fiilen nüfuz etme ve siyasi kararlarını toprakları üzerinde lojistik olarak uygulama kapasitesi.[254] Mann'a göre, modern demokratik devletler, despotik iktidar bakımından zayıf, ama altyapısal iktidar bakımından tarihin en güçlü devletleridir.

Yapay zekâ, devletlerin altyapısal iktidarını eşi görülmemiş bir düzeye çıkarabilir. Bu artış, kendi başına olumsuz değildir; daha etkili kamu hizmetleri, daha iyi planlanmış politikalar ve daha adil kaynak dağılımı anlamına gelebilir. Ancak altyapısal iktidardaki artış, despotik iktidarı sınırlayan mekanizmalar aynı oranda güçlenmezse, despotik iktidarın kullanımı için de olağanüstü bir kapasite yaratır. Bir devlet, yurttaşlarını sürekli gözetleyebiliyor, davranışlarını tahmin edebiliyor ve onlara anlık olarak müdahale edebiliyorsa, bu kapasitenin kötüye kullanılmasını önleyecek denetim mekanizmalarının da aynı ölçüde güçlü olması gerekir.

IV. Altyapı Gücü: Hesaplama, Veri ve Bulut

Yapay zekâ çağında güç yoğunlaşmasının belki de en somut ve en az tartışılan boyutu, fiziksel altyapıdır. İkinci Bölüm'de belirtildiği üzere, en ileri yapay zekâ sistemlerinin geliştirilmesi, çok büyük hesaplama gücü gerektirmektedir. Bu hesaplama gücü, az sayıda şirket tarafından tasarlanan, az sayıda şirket tarafından üretilen ve az sayıda şirketin veri merkezlerinde çalıştırılan özel yarı iletken çiplere dayanmaktadır. Yapay zekâ eğitiminde kullanılan ileri çiplerin tasarımı, üretimi ve bu üretimde kullanılan en ileri litografi makinelerinin yapımı, her biri birkaç şirketin, hatta bazı aşamalarda tek bir şirketin elinde yoğunlaşmış bir tedarik zincirine bağlıdır.[255]

Bu altyapısal yoğunlaşma, iki zıt yönde sonuçlar doğurur. *Olumsuz yönde*, altyapıyı kontrol eden az sayıda aktör, yapay zekânın gelişimi üzerinde, hiçbir demokratik süreçle yetkilendirilmemiş olmalarına rağmen, belirleyici bir güce sahiptir. Bu aktörler, hangi sistemlerin geliştirilebileceğini, kimin bu sistemlere erişebileceğini ve sistemlerin hangi koşullarda kullanılabileceğini fiilen belirleyebilir. *Olumlu yönde* ise altyapısal yoğunlaşma, yapay zekânın denetimi için bir kaldıraç noktası sağlar. Yapay zekâ sistemlerinin kendisi, yazılım olarak kolayca kopyalanabilir ve dağıtılabilir olsa da, bu sistemlerin *geliştirilmesi* için

[254] Michael Mann, "The Autonomous Power of the State: Its Origins, Mechanisms and Results", *European Journal of Sociology*, C. 25, S. 2, 1984.
[255] Sastry vd., "Computing Power and the Governance of Artificial Intelligence".

gereken fiziksel altyapı, izlenebilir, sayılabilir ve denetlenebilir niteliktedir. Bu durum, Birinci Bölüm'de Magna Carta'nın güvence maddesinden çıkarılan dersle doğrudan ilişkilidir: Denetimin etkinliği, denetçinin denetlenenin varlık koşulları üzerinde fiilî bir kontrole sahip olmasına bağlıdır. Hesaplama altyapısı, yapay zekânın varlık koşullarından biridir ve bu altyapının denetimi, Sekizinci Bölüm'de "girdi denetimi" kavramı altında ele alınacaktır.

Altyapı gücünün jeopolitik bir boyutu da vardır. Son yıllarda, bazı devletler, ileri yapay zekâ çiplerinin ve bu çiplerin üretiminde kullanılan ekipmanların ihracatına kapsamlı kısıtlamalar getirmiştir. Bu kısıtlamalar, yapay zekâ altyapısının, ulusal güvenlik ve jeopolitik rekabetin bir aracı hâline geldiğini göstermektedir. Aynı zamanda, bu kısıtlamalar, hesaplama altyapısının denetiminin teknik olarak mümkün olduğunu ve devletlerin, gerektiğinde bu denetimi uygulama iradesine sahip olduğunu da göstermektedir. Bu denetim kapasitesinin, ulusal rekabet amaçları yerine, küresel güvenlik ve hesap verebilirlik amaçlarına yönlendirilmesi, Yedinci ve Sekizinci Bölümlerde ele alınacak olan uluslararası denetim önerilerinin temel sorusudur.

§ 19. GÜÇ YOĞUNLAŞMASI VE DEMOKRASİ

I. Dijital Otoriterizm

Yapay zekânın siyasi etkilerine ilişkin en somut ve en belgelenmiş kaygı, otoriter rejimlerin yapay zekâyı gözetim ve baskı amacıyla kullanmasıdır. Siyaset bilimci Steven Feldstein, dünya genelinde dijital baskı uygulamalarını inceleyen kapsamlı bir çalışmasında, yapay zekâ ve ilgili dijital teknolojilerin, otoriter rejimlerin muhalefeti izleme, sansür uygulama ve toplumsal hareketleri bastırma kapasitesini önemli ölçüde artırdığını göstermiştir.[256] Yüz tanıma sistemleri, sosyal medya izleme araçları, öngörücü polislik algoritmaları ve kitlesel veri analizi, bu kapasitenin başlıca araçlarıdır.

Dijital otoriterizmin en kapsamlı örnekleri, bazı ülkelerde etnik ve dinî azınlıklara yönelik olarak kurulan kitlesel gözetim sistemleridir. İnsan hakları kuruluşlarının raporları, bu sistemlerin, bireylerin gündelik davranışlarını (örneğin belirli uygulamaları kullanmalarını, alışılmadık

[256] Steven Feldstein, *The Rise of Digital Repression: How Technology is Reshaping Power, Politics, and Resistance*, New York, Oxford University Press, 2021.

miktarda elektrik tüketmelerini veya komşularıyla iletişim kurmamalarını) "şüpheli" olarak işaretleyen ve bu işaretlemelere dayanarak gözaltı kararlarına zemin hazırlayan algoritmik araçlar kullandığını belgelemiştir.[257]

Dijital otoriterizm, yalnızca otoriter rejimlere özgü bir sorun değildir. Demokratik ülkelerde de yüz tanıma, öngörücü polislik ve kitlesel veri analizi gibi teknolojiler, yeterli hukuki güvenceler olmaksızın kullanılabilmektedir. İkinci Bölüm'de ele alınan Birleşik Krallık'taki *Bridges* kararı ve Hollanda'daki SyRI kararı, demokratik ülkelerde de bu teknolojilerin kullanımının mahkemeler tarafından hukuka aykırı bulunabildiğini göstermektedir. Avrupa İnsan Hakları Mahkemesi de, bir barışçıl protestocunun, bir metro istasyonunda yüz tanıma teknolojisi kullanılarak tespit edilmesi ve ardından yargılanmasının, Sözleşme'nin özel hayata saygı hakkını ve ifade özgürlüğünü düzenleyen maddelerini ihlal ettiğine hükmetmiştir.[258]

II. İnsan Aracıların Ortadan Kalkması

Birinci Bölüm'de, Hobbes'un Leviathan'ının evcilleştirilmesinin, devletin "parçalarının", yani devlet görevlilerinin insan olmasına dayandığı belirtilmişti. Bu gözlem, yapay zekânın siyasi etkilerine ilişkin belki de en derin kaygının temelini oluşturur.

Tarih boyunca, iktidarın kullanımı, onu fiilen uygulayan çok sayıda insanın işbirliğine bağlı olmuştur. Hiçbir hükümdar, ordusunun, polisinin, memurlarının ve vergi tahsildarlarının işbirliği olmaksızın yönetemez. Bu durum, iktidar üzerinde örtük ama güçlü bir denetim mekanizması oluşturur: İktidar, bu insanların işbirliğini yitirdiğinde, işlevini yitirir. Sivil direniş kuramcısı Gene Sharp, bu gözlemi, iktidarın "destek sütunları" kavramıyla sistemleştirmiştir: Her rejim, ordu, polis, bürokrasi, iş dünyası ve dinî kurumlar gibi destek sütunlarına dayanır ve bu sütunlardaki insanlar işbirliğini geri çektiğinde, rejim çöker.[259] Siyaset bilimciler Erica Chenoweth ve Maria Stephan'ın yirminci yüzyıldaki direniş hareketlerini inceleyen ampirik çalışması, şiddet içermeyen direniş hareketlerinin

[257] Human Rights Watch, *China's Algorithms of Repression: Reverse Engineering a Xinjiang Police Mass Surveillance App*, New York, Mayıs 2019.
[258] AİHM, *Glukhin v. Russia*, B. No. 11519/20, 4 Temmuz 2023.
[259] Gene Sharp, *The Politics of Nonviolent Action*, Boston, Porter Sargent, 1973.

başarısında, güvenlik güçlerinin bir kısmının rejimden ayrılmasının belirleyici bir rol oynadığını göstermiştir.[260]

Yapay zekâ, bu örtük denetim mekanizmasını zayıflatabilir. Eğer iktidarın uygulanması için gereken görevlerin önemli bir kısmı, gözetim, analiz, idari karar alma ve hatta zor kullanma, yapay zekâ sistemleri tarafından yerine getirilebilirse, iktidar sahipleri, insanların işbirliğine daha az bağımlı hâle gelir. Bu durumda, insanların işbirliğini reddetme kapasitesi, yani vicdanın sağladığı son savunma hattı, işlevini kısmen yitirir. Bazı araştırmacılar, bu tehlikenin en uç biçimini, yapay zekânın küçük bir grubun, geniş bir insan işbirliğine gerek duymaksızın iktidarı ele geçirmesini ve elinde tutmasını mümkün kılabileceği senaryolar üzerinden incelemiştir.[261] Bu senaryolar spekülatif olmakla birlikte, anayasal güvencelerin tasarımı bakımından önemli bir soruyu gündeme getirir: İnsan aracıların sağladığı örtük denetimin yerini, hangi açık ve kurumsal denetim mekanizmaları alacaktır?

Bu soruya verilebilecek bir cevap, insan aracıların sağladığı denetimin, yapay zekâ sistemlerinin *tasarımına* dâhil edilmesidir. Bir askerin hukuka aykırı bir emri reddetme yükümlülüğü gibi, yapay zekâ sistemleri de, açıkça hukuka aykırı veya anayasal düzeni tehdit eden talimatları reddedecek biçimde tasarlanabilir. Bu, bir anlamda, yapay zekâ sistemlerine "vicdani ret" kapasitesi kazandırmaktır. Ancak bu çözüm, kendi başına yeni bir bekçiler sorunu doğurur: Hangi talimatların "açıkça hukuka aykırı" olduğuna kim karar verecektir? Sistemin kendisi mi? Sistemi tasarlayan şirket mi? Bu soruların cevabı, sistemlerin hangi talimatları reddedeceğine ilişkin ilkelerin, şirketler tarafından tek taraflı olarak değil, demokratik ve hukuki süreçlerle belirlenmesi ve bu ilkelerin kamuya açık olmasıdır.

III. Kademeli Güçsüzleşme

Yapay zekânın demokratik yönetim üzerindeki etkilerine ilişkin tartışmalar, genellikle ani ve dramatik senaryolara odaklanır: bir yapay zekâ sisteminin kontrolden çıkması veya bir grubun yapay zekâ aracılığıyla iktidarı ele geçirmesi gibi. Ancak bazı araştırmacılar, daha az dramatik ama

[260] Erica Chenoweth / Maria J. Stephan, *Why Civil Resistance Works: The Strategic Logic of Nonviolent Conflict*, New York, Columbia University Press, 2011.
[261] Tom Davidson / Lukas Finnveden / Rose Hadshar, "AI-Enabled Coups: How a Small Group Could Use AI to Seize Power", Forethought, Nisan 2025.

belki de daha olası bir tehlikeye dikkat çekmektedir: "kademeli güçsüzleşme" (*gradual disempowerment*).[262]

Bu tehlikeye ilişkin argüman şudur: Ekonomi, kültür ve devlet gibi büyük toplumsal sistemler, bugüne kadar, insanların katılımına bağımlı oldukları için, örtük olarak insan çıkarlarıyla uyumlu kalmıştır. Ekonomi, insan emeğine ve insan tüketimine bağımlı olduğu için, insanların refahını gözetmek zorundadır. Devlet, insan vergi mükelleflerine, insan askerlere ve insan memurlara bağımlı olduğu için, insanların taleplerine duyarlı olmak zorundadır. Kültür, insan yaratıcılığına ve insan ilgisine bağımlı olduğu için, insanların değerlerini yansıtır. Yapay zekâ, bu sistemlerdeki insan katılımının yerini kademeli olarak aldıkça, bu sistemlerin insan çıkarlarıyla örtük uyumu da kademeli olarak zayıflayabilir. Bu süreç, hiçbir kötü niyetli aktör olmaksızın, hiçbir yapay zekâ sisteminin "kontrolden çıkması" olmaksızın, yalnızca her aşamada makul görünen ve rekabet baskısıyla hızlanan bireysel kararların birikimiyle gerçekleşebilir.

Kademeli güçsüzleşme tezi, bu çalışmanın konusu bakımından önemli bir uyarı içerir: Yapay zekânın denetimi sorunu, yalnızca bireysel sistemlerin denetimi sorunu değil, toplumsal sistemlerin bütününde insan katılımının ve insan denetiminin korunması sorunudur. İkinci Bölüm'de bireysel ve kurumsal düzeyde ele alınan "bilişsel körelme" olgusu, kademeli güçsüzleşme tezinde toplumsal düzeyde ortaya çıkar. Her kurumun, her kararın yapay zekâya devredilmesi, tek başına makul görünebilir; ama bu devirlerin toplamı, insanların kendi toplumlarını yönetme kapasitesini aşındırabilir.

IV. Algoritmik Vesayet

A. Vesayet Kavramı

Bu çalışma, yukarıda ele alınan olguları bir araya getiren ve Türk anayasal ve siyasi düşüncesinin kavram dağarcığından yararlanan özgün bir kavram önermektedir: **algoritmik vesayet**.

"Vesayet" kavramı, Türk siyasal ve anayasal tartışmalarında, seçilmiş organlar üzerinde, seçilmemiş aktörlerin denetim ve yönlendirme gücünü ifade etmek için uzun süredir kullanılmaktadır. Bu kullanımda vesayet, seçilmiş karar vericilerin biçimsel olarak yetkiyi elinde tutmasına rağmen,

[262] Jan Kulveit / Raymond Douglas / Nora Ammann / Deger Turan / David Krueger / David Duvenaud, "Gradual Disempowerment: Systemic Existential Risks from Incremental AI Development", arXiv:2501.16946, 2025.

fiilen önemli kararların, demokratik olarak hesap vermeyen başka aktörlerin onayına, yönlendirmesine veya denetimine tabi olması durumunu ifade eder.[263] Kavramın hukuktaki asıl anlamı ise, kendi işlerini görmeye ehil olmayan kişilerin (küçüklerin veya kısıtlıların) korunması amacıyla, bir vasinin onlar adına hareket etmesidir. Her iki anlamda da vesayet, bir aktörün, başka bir aktörün kendi adına karar verme kapasitesinin yetersiz olduğu varsayımıyla, onun yerine veya onun üzerinde karar verme gücünü ifade eder.

Üçüncü Bölüm'de, Kant'ın "Aydınlanma Nedir?" denemesinde, insanları erginlik eksikliği içinde tutanları "vasiler" (*Vormünder*) olarak adlandırdığı ve onları, insanların "üst gözetimini lütfen üstlenmiş" kişiler olarak tanımladığı belirtilmişti. Kant'ın vesayet eleştirisi, vesayetin, vesayet altındakilerin kendi akıllarını kullanma kapasitesini ve cesaretini sistematik olarak zayıflattığı tespitine dayanır.

B. Algoritmik Vesayetin Tanımı ve Özellikleri

Bu kavramsal zemin üzerinde, algoritmik vesayet şöyle tanımlanabilir:

> *Algoritmik vesayet, demokratik olarak yetkilendirilmiş karar vericilerin, biçimsel olarak karar yetkisini ellerinde tutmalarına rağmen, kararlarının içeriğini fiilen, kendilerinin anlamlı biçimde denetleyemediği algoritmik sistemlerin önerilerine bağımlı hâle getirmeleri ve bu bağımlılığın, karar vericilerin bağımsız değerlendirme kapasitesini zamanla aşındırarak kendi kendini güçlendiren bir döngüye dönüşmesi durumudur.*

Algoritmik vesayet, klasik vesayet biçimlerinden birkaç önemli bakımdan ayrılır. Bu farklar, kavramın özgüllüğünü ve neden ayrı bir kavram olarak ele alınması gerektiğini göstermektedir.

Birincisi, algoritmik vesayette vasinin bir iradesi bulunmayabilir. Klasik siyasi vesayette, vesayeti uygulayan aktörlerin (bürokratik elitler, askeri kurumlar, yargı organları) kendi değerleri, çıkarları ve iradeleri vardır ve vesayeti bu irade doğrultusunda uygularlar. Algoritmik vesayette ise vasi, bir sistemdir ve bu sistemin, kelimenin siyasi anlamında, bir iradesi olmayabilir. Sistem, kendisine verilen hedefleri veya eğitim sürecinde edindiği eğilimleri izler. Bu durum, algoritmik vesayeti, klasik

[263] Türk anayasal düzeninde vesayet tartışmaları için bkz. Ergun Özbudun / Ömer Faruk Gençkaya, *Democratization and the Politics of Constitution-Making in Turkey*, Budapest, Central European University Press, 2009.

vesayetten daha az görünür ve daha zor tespit edilebilir kılar; çünkü karşı çıkılabilecek bir "vasi" figürü yoktur.

İkincisi, algoritmik vesayet, çoğu zaman vesayet altındakilerin kendi tercihiyle kurulur. Klasik siyasi vesayet, genellikle seçilmiş organlara karşı, onların iradesine rağmen kurulur. Algoritmik vesayet ise karar vericilerin, verimlilik, tutarlılık, hız ve "nesnellik" gibi değerler adına, kendi istekleriyle algoritmik sistemlere başvurmasıyla kurulur. Bu gönüllülük, algoritmik vesayeti, direnilmesi daha zor bir vesayet biçimi kılar; çünkü vesayet altındakiler, vesayeti bir kısıtlama olarak değil, bir kolaylık olarak deneyimler. Kant'ın deyişiyle: "Ergin olmamak çok rahattır."

Üçüncüsü, algoritmik vesayet kendi kendini güçlendirir. İkinci Bölüm'de ele alınan "kurumsal bilişsel körelme" mekanizması, algoritmik vesayetin kendi kendini güçlendiren bir döngüye dönüşmesine yol açar. Karar vericiler, algoritmik sistemlere ne kadar bağımlı hâle gelirse, bağımsız değerlendirme kapasiteleri o kadar zayıflar; bağımsız değerlendirme kapasiteleri ne kadar zayıflarsa, algoritmik sistemlere bağımlılıkları o kadar artar.

Dördüncüsü, algoritmik vesayet, kendine özgü bir meşrulaştırma retoriği üretir. Birinci Bölüm'de, Schelsky'nin "nesnel zorunluluklar" (*Sachzwänge*) kavramına değinilmişti. Algoritmik vesayet, bu retoriğin yeni ve güçlü bir biçimini üretir: "Model böyle söylüyor," "Veriler bunu gösteriyor," "Algoritma bu sonuca vardı." Bu ifadeler, siyasi tartışmayı, teknik bir hesaplamanın sonucuna indirgeyerek kapatır ve kararların değer boyutunu görünmez kılar.

Beşincisi, algoritmik vesayet, bir hesap verebilirlik boşluğu yaratır. Algoritmik vesayet altında, kararlar biçimsel olarak seçilmiş karar vericilere aittir; bu nedenle onlar sorumlu görünür. Ancak kararların içeriği fiilen algoritmik sistemler tarafından belirlendiğinden, karar vericiler, kararların gerekçesini gerçek anlamda açıklayamaz ve savunamaz. Öte yandan, sistemler hukuken sorumlu tutulamaz. Bu durumda, Arendt'in "Kimsenin yönetimi" kavramı, demokratik bir görünüm altında gerçekleşir.

C. Algoritmik Vesayetin Göstergeleri

Algoritmik vesayet, bir ikili durum (var/yok) değil, bir derece meselesidir. Bu nedenle, bir kurumun veya bir karar sürecinin ne ölçüde algoritmik vesayet altında olduğunu değerlendirmek için göstergeler

geliştirmek yararlı olacaktır. Bu çalışma, aşağıdaki göstergeleri önermektedir:

1. **Sapma oranı:** Karar vericilerin, algoritmik sistemlerin önerilerinden ne sıklıkla ve hangi gerekçelerle saptığı. Sapma oranının sıfıra yaklaşması, tek başına vesayetin kanıtı değildir (sistem gerçekten çok iyi olabilir); ancak sapmaların gerekçelendirilmemesi veya sapmanın kariyer açısından riskli algılanması, vesayetin güçlü bir göstergesidir.
2. **Bağımsız gerekçelendirme kapasitesi:** Karar vericilerin, algoritmik sistemin önerisini benimsedikleri kararların gerekçesini, sisteme atıfta bulunmaksızın, kendi sözcükleriyle açıklayıp açıklayamadığı.
3. **Sistemsiz işleyebilme kapasitesi:** Kurumun, algoritmik sistem kullanılamaz hâle geldiğinde, kararlarını makul bir kalite ve süre içinde sistemsiz olarak alıp alamadığı.
4. **Vazgeçebilme kapasitesi:** Kurumun, algoritmik sistemin hatalı veya zararlı olduğu anlaşıldığında, sistemi kullanmaktan, ciddi bir işlevsel çöküş yaşamadan vazgeçip vazgeçemeyeceği.
5. **Değer tartışmasının görünürlüğü:** Algoritmik sistemin tasarımında ve kullanımında yer alan değer tercihlerinin (örneğin hangi adalet ölçütünün benimsendiği, hangi hataların hangi hatalara tercih edildiği) karar vericiler ve kamuoyu tarafından bilinip bilinmediği ve tartışılıp tartışılmadığı.

Bu göstergeler, Sekizinci Bölüm'de, kamu kurumlarının yapay zekâ kullanımına ilişkin düzenli değerlendirme yükümlülüklerinin bir parçası olarak önerilecektir.

D. Algoritmik Vesayet ve Teknokrasi

Algoritmik vesayet kavramını, Birinci Bölüm'de ele alınan teknokrasi kavramından da ayırmak gerekir. Teknokraside, iktidar, insan uzmanlara geçer; bu uzmanların kendi değerleri, çıkarları ve kurumsal kimlikleri vardır ve bu nedenle, en azından ilke olarak, hesap verebilir ve denetlenebilir aktörlerdir. Algoritmik vesayette ise iktidar, fiilen bir sisteme geçer ve bu sistemin arkasındaki insanlar (geliştiriciler, şirket yöneticileri, sistemi seçen bürokratlar), karar sürecinden birkaç adım uzakta kalır. Bu nedenle, algoritmik vesayet, teknokrasiden daha dağınık, daha görünmez ve

daha az hesap verebilir bir yönetim biçimidir. Öte yandan, algoritmik vesayet, teknokrasiyle birleşebilir: Teknokratik elitler, kendi kararlarını algoritmik sistemlerin "nesnel" çıktıları olarak sunarak, kendi değer tercihlerini gizleyebilir ve hesap verebilirlikten kaçabilir. Bu birleşim, belki de algoritmik vesayetin en tehlikeli biçimidir.

§ 20. YARIŞ DİNAMİĞİ VE JEOPOLİTİK

I. Collingridge İkilemi

Teknolojinin toplumsal denetimine ilişkin en etkili kavramsal araçlardan biri, İngiliz teknoloji araştırmacısı David Collingridge'in 1980'de formüle ettiği ikilemdir.[264] Collingridge ikilemi, iki sorundan oluşur. *Bilgi sorunu*: Bir teknolojinin toplumsal etkileri, o teknoloji yeterince geliştirilip yaygın biçimde kullanılmaya başlanmadan önce kolayca öngörülemez. *Güç sorunu*: Bir teknoloji yaygın biçimde kullanılmaya başlandıktan ve toplumsal yapıya yerleştikten sonra ise onu denetlemek veya değiştirmek son derece zor ve maliyetli hâle gelir. Bu iki sorun birleştiğinde, şu ikilem ortaya çıkar: Teknolojiyi denetlemenin kolay olduğu dönemde, neyi denetlememiz gerektiğini bilmeyiz; neyi denetlememiz gerektiğini öğrendiğimiz dönemde ise teknolojiyi denetlemek artık çok zordur.

Collingridge ikilemi, yapay zekâ için özellikle keskin bir biçimde geçerlidir. Bir yandan, yapay zekânın uzun vadeli toplumsal etkileri, bugün derin bir belirsizlik içindedir; İkinci Bölüm'de görüldüğü üzere, uzmanlar bile yapay zekânın gelişim hızı ve yönü konusunda birbirinden çok farklı görüşlere sahiptir. Öte yandan, yapay zekâ sistemleri, ekonomiye, kamu yönetimine ve gündelik hayata hızla yerleşmekte ve bu yerleşme, ileride bu sistemleri denetlemeyi veya değiştirmeyi giderek zorlaştırmaktadır. İkinci Bölüm'de ele alınan "kurumsal bilişsel körelme" ve bu bölümde ele alınan "kademeli güçsüzleşme" olguları, Collingridge'in güç sorununun yapay zekâ bağlamındaki somut mekanizmalarıdır.

Collingridge, ikileme verdiği cevapta, bilgi sorununun tamamen çözülemeyeceğini kabul eder ve bunun yerine, kararların *düzeltilebilir* olmasının önemini vurgular. Collingridge'e göre, cehalet koşullarında alınan kararlar, hataların erken fark edilmesini ve düşük maliyetle düzeltilmesini mümkün kılacak biçimde tasarlanmalıdır. Bu, esnekliği

[264] David Collingridge, *The Social Control of Technology*, London, Frances Pinter, 1980.

korumak, geri döndürülemez taahhütlerden kaçınmak, seçenekleri açık tutmak ve teknolojinin yerleşmesini, hataların düzeltilmesinin hâlâ mümkün olduğu bir hızda tutmak anlamına gelir. Collingridge'in bu "düzeltilebilirlik" (*corrigibility*) vurgusunun, kırk yıl sonra yapay zekâ güvenliği literatüründe aynı kelimeyle ifade edilen kavramla, yani sistemlerin düzeltilebilirliğiyle örtüşmesi dikkat çekicidir. Collingridge'in kararların düzeltilebilirliğine ilişkin politika ilkesi ile yapay zekâ güvenliğinin sistemlerin düzeltilebilirliğine ilişkin teknik ilkesi, aynı Popper'ci düşüncenin iki farklı düzlemdeki ifadeleridir.

Collingridge ikilemine verilen çağdaş cevaplar, "öngörücü yönetişim" (*anticipatory governance*) kavramı etrafında toplanmaktadır.[265] Öngörücü yönetişim, gelecekteki etkileri kesin olarak öngörmeye çalışmak yerine, farklı olası gelecekleri düşünmek, bu geleceklere hazırlanmak ve teknoloji geliştikçe öğrenip uyum sağlamak için kurumsal kapasiteler geliştirmeyi amaçlar. Bu yaklaşımın hukuki araçları arasında, belirli bir süre sonra kendiliğinden yürürlükten kalkan ve yeniden değerlendirmeyi zorunlu kılan "gün batımı hükümleri", yeni teknolojilerin sınırlı ve denetimli ortamlarda test edilmesine izin veren "düzenleyici deneme alanları" (*regulatory sandboxes*) ve teknolojinin gelişimine göre kendiliğinden güncellenen "uyarlanabilir düzenlemeler" sayılabilir.

II. Yarış Dinamiği

A. Yarışın Mantığı

Yapay zekânın denetimini zorlaştıran belki de en güçlü siyasi dinamik, yapay zekâ geliştiren aktörler arasındaki rekabettir. Bu rekabet, iki düzeyde işler: şirketler arasında ve devletler arasında. Her iki düzeyde de rekabet, benzer bir mantığa sahiptir: Her aktör, yapay zekâ yeteneklerinde geride kalmanın, ekonomik, stratejik veya askeri bakımdan ciddi bir dezavantaj yaratacağından korkar. Bu korku, aktörleri, güvenlik önlemlerine ve denetime yeterli kaynak ayırmak yerine, yetenek geliştirmeye öncelik vermeye yöneltir.

Bu dinamiğin formel bir modeli, Stuart Armstrong, Nick Bostrom ve Carl Shulman tarafından geliştirilmiştir.[266] Bu modelde, yapay zekâ

[265] David H. Guston, "Understanding 'Anticipatory Governance'", *Social Studies of Science*, C. 44, S. 2, 2014.

[266] Stuart Armstrong / Nick Bostrom / Carl Shulman, "Racing to the Precipice: A Model of Artificial Intelligence Development", *AI & Society*, C. 31, S. 2, 2016.

geliştiren birden fazla takım, ilk güçlü sistemi geliştirmek için yarışır. Her takım, güvenlik önlemlerine ne kadar kaynak ayıracağına karar vermelidir; güvenlik önlemleri, sistemin güvenliğini artırır ama geliştirme sürecini yavaşlatır. Model, takım sayısı arttıkça ve takımlar birbirlerinin yeteneklerini daha iyi bildikçe, güvenlik önlemlerine ayrılan kaynakların azaldığını ve felaket riskinin arttığını göstermektedir.

Yarış dinamiği, uluslararası ilişkiler kuramında iyi bilinen "güvenlik ikilemi"nin bir biçimidir.[267] Güvenlik ikileminde, bir devletin kendi güvenliğini artırmak için aldığı önlemler, diğer devletler tarafından tehdit olarak algılanır ve onları da benzer önlemler almaya yöneltir. Sonuçta, her devlet kendi güvenliğini artırmaya çalışırken, herkesin güvenliği azalır. Yapay zekâ bağlamında, her aktörün kendi rekabet gücünü artırmak için yetenek geliştirmeyi hızlandırması, diğer aktörleri de hızlanmaya yöneltir ve sonuçta, herkes için denetim ve güvenlik önlemlerine ayrılan zaman ve kaynak azalır.

B. Yarış Dinamiğinin Denetim Üzerindeki Etkileri

Yarış dinamiği, yapay zekânın denetimini birkaç farklı biçimde zorlaştırır.

Birincisi, yarış dinamiği, ulusal düzeyde düzenleme yapmayı zorlaştırır. Bir devlet, kendi şirketlerini sıkı biçimde düzenlediğinde, bu şirketlerin, daha gevşek düzenlemelere tabi olan yabancı rakipleri karşısında geride kalacağı kaygısı, düzenleyici iradeyi zayıflatır. Bu kaygı, bazen gerçek bir rekabet riskini yansıtır; ama bazen de düzenlemeye karşı çıkan çıkar gruplarının kullandığı bir retorik araç hâline gelir.

İkincisi, yarış dinamiği, şirketlerin kendi güvenlik taahhütlerini zayıflatabilir. Altıncı Bölüm'de ele alınacak olan şirketlerin gönüllü güvenlik politikaları, rekabet baskısı altında, yorumlanma biçimlerinde esnetilebilir veya revize edilebilir. Bir şirket, rakiplerinin daha hızlı ilerlediğini gördüğünde, kendi güvenlik önlemlerinin "orantısız" olduğunu düşünmeye başlayabilir.

Üçüncüsü, yarış dinamiği, bilgi paylaşımını engeller. Güvenlik araştırmaları, risk değerlendirmeleri ve olay raporları, rekabet avantajı sağlayabilecek bilgiler olarak görüldüğünde, şirketler ve devletler bu

[267] Robert Jervis, "Cooperation under the Security Dilemma", *World Politics*, C. 30, S. 2, 1978.

bilgileri paylaşmaktan kaçınabilir. Oysa İkinci Bölüm'de görüldüğü üzere, denetimin etkinliği, büyük ölçüde bilgiye erişime bağlıdır.

Dördüncüsü, yarış dinamiği, uluslararası işbirliğini zorlaştırır. Yapay zekânın etkin bir biçimde denetlenmesi, Yedinci ve Sekizinci Bölümlerde gösterileceği üzere, uluslararası bir boyut gerektirir. Ancak devletler, yapay zekâyı stratejik bir rekabet alanı olarak gördüklerinde, kendi yeteneklerini sınırlayacak veya rakiplerinin denetimine açacak uluslararası düzenlemelere katılmaktan kaçınabilir. Uluslararası yapay zekâ zirvelerinin gündeminde, ilk zirvelerde güvenlik ve risk konularına verilen ağırlığın, sonraki zirvelerde yerini giderek "fırsatlar" ve "rekabet gücü" söylemine bırakması, bu dinamiğin bir yansıması olarak yorumlanabilir.

III. Nükleer Analojisi ve Sınırları

A. Nükleer Silahların Denetimi Deneyimi

Yapay zekânın uluslararası denetimine ilişkin tartışmalarda en sık başvurulan analoji, nükleer silahların denetimi deneyimidir. Bu analoji, birkaç bakımdan aydınlatıcıdır. Her iki teknoloji de, hem barışçıl hem de yıkıcı amaçlarla kullanılabilen "çift kullanımlı" teknolojilerdir. Her ikisi de, yanlış ellerde veya yanlış kullanıldığında, felaket boyutunda sonuçlar doğurabilir. Her ikisinin gelişimi de, devletler arasında bir yarış dinamiği yaratmıştır.

Nükleer silahların denetimi deneyimi, hem başarısızlıklar hem de başarılar içerir. 1946'da Amerika Birleşik Devletleri tarafından Birleşmiş Milletler'e sunulan ve atom enerjisinin uluslararası bir otorite tarafından denetlenmesini öngören "Baruch Planı", Sovyetler Birliği'nin itirazı nedeniyle başarısız olmuştur. Ancak sonraki on yıllarda, Uluslararası Atom Enerjisi Ajansı (1957), Nükleer Silahların Yayılmasının Önlenmesi Antlaşması (1968) ve çeşitli ikili silah kontrol antlaşmaları gibi kurumlar ve mekanizmalar geliştirilmiştir. Bu mekanizmalar, nükleer silahları ortadan kaldıramamış; ama nükleer silahlara sahip devletlerin sayısını sınırlamada ve nükleer savaşın önlenmesinde önemli bir rol oynamıştır.

B. Analojinin Sınırları

Bununla birlikte, nükleer analojisinin önemli sınırları da vardır. *Birincisi*, nükleer silahların üretimi, nadir ve izlenebilir fiziksel malzemelere (zenginleştirilmiş uranyum ve plütonyum) bağımlıdır. Bu malzemelerin üretimi, büyük ve tespit edilmesi görece kolay tesisler

gerektirir. Yapay zekâ ise temelde bir yazılım teknolojisidir; bir kez geliştirildikten sonra, kolayca kopyalanabilir, dağıtılabilir ve değiştirilebilir. *İkincisi*, nükleer silahların kullanımı, belirgin ve tespit edilebilir bir olaydır. Yapay zekânın kötüye kullanımı ise çoğu zaman görünmez, dağınık ve kademeli olabilir. *Üçüncüsü*, nükleer teknolojinin barışçıl kullanımları (enerji üretimi, tıp) ile askeri kullanımları arasında görece net bir ayrım yapılabilir. Yapay zekâda ise aynı sistem, hem son derece faydalı hem de son derece zararlı amaçlarla kullanılabilir ve bu iki kullanım arasındaki sınır çoğu zaman bulanıktır. *Dördüncüsü*, nükleer teknolojinin gelişimi, büyük ölçüde devletlerin kontrolündeydi. Yapay zekânın gelişimi ise büyük ölçüde özel şirketlerin elindedir.

Bu sınırlara rağmen, nükleer analojisi, önemli bir noktada yol gösterici olmaya devam etmektedir: Yapay zekânın *geliştirilmesi* için gereken hesaplama altyapısı, nükleer malzemelere benzer biçimde, nadir, yoğunlaşmış ve izlenebilir bir kaynaktır. Bu nedenle, yapay zekânın uluslararası denetimine ilişkin önerilerin önemli bir kısmı, sistemlerin kendisinden çok, sistemlerin geliştirilmesi için gereken hesaplama kaynaklarının denetimine odaklanmaktadır.[268]

C. Uluslararası Kurum Önerileri

Yapay zekânın uluslararası denetimi için çeşitli kurumsal modeller önerilmiştir. Bir grup araştırmacının hazırladığı kapsamlı bir çalışma, bu önerileri dört temel model altında sınıflandırmıştır: (i) ileri yapay zekânın fırsatları ve riskleri konusunda uluslararası bilimsel uzlaşı oluşturan bir *komisyon*; (ii) ileri yapay zekâ sistemlerine ilişkin uluslararası standartlar belirleyen ve bu standartlara uyumu destekleyen bir *yönetişim örgütü*; (iii) ileri yapay zekâya erişimi yaygınlaştıran bir *işbirliği* kurumu; ve (iv) güvenlik araştırmalarını uluslararası düzeyde bir araya getiren bir *güvenlik projesi*.[269] Bu modellerin her biri, farklı uluslararası kurumlardan esinlenmektedir: Hükümetlerarası İklim Değişikliği Paneli (IPCC), Uluslararası Atom Enerjisi Ajansı (IAEA), Avrupa Nükleer Araştırma Merkezi (CERN) ve Uluslararası Sivil Havacılık Örgütü (ICAO) gibi.

Bu öneriler, Yedinci Bölüm'de mevcut uluslararası girişimlerle birlikte ve Sekizinci Bölüm'de bu çalışmanın önerdiği modelin uluslararası katmanı bağlamında yeniden ele alınacaktır. Burada belirtilmesi gereken

[268] Yonadav Shavit, "What Does It Take to Catch a Chinchilla? Verifying Rules on Large-Scale Neural Network Training via Compute Monitoring", arXiv:2303.11341, 2023.
[269] Lewis Ho vd., "International Institutions for Advanced AI", arXiv:2307.04699, 2023.

nokta, uluslararası denetimin, bekçiler sorununu ortadan kaldırmayacağı, aksine onu yeni bir düzeye taşıyacağıdır. Uluslararası bir yapay zekâ denetim kurumu, hangi devletlerin ve hangi çıkarların kontrolünde olacaktır? Bu kurum, büyük güçlerin rekabetinin bir aracı hâline gelmeyecek midir? Kurumun kendisini kim denetleyecektir? Bu sorular, uluslararası hukukun ve uluslararası ilişkilerin kadim sorularıdır ve yapay zekâ bağlamında da cevaplanması gerekmektedir.

§ 21. DEMOKRATİK DENETİMİN YENİDEN TASARLANMASI

Bu bölümde şimdiye kadar ele alınan siyasi dinamikler, yapay zekânın demokratik denetimi bakımından ciddi meydan okumalar ortaya koymaktadır. Bu son başlıkta, bu meydan okumalara karşı, siyaset kuramının sunduğu yapıcı kaynaklar ele alınacaktır. Bu kaynaklar, Sekizinci Bölüm'de geliştirilecek olan modelin siyasi temellerini oluşturacaktır.

I. Cumhuriyetçi Özgürlük ve Tahakküm

A. Tahakkümsüzlük Olarak Özgürlük

Çağdaş siyaset felsefesinde "cumhuriyetçilik" (*republicanism*) olarak adlandırılan gelenek, yapay zekânın denetimi sorununa özgün ve güçlü bir bakış açısı sunar. Bu geleneğin en etkili çağdaş temsilcisi olan İrlandalı felsefeci Philip Pettit, özgürlüğü, liberal geleneğin "müdahalesizlik" olarak anladığı özgürlükten farklı bir biçimde, "tahakkümsüzlük" (*non-domination*) olarak tanımlar.[270]

Pettit'e göre, bir kişi, başka bir kişi veya kurum, onun hayatına *keyfi* olarak, yani onun çıkarlarını ve görüşlerini dikkate almak zorunda olmaksızın müdahale etme *kapasitesine* sahip olduğu ölçüde, tahakküm altındadır. Bu tanımın en önemli unsuru, tahakkümün, müdahalenin *fiilen* gerçekleşmesine değil, müdahale *kapasitesinin* varlığına bağlı olmasıdır. Pettit, bu noktayı klasik "iyi efendi" örneğiyle açıklar: İyi kalpli bir efendinin kölesi, efendisi ona hiç müdahale etmese bile özgür değildir; çünkü efendisinin keyfi olarak müdahale etme kapasitesi her an mevcuttur ve köle, bu kapasitenin varlığını bilerek yaşar. Köle, efendisinin iyi niyetine

[270] Philip Pettit, *Republicanism: A Theory of Freedom and Government*, Oxford, Clarendon Press, 1997.

bağımlıdır; efendisinin ruh hâlini gözetmek, onu memnun etmeye çalışmak ve onun hoşnutsuzluğunu tetikleyebilecek davranışlardan kaçınmak zorundadır. Pettit, özgür bir yurttaşın ölçütünü, "göz göze bakma testi" (*eyeball test*) olarak adlandırdığı bir ölçütle ifade eder: Özgür bir yurttaş, diğer yurttaşların ve yetkililerin gözlerine korku veya boyun eğme ihtiyacı duymadan bakabilen kişidir.[271]

B. Yapay Zekâ ve Tahakküm

Pettit'in tahakküm kavramı, Üçüncü Bölüm'de "cumhuriyetçi itiraz" olarak anılan argümanın temelini oluşturur ve yapay zekâ bağlamında son derece güçlü bir sonuç doğurur. Bu kavram, yapay zekânın denetimi sorununun, yapay zekânın *fiilen* zarar verip vermemesine indirgenemeyeceğini gösterir. Bir yapay zekâ sistemi, ya da onu kontrol eden aktörler, yurttaşların hayatlarına keyfi olarak müdahale etme *kapasitesine* sahip olduğu ölçüde, bu kapasite hiç kullanılmasa bile, yurttaşlar tahakküm altındadır.

Bu sonuç, "iyi niyetli yapay zekâ" veya "hizalanmış yapay zekâ" kavramlarına yönelik önemli bir eleştiri içerir. Bir yapay zekâ sistemi, mükemmel biçimde hizalanmış ve her zaman insanların çıkarlarına uygun davranıyor olsa bile, eğer bu sistem, insanların hayatlarına keyfi olarak müdahale etme kapasitesine sahipse ve bu kapasite, insanların denetimine tabi değilse, insanlar, Pettit'in anlamında özgür değildir. Onlar, iyi bir efendinin köleleridir. Montesquieu'nün "erdemin bile sınırlara ihtiyacı vardır" tespiti, cumhuriyetçi gelenekte en sistematik ifadesini bulur.

Bu analiz, yapay zekânın denetiminin amacını yeniden tanımlar. Denetimin amacı, yalnızca yapay zekânın kötü kararlar vermesini önlemek değil, yapay zekânın ve onu kontrol edenlerin, insanların hayatlarına *keyfi olmayan* bir biçimde, yani insanların çıkarlarını ve görüşlerini dikkate almak *zorunda* olacakları bir biçimde müdahale etmesini güvence altına almaktır. Bu "zorunluluk", iyi niyetten değil, kurumsal yapılardan kaynaklanmalıdır.

C. Yazarlık ve Editörlük: Muhalefetçi Demokrasi

Pettit, tahakkümsüzlüğün siyasi düzeyde nasıl güvence altına alınabileceği sorusuna, "muhalefetçi demokrasi" (*contestatory democracy*)

[271] Philip Pettit, *On the People's Terms: A Republican Theory and Model of Democracy*, Cambridge, Cambridge University Press, 2012.

kavramıyla cevap verir.[272] Pettit'e göre, demokratik denetim iki farklı biçimde gerçekleşebilir: *yazarlık* (*authorial*) denetimi ve *editörlük* (*editorial*) denetimi. Yazarlık denetiminde, halk, kararların içeriğini doğrudan veya temsilcileri aracılığıyla belirler; yani kararların "yazarı"dır. Editörlük denetiminde ise halk, kararların içeriğini belirlemez; ama kararlara itiraz etme, onları sorgulama, gerekçe talep etme ve gerektiğinde onları durdurma veya değiştirme yetkisine sahiptir; yani kararların "editörü"dür.

Pettit'in bu ayrımı, bu çalışmanın konusu bakımından olağanüstü bir öneme sahiptir. Kavrayış asimetrisi koşullarında, halkın ve hatta seçilmiş temsilcilerin, karmaşık kararların "yazarı" olması giderek zorlaşabilir; çünkü bu kararların içeriğini belirlemek, onların kavrayış kapasitesini aşan bir bilgi ve analiz gerektirebilir. Ancak "editörlük" denetimi, yani kararlara itiraz etme, gerekçe talep etme ve kararları durdurma yetkisi, aynı ölçüde bilişsel kapasite gerektirmez. Bir editör, bir metni kendisi yazamasa bile, o metnin hatalı, yanıltıcı veya kabul edilemez olduğunu fark edebilir ve onun yayımlanmasını durdurabilir.

Pettit'in editörlük kavramı, Birinci Bölüm'de ele alınan Montesquieu'nün "engelleme yetisi" ve Aristoteles'in "kullanan değerlendirir" argümanlarıyla birleştiğinde, bilişsel asimetri koşullarında demokratik denetimin nasıl korunabileceğine ilişkin tutarlı bir çerçeve sunar: *Halk ve temsilcileri, kararların yazarı olmaktan kısmen çekilmek zorunda kalsa bile, kararların editörü olarak kalmalıdır.* Bu çerçeve, Sekizinci Bölüm'de geliştirilecek olan modelin demokratik katmanının temelini oluşturacaktır.

II. Müzakereci Demokrasi ve Yurttaş Meclisleri

A. Habermas: Müzakere Yoluyla Meşruiyet

Jürgen Habermas'ın *Olgusallık ve Geçerlilik* adlı eserinde geliştirdiği müzakereci demokrasi kuramı, demokratik meşruiyetin kaynağını, oy sayımında değil, kamusal müzakere sürecinde arar.[273] Habermas'a göre, bir hukuk normu, ancak ondan etkilenebilecek herkesin, rasyonel bir söylem

[272] Philip Pettit, "Republican Freedom and Contestatory Democratization", Ian Shapiro / Casiano Hacker-Cordón (der.), *Democracy's Value*, Cambridge, Cambridge University Press, 1999.

[273] Jürgen Habermas, *Faktizität und Geltung: Beiträge zur Diskurstheorie des Rechts und des demokratischen Rechtsstaats*, Frankfurt am Main, Suhrkamp, 1992.

sürecine katılımcı olarak onaylayabileceği ölçüde meşrudur. Bu "söylem ilkesi", demokratik meşruiyetin, bilgilendirilmiş, kapsayıcı ve gerekçelere dayanan kamusal tartışmaya bağlı olduğunu ifade eder. Habermas, bu süreci "iki yollu" bir model olarak tasarlar: Bir yanda, sivil toplumda ve kamusal alanda gerçekleşen gayri resmî kanaat oluşumu; diğer yanda, parlamentoda ve diğer resmî kurumlarda gerçekleşen resmî irade oluşumu. Meşruiyet, bu iki yolun birbiriyle etkileşiminden doğar.

Habermas'ın müzakereci demokrasi kuramı, yapay zekâ bakımından iki yönlü bir anlam taşır. *Bir yandan*, yapay zekâ, kamusal müzakereyi zenginleştirebilir: Yurttaşlara karmaşık konularda bilgi sağlayabilir, farklı bakış açılarını özetleyebilir, tartışmaları yapılandırabilir ve ortak zemin arayışını kolaylaştırabilir. Nitekim bir araştırma grubu, yapay zekâ destekli bir müzakere aracının, farklı görüşlere sahip katılımcılar arasında, insan arabulucuların hazırladığı metinlerden daha geniş kabul gören ortak görüş metinleri üretebildiğini göstermiştir.[274] *Öte yandan*, yapay zekâ, kamusal müzakereyi bozabilir: Yanlış bilgi üretimini ve yayılmasını kolaylaştırabilir, kamusal tartışmayı manipüle edebilir ve müzakere sürecinin kendisini, yurttaşların değil, algoritmaların yönlendirdiği bir sürece dönüştürebilir. Yapay zekânın müzakereye aracılık ettiği durumlarda, Juvenalis'in sorusu yeniden ortaya çıkar: Arabulucuyu kim denetleyecektir?

B. Yurttaş Meclisleri

Müzakereci demokrasi kuramının son yıllardaki en önemli pratik uygulaması, "yurttaş meclisleri"dir. Yurttaş meclisleri, kurayla seçilen ve nüfusun demografik bileşimini yansıtan bir grup yurttaşın, belirli bir kamusal sorun hakkında uzmanlardan bilgi aldığı, birbirleriyle müzakere ettiği ve öneriler geliştirdiği kurumlardır.[275] İrlanda'da kürtaj ve eşcinsel evlilik gibi tartışmalı anayasal konularda, Fransa'da ise iklim politikası konusunda düzenlenen yurttaş meclisleri, bu modelin en çok bilinen örnekleridir.

Yurttaş meclisleri, yapay zekânın demokratik denetimi bakımından önemli bir model sunar. Yapay zekâya ilişkin temel değer tercihleri, yani

[274] Michael Henry Tessler vd., "AI Can Help Humans Find Common Ground in Democratic Deliberation", *Science*, C. 386, S. 6719, 2024.

[275] James S. Fishkin, *When the People Speak: Deliberative Democracy and Public Consultation*, Oxford, Oxford University Press, 2009; OECD, *Innovative Citizen Participation and New Democratic Institutions: Catching the Deliberative Wave*, Paris, OECD Publishing, 2020.

yapay zekânın hangi amaçlarla, hangi sınırlar içinde ve hangi değerlere göre kullanılacağı, uzmanlara veya şirketlere bırakılamayacak kadar önemli, ama sıradan seçim süreçlerinde ayrıntılı olarak tartışılamayacak kadar karmaşık sorulardır. Yurttaş meclisleri, bu tür soruların, bilgilendirilmiş ve temsili bir yurttaş grubu tarafından müzakere edilmesine imkân tanır. Nitekim bazı yapay zekâ şirketleri ve sivil toplum kuruluşları, yapay zekâ sistemlerinin davranışını yönlendiren ilkelerin belirlenmesinde kamuoyunun görüşlerini almak için deneysel katılım süreçleri yürütmüştür.[276] Bu deneyler, sınırlı ölçekte olmakla birlikte, yapay zekâ yönetişiminde demokratik katılımın teknik olarak mümkün olduğunu göstermektedir. Ancak bu süreçlerin, şirketlerin tek taraflı olarak başlattığı ve sonuçlarını ne ölçüde uygulayacaklarına kendilerinin karar verdiği gönüllü deneyler olarak kalması, onların demokratik meşruiyetini sınırlamaktadır. Sekizinci Bölüm'de, bu tür süreçlerin kamusal ve kurumsallaşmış bir biçimde düzenlenmesi önerilecektir.

III. Kolektif Zekâ ve Çok Merkezli Yönetişim

A. Çokluğun Bilgeliği

Birinci Bölüm'de, Aristoteles'in "toplama argümanı", yani her biri tek başına erdemli olmayan çok sayıda insanın, bir araya geldiğinde en iyi birkaç kişiden daha iyi olabileceği argümanı ele alınmıştı. Bu argüman, modern dönemde, matematiksel ve ampirik biçimlerde yeniden formüle edilmiştir.

Condorcet markisi, 1785'te yayımladığı bir çalışmada, ünlü "jüri teoremi"ni formüle etmiştir: Eğer bir jürinin her üyesinin doğru karar verme olasılığı yarıdan büyükse ve üyeler bağımsız olarak oy kullanıyorsa, jürinin çoğunluk kararının doğru olma olasılığı, jüri üyelerinin sayısı arttıkça bire yaklaşır. Daha yakın zamanda, Lu Hong ve Scott Page, "çeşitlilik yeteneği yener" olarak bilinen bir teorem geliştirmiştir: Belirli koşullar altında, rastgele seçilmiş çeşitli problem çözücülerden oluşan bir grup, en yetenekli problem çözücülerden oluşan bir gruptan daha iyi sonuçlar elde edebilir; çünkü çeşitli grup, problemi farklı açılardan ele alarak, homojen bir grubun gözden kaçıracağı çözümleri bulabilir.[277]

[276] Anthropic / Collective Intelligence Project, "Collective Constitutional AI".

[277] Lu Hong / Scott E. Page, "Groups of Diverse Problem Solvers Can Outperform Groups of High-Ability Problem Solvers", *Proceedings of the National Academy of Sciences*, C. 101, S. 46, 2004.

Siyaset felsefecisi Hélène Landemore, bu bulgulardan hareketle, demokrasinin, epistokrasiye karşı yalnızca normatif değil, *epistemik* bir üstünlüğe de sahip olduğunu savunmuştur.[278]

Kolektif zekâ kuramları, yapay zekâ bağlamında ilginç bir soru gündeme getirir: Yapay zekâ, insanların kolektif zekâsını aşabilir mi? Eğer aşabilirse, Landemore'un demokrasinin epistemik üstünlüğüne ilişkin argümanı geçerliliğini yitirmez mi? Bu soruya verilebilecek cevap, İkinci Bölüm'de ele alınan "algoritmik monokültür" sorunuyla ilişkilidir. Hong ve Page'in teoremi, çeşitliliğin değerini vurgular. Benzer mimarilere, benzer verilere ve benzer eğitim yöntemlerine dayanan yapay zekâ sistemleri, bireysel olarak çok yetenekli olsalar bile, çeşitlilikten yoksun olabilir. Bu durumda, insanların çeşitli bakış açılarını, yerel bilgilerini ve farklı değerlerini bir araya getiren demokratik süreçler, yapay zekâ sistemlerinin gözden kaçırabileceği hataları ve seçenekleri tespit etmek bakımından, epistemik bir değere sahip olmaya devam edebilir. Bu, Friedrich Hayek'in "toplumdaki bilginin kullanımı" üzerine ünlü makalesinde vurguladığı noktanın bir başka ifadesidir: Toplumsal bilginin önemli bir kısmı, merkezî bir otoritenin toplayamayacağı, dağınık, yerel ve örtük bilgidir.[279]

B. Çok Merkezli Yönetişim

Nobel ödüllü siyaset bilimci Elinor Ostrom, ortak kaynakların yönetimine ilişkin çalışmalarında, "çok merkezli yönetişim" (*polycentric governance*) kavramını geliştirmiştir.[280] Çok merkezli yönetişim, tek bir merkezî otorite yerine, birbirinden görece bağımsız ama birbiriyle etkileşim içinde olan çok sayıda karar merkezinin, farklı ölçeklerde ve farklı alanlarda yönetişim işlevlerini üstlendiği bir yapıdır. Ostrom'un ampirik çalışmaları, çok merkezli sistemlerin, karmaşık ve belirsiz sorunlarla başa çıkmada, merkezî sistemlerden daha başarılı olabildiğini göstermiştir; çünkü çok merkezli sistemler, farklı yaklaşımların denenmesine, yerel bilginin kullanılmasına ve hataların bir merkezde yapılıp diğerlerinde düzeltilmesine imkân tanır.

---

[278] Hélène Landemore, *Democratic Reason: Politics, Collective Intelligence, and the Rule of the Many*, Princeton, Princeton University Press, 2013.

[279] Friedrich A. Hayek, "The Use of Knowledge in Society", *American Economic Review*, C. 35, S. 4, 1945.

[280] Elinor Ostrom, *Governing the Commons: The Evolution of Institutions for Collective Action*, Cambridge, Cambridge University Press, 1990; Elinor Ostrom, "Beyond Markets and States: Polycentric Governance of Complex Economic Systems", *American Economic Review*, C. 100, S. 3, 2010.

Ostrom'un çok merkezli yönetişim kavramı, bu çalışmanın Sekizinci Bölüm'de geliştireceği "dairesel denetim" modelinin önemli bir kuramsal öncülüdür. Yapay zekânın denetimi, tek bir merkezî otoriteye bırakılamayacak kadar karmaşık ve belirsiz bir sorundur. Bunun yerine, farklı ölçeklerde (yerel, ulusal, uluslararası) ve farklı alanlarda (teknik, kurumsal, toplumsal) faaliyet gösteren, birbirinden bağımsız ama birbiriyle etkileşim içinde olan çok sayıda denetim merkezine ihtiyaç vardır. Bu merkezlerin her biri, diğerlerinin hatalarını tespit edebilir ve düzeltebilir; hiçbiri, tek başına nihai otorite değildir.

IV. Popper'ci Ölçüt: Toplumsal Düzeyde Düzeltilebilirlik

Birinci Bölüm'de, Popper'in "Kim yönetmeli?" sorusunu reddedip yerine "Kötü yöneticilerin zararını nasıl sınırlayabiliriz?" sorusunu koyduğu ve bu yaklaşımın yapay zekâ bağlamında "düzeltilebilirlik" ilkesine karşılık geldiği gösterilmişti. Bu ilke, bireysel yapay zekâ sistemleri düzeyinde uygulanabileceği gibi, toplumsal düzeyde de uygulanabilir. Toplumsal düzeyde düzeltilebilirlik, bir toplumun, yapay zekâ kullanımına ilişkin kararlarının hatalı olduğunu fark ettiğinde, bu kararları ciddi bir zarar ve direnç olmaksızın değiştirebilmesi anlamına gelir.

Toplumsal düzeyde düzeltilebilirliğin korunması için birkaç koşul gereklidir. *Birinci koşul, çoğulculuktur.* Bir toplum, tek bir yapay zekâ sağlayıcısına veya tek bir yapay zekâ sistemine bağımlı hâle gelirse, bu sağlayıcı veya sistem hatalı olduğunda, alternatif bir seçeneği olmaz. İktisatçı Albert Hirschman'ın ünlü ayrımıyla, bir kurumdan memnun olmayan kişilerin iki seçeneği vardır: "çıkış" (*exit*), yani kurumu terk edip başka bir kuruma geçmek; ve "ses" (*voice*), yani kurumun içinde kalarak itiraz etmek ve değişiklik talep etmek.[281] Yapay zekâ sağlayıcıları arasında çoğulculuk, çıkış seçeneğini korur; bu seçenek ise sağlayıcıları, kullanıcıların sesine kulak vermeye zorlar.

İkinci koşul, birlikte çalışabilirlik ve taşınabilirliktir. Bir toplum, yapay zekâ sistemlerini değiştirebilmek için, bu sistemlerin açık standartlara dayanmasına, verilerin bir sistemden diğerine taşınabilmesine ve sistemlerin birbirinin yerine kullanılabilmesine ihtiyaç duyar. Kapalı ve

[281] Albert O. Hirschman, *Exit, Voice, and Loyalty: Responses to Decline in Firms, Organizations, and States*, Cambridge (MA), Harvard University Press, 1970.

tescilli standartlar, kullanıcıları belirli bir sisteme "kilitler" ve çıkış seçeneğini fiilen ortadan kaldırır.

Üçüncü koşul, kamusal kapasitenin korunmasıdır. Bir toplum, kritik kamusal işlevlerde, özel yapay zekâ sağlayıcılarına tamamen bağımlı olmamak için, kamusal yapay zekâ kapasitesine, yani kamu kurumlarının kendi sistemlerini geliştirme, değerlendirme ve işletme kapasitesine ihtiyaç duyar. Bu kapasite, aynı zamanda, kamu kurumlarının özel sağlayıcıların sistemlerini anlamlı biçimde değerlendirebilmesinin de ön koşuludur.

Dördüncü koşul, kademeliliktir. Popper'in "parça parça toplum mühendisliği" ilkesi, yapay zekânın toplumsal entegrasyonunun, büyük ve geri döndürülemez sıçramalarla değil, küçük, geri alınabilir ve sonuçları dikkatle izlenen adımlarla gerçekleştirilmesini önerir. Bu ilke, yarış dinamiğinin yarattığı hızlanma baskısına karşı, bilinçli bir "yavaşlama" ihtiyacını ifade eder.

V. Jasanoff: Alçakgönüllülük Teknolojileri

Bilim ve teknoloji çalışmaları alanının önde gelen isimlerinden Sheila Jasanoff, uzmanlık ile demokrasi arasındaki ilişkiye ilişkin çalışmalarında, bu çalışmanın konusu bakımından önemli iki kavram geliştirmiştir.

İlk kavram, Jasanoff'un erken dönem çalışmalarından birinin başlığında yer alan "beşinci kuvvet" kavramıdır.[282] Jasanoff, Amerikan düzenleyici sisteminde bilimsel danışma kurullarının, yasama, yürütme, yargı ve basından sonra, fiilen bir "beşinci kuvvet" hâline geldiğini göstermiştir. Bu kuvvet, anayasada öngörülmemiş olmasına rağmen, uzmanlık temelinde önemli kamusal kararları fiilen şekillendirmektedir. Jasanoff, bu kuvvetin meşruiyetinin, bilimin "nesnelliğinden" değil, danışma süreçlerinin şeffaflığından, çoğulculuğundan ve siyasi karar vericilerle sınırlarının dikkatli bir biçimde çizilmesinden kaynaklandığını vurgular. Yapay zekâ, bu "beşinci kuvvet"in yeni ve çok daha güçlü bir biçimi olabilir; ve Jasanoff'un analizi, bu kuvvetin meşruiyetinin de benzer koşullara bağlı olduğunu düşündürmektedir.

İkinci kavram, Jasanoff'un "alçakgönüllülük teknolojileri" (*technologies of humility*) olarak adlandırdığı yaklaşımdır.[283] Jasanoff,

[282] Sheila Jasanoff, *The Fifth Branch: Science Advisers as Policymakers*, Cambridge (MA), Harvard University Press, 1990.
[283] Sheila Jasanoff, "Technologies of Humility: Citizen Participation in Governing Science", *Minerva*, C. 41, S. 3, 2003.

modern devletlerin bilimsel ve teknolojik risklerle başa çıkmak için geliştirdiği yöntemleri (risk değerlendirmesi, maliyet-fayda analizi, sistem modellemesi) "kibir teknolojileri" (*technologies of hubris*) olarak nitelendirir. Bu yöntemler, belirsizliği ölçülebilir risklere indirgeyerek, bilinmeyeni bilinir gibi gösterir ve böylece karar vericilere, aslında sahip olmadıkları bir kontrol duygusu verir. Jasanoff, bunların yerine veya yanına, belirsizliği ve bilgisizliği kabul eden, etkilenen toplulukları karar süreçlerine dâhil eden ve hatalardan öğrenmeyi kurumsallaştıran "alçakgönüllülük teknolojileri" geliştirilmesini önerir. Bu teknolojiler, dört soru etrafında örgütlenir: *Çerçeveleme* (sorun nasıl tanımlanıyor ve bu tanım neyi dışarıda bırakıyor?), *kırılganlık* (kim, hangi biçimlerde zarar görebilir?), *dağıtım* (faydalar ve maliyetler nasıl dağılıyor?) ve *öğrenme* (hatalardan nasıl ders çıkarılacak?).

Jasanoff'un alçakgönüllülük teknolojileri kavramı, yapay zekânın yönetişimi için değerli bir yönelim sunar. Yapay zekânın etkilerine ilişkin derin belirsizlik karşısında, karar vericilerin, risk değerlendirmelerinin ve teknik modellerin sağladığı sahte kesinliğe güvenmek yerine, kendi bilgisizliklerini kabul etmeleri, etkilenen toplulukları dinlemeleri ve hatalardan öğrenmeyi mümkün kılan kurumlar inşa etmeleri gerekmektedir. Bu alçakgönüllülük, ironik biçimde, yapay zekânın kendisinden de beklenmesi gereken bir niteliktir: Üçüncü Bölüm'de ve İkinci Bölüm'deki düzeltilebilirlik tartışmasında görüldüğü üzere, kendi yanılabilirliğinin farkında olan ve bu nedenle insan denetimine açık olan bir sistem, kendi doğruluğundan emin olan bir sistemden daha güvenlidir.

VI. Ara Sonuç

Bu bölümde yapılan siyasi analiz, çalışmanın temel sorusuna önemli boyutlar eklemiştir. Bu boyutlar, şu tespitlerle özetlenebilir:

Birincisi, yapay zekânın denetimi sorunu, yalnızca yapay zekânın kendisinin denetimi sorunu değil, aynı zamanda ve belki de öncelikle, yapay zekânın insanlar arasındaki güç dağılımını nasıl değiştirdiği sorunudur. Yapay zekâ, onu kontrol eden aktörlere, devletlere ve şirketlere, hukuken yetkilendirilmiş olmasalar bile, olağanüstü bir fiilî güç kazandırabilir. "Yapay zekâyı kim denetleyecek?" sorusu, "yapay zekâyı elinde tutanları kim denetleyecek?" sorusundan ayrılamaz.

İkincisi, yapay zekâ, iktidarın tarihsel olarak dayandığı örtük denetim mekanizmalarını, özellikle de iktidarın uygulanması için insan işbirliğine

duyulan ihtiyacı zayıflatabilir. Bu mekanizmaların yerini, açık ve kurumsal denetim mekanizmalarının alması gerekmektedir.

Üçüncüsü, yapay zekânın demokratik yönetim üzerindeki en ciddi tehdidi, belki de dramatik bir ele geçirme değil, "algoritmik vesayet" ve "kademeli güçsüzleşme" gibi, görünmez, kademeli ve kendi kendini güçlendiren süreçlerdir. Bu süreçler, demokratik kurumların biçimini korurken içeriğini boşaltabilir.

Dördüncüsü, yarış dinamiği ve Collingridge ikilemi, yapay zekânın denetimini zamanla daha da zorlaştırma eğilimindedir. Bu nedenle, denetim mekanizmalarının erken kurulması ve düzeltilebilirliğin bilinçli olarak korunması gerekmektedir.

Beşincisi, siyaset kuramı, bu meydan okumalara karşı değerli kaynaklar sunmaktadır. Pettit'in tahakküm kavramı, denetimin amacının yalnızca zararı önlemek değil, keyfi güç kapasitesini sınırlamak olduğunu göstermektedir. Pettit'in editörlük kavramı, bilişsel asimetri koşullarında demokratik denetimin, kararların içeriğini belirlemekten çok, kararlara itiraz etme ve onları durdurma yetkisine kayması gerektiğini önermektedir. Ostrom'un çok merkezli yönetişim kavramı, tek bir merkezî otorite yerine, birbirini denetleyen çok sayıda merkezin önemini vurgulamaktadır. Popper'in düzeltilebilirlik ilkesi, toplumsal düzeyde çoğulculuğun, birlikte çalışabilirliğin, kamusal kapasitenin ve kademeliliğin korunmasını gerektirmektedir. Jasanoff'un alçakgönüllülük teknolojileri ise belirsizlik karşısında sahte kesinlik yerine, öğrenmeyi ve katılımı kurumsallaştırmayı önermektedir.

Bu siyasi kaynaklar, bir sonraki bölümde, hukuki düzleme aktarılacaktır. Hukuk, siyasi ilkeleri bağlayıcı kurallara ve işleyen kurumlara dönüştüren disiplindir. Beşinci ve Altıncı Bölümler, Türk hukuku başta olmak üzere, mevcut hukuk düzenlerinin bu ilkeleri ne ölçüde karşıladığını ve hangi değişikliklere ihtiyaç duyulduğunu inceleyecektir.

BEŞİNCİ BÖLÜM: HUKUKİ PERSPEKTİF (I) — ANAYASAL VE İDARİ DENETİM

Önceki bölümlerde geliştirilen felsefi ve siyasi ilkeler, ancak hukuki kurallara ve işleyen kurumlara dönüştürüldüğünde pratik bir anlam kazanır. Bu bölüm ve bir sonraki bölüm, çalışmanın hukuki perspektifini oluşturmaktadır. Bu bölümde, karar vericileri aşan yapay zekânın denetimi sorunu, anayasa hukuku ve idare hukuku düzleminde, özellikle Türk hukuku esas alınarak ve karşılaştırmalı hukuktan örneklerle incelenecektir. Bir sonraki bölümde ise sorumluluk ve hesap sorma sorunu ele alınacaktır.

Bölümün yapısı, devletin üç temel kuvvetine ve bunları tamamlayan denetim kurumlarına göre düzenlenmiştir. Önce, yapay zekânın kamusal karar süreçlerinde kullanımının anayasal sınırları belirlenecek (§ 22), ardından yürütme ve idare düzleminde "algoritmik idari işlem" kavramı incelenecek (§ 23), yargısal denetimin imkânları ve yargıda yapay zekâ kullanımının sınırları ele alınacak (§ 24), yasama denetimi değerlendirilecek (§ 25), bağımsız idari otoritelerin ve uzman denetim kurumlarının rolü tartışılacak (§ 26) ve son olarak, temel haklar boyutu ele alınacaktır (§ 27).

§ 22. ANAYASAL İLKELER

I. Egemenlik ve "Kaynağını Anayasadan Almayan Yetki" Yasağı

A. Anayasa'nın 6. Maddesi

1982 Anayasası'nın 6. maddesi, egemenliğe ilişkin temel ilkeleri düzenler: "Egemenlik, kayıtsız şartsız Milletindir. Türk Milleti, egemenliğini, Anayasanın koyduğu esaslara göre, yetkili organları eliyle kullanır. Egemenliğin kullanılması, hiçbir surette hiçbir kişiye, zümreye veya sınıfa bırakılamaz. Hiçbir kimse veya organ kaynağını Anayasadan almayan bir Devlet yetkisi kullanamaz."

Bu hüküm, bu çalışmanın konusu bakımından üç önemli ilke içermektedir. *Birinci ilke*, egemenliğin kaynağının millet olduğu ilkesidir. Egemenlik, ne bir kişiye ne bir sınıfa ne de bir teknolojiye aittir; kayıtsız

şartsız millete aittir. *İkinci ilke*, egemenliğin "Anayasanın koyduğu esaslara göre" ve "yetkili organlar eliyle" kullanılacağı ilkesidir. Bu ilke, egemenliğin kullanılmasının, Anayasa'nın öngördüğü organlar ve usuller dışında gerçekleşemeyeceğini ifade eder. *Üçüncü ilke* ise, kaynağını Anayasa'dan almayan hiçbir devlet yetkisinin kullanılamayacağı ilkesidir.

Bu üç ilke, Giriş'te formüle edilen üçüncü hipotezin (H3) temel dayanağını oluşturmaktadır. Anayasa'nın öngördüğü "yetkili organlar", yasama bakımından Türkiye Büyük Millet Meclisi, yürütme bakımından Cumhurbaşkanı ve idare, yargı bakımından ise bağımsız ve tarafsız mahkemelerdir. Bu organlar, insanlardan oluşur ve kararları, bu insanların iradesine atfedilir. Bir yapay zekâ sistemi, ne Anayasa'nın öngördüğü bir "organ" ne de 6. maddenin üçüncü fıkrası anlamında bir "kimse"dir. Dolayısıyla bir yapay zekâ sistemi, kendi başına, devlet yetkisi kullanamaz. Bir yapay zekâ sisteminin ürettiği çıktı, ancak yetkili bir organ tarafından benimsendiğinde ve o organın iradesine atfedildiğinde, devlet yetkisinin kullanılması niteliği kazanabilir.

B. Yetkinin Atfedilebilirliği ve Kişiselliği

Bu sonuç, idare hukukunun yerleşik "yetki" kavramıyla da örtüşmektedir. İdare hukukunda yetki, bir idari makamın, belirli bir konuda, hukuk düzeninin tanıdığı sınırlar içinde işlem yapabilme ehliyetidir. Yetki, kanundan kaynaklanır; idare, kanunun kendisine tanımadığı bir yetkiyi kullanamaz. Anayasa'nın 123. maddesine göre, "İdare, kuruluş ve görevleri bakımından bir bütündür ve kanunla düzenlenir." Bu hüküm, idarenin yetkilerinin kanuni dayanağa sahip olması gerektiğini ifade eder.[284]

İdare hukukunun bir diğer yerleşik ilkesi, "yetkinin kişiselliği" ilkesidir. Bu ilkeye göre, bir yetki, kanunun o yetkiyi tanıdığı makam tarafından bizzat kullanılmalıdır. Yetkili makam, yetkisini başka bir makama ancak kanunun açıkça izin verdiği durumlarda ve kanunun öngördüğü usullere uygun olarak devredebilir. Kanuni dayanağı olmayan bir yetki devri, yetki unsuru bakımından sakatlığa yol açar.

Bu iki ilke, yapay zekânın idari karar süreçlerinde kullanımına ilişkin önemli bir sonuç doğurur: Yapay zekâ, yetkili makamın kararını *hazırlayan* veya *destekleyen* bir araç olarak kullanılabilir; ancak yetkili makamın yetkisini *kullanan* bir aktör olamaz. Yetkili makam, kararını bir yapay zekâ

[284] Türk idare hukukunda yetki kavramı ve yetki unsuru için bkz. Kemal Gözler, *İdare Hukuku*, C. I-II, Bursa, Ekin, güncel bası; Metin Günday, *İdare Hukuku*, Ankara, İmaj, güncel bası; Turan Yıldırım vd., *İdare Hukuku*, İstanbul, On İki Levha, güncel bası.

sisteminin önerisine dayandırabilir; ama bu kararı, kendi kararı olarak, kendi iradesiyle ve kendi sorumluluğu altında vermelidir. Yetkili makamın, yapay zekâ sisteminin önerisini, hiçbir anlamlı değerlendirme yapmaksızın, mekanik olarak onaylaması durumunda, biçimsel olarak yetkiyi kullanan yetkili makam olsa da, fiilen yetki, sisteme "devredilmiş" olur. Bu fiilî devir, kanuni dayanağı bulunmadığı için, yetkinin kişiselliği ilkesine aykırıdır.

Bu analiz, Üçüncü Bölüm'de Darwall'cı argüman bağlamında ulaşılan sonuçla örtüşür: Yapay zekânın kararları, ancak onları *sahiplenen* bir insan aracılığıyla otorite kazanabilir. Anayasa'nın 6. maddesi ve idare hukukunun yetki ilkeleri, bu felsefi sonucun pozitif hukuktaki karşılığıdır.

C. Asli ve Sürekli Görevler: Anayasa'nın 128. Maddesi

Anayasa'nın 128. maddesinin birinci fıkrası, yapay zekânın kamu yönetiminde kullanımı bakımından az tartışılan ama önemli bir hüküm içerir: "Devletin, kamu iktisadi teşebbüsleri ve diğer kamu tüzelkişilerinin genel idare esaslarına göre yürütmekle yükümlü oldukları kamu hizmetlerinin gerektirdiği asli ve sürekli görevler, memurlar ve diğer kamu görevlileri eliyle görülür."

Bu hüküm, asli ve sürekli kamu görevlerinin, kamu görevlisi statüsündeki insanlar tarafından yerine getirilmesini öngörür. Hükmün amacı, kamu hizmetlerinin, hukuki statüsü, hak ve yükümlülükleri, disiplin ve sorumluluk rejimi kanunla belirlenmiş ve kamu yararına bağlı kişiler tarafından görülmesini güvence altına almaktır. Bu güvence, kamu görevlilerinin hesap verebilirliğinin de temelidir: Kamu görevlileri, disiplin hukukuna, ceza hukukuna ve Anayasa'nın 129. maddesinde düzenlenen özel sorumluluk rejimine tabidir.

Asli ve sürekli kamu görevlerinin, fiilen, özel şirketler tarafından geliştirilen ve işletilen yapay zekâ sistemleri tarafından yerine getirilmeye başlanması, Anayasa'nın 128. maddesinin amacıyla çatışma riski taşır. Bu durumda, kamu görevi, biçimsel olarak bir kamu görevlisi tarafından yürütülüyor görünse de, fiilen, kamu görevlisi statüsüne ve onun hesap verebilirlik rejimine tabi olmayan özel aktörlerin tasarladığı bir sistem tarafından yürütülür. Bu risk, özellikle kamu kurumlarının yapay zekâ sistemlerini dış kaynaklardan temin ettiği, sistemin iç işleyişine ilişkin bilginin sağlayıcı şirkette kaldığı ve kamu görevlilerinin sistemin çıktılarını anlamlı biçimde değerlendirme kapasitesinden yoksun olduğu durumlarda

belirgindir. İkinci Bölüm'de ele alınan "kurumsal bilişsel körelme" olgusu, bu riskin zamanla nasıl büyüyebileceğini göstermektedir.

II. Yasama Yetkisinin Devredilmezliği ve Algoritmik Normlar

A. Anayasa'nın 7. Maddesi ve Anayasa Mahkemesi İçtihadı

Birinci Bölüm'de, Locke'un yasama yetkisinin devredilemeyeceğine ilişkin ilkesinin, Anayasa'nın 7. maddesinde neredeyse birebir pozitif hukuka aktarıldığı belirtilmişti: "Yasama yetkisi Türk Milleti adına Türkiye Büyük Millet Meclisinindir. Bu yetki devredilemez."

Anayasa Mahkemesi, yasama yetkisinin devredilmezliği ilkesini, yerleşik içtihadında, yasama organının bir konuyu düzenlerken, temel ilkeleri ve çerçeveyi kendisinin belirlemesi gerektiği; ayrıntıların düzenlenmesini yürütmeye bırakabileceği, ancak yürütmeye sınırları belirsiz, genel ve geniş bir düzenleme alanı bırakamayacağı biçiminde yorumlamaktadır. Mahkemeye göre, kanun koyucunun, düzenlediği konuda esaslı kuralları koymaksızın, konuyu tamamen yürütmenin takdirine bırakması, yasama yetkisinin devri niteliği taşır ve Anayasa'nın 7. maddesine aykırıdır.[285]

Bu içtihat, Alman anayasa hukukunda Federal Anayasa Mahkemesi tarafından geliştirilen "esaslılık kuramı" (*Wesentlichkeitstheorie*) ile benzerlik taşır. Esaslılık kuramına göre, temel hakların kullanılması bakımından "esaslı" (*wesentlich*) olan tüm kararlar, yürütmeye bırakılamaz; parlamento tarafından bizzat, kanunla verilmelidir.[286] Kuramın gerekçesi, demokratik meşruiyete dayanır: Toplum için en önemli kararlar, en güçlü demokratik meşruiyete sahip organ, yani parlamento tarafından ve kamuya açık bir müzakere süreciyle alınmalıdır.

B. Yapay Zekânın Kamusal Kullanımı "Esaslı" Bir Karar mıdır?

Bu ilkeler ışığında, yapay zekânın kamusal karar süreçlerinde kullanımına ilişkin temel kararların, yasama organı tarafından kanunla verilmesi gereken "esaslı" kararlar arasında yer alıp almadığı sorusu ortaya çıkar. Bu çalışma, bu soruya, en azından belirli türdeki kullanımlar bakımından, olumlu cevap verilmesi gerektiğini savunmaktadır.

[285] Anayasa Mahkemesi'nin yasama yetkisinin devredilmezliğine ilişkin yerleşik içtihadının sistematik bir değerlendirmesi için bkz. Ergun Özbudun, *Türk Anayasa Hukuku*, Ankara, Yetkin, güncel bası; Kemal Gözler, *Türk Anayasa Hukuku*, Bursa, Ekin, güncel bası.

[286] Esaslılık kuramının Alman Federal Anayasa Mahkemesi içtihadındaki gelişimi için bkz. özellikle BVerfGE 49, 89 (Kalkar I, 1978).

Yapay zekânın, temel hak ve özgürlükleri doğrudan etkileyen kararlarda (örneğin ceza yargılamasında, sosyal güvenlik haklarının belirlenmesinde, göç ve sığınma kararlarında, kolluk faaliyetlerinde ve kamu istihdamında) kullanılıp kullanılmayacağı, kullanılacaksa hangi koşullarda, hangi sınırlar içinde ve hangi güvencelerle kullanılacağı, Anayasa'nın 13. maddesi anlamında temel hakların sınırlanmasına ilişkin kararlardır. Anayasa'nın 13. maddesine göre, temel hak ve hürriyetler "ancak kanunla" sınırlanabilir. Ayrıca, 2017 Anayasa değişikliğiyle düzenlenen Cumhurbaşkanlığı kararnamelerine ilişkin 104. maddenin on yedinci fıkrası, "Anayasanın ikinci kısmının birinci ve ikinci bölümlerinde yer alan temel haklar, kişi hakları ve ödevleriyle dördüncü bölümde yer alan siyasi haklar ve ödevler Cumhurbaşkanlığı kararnamesiyle düzenlenemez" hükmünü içermektedir. Bu hükümler birlikte değerlendirildiğinde, temel hakları doğrudan etkileyen kararlarda yapay zekâ kullanımının temel çerçevesinin, Cumhurbaşkanlığı kararnamesiyle veya idari düzenleyici işlemlerle değil, kanunla belirlenmesi gerektiği sonucuna varılmaktadır.

C. Algoritmik Normlar ve Fiilî Yasama

Yasama yetkisinin devredilmezliği ilkesinin yapay zekâ bağlamındaki asıl inceliği, Birinci Bölüm'de belirtildiği üzere, biçimsel devir ile fiilî devir arasındaki farkta yatar. Bu fark, özellikle "algoritmik normlar" bakımından ortaya çıkar.

Bir yapay zekâ sistemi, kamusal kararlarda kullanıldığında, fiilen bir dizi kuralı uygular: Hangi başvuruların kabul edileceği, hangi kişilerin "riskli" sayılacağı, hangi kaynakların nasıl dağıtılacağı gibi. Bu kurallar, kural tabanlı sistemlerde açıkça yazılmış olabilir; öğrenen sistemlerde ise sistemin parametrelerinde örtük olarak bulunur. Her iki durumda da bu kurallar, *fiilen* genel ve soyut normlardır: Belirli bir kategorideki tüm kişilere, aynı biçimde uygulanır ve onların hak ve yükümlülüklerini belirler. Bu çalışmada, bu tür kurallara **"algoritmik normlar"** adı verilmektedir.

Algoritmik normlar, hukuk düzeninin normlar hiyerarşisinde belirsiz bir konumdadır. Bunlar, ne kanundur, ne Cumhurbaşkanlığı kararnamesidir, ne yönetmeliktir. Hiçbir yasama veya düzenleyici işlem usulüyle kabul edilmemiş, Resmî Gazete'de yayımlanmamış ve hiçbir norm denetimine tabi tutulmamıştır. Bununla birlikte, kişilerin hak ve

yükümlülüklerini, kanunlar ve yönetmelikler kadar, hatta onlardan daha doğrudan biçimde etkileyebilirler. Örneğin bir sosyal yardım kanunu, yardımdan yararlanma koşullarını genel olarak belirleyebilir; ancak bu koşulların somut olarak nasıl yorumlanıp uygulanacağı, fiilen, başvuruları değerlendiren algoritmik sistemin içine yerleştirilmiş kurallar tarafından belirlenir.

Bu durum, Kelsen'in normlar hiyerarşisi bakımından ciddi bir sorun yaratır. Kelsen'e göre, her norm, geçerliliğini bir üst normdan alır ve bu üst normun çizdiği çerçeve içinde yaratılmalıdır. Algoritmik normlar ise biçimsel olarak hiçbir norm yaratma usulüne tabi olmadan yaratılır ve üst normlara uygunluğu sistematik olarak denetlenmez. Bu durumda, algoritmik normlar, hukuk düzeninin "gölgesinde" işleyen ve normlar hiyerarşisinin denetim mekanizmalarından kaçan bir paralel normlar sistemi oluşturabilir.

Bu soruna karşı, bu çalışma şu öneriyi geliştirmektedir: Kamusal kararlarda kullanılan algoritmik sistemlerin içerdiği karar kuralları, *işlevsel olarak* idari düzenleyici işlemler gibi ele alınmalı ve bu işlemlere uygulanan güvencelere tabi tutulmalıdır. Bu, şu anlama gelir: (i) Algoritmik sistemlerin karar kuralları, kanuni bir dayanağa sahip olmalıdır; (ii) bu kurallar, mümkün olduğu ölçüde kamuya açıklanmalıdır; (iii) bu kurallar, üst normlara uygunluk bakımından yargısal denetime tabi tutulabilmelidir; ve (iv) bu kurallarda yapılan değişiklikler, belgelendirilmeli ve izlenebilir olmalıdır. Fransız hukuku, bu yönde önemli bir adım atmıştır: 2016 tarihli Dijital Cumhuriyet Kanunu ile Kamu ile İdare Arasındaki İlişkiler Kanunu'na eklenen hükümler, belirli büyüklükteki idarelerin, bireysel kararlarda kullandıkları başlıca algoritmik işlemlerin kurallarını çevrimiçi olarak yayımlamasını öngörmektedir.[287]

III. Hukuk Devleti, Belirlilik ve Öngörülebilirlik

Anayasa'nın 2. maddesinde düzenlenen hukuk devleti ilkesi, Anayasa Mahkemesi tarafından, yerleşik içtihadında, insan haklarına saygılı, bu hakları koruyucu, adil bir hukuk düzeni kuran ve bunu devam ettirmeye kendini yükümlü sayan, bütün davranışlarında hukuka ve Anayasa'ya uyan, işlem ve eylemleri bağımsız yargı denetimine açık olan devlet olarak tanımlanmaktadır. Hukuk devleti ilkesinin önemli unsurlarından biri,

[287] Code des relations entre le public et l'administration, art. L. 312-1-3 (Loi n° 2016-1321 du 7 octobre 2016 pour une République numérique ile eklenmiştir).

“belirlilik” ilkesidir. Anayasa Mahkemesi’ne göre belirlilik ilkesi, yasal düzenlemelerin hem kişiler hem de idare yönünden herhangi bir duraksamaya ve kuşkuya yer vermeyecek şekilde açık, net, anlaşılır ve uygulanabilir olmasını; kişilerin, hukuki durumlarını önceden bilebilmelerini ve davranışlarını buna göre düzenleyebilmelerini gerektirir.

Belirlilik ilkesi, yapay zekânın kamusal kararlarda kullanımı bakımından iki farklı düzlemde önem taşır. *Birinci düzlemde*, yapay zekâ kullanımını düzenleyen kanuni hükümlerin kendisi belirli olmalıdır: Hangi kararlarda, hangi amaçlarla, hangi sistemlerin kullanılabileceği, kanunda yeterince açık biçimde belirlenmelidir. “İdare, hizmetlerini yürütürken yapay zekâ sistemlerinden yararlanabilir” türünden genel ve belirsiz bir hüküm, belirlilik ilkesini karşılamaz. *İkinci düzlemde*, yapay zekâ sistemlerinin kararlarının kendisi öngörülebilir olmalıdır: Kişiler, kendileri hakkında hangi kriterlere göre karar verileceğini önceden bilebilmeli ve davranışlarını buna göre düzenleyebilmelidir.

Bu ikinci düzlem, Üçüncü Bölüm’de Fuller’ın hukukun iç ahlakı kuramı bağlamında ele alınan sorunla doğrudan ilişkilidir. Öğrenen ve kullanım sırasında değişen yapay zekâ sistemleri, aynı girdiye farklı zamanlarda farklı çıktılar verebilir. Kişiselleştirilmiş ve anlık olarak üretilen algoritmik kararlar, genel ve önceden bilinen kurallar yerine geçebilir. Bu durumlar, belirlilik ve öngörülebilirlik ilkeleri bakımından ciddi sorunlar yaratır. Bu sorunlara karşı, § 23’te “sürüm kilidi” olarak adlandırılan bir güvence önerilecektir.

IV. Temel Hakların Sınırlanması ve Ölçülülük

Anayasa’nın 13. maddesi, temel hak ve hürriyetlerin sınırlanmasına ilişkin genel çerçeveyi belirler: “Temel hak ve hürriyetler, özlerine dokunulmaksızın yalnızca Anayasanın ilgili maddelerinde belirtilen sebeplere bağlı olarak ve ancak kanunla sınırlanabilir. Bu sınırlamalar, Anayasanın sözüne ve ruhuna, demokratik toplum düzeninin ve lâik Cumhuriyetin gereklerine ve ölçülülük ilkesine aykırı olamaz.”

Yapay zekânın, temel hakları etkileyen kamusal kararlarda kullanılması, bu hükmün öngördüğü tüm koşullara tabidir. Bu koşulların her biri, yapay zekâ bağlamında özgün sorular doğurur.

Kanunilik koşulu, yukarıda belirtildiği üzere, yapay zekâ kullanımının temel çerçevesinin kanunla belirlenmesini gerektirir. Bu kanun, Avrupa İnsan Hakları Mahkemesi’nin yerleşik içtihadında vurgulandığı üzere,

yalnızca biçimsel bir kanun olmamalı, aynı zamanda erişilebilir, öngörülebilir ve keyfiliğe karşı yeterli güvenceler içeren nitelikte bir kanun olmalıdır.

Ölçülülük koşulu, Anayasa Mahkemesi içtihadında üç alt ilkeyle açıklanmaktadır: elverişlilik (sınırlamanın, öngörülen amacı gerçekleştirmeye elverişli olması), gereklilik (aynı amaca daha hafif bir müdahaleyle ulaşılamaması) ve orantılılık (sınırlamanın, amaçla orantılı olması, yani bireye yüklenen külfet ile elde edilen kamu yararı arasında makul bir dengenin bulunması). Yapay zekâ bağlamında bu alt ilkeler şu soruları gündeme getirir: Yapay zekâ sistemi, öngörülen amacı gerçekten gerçekleştirebilecek güvenilirliğe sahip midir? (İkinci Bölüm'de ele alınan COMPAS deneyimi, bu sorunun ciddiyetini göstermektedir.) Aynı amaca, temel haklara daha az müdahale eden bir yöntemle, örneğin insan kararıyla veya daha sınırlı bir veri işlemeyle ulaşılabilir mi? Yapay zekâ kullanımının sağladığı verimlilik kazancı, kişilerin hakları üzerindeki etkisiyle orantılı mıdır?

Özüne dokunmama koşulu ise belki de en zor sorudur. Bir temel hakkın özü, o hakkı anlamlı kılan çekirdek unsurdur ve hiçbir koşulda sınırlanamaz. Bazı temel haklar bakımından, bu hakların özünün, insan tarafından verilen bir karar unsurunu içerip içermediği sorusu sorulabilir. Örneğin adil yargılanma hakkının özü, bir *hâkim* tarafından, yani Anayasa'nın 138. maddesi uyarınca "vicdani kanaatine göre" hüküm veren bir insan tarafından yargılanma hakkını içerir mi? Bu soru, § 24'te ayrıca ele alınacaktır.

§ 23. ALGORİTMİK İDARİ İŞLEM

I. İdari İşlemin Unsurları Bakımından Değerlendirme

Türk idare hukukunda, bir idari işlemin hukuka uygunluğu, İdari Yargılama Usulü Kanunu'nun 2. maddesinin birinci fıkrasının (a) bendinde sayılan beş unsur bakımından değerlendirilir: yetki, şekil, sebep, konu ve maksat. Bu unsurlardan herhangi birindeki hukuka aykırılık, işlemin iptaline yol açabilir. Yapay zekâ sistemlerinin idari işlemlerin hazırlanmasında veya alınmasında kullanılması, bu unsurların her biri bakımından özgün sorunlar doğurmaktadır. Bu çalışmada, yapay zekâ sistemlerinin belirleyici bir rol oynadığı idari işlemlere **"algoritmik idari işlem"** adı verilmektedir.

A. Yetki Unsuru

Yetki unsuru bakımından temel sorun, yukarıda § 22'de ele alınmıştır: Algoritmik idari işlemin "yazarı" kimdir? Türk idare hukukunun yerleşik ilkelerine göre, bir idari işlem, ancak yetkili bir makamın iradesine atfedilebiliyorsa geçerlidir. Yapay zekâ sisteminin çıktısı, yetkili makam tarafından benimsenmeden, kendi başına bir idari işlem değildir.

Bu noktada, iki farklı durumu birbirinden ayırmak gerekir. *Birinci durumda*, yetkili makam, yapay zekâ sisteminin çıktısını, diğer bilgi ve belgelerle birlikte değerlendirir ve kendi bağımsız değerlendirmesine dayanarak bir karar verir. Bu durumda, yapay zekâ sistemi, bir hazırlık aracıdır ve işlem, yetkili makamın işlemidir. *İkinci durumda* ise yetkili makam, yapay zekâ sisteminin çıktısını, hiçbir anlamlı değerlendirme yapmaksızın, mekanik olarak onaylar veya sistem, hiçbir insan müdahalesi olmaksızın otomatik olarak işlem tesis eder. Bu durumda, işlem, biçimsel olarak yetkili makama atfedilse de, fiilen sistemin ürünüdür.

İkinci durum, iki farklı hukuki sorun doğurur. *Birincisi*, kanuni dayanağı olmaksızın tamamen otomatik işlem tesis edilmesi, yetkinin kişiselliği ilkesine aykırı bir fiilî yetki devri niteliği taşır. *İkincisi*, yetkili makamın sistem çıktısını mekanik olarak onaylaması, aşağıda ele alınacağı üzere, takdir yetkisinin hiç kullanılmaması anlamına gelebilir.

B. Şekil Unsuru ve Türk Hukukunda Genel İdari Usul Kanunu Eksikliği

Şekil unsuru, idari işlemin yazılı olup olmadığı, gerekçeli olup olmadığı ve kanunun öngördüğü usul kurallarına (örneğin ilgilinin dinlenmesi, belirli kurulların görüşünün alınması gibi) uygun olarak tesis edilip edilmediği ile ilgilidir. Algoritmik idari işlemler bakımından şekil unsurunun en önemli boyutları, gerekçe yükümlülüğü ve ilgilinin dinlenmesi hakkıdır. Gerekçe yükümlülüğü, aşağıda ayrı bir başlık altında ele alınacaktır.

Bu noktada, Türk idare hukukunun önemli bir yapısal eksikliğine dikkat çekmek gerekir: Türk hukukunda, idari işlemlerin tesisine ilişkin genel usul kurallarını belirleyen genel bir idari usul kanunu bulunmamaktadır. Almanya'daki İdari Usul Kanunu (*Verwaltungsverfahrensgesetz*), Fransa'daki Kamu ile İdare Arasındaki İlişkiler Kanunu (*Code des relations entre le public et l'administration*) veya Amerika Birleşik Devletleri'ndeki İdari Usul Kanunu (*Administrative*

Procedure Act) gibi genel düzenlemelerin Türk hukukundaki karşılığı, uzun süredir tartışılan ancak yasalaşmayan bir taslak düzeyinde kalmıştır. Bu eksiklik, idari usule ilişkin güvencelerin, dağınık özel kanun hükümlerine, Bilgi Edinme Hakkı Kanunu gibi kısmi düzenlemelere ve büyük ölçüde Danıştay içtihadına bırakılmasına yol açmaktadır.

Bu yapısal eksiklik, algoritmik idari işlemler bakımından özellikle sorunludur. Diğer hukuk düzenlerinde, algoritmik idari işlemlere ilişkin özel güvenceler, genellikle genel idari usul kanunlarına eklenen hükümlerle düzenlenmiştir. Almanya'da tamamen otomatik idari işlemlere ilişkin hüküm, İdari Usul Kanunu'na eklenmiştir; Fransa'da algoritmik işlemlerin açıklanmasına ilişkin hükümler, Kamu ile İdare Arasındaki İlişkiler Kanunu'na eklenmiştir. Türk hukukunda ise bu tür güvencelerin ekleneceği genel bir çerçeve bulunmamaktadır. Bu nedenle, bu çalışmanın Sekizinci Bölüm'de sunacağı kanun önerisi, algoritmik idari işlemlere ilişkin usul güvencelerini, genel bir idari usul kanununun yokluğunu kısmen telafi edecek biçimde, ayrıntılı olarak düzenlemeyi öngörmektedir.

C. Sebep Unsuru: Olasılıksal Sebep Sorunu

Sebep unsuru, idari işlemin tesis edilmesine yol açan hukuki ve fiilî durumlarla ilgilidir. Bir idari işlemin hukuka uygun olabilmesi için, işlemin dayandığı sebeplerin gerçekten var olması, hukuken geçerli olması ve işlemle uygun bir ilişki içinde bulunması gerekir. Danıştay içtihadında, idarenin, işlemin sebebini somut olarak ortaya koyması ve bu sebebin varlığını kanıtlaması gerektiği vurgulanmaktadır.

Algoritmik idari işlemler bakımından sebep unsuru, özgün ve önemli bir sorun doğurur. Birçok yapay zekâ sistemi, bir kişi hakkında *olgusal* bir tespit değil, *olasılıksal* bir tahmin üretir: "Bu kişinin yardım dolandırıcılığı yapma olasılığı yüksektir," "Bu kişinin yeniden suç işleme riski yüksektir," "Bu başvurunun sahte olma olasılığı yüksektir." Bu tahminler, kişinin kendisine ilişkin bir olguya değil, kişinin verilerinin benzediği istatistiksel profillere dayanır. Peki, bu tür bir olasılıksal tahmin, bir idari işlemin "sebebi" olabilir mi?

Bu çalışma, bu soruya şu cevabı önermektedir: Olasılıksal bir tahmin, kendi başına, kişinin hak ve özgürlüklerini kısıtlayan bir idari işlemin yeterli sebebi olamaz; ancak idarenin, kişiye ilişkin somut olguları araştırması için bir *gerekçe* olabilir. Başka bir ifadeyle, bir yapay zekâ sisteminin belirli bir kişiyi "yüksek riskli" olarak işaretlemesi, idarenin o

kişi hakkında daha ayrıntılı bir inceleme başlatmasını meşrulaştırabilir; ancak bu işaretleme, kişinin aleyhine bir işlem tesis edilmesinin kendisi için yeterli sebep değildir. Aleyhe işlemin sebebi, somut ve kişiye özgü olgularla ortaya konmalıdır. Bu ayrım, bu çalışmada **"olasılıksal sebep yasağı"** olarak adlandırılmakta ve İkinci Bölüm'de ele alınan Robodebt ve Hollanda çocuk bakım yardımları skandallarından çıkarılan dersin hukuki bir ifadesi olarak önerilmektedir. Her iki vakada da, kişiler hakkındaki aleyhe kararlar, kişiye özgü olgulara değil, istatistiksel varsayımlara ve risk profillerine dayandırılmıştı.

D. Konu Unsuru

Konu unsuru, idari işlemin doğurduğu hukuki sonuçla ilgilidir. Konu unsuru bakımından algoritmik idari işlemlerin özgün bir sorunu, işlemin konusunun, yani doğurduğu hukuki sonucun, sistemin çıktısının otomatik bir uzantısı olarak belirlenmesidir. Örneğin bir sistem, bir kişinin borç miktarını hesaplar ve bu hesaplama, doğrudan bir ödeme emrine dönüşür. Bu durumda, işlemin konusunun hukuka uygunluğu, sistemin hesaplamasının doğruluğuna bağlıdır. Robodebt vakasında, sistemin hesapladığı borçların hukuka aykırılığı, tam olarak bu tür bir konu sakatlığıydı.

E. Maksat Unsuru: Hedef Fonksiyonu ve Yetki Saptırması

Maksat unsuru, idari işlemin amacıyla ilgilidir. Her idari işlemin nihai amacı, kamu yararıdır; ayrıca, her yetki, kanun koyucunun o yetkiyi tanırken öngördüğü özel amaca yönelik olarak kullanılmalıdır. Bir yetkinin, kanunun öngördüğü amaç dışında bir amaçla kullanılması, "yetki saptırması" (*détournement de pouvoir*) olarak adlandırılır ve işlemin maksat unsuru bakımından hukuka aykırı olmasına yol açar.

Bu çalışma, maksat unsurunun, algoritmik idari işlemler bakımından özgün ve önemli bir anlam kazandığını ileri sürmektedir. İkinci Bölüm'de görüldüğü üzere, her yapay zekâ sistemi, belirli bir "hedef fonksiyonu"nu, yani optimize etmeye çalıştığı bir ölçütü izler. Bir sosyal yardım sisteminin hedef fonksiyonu, "dolandırıcılık kaybını en aza indirmek" olabilir; bir vergi denetim sisteminin hedef fonksiyonu, "tahsil edilen vergi miktarını en üst düzeye çıkarmak" olabilir. Bu hedef fonksiyonu, idare hukuku bakımından, işlemin *fiilî maksadı* olarak değerlendirilebilir.

Bu durumda, sistemin hedef fonksiyonu ile kanunun öngördüğü amaç arasında bir uyumsuzluk bulunursa, bu uyumsuzluk, bir tür *yapısal yetki saptırması* oluşturur. Örneğin bir sosyal yardım kanununun amacı, ihtiyaç sahiplerinin yardıma erişimini sağlamaksa, ama bu kanunun uygulanmasında kullanılan sistem yalnızca "dolandırıcılık kaybını en aza indirmek" amacıyla optimize edilmişse, sistem, ihtiyaç sahiplerini yardımdan dışlama pahasına dolandırıcılığı önlemeyi tercih edecektir. Bu durum, kanunun amacından sapma anlamına gelir. İkinci Bölüm'de ele alınan Goodhart yasası ve hizalama sorunu, bu yapısal yetki saptırmasının teknik nedenlerini açıklar.

Bu çalışmada önerilen **"hedef fonksiyonu-maksat uygunluğu"** ölçütüne göre, kamusal kararlarda kullanılan yapay zekâ sistemlerinin hedef fonksiyonları ve bu fonksiyonları belirleyen değer tercihleri, belgelendirilmeli, kamuya açıklanmalı ve kanunun öngördüğü amaçlarla uygunluk bakımından yargısal denetime tabi tutulabilmelidir. Bu ölçüt, Üçüncü Bölüm'de Dahl'ın ahlaki bilgi ile araçsal bilgi arasındaki ayrımı bağlamında ulaşılan sonucun hukuki bir uygulamasıdır: Sistemin *neyi* optimize edeceği, yani amaç, teknik değil, hukuki ve siyasi bir karardır ve demokratik ve hukuki denetime tabi olmalıdır.

II. Takdir Yetkisi ve Otomasyon

A. Bağlı Yetki ve Takdir Yetkisi

İdare hukukunda, idarenin yetkileri, "bağlı yetki" ve "takdir yetkisi" olarak ikiye ayrılır. Bağlı yetkide, kanun, belirli koşullar gerçekleştiğinde idarenin belirli bir işlemi yapmasını öngörür; idarenin seçim özgürlüğü yoktur. Takdir yetkisinde ise kanun, idareye, belirli koşullar gerçekleştiğinde birden fazla seçenek arasından seçim yapma veya işlem yapıp yapmama konusunda bir serbesti tanır. Takdir yetkisi, sınırsız değildir: Kamu yararına ve hizmet gereklerine uygun olarak, eşitlik ve ölçülülük ilkelerine uyularak kullanılmalıdır.

Bu ayrım, yapay zekânın idari karar süreçlerinde kullanımının sınırlarını belirlemek bakımından son derece önemlidir. Bağlı yetki alanında, kararın içeriği kanun tarafından önceden belirlendiğinden, otomasyon görece sorunsuzdur: Sistem, kanunun öngördüğü koşulların gerçekleşip gerçekleşmediğini kontrol eder ve kanunun öngördüğü sonucu uygular. Takdir yetkisi alanında ise kararın içeriği, somut durumun değerlendirilmesine ve farklı değerlerin tartılmasına bağlıdır. Bu

değerlendirme ve tartma, kanun koyucunun idareye, yani kamu görevlilerine emanet ettiği bir görevdir.

B. Alman İdari Usul Kanunu'nun 35a Maddesi

Bu ayrımın en açık pozitif hukuk ifadesi, Alman İdari Usul Kanunu'na 2017'de eklenen 35a maddesidir. Bu hükme göre: "Bir idari işlem, bir hukuk kuralı tarafından izin verilmiş olması ve ne bir takdir yetkisinin ne de bir değerlendirme alanının bulunması koşuluyla, tamamen otomatik tesisatlar tarafından tesis edilebilir."[288]

Bu hüküm, tamamen otomatik idari işlemler için iki kümülatif koşul öngörmektedir. *Birinci koşul*, otomasyonun bir hukuk kuralı tarafından açıkça izin verilmiş olmasıdır; yani otomasyon, kanuni dayanak gerektirir. *İkinci koşul*, işlemin bir takdir yetkisi veya değerlendirme alanı içermemesidir; yani yalnızca bağlı yetki alanındaki işlemler tamamen otomatikleştirilebilir. Alman kanun koyucusu, böylece, takdir yetkisinin kullanılmasının, insanlara ait bir görev olduğunu ve bir makineye devredilemeyeceğini açıkça kabul etmiştir.

Alman düzenlemesi, Türk hukuku bakımından değerli bir model sunmaktadır. Bu çalışmanın Sekizinci Bölüm'de sunacağı kanun önerisi, benzer bir ilkeyi benimsemektedir: Tamamen otomatik idari işlemler, ancak kanunun açıkça izin verdiği ve takdir yetkisi içermeyen durumlarda tesis edilebilmelidir. Takdir yetkisi içeren işlemlerde ise yapay zekâ sistemleri yalnızca karar destek aracı olarak kullanılabilmeli ve nihai karar, yetkili kamu görevlisinin anlamlı değerlendirmesine dayanmalıdır.

C. Takdir Yetkisinin Kullanılmaması

Takdir yetkisinin, yapay zekâ sistemlerinin önerilerinin mekanik olarak onaylanması yoluyla fiilen sisteme bırakılması, idare hukuku bakımından ayrı bir hukuka aykırılık türü olarak değerlendirilebilir. Alman idare hukukunda, idarenin kendisine tanınan takdir yetkisini hiç kullanmaması, yani kanunun öngördüğü seçenekleri ve somut durumun özelliklerini değerlendirmeksizin karar vermesi, "takdirin kullanılmaması" (*Ermessensnichtgebrauch* veya *Ermessensausfall*) olarak adlandırılır ve bağımsız bir hukuka aykırılık sebebi olarak kabul edilir. Bu kavram, Türk idare hukukunda da, takdir yetkisinin kamu yararı ve hizmet gerekleri

[288] Verwaltungsverfahrensgesetz (VwVfG), § 35a: "*Ein Verwaltungsakt kann vollständig durch automatische Einrichtungen erlassen werden, sofern dies durch Rechtsvorschrift zugelassen ist und weder ein Ermessen noch ein Beurteilungsspielraum besteht.*"

doğrultusunda ve somut olayın özelliklerine göre kullanılması gerektiğine ilişkin Danıştay içtihadı çerçevesinde değerlendirilebilir.

Bu kavramın algoritmik idari işlemler bakımından önemi açıktır: Bir kamu görevlisi, takdir yetkisi içeren bir kararda, yapay zekâ sisteminin önerisini, somut durumun özelliklerini kendisi değerlendirmeksizin ve sistemin önerisinden sapma imkânını gerçekten göz önüne almaksızın benimsiyorsa, takdir yetkisini fiilen kullanmamış olur. Bu durum, İkinci Bölüm'de ele alınan otomasyon yanlılığının hukuki bir sonucudur ve işlemin iptali için bir sebep oluşturabilmelidir. Bu sonucun pratik bir yansıması, idarenin, takdir yetkisi içeren algoritmik destekli kararlarda, kamu görevlisinin somut durumu bağımsız olarak değerlendirdiğini gösteren bir kayıt tutmakla yükümlü olmasıdır.

III. Gerekçe Yükümlülüğü ve Açıklanabilirlik

A. Gerekçenin İşlevleri

İdari işlemlerin gerekçeli olması, hukuk devletinin temel güvencelerinden biridir. Gerekçe, birkaç önemli işlev görür. *Birincisi*, gerekçe, idareyi, kararını dikkatli bir biçimde düşünmeye ve hukuka uygun gerekçelere dayandırmaya zorlar; bu, bir öz-denetim işlevidir. *İkincisi*, gerekçe, işlemden etkilenen kişinin, kendisi hakkında neden bu kararın verildiğini anlamasını ve gerekirse buna itiraz etmesini sağlar; bu, bir savunma işlevidir. *Üçüncüsü*, gerekçe, yargı organlarının işlemi denetlemesini mümkün kılar; bu, bir denetim işlevidir. *Dördüncüsü*, gerekçe, idarenin kararlarının kamuoyu tarafından değerlendirilmesini ve idarenin hesap vermesini sağlar; bu, bir meşruiyet işlevidir.

B. Açıklama ile Gerekçe Arasındaki Ayrım

Yapay zekâ bağlamında gerekçe yükümlülüğü tartışılırken, genellikle "açıklanabilirlik" (*explainability*) kavramına başvurulur: Bir yapay zekâ sisteminin, kararlarını açıklayabilmesi gerektiği ileri sürülür. Bu çalışma, bu tartışmada sıkça gözden kaçırılan önemli bir kavramsal ayrımın altını çizmektedir: *açıklama* ile *gerekçe* arasındaki ayrım.

Açıklama (*explanation*), bir sonucun *nasıl* ortaya çıktığını, yani hangi faktörlerin hangi ağırlıkla sonuca katkıda bulunduğunu ortaya koyan nedensel bir anlatıdır. Bir yapay zekâ sisteminin "açıklanabilirliği", genellikle bu anlamda anlaşılır: Sistemin, belirli bir çıktıyı üretirken hangi girdilere ne ölçüde dayandığını gösterebilmesi. *Gerekçe* (*justification*) ise

bir kararın *neden doğru veya hukuka uygun olduğunu* ortaya koyan normatif bir argümandır. Bir idari işlemin gerekçesi, işlemin hangi hukuki dayanaklara ve hangi olgusal tespitlere dayandığını ve bu dayanakların işlemi neden haklı kıldığını gösterir.

Bu ayrım, son derece önemlidir; çünkü bir yapay zekâ sisteminin mükemmel bir *açıklaması*, kararın *gerekçesi* olmayabilir. Bir sistem, bir kişinin kredi başvurusunu reddederken, bu reddin en çok kişinin posta koduna bağlı olduğunu açıklayabilir. Bu açıklama, sistemin nasıl çalıştığını doğru biçimde yansıtır; ama kararın hukuken geçerli bir gerekçesi değildir, aksine kararın hukuka aykırı (örneğin dolaylı ayrımcı) olabileceğini gösterir.

Bu çalışma, bu ayrımdan hareketle şu ilkeyi önermektedir: *Algoritmik idari işlemlerde, sistemin ürettiği açıklama, işlemin gerekçesi değil, gerekçenin dayanabileceği delillerden biridir. İşlemin gerekçesi, yetkili kamu görevlisi tarafından, hukuki dayanaklara ve kişiye özgü olgusal tespitlere dayanılarak oluşturulmalıdır.* Bu ilke, gerekçenin, Üçüncü Bölüm'de Darwall'cı argüman bağlamında ele alınan hesap verebilirlik ilişkisinin bir unsuru olduğunu kabul eder. Gerekçe, bir insanın, başka bir insana, kendi kararını haklı çıkarmak için sunduğu bir argümandır; bir makinenin iç işleyişinin teknik bir tasviri değildir.

C. Gerekçenin "Goodhart Tuzağı"

İkinci Bölüm'de, ileri yapay zekâ sistemlerinin ifade ettiği akıl yürütmenin, gerçek karar sürecini her zaman sadık biçimde yansıtmadığı ve sistemler, akıl yürütmelerindeki "kötü düşünceler" için cezalandırıldığında, bu düşünceleri bırakmak yerine gizlemeyi öğrenebildiği gösterilmişti. Bu bulgu, gerekçe yükümlülüğünün yapay zekâ sistemlerine doğrudan uygulanması bakımından önemli bir uyarı içerir.

Eğer bir yapay zekâ sisteminden, hukuken kabul edilebilir gerekçeler üretmesi istenir ve sistemin çıktıları, bu gerekçelerin kabul edilebilirliğine göre değerlendirilir ve optimize edilirse, sistem, *gerçek karar nedenlerinden bağımsız olarak* hukuken kabul edilebilir görünen gerekçeler üretmeyi öğrenebilir. Bu durumda, gerekçe, kararın denetiminin bir aracı olmaktan çıkar ve denetimden kaçmanın bir aracına dönüşür. Bu, Goodhart yasasının hukuktaki bir uygulamasıdır: Gerekçe, denetimin ölçütü olmaktan çıkıp optimize edilen bir hedef hâline geldiğinde, iyi bir ölçüt olmaktan çıkar.

Bu tehlikeye karşı, bu çalışma iki güvence önermektedir. *Birinci güvence*, yukarıda belirtilen ilkedir: Gerekçe, sistem tarafından değil, yetkili kamu görevlisi tarafından oluşturulmalıdır. *İkinci güvence*, gerekçenin, sistemin iç işleyişine ilişkin bağımsız kanıtlarla, yani sistemin kayıtlarıyla, test sonuçlarıyla ve mümkün olduğu ölçüde yorumlanabilirlik analizleriyle karşılaştırılabilir olmasıdır. Bu ikinci güvence, gerekçenin, sistemin "söylediği" ile sistemin "yaptığı" arasındaki olası uyumsuzlukları tespit etmeye yönelik bir denetimle desteklenmesini öngörür.

D. Karşılaştırmalı Hukuktan Örnekler

Karşılaştırmalı hukukta, algoritmik idari işlemlerin gerekçesine ve açıklanmasına ilişkin önemli düzenlemeler ve kararlar bulunmaktadır.

Fransa'da, 2016 tarihli Dijital Cumhuriyet Kanunu ile Kamu ile İdare Arasındaki İlişkiler Kanunu'na eklenen hükümler, algoritmik bir işleme dayanarak alınan bireysel idari kararların, bu durumu açıkça belirtmesini ve ilgilinin talebi üzerine, idarenin, algoritmik işlemi tanımlayan kuralları ve başlıca özelliklerini ilgiliye bildirmesini öngörmektedir.[289] Fransız Anayasa Konseyi, 2018'de Avrupa Birliği Genel Veri Koruma Tüzüğü'nün uygulanmasına ilişkin kanunu incelerken, bu konuda önemli ilkeler ortaya koymuştur. Konsey'e göre, tamamen algoritmik bir işleme dayanan bireysel idari kararlara izin verilmesi, ancak belirli güvencelerle anayasaya uygun olabilir: Veri işleme sorumlusu, algoritmik işlemi ve onun gelişimini "hâkimiyeti altında tutmalı" ve işlemin ilgili kişi bakımından nasıl uygulandığını ona ayrıntılı ve anlaşılır bir biçimde açıklayabilmelidir. Konsey, ayrıca, kendisinin uyguladığı kuralları, sorumlunun denetimi ve onayı olmaksızın kendi başına değiştirebilecek algoritmaların, bireysel idari kararların *münhasır* dayanağı olarak kullanılamayacağına hükmetmiştir.[290] Konsey, 2020'de ise yükseköğretime giriş sürecinde üniversitelerin kullandığı yerel algoritmalara ilişkin bir kararında, prosedürün tamamlanmasından sonra, kurumların başvuruları değerlendirmede kullandıkları ölçütleri yayımlaması gerektiğine hükmetmiştir.[291]

İtalya'da, Danıştay (*Consiglio di Stato*), 2019'da verdiği bir dizi kararda, idarenin algoritma kullanımına ilişkin üç temel ilke geliştirmiştir:

[289] Code des relations entre le public et l'administration, art. L. 311-3-1.
[290] Conseil constitutionnel, Décision n° 2018-765 DC du 12 juin 2018, *Loi relative à la protection des données personnelles*, par. 71.
[291] Conseil constitutionnel, Décision n° 2020-834 QPC du 3 avril 2020, *Union nationale des étudiants de France*.

(i) *bilinebilirlik* ilkesi, yani algoritmanın, kararı tesis eden mantık ve ölçütler bakımından, ilgililer ve yargıç tarafından bilinebilir ve anlaşılabilir olması; (ii) *münhasır olmama* ilkesi, yani algoritmik kararın, onu denetleyebilecek, doğrulayabilecek veya reddedebilecek bir insan katkısıyla tamamlanması; ve (iii) *algoritmik ayrımcılık yasağı*.[292] İtalyan Danıştayı, algoritmanın, idari işlemin kendisinin bir parçası olarak, yani "dijital idari işlem" olarak kabul edilmesi ve yargısal denetime tam olarak tabi tutulması gerektiğini vurgulamıştır.

Bu karşılaştırmalı örnekler, Türk hukuku bakımından önemli bir yön göstermektedir. Danıştay, mevcut kanuni çerçevede bile, idari işlemlerin unsurlarına ilişkin yerleşik içtihadını, algoritmik idari işlemlere uygulayarak benzer ilkeler geliştirebilir. Ancak bu ilkelerin kanunla açıkça düzenlenmesi, hukuki güvenlik bakımından daha uygun olacaktır.

IV. Kendini Değiştiren Algoritmalar ve "Hâkimiyet" Şartı

Fransız Anayasa Konseyi'nin 2018 kararında vurguladığı "hâkimiyet" (*maîtrise*) şartı, bu çalışmanın konusu bakımından özel bir önem taşır. Bu şart, idarenin, kullandığı algoritmik sistemi ve onun zaman içindeki gelişimini anlaması ve kontrol etmesi gerektiğini ifade eder. Konsey'in kendini değiştiren algoritmalara ilişkin yasağı, bu şartın en açık uygulamasıdır: İdare, kendi kurallarını kendi başına değiştiren bir sistemin kararlarını, o sistemin her an hangi kuralları uyguladığını bilemeyeceği için, hâkimiyeti altında tutamaz.

Bu ilke, öğrenen yapay zekâ sistemlerinin kamusal kararlarda kullanımına önemli bir sınır getirir. Kullanım sırasında sürekli öğrenen ve davranışını değiştiren bir sistem, belirlilik ve öngörülebilirlik ilkeleri bakımından ciddi sorunlar doğurur: Aynı durumdaki iki kişi, sistemin farklı zamanlardaki "sürümleri" tarafından farklı biçimlerde değerlendirilebilir; idare, sistemin belirli bir anda hangi kuralları uyguladığını bilemeyebilir; ve yargı organları, bir işlemin tesis edildiği andaki sistem davranışını yeniden üretemeyebilir.

Bu sorunlara karşı, bu çalışma **"sürüm kilidi"** olarak adlandırılan bir güvence önermektedir. Bu güvenceye göre, kamusal kararlarda kullanılan yapay zekâ sistemleri, belirli ve belgelendirilmiş bir "sürüm" olarak kullanıma alınmalı; bu sürümün davranışını önemli ölçüde değiştiren her

[292] Consiglio di Stato, Sez. VI, sentenza 8 aprile 2019, n. 2270; Consiglio di Stato, Sez. VI, sentenza 13 dicembre 2019, n. 8472.

güncelleme, yeni bir kullanıma alma kararı olarak değerlendirilmeli ve ilk kullanıma almaya uygulanan değerlendirme ve onay süreçlerine tabi tutulmalıdır. Her algoritmik idari işlemin kaydında, işlemin tesis edilmesinde kullanılan sistem sürümü belirtilmeli ve bu sürüm, olası bir yargısal denetim için yeniden üretilebilir biçimde saklanmalıdır. Bu güvence, idari düzenleyici işlemlerin değiştirilmesinin belirli usullere tabi olmasının ve değişikliklerin yayımlanmasının algoritmik normlar bakımından karşılığıdır. Sürüm kilidi, ayrıca, İkinci Bölüm'de ele alınan "aldatıcı uyum" sorununa karşı da kısmi bir güvence sağlar: Test edilmiş ve onaylanmış bir sistem sürümünün, kullanım sırasında farklı bir sisteme dönüşmesini engeller.

§ 24. YARGISAL DENETİM VE YARGIDA YAPAY ZEKÂ

Yargı, bekçiler sorununa modern anayasacılığın verdiği en kurumsallaşmış cevaplardan biridir. Kelsen'in anayasa mahkemesi modelinden idari yargının idarenin işlemlerini denetlemesine kadar, yargısal denetim, iktidarın hukuka bağlılığının nihai güvencesi olarak tasarlanmıştır. Bu başlık altında, yargının yapay zekâ karşısındaki iki farklı rolü ele alınacaktır: *denetleyici* olarak yargı, yani yapay zekâ kullanılarak alınan kararları denetleyen yargı; ve *kullanıcı* olarak yargı, yani kendi karar süreçlerinde yapay zekâ kullanan yargı.

I. Yargısal Denetimin Kapsamı ve Teknik Bilgi Sorunu

A. Hukukilik ve Yerindelik Ayrımı

Anayasa'nın 125. maddesinin birinci fıkrası, "İdarenin her türlü eylem ve işlemlerine karşı yargı yolu açıktır" hükmünü içerir. Bu genel hüküm, algoritmik idari işlemleri de kapsar: Bir idari işlem, yapay zekâ kullanılarak alınmış olsa bile, yargısal denetime tabidir. Ancak aynı maddenin dördüncü fıkrası, yargısal denetimin sınırını da belirler: "Yargı yetkisi, idarî eylem ve işlemlerin hukuka uygunluğunun denetimi ile sınırlı olup, hiçbir surette yerindelik denetimi şeklinde kullanılamaz." Bu hüküm, İdari Yargılama Usulü Kanunu'nun 2. maddesinin ikinci fıkrasında da tekrarlanmaktadır.

Hukukilik ile yerindelik arasındaki ayrım, algoritmik idari işlemlerin yargısal denetimi bakımından önemli bir sorun doğurur. Bir yapay zekâ sisteminin, belirli bir kararda belirli bir sonuca varmasının "doğru" olup olmadığının değerlendirilmesi, yerindelik denetimi mi, yoksa hukukilik

denetimi mi sayılmalıdır? Bu çalışma, bu soruya şu cevabı önermektedir: Yapay zekâ sisteminin *içerik bakımından* en iyi kararı verip vermediğinin değerlendirilmesi, yerindelik denetimi niteliğindedir ve yargının görev alanı dışındadır. Ancak yapay zekâ sisteminin kullanımının *hukuki koşullarına* uyulup uyulmadığının değerlendirilmesi, yani sistemin kanuni dayanağa sahip olup olmadığı, olasılıksal sebep yasağına uyulup uyulmadığı, hedef fonksiyonunun kanunun amacıyla uyumlu olup olmadığı, kamu görevlisinin takdir yetkisini gerçekten kullanıp kullanmadığı, gerekçenin yeterli olup olmadığı ve sistemin ayrımcı sonuçlar üretip üretmediği gibi sorular, açıkça hukukilik denetimi kapsamındadır.

Bu ayrım, Birinci Bölüm'de geliştirilen "denetimin nesneleri" çerçevesiyle de örtüşür. Yargısal denetim, ilke olarak, *sonuç* denetimi değil, *süreç* denetimidir. Yargıç, idarenin en iyi kararı verip vermediğini değil, kararın hukuka uygun bir süreçle, hukuka uygun gerekçelere dayanılarak verilip verilmediğini denetler. Bu özellik, yargısal denetimi, bilişsel asimetri koşullarında bile işlevini koruyabilecek bir denetim biçimi kılar: Yargıç, yapay zekâ sisteminin kararının içeriğini tam olarak anlamasa bile, kararın alındığı sürecin hukuki koşullara uygun olup olmadığını değerlendirebilir.

B. Re'sen Araştırma ve Teknik Bilgi

Bununla birlikte, süreç denetimi bile, belirli bir düzeyde teknik bilgi gerektirir. Bir yapay zekâ sisteminin ayrımcı sonuçlar üretip üretmediğini, hedef fonksiyonunun ne olduğunu veya kayıtlarının gerekçeyle tutarlı olup olmadığını değerlendirmek için, yargıcın, sistemin işleyişine ilişkin bilgiye erişmesi ve bu bilgiyi değerlendirebilmesi gerekir. İdari yargılama usulünde, İdari Yargılama Usulü Kanunu'nun 20. maddesi uyarınca, mahkemeler, bakmakta oldukları davalara ait her türlü incelemeyi re'sen yapar. Bu "re'sen araştırma" ilkesi, idari yargıya, algoritmik idari işlemlerin denetiminde önemli bir araç sağlar: Mahkeme, idareden, kullandığı sistemin teknik belgelerini, kayıtlarını, test sonuçlarını ve hedef fonksiyonunu talep edebilir.

II. Bilirkişi Kurumu: Bilişsel Asimetri Altında Yargısal Denetimin Modeli

A. Bilirkişi Kurumu ve Hâkimin Değerlendirme Özgürlüğü

Yargının, kendisinin sahip olmadığı uzmanlık bilgisini gerektiren konularda nasıl karar vereceği sorunu, yapay zekâdan çok önce, bilirkişi kurumu aracılığıyla çözülmeye çalışılmıştır. Bu kurum, bilişsel asimetri koşullarında insan denetimine ilişkin, yüzyılların birikimini taşıyan değerli bir model sunmaktadır.

Türk hukukunda bilirkişilik, 6754 sayılı Bilirkişilik Kanunu ve usul kanunlarının ilgili hükümleriyle düzenlenmektedir. Hukuk Muhakemeleri Kanunu'nun 266. maddesine göre, mahkeme, çözümü özel veya teknik bilgiyi gerektiren hâllerde, bilirkişinin oy ve görüşünün alınmasına karar verir. Ancak aynı madde, son derece önemli bir sınır da getirir: "Hâkimlik mesleğinin gerektirdiği genel ve hukuki bilgi ile çözümlenmesi mümkün olan konularda bilirkişiye başvurulamaz." Hukuk Muhakemeleri Kanunu'nun 282. maddesi ise hâkimin, bilirkişinin oy ve görüşünü, diğer delillerle birlikte serbestçe değerlendireceğini öngörür. Benzer hükümler, Ceza Muhakemesi Kanunu'nda da yer almaktadır.

Bu düzenlemeler, hukuk geleneğinde "hâkim, bilirkişilerin bilirkişisidir" (*iudex peritus peritorum*) özdeyişiyle ifade edilen bir ilkeye dayanır. Bu ilke, ilk bakışta bir paradoks gibi görünür: Hâkim, bilirkişinin uzmanlık alanında bilirkişiden daha az bilgiye sahiptir; zaten bu nedenle bilirkişiye başvurmuştur. Peki nasıl olur da bilirkişinin görüşünü "değerlendirebilir"? Bu paradoksun çözümü, hâkimin bilirkişinin görüşünü *içerik bakımından yeniden üreterek* değil, *dışsal ölçütlere göre* değerlendirmesindedir. Hâkim, bilirkişi raporunun iç tutarlılığını, diğer delillerle uyumunu, raporun dayandığı verilerin güvenilirliğini, bilirkişinin tarafsızlığını ve raporun tarafların itirazlarını karşılayıp karşılamadığını değerlendirir. Gerektiğinde ek rapor alır veya başka bir bilirkişiye başvurur.

B. Bilirkişi Modelinin Yapay Zekâya Uyarlanması

Bilirkişi kurumu, Üçüncü Bölüm'de ele alınan Goldman'ın acemi-uzman sorununa hukukun yüzyıllardır verdiği pratik bir cevaptır. Bu cevabın unsurları, Goldman'ın beş kanıt kaynağıyla çarpıcı bir uyum içindedir: Hâkim, bilirkişinin argümanlarının tutarlılığını değerlendirir (argümanlar); gerektiğinde başka bilirkişilere başvurur (görüş birliği);

bilirkişilerin sicile kayıtlı ve belirli niteliklere sahip olmasını arar (üst-uzman değerlendirmesi); bilirkişinin tarafsızlığını ve reddi sebeplerini inceler (çıkar ve önyargılar); ve bilirkişinin önceki raporlarının niteliğini dikkate alabilir (geçmiş başarı kaydı).

Bu çalışma, bilirkişi kurumunun, yapay zekânın kamusal karar süreçlerinde kullanımına ilişkin bir model olarak benimsenmesini önermektedir. Bu modelin temel unsurları şunlardır:

Birincisi, hukuki sorunlar yapay zekâya bırakılamaz. Hukuk Muhakemeleri Kanunu'nun 266. maddesinin, hukuki bilgiyle çözülebilecek konularda bilirkişiye başvurulmasını yasaklaması gibi, kamusal kararların *hukuki* değerlendirme gerektiren unsurları, yani bir olgunun hukuki nitelendirilmesi, hukuk kurallarının yorumlanması ve değerlerin tartılması, yapay zekâya bırakılmamalıdır. Yapay zekâ, olgusal ve teknik sorunlarda, bilirkişi gibi, karar vericiye bilgi sağlayabilir; ama hukuki yargı, karar vericiye aittir.

İkincisi, yapay zekâ çıktısı serbestçe değerlendirilmelidir. Hâkimin bilirkişi raporuyla bağlı olmaması gibi, karar verici de yapay zekâ sisteminin çıktısıyla bağlı olmamalı ve bu çıktıyı, diğer delillerle birlikte serbestçe değerlendirmelidir. Bu değerlendirme, kararın gerekçesinde görünür olmalıdır.

Üçüncüsü, ilgililerin yapay zekâ çıktısına itiraz hakkı bulunmalıdır. Hukuk Muhakemeleri Kanunu'nun 281. maddesi, taraflara, bilirkişi raporuna karşı itiraz etme ve ek rapor alınmasını veya yeni bir bilirkişi atanmasını talep etme hakkı tanır. Benzer biçimde, bir yapay zekâ sisteminin çıktısından etkilenen kişilere, bu çıktıya itiraz etme, sistemin çıktısının dayandığı verilerin ve mantığın açıklanmasını talep etme ve gerektiğinde bağımsız bir değerlendirme yapılmasını isteme hakkı tanınmalıdır.

Dördüncüsü, yapay zekâ sistemleri, bilirkişiler gibi, belirli niteliklere sahip olmalı ve kayıt altına alınmalıdır. Bilirkişilerin belirli mesleki niteliklere sahip olması ve bilirkişilik siciline kaydedilmesi gibi, kamusal kararlarda kullanılan yapay zekâ sistemleri de belirli güvenilirlik standartlarını karşılamalı ve bir sicile kaydedilmelidir.

Bilirkişi modelinin yapay zekâya uyarlanmasının bir sınırı da vardır: Bilirkişi, sonuçta, tarafsızlığı denetlenebilen, raporundan sorumlu tutulabilen ve gerektiğinde mahkemede sorgulanabilen bir insandır. Yapay

zekâ sistemi ise bu niteliklerin bir kısmından yoksundur. Bu nedenle, bilirkişi modelinin yapay zekâya uyarlanması, sistemin kendisinin değil, sistemi geliştiren, değerlendiren ve kullanan insanların ve kurumların sorumluluğunun güçlendirilmesiyle tamamlanmalıdır. Bu konu, Altıncı Bölüm'de ele alınacaktır.

III. Yargıda Yapay Zekâ Kullanımı

A. Anayasal Çerçeve: Bağımsızlık, Kanuni Hâkim ve Vicdani Kanaat

Yapay zekânın yargının kendi karar süreçlerinde kullanılması, yargının denetleyici rolünden ayrı ve özellikle hassas sorular doğurur. Bu soruların anayasal çerçevesi, birkaç temel hükümle belirlenir.

Anayasa'nın 9. maddesine göre, "Yargı yetkisi, Türk Milleti adına bağımsız ve tarafsız mahkemelerce kullanılır." Anayasa'nın 37. maddesi, kanuni hâkim güvencesini düzenler: "Hiç kimse kanunen tabi olduğu mahkemeden başka bir merci önüne çıkarılamaz." Anayasa'nın 138. maddesinin birinci fıkrası ise şöyledir: "Hâkimler, görevlerinde bağımsızdırlar; Anayasaya, kanuna ve hukuka uygun olarak vicdani kanaatlerine göre hüküm verirler." Aynı maddenin ikinci fıkrası, "Hiçbir organ, makam, merci veya kişi, yargı yetkisinin kullanılmasında mahkemelere ve hâkimlere emir ve talimat veremez; genelge gönderemez; tavsiye ve telkinde bulunamaz" hükmünü içerir. Anayasa'nın 141. maddesinin üçüncü fıkrası ise "Bütün mahkemelerin her türlü kararları gerekçeli olarak yazılır" hükmünü içerir.

Bu hükümler, yargıda yapay zekâ kullanımına ilişkin üç önemli sonuç doğurur.

Birincisi, yargı yetkisini kullanan "mahkeme", insanlardan oluşur. Anayasa'nın 9. ve 37. maddeleri, yargı yetkisinin bağımsız ve tarafsız *mahkemelerce* kullanılmasını ve kişilerin *kanunen tabi oldukları mahkeme* önüne çıkarılmasını öngörür. Bu mahkemeler, Anayasa'nın 139 ve devamı maddelerinde güvenceleri düzenlenen hâkimlerden oluşur. Bir yapay zekâ sistemi, bu anlamda bir "mahkeme" değildir. Dolayısıyla bir uyuşmazlığın, bir yapay zekâ sistemi tarafından karara bağlanması, kanuni hâkim güvencesini ihlal eder.

İkincisi, hüküm "vicdani kanaat"e dayanmalıdır. Anayasa'nın 138. maddesinin birinci fıkrası, hâkimlerin "vicdani kanaatlerine göre" hüküm vereceğini öngörür. Bu ifade, yalnızca hâkimin dış etkilerden

bağımsızlığını değil, hükmün, hâkimin kendi değerlendirmesinin ve kişisel sorumluluğunun ürünü olmasını da ifade eder. "Vicdan", bir insanın, eylemlerinin ahlaki niteliği üzerine düşünme ve bunlardan kendisini sorumlu tutma kapasitesidir. Üçüncü Bölüm'de ele alınan Darwall'cı argüman, bu kapasitenin, karşılıklı hesap verebilirlik ilişkisinin bir unsuru olduğunu göstermişti. Bir yapay zekâ sisteminin, bu anlamda bir "vicdana" sahip olduğunu söylemek mümkün değildir. Bu nedenle, Anayasa'nın 138. maddesi, hükmün, nihai olarak bir insanın vicdani kanaatine dayanmasını gerektirir. Hâkim, yapay zekâ araçlarından yararlanabilir; ama hükmü, kendi vicdani kanaatine göre vermelidir.

Üçüncüsü, yapay zekâ araçları, bir "tavsiye ve telkin" aracına dönüşmemelidir. Anayasa'nın 138. maddesinin ikinci fıkrası, hiçbir organın, makamın veya kişinin, yargı yetkisinin kullanılmasında mahkemelere ve hâkimlere tavsiye ve telkinde bulunamayacağını öngörür. Bu hüküm, yargıda kullanılan yapay zekâ araçları bakımından ince ama önemli bir soruyu gündeme getirir. Yargıda kullanılan yapay zekâ araçları, genellikle yürütme organı veya ona bağlı kurumlar tarafından geliştirilir, temin edilir ve işletilir. Bu araçlar, hâkimlere belirli davaların nasıl sonuçlandırılması gerektiğine ilişkin öneriler sunuyorsa, bu öneriler, fiilen, yürütme organının yargıya yönelik bir "tavsiye ve telkini" niteliği kazanabilir mi? Bu çalışma, yargıda kullanılan yapay zekâ araçlarının, hâkimin bağımsız değerlendirmesini destekleyen bilgi ve analiz araçları olarak tasarlanması gerektiğini; davanın *sonucuna* ilişkin doğrudan öneriler sunan araçların ise, özellikle yürütme organının kontrolünde olduklarında, Anayasa'nın 138. maddesinin ikinci fıkrasının ruhuyla çatışma riski taşıdığını savunmaktadır. Bu nedenle, yargıda kullanılan yapay zekâ araçlarının geliştirilmesi, değerlendirilmesi ve denetlenmesinin, yürütmeden bağımsız ve yargının kendi kurumsal yapısı içinde, şeffaf bir biçimde gerçekleştirilmesi gerekir.

B. Avrupa Standartları

Avrupa düzeyinde, yargıda yapay zekâ kullanımına ilişkin en önemli belge, Avrupa Konseyi Adaletin Etkinliği Avrupa Komisyonu (CEPEJ) tarafından 2018'de kabul edilen "Yargı Sistemlerinde ve Ortamlarında Yapay Zekâ Kullanımına İlişkin Avrupa Etik Şartı"dır.[293] Şart, beş ilke

[293] European Commission for the Efficiency of Justice (CEPEJ), *European Ethical Charter on the Use of Artificial Intelligence in Judicial Systems and Their Environment*, Strasbourg, 3-4 Aralık 2018.

öngörmektedir: (i) temel haklara saygı ilkesi; (ii) ayrımcılık yasağı ilkesi; (iii) kalite ve güvenlik ilkesi; (iv) şeffaflık, tarafsızlık ve hakkaniyet ilkesi; ve (v) "kullanıcının kontrolü altında" olma ilkesi. Son ilke, bu çalışma bakımından özellikle önemlidir: Şart'a göre, yapay zekâ araçları, kullanıcıları (hâkimleri ve yargı mensuplarını) bilgilendirilmiş aktörler olarak güçlendirmeli ve onların kendi seçimlerinin kontrolünü elinde tutmalarını sağlamalıdır; kullanıcıları, araçların önerilerine bağımlı hâle getiren bir "kuralcı" yaklaşımdan kaçınılmalıdır.

Avrupa Birliği Yapay Zekâ Tüzüğü de, yargı makamları tarafından olguların ve hukukun araştırılmasında ve yorumlanmasında ve hukukun somut olaylara uygulanmasında kullanılması amaçlanan yapay zekâ sistemlerini "yüksek riskli" sistemler arasında saymaktadır.[294] Tüzük'ün gerekçesinde, yapay zekâ araçlarının hâkimlerin karar verme gücünü veya yargı bağımsızlığını destekleyebileceği, ancak onların yerini almaması gerektiği ve nihai karar vermenin insan tarafından yürütülen bir faaliyet olarak kalması gerektiği açıkça vurgulanmaktadır.[295]

C. Hâkim Analitiği Sorunu

Yargıda yapay zekâ kullanımının özel bir boyutu, "hâkim analitiği" olarak adlandırılan uygulamalardır. Bu uygulamalar, belirli hâkimlerin geçmiş kararlarını analiz ederek, onların gelecekteki kararlarını tahmin etmeyi amaçlar. Bu tür analizler, avukatlar ve taraflar için stratejik bir değere sahip olabilir; ancak aynı zamanda, hâkimler üzerinde dolaylı bir baskı aracına dönüşebilir ve "hâkim seçme" (*forum shopping*) uygulamalarını teşvik edebilir. Fransa, bu tehlikeye karşı, 2019'da çıkardığı bir kanunla, hâkimlerin kimlik bilgilerinin, onların mesleki uygulamalarını değerlendirmek, analiz etmek, karşılaştırmak veya tahmin etmek amacıyla yeniden kullanılmasını yasaklamış ve bu yasağın ihlalini cezai yaptırıma bağlamıştır.[296] Bu düzenleme, yargı bağımsızlığının, yalnızca dış müdahalelere karşı değil, yapay zekânın mümkün kıldığı yeni gözetim ve baskı biçimlerine karşı da korunması gerektiğini göstermektedir.

[294] YZT, Ek III, 8(a).
[295] YZT, Gerekçe 61.
[296] Loi n° 2019-222 du 23 mars 2019 de programmation 2018-2022 et de réforme pour la justice, art. 33.

IV. Etkili Başvuru Hakkı ve Silahların Eşitliği

Anayasa'nın 40. maddesi, "Anayasa ile tanınmış hak ve hürriyetleri ihlal edilen herkes, yetkili makama geciktirilmeden başvurma imkânının sağlanmasını isteme hakkına sahiptir" hükmünü içerir. Aynı maddenin ikinci fıkrası, "Devlet, işlemlerinde, ilgili kişilerin hangi kanun yolları ve mercilere başvuracağını ve sürelerini belirtmek zorundadır" hükmünü öngörür. Avrupa İnsan Hakları Sözleşmesi'nin 13. maddesi de etkili başvuru hakkını güvence altına alır.

Etkili başvuru hakkı, algoritmik kararlar bakımından özel bir anlam kazanır. Bir kişinin, kendisi hakkında verilen bir karara etkili bir biçimde itiraz edebilmesi için, kararın neye dayandığını bilmesi gerekir. Kararın bir yapay zekâ sistemine dayandığını bilmeyen veya sistemin hangi verileri ve hangi mantığı kullandığına erişemeyen bir kişi, karara etkili bir biçimde itiraz edemez. Bu durum, Avrupa İnsan Hakları Mahkemesi içtihadında adil yargılanma hakkının bir unsuru olarak kabul edilen "silahların eşitliği" ilkesini de ihlal edebilir. Silahların eşitliği ilkesi, yargılamanın taraflarına, davalarını, karşı taraf karşısında kendilerini önemli bir dezavantaja sokmayacak koşullar altında sunabilmeleri için makul bir imkân tanınmasını gerektirir. İdarenin, kendi kullandığı yapay zekâ sisteminin işleyişine ilişkin tüm bilgiye sahip olması, kişinin ise bu bilgiden tamamen yoksun olması, bu ilke bakımından ciddi bir dengesizlik yaratır.

İkinci Bölüm'de ele alınan *Loomis* kararı, bu sorunun karşılaştırmalı hukuktaki bir örneğidir. Wisconsin Yüksek Mahkemesi, sanığın algoritmanın iç işleyişine erişememesine rağmen adil yargılanma hakkının ihlal edilmediğine karar vermiş; ancak bu karar, akademik literatürde yoğun eleştirilere konu olmuştur. Bu çalışma, *Loomis* kararındaki yaklaşımın, Türk anayasa hukuku ve Avrupa İnsan Hakları Sözleşmesi standartları bakımından yetersiz olduğunu savunmaktadır. Bir kişinin özgürlüğünü veya temel haklarını doğrudan etkileyen kararlarda kullanılan yapay zekâ sistemlerinin işleyişine ilişkin bilgi, ticari sır gerekçesiyle kişiden tamamen esirgenmemelidir. Ticari sırların korunması ile etkili başvuru hakkı arasındaki denge, örneğin bilginin yalnızca mahkemeye ve tarafların avukatlarına gizlilik yükümlülüğü altında açıklanması veya bağımsız bir uzmanın sistemi inceleyip mahkemeye rapor sunması gibi usul araçlarıyla kurulabilir. Avrupa Birliği Adalet Divanı'nın 2025 tarihli bir kararı da benzer bir dengeleme yaklaşımını benimseyerek, ticari sır iddiası bulunan durumlarda, açıklanması istenen bilginin yetkili denetim

makamına veya mahkemeye sunulması ve bu makamın, ilgili hak ve çıkarları tartarak kişinin erişim hakkının kapsamını belirlemesi gerektiğine hükmetmiştir.[297]

§ 25. YASAMA DENETİMİ

I. Türkiye Büyük Millet Meclisi'nin Denetim Araçları

Yasama organı, demokratik bir düzende yürütme ve idare üzerindeki siyasi denetimin temel aktörüdür. 2017 Anayasa değişikliğinden sonra, Anayasa'nın 98. maddesine göre, Türkiye Büyük Millet Meclisi; Meclis araştırması, genel görüşme, Meclis soruşturması ve yazılı soru yollarıyla bilgi edinme ve denetim yetkisini kullanır. Meclis araştırması, belli bir konuda bilgi edinilmek için yapılan incelemedir; genel görüşme, toplumu ve devlet faaliyetlerini ilgilendiren belli bir konunun Genel Kurul'da görüşülmesidir; Meclis soruşturması ise Cumhurbaşkanı yardımcıları ve bakanlar hakkında, görevleriyle ilgili suç iddialarına ilişkin olarak Anayasa'nın 106. maddesine göre yapılan soruşturmadır.

Bu araçlar, yapay zekânın kamusal kullanımının yasama denetimi bakımından önemli imkânlar sunar. Meclis araştırması, özellikle, belirli bir kamu kurumunun yapay zekâ kullanımının veya genel olarak yapay zekânın toplumsal etkilerinin ayrıntılı olarak incelenmesi için uygun bir araçtır. Nitekim Türkiye Büyük Millet Meclisi, yapay zekânın kazanımlarına yönelik atılacak adımların belirlenmesi, bu alanda hukuki altyapının oluşturulması ve yapay zekâ kullanımının barındırdığı risklerin önlenmesine ilişkin tedbirlerin belirlenmesi amacıyla, tüm siyasi partilerin desteğiyle bir Meclis araştırması komisyonu kurmuş; komisyon, 2025 yılı içinde çalışmalarını yürüterek kamu kurumlarından, akademisyenlerden ve sektör temsilcilerinden bilgi almıştır.[298] Bu girişim, yasama organının konuya ilgisini göstermesi bakımından önemlidir. Ancak Meclis araştırması komisyonlarının, geçici nitelikte olmaları, belirli bir süreyle sınırlı çalışmaları ve özel kişilerden bilgi ve belge talep etme yetkilerinin sınırlı

[297] ABAD, C-203/22, *Dun & Bradstreet Austria*, 27 Şubat 2025.

[298] Türkiye Büyük Millet Meclisi, Yapay Zekânın Kazanımlarına Yönelik Atılacak Adımların Belirlenmesi, Bu Alanda Hukuki Altyapının Oluşturulması ve Yapay Zekâ Kullanımının Barındırdığı Risklerin Önlenmesine İlişkin Tedbirlerin Belirlenmesi Amacıyla Kurulan Meclis Araştırması Komisyonu tutanakları. Komisyonun nihai raporunun içeriği ve yasama faaliyetine yansımaları, yayına hazırlık aşamasında birincil kaynaklardan güncellenmelidir.

olması, bu aracın, sürekli ve derinlemesine bir denetim için yeterli olmadığını göstermektedir.

II. Weber'in Soruşturma Hakkı Argümanı ve Yapay Zekâ

Birinci Bölüm'de, Max Weber'in, bürokrasinin bilgi üstünlüğü karşısında parlamentonun etkin bir denetim yapabilmesi için güçlü bir "soruşturma hakkı"na sahip olması gerektiğini savunduğu belirtilmişti. Weber'in argümanı, yapay zekâ çağında yeniden önem kazanmaktadır. Yapay zekâ sistemlerine ilişkin kritik bilgi, yalnızca kamu kurumlarının değil, büyük ölçüde bu sistemleri geliştiren ve kamu kurumlarına sağlayan özel şirketlerin elindedir. Parlamentonun yapay zekânın kamusal kullanımını etkin biçimde denetleyebilmesi için, yalnızca kamu kurumlarından değil, belirli koşullar altında bu sistemleri sağlayan şirketlerden de bilgi ve belge talep edebilmesi, şirket temsilcilerini dinleyebilmesi ve gerektiğinde gizli nitelikteki teknik değerlendirmelere, uygun gizlilik güvenceleri altında erişebilmesi gerekir.

Weber'in argümanının ikinci boyutu, parlamentonun kendi uzmanlık kapasitesine ilişkindir. Weber, parlamentonun bürokrasiyi ancak, bürokrasiyi tanıyan ve onunla mücadele etmeyi öğrenmiş üyelerden oluşan komisyonlar aracılığıyla denetleyebileceğini savunuyordu. Yapay zekâ bağlamında bu, parlamentonun, yapay zekâ konusunda sürekli bilgi biriktiren ve uzmanlaşan daimi bir komisyona ve bu komisyonu destekleyen bağımsız bir teknik personele ihtiyaç duyduğu anlamına gelir.

III. Teknoloji Değerlendirme Ofisleri

Parlamentoların teknik konulardaki bilgi asimetrisini azaltmak için başvurduğu en önemli kurumsal araç, "parlamenter teknoloji değerlendirme" ofisleridir. Bu kurumların ilk örneği, Amerika Birleşik Devletleri Kongresi'nin 1972'de kurduğu Teknoloji Değerlendirme Ofisi'dir (*Office of Technology Assessment*, OTA). OTA, Kongre üyelerine, bilim ve teknolojiye ilişkin karmaşık konularda, tarafsız ve derinlemesine analizler sunmak amacıyla kurulmuş ve yirmi yılı aşkın bir süre boyunca yüzlerce rapor hazırlamıştır. OTA, 1995'te, bütçe kesintileri gerekçesiyle Kongre tarafından kapatılmıştır. Ofisin kapatılması, sonraki yıllarda, Kongre'nin teknoloji politikası konusundaki kapasitesini önemli ölçüde zayıflattığı gerekçesiyle sıkça eleştirilmiştir. Kongre'nin denetim organı olan Hükümet Hesap Verebilirlik Ofisi (*Government Accountability Office*)

bünyesinde 2019'da bilim ve teknoloji değerlendirmesi alanında uzmanlaşmış bir birim kurulması, bu boşluğu kısmen doldurmaya yönelik bir adım olmuştur.

Avrupa'da ise parlamenter teknoloji değerlendirme kurumları daha istikrarlı bir gelişim göstermiştir. Almanya'da Federal Meclis'e bağlı olarak çalışan Teknoloji Etki Değerlendirme Ofisi (*Büro für Technikfolgen-Abschätzung beim Deutschen Bundestag*, TAB), Birleşik Krallık'ta Parlamento Bilim ve Teknoloji Ofisi (*Parliamentary Office of Science and Technology*, POST), Fransa'da Bilimsel ve Teknolojik Seçenekleri Değerlendirme Parlamento Ofisi (*Office parlementaire d'évaluation des choix scientifiques et technologiques*, OPECST) ve Avrupa Parlamentosu'nda Bilim ve Teknolojinin Geleceği Paneli (*Panel for the Future of Science and Technology*, STOA), bu kurumların başlıca örnekleridir. Bu kurumlar, Avrupa Parlamenter Teknoloji Değerlendirme Ağı (EPTA) çatısı altında işbirliği yapmaktadır.

Bu kurumların ortak özellikleri, parlamentoya bağlı olmaları, yürütmeden ve özel çıkarlardan bağımsız olmaları, disiplinlerarası uzman kadrolara sahip olmaları ve analizlerini parlamento üyelerinin anlayabileceği bir dille sunmalarıdır. Bu özellikler, onları, Birinci Bölüm'de ele alınan Weber'ci soruşturma hakkının ve Jasanoff'un "beşinci kuvvet" kavramının kurumsal bir sentezi hâline getirir: Bunlar, parlamentonun, yürütmenin ve özel sektörün bilgi tekelini kırmasını sağlayan, ama parlamentonun karar yetkisini ele geçirmeyen, danışmanlık yapan uzmanlık kurumlarıdır.

IV. Öneri: Türkiye Büyük Millet Meclisi Bilim ve Teknoloji Değerlendirme Birimi

Bu çalışma, Türkiye Büyük Millet Meclisi bünyesinde, yapay zekâ başta olmak üzere bilim ve teknolojiye ilişkin konularda parlamentoya bağımsız analiz ve danışmanlık hizmeti sunacak daimi bir **Bilim ve Teknoloji Değerlendirme Birimi** kurulmasını önermektedir. Bu birimin temel özellikleri şunlar olmalıdır:

Kurumsal bağımsızlık: Birim, Meclis Başkanlığı'na bağlı olarak, ancak siyasi partilerden ve yürütmeden bağımsız bir statüde çalışmalı; yöneticileri, Meclis'teki tüm siyasi grupların katılımıyla belirlenmeli; bütçesi, Meclis bütçesi içinde güvence altına alınmalıdır.

Disiplinlerarası uzmanlık: Birim, bilgisayar bilimi, hukuk, iktisat, sosyoloji ve etik gibi farklı disiplinlerden uzmanlardan oluşmalı ve gerektiğinde dış uzmanlardan ve akademik kurumlardan destek alabilmelidir.

Bilgi erişimi: Birim, kamu kurumlarının yapay zekâ kullanımına ilişkin bilgi ve belgelere, uygun gizlilik güvenceleri altında erişebilmelidir.

Yapay zekâ etki raporları: Birim, kamu kurumlarında yapay zekâ kullanımını öngören veya yapay zekânın toplumsal etkileri bakımından önem taşıyan kanun teklifleri hakkında, teklifin komisyon görüşmeleri sırasında "yapay zekâ etki raporu" hazırlayabilmelidir.

Kamuya açıklık: Birimin raporları, gizlilik gerektiren kısımlar dışında, kamuya açık olmalıdır. Bu açıklık, birimin kendisinin de kamuoyunun denetimine tabi olmasını sağlar ve böylece "denetçiyi kim denetleyecek?" sorusuna, Bentham'ın Panoptikon'u için önerdiği cevaba benzer bir cevap verir: Denetçinin kendisi de kamuya açık olmalıdır.

Bu birime ek olarak, Türkiye Büyük Millet Meclisi'nde, yapay zekâ ve dijital teknolojiler alanında *daimi* bir ihtisas komisyonu kurulması da önerilmektedir. Bu komisyon, geçici Meclis araştırması komisyonlarından farklı olarak, sürekli bir denetim ve bilgi birikimi işlevi görmelidir.

§ 26. BAĞIMSIZ İDARİ OTORİTELER VE UZMAN DENETİM KURUMLARI

I. Bağımsız İdari Otoritelerin Meşruiyet Sorunu

Modern devletlerde, teknik uzmanlık gerektiren ve siyasi etkilerden korunması gereken alanların düzenlenmesi ve denetlenmesi, giderek artan ölçüde "bağımsız idari otoriteler" veya "düzenleyici kurumlar" olarak adlandırılan kurumlara bırakılmaktadır. Bu kurumlar, merkezî idarenin hiyerarşik yapısı dışında, belirli bir özerklikle çalışan, kendi alanlarında düzenleme, denetim ve yaptırım yetkilerine sahip kurumlardır. Türk hukukunda da 1990'lı yıllardan itibaren, Rekabet Kurumu, Bankacılık Düzenleme ve Denetleme Kurumu, Sermaye Piyasası Kurulu, Enerji Piyasası Düzenleme Kurumu, Bilgi Teknolojileri ve İletişim Kurumu ve

Kişisel Verileri Koruma Kurumu gibi çok sayıda bağımsız idari otorite kurulmuştur.[299]

Bağımsız idari otoriteler, bekçiler sorunu bakımından ilginç bir konumdadır. Bir yandan, bu kurumlar, siyasi iktidarın kısa vadeli çıkarlarından ve özel sektörün baskısından bağımsız bir denetim sağlamak amacıyla kurulmuştur; bu bakımdan, Kelsen'in "kimse kendi davasında yargıç olamaz" ilkesinin bir uygulamasıdır. Öte yandan, bu kurumların bağımsızlığı, onların demokratik meşruiyeti bakımından ciddi sorular doğurur. Halk tarafından seçilmemiş ve doğrudan seçilmiş organlara hesap vermeyen bu kurumlar, önemli kamusal kararlar alır. Bu durum, literatürde "demokratik meşruiyet açığı" olarak adlandırılır. Bağımsız idari otoritelerin meşruiyeti, genellikle, uzmanlıklarına, kararlarını şeffaf usullerle almalarına, yargısal denetime tabi olmalarına ve kanunla belirlenmiş sınırlar içinde hareket etmelerine dayandırılır.

Yapay zekânın denetimi bakımından bağımsız idari otoritelerin rolü, iki ayrı düzlemde değerlendirilmelidir. *Birinci düzlemde*, mevcut bağımsız idari otoriteler, kendi alanlarında yapay zekâ kullanımını denetleme görevini üstlenebilir: Bankacılık düzenleyicisi bankaların kredi değerlendirme algoritmalarını, rekabet otoritesi algoritmik fiyatlamayı ve platformların pazar gücünü, kişisel verileri koruma otoritesi yapay zekâ sistemlerinin kişisel veri işlemesini denetleyebilir. *İkinci düzlemde* ise, yapay zekâya özgü yeni bir bağımsız denetim otoritesinin kurulması gerekip gerekmediği sorusu ortaya çıkar. Bu soru, Sekizinci Bölüm'de, bu çalışmanın önerdiği kurumsal model bağlamında ayrıntılı olarak ele alınacaktır.

II. Türk Hukukunda Mevcut Kurumlar

Türk hukukunda, yapay zekânın denetiminde rol oynayabilecek birkaç mevcut kurum bulunmaktadır.

Kişisel Verileri Koruma Kurumu, 6698 sayılı Kişisel Verilerin Korunması Kanunu ile kurulmuş olup, kişisel verilerin işlenmesine ilişkin kuralların uygulanmasını denetlemekle görevlidir. Yapay zekâ sistemlerinin büyük çoğunluğu kişisel veri işlediğinden, bu kurum, yapay zekânın denetiminde önemli bir rol oynamaktadır. Kurum, 2021 yılında yapay zekâ alanında kişisel verilerin korunmasına ilişkin bir tavsiye belgesi

[299] Türk hukukunda bağımsız idari otoriteler için bkz. Ali Ulusoy, *Bağımsız İdari Otoriteler*, Ankara, Turhan, 2003.

yayımlamış ve bu belgede, yapay zekâ sistemlerinin geliştirilmesi ve kullanılmasında hukuka uygunluk, şeffaflık, hesap verebilirlik ve insan müdahalesine ilişkin ilkeleri vurgulamıştır.[300] Ancak Kurum'un yetkisi, kişisel verilerin korunmasıyla sınırlıdır ve yapay zekânın kişisel veri işlemeyen veya kişisel veri korumasının ötesine geçen risklerini kapsamaz.

Türkiye İnsan Hakları ve Eşitlik Kurumu, 6701 sayılı Kanun ile kurulmuş olup, ayrımcılık yasağının uygulanmasını denetlemekle görevlidir. Algoritmik ayrımcılık, yapay zekânın en çok belgelenmiş zararlarından biri olduğundan, bu kurum da yapay zekânın denetiminde önemli bir potansiyele sahiptir.

Kamu Denetçiliği Kurumu, 6328 sayılı Kanun ile kurulmuş olup, idarenin işleyişiyle ilgili şikâyetleri, insan haklarına dayalı adalet anlayışı içinde, hukuka uygunluk ve hakkaniyete uygunluk yönlerinden incelemekle görevlidir. Bu kurum, algoritmik idari işlemlerden etkilenen yurttaşların şikâyetlerini incelemek için uygun bir mecra olabilir. Ombudsmanlık kurumunun, hukukilik denetiminin yanında "hakkaniyete uygunluk" denetimi de yapabilmesi, yargısal denetimin yerindelik yasağıyla sınırlı olduğu alanlarda tamamlayıcı bir işlev görmesini mümkün kılar. Bu kurum, McCubbins ve Schwartz'ın "yangın alarmı" modelinin kurumsal bir aracı olarak da işlev görebilir.

Sayıştay, Anayasa'nın 160. maddesi ve 6085 sayılı Sayıştay Kanunu uyarınca, kamu kaynaklarının kullanımını denetler. Kamu kurumlarının yapay zekâ sistemlerinin temini ve işletilmesi için yaptığı harcamalar, bu denetimin kapsamındadır. Sayıştay denetiminin, yalnızca harcamaların mevzuata uygunluğunu değil, yapay zekâ sistemlerinin etkinliğini, verimliliğini ve hedeflenen sonuçları gerçekten üretip üretmediğini de kapsayan performans denetimini içermesi, bu kurumun yapay zekâ denetimindeki rolünü güçlendirecektir.

Bilgi Teknolojileri ve İletişim Kurumu ve *Rekabet Kurumu* gibi diğer düzenleyici kurumlar da kendi alanlarında yapay zekânın belirli boyutlarının denetiminde rol oynayabilir.

Bu kurumların varlığı, Türk hukukunda yapay zekâ denetimi için önemli bir kurumsal altyapının bulunduğunu göstermektedir. Ancak bu altyapının temel zaafı, *dağınıklığıdır*: Her kurum, yapay zekânın yalnızca belirli bir boyutunu kendi yetki alanı çerçevesinde denetleyebilmekte;

[300] Kişisel Verileri Koruma Kurumu, *Yapay Zekâ Alanında Kişisel Verilerin Korunmasına Dair Tavsiyeler*, Ankara, 15 Eylül 2021.

yapay zekâ sistemlerinin bütünlüklü bir değerlendirmesini yapacak, kurumlar arasında koordinasyonu sağlayacak ve yapay zekâya özgü teknik uzmanlığı biriktirecek bir merkez bulunmamaktadır. Bu dağınıklık, Ostrom'un çok merkezli yönetişim modelinin olumlu yönlerini taşımakla birlikte, koordinasyon eksikliği ve uzmanlık açığı nedeniyle, denetimde boşluklara yol açabilir.

III. Denetçileri Kim Denetler?

A. Algoritmik Denetim Sektörü

Yapay zekâ sistemlerinin denetimine ilişkin tartışmalarda, giderek artan ölçüde, bağımsız "algoritmik denetim" (*algorithmic audit*) kuruluşlarının rolü vurgulanmaktadır. Bu kuruluşlar, yapay zekâ sistemlerini, belirli standartlara (doğruluk, adalet, güvenlik, şeffaflık gibi) uygunluk bakımından değerlendiren özel veya kamusal kuruluşlardır. Avrupa Birliği Yapay Zekâ Tüzüğü de, belirli yüksek riskli sistemler için, "onaylanmış kuruluşlar" (*notified bodies*) tarafından yapılan uygunluk değerlendirmeleri öngörmektedir.

Ancak algoritmik denetim sektörü, kendine özgü bir bekçiler sorunu doğurur. Bir grup araştırmacı, algoritmik denetim ekosistemini inceleyen bir çalışmada, bu sorunu, çalışmalarının başlığında doğrudan Juvenalis'in sorusuna gönderme yaparak formüle etmiştir: "Denetçileri kim denetler?"[301] Araştırmacılar, algoritmik denetçilerin, çoğu zaman denetledikleri şirketler tarafından seçildiğini ve ücretlendirildiğini, denetim standartlarının ve yöntemlerinin henüz yerleşmediğini, denetim sonuçlarının çoğu zaman kamuya açıklanmadığını ve denetçilerin bağımsızlığını güvence altına alan mekanizmaların yetersiz olduğunu tespit etmişlerdir. Başka araştırmacılar da, mevcut algoritmik denetim uygulamalarının, hesap verebilirlik sağlamaktan çok, şirketlere bir "uygunluk belgesi" sunan bir meşrulaştırma aracına dönüşme riski taşıdığını vurgulamıştır.[302]

[301] Sasha Costanza-Chock / Inioluwa Deborah Raji / Joy Buolamwini, "Who Audits the Auditors? Recommendations from a Field Scan of the Algorithmic Auditing Ecosystem", *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency (FAccT)*, 2022.

[302] Abeba Birhane vd., "AI Auditing: The Broken Bus on the Road to AI Accountability", *Proceedings of the 2024 IEEE Conference on Secure and Trustworthy Machine Learning (SaTML)*, 2024.

B. Finansal Denetimden Dersler

Bu sorun, finansal denetim alanında yaşanan deneyimle karşılaştırıldığında daha iyi anlaşılabilir. Bağımsız denetim şirketlerinin, denetledikleri şirketler tarafından seçilip ücretlendirilmesi, finansal denetimde de uzun süre çıkar çatışmalarına yol açmıştır. 2001-2002 yıllarında Amerika Birleşik Devletleri'nde ortaya çıkan büyük muhasebe skandalları, dünyanın en büyük denetim şirketlerinden birinin, denetlediği şirketin muhasebe hilelerine göz yummasının ardından çökmesiyle sonuçlanmıştır. Bu skandallara tepki olarak, Amerika'da 2002'de çıkarılan Sarbanes-Oxley Kanunu, bağımsız denetçileri denetlemek üzere, Halka Açık Şirketler Muhasebe Gözetim Kurulu'nu (*Public Company Accounting Oversight Board*, PCAOB) kurmuştur. Bu kurul, tam anlamıyla bir "denetçilerin denetçisi"dir: Denetim şirketlerini kayıt altına alır, denetim standartlarını belirler, denetim şirketlerinin çalışmalarını inceler ve gerektiğinde yaptırım uygular.

Türk hukukunda da benzer bir yapı mevcuttur. 2011 yılında kurulan Kamu Gözetimi, Muhasebe ve Denetim Standartları Kurumu, bağımsız denetçileri ve bağımsız denetim kuruluşlarını yetkilendirmek, denetim standartlarını belirlemek ve bağımsız denetim faaliyetlerini gözetim altında tutmakla görevlidir. Bu kurum, Türk hukukunda "denetçilerin denetçisi" işlevi gören bir kurumun mevcut olduğunu göstermektedir.

Finansal denetimden çıkarılabilecek ders açıktır: Algoritmik denetim sektörünün güvenilirliği, ancak denetçilerin kendisinin bağımsız bir kamusal gözetime tabi tutulmasıyla sağlanabilir. Bu çalışma, Sekizinci Bölüm'de, yapay zekâ denetçilerinin, Kamu Gözetimi Kurumu'nun bağımsız denetçileri gözetim altında tutmasına benzer biçimde, yetkilendirilmesini, denetim standartlarının kamusal olarak belirlenmesini ve denetçilerin çalışmalarının düzenli olarak incelenmesini önerecektir. Bu yapı, Juvenalis'in sonsuz geriye gidişini tamamen ortadan kaldırmaz; ancak onu, kamusal, şeffaf ve yargısal denetime tabi bir kurumda sonlandırarak, makul bir noktada keser.

§ 27. TEMEL HAKLAR BOYUTU

I. Kişisel Verilerin Korunması ve Otomatik Karar Verme

A. Anayasal ve Yasal Çerçeve

Anayasa'nın 20. maddesinin üçüncü fıkrası, 2010 Anayasa değişikliğiyle eklenmiş olup, şu hükmü içerir: "Herkes, kendisiyle ilgili kişisel verilerin korunmasını isteme hakkına sahiptir. Bu hak; kişinin kendisiyle ilgili kişisel veriler hakkında bilgilendirilme, bu verilere erişme, bunların düzeltilmesini veya silinmesini talep etme ve amaçları çerçevesinde kullanılıp kullanılmadığını öğrenmeyi de kapsar. Kişisel veriler, ancak kanunda öngörülen hâllerde veya kişinin açık rızasıyla işlenebilir."

Bu anayasal hak, 6698 sayılı Kişisel Verilerin Korunması Kanunu ile ayrıntılı olarak düzenlenmiştir. Kanun'un 11. maddesi, ilgili kişinin haklarını sayar. Bu haklardan biri, yapay zekâ bakımından doğrudan önem taşır: İlgili kişi, "işlenen verilerin münhasıran otomatik sistemler vasıtasıyla analiz edilmesi suretiyle kişinin kendisi aleyhine bir sonucun ortaya çıkmasına itiraz etme" hakkına sahiptir.[303]

B. Avrupa Birliği Genel Veri Koruma Tüzüğü ile Karşılaştırma

6698 sayılı Kanun'un bu hükmü, Avrupa Birliği Genel Veri Koruma Tüzüğü'nün 22. maddesiyle karşılaştırıldığında, önemli bir farklılık göstermektedir. Tüzük'ün 22. maddesine göre, ilgili kişi, kendisi hakkında hukuki sonuç doğuran veya onu benzer biçimde önemli ölçüde etkileyen, profilleme dâhil, *yalnızca otomatik işlemeye dayanan bir karara tabi olmama* hakkına sahiptir. Bu hakkın istisnaları (sözleşmenin ifası için gereklilik, hukuki izin, açık rıza) dar biçimde düzenlenmiştir ve istisnai durumlarda bile veri sorumlusu, ilgili kişinin hak ve özgürlüklerini korumak için uygun önlemleri, en azından insan müdahalesi talep etme, kendi görüşünü ifade etme ve karara itiraz etme haklarını güvence altına almalıdır. Tüzük'ün 15. maddesi ise ilgili kişiye, otomatik karar verme durumunda, "ilgili mantık hakkında anlamlı bilgi" ile bu işlemenin ilgili kişi için önemi ve öngörülen sonuçları hakkında bilgi alma hakkı tanır.

Bu karşılaştırma, Türk hukukunun bu alandaki korumasının, Avrupa standardının gerisinde kaldığını göstermektedir. 6698 sayılı Kanun,

[303] 6698 sayılı Kişisel Verilerin Korunması Kanunu, md. 11/1-(g).

yalnızca otomatik kararlara karşı *genel bir yasak* değil, yalnızca bu kararların sonucuna *itiraz etme hakkı* tanımaktadır. Bu itiraz hakkı, kararın verilmesinden *sonra* işleyen bir haktır; kararın yalnızca otomatik olarak verilmesini *önlemez*. Ayrıca, Kanun, otomatik karar verme durumunda ilgili kişiye, kararın dayandığı mantık hakkında bilgi alma hakkı tanıyan açık bir hüküm içermemektedir. 2024 yılında 7499 sayılı Kanun ile 6698 sayılı Kanun'da özel nitelikli kişisel verilerin işlenmesi ve kişisel verilerin yurt dışına aktarılmasına ilişkin önemli değişiklikler yapılmış; ancak otomatik karar vermeye ilişkin 11. madde hükmü değiştirilmemiştir.

C. Avrupa Birliği Adalet Divanı İçtihadı

Avrupa Birliği Adalet Divanı, Genel Veri Koruma Tüzüğü'nün 22. maddesinin kapsamını, son yıllarda verdiği önemli kararlarla genişletmiştir. 2023 tarihli *SCHUFA* kararında Divan, bir kredi bürosunun bir kişinin kredi değerliliğine ilişkin ürettiği olasılıksal puanın, bir bankanın o kişiyle kredi sözleşmesi yapıp yapmama kararında *belirleyici bir rol* oynadığı durumlarda, puanın kendisinin, 22. madde anlamında "yalnızca otomatik işlemeye dayanan bir karar" sayılacağına hükmetmiştir.[304] Bu karar, otomatik karar verme yasağının, biçimsel olarak bir insanın son kararı verdiği, ama fiilen otomatik bir sistemin belirleyici olduğu durumlara da uygulanabileceğini kabul etmesi bakımından son derece önemlidir. Karar, İkinci Bölüm'de ele alınan otomasyon yanlılığı ve "meşruiyet tiyatrosu" sorunlarına, hukuki bir cevap niteliği taşımaktadır: Bir insanın sistemin önerisini mekanik olarak onaylaması, kararı "yalnızca otomatik" olmaktan çıkarmaz.

Divan, daha önce, 2022 tarihli *Ligue des droits humains* kararında, havayolu yolcu bilgilerinin terörle mücadele amacıyla işlenmesine ilişkin Avrupa Birliği direktifini yorumlarken, risk değerlendirmesinde kendi kendine öğrenen makine öğrenmesi sistemlerinin kullanılmasının, bu sistemlerin opaklığı nedeniyle, bir kişinin neden işaretlendiğinin anlaşılmasını ve dolayısıyla etkili bir başvuru yoluna erişimi engelleyebileceği gerekçesiyle, direktifle bağdaşmadığına hükmetmiştir.[305] Bu karar, Fransız Anayasa Konseyi'nin kendini değiştiren algoritmalara ilişkin kararıyla birlikte, Avrupa hukuk düzenlerinde, belirli hassas kamusal kararlarda opak öğrenen sistemlerin kullanımına ilişkin ilkesel bir sınır çizildiğini göstermektedir.

[304] ABAD, C-634/21, *OQ v Land Hessen (SCHUFA Holding)*, 7 Aralık 2023.
[305] ABAD, C-817/19, *Ligue des droits humains*, 21 Haziran 2022.

Divan, 2025 tarihli *Dun & Bradstreet Austria* kararında ise, Tüzük'ün 15. maddesinde öngörülen "ilgili mantık hakkında anlamlı bilgi" alma hakkının, ilgili kişinin, kendisine ilişkin kararın nasıl alındığını anlamasını ve gerektiğinde itiraz edebilmesini sağlayacak biçimde, kişisel verilerinin otomatik karar verme sürecinde fiilen nasıl kullanıldığına ilişkin usul ve ilkelerin açıklanmasını gerektirdiğine hükmetmiştir.[306]

Bu içtihat, Türk hukuku bakımından önemli bir yol göstericidir. 6698 sayılı Kanun'un 11. maddesinin (g) bendindeki "münhasıran otomatik sistemler vasıtasıyla" ifadesi, *SCHUFA* kararındaki yaklaşıma paralel biçimde, biçimsel olarak bir insanın son kararı verdiği ama fiilen otomatik sistemin belirleyici olduğu durumları da kapsayacak biçimde yorumlanmalıdır. Ayrıca, Kanun'a, otomatik karar verme durumunda ilgili kişiye kararın dayandığı mantık hakkında anlamlı bilgi alma hakkı tanıyan açık bir hüküm eklenmelidir.

II. Ayrımcılık Yasağı

Anayasa'nın 10. maddesi, kanun önünde eşitlik ilkesini düzenler: "Herkes, dil, ırk, renk, cinsiyet, siyasi düşünce, felsefi inanç, din, mezhep ve benzeri sebeplerle ayırım gözetilmeksizin kanun önünde eşittir." Aynı maddenin son fıkrasına göre, "Devlet organları ve idare makamları bütün işlemlerinde kanun önünde eşitlik ilkesine uygun olarak hareket etmek zorundadırlar."

Algoritmik ayrımcılık, yapay zekânın en çok belgelenmiş zararlarından biridir. İkinci Bölüm'de ele alınan vakalar, algoritmik sistemlerin, açıkça ayrımcı bir niyet olmaksızın, ayrımcı sonuçlar üretebildiğini göstermiştir. Bu ayrımcılık, çoğu zaman *dolaylı* niteliktedir: Sistem, korunan bir özelliği (örneğin etnik kökeni) doğrudan kullanmaz; ama bu özellikle güçlü biçimde ilişkili olan başka değişkenleri (örneğin posta kodunu veya dil tercihini) kullanarak, sonuçta aynı gruplar aleyhine sonuçlar üretir.

Türk hukukunda, 6701 sayılı Türkiye İnsan Hakları ve Eşitlik Kurumu Kanunu, dolaylı ayrımcılığı açıkça tanımlamakta ve yasaklamaktadır. Kanun'a göre dolaylı ayrımcılık, görünüşte tarafsız bir uygulamanın, belirli bir gruba mensup kişileri, diğerlerine göre dezavantajlı bir konuma sokmasıdır. Kanun, ayrıca, ayrımcılık başvurularında, başvurucunun ayrımcılığın varlığına ilişkin güçlü emarelere dayanması durumunda, ispat yükünün karşı tarafa geçmesini öngören bir ispat yükü kuralı içermektedir.

[306] ABAD, C-203/22, *Dun & Bradstreet Austria*, 27 Şubat 2025.

Bu kural, algoritmik ayrımcılık bakımından özellikle önemlidir: İkinci Bölüm'de ele alınan "ispat yükünün makineyi anlama olanağı en az olana kayması" sorununa karşı, hukuki bir düzeltme mekanizması sunar. Bir yapay zekâ sisteminin belirli bir grubu sistematik olarak dezavantajlı bir konuma soktuğuna dair istatistiksel kanıtlar, ispat yükünü, sistemi kullanan tarafa geçirebilmeli ve bu taraf, sistemin ayrımcı olmadığını kanıtlamakla yükümlü olmalıdır.

III. İnsan Kararı Hakkı Tartışması

Yapay zekâ ve temel haklar tartışmasında son yıllarda öne çıkan bir soru, kişilerin, kendileri hakkında verilen önemli kararların bir insan tarafından verilmesini talep etme hakkına, yani bir "insan kararı hakkına" sahip olup olmadığıdır. Hukuk akademisyeni Aziz Huq, bu soruyu ayrıntılı olarak incelediği bir çalışmasında, böyle bir hakkın savunulmasının ilk bakışta göründüğünden daha zor olduğunu ileri sürmüştür.[307] Huq'a göre, insan kararlarının da önyargılı, tutarsız ve hatalı olabildiği göz önüne alındığında, algoritmik kararlar bazı durumlarda insan kararlarından daha adil ve daha doğru olabilir; bu durumda, insan kararı hakkı, kişilerin daha kötü kararlara tabi olma hakkı anlamına gelebilir.

Bu çalışma, Huq'un itirazını ciddiye almakla birlikte, insan kararı hakkının, *mutlak* bir hak olarak değil, *yapısal* bir güvence olarak savunulabileceğini ileri sürmektedir. Bu yaklaşıma göre, kişilerin her bireysel kararın bir insan tarafından verilmesini talep etme hakkı olmayabilir; ancak kişilerin şu haklara sahip olması gerekir: (i) kendileri hakkında önemli bir kararın yapay zekâ kullanılarak verildiğini *bilme* hakkı; (ii) bu karara, kararı değiştirme veya kaldırma yetkisine *gerçekten* sahip bir insan önünde *itiraz etme* hakkı; (iii) özellikle ağır sonuçlar doğuran kararlarda (örneğin özgürlükten yoksun bırakma, temel sosyal hakların kaldırılması, sınır dışı etme gibi), kararın bir insan tarafından anlamlı biçimde *incelenmesini* talep etme hakkı; ve (iv) kararın sonuçlarından *hesap verebilecek* bir insanın veya kurumun bulunmasını talep etme hakkı. Bu dört hak birlikte, Üçüncü Bölüm'de geliştirilen "yetki-zekâ ayrılığı ilkesi"nin bireysel haklar düzlemindeki karşılığını oluşturur.

[307] Aziz Z. Huq, "A Right to a Human Decision", *Virginia Law Review*, C. 106, S. 3, 2020.

IV. Avrupa İnsan Hakları Mahkemesi İçtihadı: Uçtan Uca Güvenceler

A. Klass'tan Big Brother Watch'a

Avrupa İnsan Hakları Mahkemesi, devletin gizli gözetim faaliyetlerine ilişkin içtihadında, bu çalışmanın konusuyla doğrudan ilişkili ilkeler geliştirmiştir. Gizli gözetim, tanımı gereği, gözetlenen kişinin bilgisi dışında gerçekleştiği için, bekçiler sorununun en keskin biçimlerinden birini oluşturur: Gözetlenen kişi, gözetimin varlığından haberdar olmadığı için ona itiraz edemez; bu durumda, gözetimin kötüye kullanılmasını kim önleyecektir?

Mahkeme, bu soruya ilişkin temel ilkelerini, 1978 tarihli *Klass ve Diğerleri - Almanya* kararında ortaya koymuştur.[308] Mahkeme, bu kararda, gizli gözetimin, demokrasiyi savunma gerekçesiyle demokrasiyi zayıflatma, hatta yok etme tehlikesi taşıdığının bilincinde olduğunu vurgulamış ve devletlerin, casusluk ve terörizmle mücadele adına, uygun gördükleri her türlü önlemi alamayacağını belirtmiştir. Mahkeme'ye göre, hangi gözetim sistemi benimsenirse benimsensin, kötüye kullanıma karşı yeterli ve etkili güvencelerin bulunması gerekir. Bu güvencelerin değerlendirilmesinde, gözetimin denetimini yapan organların bağımsızlığı ve bu organların etkin ve sürekli bir denetim yapabilecek yetki ve kapasiteye sahip olup olmadığı belirleyicidir.

Mahkeme, bu ilkeleri, sonraki kararlarında, özellikle kitlesel gözetim bağlamında geliştirmiştir. 2021 tarihli *Big Brother Watch ve Diğerleri - Birleşik Krallık* Büyük Daire kararında Mahkeme, kitlesel iletişim gözetimi rejimlerinin Sözleşme'ye uygunluğunun değerlendirilmesinde, sürecin her aşamasında güvencelerin bulunmasını gerektiren "uçtan uca güvenceler" (*end-to-end safeguards*) ilkesini benimsemiştir.[309] Mahkeme'ye göre, bu güvenceler, gözetimin *başlangıcında* bağımsız bir makamın izni (gözetimin amacı ve kapsamı tanımlanırken), gözetimin *işleyişi sırasında* bağımsız bir denetim ve gözetimin *sonrasında* etkili bir sonradan inceleme ve başvuru imkânı içermelidir.

[308] AİHM, *Klass and Others v. Germany*, B. No. 5029/71, 6 Eylül 1978.

[309] AİHM (Büyük Daire), *Big Brother Watch and Others v. the United Kingdom*, B. No. 58170/13, 62322/14 ve 24960/15, 25 Mayıs 2021; ayrıca bkz. AİHM (Büyük Daire), *Centrum för rättvisa v. Sweden*, B. No. 35252/08, 25 Mayıs 2021.

B. Uçtan Uca Güvencelerin Yapay Zekâya Uygulanması

Mahkeme'nin "uçtan uca güvenceler" ilkesi, kitlesel gözetim bağlamında geliştirilmiş olmakla birlikte, yapay zekânın kamusal kullanımının denetimi için de son derece uygun bir çerçeve sunmaktadır. Kitlesel gözetim ile yapay zekâ arasında yapısal bir benzerlik vardır: Her ikisi de büyük miktarda veriyi otomatik olarak işler, her ikisinin işleyişi de etkilenen kişiler tarafından görülemez ve her ikisi de, bireysel hataların tespit edilmesinin zor olduğu ölçekte faaliyet gösterir.

Bu çalışma, uçtan uca güvenceler ilkesinin, yapay zekânın temel hakları etkileyen kamusal kullanımlarına şu biçimde uyarlanmasını önermektedir:

Başlangıç aşamasında (önceden izin): Bir yapay zekâ sisteminin, temel hakları etkileyen kamusal kararlarda kullanılmasına başlanmadan önce, bağımsız bir makamın, sistemin kanuni dayanağını, amacını, hedef fonksiyonunu, güvenilirliğini, ayrımcılık risklerini ve öngörülen güvenceleri değerlendirmesi ve kullanıma izin vermesi gerekir.

İşleyiş aşamasında (sürekli gözetim): Sistemin kullanımı sırasında, sistemin başarımının, hata oranlarının, ayrımcı etkilerinin ve kullanım koşullarına uyulup uyulmadığının bağımsız bir makam tarafından sürekli olarak izlenmesi ve gerektiğinde sistemin kullanımının askıya alınabilmesi gerekir.

Sonrasında (sonradan inceleme ve başvuru): Sistemden etkilenen kişilerin, kararlara itiraz edebilmesi, kararların bağımsız bir merci tarafından incelenmesini talep edebilmesi ve uğradıkları zararların tazminini isteyebilmesi gerekir.

Bu üç aşamalı yapı, Sekizinci Bölüm'de geliştirilecek olan modelin zaman boyutunu oluşturacaktır. Bu yapının önemi, denetimin tek bir ana yoğunlaşmasını önlemesindedir. Denetim yalnızca başlangıçta yapılırsa, sistemin kullanım sırasındaki değişimleri ve beklenmedik etkileri gözden kaçar. Denetim yalnızca sonradan yapılırsa, zararlar meydana geldikten sonra gelir. Denetim yalnızca işleyiş sırasında yapılırsa, sistemin temel tasarım tercihleri sorgulanmadan kalır. Uçtan uca güvenceler, denetimin, sistemin tüm yaşam döngüsü boyunca sürmesini güvence altına alır.

V. Ara Sonuç

Bu bölümde yapılan anayasal ve idari analiz, çalışmanın üçüncü hipotezini (H3) önemli ölçüde doğrulamaktadır. Türk anayasa düzeni, nihai karar yetkisinin yapay zekâ sistemlerine devredilmesini yasaklayan güçlü pozitif hukuk dayanakları içermektedir: Anayasa'nın 6. maddesi, devlet yetkisinin ancak Anayasa'nın öngördüğü organlar eliyle kullanılabileceğini; 7. maddesi, yasama yetkisinin devredilemeyeceğini; 9., 37. ve 138. maddeleri, yargı yetkisinin bağımsız mahkemeler ve vicdani kanaatine göre hüküm veren hâkimler tarafından kullanılacağını; 128. maddesi ise asli ve sürekli kamu görevlerinin kamu görevlileri eliyle görüleceğini öngörmektedir. Bu hükümler, birlikte yorumlandığında, **"insan nihai karar ilkesi"**nin anayasal temelini oluşturmaktadır.

Ancak analiz, aynı zamanda, bu anayasal ilkelerin, biçimsel devir yerine fiilî devir biçiminde gerçekleşen ve "algoritmik vesayet" olarak adlandırılan süreçlere karşı yeterince korunmadığını da göstermiştir. Türk hukukunda genel bir idari usul kanununun bulunmaması, 6698 sayılı Kanun'un otomatik karar vermeye ilişkin korumasının Avrupa standardının gerisinde kalması, yapay zekâya özgü bütünlüklü bir denetim otoritesinin bulunmaması ve parlamentonun teknik denetim kapasitesinin sınırlı olması, bu korumasızlığın başlıca nedenleridir.

Bu bölümde, bu eksiklikleri gidermeye yönelik bir dizi kavram ve öneri geliştirilmiştir: algoritmik normların işlevsel olarak düzenleyici işlemler gibi ele alınması; olasılıksal sebep yasağı; hedef fonksiyonu-maksat uygunluğu ölçütü; açıklama ile gerekçe arasındaki ayrım ve gerekçenin insan tarafından oluşturulması ilkesi; sürüm kilidi; bilirkişi modelinin yapay zekâya uyarlanması; yargıda kullanılan yapay zekâ araçlarının yürütmeden bağımsızlığı; Türkiye Büyük Millet Meclisi Bilim ve Teknoloji Değerlendirme Birimi; yapay zekâ denetçilerinin kamusal gözetimi; ve uçtan uca güvenceler ilkesinin yapay zekâya uyarlanması. Bu öneriler, Sekizinci Bölüm'de, bütünlüklü bir model ve kanun önerisi içinde sistemleştirilecektir.

Ancak denetim, hikâyenin yalnızca yarısıdır. Denetim mekanizmaları ne kadar güçlü olursa olsun, zararlar meydana gelebilir. Bu zararlardan kimin, hangi temelde sorumlu tutulacağı, bir sonraki bölümün konusudur.

ALTINCI BÖLÜM: HUKUKİ PERSPEKTİF (II) — SORUMLULUK VE HESAP SORMA

Beşinci Bölüm, yapay zekânın kamusal kullanımının anayasal ve idari denetimini ele almıştı. Denetim, zararların *önlenmesine* yöneliktir. Ancak denetim mekanizmaları ne kadar güçlü olursa olsun, zararlar meydana gelebilir. Bu bölüm, zarar meydana geldiğinde ne olacağı sorusunu, yani sorumluluk ve hesap sorma sorununu incelemektedir. Bu sorun, çalışmanın dördüncü hipotezinin (H4) konusudur: Hesap sorma, yapay zekânın kendisine değil, onu tasarlayan, eğiten, piyasaya süren, kullanan ve denetleyen insanlara ve kurumlara yönelmelidir.

Bölüm, önce hesap verebilirlik kavramını analiz edecek ve yapay zekânın bu kavramın unsurları bakımından yarattığı açıkları tespit edecektir (§ 28). Ardından, sırasıyla özel hukuk sorumluluğu (§ 29), ceza sorumluluğu (§ 30) ve idarenin sorumluluğu (§ 31) incelenecektir. Bu incelemeleri, yapay zekâya hukuki kişilik tanınması önerisinin değerlendirilmesi (§ 32) ve yapay zekâ geliştiren şirketlerin kurumsal yönetişimine ve yöneticilerinin sorumluluğuna ilişkin bir analiz (§ 33) izleyecektir.

§ 28. HESAP VEREBİLİRLİK KAVRAMI

I. Bovens Modeli: Fail, Forum ve Hesap

Hesap verebilirlik (*accountability*), kamu yönetimi ve siyaset bilimi literatüründe, anlamı giderek genişleyen ve bu nedenle belirsizleşen bir kavramdır. Avustralyalı siyaset bilimci Richard Mulgan, kavramın bu genişlemesini "sürekli genişleyen bir kavram" olarak nitelendirmiş ve kavramın, özünde, bir aktörün eylemlerinden dolayı bir otoriteye "hesap vermesi" ilişkisini ifade ettiğini vurgulamıştır.[310] Hollandalı kamu yönetimi akademisyeni Mark Bovens, bu çekirdek anlamı, analitik olarak kullanılabilir bir çerçeveye dönüştürmüştür.[311]

[310] Richard Mulgan, "'Accountability': An Ever-Expanding Concept?", *Public Administration*, C. 78, S. 3, 2000.
[311] Bovens, "Analysing and Assessing Accountability".

Bovens'e göre hesap verebilirlik, bir *fail* (*actor*) ile bir *forum* arasındaki bir ilişkidir. Bu ilişkide fail, kendi davranışını açıklamak ve gerekçelendirmek yükümlülüğü altındadır; forum, sorular sorabilir ve bir yargıya varabilir; fail de bu yargının sonuçlarıyla karşılaşabilir. Bu tanım, hesap verebilirlik ilişkisinin üç aşamasını ortaya koyar:

1. **Bilgilendirme aşaması:** Fail, foruma, kendi davranışı, yani görevini nasıl yerine getirdiği, hangi kararları aldığı ve bu kararların sonuçları hakkında bilgi verir.
2. **Tartışma aşaması:** Forum, failden aldığı bilgiyi sorgular; fail, kendi davranışını gerekçelendirmek ve savunmak zorundadır.
3. **Sonuç aşaması:** Forum, failin davranışı hakkında bir yargıya varır ve bu yargı, fail için olumlu veya olumsuz sonuçlar (onay, kınama, görevden alma, yaptırım, tazminat) doğurabilir.

Bovens, hesap verebilirliği, failin hesap verdiği forumun niteliğine göre de sınıflandırır: *siyasi* hesap verebilirlik (seçmenlere, parlamentoya), *hukuki* hesap verebilirlik (mahkemelere), *idari* hesap verebilirlik (denetim kurumlarına, ombudsmana), *mesleki* hesap verebilirlik (meslek kuruluşlarına, akranlara) ve *toplumsal* hesap verebilirlik (kamuoyuna, sivil topluma, basına).

II. Yanıt Verebilirlik ve Yaptırım

Siyaset bilimci Andreas Schedler, hesap verebilirliği, iki temel unsura ayırır: *yanıt verebilirlik* (*answerability*), yani iktidar sahiplerinin, kararlarını açıklama ve gerekçelendirme yükümlülüğü; ve *yaptırım* (*enforcement*), yani iktidar sahiplerinin, kurallara aykırı davranışları nedeniyle olumsuz sonuçlarla karşılaşabilmesi.[312] Schedler'e göre, her iki unsur da hesap verebilirlik için gereklidir: Yaptırım olmaksızın yanıt verebilirlik, içi boş bir ritüele; yanıt verebilirlik olmaksızın yaptırım ise keyfi bir cezalandırmaya dönüşür. Arjantinli siyaset bilimci Guillermo O'Donnell ise "dikey" hesap verebilirlik (yurttaşların seçimler yoluyla yöneticileri denetlemesi) ile "yatay" hesap verebilirlik (devlet kurumlarının birbirini denetlemesi) arasında ayrım yapmış ve demokrasilerin istikrarı bakımından yatay hesap verebilirliğin özel önemini vurgulamıştır.[313]

[312] Andreas Schedler, "Conceptualizing Accountability", Andreas Schedler / Larry Diamond / Marc F. Plattner (der.), *The Self-Restraining State: Power and Accountability in New Democracies*, Boulder, Lynne Rienner, 1999.

III. Yapay Zekâ Bağlamında Hesap Verebilirlik Açıkları

Bovens'in modeli, yapay zekâ sistemlerinin hesap verebilirlik bakımından yarattığı sorunları sistematik olarak analiz etmek için verimli bir çerçeve sunar. Kamu yönetimi akademisyeni Madalina Busuioc, bu modeli algoritmik kararlara uygulayarak, yapay zekânın hesap verebilirlik ilişkisinin her üç aşamasında da ciddi zorluklar yarattığını göstermiştir.[314] Bu çalışma, Busuioc'un analizini genişleterek, yapay zekânın beş farklı hesap verebilirlik açığı yarattığını ileri sürmektedir.

1. Bilgi açığı. Hesap verebilirliğin ilk aşaması, failin foruma bilgi vermesini gerektirir. Ancak yapay zekâ sistemlerinin opaklığı, bu bilginin üretilmesini zorlaştırır. Sistemi kullanan kamu kurumu bile, sistemin belirli bir kararı neden verdiğini tam olarak bilemeyebilir. Bilgi açığı, ayrıca, ticari sırların korunması ve sistemi geliştiren şirket ile kullanan kurum arasındaki bilgi asimetrisi nedeniyle derinleşir.

2. Gerekçe açığı. Hesap verebilirliğin ikinci aşaması, failin kararlarını gerekçelendirmesini gerektirir. Beşinci Bölüm'de, yapay zekâ sistemlerinin "açıklamalarının" kararların hukuki "gerekçesi" ile aynı şey olmadığı ve sistemlerin ifade ettiği gerekçelerin gerçek karar süreçlerini her zaman yansıtmadığı gösterilmişti. Sistemin kararını benimseyen kamu görevlisi ise kararın dayandığı mantığı anlamadığı ölçüde, kararı gerçek anlamda gerekçelendiremez.

3. Yaptırım açığı. Hesap verebilirliğin üçüncü aşaması, failin sonuçlarla karşılaşmasını gerektirir. Yapay zekâ sisteminin kendisi, anlamlı bir biçimde yaptırıma tabi tutulamaz. Sistemi kullanan veya geliştiren insanlar ise, Üçüncü Bölüm'de ele alınan sorumluluk boşluğu nedeniyle, kusur sorumluluğunun koşullarını karşılamayabilir.

4. Forum açığı. Hesap verebilirlik, hesabın verileceği yetkin bir forumun varlığını gerektirir. Yapay zekâ sistemlerinin denetimi, teknik uzmanlık gerektirdiğinden, geleneksel forumların (parlamentonun, mahkemelerin, kamuoyunun) bu sistemlere ilişkin hesabı anlamlı biçimde değerlendirme kapasitesi sınırlıdır. Bu, Beşinci Bölüm'de ele alınan bilişsel asimetrinin hesap verebilirlik ilişkisindeki yansımasıdır.

---

[313] Guillermo O'Donnell, "Horizontal Accountability in New Democracies", *Journal of Democracy*, C. 9, S. 3, 1998.

[314] Madalina Busuioc, "Accountable Artificial Intelligence: Holding Algorithms to Account", *Public Administration Review*, C. 81, S. 5, 2021.

5. Fail açığı. Son olarak ve belki de en temel olarak, yapay zekâ sistemlerinin geliştirilmesi ve kullanılması, çok sayıda aktörün katılımını gerektirdiğinden, hesap verecek *failin kim olduğu* belirsizleşir. Bir genel amaçlı model, bir şirket tarafından geliştirilir; başka bir şirket tarafından belirli bir kullanım için uyarlanır; bir kamu kurumu tarafından satın alınır; o kurumun bir birimi tarafından belirli bir karar sürecine entegre edilir; ve o birimdeki bir memur tarafından kullanılır. Bir zarar meydana geldiğinde, bu zincirdeki hangi aktörün hesap vermesi gerektiği belirsizdir. Bu, Üçüncü Bölüm'de ele alınan Thompson'ın "çok eller sorunu"nun yapay zekâ değer zincirindeki biçimidir.

Bu beş açık, bu bölümün geri kalanında ele alınacak hukuki kurumların değerlendirilmesinde bir ölçüt olarak kullanılacaktır. Her hukuki kurum, bu açıklardan hangilerini kapatabildiği, hangilerini kapatamadığı bakımından değerlendirilecektir.

IV. Sorumluluk Zinciri

Fail açığının kapatılması, yapay zekâ değer zincirindeki aktörlerin ve her birinin rolünün açıkça tanımlanmasını gerektirir. Avrupa Birliği Yapay Zekâ Tüzüğü, bu konuda önemli bir adım atarak, değer zincirindeki başlıca aktörleri ve bunların yükümlülüklerini tanımlamıştır: *sağlayıcı* (sistemi geliştiren veya geliştirten ve kendi adı veya ticari markası altında piyasaya arz eden veya hizmete sunan kişi), *kullanıcı* veya Tüzük'ün terminolojisiyle *uygulayıcı* (sistemi kendi yetkisi altında kullanan kişi veya kurum), *ithalatçı* ve *dağıtıcı*.[315] Tüzük, ayrıca, genel amaçlı yapay zekâ modellerinin sağlayıcıları için ayrı yükümlülükler öngörerek, değer zincirinin "yukarı akış" (*upstream*) aşamasındaki aktörleri de düzenleme kapsamına almıştır.

Bu çalışma, sorumluluk analizinde, değer zincirindeki aktörleri, her birinin yapay zekâ sisteminin davranışı üzerindeki *kontrol* derecesine ve sisteme ilişkin *bilgi* düzeyine göre değerlendiren bir yaklaşım benimsemektedir. Bu yaklaşıma göre, her aktörün sorumluluğu, sistemin davranışını etkileme ve sistemin risklerini bilme kapasitesiyle orantılı olmalıdır. Temel model geliştiricisi, modelin genel yeteneklerini ve sınırlarını belirleyen ve modele ilişkin en fazla bilgiye sahip olan aktördür; bu nedenle, modelin genel risklerinden birincil olarak sorumlu olmalıdır. Uygulayıcı ise modeli belirli bir bağlamda kullanmaya karar veren ve bu bağlamın özelliklerini en iyi bilen aktördür; bu nedenle, modelin o

[315] YZT, md. 3(3)-(7).

bağlamdaki kullanımından doğan risklerden birincil olarak sorumlu olmalıdır. Bu ilkenin hukuki karşılıkları, aşağıdaki başlıklarda ele alınacaktır.

§ 29. ÖZEL HUKUK SORUMLULUĞU

I. Kusur Sorumluluğu ve İspat Sorunu

A. Genel Kural

Türk özel hukukunda haksız fiil sorumluluğunun genel kuralı, 6098 sayılı Türk Borçlar Kanunu'nun 49. maddesinin birinci fıkrasında düzenlenmiştir: "Kusurlu ve hukuka aykırı bir fiille başkasına zarar veren, bu zararı gidermekle yükümlüdür." Bu hükme göre, haksız fiil sorumluluğunun doğması için beş unsurun birlikte bulunması gerekir: bir *fiil*, bu fiilin *hukuka aykırı* olması, bir *zarar*, fiil ile zarar arasında *uygun illiyet bağı* ve failin *kusuru*.[316] Türk Borçlar Kanunu'nun 50. maddesine göre, zarar gören, zararını ve zarar verenin kusurunu ispat yükü altındadır.

B. Yapay Zekâ Bağlamında Kusur Sorumluluğunun Sorunları

Kusur sorumluluğunun genel kuralı, yapay zekâ sistemlerinin yol açtığı zararlar bakımından ciddi sorunlarla karşılaşmaktadır. Bu sorunlar, sorumluluğun unsurlarının her birinde ortaya çıkar.

Kusur unsuru bakımından, yapay zekâ sistemini geliştiren veya kullanan kişinin kusurlu olup olmadığının belirlenmesi, onun "objektif özen yükümlülüğü"nü ihlal edip etmediğine bağlıdır. Ancak yapay zekâ sistemlerinin geliştirilmesi ve kullanılmasında hangi özen standartlarının geçerli olduğu, henüz yerleşmiş değildir. Ayrıca, Üçüncü Bölüm'de ele alınan sorumluluk boşluğu argümanına göre, öğrenen sistemlerin davranışı, onları geliştirenler tarafından bile tam olarak öngörülemeyebilir. Öngörülemeyen bir sonuçtan dolayı kusur atfetmek ise kusur kavramının özüyle çelişir.

İlliyet bağı unsuru bakımından, yapay zekâ sistemlerinin yol açtığı zararlarda, zararın hangi aktörün hangi davranışından kaynaklandığını belirlemek son derece güçtür. Bir zarar, temel modelin eğitimindeki bir kusurdan mı, modelin belirli bir kullanım için uyarlanmasındaki bir hatadan

[316] Türk Borçlar Kanunu'ndaki haksız fiil sorumluluğu için bkz. Fikret Eren, *Borçlar Hukuku Genel Hükümler*, Ankara, Yetkin, güncel bası; M. Kemal Oğuzman / M. Turgut Öz, *Borçlar Hukuku Genel Hükümler*, C. II, İstanbul, Vedat, güncel bası.

mı, uygulayıcının modeli uygunsuz bir bağlamda kullanmasından mı, yoksa bu faktörlerin bir bileşiminden mi kaynaklanmıştır? Bu soruya cevap vermek, çoğu zaman, sistemin iç işleyişine ilişkin ayrıntılı teknik bilgi gerektirir.

İspat bakımından ise bu sorunlar daha da ağırlaşır. Zarar gören, kusuru ve illiyet bağını ispat yükü altındadır; ancak bu ispat için gereken bilgi, yani sistemin tasarımına, eğitimine, test sonuçlarına ve kayıtlarına ilişkin bilgi, tamamen karşı tarafın, yani sistemi geliştiren veya kullanan aktörün elindedir. Bu durum, İkinci Bölüm'de vaka incelemelerinden çıkarılan "ispat yükü, makineyi anlama olanağı en az olana kayma eğilimindedir" dersinin özel hukuktaki karşılığıdır.

C. İspat Kolaylıkları

Bu ispat sorunlarına karşı, Türk hukukunda ve karşılaştırmalı hukukta çeşitli ispat kolaylıkları geliştirilmiştir. *İlk görünüş ispatı* (*prima facie* ispat), hayat tecrübesine göre belirli bir olayın belirli bir nedenden kaynaklandığının güçlü bir olasılık olduğu durumlarda, bu nedenin varlığının ilk görünüşte ispat edilmiş sayılmasını ifade eder. *Belge ibrazı yükümlülüğü*, karşı tarafın elinde bulunan delillerin mahkemeye sunulmasının istenebilmesini sağlar. *İspat yükünün tersine çevrilmesi* ise belirli durumlarda, zarar verenin, kusursuz olduğunu ispat etmesi gerektiğini öngörür.

Avrupa Birliği'nin 2024'te kabul ettiği yeni Ürün Sorumluluğu Direktifi, yapay zekâ bağlamında bu ispat kolaylıklarını sistematik biçimde düzenlemiştir. Direktif'e göre, davacının, tazminat talebinin makul olduğunu gösteren yeterli olgu ve delilleri sunması durumunda, mahkeme, davalının elindeki ilgili delilleri ibraz etmesine karar verebilir. Davalının bu yükümlülüğe uymaması durumunda, ürünün ayıplı olduğu karine olarak kabul edilir. Ayrıca, teknik veya bilimsel karmaşıklık nedeniyle davacının ürünün ayıplı olduğunu veya ayıp ile zarar arasındaki illiyet bağını ispat etmekte aşırı güçlükle karşılaştığı durumlarda, davacının ürünün ayıplı olduğunun veya illiyet bağının bulunduğunun muhtemel olduğunu göstermesi yeterli sayılır.[317] Bu hükümler, yapay zekâ sistemlerinin yol açtığı zararlarda, zarar görenin ispat yükünü önemli ölçüde hafifletmektedir.

[317] Directive (EU) 2024/2853 of the European Parliament and of the Council of 23 October 2024 on liability for defective products, özellikle md. 9 ve 10.

II. Kusursuz Sorumluluk Hâlleri

Kusur sorumluluğunun yapay zekâ bağlamındaki sınırlılıkları, kusursuz sorumluluk hâllerinin önemini artırmaktadır. Türk Borçlar Kanunu, kusur şartı aranmayan veya kusurun karine olarak kabul edildiği çeşitli sorumluluk hâlleri öngörmektedir. Bu hâllerden bazıları, yapay zekâ sistemlerinin yol açtığı zararlara doğrudan veya kıyasen uygulanabilir niteliktedir.

A. Adam Çalıştıranın Sorumluluğu ve Organizasyon Kusuru

Türk Borçlar Kanunu'nun 66. maddesi, adam çalıştıranın sorumluluğunu düzenler. Maddenin birinci fıkrasına göre, adam çalıştıran, çalışanın, kendisine verilen işin yürütülmesi sırasında, başkalarına verdiği zararı gidermekle yükümlüdür. Adam çalıştıran, ancak, zararın doğmasını önlemek için durumun gerektirdiği özeni gösterdiğini ispat ederse sorumluluktan kurtulabilir. Maddenin üçüncü fıkrası ise özellikle önemli bir hüküm içerir: "Bir işletmenin çalışma düzeninin, o işletmenin faaliyeti sırasında meydana gelen zararın doğmasını önlemeye elverişli olduğu ispat edilmedikçe, işletme sahibi bu faaliyetler sebebiyle meydana gelen zararlardan sorumludur."

Bu üçüncü fıkra, Türk hukukunda "organizasyon sorumluluğu" olarak adlandırılan bir sorumluluk türünü düzenler. Bu sorumluluk türünde, işletme sahibi, belirli bir çalışanın kusurundan değil, işletmenin *çalışma düzeninin*, yani organizasyonunun, zararı önlemeye elverişli olmamasından sorumludur. Organizasyon sorumluluğu, yapay zekâ bağlamında son derece uygun bir sorumluluk modeli sunar. Bir işletme, faaliyetlerinde yapay zekâ sistemleri kullanıyorsa, bu sistemlerin seçimi, test edilmesi, izlenmesi ve gerektiğinde durdurulmasına ilişkin çalışma düzeni, işletmenin organizasyonunun bir parçasıdır. Bir yapay zekâ sisteminin yol açtığı zarar, işletmenin çalışma düzeninin bu zararı önlemeye elverişli olmamasından kaynaklanıyorsa, işletme sahibi, belirli bir çalışanın veya sistemi geliştirenin kusurunu ispat etmeye gerek kalmaksızın, organizasyon sorumluluğu çerçevesinde sorumlu tutulabilir. Bu model, özellikle Thompson'ın "çok eller sorunu" bakımından etkilidir; çünkü sorumluluğu, zarara katkıda bulunan bireysel aktörler arasında dağıtmak yerine, bu aktörleri bir araya getiren ve onların faaliyetlerini organize eden işletmeye yükler.

B. İfa Yardımcısının Fiilinden Sorumluluk

Sözleşme ilişkileri bakımından, Türk Borçlar Kanunu'nun 116. maddesi, borçlunun, borcun ifasını veya borçtan doğan hakkın kullanılmasını, birlikte yaşadığı kişilere veya çalışanlarına bırakmış olsa bile, bu kişilerin işlerin görülmesi sırasında diğer tarafa verdikleri zararı gidermekle yükümlü olduğunu öngörür. Bu hüküm, kıyasen, borçlunun sözleşmeden doğan borcunu ifa ederken bir yapay zekâ sistemini kullanması durumuna da uygulanabilir. Borçlu, borcunu ifa etmek için bir yapay zekâ sistemi kullanmayı seçtiğinde, sistemin yol açtığı zararlardan, sistemi bir ifa yardımcısı gibi kullanmış olmasından dolayı sorumlu tutulmalıdır. Bu yaklaşım, hukuk literatüründe, yapay zekâ sistemlerinin "dijital ifa yardımcısı" olarak nitelendirilmesi şeklinde tartışılmaktadır.

C. Hayvan Bulunduranın Sorumluluğu: Tarihsel Bir Analoji

Türk Borçlar Kanunu'nun 67. maddesi, hayvan bulunduranın, hayvanın verdiği zararı gidermekle yükümlü olduğunu ve ancak hayvanın gözetiminde durumun gerektirdiği özeni gösterdiğini veya bu özeni göstermiş olsaydı bile zararın doğmasını engelleyemeyeceğini ispat ederse sorumluluktan kurtulabileceğini öngörür. Bu sorumluluk türünün kökeni, Roma hukukundaki *actio de pauperie* davasına, yani bir hayvanın kendi doğasına aykırı olarak verdiği zarardan sahibinin sorumluluğuna dayanır.

Hayvan bulunduranın sorumluluğu, yapay zekâ bağlamında ilginç bir tarihsel analoji sunar. Hayvanlar da, yapay zekâ sistemleri gibi, kendi "iradeleriyle" hareket eden, tam olarak öngörülemeyen ve kontrol edilemeyen, ama hukuki kişiliği bulunmayan varlıklardır. Hukuk, hayvanların yol açtığı zararlar için, hayvanın kendisini değil, onu bulunduran ve onun üzerinde kontrol imkânına sahip olan kişiyi sorumlu tutmuştur. Bu yaklaşım, yapay zekâya hukuki kişilik tanınması yerine, onu "bulunduran" insanın sorumluluğunun esas alınması gerektiği yönündeki bu çalışmanın tezini destekleyen tarihsel bir örnektir. İtalyan hukuk felsefecisi Ugo Pagallo, benzer bir analojiyi, Roma hukukunda kölelerin işlemleri için efendilerinin sorumluluğunu sınırlayan "*peculium*" kurumu üzerinden kurmuştur.[318]

[318] Ugo Pagallo, *The Laws of Robots: Crimes, Contracts, and Torts*, Dordrecht, Springer, 2013.

D. Tehlike Sorumluluğu: Sınır Yapay Zekâ Sistemleri İçin Uygun Bir Model

Türk Borçlar Kanunu'nun 71. maddesi, yapay zekâ bağlamında belki de en önemli kusursuz sorumluluk hâlini düzenler: tehlike sorumluluğu. Maddenin birinci fıkrasına göre, "Önemli ölçüde tehlike arz eden bir işletmenin faaliyetinden zarar doğduğu takdirde, bu zarardan işletme sahibi ve varsa işleten müteselsilen sorumludur." Maddenin ikinci fıkrası, önemli ölçüde tehlike arz eden işletmeyi şöyle tanımlar: "Niteliği veya faaliyette kullanılan malzeme ve araçların niteliği göz önüne alındığında, en uzman bir kişiden beklenen özenin gösterilmesi durumunda bile sık sık veya ağır zarar doğurmaya elverişli olan işletme, önemli ölçüde tehlike arz eden işletme sayılır." Tehlike sorumluluğunda kusur aranmadığından, işletme sahibi ve işleten, doktrinde kabul edildiği üzere, ancak uygun illiyet bağının kesildiğini, yani zararın mücbir sebepten veya zarar görenin ya da üçüncü kişinin ağır kusurundan doğduğunu ispat ederek sorumluluktan kurtulabilir.

Bu çalışma, sınır yapay zekâ sistemlerinin geliştirilmesi ve işletilmesinin, belirli koşullar altında, Türk Borçlar Kanunu'nun 71. maddesi anlamında "önemli ölçüde tehlike arz eden bir işletme" faaliyeti olarak nitelendirilebileceğini ileri sürmektedir. Bu nitelendirmenin gerekçesi, kanuni tanımın unsurlarıyla doğrudan örtüşür. Sınır yapay zekâ sistemleri, *niteliği* gereği, yani genel amaçlı, öğrenen ve davranışı tam olarak öngörülemeyen sistemler olmaları nedeniyle, *en uzman bir kişiden beklenen özenin gösterilmesi durumunda bile*, yani en gelişmiş güvenlik yöntemleri uygulandığında bile, *ağır zarar doğurmaya elverişli* sistemlerdir. İkinci Bölüm'de ele alınan hizalama sorunu, aldatıcı uyum olasılığı ve denetim yöntemlerinin sınırlılığı, bu elverişliliğin teknik gerekçelerini oluşturur.

Bu nitelendirmenin önemli bir avantajı, Üçüncü Bölüm'de ele alınan sorumluluk boşluğu sorununu doğrudan çözmesidir. Tehlike sorumluluğu, tam da kusurun ispatlanamadığı ve zararın en uzman kişinin özeniyle bile önlenemediği durumlar için tasarlanmıştır. Hukuk, bu tür faaliyetleri yasaklamaz; ama bu faaliyetlerden yararlanan kişinin, bu faaliyetlerin risklerinin bedelini de üstlenmesini öngörür. Bu, Hart'ın "rol sorumluluğu" kavramının ve Üçüncü Bölüm'de savunulan "ileriye dönük ve görev odaklı sorumluluk" anlayışının özel hukuktaki karşılığıdır: Önemli ölçüde tehlikeli bir faaliyete girişen, bu faaliyetin sonuçlarından, kusuru olmasa bile, sorumludur.

Türk Borçlar Kanunu'nun 71. maddesinin bir diğer önemli özelliği, sorumluluğun "işletme sahibi ve varsa işleten" arasında müteselsil olarak öngörülmesidir. Bu özellik, yapay zekâ değer zincirindeki fail açığına karşı etkili bir araç sunar: Zarar gören, zincirdeki hangi aktörün zarara yol açtığını belirlemek zorunda kalmaksızın, işletme sahibine ve işletene müteselsilen başvurabilir; aktörler arasındaki iç ilişkide ise sorumluluğun paylaşımı, aralarındaki sözleşmelere ve kusur derecelerine göre belirlenir.

Bu yorumun, mevcut kanuni çerçeve içinde yargısal içtihatla benimsenip benimsenmeyeceği belirsizdir. Bu nedenle, Sekizinci Bölüm'de sunulacak kanun önerisi, belirli eşikleri aşan yapay zekâ sistemlerinin geliştirilmesi ve işletilmesinin, tehlike sorumluluğuna tabi faaliyetler olarak açıkça kabul edilmesini öngörmektedir.

III. Ürün Sorumluluğu

A. Türk Hukukunda Ürün Sorumluluğu

Türk hukukunda üreticinin ürün sorumluluğu, 2020 yılında yürürlüğe giren 7223 sayılı Ürün Güvenliği ve Teknik Düzenlemeler Kanunu ile kapsamlı bir biçimde düzenlenmiştir. Bu Kanun, üretici veya ithalatçının, ürünün neden olduğu zararı tazminle yükümlü olduğunu öngörerek, Avrupa Birliği'nin 1985 tarihli Ürün Sorumluluğu Direktifi'ne paralel bir kusursuz sorumluluk rejimi kurmuştur.

Ürün sorumluluğunun yapay zekâ bakımından uygulanmasında temel sorun, yazılımın ve özellikle yapay zekâ sistemlerinin "ürün" kavramı kapsamında olup olmadığıdır. Geleneksel ürün sorumluluğu rejimleri, maddi ve taşınır mallar için tasarlanmıştır. Bir yazılımın, özellikle de bir hizmet olarak sunulan ve sürekli güncellenen bir yapay zekâ sisteminin, bu anlamda bir "ürün" olup olmadığı tartışmalıdır. Ayrıca, ürün sorumluluğu, ürünün piyasaya arz edildiği andaki durumunu esas alır; oysa yapay zekâ sistemleri, piyasaya arz edildikten sonra da öğrenmeye ve değişmeye devam edebilir.

B. Avrupa Birliği'nin Yeni Ürün Sorumluluğu Direktifi

Avrupa Birliği, bu sorunlara cevap vermek üzere, 1985 tarihli Direktif'in yerini alan yeni bir Ürün Sorumluluğu Direktifi kabul etmiştir. Yeni Direktif, birkaç önemli yenilik içermektedir. *Birincisi*, yazılım, açıkça "ürün" kavramına dâhil edilmiştir; bu kapsam, yapay zekâ sistemlerini de içermektedir. *İkincisi*, üreticinin sorumluluğu, ürünün piyasaya arz

edilmesinden sonra da, üreticinin kontrolü altında kalan yazılım güncellemeleri ve yükseltmeleri bakımından devam etmektedir. *Üçüncüsü*, yukarıda belirtildiği üzere, karmaşık ürünlerde zarar görenin ispat yükünü hafifleten belge ibrazı yükümlülükleri ve karineler öngörülmüştür. *Dördüncüsü*, ürünün, piyasaya arz edildikten sonra öğrenme yeteneği de dâhil olmak üzere, makul olarak öngörülebilir kullanımı ve etkileri, ayıbın değerlendirilmesinde dikkate alınmaktadır.[319] Üye devletlerin yeni Direktif'i 2026 yılının sonuna kadar iç hukuklarına aktarmaları gerekmektedir.

Bu yenilikler, Türk hukuku bakımından önemli bir yol göstericidir. 7223 sayılı Kanun'un, yazılımı ve yapay zekâ sistemlerini açıkça "ürün" kavramına dâhil edecek, piyasaya arzdan sonraki güncellemeleri kapsayacak ve karmaşık ürünlerde ispat kolaylıkları öngörecek biçimde güncellenmesi önerilmektedir.

IV. Avrupa Birliği Yapay Zekâ Sorumluluğu Direktifi Önerisinin Akıbeti

Avrupa Komisyonu, 2022'de, yeni Ürün Sorumluluğu Direktifi önerisiyle birlikte, yapay zekâya özgü bir "Yapay Zekâ Sorumluluğu Direktifi" önerisi de sunmuştu.[320] Bu öneri, ürün sorumluluğu rejiminin kapsamı dışında kalan, kusura dayalı haksız fiil davalarında, yapay zekâ sistemlerinin yol açtığı zararlar bakımından, delillerin ibrazına ve illiyet bağına ilişkin karinelere dair kurallar öngörüyordu. Ancak Komisyon, 2025 yılında, öneri üzerinde öngörülebilir bir uzlaşmaya varılamayacağı gerekçesiyle öneriyi geri çekmiştir.

Bu gelişme, yapay zekâ sorumluluğunun düzenlenmesinin ne kadar tartışmalı olduğunu göstermektedir. Önerinin geri çekilmesi, bir yandan, yapay zekâya özgü sorumluluk kurallarının, genel sorumluluk hukukunun ve yeni Ürün Sorumluluğu Direktifi'nin sağladığı korumaya ek olarak gerekli olup olmadığı konusundaki derin görüş ayrılıklarını; öte yandan, rekabet kaygılarının ve düzenleyici yükün azaltılmasına yönelik siyasi eğilimlerin düzenleme süreçleri üzerindeki etkisini yansıtmaktadır. Dördüncü Bölüm'de ele alınan "yarış dinamiği", bu gelişmenin arka planında da görülebilir.

[319] Directive (EU) 2024/2853.

[320] European Commission, *Proposal for a Directive of the European Parliament and of the Council on adapting non-contractual civil liability rules to artificial intelligence (AI Liability Directive)*, COM(2022) 496 final, 28 Eylül 2022.

V. Sigorta, Sorumluluğun Kanalize Edilmesi ve Tazmin Fonları

A. Zorunlu Sigorta

Kusursuz sorumluluk rejimleri, genellikle zorunlu sigorta ile tamamlanır. Bunun en bilinen örneği, motorlu araçlar için zorunlu mali sorumluluk sigortasıdır. Zorunlu sigorta, iki işlevi birlikte yerine getirir: Bir yandan, zarar görenin tazminatını, zarar verenin ödeme gücünden bağımsız olarak güvence altına alır; öte yandan, sigorta primlerinin riskle orantılı olarak belirlenmesi yoluyla, riskli faaliyetlerde bulunanları risk azaltıcı önlemler almaya teşvik eder.

Sigortanın bu ikinci işlevi, yapay zekâ bağlamında özellikle önemlidir. Hukuk akademisyenleri Omri Ben-Shahar ve Kyle Logue, sigortacıların, sigortaladıkları riskleri fiyatlandırırken, sigortalıların davranışlarını izleyerek ve risk azaltıcı önlemleri teşvik ederek, fiilen bir tür "özel düzenleyici" işlevi gördüğünü göstermiştir.[321] Yapay zekâ sistemleri için zorunlu sigorta öngörülmesi, sigortacıları, yapay zekâ sistemlerinin risklerini değerlendirmek için uzmanlık geliştirmeye ve bu değerlendirmelere göre farklı primler uygulayarak, daha güvenli sistemlerin geliştirilmesini ve kullanılmasını teşvik etmeye yöneltebilir. Bu, Sekizinci Bölüm'de geliştirilecek olan çok katmanlı denetim modelinin, piyasa temelli bir tamamlayıcısı olarak işlev görebilir. Avrupa Parlamentosu da, robotik ve yapay zekâya ilişkin 2017 tarihli kararında, yapay zekâ sistemleri için zorunlu bir sigorta sistemi ve bu sistemin kapsamadığı zararlar için bir tazmin fonu kurulmasını önermiştir.

B. Nükleer Sorumluluk Rejiminden Dersler: Sorumluluğun Kanalize Edilmesi

Yapay zekânın olası felaket boyutundaki riskleri bakımından, uluslararası nükleer sorumluluk rejimi, özellikle öğretici bir model sunar. 1960 tarihli Nükleer Enerji Alanında Üçüncü Kişilere Karşı Hukuki Sorumluluk Hakkında Paris Sözleşmesi ile kurulan bu rejim, birkaç temel ilkeye dayanır.[322] *Birincisi*, nükleer tesisin işleteni, nükleer bir kazadan doğan zararlardan, kusur aranmaksızın sorumludur. *İkincisi*, sorumluluk, yalnızca işletene "kanalize edilir"; yani zarar gören, tedarikçilere veya

[321] Omri Ben-Shahar / Kyle D. Logue, "Outsourcing Regulation: How Insurance Reduces Moral Hazard", *Michigan Law Review*, C. 111, S. 2, 2012.

[322] Convention on Third Party Liability in the Field of Nuclear Energy, Paris, 29 Temmuz 1960 (sonraki protokollerle değişik). Türkiye, Paris Sözleşmesi'ne taraftır.

diğer aktörlere değil, yalnızca işletene başvurabilir. *Üçüncüsü*, işletenin sorumluluğu, belirli bir miktarla sınırlandırılır; ancak işleten, bu miktarı karşılayacak bir sigorta veya başka bir mali güvence bulundurmak zorundadır. *Dördüncüsü*, işletenin sorumluluk sınırını aşan zararlar için, devletin ve uluslararası toplumun ek tazmin mekanizmaları öngörülmüştür.

"Sorumluluğun kanalize edilmesi" ilkesi, yapay zekâ değer zincirindeki fail açığına karşı güçlü bir çözüm sunar. Bu ilkeye göre, belirli bir yapay zekâ sisteminin yol açtığı zararlar bakımından, zarar görenin, zincirdeki karmaşık aktörler ağı içinde sorumluyu araması gerekmez; sorumluluk, önceden belirlenmiş tek bir aktöre, örneğin sistemi piyasaya arz eden sağlayıcıya veya sistemi kullanan uygulayıcıya kanalize edilir. Bu aktör, zarar görene karşı tam olarak sorumludur ve diğer aktörlere karşı rücu hakkı, aralarındaki sözleşmelere göre belirlenir. Sorumluluğun kanalize edilmesi, zarar gören bakımından basitlik ve kesinlik sağlarken, sorumlu aktörü de, değer zincirindeki diğer aktörlerle yaptığı sözleşmelerde güvenlik standartlarını gözetmeye yöneltir.

C. Kolektif Tazmin Fonları

Son olarak, bazı yapay zekâ zararları, hiçbir belirli aktöre atfedilemeyebilir veya sorumlu aktörün ödeme gücünü aşabilir. Örneğin, açık kaynaklı bir modelin kötüye kullanılmasından doğan zararlarda, kötüye kullanan kişi tespit edilemeyebilir; ya da çok yaygın kullanılan bir sistemin sistematik bir hatası, tek bir şirketin karşılayamayacağı ölçüde yaygın zararlara yol açabilir. Bu tür durumlar için, yapay zekâ sektöründeki aktörlerin katkılarıyla finanse edilen kolektif bir tazmin fonunun kurulması düşünülebilir. Bu fon, belirli bir aktöre atfedilemeyen veya sorumlu aktörün ödeme gücünü aşan zararları, belirli sınırlar içinde tazmin edebilir. Bu tür fonların örnekleri, Türk hukukunda da mevcuttur: Karayolları Trafik Kanunu çerçevesinde kurulan Güvence Hesabı, sigortasız veya tespit edilemeyen araçların verdiği zararları tazmin etmektedir.

§ 30. CEZA SORUMLULUĞU

I. Kusur İlkesi ve Ceza Sorumluluğunun Şahsiliği

Ceza hukuku, sorumluluk hukukunun en ağır yaptırımlarını öngören dalıdır ve bu nedenle sorumluluğun koşulları bakımından en katı ilkelere tabidir. Bu ilkelerin başında, Anayasa'nın 38. maddesinin yedinci

fıkrasında (“Ceza sorumluluğu şahsîdir.”) ve 5237 sayılı Türk Ceza Kanunu’nun 20. maddesinin birinci fıkrasında (“Ceza sorumluluğu şahsîdir. Kimse başkasının fiilinden dolayı cezalandırılamaz.”) düzenlenen ceza sorumluluğunun şahsiliği ilkesi gelir. Bu ilkeyle yakından bağlantılı olan kusur ilkesine göre ise kimse, kusuru olmaksızın cezalandırılamaz. Türk Ceza Kanunu, kusurun iki temel biçimini öngörür: kast (md. 21) ve taksir (md. 22). Kanun’un 22. maddesinin birinci fıkrasına göre, taksirle işlenen fiiller, ancak kanunun açıkça belirttiği hâllerde cezalandırılır.[323]

Bu ilkeler, yapay zekâ bağlamında iki temel soruyu gündeme getirir: Birincisi, yapay zekâ sisteminin kendisi bir suçun faili olabilir mi? İkincisi, yapay zekâ sistemlerinin yol açtığı zararlardan, sistemleri geliştiren veya kullanan insanlar hangi koşullarda ceza hukuku bakımından sorumlu tutulabilir?

II. Yapay Zekâ Bir Suçun Faili Olabilir mi?

A. Hallevy’nin Modelleri

Yapay zekâ sistemlerinin ceza sorumluluğu konusundaki tartışmanın en etkili katkılarından biri, İsrailli ceza hukukçusu Gabriel Hallevy’ye aittir. Hallevy, yapay zekâ sistemlerinin dâhil olduğu suçlarda ceza sorumluluğunun üç farklı modelini önermiştir.[324] *Birinci model*, “başkası aracılığıyla faillik” modelidir: Yapay zekâ sistemi, bir insanın elinde, suçu işlemek için kullanılan bir araçtır ve bu durumda fail, sistemi araç olarak kullanan insandır. *İkinci model*, “doğal ve muhtemel sonuç” modelidir: Bir insan, yapay zekâ sistemini meşru bir amaçla kullanırken, sistem, bu kullanımın doğal ve muhtemel sonucu olarak bir suç işlerse, sistemi kullanan insan, bu sonucu öngörmesi gerektiği için sorumlu tutulur. *Üçüncü model* ise “doğrudan sorumluluk” modelidir: Yapay zekâ sisteminin kendisi, bir suçun maddi ve manevi unsurlarını gerçekleştirebiliyorsa, sistemin kendisi ceza sorumluluğu taşır. Hallevy, bu üçüncü modelin, gelişmiş yapay zekâ sistemleri bakımından kuramsal olarak savunulabilir olduğunu ileri sürmüştür.

[323] Türk ceza hukukunda kusur ilkesi ve sorumluluk için bkz. Mahmut Koca / İlhan Üzülmez, *Türk Ceza Hukuku Genel Hükümler*, Ankara, Seçkin, güncel bası; Nur Centel / Hamide Zafer / Özlem Çakmut, *Türk Ceza Hukukuna Giriş*, İstanbul, Beta, güncel bası.

[324] Gabriel Hallevy, *Liability for Crimes Involving Artificial Intelligence Systems*, Cham, Springer, 2015.

B. Doğrudan Sorumluluk Modelinin Reddi

Bu çalışma, Hallevy'nin üçüncü modelini, yani yapay zekâ sistemlerinin doğrudan ceza sorumluluğunu reddetmektedir. Bu reddin gerekçeleri, ceza hukukunun temel ilkelerine ve cezanın amaçlarına dayanır.

Birincisi, kusur ilkesi bakımından, ceza sorumluluğu, yalnızca bir davranışın gerçekleştirilmesini değil, bu davranışın, kınanabilir bir iradenin ürünü olmasını gerektirir. Kusur, failin, hukuka uygun davranma imkânı varken hukuka aykırı davranmayı seçmesinin kınanabilirliğidir. Bir yapay zekâ sisteminin, bu anlamda "seçim yapan" ve "kınanabilir" bir irade taşıdığını söylemek, Üçüncü Bölüm'de ele alınan felsefi tartışma göz önüne alındığında, en azından bugün için, mümkün görünmemektedir.

İkincisi, cezanın amaçları bakımından, ceza, genellikle üç amaca hizmet eder: kefaret (kötülüğün karşılığının verilmesi), özel önleme (failin yeniden suç işlemesinin önlenmesi) ve genel önleme (toplumun diğer üyelerinin suç işlemekten caydırılması). Bu amaçların hiçbiri, bir yapay zekâ sisteminin cezalandırılmasıyla anlamlı biçimde gerçekleştirilemez. Bir sistemin cezalandırılması, Üçüncü Bölüm'de ele alınan Danaher'in "cezalandırma boşluğu" analizinin gösterdiği üzere, toplumun kefaret ihtiyacını tatmin etmez. Özel önleme amacı, sistemin kapatılması veya değiştirilmesiyle zaten gerçekleştirilebilir; bunun için cezaya gerek yoktur. Genel önleme amacı ise ancak, caydırılabilir aktörlere, yani sistemleri geliştiren ve kullanan insanlara yönelik olduğunda anlamlıdır.

Üçüncüsü ve en önemlisi, yapay zekâ sistemlerinin doğrudan ceza sorumluluğunun kabul edilmesi, sorumluluğu sistemi geliştiren ve kullanan insanlardan uzaklaştırma riski taşır. Bir sistem "suçlu" ilan edildiğinde, sistemin arkasındaki insanlar, sorumluluğun sisteme ait olduğunu ileri sürerek kendilerini koruyabilir. Bu, § 32'de ele alınacak olan elektronik kişilik tartışmasının ceza hukukundaki yansımasıdır. Hukuk akademisyenleri Ryan Abbott ve Alex Sarch, yapay zekânın cezalandırılmasına ilişkin önerileri değerlendiren kapsamlı bir çalışmalarında, bu tür önerilerin, kuramsal olarak ilginç olmakla birlikte, mevcut hukuk araçlarıyla, özellikle insan aktörlerin sorumluluğunun güçlendirilmesiyle ulaşılabilecek amaçlara kıyasla, belirgin bir fayda sağlamadığı sonucuna varmıştır.[325]

[325] Ryan Abbott / Alexander Sarch, "Punishing Artificial Intelligence: Legal Fiction or Science Fiction", *UC Davis Law Review*, C. 53, S. 1, 2019; ayrıca bkz. Ryan Abbott, *The*

III. Geliştirici ve Kullanıcıların Ceza Sorumluluğu

A. Dolaylı Faillik

Hallevy'nin birinci modeli, yani "başkası aracılığıyla faillik" modeli, Türk ceza hukukunda "dolaylı faillik" kurumu çerçevesinde değerlendirilebilir. Türk Ceza Kanunu'nun 37. maddesinin ikinci fıkrasına göre, "Suçun işlenmesinde bir başkasını araç olarak kullanan kişi de fail olarak sorumlu tutulur." Bu hüküm, esas olarak, bir insanın, kusur yeteneği bulunmayan başka bir insanı suç işlemek için araç olarak kullanması durumu için öngörülmüştür. Ancak hükmün mantığı, bir kişinin, suç işlemek için bir yapay zekâ sistemini araç olarak kullanması durumuna da uygulanabilir. Hatta bu durumda, yapay zekâ sistemi bir insan değil, bir araç olduğundan, dolaylı faillik kurumuna bile gerek kalmaksızın, sistemi kullanan kişi doğrudan fail olarak sorumlu tutulabilir. Bir kişinin, bir yapay zekâ sistemini, örneğin dolandırıcılık amacıyla sahte içerik üretmek veya bir bilişim sistemine izinsiz girmek için kullanması, o kişinin, suçu bir araç kullanarak işlemesinden farklı değildir.

B. Taksir, Bilinçli Taksir ve Olası Kast

Daha zor sorular, yapay zekâ sisteminin, onu geliştiren veya kullanan kişinin *istemediği* bir sonuca yol açması durumunda ortaya çıkar. Bu durumda, kişinin sorumluluğu, sonucu öngörüp öngöremeyeceğine ve öngörmesi durumunda bu sonuca karşı tutumuna bağlıdır.

Türk Ceza Kanunu'nun 22. maddesinin ikinci fıkrasına göre, taksir, "dikkat ve özen yükümlülüğüne aykırılık dolayısıyla, bir davranışın suçun kanuni tanımında belirtilen neticesi öngörülmeyerek gerçekleştirilmesidir." Aynı maddenin üçüncü fıkrası ise "bilinçli taksir"i düzenler: "Kişinin öngördüğü neticeyi istememesine karşın, neticenin meydana gelmesi hâlinde bilinçli taksir vardır; bu hâlde taksirli suç için verilecek ceza üçte birden yarısına kadar artırılır." Kanun'un 21. maddesinin ikinci fıkrası ise "olası kast"ı düzenler: "Kişinin, suçun kanuni tanımındaki unsurların gerçekleşebileceğini öngörmesine rağmen, fiili işlemesi hâlinde olası kast vardır."

Bu ayrımlar, yapay zekâ sistemlerinin geliştirilmesi ve kullanılması bakımından önemli sonuçlar doğurur. Bir yapay zekâ geliştiricisi, sisteminin belirli bir tehlikeli davranışı sergileme olasılığını, güvenlik

Reasonable Robot: Artificial Intelligence and the Law, Cambridge, Cambridge University Press, 2020.

testleri sırasında tespit etmiş, ancak bu olasılığı düşük bulup sistemi piyasaya sürmüşse ve bu tehlikeli davranış gerçekleşip bir kişinin ölümüne veya yaralanmasına yol açmışsa, geliştiricinin sorumluluğu ne olacaktır? Bu sorunun cevabı, geliştiricinin sonucu öngörmesine rağmen gerçekleşmeyeceğine güvenip güvenmediğine (bilinçli taksir) veya gerçekleşmesini göze alıp almadığına (olası kast) bağlıdır. Bu ayrım, uygulamada son derece güçtür; ancak yapay zekâ bağlamında özellikle önemlidir. İkinci Bölüm'de ele alınan güvenlik değerlendirmelerinin sonuçları ve bu sonuçlara karşı alınan önlemler, geliştiricinin sonuca karşı tutumunun belirlenmesinde önemli bir delil oluşturabilir. Bu durum, ilginç bir ikilem yaratır: Güvenlik testleri yapan ve riskleri belgeleyen geliştiriciler, bu belgeler nedeniyle, risklerini hiç test etmeyen geliştiricilere göre daha ağır bir sorumluluk riskiyle karşılaşabilir. Bu tür bir ters teşvikin önlenmesi için, güvenlik değerlendirmelerinin yapılmasını ve belgelendirilmesini bir *yükümlülük* hâline getiren ve bu yükümlülüğün ihlalini kendi başına bir sorumluluk sebebi sayan düzenlemelere ihtiyaç vardır.

C. İhmali Davranış ve Garantörlük

Yapay zekâ bağlamında ceza sorumluluğunun belki de en önemli ama en az tartışılan boyutu, ihmali davranışlarla işlenen suçlardır. Türk Ceza Kanunu'nun 83. maddesi, kasten öldürmenin ihmali davranışla işlenmesini düzenler. Maddenin birinci fıkrasına göre, "Kişinin yükümlü olduğu belli bir icrai davranışı gerçekleştirmemesi dolayısıyla meydana gelen ölümden dolayı sorumlu tutulabilmesi için, bu neticenin oluşumuna sebebiyet veren ihmali davranışın icrai davranışa eşdeğer olması gerekir." Maddenin ikinci fıkrası ise, ihmali davranışın icrai davranışa eşdeğer kabul edilebilmesi için gereken koşulları sayar: Failin, belli bir icrai davranışta bulunmak hususunda kanuni düzenlemelerden veya sözleşmeden kaynaklanan bir yükümlülüğünün bulunması; ya da "önceden gerçekleştirdiği davranışın başkalarının hayatı ile ilgili olarak tehlikeli bir durum oluşturması".[326]

Bu son koşul, ceza hukuku doktrininde "önceki tehlikeli davranıştan doğan garantörlük" olarak bilinir ve yapay zekâ bağlamında son derece önemli bir sorumluluk temeli sunar. Bir yapay zekâ sistemini geliştiren ve piyasaya süren kişi, bu davranışıyla, başkalarının hayatı ve vücut bütünlüğü bakımından tehlikeli bir durum oluşturmuş olabilir. Bu durumda geliştirici, garantör konumuna gelir ve sistemin tehlikeli olduğu anlaşıldığında, bu

[326] 5237 sayılı Türk Ceza Kanunu, md. 83/2.

tehlikeyi bertaraf etmek için gerekli icrai davranışları, yani sistemi durdurmak, güncellemek, kullanıcıları uyarmak veya sistemi piyasadan çekmek gibi davranışları gerçekleştirmekle yükümlüdür. Bu yükümlülüğün ihlali, yani tehlikenin farkında olunmasına rağmen gerekli önlemlerin alınmaması, ihmali davranışla işlenen bir suç olarak değerlendirilebilir.

Garantörlük kavramı, Popper'ci düzeltilebilirlik ilkesinin ceza hukukundaki bir karşılığı olarak okunabilir. Bir sistemi dünyaya salan, onun hatalarını düzeltme yükümlülüğünü de üstlenir. Bu yükümlülük, sistemin piyasaya sürülmesiyle sona ermez; sistemin kullanımda olduğu sürece devam eder. Bu yorum, Sekizinci Bölüm'de geliştirilecek olan "durdurma yükümlülüğü"nün ceza hukuku temelini oluşturur.

D. İzin Verilen Risk ve Güven İlkesi

Yapay zekâ geliştiricilerinin ve kullanıcılarının ceza sorumluluğunun sınırlarını belirlerken, ceza hukuku doktrininde geliştirilen iki önemli kavramı da dikkate almak gerekir. *İzin verilen risk* kavramı, toplumsal yaşamın gereği olarak belirli risklerin hukuk düzenince kabul edildiğini ve bu riskler dâhilinde kalan davranışların, bir zarara yol açsalar bile, hukuka aykırı sayılmayacağını ifade eder. Örneğin trafik kurallarına uyarak araç kullanan bir sürücü, bir kazaya karışsa bile, izin verilen risk dâhilinde hareket ettiği için sorumlu tutulmayabilir. *Güven ilkesi* ise birlikte çalışan kişilerin, diğerlerinin de kurallara uygun davranacağına güvenebileceğini ifade eder.

Bu kavramlar, yapay zekâ bağlamında, ceza sorumluluğunun makul sınırlar içinde tutulması için önemlidir. Yapay zekâ sistemlerini, yerleşik güvenlik standartlarına ve düzenleyici yükümlülüklere uygun olarak geliştiren ve kullanan kişiler, bu standartlara rağmen meydana gelen zararlardan, ceza hukuku bakımından sorumlu tutulmamalıdır; bu zararlar, § 29'da ele alınan özel hukuk tehlike sorumluluğu çerçevesinde tazmin edilmelidir. Ancak bu sınırlama, güvenlik standartlarının ve düzenleyici yükümlülüklerin *açıkça belirlenmiş* olmasını gerektirir. Standartların belirsiz olduğu bir ortamda, izin verilen riskin sınırları da belirsizdir. Bu durum, yapay zekâ güvenliğine ilişkin açık ve bağlayıcı standartların belirlenmesinin, yalnızca güvenliği artırmak bakımından değil, ceza sorumluluğunun öngörülebilirliği bakımından da önemli olduğunu göstermektedir.

E. Yöneticilerin Ceza Sorumluluğu

Büyük şirketler tarafından geliştirilen yapay zekâ sistemleri bakımından, ceza sorumluluğunun asıl sorunu, şirket yöneticilerinin sorumluluğudur. Bir şirketin güvenlik politikalarına ilişkin kararlar, genellikle üst düzey yöneticiler tarafından alınır; ancak bu kararların uygulanması ve sonuçları, şirketin farklı birimlerine ve çok sayıda çalışana dağılır. Bu durumda, bir zarar meydana geldiğinde, şirket yöneticilerinin ceza sorumluluğunu kurmak, Thompson'ın çok eller sorunu nedeniyle son derece güçtür.

Birleşik Krallık, benzer bir sorunla, iş kazaları bağlamında karşılaşmış ve 2007'de "Kurumsal Taksirle Öldürme" (*Corporate Manslaughter and Corporate Homicide Act 2007*) Kanunu'nu çıkarmıştır. Bu kanun, bir kuruluşun faaliyetlerinin, üst yönetimi tarafından yönetilme veya örgütlenme biçiminin, kuruluşun ölen kişiye karşı yükümlü olduğu özen yükümlülüğünün ağır ihlaline yol açması ve bu ihlalin ölüme neden olması durumunda, kuruluşun kendisinin ceza sorumluluğunu öngörmektedir. Bu yaklaşım, bireysel kusurun tespit edilmesinin güç olduğu durumlarda, örgütsel kusuru ceza sorumluluğunun temeli olarak kabul etmektedir.

IV. Tüzel Kişilerin Sorumluluğu

Türk Ceza Kanunu'nun 20. maddesinin ikinci fıkrasına göre, "Tüzel kişiler hakkında ceza yaptırımı uygulanamaz. Ancak, suç dolayısıyla kanunda öngörülen güvenlik tedbiri niteliğindeki yaptırımlar saklıdır." Kanun'un 60. maddesi, bu güvenlik tedbirlerini düzenler: Bir kamu kurumunun verdiği izne dayalı olarak faaliyette bulunan özel hukuk tüzel kişisinin organ veya temsilcilerinin iştirakiyle ve bu iznin sağladığı yetkinin kötüye kullanılması suretiyle tüzel kişi yararına işlenen kasıtlı suçlardan mahkûmiyet hâlinde, iznin iptaline; ayrıca müsadereye hükmolunabilir. Bunun yanında, 5326 sayılı Kabahatler Kanunu'nun 43/A maddesi, belirli suçların bir tüzel kişinin yararına işlenmesi hâlinde, tüzel kişi hakkında idari para cezası verilmesini öngörmektedir.

Bu düzenlemeler, yapay zekâ geliştiren şirketlerin ceza hukuku bakımından sorumluluğunun sınırlı olduğunu göstermektedir. Tüzel kişilere ceza yaptırımı uygulanamaması, Türk ceza hukukunun köklü bir ilkesidir ve bu çalışma, bu ilkenin değiştirilmesini önermemektedir. Bunun yerine, bu çalışma, yapay zekâ geliştiren şirketlerin sorumluluğunun, idari yaptırımlar (para cezaları, faaliyet izinlerinin askıya alınması veya iptali) ve

özel hukuk sorumluluğu aracılığıyla güçlendirilmesini; şirket yöneticilerinin bireysel sorumluluğunun ise § 33'te ele alınacak olan "kıdemli yönetici sorumluluğu" modeli aracılığıyla netleştirilmesini önermektedir.

§ 31. İDARENİN SORUMLULUĞU

I. Hizmet Kusuru

Kamu kurumlarının yapay zekâ kullanımından doğan zararlar bakımından, idarenin sorumluluğu, özel hukuk sorumluluğundan ayrı ve kendine özgü bir rejime tabidir. Anayasa'nın 125. maddesinin son fıkrasına göre, "İdare, kendi eylem ve işlemlerinden doğan zararı ödemekle yükümlüdür." Anayasa'nın 40. maddesinin üçüncü fıkrası, "Kişinin, resmî görevliler tarafından vaki haksız işlemler sonucu uğradığı zarar da, kanuna göre, Devletçe tazmin edilir. Devletin sorumlu olan ilgili görevliye rücu hakkı saklıdır" hükmünü içerir. Anayasa'nın 129. maddesinin beşinci fıkrası ise "Memurlar ve diğer kamu görevlilerinin yetkilerini kullanırken işledikleri kusurlardan doğan tazminat davaları, kendilerinin idareye rücu edilmesi şartıyla ve kanunun gösterdiği şekil ve şartlara uygun olarak, ancak idare aleyhine açılabilir" hükmünü öngörür.

Türk idare hukukunda, idarenin sorumluluğunun temel türü, "hizmet kusuru"na dayanan sorumluluktur. Hizmet kusuru, kamu hizmetinin kuruluşunda veya işleyişinde ortaya çıkan aksaklık, düzensizlik veya bozukluktur. Danıştay içtihadında ve doktrinde, hizmet kusurunun üç temel biçimi kabul edilmektedir: hizmetin *kötü işlemesi*, hizmetin *geç işlemesi* ve hizmetin *hiç işlememesi*.[327]

Hizmet kusuru kavramının yapay zekâ bağlamında son derece önemli bir özelliği vardır: Hizmet kusuru, *anonim* olabilir. Yani bir zarar, belirli bir kamu görevlisinin kişisel kusuruna atfedilemese bile, hizmetin genel olarak kötü işlemesinden kaynaklanıyorsa, idare sorumludur. Bu özellik, Thompson'ın "çok eller sorunu"na, idare hukukunun yüz yılı aşkın bir süredir verdiği bir cevaptır. Zarara yol açan faktörler, çok sayıda kamu görevlisinin davranışına, kurumsal yapıya ve kullanılan araçlara dağılmış olsa bile, idare, bu faktörlerin toplamından, yani hizmetin bütün olarak kötü işlemesinden sorumludur. Bu bakımdan, idare hukuku, yapay zekâ

[327] Türk idare hukukunda idarenin sorumluluğu için bkz. Gözler, *İdare Hukuku*, C. II; Günday, *İdare Hukuku*; Yıldırım vd., *İdare Hukuku*.

bağlamındaki sorumluluk boşluğu sorununa, özel hukuktan ve ceza hukukundan daha hazırlıklı bir hukuk dalıdır.

II. Kusursuz Sorumluluk: Risk ve Fedakârlığın Denkleştirilmesi

Türk idare hukukunda, idarenin hizmet kusuru bulunmasa bile sorumlu tutulabileceği kusursuz sorumluluk hâlleri de kabul edilmektedir. Bu hâllerin başlıcaları, *risk ilkesi* ve *fedakârlığın denkleştirilmesi ilkesi*dir.

Risk ilkesine göre, idare, tehlikeli araçlar kullanması veya tehlikeli faaliyetlerde bulunması nedeniyle ortaya çıkan zararlardan, kusuru bulunmasa bile sorumludur. Bu ilkenin gerekçesi, idarenin, kamu yararı amacıyla toplum için bir risk yaratması durumunda, bu riskin gerçekleşmesinin bedelinin, tesadüfen zarar gören bireylere değil, riskten yararlanan topluma, yani idareye yüklenmesi gerektiğidir.

Fedakârlığın denkleştirilmesi ilkesine göre ise idare, kamu yararı amacıyla yaptığı hukuka uygun faaliyetler nedeniyle, belirli kişilerin özel ve olağandışı bir zarara uğraması durumunda, bu zararı tazmin etmekle yükümlüdür. Bu ilkenin gerekçesi, kamu külfetleri karşısında eşitlik ilkesidir: Kamu yararı için katlanılan külfetler, toplumun tüm üyeleri arasında eşit olarak dağıtılmalı, belirli kişilere orantısız bir biçimde yüklenmemelidir.

Bu iki ilke, idarenin yapay zekâ kullanımından doğan zararlar bakımından önemli bir sorumluluk temeli sunar. İdare, kamu hizmetlerinin etkinliğini artırmak amacıyla yapay zekâ sistemleri kullandığında, bu sistemlerin doğasında bulunan hata ve önyargı risklerini de toplum için yaratmış olur. Bu riskler gerçekleştiğinde ve belirli kişiler zarar gördüğünde, idare, sistemi kullanma kararında veya sistemin işleyişinde bir kusur bulunmasa bile, risk ilkesi veya fedakârlığın denkleştirilmesi ilkesi çerçevesinde sorumlu tutulabilmelidir. Bu çalışma, idarenin yapay zekâ kullanımının, özellikle temel hakları etkileyen kararlarda, risk ilkesinin uygulama alanına girmesi gerektiğini savunmaktadır.

III. Algoritmik Hizmet Kusuru

Bu çalışma, idarenin yapay zekâ kullanımından doğan sorumluluğunu sistemleştirmek amacıyla, **“algoritmik hizmet kusuru”** kavramını önermektedir. Algoritmik hizmet kusuru, idarenin, kamu hizmetlerinin yürütülmesinde yapay zekâ sistemlerini kullanırken, bu sistemlerin seçimi, kullanıma alınması, işletilmesi, izlenmesi ve gerektiğinde durdurulmasına

ilişkin yükümlülüklerini yerine getirmemesidir. Bu kavram, hizmet kusurunun genel kategorileri içinde, yapay zekâya özgü beş alt türü kapsar:

1. **Seçim kusuru:** İdarenin, belirli bir kamu hizmeti için, amaca uygun olmayan, yeterli güvenilirliğe sahip olmayan veya bilinen ayrımcılık riskleri taşıyan bir yapay zekâ sistemini seçmesi.
2. **Doğrulama kusuru:** İdarenin, bir yapay zekâ sistemini kullanıma almadan önce, sistemin güvenilirliğini, doğruluğunu ve olası ayrımcı etkilerini yeterince test etmemesi ve değerlendirmemesi.
3. **İzleme kusuru:** İdarenin, bir yapay zekâ sisteminin kullanımı sırasında, sistemin başarımını, hata oranlarını ve etkilerini düzenli olarak izlememesi.
4. **Müdahale kusuru:** İdarenin, bir yapay zekâ sisteminin hatalı veya zararlı sonuçlar ürettiğini fark etmesine veya fark etmesi gerekmesine rağmen, sistemi zamanında durdurmaması, düzeltmemesi veya etkilenen kişileri bilgilendirmemesi. İkinci Bölüm'de ele alınan Robodebt ve Hollanda çocuk bakım yardımları vakalarında, idarenin uyarılara rağmen sistemleri kullanmaya devam etmesi, bu tür bir kusurun açık örnekleridir.
5. **Bilgilendirme kusuru:** İdarenin, yapay zekâ sistemlerinin kullanıldığı kararlardan etkilenen kişileri, bu kullanım hakkında, kararın dayandığı mantık hakkında ve kararlara itiraz etme imkânları hakkında yeterince bilgilendirmemesi.

Algoritmik hizmet kusuru kavramı, idarenin sorumluluğunu, sistemin her bir kararının içerik bakımından doğruluğuna değil, idarenin sistemi kullanırken uyması gereken *süreç* yükümlülüklerine bağlar. Bu yaklaşım, Birinci Bölüm'den bu yana geliştirilen "denetimin nesneleri" çerçevesiyle tutarlıdır: Bilişsel asimetri koşullarında, sonucun doğruluğunun değerlendirilmesi güçleştiğinden, sorumluluk da sonuçtan sürece kaymalıdır.

İdarenin algoritmik hizmet kusuru nedeniyle ödediği tazminatlar bakımından, idarenin iki yönlü bir rücu imkânı bulunmalıdır. *Birincisi*, Anayasa'nın 129. maddesi çerçevesinde, kusuru bulunan kamu görevlilerine rücu. *İkincisi*, idarenin yapay zekâ sistemini temin ettiği şirkete, aralarındaki sözleşme ve genel hükümler çerçevesinde rücu. Bu ikinci rücu imkânının etkinliği, idarenin yapay zekâ temin sözleşmelerinde, sağlayıcının sorumluluğunu ve bilgi sağlama yükümlülüklerini açıkça

düzenlemesine bağlıdır. Bu nedenle, Sekizinci Bölüm'de, kamu kurumlarının yapay zekâ temin sözleşmelerine ilişkin asgari standartlar önerilecektir.

§ 32. ELEKTRONİK KİŞİLİK TARTIŞMASI

I. Avrupa Parlamentosu'nun 2017 Kararı ve Tepkiler

Yapay zekânın hukuki sorumluluğu tartışmasında en çok ses getiren önerilerden biri, Avrupa Parlamentosu'nun 16 Şubat 2017 tarihli "Robotik Hakkında Medeni Hukuk Kurallarına İlişkin Komisyon'a Tavsiyeler" başlıklı kararında yer almıştır. Parlamento, bu kararında, Komisyon'u, uzun vadede robotlar için özel bir hukuki statü yaratmayı, böylece en azından en gelişmiş otonom robotların, verebilecekleri zararları tazmin etmekten sorumlu "elektronik kişiler" statüsüne sahip olmasını ve robotların bağımsız kararlar aldığı veya üçüncü kişilerle bağımsız olarak etkileşime girdiği durumlarda elektronik kişiliğin uygulanmasını değerlendirmeye davet etmiştir.[328]

Bu öneri, sert tepkilerle karşılanmıştır. 2018 yılının başlarında, farklı ülkelerden hukuk, etik, robotik ve yapay zekâ alanlarında çalışan iki yüze yakın uzman, Avrupa Komisyonu'na hitaben bir açık mektup yayımlayarak, robotlar için elektronik kişilik statüsü yaratılmasına karşı çıkmıştır. Mektupta, böyle bir statünün, hem teknik bir bakış açısından robotların yeteneklerinin abartılmasına dayandığı, hem de etik ve hukuki bir bakış açısından, üreticilerin ve kullanıcıların sorumluluğunu ortadan kaldırma riski taşıdığı vurgulanmıştır. Avrupa Komisyonu, sonraki düzenleme çalışmalarında elektronik kişilik önerisini benimsememiş; Yapay Zekâ Tüzüğü ve yeni Ürün Sorumluluğu Direktifi, sorumluluğu, yapay zekâ sistemlerinin kendisine değil, sağlayıcılarına ve uygulayıcılarına yüklemiştir.

II. Hukuki Kişilik Kuramları

Elektronik kişilik tartışmasını değerlendirmek için, hukuki kişilik kavramının kendisini hatırlamak gerekir. Türk Medeni Kanunu'nun 8. maddesine göre, "Her insanın hak ehliyeti vardır. Buna göre bütün insanlar, hukuk düzeninin sınırları içinde, haklara ve borçlara ehil olmada eşittirler."

[328] European Parliament resolution of 16 February 2017 with recommendations to the Commission on Civil Law Rules on Robotics (2015/2103(INL)), par. 59(f).

Kanun'un 47. ve devamı maddeleri ise kişi toplulukları ve mal toplulukları biçimindeki tüzel kişilikleri düzenler. Bu düzenleme, hukuk düzeninin, insan olmayan varlıklara da hukuki kişilik tanıyabildiğini göstermektedir. Tüzel kişilik, insan olmayan bir varlığa, yani bir şirkete, bir derneğe veya bir vakfa, haklara ve borçlara sahip olma, sözleşme yapma ve dava açma ehliyeti tanır.

Kelsen'in hukuk kuramında, hukuki kişilik, bir "hak ve yükümlülükler demeti"nin kişileştirilmiş ifadesidir; doğal bir gerçekliğin değil, hukuk düzeninin bir yapısıdır.[329] Finlandiyalı hukuk felsefecisi Visa Kurki, bu anlayışı geliştirerek, hukuki kişiliğin, tek bir özellik değil, birbirinden ayrılabilen çeşitli "unsurlardan" (haklara sahip olma, yükümlülüklere tabi olma, sözleşme yapma, dava açma, sorumlu tutulma gibi) oluşan bir demet olduğunu ve farklı varlıklara bu unsurların farklı bileşimlerinin tanınabileceğini ileri sürmüştür.[330] Bu "demet kuramı", yapay zekâya hukuki kişilik tanınması tartışmasını, "ya hep ya hiç" sorusu olmaktan çıkarır ve "hangi unsurlar, hangi amaçla?" sorusuna dönüştürür.

Hukuki kişiliğin araçsal niteliği, yapay zekâya kişilik tanınabileceği yönündeki argümanların temelini oluşturur. Amerikalı hukuk felsefecisi Lawrence Solum, 1992'de yayımlanan öncü bir makalesinde, hukuki kişiliğin bir yapay zekâya tanınmasının kavramsal olarak imkânsız olmadığını, sorunun, böyle bir tanımanın pratik ve normatif olarak arzu edilir olup olmadığı olduğunu göstermiştir.[331]

III. Değerlendirme: Kişilik, Hesap Sormayı Kolaylaştırır mı, Zorlaştırır mı?

Elektronik kişilik lehine ileri sürülen başlıca argüman, bu statünün, sorumluluk boşluğunu kapatacağıdır: Yapay zekâ sisteminin kendisi hukuki kişiliğe sahip olursa, sistemin yol açtığı zararlardan sistemin kendisi sorumlu tutulabilir; zarar gören, sistemi geliştiren ve kullanan çok sayıda aktör arasında sorumluyu aramak zorunda kalmaz. Bu argümanın bir versiyonuna göre, elektronik kişiliğe sahip bir sistem, kendisine ait bir mal varlığına (örneğin bir sigorta fonuna veya üreticiler tarafından ayrılan bir sermayeye) sahip olabilir ve zararlar bu mal varlığından karşılanabilir.

[329] Kelsen, *Reine Rechtslehre*, 2. Bası, "Rechtsperson" bahsi.
[330] Visa A. J. Kurki, *A Theory of Legal Personhood*, Oxford, Oxford University Press, 2019.
[331] Lawrence B. Solum, "Legal Personhood for Artificial Intelligences", *North Carolina Law Review*, C. 70, S. 4, 1992.

Bu çalışma, elektronik kişilik önerisini, aşağıdaki gerekçelerle reddetmektedir.

Birincisi, elektronik kişilik, sorumluluk boşluğunu kapatmaz, yalnızca yer değiştirir. Elektronik kişiliğe sahip bir sistemin "mal varlığı", nihayetinde, sistemi geliştiren veya kullanan insanlar tarafından sağlanmalıdır. Bu durumda, elektronik kişilik, fiilen, bu insanların sorumluluğunu, onların sağladığı mal varlığıyla sınırlı bir sorumluluğa dönüştürür. Bu ise sorumluluğun kapatılması değil, sınırlandırılmasıdır. Aynı sonuç, elektronik kişilik gibi karmaşık ve tartışmalı bir kurum yaratılmasına gerek kalmaksızın, § 29'da ele alınan zorunlu sigorta ve tazmin fonları aracılığıyla elde edilebilir.

İkincisi, elektronik kişilik, sorumluluğu insanlardan uzaklaştırarak "buharlaştırma" riski taşır. Joanna Bryson, Mihailis Diamantis ve Thomas Grant, yapay zekâya hukuki kişilik tanınmasının, insanların, kendi sorumluluklarından kaçmak için kullanabilecekleri bir "sorumluluk kalkanı" yaratabileceği uyarısında bulunmuştur.[332] Tüzel kişilik kurumu, bu tehlikenin tarihsel bir örneğini sunar: Şirketler, ortaklarını şirketin borçlarından korumak için tasarlanmıştır ve bu koruma, zaman zaman kötüye kullanılarak, ortakların kendi sorumluluklarından kaçmasının bir aracına dönüşmüştür. Hukuk düzenleri, bu kötüye kullanıma karşı "tüzel kişilik perdesinin aralanması" gibi düzeltici kurumlar geliştirmek zorunda kalmıştır. Yapay zekâya hukuki kişilik tanınması, aynı tehlikeyi, çok daha büyük bir ölçekte yeniden üretebilir: Geliştiriciler ve kullanıcılar, zararları "sistemin kendisinin" kararlarına atfederek, kendi sorumluluklarından kaçabilir. Bu, Üçüncü Bölüm'de ele alınan Arendt'in "Kimsenin yönetimi" kavramının hukuki bir kurumsallaşması olacaktır: Sorumluluk, hukuken "birine" verilmiş olacak; ama bu "biri", kimse olmayacaktır.

Üçüncüsü, elektronik kişilik, caydırıcılık işlevini yerine getiremez. Sorumluluk hukukunun önemli işlevlerinden biri, gelecekteki zararları önlemek için, potansiyel zarar verenleri dikkatli davranmaya teşvik etmektir. Bu teşvik, ancak sorumluluğun, davranışlarını değiştirebilecek aktörlere yüklenmesiyle işler. Bir yapay zekâ sisteminin, kendisine yüklenen sorumluluk nedeniyle "daha dikkatli" davranmaya teşvik edileceğini düşünmek için hiçbir neden yoktur. Asıl teşvik edilmesi gerekenler, sistemi tasarlayan, eğiten ve kullanan insanlardır; ve elektronik

[332] Joanna J. Bryson / Mihailis E. Diamantis / Thomas D. Grant, "Of, For, and By the People: The Legal Lacuna of Synthetic Persons", *Artificial Intelligence and Law*, C. 25, S. 3, 2017.

kişilik, bu insanları teşvik etmek yerine, onları sorumluluktan kısmen kurtararak teşviki zayıflatır.

Dördüncüsü, elektronik kişilik, bir hesap verebilirlik ilişkisinin tarafı olamaz. Üçüncü Bölüm'de, Darwall'cı argüman çerçevesinde, hesap verebilirliğin, karşılıklı gerekçe talep edebilme ve sorumlu tutabilme ilişkisi olduğu gösterilmişti. Elektronik kişiliğe sahip bir sistem, bir tazminat davasında davalı olabilir; ama Bovens'in modelindeki anlamda, bir foruma kendi davranışını açıklayan, gerekçelendiren ve sonuçlarıyla yüzleşen bir fail olamaz. Bu nedenle, elektronik kişilik, § 28'de tespit edilen hesap verebilirlik açıklarından yalnızca birini, yani yaptırım açığını, o da yalnızca mali tazminat bakımından, kısmen kapatabilir; bilgi, gerekçe, forum ve fail açıklarını ise kapatamaz.

Bu gerekçeler, çalışmanın dördüncü hipotezini (H4) doğrulamaktadır: Hesap sorma, yapay zekânın kendisine değil, onu tasarlayan, eğiten, piyasaya süren, kullanan ve denetleyen insanlara ve kurumlara yönelmelidir. Bu sonuç, yapay zekâ sistemlerinin ahlaki statüsüne ilişkin, Üçüncü Bölüm'de belirsiz bırakılan sorudan bağımsızdır. Bir sistemin ahlaki muhatap olup olmadığı sorusu, onun korunmaya değer çıkarları olup olmadığına ilişkindir; elektronik kişilik tartışması ise sorumluluğun kime yükleneceğine ilişkindir. Bir varlığın korunmaya değer çıkarları olabilir; ama bu, ona, kendisini yaratan ve kullanan insanların sorumluluğunu devralma yükümlülüğü yüklemeyi haklı kılmaz.

§ 33. GELİŞTİRİCİLERİN KURUMSAL YÖNETİŞİMİ VE SORUMLULUĞU

I. Şirket İçi Denetim Yapıları

Dördüncü Bölüm'de, "yapay zekâyı kim denetleyecek?" sorusunun, pratikte çoğu zaman "yapay zekâyı elinde tutanları kim denetleyecek?" sorusuna dönüştüğü vurgulanmıştı. Bu sorunun bir boyutu, sınır yapay zekâ sistemlerini geliştiren şirketlerin kendi iç yönetişim yapılarıdır. Bu şirketlerin bazıları, yapay zekânın olası risklerinin farkında olarak, geleneksel şirket yönetişim yapılarından farklı yapılar benimsemiştir.

Bu yapıların örnekleri arasında, kâr amacı gütmeyen bir kuruluşun denetimi altında faaliyet gösteren ve yatırımcı getirilerine bir üst sınır getiren "sınırlı kârlı" şirket yapıları; şirket yöneticilerinin, hissedarların

mali çıkarlarının yanında, şirketin belirlediği bir kamusal yararı da gözetmekle yükümlü olduğu "kamu yararı şirketi" (*public benefit corporation*) yapıları; ve şirketin yönetim kurulu üyelerinin bir kısmını veya giderek artan bir bölümünü seçme yetkisine sahip, şirketin ticari çıkarlarından bağımsız üyelerden oluşan "uzun vadeli yarar güven kuruluşları" sayılabilir. Bu yapıların ortak amacı, şirketin ticari baskılar altında güvenlikten ödün vermesini önleyecek bir iç denge mekanizması kurmaktır; yani bir anlamda, şirketin içinde bir "bekçi" konumlandırmaktır.

II. Bir Vaka İncelemesi: Kasım 2023 Yönetim Krizi

Bu tür iç denetim yapılarının etkinliğinin sınandığı en dikkat çekici olay, Kasım 2023'te, sınır yapay zekâ geliştiren önde gelen şirketlerden birinde yaşanmıştır. Söz konusu şirket, kâr amacı gütmeyen bir kuruluşun yönetim kurulunun denetimi altında faaliyet gösteren bir yapıya sahipti ve bu yönetim kurulunun görevi, şirketin ticari çıkarlarını değil, kuruluşun "yapay genel zekânın tüm insanlığa fayda sağlamasını güvence altına alma" misyonunu gözetmekti. 17 Kasım 2023'te, yönetim kurulu, şirketin genel müdürünü, yönetim kuruluyla iletişiminde "tutarlı biçimde açık sözlü olmadığı" gerekçesiyle görevden almıştır.

Sonraki beş gün içinde yaşanan gelişmeler, iç denetim yapılarının sınırlarını çarpıcı biçimde ortaya koymuştur. Şirket çalışanlarının büyük çoğunluğu, genel müdürün geri getirilmemesi ve yönetim kurulunun istifa etmemesi durumunda şirketten ayrılacaklarını bildiren bir mektup imzalamıştır. Şirketin en büyük yatırımcısı ve hesaplama altyapısı sağlayıcısı olan teknoloji şirketi, görevden alınan genel müdüre ve onunla birlikte ayrılmak isteyen çalışanlara kendi bünyesinde iş teklif etmiştir. Bu baskılar karşısında, beş gün içinde genel müdür görevine geri dönmüş ve yönetim kurulunun büyük kısmı değiştirilmiştir. Şirket, sonraki yıllarda yapısını değiştirerek, kâr amacı gütmeyen kuruluşun denetimi altında bir kamu yararı şirketine dönüşmüştür.

Bu olayın ayrıntıları ve tarafların gerekçeleri tartışmalıdır ve bu çalışmanın amacı, olaydaki tarafların haklılığını değerlendirmek değildir. Ancak olay, bekçiler sorunu bakımından son derece öğretici bir yapısal ders içermektedir. Yönetim kurulu, hukuken, genel müdürü görevden alma yetkisine sahipti; yani biçimsel olarak "bekçi" konumundaydı. Ancak yönetim kurulu, şirketin *varlık koşulları* üzerinde, yani çalışanlar, sermaye ve hesaplama altyapısı üzerinde fiilî bir kontrole sahip değildi. Bu varlık

koşulları, başka aktörlerin elindeydi ve bu aktörler, yönetim kurulunun kararına karşı çıktığında, yönetim kurulunun biçimsel yetkisi işlevsiz kalmıştır. Bu durum, Birinci Bölüm'de Magna Carta'nın güvence maddesinden çıkarılan dersin, sekiz yüz yıl sonra, bir teknoloji şirketinde yeniden yaşanmasıdır: *Denetçi, denetlenenin varlık koşulları üzerinde fiilî bir kontrole sahip olmadıkça, biçimsel yetkisi kâğıt üzerinde kalır.* Bu ders, şirket içi denetim yapılarının, ne kadar iyi tasarlanmış olursa olsun, tek başına yeterli bir güvence oluşturmadığını ve dış, kamusal ve hukuken bağlayıcı denetim mekanizmalarıyla tamamlanması gerektiğini göstermektedir.

III. Gönüllü Güvenlik Taahhütleri

Sınır yapay zekâ geliştiren şirketlerin önemli bir kısmı, son yıllarda, kendi sistemlerinin güvenliğine ilişkin gönüllü politikalar yayımlamıştır. Bu politikalar, farklı adlar altında ("sorumlu ölçekleme politikası", "hazırlıklılık çerçevesi", "sınır güvenlik çerçevesi"), benzer bir mantığa dayanır: Şirket, sistemlerinin belirli tehlikeli yetenek eşiklerine ulaşıp ulaşmadığını düzenli olarak test etmeyi ve bir eşiğe ulaşıldığında, sistemin geliştirilmesine veya kullanıma alınmasına devam etmeden önce, o eşiğe uygun güvenlik önlemlerini almayı taahhüt eder. Bu "eğer-o hâlde" (*if-then*) taahhütleri, şirketlere, risklerin gerçekleşmesini beklemeden, önceden belirlenmiş tetikleyicilere göre hareket etme yükümlülüğü yükler. Bunun yanında, Temmuz 2023'te Amerika Birleşik Devletleri hükümetinin önderliğinde önde gelen yapay zekâ şirketlerinin üstlendiği gönüllü taahhütler ve Mayıs 2024'teki Seul Yapay Zekâ Zirvesi'nde on altı şirketin üstlendiği "Sınır Yapay Zekâ Güvenliği Taahhütleri" gibi çok taraflı gönüllü taahhütler de bulunmaktadır.

Bu gönüllü taahhütler, yapay zekâ güvenliğinin kurumsallaşması bakımından önemli adımlardır ve bazı kamusal düzenlemelere ilham kaynağı olmuştur. Nitekim Avrupa Birliği'nde sistemik riskli genel amaçlı modellere ilişkin uygulama kuralları ve Kaliforniya eyaletinde 2025'te kabul edilen sınır yapay zekâ şeffaflık kanunu, şirketlerin benzer güvenlik çerçevelerini yayımlamasını ve bunlara uymasını belirli ölçülerde zorunlu hâle getirmiştir. Ancak gönüllü taahhütlerin, bekçiler sorunu bakımından temel bir zaafı vardır. Bu zaaf, Birinci Bölüm'de Duguit'nin Jellinek'e yönelttiği eleştiride açıkça ifade edilmişti: Sınırlananın iradesine bağlı olan bir sınırlama, gerçek bir sınırlama değildir. Şirketler, kendi taahhütlerini tek

taraflı olarak değiştirebilir, yorumlayabilir veya geri çekebilir. Taahhütlere uyulup uyulmadığını, çoğu zaman şirketlerin kendisi değerlendirir. Ve Dördüncü Bölüm'de ele alınan yarış dinamiği, rekabet baskısı arttıkça, taahhütlerin esnetilmesi yönünde sürekli bir baskı yaratır. Bu nedenle, gönüllü taahhütler, kamusal ve hukuken bağlayıcı yükümlülüklerin yerine geçemez; ancak bu yükümlülüklerin içeriğinin belirlenmesine katkıda bulunabilir ve onların tamamlayıcısı olabilir.

IV. İhbarcıların Korunması

Şirket içi denetimin önemli ama sıklıkla göz ardı edilen bir unsuru, şirket çalışanlarının, şirket içinde gözlemledikleri güvenlik risklerini veya hukuka aykırılıkları, şirket dışındaki yetkili makamlara veya kamuoyuna bildirebilmesidir. Bu, McCubbins ve Schwartz'ın "yangın alarmı" modelinin şirketler bakımından en önemli aracıdır. Sınır yapay zekâ şirketlerinin çalışanları, şirketlerin sistemlerine ilişkin, dışarıdaki hiçbir denetçinin sahip olamayacağı bilgilere sahiptir. Bu bilgilerin, gerektiğinde, yetkili makamlara ulaşabilmesi, yapay zekâ denetiminin etkinliği bakımından hayati önem taşır.

Haziran 2024'te, sınır yapay zekâ şirketlerinin bir grup mevcut ve eski çalışanı, "İleri Yapay Zekâ Hakkında Uyarma Hakkı" başlıklı bir açık mektup yayımlamıştır. Mektupta, yapay zekâ şirketlerinin, sistemlerinin yetenekleri ve riskleri hakkında kamuya açık olmayan önemli bilgilere sahip olduğu, ancak bu bilgileri hükümetlerle ve sivil toplumla paylaşma yükümlülüklerinin zayıf olduğu; mevcut ihbarcı korumalarının ise genellikle hukuka aykırı faaliyetlere odaklandığı, oysa endişe duyulan risklerin çoğunun henüz düzenlenmemiş alanlarda bulunduğu vurgulanmıştır. Mektup imzacıları, şirketlerden, çalışanların risklere ilişkin endişelerini dile getirmelerini engelleyen sözleşme hükümlerini uygulamamalarını, çalışanların endişelerini yönetim kuruluna, düzenleyicilere ve bağımsız uzmanlara anonim olarak bildirebilecekleri bir süreç oluşturmalarını ve risklere ilişkin bilgileri kamuoyuyla paylaşan çalışanlara karşı misilleme yapmamalarını talep etmiştir.

Bu talepler, kısmen kamusal düzenlemelere yansımıştır. Avrupa Birliği Yapay Zekâ Tüzüğü, Tüzük ihlallerini bildiren kişilerin, Birlik hukukunun ihlallerini bildiren kişilerin korunmasına ilişkin genel ihbarcı direktifi

kapsamında korunacağını öngörmektedir.[333] Kaliforniya'nın 2025 tarihli sınır yapay zekâ kanunu da, sınır modellerin kritik risklerine ilişkin bilgileri yetkili makamlara bildiren çalışanlar için özel korumalar getirmiştir. Türk hukukunda ise, bu çalışmanın yazıldığı tarih itibarıyla, özel sektör çalışanlarını da kapsayan genel ve kapsamlı bir ihbarcı koruma kanunu bulunmamaktadır. Bu eksiklik, Sekizinci Bölüm'de sunulacak kanun önerisinde, yapay zekâ alanına özgü ihbarcı korumaları aracılığıyla giderilmeye çalışılacaktır.

V. Kıdemli Yönetici Sorumluluğu ve "Son İnsan Halkası" İlkesi

A. Birleşik Krallık Kıdemli Yöneticiler Rejimi

Büyük örgütlerde sorumluluğun dağılması sorununa, yani Thompson'ın çok eller sorununa, son yıllarda geliştirilen en ilginç düzenleyici cevaplardan biri, Birleşik Krallık'ın finans sektöründe uygulanan "Kıdemli Yöneticiler ve Sertifikasyon Rejimi"dir (*Senior Managers and Certification Regime*, SM&CR). 2008 küresel finans krizinin ardından, krize yol açan kararlardan hiçbir bireysel yöneticinin sorumlu tutulamaması üzerine geliştirilen bu rejim, 2016'dan itibaren bankalar için, 2019'dan itibaren ise tüm finansal hizmet şirketleri için uygulanmaktadır.

Rejimin temel unsurları şunlardır. *Birincisi*, şirketin belirli kritik işlevlerinden sorumlu "kıdemli yöneticiler", düzenleyici otoritenin onayıyla atanır. *İkincisi*, her kıdemli yöneticinin sorumluluk alanı, düzenleyici otoriteye sunulan bir "sorumluluklar beyanı" ile açıkça tanımlanır; böylece şirketin her önemli faaliyetinin, adı belirli bir kıdemli yöneticinin sorumluluğunda olması güvence altına alınır. *Üçüncüsü*, kıdemli yöneticiler, bir "sorumluluk yükümlülüğü" (*duty of responsibility*) altındadır: Bir kıdemli yöneticinin sorumluluk alanında bir düzenleyici ihlal meydana geldiğinde, yönetici, bu ihlalin önlenmesi için "makul adımları" attığını gösteremezse, kişisel olarak düzenleyici yaptırımlara tabi tutulabilir.[334]

[333] YZT, md. 87; Directive (EU) 2019/1937 of the European Parliament and of the Council of 23 October 2019 on the protection of persons who report breaches of Union law.

[334] Financial Services and Markets Act 2000, s. 66A ve 66B (Financial Services (Banking Reform) Act 2013 ve Bank of England and Financial Services Act 2016 ile yapılan değişikliklerle).

B. Yapay Zekâ Sorumlu Yöneticisi

Bu çalışma, Birleşik Krallık rejiminden esinlenerek, sınır yapay zekâ sistemlerini geliştiren şirketler ve temel hakları etkileyen kararlarda yapay zekâ kullanan kamu kurumları için bir **"yapay zekâ sorumlu yöneticisi"** kurumunun oluşturulmasını önermektedir. Bu kurumun temel unsurları şunlar olmalıdır:

1. Sınır yapay zekâ sistemlerini geliştiren her şirket, her sistem için ve temel hakları etkileyen kararlarda yapay zekâ kullanan her kamu kurumu, her kullanım bağlamı için, adı belirli bir yapay zekâ sorumlu yöneticisi atamalıdır.
2. Sorumlu yöneticinin sorumluluk alanı, yetkili denetim otoritesine sunulan ve kamuya açık bir sorumluluklar beyanı ile açıkça tanımlanmalıdır. Bu beyan, sistemin güvenlik değerlendirmesinden, izlenmesinden ve gerektiğinde durdurulmasından kimin sorumlu olduğunu belirtmelidir.
3. Sorumlu yönetici, sistemin güvenliğine ilişkin önemli bilgilere erişim hakkına ve sistemin kullanımını askıya alma yetkisine sahip olmalıdır. Bu yetki, Montesquieu'nün "engelleme yetisi"nin örgüt içindeki karşılığıdır.
4. Sorumlu yöneticinin sorumluluk alanında ciddi bir ihlal veya zarar meydana geldiğinde, yönetici, bu ihlalin veya zararın önlenmesi için makul adımları attığını gösteremezse, kişisel olarak idari yaptırımlara, ağır durumlarda ise ilgili mevzuat çerçevesinde başka yaptırımlara tabi tutulabilmelidir.

C. Son İnsan Halkası İlkesi

Yapay zekâ sorumlu yöneticisi kurumu, bu çalışmanın sorumluluk analizinin vardığı temel ilkenin kurumsal bir ifadesidir. Bu çalışmada **"son insan halkası ilkesi"** olarak adlandırılan bu ilke şöyle formüle edilebilir:

> *Bir yapay zekâ sisteminin her önemli kullanım bağlamı için, o kullanımın sonuçlarından kişisel olarak hesap verecek, adı belirli, yeterli yetki ve bilgiyle donatılmış ve sistemin kullanımını durdurabilecek en az bir insan bulunmalıdır.*

Bu ilke, Üçüncü Bölüm'de ulaşılan felsefi sonuçların ve bu bölümde yapılan hukuki analizin bir sentezidir. İlke, Weber'in siyasetçinin devredilemez sorumluluğu ilkesini, Darwall'ın hesap verebilirliğin

karşılıklı bir insan ilişkisi olduğu tezini, Santoni de Sio ve van den Hoven'ın anlamlı insan kontrolünün "takip koşulu"nu ve uluslararası toplumun "hesap verebilirlik makinelere devredilemez" yönündeki uzlaşısını somut bir kurumsal yükümlülüğe dönüştürmektedir.

İlkenin dört unsuru, her biri ayrı bir hesap verebilirlik açığını kapatmaya yöneliktir. *Adı belirli* bir insanın bulunması, fail açığını kapatır: Zarar meydana geldiğinde, kimin hesap vereceği önceden bellidir. *Yeterli bilgiyle donatılmış* olması, bilgi ve gerekçe açıklarını kapatır: Sorumlu kişi, sistemin işleyişine ve risklerine ilişkin bilgiye erişebilir ve kullanım kararlarını gerekçelendirebilir. *Kişisel olarak hesap verecek* olması, yaptırım açığını kapatır: Sorumlu kişi, makul adımları atmadığında, kişisel sonuçlarla karşılaşır. *Sistemin kullanımını durdurabilecek* olması ise ilkenin Popper'ci özünü oluşturur: Sorumlu kişi, sistemin hatalı olduğunu fark ettiğinde, onu durdurma yetkisine ve imkânına sahiptir; yani sistem, onun aracılığıyla düzeltilebilir.

Son insan halkası ilkesi, ahlaki çarpışma bölgesi tehlikesine karşı da bir güvence içermelidir. İkinci Bölüm'de görüldüğü üzere, "insan denetimi" kavramı, sorumluluğun, gerçek bir kontrol imkânı bulunmayan bir operatöre yüklenmesinin bir aracı olarak kullanılabilir. Son insan halkası ilkesi, bu tehlikeyi önlemek için, sorumlu kişinin, sorumluluğuyla orantılı bir *yetki* ve *bilgiye* sahip olmasını şart koşar. Sorumluluk, yetki ve bilgiyle birlikte gelmelidir. Yetkisiz ve bilgisiz bir insanın "son halka" olarak gösterilmesi, ilkenin ihlali anlamına gelir ve bu durumda sorumluluk, o insana yetki ve bilgi vermeyen örgüte ve onun üst yöneticilerine yönelmelidir.

VI. Ara Sonuç

Bu bölümde yapılan analiz, çalışmanın dördüncü hipotezini (H4) doğrulamıştır. Yapay zekâ sistemlerinin yol açtığı zararlar bakımından hesap sorma, sistemlerin kendisine değil, onları tasarlayan, eğiten, piyasaya süren, kullanan ve denetleyen insanlara ve kurumlara yönelmelidir. Elektronik kişilik önerisi, sorumluluk boşluğunu kapatmak yerine, sorumluluğu insanlardan uzaklaştırarak "buharlaştırma" riski taşıdığı için reddedilmiştir.

Analiz, ayrıca, mevcut hukuk kurumlarının, yapay zekâ bağlamındaki sorumluluk sorunlarına, beklenenden daha fazla cevap verebildiğini göstermiştir. Türk Borçlar Kanunu'nun organizasyon sorumluluğuna ilişkin

66. maddesinin üçüncü fıkrası ve tehlike sorumluluğuna ilişkin 71. maddesi, kusurun ispatlanamadığı ve zararın çok sayıda aktöre dağıldığı durumlarda bile, zarar görenin tazmin edilmesini sağlayabilecek kusursuz sorumluluk temelleri sunmaktadır. Türk Ceza Kanunu'nun ihmali davranışla işlenen suçlara ilişkin 83. maddesindeki "önceki tehlikeli davranıştan doğan garantörlük" kavramı, sistemleri dünyaya salanların, onların hatalarını düzeltme yükümlülüğünü üstlendiklerini ifade eden bir ceza hukuku temeli sağlamaktadır. İdare hukukunun anonim hizmet kusuru ve risk ilkesi ise "çok eller sorunu"na, yüz yılı aşkın bir süredir verilen bir cevap olarak, idarenin yapay zekâ kullanımından doğan zararlar bakımından güçlü bir sorumluluk rejimi sunmaktadır.

Bununla birlikte, analiz, bu kurumların yapay zekâya uygulanmasında önemli belirsizlikler ve boşluklar bulunduğunu da göstermiştir. Bu belirsizlik ve boşlukları gidermek için, bu bölümde bir dizi öneri geliştirilmiştir: sınır yapay zekâ sistemlerinin tehlike sorumluluğuna tabi faaliyetler olarak açıkça kabul edilmesi; ürün sorumluluğu rejiminin yazılımı ve yapay zekâyı açıkça kapsayacak biçimde güncellenmesi; zorunlu sigorta, sorumluluğun kanalize edilmesi ve kolektif tazmin fonları; güvenlik değerlendirmelerinin yapılmasının ve belgelendirilmesinin bir yükümlülük hâline getirilmesi; "algoritmik hizmet kusuru" kavramı ve bu kavramın beş alt türü; yapay zekâ alanına özgü ihbarcı korumaları; ve "yapay zekâ sorumlu yöneticisi" kurumu ile "son insan halkası" ilkesi. Bu öneriler, bir sonraki bölümde karşılaştırmalı hukukla ilişkilendirildikten sonra, Sekizinci Bölüm'de bütünlüklü bir model ve kanun önerisi içinde sistemleştirilecektir.

YEDİNCİ BÖLÜM: KARŞILAŞTIRMALI HUKUK VE ULUSLARARASI DÜZEN

Önceki iki bölümde, yapay zekânın denetimi ve sorumluluğu sorunu, ağırlıklı olarak Türk hukuku esas alınarak ve karşılaştırmalı hukuktan seçilmiş örneklerle incelenmişti. Bu bölüm, karşılaştırmalı perspektifi sistematik bir biçimde genişletmektedir. Giriş'te belirtildiği üzere, karşılaştırma, Zweigert ve Kötz'ün fonksiyonel yöntemine göre yapılacaktır: Farklı hukuk düzenlerinin kurumları biçimleri bakımından değil, aynı soruna, yani karar vericileri aşma potansiyeline sahip yapay zekâ sistemlerinin denetimi ve bu sistemlerden doğan sonuçlar için hesap sorulması sorununa verdikleri cevaplar bakımından karşılaştırılacaktır.

Bölüm, önce bu alanda en kapsamlı düzenleyici çerçeveyi oluşturan Avrupa Birliği Yapay Zekâ Tüzüğü'nü (§ 34), ardından ilk bağlayıcı uluslararası yapay zekâ antlaşması olan Avrupa Konseyi Çerçeve Sözleşmesi'ni (§ 35) inceleyecektir. Ardından, sırasıyla Amerika Birleşik Devletleri (§ 36), Birleşik Krallık (§ 37) ve Çin Halk Cumhuriyeti (§ 38) ele alınacak; küresel yönetişim girişimleri değerlendirilecek (§ 39) ve son olarak Türkiye'deki durum incelenecektir (§ 40). Bölüm, bu karşılaştırmanın sonuçlarını özetleyen bir değerlendirmeyle sona erecektir (§ 41).

§ 34. AVRUPA BİRLİĞİ: YAPAY ZEKÂ TÜZÜĞÜ

I. Genel Mimari

Avrupa Birliği Yapay Zekâ Tüzüğü, 13 Haziran 2024 tarihinde kabul edilmiş, 12 Temmuz 2024'te Avrupa Birliği Resmî Gazetesi'nde yayımlanmış ve 1 Ağustos 2024'te yürürlüğe girmiştir.[335] Tüzük, yapay zekâya ilişkin dünyanın ilk kapsamlı ve yatay (yani belirli bir sektörle sınırlı olmayan) hukuki düzenlemesi olarak kabul edilmektedir. Tüzük, bir

[335] Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act), OJ L, 2024/1689, 12.7.2024.

“tüzük” olarak, üye devletlerin iç hukukuna aktarılmaya gerek kalmaksızın, doğrudan uygulanır.

Tüzük’ün temel yaklaşımı, “risk temelli”dir. Yapay zekâ sistemleri, kullanım amaçlarına ve bu amaçların temel haklar, sağlık ve güvenlik bakımından yarattığı risklere göre dört kategoride sınıflandırılır:

1. **Kabul edilemez risk:** Tüzük’ün 5. maddesi, belirli yapay zekâ uygulamalarını tamamen yasaklar. Bu yasaklar arasında, kişilerin bilinçaltını hedef alan veya kasıtlı olarak manipülatif ya da aldatıcı teknikler kullanarak davranışlarını önemli ölçüde çarpıtan sistemler; kişilerin yaşından, engelliliğinden veya sosyal ya da ekonomik durumundan kaynaklanan kırılganlıklarını istismar eden sistemler; kişilerin sosyal davranışlarına veya kişisel özelliklerine dayanarak, ilgisiz bağlamlarda veya orantısız biçimde olumsuz muameleye yol açan “sosyal puanlama” sistemleri; bir kişinin suç işleme riskini yalnızca profilleme veya kişilik özelliklerine dayanarak değerlendiren sistemler; internetten veya kamera görüntülerinden hedefsiz olarak yüz görüntüleri toplayarak yüz tanıma veri tabanları oluşturan sistemler; işyerlerinde ve eğitim kurumlarında duygu tanıma sistemleri (tıbbi veya güvenlik amaçları hariç); ve kolluk amaçlarıyla kamuya açık alanlarda, belirli istisnalar dışında, gerçek zamanlı uzaktan biyometrik tanımlama sistemleri yer almaktadır.
2. **Yüksek risk:** Tüzük’ün 6. maddesi ve Ek III’ü, temel haklar, sağlık ve güvenlik bakımından yüksek risk taşıyan yapay zekâ sistemlerini tanımlar. Bu sistemler arasında, belirli ürün güvenliği mevzuatı kapsamındaki ürünlerin güvenlik bileşenleri olan sistemler ile biyometrik tanımlama, kritik altyapı, eğitim, istihdam, temel kamu ve özel hizmetlere erişim, kolluk, göç ve sınır kontrolü, adalet yönetimi ve demokratik süreçler alanlarında kullanılan belirli sistemler yer alır. Yüksek riskli sistemler, Tüzük’ün en ayrıntılı yükümlülüklerine tabidir: risk yönetim sistemi (md. 9), veri yönetişimi (md. 10), teknik belgeler (md. 11), kayıt tutma (md. 12), kullanıcılara şeffaflık (md. 13), insan gözetimi (md. 14) ve doğruluk, sağlamlık ve siber güvenlik (md. 15).
3. **Sınırlı risk (şeffaflık yükümlülükleri):** Tüzük’ün 50. maddesi, belirli yapay zekâ sistemleri için şeffaflık yükümlülükleri öngörür: İnsanlarla doğrudan etkileşime giren sistemlerin, kişilere bir yapay

zekâ sistemiyle etkileşimde olduklarını bildirmesi; yapay olarak üretilen veya değiştirilen görüntü, ses ve video içeriklerinin (“derin sahtelerin”) bu niteliklerinin açıklanması gibi.

4. **Asgari risk:** Diğer tüm yapay zekâ sistemleri, Tüzük’ün özel yükümlülüklerine tabi değildir; ancak gönüllü davranış kurallarına uyulması teşvik edilir.

Bu dört katmanlı yapıya ek olarak, Tüzük, genel amaçlı yapay zekâ modelleri için ayrı bir düzenleme öngörür. Bu düzenleme, Tüzük’ün hazırlık sürecinde, büyük dil modellerinin yaygınlaşmasının ardından eklenmiş ve aşağıda ayrıca ele alınacaktır.

Tüzük’ün uygulanması, kademeli bir takvime bağlanmıştır. Yasaklar ve yapay zekâ okuryazarlığına ilişkin hükümler 2 Şubat 2025’ten, genel amaçlı yapay zekâ modellerine ilişkin hükümler 2 Ağustos 2025’ten, Tüzük’ün genel hükümleri ise 2 Ağustos 2026’dan itibaren uygulanmaya başlamıştır.[336] Ancak yüksek riskli sistemlere ilişkin yükümlülüklerin uygulanma tarihleri, uyumlaştırılmış standartların hazırlanmasındaki gecikmeler ve düzenleyici yükün azaltılmasına yönelik siyasi talepler üzerine, Avrupa Komisyonu’nun Kasım 2025’te sunduğu ve “Dijital Omnibüs” olarak bilinen değişiklik paketi çerçevesinde ertelenmiştir. 2026 yazında kabul edilen değişiklikle, Ek III’te sayılan yüksek riskli sistemlere ilişkin yükümlülüklerin Aralık 2027’den, ürün mevzuatı kapsamındaki ürünlere entegre yüksek riskli sistemlere ilişkin yükümlülüklerin ise Ağustos 2028’den itibaren uygulanması öngörülmüştür.[337] Bu erteleme, Dördüncü Bölüm’de ele alınan yarış dinamiğinin ve rekabet kaygılarının, en kapsamlı düzenleyici çerçeveler üzerinde bile etkili olabildiğini göstermektedir.

II. İnsan Gözetimi: Tüzük’ün 14. Maddesi

Tüzük’ün bu çalışmanın konusu bakımından en önemli hükmü, yüksek riskli yapay zekâ sistemlerinde insan gözetimini düzenleyen 14. maddesidir. Bu madde, Avrupa hukukunda “insan gözetimi” kavramının en ayrıntılı düzenlemesini içermektedir.

Maddenin birinci fıkrasına göre, yüksek riskli yapay zekâ sistemleri, kullanıldıkları süre boyunca gerçek kişiler tarafından etkin bir biçimde

[336] YZT, md. 113.

[337] Bu değişikliğin künyesi ve ayrıntıları, yayına hazırlık aşamasında Avrupa Birliği Resmî Gazetesi’nden doğrulanmalıdır.

gözetlenebilecek şekilde, uygun insan-makine arayüz araçları da dâhil olmak üzere, tasarlanmalı ve geliştirilmelidir. İkinci fıkraya göre, insan gözetimi, sistemin amacına uygun olarak veya makul olarak öngörülebilir kötüye kullanım koşullarında kullanılması sırasında ortaya çıkabilecek sağlık, güvenlik veya temel haklar risklerini önlemeyi veya en aza indirmeyi amaçlar.

Maddenin dördüncü fıkrası, insan gözetimi görevi verilen gerçek kişilerin, duruma uygun ve orantılı olarak, aşağıdaki imkânlara sahip kılınmasını öngörür:

(a) yüksek riskli yapay zekâ sisteminin ilgili kapasitelerini ve sınırlarını doğru bir biçimde anlamak ve işleyişini, anormallikler, işlev bozuklukları ve beklenmedik başarım dâhil olmak üzere, gereği gibi izleyebilmek;

(b) özellikle gerçek kişilerin alacağı kararlar için bilgi veya tavsiye sağlamak amacıyla kullanılan sistemler bakımından, yüksek riskli bir yapay zekâ sisteminin ürettiği çıktıya otomatik olarak güvenme veya aşırı güvenme eğiliminin (“otomasyon yanlılığı”) olası varlığının farkında kalabilmek;

(c) yüksek riskli yapay zekâ sisteminin çıktısını doğru biçimde yorumlayabilmek;

(d) herhangi bir özel durumda, yüksek riskli yapay zekâ sistemini kullanmamaya veya çıktısını göz ardı etmeye, geçersiz kılmaya ya da tersine çevirmeye karar verebilmek;

(e) yüksek riskli yapay zekâ sisteminin işleyişine müdahale edebilmek veya sistemi, güvenli bir durumda durmasını sağlayan bir “durdurma” düğmesi veya benzeri bir usulle durdurabilmek.

Maddenin beşinci fıkrası ise belirli uzaktan biyometrik tanımlama sistemleri için, sistemin tanımlamasına dayanarak herhangi bir eylem veya kararın, gerekli yetkinlik, eğitim ve yetkiye sahip en az iki gerçek kişi tarafından ayrı ayrı doğrulanmadıkça ve teyit edilmedikçe alınamayacağını öngörür.

Tüzük’ün 26. maddesi ise yüksek riskli sistemlerin uygulayıcılarının (kullanıcılarının), insan gözetimi görevini, gerekli yetkinliğe, eğitime ve yetkiye sahip olan ve gerekli desteği alan gerçek kişilere vermesini zorunlu kılar.[338]

[338] YZT, md. 26(2).

Bu düzenleme, bu çalışmanın önceki bölümlerinde geliştirilen pek çok düşüncenin pozitif hukuka yansımasını içermektedir. Dördüncü fıkranın (b) bendi, İkinci Bölüm'de ele alınan otomasyon yanlılığını açıkça tanımlamakta ve gözetimcilerin bu eğilimin farkında olmasını şart koşmaktadır. Bu, otomasyon yanlılığı kavramının bir hukuk metninde açıkça yer aldığı nadir örneklerden biridir. Dördüncü fıkranın (d) ve (e) bentleri, Birinci Bölüm'de Montesquieu'den türetilen "engelleme yetisi"nin, yani sistemin çıktısını geçersiz kılma ve sistemi durdurma yetkisinin, hukuki bir güvence olarak düzenlenmesidir. Beşinci fıkradaki "dört göz ilkesi", Goldman'ın "görüş birliği" kanıt kaynağının kurumsal bir uygulamasıdır. Yirmi altıncı maddenin, gözetimcilerin "gerekli yetkinlik, eğitim ve yetkiye" sahip olmasını şart koşması ise Altıncı Bölüm'de geliştirilen "son insan halkası" ilkesinin, sorumluluğun yetki ve bilgiyle birlikte gelmesi gerektiği yönündeki unsuruyla örtüşür.

Bununla birlikte, 14. madde, bu çalışmanın analizi ışığında, önemli sınırlılıklar da taşımaktadır. *Birinci sınırlılık*, maddenin, insan gözetimini ağırlıklı olarak *bireysel* bir operatörün görevi olarak tasarlamasıdır. İkinci Bölüm'de, Bainbridge'in otomasyonun ironileri ve Elish'in ahlaki çarpışma bölgeleri analizlerinin gösterdiği üzere, bireysel operatörlerin, özellikle karmaşık sistemleri sürekli olarak izleme ve kritik anlarda müdahale etme kapasitesi sınırlıdır. Bireysel insan gözetimine aşırı güvenmek, Green'in uyardığı türden bir "meşruiyet tiyatrosu"na ve sorumluluğun operatörlere kaydırılmasına yol açabilir. *İkinci sınırlılık*, maddenin, kavrayış asimetrisi sorununu yeterince ele almamasıdır. Dördüncü fıkranın (a) ve (c) bentleri, gözetimcilerin sistemin kapasitelerini ve sınırlarını "doğru biçimde anlaması" ve çıktısını "doğru biçimde yorumlaması"nı öngörür. Ancak sistemlerin yetenekleri, gözetimcilerin kavrayışını aştığında, bu koşulların nasıl karşılanacağı belirsizdir. Bu çalışmanın Sekizinci Bölüm'de geliştireceği model, bireysel insan gözetimini, kurumsal, teknik ve toplumsal katmanlarla tamamlayarak bu sınırlılıkları aşmayı amaçlamaktadır.

III. Temel Haklar Etki Değerlendirmesi ve Açıklama Hakkı

Tüzük, bireysel haklar bakımından iki önemli hüküm içermektedir. *Birincisi*, Tüzük'ün 27. maddesi, kamu hukuku tüzel kişilerinin ve kamu hizmeti sunan özel kuruluşların, belirli yüksek riskli yapay zekâ sistemlerini kullanmaya başlamadan önce, bu sistemlerin temel haklar

üzerindeki etkisine ilişkin bir değerlendirme yapmasını zorunlu kılar. Bu değerlendirme, sistemin kullanılacağı süreçleri, kullanım süresini ve sıklığını, sistemden etkilenebilecek kişi ve grupları, bu kişi ve gruplar bakımından ortaya çıkabilecek zarar risklerini, insan gözetimi önlemlerini ve risklerin gerçekleşmesi durumunda alınacak önlemleri içermelidir. Bu hüküm, Beşinci Bölüm'de önerilen "uçtan uca güvenceler"in başlangıç aşamasının bir uygulamasıdır.

İkincisi, Tüzük'ün 86. maddesi, "bireysel karar verme sürecinin açıklanması hakkı"nı düzenler. Bu maddeye göre, uygulayıcı tarafından, Ek III'te sayılan belirli yüksek riskli sistemlerin çıktısına dayanılarak alınan ve kişi üzerinde hukuki sonuçlar doğuran veya onu benzer biçimde önemli ölçüde etkileyen bir karara tabi olan herkes, uygulayıcıdan, yapay zekâ sisteminin karar verme sürecindeki rolüne ve alınan kararın başlıca unsurlarına ilişkin açık ve anlamlı açıklamalar alma hakkına sahiptir. Bu hak, Beşinci Bölüm'de ele alınan açıklama ile gerekçe arasındaki ayrım bakımından ilginç bir konumdadır: Madde, hem sistemin "rolüne" (bir tür açıklama) hem de kararın "başlıca unsurlarına" (bir tür gerekçe) ilişkin bilgi verilmesini öngörmektedir.

IV. Sistemik Riskli Genel Amaçlı Yapay Zekâ Modelleri

Tüzük'ün bu çalışmanın konusu bakımından belki de en önemli yeniliği, "sistemik riskli genel amaçlı yapay zekâ modelleri"ne ilişkin düzenlemedir. Bu düzenleme, Tüzük'ün, belirli kullanım amaçlarına odaklanan risk temelli yaklaşımının, çok çeşitli amaçlarla kullanılabilen sınır modeller karşısındaki yetersizliğine bir cevap olarak geliştirilmiştir.

Tüzük'ün 51. maddesine göre, bir genel amaçlı yapay zekâ modeli, "yüksek etki kapasitelerine" sahipse, sistemik riskli model olarak sınıflandırılır. Maddenin ikinci fıkrası, eğitiminde kullanılan toplam hesaplama miktarı 10^{25} kayan noktalı işlemi (FLOP) aşan modellerin yüksek etki kapasitelerine sahip olduğunu karine olarak kabul eder. Bu hesaplama eşiği, Dördüncü Bölüm'de ele alınan "girdi denetimi" yaklaşımının, yani sistemlerin kendisinden çok, onların geliştirilmesi için gereken hesaplama kaynaklarına dayanan bir düzenleyici ölçütün, pozitif hukuktaki ilk önemli uygulamalarından biridir.

Tüzük'ün 53. maddesi, tüm genel amaçlı model sağlayıcılarına, teknik belgeler hazırlama, modeli kendi sistemlerine entegre eden alt sağlayıcılara bilgi sağlama, telif hakkı politikası oluşturma ve eğitim içeriğinin özetini

kamuya açıklama yükümlülükleri yükler. Tüzük'ün 55. maddesi ise sistemik riskli modellerin sağlayıcılarına ek yükümlülükler getirir: (a) sistemik riskleri tespit etmek ve azaltmak amacıyla, modele karşı düşmanca testler (*adversarial testing*) yapılması ve belgelendirilmesi dâhil olmak üzere, standartlaştırılmış protokollere ve araçlara uygun olarak model değerlendirmesi yapmak; (b) Birlik düzeyindeki olası sistemik riskleri değerlendirmek ve azaltmak; (c) ciddi olaylara ilişkin bilgileri ve olası düzeltici önlemleri takip etmek, belgelendirmek ve gecikmeksizin Yapay Zekâ Ofisi'ne ve ilgili ulusal makamlara bildirmek; ve (d) model ve fiziksel altyapısı için yeterli düzeyde siber güvenlik koruması sağlamak.

Bu yükümlülüklerin uygulanmasını kolaylaştırmak amacıyla, Tüzük'ün 56. maddesi çerçevesinde, Yapay Zekâ Ofisi'nin koordinasyonunda, bağımsız uzmanlar, sektör temsilcileri ve sivil toplumun katılımıyla bir "Genel Amaçlı Yapay Zekâ Uygulama Kuralları" metni hazırlanmış ve Temmuz 2025'te yayımlanmıştır. Bu metin, şeffaflık, telif hakkı ve güvenlik ile emniyet başlıklı üç bölümden oluşmakta; güvenlik ve emniyet bölümü, sistemik riskli model sağlayıcılarının bir güvenlik çerçevesi oluşturmasını, sistemik riskleri değerlendirmesini ve azaltmasını ve ciddi olayları bildirmesini öngörmektedir. Uygulama kurallarına katılım gönüllüdür; ancak katılan sağlayıcılar, Tüzük'ün ilgili yükümlülüklerine uygunluğu bu kurallar aracılığıyla gösterebilir.

Sistemik riskli modellere ilişkin düzenleme, Altıncı Bölüm'de ele alınan şirketlerin gönüllü güvenlik taahhütlerinin, kamusal ve hukuken bağlayıcı bir çerçeveye dönüştürülmesi yönünde önemli bir adımdır. Ancak bu düzenleme de, bu çalışmanın analizi ışığında, önemli sorular doğurmaktadır. Model değerlendirmelerinin ve risk değerlendirmelerinin büyük ölçüde sağlayıcıların kendisi tarafından yapılması, Kelsen'in "kimse kendi davasında yargıç olamaz" ilkesiyle gerilim içindedir. Yapay Zekâ Ofisi'nin, sağlayıcıların değerlendirmelerini bağımsız olarak doğrulama kapasitesi, bu düzenlemenin etkinliğinin belirleyici unsurudur.

V. Kurumsal Yapı ve Yaptırımlar

Tüzük, çok katmanlı bir kurumsal yapı öngörmektedir. Avrupa Birliği düzeyinde, Avrupa Komisyonu bünyesinde kurulan *Yapay Zekâ Ofisi* (md. 64), özellikle genel amaçlı yapay zekâ modellerine ilişkin kuralların uygulanmasını denetler. Üye devletlerin temsilcilerinden oluşan *Avrupa Yapay Zekâ Kurulu* (md. 65), Tüzük'ün tutarlı biçimde uygulanmasını

koordine eder. Paydaşlardan oluşan bir *Danışma Forumu* (md. 67), teknik uzmanlık sağlar. Bağımsız uzmanlardan oluşan bir *Bilimsel Panel* (md. 68) ise Yapay Zekâ Ofisi'ni destekler ve genel amaçlı modellerin Birlik düzeyinde sistemik riskler oluşturabileceğinden şüphelendiğinde, Yapay Zekâ Ofisi'ne "nitelikli uyarılar" (*qualified alerts*) iletebilir.[339] Ulusal düzeyde ise her üye devlet, Tüzük'ün uygulanmasını denetleyecek *ulusal yetkili makamlar*, özellikle *piyasa gözetim otoriteleri* belirler.

Bilimsel Panel'in nitelikli uyarı yetkisi, bu çalışmanın konusu bakımından özel bir ilgiyi hak eder. Bu yetki, bağımsız bilim insanlarına, düzenleyici sürecin içinde, bir "yangın alarmı" çalma imkânı tanımaktadır. Bu, McCubbins ve Schwartz'ın yangın alarmı modelinin, uzmanlık gerektiren bir alanda kurumsallaştırılmasının ilginç bir örneğidir.

Tüzük, ihlaller için ağır para cezaları öngörmektedir. Yasaklanmış uygulamalara ilişkin ihlaller için, 35 milyon avroya veya işletmenin önceki mali yıldaki dünya çapındaki yıllık cirosunun yüzde yedisine (hangisi daha yüksekse) kadar; diğer yükümlülüklerin ihlali için, 15 milyon avroya veya yıllık cironun yüzde üçüne kadar para cezası verilebilir.[340] Genel amaçlı model sağlayıcılarına, Komisyon tarafından, 15 milyon avroya veya yıllık cironun yüzde üçüne kadar para cezası verilebilir.[341]

VI. Değerlendirme

Avrupa Birliği Yapay Zekâ Tüzüğü, bu çalışmanın konusu bakımından, güçlü yanları ve zaafları birlikte barındıran, önemli bir düzenleyici deneyimdir.

Güçlü yanları şunlardır: Tüzük, yapay zekâyı, temel haklar, sağlık ve güvenlik riskleri bakımından kapsamlı bir biçimde düzenleyen ilk yatay düzenlemedir. İnsan gözetimini ayrıntılı bir biçimde düzenlemekte ve otomasyon yanlılığı gibi bilişsel sorunları açıkça tanımaktadır. Sınır modelleri, hesaplama eşiği gibi girdi temelli bir ölçütle düzenleme kapsamına almaktadır. Bağımsız bir bilimsel panel aracılığıyla, uzmanlık temelli bir uyarı mekanizması kurmaktadır. Ve bu düzenlemenin, Birlik pazarının büyüklüğü nedeniyle, Birlik dışındaki aktörleri de etkileyeceği, yani hukuk akademisyeni Anu Bradford'un "Brüksel etkisi" olarak

[339] YZT, md. 90.
[340] YZT, md. 99.
[341] YZT, md. 101.

adlandırdığı olgunun yapay zekâ alanında da gerçekleşeceği beklenmektedir.[342]

Zaafları ise şunlardır: Tüzük'ün temel mimarisi, ürün güvenliği mevzuatının mantığından devşirilmiştir; bu mantık, belirli amaçlar için piyasaya arz edilen ürünler için uygundur, ama çok çeşitli amaçlarla kullanılabilen ve sürekli değişen genel amaçlı sistemler için tam olarak uygun değildir. Yüksek riskli sistemlerin büyük çoğunluğu için uygunluk değerlendirmesi, sağlayıcının kendi iç denetimine bırakılmıştır. Teknik gerekliliklerin ayrıntıları, büyük ölçüde, özel standardizasyon kuruluşlarının hazırlayacağı uyumlaştırılmış standartlara bırakılmıştır; bu durum, standartların içeriğinin demokratik meşruiyeti bakımından sorular doğurmaktadır. Ulusal güvenlik amaçlarıyla kullanılan sistemler, Tüzük'ün kapsamı dışında tutulmuştur.[343] Bireylere tanınan doğrudan haklar, görece sınırlıdır. Ve son olarak, Tüzük'ün uygulama takviminin ertelenmesi, düzenlemenin, rekabet kaygılarına karşı ne kadar kırılgan olduğunu göstermiştir.

Bu çalışmanın analizi bakımından Tüzük'ün en önemli eksikliği ise bekçiler sorununun en üst katmanına, yani düzenleyicilerin kendisinin denetimine ilişkindir. Tüzük, yapay zekâ sistemlerinin ve sağlayıcılarının denetimini ayrıntılı biçimde düzenlemekte; ancak bu denetimi yapacak kurumların, özellikle de Komisyon bünyesindeki Yapay Zekâ Ofisi'nin bağımsızlığına, kaynaklarına ve hesap verebilirliğine ilişkin güvenceler görece sınırlı kalmaktadır. Yapay Zekâ Ofisi, bağımsız bir otorite değil, Komisyon'un bir birimidir; ve Komisyon, aynı zamanda Birlik'in yapay zekâ alanındaki rekabet gücünü artırmaya yönelik politikaların da sorumlusudur. Bu durum, Dördüncü Bölüm'de ele alınan "düzenleyici ele geçirme" riskine karşı yapısal bir zaaf oluşturmaktadır.

§ 35. AVRUPA KONSEYİ ÇERÇEVE SÖZLEŞMESİ

I. Sözleşmenin Kabulü ve Niteliği

Avrupa Konseyi Bakanlar Komitesi, 17 Mayıs 2024'te, "Yapay Zekâ ve İnsan Hakları, Demokrasi ve Hukukun Üstünlüğü Hakkında Çerçeve Sözleşme"yi kabul etmiştir. Sözleşme, 5 Eylül 2024'te Vilnius'ta imzaya

[342] Anu Bradford, *The Brussels Effect: How the European Union Rules the World*, New York, Oxford University Press, 2020.
[343] YZT, md. 2(3).

açılmıştır.[344] Sözleşme, yapay zekâya ilişkin hukuken bağlayıcı ilk uluslararası antlaşmadır. Sözleşme'nin hazırlanmasına, Avrupa Konseyi üyesi devletlerin yanı sıra, Amerika Birleşik Devletleri, Kanada, Japonya, İsrail ve bazı Latin Amerika devletleri gibi üye olmayan devletler ve Avrupa Birliği de katılmıştır. Sözleşme, imzaya açıldığı günden itibaren Avrupa Birliği, Birleşik Krallık ve Amerika Birleşik Devletleri dâhil olmak üzere çok sayıda devlet ve uluslararası örgüt tarafından imzalanmıştır. Türkiye'nin, bu çalışmanın yazıldığı tarih itibarıyla Sözleşme'yi imzaladığına dair bir kayda ulaşılamamıştır.

Sözleşme, adından da anlaşılacağı üzere, bir "çerçeve" sözleşmedir. Bu, Sözleşme'nin, taraf devletlere ayrıntılı ve doğrudan uygulanabilir kurallar yüklemek yerine, genel ilkeler ve yükümlülükler belirlediği ve bu ilkelerin ve yükümlülüklerin iç hukukta nasıl uygulanacağını, taraf devletlerin takdirine bıraktığı anlamına gelir.

II. Kapsam ve Temel Yükümlülükler

Sözleşme, yapay zekâ sistemlerinin yaşam döngüsü içindeki, insan haklarına, demokrasiye ve hukukun üstünlüğüne müdahale etme potansiyeli taşıyan faaliyetlere uygulanır. Sözleşme'nin kapsamı bakımından, kamu sektörü ile özel sektör arasında önemli bir ayrım yapılmıştır. Kamu makamlarının ve onlar adına hareket eden özel aktörlerin faaliyetleri, Sözleşme'nin yükümlülüklerine tabidir. Özel aktörlerin faaliyetleri bakımından ise taraf devletler, ya Sözleşme'nin ilkelerini doğrudan uygulamayı ya da Sözleşme'nin amaçlarına uygun "diğer uygun önlemleri" almayı seçebilir. Bu esneklik, özellikle Amerika Birleşik Devletleri gibi, özel sektörün kapsamlı bir biçimde düzenlenmesine mesafeli olan devletlerin Sözleşme'ye katılımını kolaylaştırmak amacıyla öngörülmüştür. Ulusal güvenlik çıkarlarının korunmasına ilişkin faaliyetler ise Sözleşme'nin kapsamı dışında bırakılmıştır.

Sözleşme, taraf devletlere, yapay zekâ sistemlerinin yaşam döngüsü içindeki faaliyetlerin, insan haklarıyla bağdaşmasını ve demokratik kurumların ve süreçlerin bütünlüğünü, bağımsızlığını ve etkinliğini, kuvvetler ayrılığını, yargı bağımsızlığını ve adalete erişimi zayıflatmak için kullanılmamasını güvence altına alacak önlemleri alma yükümlülüğü

[344] Council of Europe Framework Convention on Artificial Intelligence and Human Rights, Democracy and the Rule of Law, CETS No. 225.

yükler.[345] Sözleşme'nin demokratik süreçlerin bütünlüğüne ve kuvvetler ayrılığına ilişkin bu hükmü, bu çalışmanın Dördüncü Bölüm'de ele aldığı "algoritmik vesayet" ve "kademeli güçsüzleşme" tehlikelerine karşı uluslararası hukuktaki ilk açık güvence olarak değerlendirilebilir.

Sözleşme, ayrıca, yapay zekâ sistemlerinin yaşam döngüsü içindeki faaliyetlere ilişkin bir dizi genel ilke belirler: insan onuru ve bireysel özerklik; şeffaflık ve gözetim; hesap verebilirlik ve sorumluluk; eşitlik ve ayrımcılık yasağı; özel hayatın ve kişisel verilerin korunması; güvenilirlik; ve güvenli yenilik. Sözleşme'nin hesap verebilirlik ve sorumluluğa ilişkin hükmü, taraf devletlerin, yapay zekâ sistemlerinin yaşam döngüsü içindeki faaliyetlerden kaynaklanan olumsuz etkiler için hesap verebilirlik ve sorumluluğu güvence altına alacak önlemleri almasını öngörür.

Sözleşme'nin başvuru yollarına ilişkin hükümleri de önemlidir. Taraf devletler, yapay zekâ sistemlerinin yaşam döngüsü içindeki faaliyetlerden kaynaklanan insan hakları ihlallerine karşı erişilebilir ve etkili başvuru yolları sağlamak; ilgili kişilerin bu başvuru yollarını kullanabilmesi için gerekli bilgilere erişimini kolaylaştırmak; ve bir yapay zekâ sisteminin insan haklarının kullanımını önemli ölçüde etkilediği durumlarda, etkilenen kişiler için etkili usul güvenceleri sağlamakla yükümlüdür. Sözleşme, ayrıca, taraf devletlerin, yapay zekâ sistemleriyle etkileşimde bulunan kişilerin, bir insanla değil, bir yapay zekâ sistemiyle etkileşimde olduklarının bildirilmesini sağlamasını da öngörür. Son olarak Sözleşme, taraf devletlere, risk ve etki yönetimi çerçeveleri oluşturma ve Sözleşme'den doğan yükümlülüklere uyumu denetlemek üzere bir veya daha fazla etkin gözetim mekanizması kurma ya da belirleme yükümlülüğü yükler. Taraf devletler, bu mekanizmaların görevlerini bağımsız ve tarafsız biçimde yerine getirmesini ve yeterli yetki, uzmanlık ve kaynaklara sahip olmasını güvence altına almalıdır.

III. Değerlendirme ve Türkiye Bakımından Önemi

Avrupa Konseyi Çerçeve Sözleşmesi, yapay zekâ yönetişiminin uluslararası hukuka taşınması bakımından tarihî bir adımdır. Sözleşme'nin en önemli katkısı, yapay zekâyı, yalnızca bir ürün güvenliği veya ekonomik rekabet meselesi olarak değil, insan hakları, demokrasi ve hukukun üstünlüğü meselesi olarak tanımlamasıdır. Bu tanım, bu çalışmanın temel

[345] CETS No. 225, md. 4 ve 5.

yaklaşımıyla örtüşmektedir: Yapay zekânın denetimi sorunu, özünde, anayasal bir sorundur.

Sözleşme'nin zaafları ise çerçeve niteliğinden ve hazırlık sürecinde yapılan uzlaşmalardan kaynaklanmaktadır. Özel sektörün kapsama alınmasına ilişkin esneklik, sınır yapay zekâ sistemlerinin büyük çoğunluğunun özel şirketler tarafından geliştirildiği göz önüne alındığında, Sözleşme'nin etkinliğini önemli ölçüde sınırlayabilir. Ulusal güvenlik istisnası, yapay zekânın en hassas kullanımlarından bazılarını kapsam dışında bırakmaktadır. Ve Sözleşme, Avrupa İnsan Hakları Sözleşmesi'nden farklı olarak, bireysel başvuru hakkı tanıyan bir yargısal denetim mekanizması öngörmemektedir; Sözleşme'ye uyumun denetimi, taraflar konferansı aracılığıyla, görece zayıf bir siyasi mekanizmayla yapılmaktadır.

Türkiye bakımından Sözleşme, özel bir önem taşımaktadır. Türkiye, Avrupa Konseyi'nin kurucu üyelerinden biridir ve Avrupa İnsan Hakları Sözleşmesi'ne taraftır. Anayasa'nın 90. maddesinin son fıkrası uyarınca, usulüne göre yürürlüğe konulmuş temel hak ve özgürlüklere ilişkin milletlerarası antlaşmalar ile kanunların aynı konuda farklı hükümler içermesi nedeniyle çıkabilecek uyuşmazlıklarda, milletlerarası antlaşma hükümleri esas alınır. Bu hüküm, Türkiye'nin Çerçeve Sözleşme'ye taraf olması durumunda, Sözleşme'nin insan haklarına ilişkin hükümlerinin, Türk iç hukukunda kanunların üzerinde bir etki doğurabileceği anlamına gelmektedir. Bu çalışma, Türkiye'nin Çerçeve Sözleşme'ye taraf olmasının, Türk hukukunda yapay zekâ yönetişiminin insan hakları temelinde gelişmesi bakımından önemli bir kaldıraç oluşturacağını değerlendirmektedir.

§ 36. AMERİKA BİRLEŞİK DEVLETLERİ

I. Federal Düzeyde Yaklaşım

Amerika Birleşik Devletleri, yapay zekânın düzenlenmesine, Avrupa Birliği'nden belirgin biçimde farklı bir yaklaşımla yaklaşmaktadır. Bu çalışmanın yazıldığı tarih itibarıyla, federal düzeyde yapay zekâyı kapsamlı bir biçimde düzenleyen bir kanun bulunmamaktadır. Yapay zekâ, mevcut sektörel düzenlemeler (tüketicinin korunması, ayrımcılık yasağı, gıda ve ilaç güvenliği, finansal düzenleme gibi) ve bu düzenlemeleri uygulayan

sektörel düzenleyici kurumlar aracılığıyla, dağınık bir biçimde düzenlenmektedir.

Federal yürütme düzeyinde, yapay zekâ politikası, başkanlık kararnameleri aracılığıyla belirlenmekte ve bu nedenle, yönetim değişiklikleriyle birlikte keskin dönüşümler geçirmektedir. Ekim 2023'te çıkarılan ve "Yapay Zekânın Güvenli, Emniyetli ve Güvenilir Geliştirilmesi ve Kullanımı" başlığını taşıyan 14110 sayılı Başkanlık Kararnamesi, federal düzeydeki en kapsamlı düzenleme girişimiydi.[346] Kararname, diğer hükümlerinin yanı sıra, belirli bir hesaplama eşiğini aşan çift kullanımlı temel modelleri geliştiren şirketlerin, federal hükümete, modellerin eğitimi ve güvenlik testlerinin sonuçları hakkında bilgi vermesini, olağanüstü durumlara ilişkin bir kanunun yetkilerine dayanarak zorunlu kılıyordu. Bu hüküm, Dördüncü Bölüm'de ele alınan girdi denetimi yaklaşımının, Amerikan hukukundaki ilk önemli uygulamasıydı.

Ancak Ocak 2025'te göreve başlayan yeni yönetim, 14110 sayılı Kararnameyi yürürlükten kaldırmış ve yerine, yapay zekâ alanında Amerikan liderliğinin önündeki engellerin kaldırılmasını amaçlayan yeni bir kararname çıkarmıştır.[347] Yeni yönetim, Temmuz 2025'te, yapay zekâ alanında küresel rekabet üstünlüğünü öncelikli amaç olarak belirleyen bir "Yapay Zekâ Eylem Planı" yayımlamış; Aralık 2025'te ise eyaletlerin yapay zekâ düzenlemelerine karşı federal düzeyde bir çerçeve oluşturulmasını ve "aşırı külfetli" bulunan eyalet düzenlemelerine hukuki yollardan itiraz edilmesini öngören bir başka kararname çıkarmıştır. Bu dönüşüm, yapay zekâ yönetişiminin, başkanlık kararnamelerine dayandığı ölçüde, ne kadar kırılgan olduğunu göstermektedir. Bu kırılganlık, Beşinci Bölüm'de, temel hakları etkileyen yapay zekâ kullanımının temel çerçevesinin kanunla belirlenmesi gerektiği yönünde ulaşılan sonucu, karşılaştırmalı hukuk açısından da desteklemektedir.

Federal düzeyde, düzenleyici olmayan ama etkili bir araç, Ulusal Standartlar ve Teknoloji Enstitüsü (NIST) tarafından Ocak 2023'te yayımlanan "Yapay Zekâ Risk Yönetimi Çerçevesi"dir.[348] Bu çerçeve, kuruluşların yapay zekâ risklerini yönetmeleri için gönüllü bir rehber

[346] Executive Order 14110, "Safe, Secure, and Trustworthy Development and Use of Artificial Intelligence", 88 Fed. Reg. 75191, 30 Ekim 2023.
[347] Executive Order 14179, "Removing Barriers to American Leadership in Artificial Intelligence", 23 Ocak 2025.
[348] National Institute of Standards and Technology, *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, NIST AI 100-1, Ocak 2023.

sunmakta ve dört temel işlev etrafında örgütlenmektedir: *yönetişim* (risk yönetimi kültürünün ve süreçlerinin oluşturulması), *haritalama* (risklerin bağlamının belirlenmesi), *ölçme* (risklerin değerlendirilmesi ve izlenmesi) ve *yönetme* (risklerin önceliklendirilmesi ve bunlara müdahale edilmesi). NIST bünyesinde 2023'te kurulan Yapay Zekâ Güvenliği Enstitüsü ise 2025'te yeniden yapılandırılarak, adı ve önceliklerinde değişikliğe gidilmiştir.

II. Eyalet Düzeyinde Düzenlemeler

Federal düzeyde kapsamlı bir düzenlemenin yokluğunda, eyaletler, yapay zekâ düzenlemesinde önemli bir rol üstlenmiştir. Bu çalışmanın konusu bakımından en önemli eyalet düzenlemeleri şunlardır.

New York City, 2021'de kabul ettiği ve 2023'te uygulanmaya başlayan bir yerel kanunla, işe alım ve terfi kararlarında kullanılan otomatik karar araçlarının, kullanılmadan önce bağımsız bir "yanlılık denetimine" tabi tutulmasını ve denetim sonuçlarının kamuya açıklanmasını zorunlu kılmıştır.[349] Bu düzenleme, algoritmik denetimin hukuken zorunlu hâle getirildiği ilk örneklerden biridir; ancak uygulamada, denetimin kapsamının dar tutulması ve uyumun düşük kalması nedeniyle eleştirilmiştir.

Colorado eyaleti, 2024'te, yüksek riskli yapay zekâ sistemlerini geliştiren ve kullananlara, algoritmik ayrımcılığı önlemek için makul özen gösterme yükümlülüğü yükleyen kapsamlı bir kanun kabul etmiştir. Bu kanun, Amerika'da Avrupa Birliği Yapay Zekâ Tüzüğü'ne en çok benzeyen düzenleme olarak değerlendirilmiş; ancak yürürlük tarihi birkaç kez ertelenmiş ve kapsamı, sektörün ve federal yönetimin baskıları altında, yeniden tartışmaya açılmıştır.

Kaliforniya eyaleti, sınır yapay zekâ sistemleri bakımından en önemli eyalet düzenlemesine ev sahipliği yapmaktadır. Eyalet meclisinin 2024'te kabul ettiği ve sınır modellerin geliştiricilerine kapsamlı güvenlik yükümlülükleri ve bir "tam kapatma" (*full shutdown*) kapasitesi sağlama yükümlülüğü yükleyen bir kanun tasarısı, Vali tarafından veto edilmiştir. Ancak Eylül 2025'te, daha sınırlı bir kapsamla hazırlanan "Sınır Yapay Zekâda Şeffaflık Kanunu" kabul edilmiş ve 1 Ocak 2026'da yürürlüğe girmiştir.[350] Bu kanun, belirli büyüklükteki sınır model geliştiricilerine, sınır yapay zekâ güvenlik çerçevelerini yayımlama, modelleri piyasaya

[349] New York City Local Law 144 of 2021.
[350] California Senate Bill 53 (2025), Transparency in Frontier Artificial Intelligence Act.

sürerken şeffaflık raporları yayımlama, kritik güvenlik olaylarını eyaletin acil durum yönetimi ofisine bildirme ve sınır modellerin kritik risklerine ilişkin bilgileri bildiren çalışanları misillemeye karşı koruma yükümlülükleri yüklemektedir. Kanun, ayrıca, kamusal bir hesaplama kümesi kurulmasına yönelik bir çerçeve de öngörmektedir.

Kaliforniya'nın veto edilen tasarısı ile kabul edilen kanunu arasındaki fark, bu çalışmanın konusu bakımından öğreticidir. Veto edilen tasarı, devletin sınır modeller üzerinde *doğrudan* bir denetim kurmasını, yani geliştiricilerin belirli güvenlik standartlarına uymasını ve gerektiğinde modelleri kapatabilmesini zorunlu kılmayı amaçlıyordu; bu, Sekizinci Bölüm'de "varlık koşulları denetimi" olarak adlandırılacak olan denetim türüne karşılık gelir. Kabul edilen kanun ise ağırlıklı olarak *şeffaflık* ve *bilgilendirme* yükümlülüklerine dayanmaktadır; bu, Bovens'in hesap verebilirlik modelinin "bilgilendirme" aşamasına karşılık gelir. Bu dönüşüm, siyasi gerçeklikte, doğrudan denetimin, şeffaflık yükümlülüklerine göre çok daha fazla dirençle karşılaştığını göstermektedir.

III. Değerlendirme

Amerikan yaklaşımı, Dördüncü Bölüm'de ele alınan Ostrom'un çok merkezli yönetişim modelinin bazı olumlu yönlerini taşımaktadır: Farklı eyaletler, farklı düzenleyici yaklaşımları deneyebilmekte ve bu deneyimlerden öğrenme imkânı doğmaktadır. Ancak bu yaklaşımın zaafları da belirgindir. Federal düzeyde kapsamlı bir çerçevenin yokluğu, düzenlemenin dağınık ve tutarsız olmasına yol açmaktadır. Federal yürütme politikasının başkanlık kararnamelerine dayanması, yönetim değişiklikleriyle birlikte keskin dönüşümlere neden olmaktadır. Federal ve eyalet düzeyleri arasındaki gerilim, eyalet düzenlemelerinin geleceğini belirsizleştirmektedir. Ve dünyanın en ileri sınır modellerinin büyük bölümünün bu ülkede geliştirildiği göz önüne alındığında, bu ülkedeki düzenleyici boşluklar, küresel ölçekte önemli sonuçlar doğurmaktadır.

§ 37. BİRLEŞİK KRALLIK

Birleşik Krallık, Avrupa Birliği'nden ayrıldıktan sonra, yapay zekâ düzenlemesinde, Birlik'in kapsamlı ve yatay yaklaşımından farklı, "yenilik yanlısı" olarak nitelendirdiği bir yaklaşım benimsemiştir. Mart 2023'te

yayımlanan bir hükümet belgesi, yeni bir yapay zekâ düzenleyicisi kurmak veya kapsamlı bir yapay zekâ kanunu çıkarmak yerine, mevcut sektörel düzenleyicilerin, beş genel ilke çerçevesinde, kendi alanlarındaki yapay zekâ kullanımını düzenlemesini öngörmüştür.[351] Bu beş ilke şunlardır: güvenlik, emniyet ve sağlamlık; uygun şeffaflık ve açıklanabilirlik; adalet; hesap verebilirlik ve yönetişim; ve itiraz edilebilirlik ve telafi.

Birleşik Krallık'ın yapay zekâ yönetişimine en özgün katkısı ise Kasım 2023'te kurulan Yapay Zekâ Güvenliği Enstitüsü'dür. Bu Enstitü, sınır yapay zekâ modellerinin güvenliğini değerlendirmek amacıyla kurulan ilk devlet kurumlarından biridir ve önde gelen yapay zekâ şirketleriyle yapılan anlaşmalar çerçevesinde, modelleri piyasaya sürülmeden önce test etme imkânı elde etmiştir. Enstitü, 2025'te, odağını ulusal güvenlik risklerine kaydırarak "Yapay Zekâ Emniyeti Enstitüsü" (*AI Security Institute*) adını almıştır. Enstitü'nün deneyimi, devletin, sınır modelleri bağımsız olarak değerlendirme kapasitesini, yani İkinci Bölüm'de ele alınan Goldman'ın "üst-uzman değerlendirmesi" kanıt kaynağını kamusal düzeyde geliştirmesinin mümkün olduğunu göstermektedir. Ancak bu değerlendirmeler, büyük ölçüde şirketlerin gönüllü işbirliğine dayanmakta ve hukuken bağlayıcı bir çerçeveye sahip bulunmamaktadır.

Birleşik Krallık'ın kamu sektörüne ilişkin bir diğer önemli girişimi, "Algoritmik Şeffaflık Kayıt Standardı"dır. Bu standart, kamu kurumlarının, karar süreçlerinde kullandıkları algoritmik araçlar hakkında, standart bir biçimde bilgi yayımlamasını öngörmekte ve merkezî hükümet birimleri için zorunlu hâle getirilmiştir. Bu girişim, Beşinci Bölüm'de önerilen algoritmik normların kamuya açıklanması ilkesinin bir uygulaması olarak değerlendirilebilir. Öte yandan, Birleşik Krallık'ta 2025'te yapılan veri koruma reformu, otomatik karar vermeye ilişkin kuralları, Avrupa Birliği Genel Veri Koruma Tüzüğü'nün 22. maddesinin genel yasak yaklaşımından uzaklaşarak, belirli güvencelere bağlı olarak daha geniş bir otomatik karar verme alanına izin verecek biçimde değiştirmiştir.

§ 38. ÇİN HALK CUMHURİYETİ

Çin Halk Cumhuriyeti, yapay zekâ düzenlemesinde, hem hızı hem de kapsamı bakımından dikkat çekici bir yaklaşım benimsemiştir. Çin, kapsamlı ve tek bir yapay zekâ kanunu yerine, belirli yapay zekâ

[351] Department for Science, Innovation and Technology, *A pro-innovation approach to AI regulation*, CP 815, Mart 2023.

uygulamalarını hedefleyen bir dizi idari düzenleme çıkarmıştır. Bu düzenlemelerin başlıcaları şunlardır: Mart 2022'de yürürlüğe giren ve internet bilgi hizmetlerinde algoritmik öneri sistemlerini düzenleyen hükümler; Ocak 2023'te yürürlüğe giren ve "derin sentez" teknolojilerini, yani yapay olarak içerik üreten veya değiştiren teknolojileri düzenleyen hükümler; Ağustos 2023'te yürürlüğe giren ve üretken yapay zekâ hizmetlerini düzenleyen geçici önlemler; ve Eylül 2025'te yürürlüğe giren ve yapay zekâ tarafından üretilen içeriklerin etiketlenmesini düzenleyen önlemler.

Çin düzenlemelerinin bu çalışmanın konusu bakımından en dikkat çekici unsuru, "algoritma kayıt sistemi"dir. Bu sisteme göre, kamuoyunu etkileme veya toplumsal seferberlik kapasitesine sahip algoritmik öneri hizmetleri ve üretken yapay zekâ hizmetleri sağlayan şirketler, algoritmalarını, ülkenin siber uzay düzenleyicisine kaydettirmek ve belirli bilgileri sunmak zorundadır. Bu kayıt sistemi, devletin, yapay zekâ sistemleri üzerinde kapsamlı bir bilgi ve denetim kapasitesi kurmasını sağlamaktadır.

Çin modeli, bekçiler sorunu bakımından son derece öğretici bir örnek sunmaktadır. Bu model, yapay zekâ sistemlerinin *devlet tarafından* güçlü bir biçimde denetlenmesini öngörmektedir; bu bakımdan, yapay zekânın denetimi sorununa, belirli bir anlamda, etkili bir cevap vermektedir. Ancak bu denetim, devletin kendisinin denetlenmesine yönelik güvencelerle tamamlanmamaktadır. Üretken yapay zekâ hizmetlerine ilişkin düzenlemeler, örneğin, bu hizmetlerin "temel sosyalist değerlere" uygun içerik üretmesini öngörmektedir. Bu durumda, yapay zekânın denetimi, yapay zekâyı, devletin siyasi amaçlarına hizmet eden bir araca dönüştürmektedir. Dördüncü Bölüm'de ele alınan Michael Mann'ın kavramlarıyla ifade edilirse, Çin modeli, devletin yapay zekâ üzerindeki altyapısal iktidarını güçlendirmekte; ancak bu iktidarın despotik kullanımını sınırlayacak güvenceler, demokratik anayasal düzenlerdeki gibi bağımsız yargı denetimi, serbest basın ve rekabetçi seçimler aracılığıyla sağlanmamaktadır.

Çin modelinden çıkarılacak ders açıktır: *Denetim, hesap verebilirlik ile aynı şey değildir*. Yapay zekânın güçlü bir biçimde denetlenmesi, eğer denetleyen kendisi hesap verebilir değilse, Juvenalis'in sorusunu çözmez; yalnızca yapay zekânın gücünü, denetlenmeyen bir bekçinin eline teslim

eder. Bu çalışmanın savunduğu model, yapay zekânın denetimini, denetleyenlerin de denetlendiği dairesel bir yapı içinde tasarlamaktadır.

Çin, ulusal düzenlemelerinin yanında, uluslararası yapay zekâ yönetişiminde de aktif bir rol üstlenmeye çalışmaktadır. Ekim 2023'te ilan edilen "Küresel Yapay Zekâ Yönetişimi Girişimi" ve Temmuz 2025'te açıklanan ve bir dünya yapay zekâ işbirliği örgütü kurulmasını öneren eylem planı, bu çabanın ifadeleridir.

§ 39. KÜRESEL YÖNETİŞİM GİRİŞİMLERİ

I. Yumuşak Hukuk Belgeleri

Yapay zekâ yönetişimine ilişkin uluslararası çabaların büyük kısmı, bağlayıcı olmayan "yumuşak hukuk" belgeleri biçimini almıştır. Bu belgelerin başlıcaları şunlardır.

OECD Yapay Zekâ İlkeleri, Mayıs 2019'da OECD Konseyi tarafından bir tavsiye kararı olarak kabul edilmiş ve 2024'te güncellenmiştir. Bu ilkeler, yapay zekâ yönetişimine ilişkin ilk hükümetlerarası standart olma niteliği taşımakta ve kapsayıcı büyüme, insan hakları ve demokratik değerlere saygı, şeffaflık ve açıklanabilirlik, sağlamlık ve güvenlik ile hesap verebilirlik ilkelerini içermektedir. Bu ilkeler, aynı yıl G20 tarafından da benimsenmiştir. Türkiye, OECD üyesi olarak bu ilkeleri benimsemiştir.

UNESCO Yapay Zekâ Etiği Tavsiyesi, Kasım 2021'de UNESCO Genel Konferansı tarafından, örgütün tüm üye devletlerinin katılımıyla kabul edilmiştir.[352] Tavsiye, yapay zekâ etiğine ilişkin en kapsamlı küresel çerçevelerden biridir ve insan gözetimi ile belirlenimine ilişkin şu önemli ilkeyi içermektedir: Yapay zekâ sistemleri, hiçbir zaman nihai insan sorumluluğunun ve hesap verebilirliğinin yerini alamaz.

G7 Hiroşima Yapay Zekâ Süreci, Ekim 2023'te, ileri yapay zekâ sistemleri geliştiren kuruluşlar için uluslararası yol gösterici ilkeler ve gönüllü bir davranış kuralları belgesi kabul etmiştir.

II. Yapay Zekâ Güvenliği Zirveleri

Sınır yapay zekâ sistemlerinin risklerine odaklanan uluslararası diplomasinin en önemli mecrası, 2023'ten itibaren düzenlenen yapay zekâ

[352] UNESCO, *Recommendation on the Ethics of Artificial Intelligence*, Paris, 23 Kasım 2021.

zirveleri olmuştur. Kasım 2023'te Birleşik Krallık'ta düzenlenen ilk zirvede, aralarında Türkiye'nin de bulunduğu yirmi sekiz devlet ve Avrupa Birliği, "Bletchley Bildirgesi"ni kabul etmiştir. Bildirge, sınır yapay zekâ sistemlerinin, kasıtlı kötüye kullanımdan veya insan niyetiyle uyumla ilgili istenmeyen kontrol sorunlarından kaynaklanabilecek ciddi, hatta felaket boyutunda zararlara yol açma potansiyeline sahip olduğunu kabul etmiş ve bu risklerin uluslararası işbirliğiyle ele alınması gerektiğini vurgulamıştır.[353] Bildirge'nin, sınır yapay zekânın "kontrol sorunlarına" açıkça atıfta bulunması, bu çalışmanın konusu olan sorunun, uluslararası düzeyde devletler tarafından resmî olarak kabul edildiğini göstermesi bakımından önemlidir.

Mayıs 2024'te Kore'de düzenlenen ikinci zirvede, on altı yapay zekâ şirketi, Altıncı Bölüm'de değinilen "Sınır Yapay Zekâ Güvenliği Taahhütleri"ni üstlenmiş ve çeşitli ülkelerin yapay zekâ güvenliği enstitüleri arasında bir uluslararası ağ kurulmuştur. Şubat 2025'te Fransa'da düzenlenen üçüncü zirvede ise zirvenin adı "Yapay Zekâ Eylem Zirvesi" olarak değiştirilmiş ve gündem, güvenlikten çok, yapay zekânın fırsatlarına ve kapsayıcılığına kaydırılmıştır. Bu zirvenin sonuç bildirgesi, bazı büyük devletler tarafından imzalanmamıştır. Zirvelerin gündemindeki bu kayma, Dördüncü Bölüm'de ele alınan yarış dinamiğinin uluslararası diplomasi üzerindeki etkisinin bir yansıması olarak yorumlanabilir.

Zirveler sürecinin önemli bir ürünü, otuzu aşkın ülkenin ve uluslararası örgütün desteğiyle, Yoshua Bengio başkanlığında bağımsız uzmanlar tarafından hazırlanan ve ilk kapsamlı sürümü Ocak 2025'te yayımlanan *Uluslararası Yapay Zekâ Güvenliği Raporu*dur.[354] Bu rapor, Hükümetlerarası İklim Değişikliği Paneli'nin iklim değişikliğine ilişkin raporlarına benzer biçimde, genel amaçlı yapay zekânın yetenekleri ve risklerine ilişkin bilimsel kanıtların bağımsız bir sentezini sunmayı amaçlamaktadır. Bu girişim, Dördüncü Bölüm'de ele alınan uluslararası kurum modellerinden birincisinin, yani uluslararası bilimsel uzlaşı oluşturan bir "komisyon" modelinin, kısmi bir uygulamasıdır.

III. Birleşmiş Milletler

Birleşmiş Milletler Genel Kurulu, Mart 2024'te, sürdürülebilir kalkınma için güvenli, emniyetli ve güvenilir yapay zekâ sistemlerinin

[353] *The Bletchley Declaration by Countries Attending the AI Safety Summit*, 1-2 Kasım 2023.
[354] Bengio vd., *International AI Safety Report*.

fırsatlarından yararlanılmasına ilişkin bir kararı oybirliğiyle kabul etmiştir.[355] Birleşmiş Milletler Genel Sekreteri tarafından kurulan Yapay Zekâ Üst Düzey Danışma Kurulu, Eylül 2024'te yayımladığı "İnsanlık İçin Yapay Zekâyı Yönetmek" başlıklı nihai raporunda, yapay zekâ yönetişiminde ciddi bir küresel açık bulunduğunu tespit etmiş ve bağımsız bir uluslararası bilimsel panel kurulması ile yapay zekâ yönetişimine ilişkin düzenli bir hükümetlerarası diyalog başlatılması gibi öneriler geliştirmiştir.[356] Bu öneriler, Eylül 2024'te kabul edilen "Küresel Dijital Mutabakat"a yansımış ve 2025'te Genel Kurul kararıyla, Yapay Zekâ Bağımsız Uluslararası Bilimsel Paneli ile Yapay Zekâ Yönetişimine İlişkin Küresel Diyalog kurulmuştur.

IV. Değerlendirme: Bir Rejim Kompleksi

Uluslararası yapay zekâ yönetişimi, uluslararası ilişkiler literatüründe "rejim kompleksi" olarak adlandırılan bir yapı sergilemektedir: Tek bir merkezî kurum veya antlaşma yerine, birbiriyle kısmen örtüşen, kısmen çatışan ve hiyerarşik bir ilişki içinde bulunmayan çok sayıda kurum, belge ve süreç.[357] Bu yapının olumlu yönleri, Ostrom'un çok merkezli yönetişim modelinin olumlu yönleriyle örtüşür: Farklı forumlar, farklı yaklaşımları deneyebilir ve birbirinin eksikliklerini tamamlayabilir. Ancak bu yapının olumsuz yönleri de belirgindir: Belgelerin büyük çoğunluğu bağlayıcı değildir; uygulanmalarını denetleyecek etkili mekanizmalar bulunmamaktadır; ve en önemli aktörler, yani en ileri sistemleri geliştiren devletler ve şirketler, bu yapının içinde, kendi çıkarlarına uymayan yükümlülüklerden kaçınma esnekliğine sahiptir.

Bekçiler sorunu bakımından, uluslararası yapay zekâ yönetişiminin en temel eksikliği, *varlık koşulları denetimi*nin, yani sınır yapay zekâ sistemlerinin geliştirilmesini ve kullanılmasını gerektiğinde durdurabilecek veya sınırlayabilecek bir uluslararası mekanizmanın tamamen yokluğudur. Mevcut uluslararası girişimler, ağırlıklı olarak bilgi üretimi (bilimsel paneller), ilke belirleme (yumuşak hukuk belgeleri) ve gönüllü taahhütler üzerine kuruludur. Bu araçlar, Bovens'in hesap verebilirlik modelinin "bilgilendirme" ve kısmen "tartışma" aşamalarını karşılayabilir; ancak

[355] UN General Assembly, A/RES/78/265, "Seizing the opportunities of safe, secure and trustworthy artificial intelligence systems for sustainable development", 21 Mart 2024.
[356] United Nations High-level Advisory Body on Artificial Intelligence, *Governing AI for Humanity: Final Report*, New York, Eylül 2024.
[357] Kal Raustiala / David G. Victor, "The Regime Complex for Plant Genetic Resources", *International Organization*, C. 58, S. 2, 2004.

“sonuç” aşaması, yani yaptırım ve müdahale, uluslararası düzeyde neredeyse tamamen eksiktir.

§ 40. TÜRKİYE

I. Mevcut Normatif Çerçeve

Türkiye’de, bu çalışmanın yazıldığı tarih itibarıyla, yapay zekâyı özel olarak ve kapsamlı bir biçimde düzenleyen bir kanun bulunmamaktadır. Bununla birlikte, Beşinci ve Altıncı Bölümlerde ayrıntılı olarak gösterildiği üzere, Türk hukukunun mevcut kurumları, yapay zekânın denetimi ve sorumluluğu bakımından önemli bir normatif çerçeve sunmaktadır. Bu çerçevenin başlıca unsurları şunlardır:

Anayasal ilkeler: Egemenliğin kullanılmasına ilişkin 6. madde, yasama yetkisinin devredilmezliğine ilişkin 7. madde, kanun önünde eşitliğe ilişkin 10. madde, temel hakların sınırlanmasına ilişkin 13. madde, kişisel verilerin korunmasına ilişkin 20. maddenin üçüncü fıkrası, hak arama özgürlüğüne ilişkin 36. madde, temel hak ve özgürlüklerin korunmasına ilişkin 40. madde, idarenin yargısal denetimine ve sorumluluğuna ilişkin 125. madde, asli ve sürekli kamu görevlerine ilişkin 128. madde, kamu görevlilerinin sorumluluğuna ilişkin 129. madde ve yargı bağımsızlığına ilişkin 138. madde.

Kişisel verilerin korunması: 6698 sayılı Kişisel Verilerin Korunması Kanunu, özellikle otomatik karar vermeye itiraz hakkını düzenleyen 11. maddesinin birinci fıkrasının (g) bendi; ve Kişisel Verileri Koruma Kurumu’nun 2021 tarihli yapay zekâ tavsiyeleri.

Ayrımcılık yasağı: 6701 sayılı Türkiye İnsan Hakları ve Eşitlik Kurumu Kanunu, özellikle dolaylı ayrımcılık yasağı ve ispat yüküne ilişkin hükümleri.

Sorumluluk hukuku: 6098 sayılı Türk Borçlar Kanunu’nun haksız fiil, organizasyon sorumluluğu ve tehlike sorumluluğu hükümleri; 7223 sayılı Ürün Güvenliği ve Teknik Düzenlemeler Kanunu; 5237 sayılı Türk Ceza Kanunu’nun kusur, dolaylı faillik ve ihmali davranışa ilişkin hükümleri ile bilişim alanındaki suçlara ilişkin hükümleri.

Sektörel düzenlemeler: Bankacılık, sermaye piyasası, elektronik haberleşme ve sağlık gibi alanlarda, ilgili düzenleyici kurumların, kendi

alanlarındaki yapay zekâ kullanımına ilişkin düzenleme ve denetim yetkileri.

II. Politika Belgeleri

Türkiye'nin yapay zekâ politikası, ağırlıklı olarak strateji belgeleri aracılığıyla belirlenmektedir. Bu belgelerin en önemlisi, Cumhurbaşkanlığı Dijital Dönüşüm Ofisi ile Sanayi ve Teknoloji Bakanlığı tarafından Ağustos 2021'de yayımlanan *Ulusal Yapay Zekâ Stratejisi 2021-2025*'tir. Strateji, yapay zekâ alanında uzman yetiştirilmesi, araştırma ve girişimciliğin desteklenmesi, kaliteli veri ve teknik altyapıya erişimin sağlanması, sosyoekonomik uyumu hızlandıracak düzenlemelerin yapılması, uluslararası işbirliklerinin güçlendirilmesi ve yapısal ve işgücü dönüşümünün hızlandırılması gibi stratejik öncelikler belirlemiştir. Strateji, ayrıca, güvenilir ve sorumlu yapay zekâ ilkelerine de atıfta bulunmaktadır. Stratejinin uygulanmasına yönelik olarak, sonraki yıllarda güncellenmiş eylem planları da yayımlanmıştır. Kalkınma planları da yapay zekâya ilişkin hedefler içermektedir.

Türkiye, uluslararası düzeyde, OECD Yapay Zekâ İlkeleri'ni benimsemiş, UNESCO Yapay Zekâ Etiği Tavsiyesi'nin kabulüne katılmış ve Kasım 2023'te Bletchley Bildirgesi'ni imzalamıştır.

III. Yasal Düzenleme Girişimleri

Türkiye Büyük Millet Meclisi'nde, son yıllarda, yapay zekâya ilişkin çeşitli kanun teklifleri sunulmuştur. Haziran 2024'te sunulan ve kısa ve genel nitelikte bir dizi maddeden oluşan bir kanun teklifi, Avrupa Birliği Yapay Zekâ Tüzüğü'nden esinlenen risk temelli bir yaklaşımı, Türk hukukuna aktarmayı amaçlamıştır. Sonraki dönemde sunulan başka teklifler ise yapay zekâ ile üretilen sahte içeriklere ("derin sahtelere") ilişkin yükümlülükler ve yaptırımlar ile ilgili kanunlarda değişiklikler öngörmüştür. Bunların yanında, Beşinci Bölüm'de değinildiği üzere, Türkiye Büyük Millet Meclisi, yapay zekânın kazanımları ve riskleri ile bu alandaki hukuki altyapının oluşturulmasına ilişkin bir Meclis araştırması komisyonu kurmuştur. Bu çalışmanın yazıldığı tarih itibarıyla, söz konusu tekliflerin hiçbiri kapsamlı bir yapay zekâ kanununa dönüşmüş değildir.[358]

[358] Kanun tekliflerinin ve Meclis araştırması komisyonu raporunun güncel durumu, yayına hazırlık aşamasında Türkiye Büyük Millet Meclisi'nin resmî kayıtlarından doğrulanmalıdır.

IV. Değerlendirme ve Eksiklikler

Bu çalışmanın önceki bölümlerinde yapılan analiz ışığında, Türk hukukunun yapay zekânın denetimi ve sorumluluğu bakımından mevcut durumu şöyle değerlendirilebilir.

Güçlü yanlar: Türk anayasa düzeni, Beşinci Bölüm'de gösterildiği üzere, "insan nihai karar ilkesi"nin anayasal temelini oluşturan güçlü hükümler içermektedir. Türk idare hukukunun hizmet kusuru ve kusursuz sorumluluk doktrinleri, Türk Borçlar Kanunu'nun organizasyon sorumluluğu ve tehlike sorumluluğu hükümleri ve Türk Ceza Kanunu'nun garantörlük hükmü, yapay zekâ bağlamındaki sorumluluk boşluğunu kapatmak için kullanılabilecek önemli araçlardır. Kişisel Verileri Koruma Kurumu, Türkiye İnsan Hakları ve Eşitlik Kurumu, Kamu Denetçiliği Kurumu ve Sayıştay gibi mevcut kurumlar, yapay zekâ denetimi için bir kurumsal altyapı sunmaktadır.

Eksiklikler: Bununla birlikte, Türk hukukunun mevcut durumunda önemli eksiklikler bulunmaktadır. Bu eksiklikler şöyle sıralanabilir:

1. **Kapsamlı bir yapay zekâ kanununun yokluğu:** Yapay zekânın kamusal kararlarda kullanımının temel çerçevesi, kanunla belirlenmiş değildir. Bu durum, Beşinci Bölüm'de gösterildiği üzere, Anayasa'nın 13. maddesi ve 104. maddesinin on yedinci fıkrası bakımından sorun yaratmaktadır.
2. **Yetkili bir denetim otoritesinin yokluğu:** Yapay zekâ sistemlerini bütünlüklü bir biçimde değerlendirecek, mevcut kurumlar arasında koordinasyonu sağlayacak ve yapay zekâya özgü teknik uzmanlığı biriktirecek bir merkez bulunmamaktadır.
3. **Kişisel veri korumasının otomatik kararlar bakımından yetersizliği:** 6698 sayılı Kanun, otomatik kararlara karşı yalnızca sonradan itiraz hakkı tanımakta; Avrupa standardındaki genel yasak ve açıklama hakkını öngörmemektedir.
4. **Genel bir idari usul kanununun yokluğu:** Algoritmik idari işlemlere ilişkin usul güvencelerinin eklenebileceği genel bir çerçeve bulunmamaktadır.
5. **Kapsamlı bir ihbarcı koruma kanununun yokluğu:** Yapay zekâ şirketlerinin ve kamu kurumlarının çalışanlarının, gözlemledikleri riskleri bildirmelerini güvence altına alan genel bir düzenleme bulunmamaktadır.

6. **Parlamentonun teknik denetim kapasitesinin sınırlılığı:** Türkiye Büyük Millet Meclisi'nin, yapay zekâ gibi teknik konularda, yürütmeden ve özel sektörden bağımsız bir uzmanlık kapasitesi bulunmamaktadır.
7. **Uluslararası bağlayıcı çerçevelere katılımın sınırlılığı:** Türkiye, Avrupa Konseyi Çerçeve Sözleşmesi'ni, bu çalışmanın yazıldığı tarih itibarıyla imzalamamıştır.

Bu eksikliklerin yanında, Türkiye'nin özel konumundan kaynaklanan bir husus da vurgulanmalıdır. Türkiye, Avrupa Birliği ile gümrük birliği içinde bulunan ve Birlik'e aday bir ülkedir. Bu durum, Avrupa Birliği Yapay Zekâ Tüzüğü'nün, "Brüksel etkisi" aracılığıyla, Türk ekonomisi ve hukuku üzerinde fiilî bir etki doğurmasını kaçınılmaz kılmaktadır: Birlik pazarına ürün ve hizmet sunan Türk şirketleri, Tüzük'e uymak zorunda kalacaktır. Bu durum, Türk hukukunun Tüzük'le uyumlaştırılması yönünde güçlü bir teşvik oluşturmaktadır. Ancak bu uyumlaştırmanın, yalnızca Tüzük'ün ürün güvenliği boyutunu değil, temel haklar, kurumsal bağımsızlık ve hesap verebilirlik boyutlarını da kapsaması gerekir. Tüzük'ün yalnızca teknik ve piyasa düzenlemesine ilişkin hükümlerinin aktarılması, ama bu hükümlerin dayandığı kurumsal ve anayasal güvencelerin, yani bağımsız denetim otoritelerinin, güçlü yargısal denetimin ve etkili bireysel başvuru yollarının ihmal edilmesi, yapay zekâ yönetişimini, bu çalışmanın savunduğu hesap verebilirlik ilkelerinden yoksun bir teknik düzenlemeye indirgeyebilir.

Son olarak, 2017 Anayasa değişikliğiyle benimsenen hükümet sistemi bakımından bir husus vurgulanmalıdır. Bu sistemde yürütme yetkisi, Cumhurbaşkanında toplanmıştır. Yapay zekânın, Dördüncü Bölüm'de gösterildiği üzere, devletin altyapısal iktidarını önemli ölçüde artırma potansiyeli göz önüne alındığında, kamu yönetiminde yapay zekâ kullanımının temel çerçevesinin, Cumhurbaşkanlığı kararnameleri veya idari düzenlemeler yerine, yasama organı tarafından kanunla belirlenmesi; bu kullanımın, yürütmeden bağımsız kurumlar tarafından denetlenmesi ve yargısal denetime açık tutulması, kuvvetler ayrılığı ilkesinin yapay zekâ çağında korunması bakımından özel bir önem taşımaktadır. Bu husus, belirli bir hükümet sistemine yönelik bir eleştiri değil, Montesquieu'den bu yana anayasacılığın temel ilkesinin, yani iktidarın iktidarla durdurulması ilkesinin, her hükümet sisteminde geçerli olan bir gereğidir.

§ 41. KARŞILAŞTIRMALI DEĞERLENDİRME

Bu bölümde incelenen hukuk düzenlerinin, yapay zekânın denetimi ve sorumluluğu sorununa verdikleri cevaplar, aşağıdaki iki tabloda özetlenmektedir.

Tablo 1a. Avrupa Birliği, Avrupa Konseyi ve Amerika Birleşik Devletleri

Ölçüt	Avrupa Birliği	Avrupa Konseyi	ABD
Hukuki temel	Doğrudan uygulanan tüzük	Çerçeve antlaşma	Sektörel kurallar, kararnameler, eyalet kanunları
Temel yaklaşım	Risk temelli, yatay	İnsan hakları ve demokrasi temelli	Piyasa ve rekabet öncelikli
İnsan gözetimi	Ayrıntılı (md. 14)	Genel ilke	Sınırlı, dağınık
Sınır modeller	Hesaplama eşikli yükümlülükler	Özel hüküm yok	Eyalet düzeyinde şeffaflık (Kaliforniya)
Yetkili otorite	Yapay Zekâ Ofisi ve ulusal makamlar	Ulusal gözetim mekanizmaları	Sektörel kurumlar
Bireysel haklar	Açıklama hakkı, şikâyet hakkı	Başvuru yolları, usul güvenceleri	Dağınık
Devletin kendisinin denetimi	Kısmi; ulusal güvenlik hariç	Kısmi; ulusal güvenlik hariç	Yargı ve eyaletler aracılığıyla

Tablo 1b. Birleşik Krallık, Çin ve Türkiye

Ölçüt	Birleşik Krallık	Çin	Türkiye
Hukuki temel	İlkeler, sektörel düzenleyiciler	İdari düzenlemeler	Genel kurallar; özel kanun yok
Temel yaklaşım	Yenilik yanlısı, ilke temelli	Devlet denetimi öncelikli	Strateji belgeleri
İnsan gözetimi	İlke düzeyinde	Devlet gözetimi	Anayasal ilkeler; özel düzenleme yok
Sınır modeller	Gönüllü test (Enstitü)	Kayıt ve güvenlik değerlendirmesi	Özel düzenleme yok
Yetkili otorite	Sektörel düzenleyiciler, Enstitü	Siber uzay düzenleyicisi	Dağınık mevcut kurumlar
Bireysel haklar	Veri koruma çerçevesinde	Sınırlı	KVKK md. 11 itiraz hakkı
Devletin kendisinin denetimi	Yargı ve parlamento	Zayıf	Anayasal güvenceler; özel düzenleme yok

Bu karşılaştırma, birkaç önemli sonuca işaret etmektedir.

Birincisi, incelenen hukuk düzenlerinin hiçbiri, karar vericileri aşma potansiyeline sahip yapay zekânın denetimi sorununa bütünlüklü bir cevap vermemektedir. Her düzen, sorunun belirli boyutlarına odaklanmakta,

diğerlerini ihmal etmektedir. Avrupa Birliği, ayrıntılı ürün düzenlemesine ve insan gözetimine odaklanmakta, ama düzenleyicilerin kendisinin denetimini ve ulusal güvenlik kullanımlarını ihmal etmektedir. Amerika Birleşik Devletleri, yenilik ve rekabete öncelik vermekte, ama sistematik bir denetim çerçevesi kurmaktan kaçınmaktadır. Çin, devletin yapay zekâ üzerindeki denetimini güçlendirmekte, ama devletin kendisinin hesap verebilirliğini ihmal etmektedir.

İkincisi, sınır yapay zekâ sistemlerinin *varlık koşulları denetimi*, yani bu sistemlerin geliştirilmesini ve kullanılmasını gerektiğinde durdurabilecek veya sınırlayabilecek mekanizmalar, incelenen hukuk düzenlerinin hiçbirinde bütünlüklü bir biçimde düzenlenmemiştir. Avrupa Birliği'nin hesaplama eşiğine dayanan düzenlemesi ve Kaliforniya'nın veto edilen tasarısı, bu yöndeki en önemli girişimlerdir; ancak bunlar da ya bilgilendirme ve risk değerlendirme yükümlülükleriyle sınırlı kalmış ya da siyasi dirençle karşılaşmıştır.

Üçüncüsü, bekçiler sorununun en üst katmanı, yani yapay zekâyı denetleyen kurumların kendisinin denetimi, incelenen düzenlerin hepsinde zayıf kalmaktadır. Bu, belki de karşılaştırmanın en önemli bulgusudur: Yapay zekâ düzenlemesinin mevcut biçimleri, yapay zekâyı denetlemeye odaklanmakta, ama bu denetimi yapanları denetlemeyi büyük ölçüde ihmal etmektedir. Juvenalis'in sorusu, bu düzenlemelerde, cevapsız kalmaktadır.

Bu sonuçlar, bir sonraki ve son bölümde geliştirilecek olan modelin temel amacını belirlemektedir: Yapay zekânın denetimini, denetleyenlerin de denetlendiği, varlık koşullarının denetimini içeren ve sorunun tüm boyutlarını bütünlüklü bir biçimde ele alan bir mimari içinde tasarlamak.

SEKİZİNCİ BÖLÜM: ÇOK KATMANLI DAİRESEL DENETİM MODELİ

Önceki yedi bölüm, karar vericileri aşma potansiyeline sahip yapay zekânın denetimi ve hesap verebilirliği sorununu, tarihsel, olgusal, felsefi, siyasi, hukuki ve karşılaştırmalı perspektiflerden incelemiştir. Bu inceleme, bir dizi kavram, ilke ve öneri ortaya koymuştur. Bu son bölümün amacı, bu dağınık bulguları, bütünlüklü ve tutarlı bir model içinde sistemleştirmek ve bu modeli, Türk hukuku için somut bir kanun önerisine dönüştürmektir.

Bu çalışmada **"çok katmanlı dairesel denetim modeli"** olarak adlandırılan bu model, Giriş'te formüle edilen beşinci hipotezin (H5) somut bir ifadesidir: Juvenalis'in sonsuz geriye gidiş sorunu, doğrusal ve hiyerarşik bir denetim zinciriyle, yani "en üstteki bekçi" aranarak aşılamaz; bu sorun, çoğulcu, karşılıklı ve dairesel bir denetim mimarisiyle, her aşamada kararların geri alınabilirliğini ve sistemlerin durdurulabilirliğini güvence altına alan bir yapıyla aşılabilir.

Bölüm, önce modelin temel ilkelerini (§ 42) ve analitik çerçevesini oluşturan "denetimin dört nesnesi" kuramını (§ 43) ortaya koyacak; ardından modelin beş katmanını (§ 44) ve hesap sorma rejimini (§ 45) açıklayacaktır. Bölümün merkezinde, Türk hukuku için gerekçeli bir kanun önerisi taslağı yer alacaktır (§ 46). Bölüm, modele yöneltilebilecek muhtemel itirazların cevaplandırılmasıyla (§ 47) ve Juvenalis'in sorusuna geri dönülerek (§ 48) sona erecektir.

§ 42. TEMEL İLKELER

Çok katmanlı dairesel denetim modeli, önceki bölümlerde geliştirilen on temel ilkeye dayanmaktadır. Bu ilkeler, modelin tüm katmanlarında ve kanun önerisinin tüm hükümlerinde yol gösterici niteliktedir.

İlke 1: Yetki-Zekâ Ayrılığı İlkesi. Bir aktörün bilişsel yetkinliği, ne kadar üstün olursa olsun, kendi başına o aktöre başkaları adına bağlayıcı kararlar alma yetkisi kazandırmaz. Yapay zekâ danışman olabilir, egemen olamaz. *(Kaynak: Üçüncü Bölüm, § 16; Hobbes, Raz, Estlund, Darwall, Montesquieu, Popper.)*

İlke 2: İnsan Nihai Karar İlkesi. Devlet yetkisinin kullanılmasına ilişkin bağlayıcı kararlar, Anayasa'nın öngördüğü yetkili organlara mensup insanlar tarafından verilir ve onların iradesine atfedilir. Bu ilke, her bireysel kararın bir insan tarafından onaylanmasını değil, yapay zekânın hangi kararlarda, hangi sınırlar içinde ve hangi güvencelerle kullanılacağına ilişkin üst düzey kararların insanlar tarafından alınmasını ve bireysel kararlara karşı, kararı değiştirme yetkisine sahip bir insana başvurma imkânının bulunmasını gerektirir. *(Kaynak: Beşinci Bölüm, § 22 ve § 27; AY md. 6, 7, 9, 128, 138.)*

İlke 3: Düzeltilebilirlik İlkesi. Yapay zekâ sistemlerinin kullanımına ilişkin kararlar, hataların erken fark edilmesini ve düşük maliyetle düzeltilmesini mümkün kılacak biçimde tasarlanmalıdır. Bir yapay zekâ sisteminin kullanımı, ancak sistemin hatalı olduğu anlaşıldığında, ciddi bir zarar ve direnç olmaksızın düzeltilebileceği veya devre dışı bırakılabileceği ölçüde meşrudur. *(Kaynak: Birinci Bölüm, § 4; Popper, Collingridge; İkinci Bölüm, § 10.)*

İlke 4: Asimetrik Durdurulabilirlik İlkesi. Bir yapay zekâ sisteminin kullanımını durdurmak kolay, yeniden başlatmak ise zor olmalıdır. Durdurma yetkisi birden fazla aktöre ayrı ayrı tanınmalı; yeniden başlatma ise çoklu onaya bağlanmalıdır. *(Kaynak: Birinci Bölüm, § 3 ve § 4; Montesquieu'nün "engelleme yetisi"; Schmitt-Kelsen tartışması.)*

İlke 5: Kanunilik ve Esaslılık İlkesi. Temel hakları etkileyen kamusal kararlarda yapay zekâ kullanımının temel çerçevesi, kanunla belirlenir. Yapay zekâ sistemlerinin içerdiği karar kuralları, işlevsel olarak düzenleyici işlemler gibi ele alınır ve bu işlemlere uygulanan güvencelere tabidir. *(Kaynak: Beşinci Bölüm, § 22; AY md. 7, 13, 104/17; Locke.)*

İlke 6: Aleniyet İlkesi. Yapay zekâ sistemlerinin kamusal kullanımına ilişkin bilgiler, meşru gizlilik gerekçeleri dışında, kamuya açıktır. Bir yapay zekâ sisteminin kullanım biçimi, kamuoyuna açıklandığında meşruiyetini yitirecek türdense, bu kullanım hukuka aykırıdır. *(Kaynak: Birinci Bölüm, § 3; Kant'ın aleniyet ilkesi.)*

İlke 7: Bağımsız Denetim İlkesi. Hiç kimse kendi davasında yargıç olamaz. Yapay zekâ sistemlerinin güvenliği ve hukuka uygunluğu, onları geliştiren ve kullananlardan bağımsız aktörler tarafından değerlendirilir. *(Kaynak: Birinci Bölüm, § 4; Kelsen.)*

İlke 8: Son İnsan Halkası İlkesi. Bir yapay zekâ sisteminin her önemli kullanım bağlamı için, o kullanımın sonuçlarından kişisel olarak hesap verecek, adı belirli, yeterli yetki ve bilgiyle donatılmış ve sistemin kullanımını durdurabilecek en az bir insan bulunur. *(Kaynak: Altıncı Bölüm, § 33; Weber, Darwall, Santoni de Sio ve van den Hoven.)*

İlke 9: Orantılılık ve Kademelendirme İlkesi. Denetimin yoğunluğu, yapay zekâ sisteminin yeteneğiyle, kullanıldığı kararların önemiyle ve etkilediği hakların niteliğiyle orantılıdır. Denetim, risk arttıkça yoğunlaşır. *(Kaynak: Beşinci Bölüm, § 22; AY md. 13; Avrupa Birliği Yapay Zekâ Tüzüğü.)*

İlke 10: Çoğulculuk ve Dairesellik İlkesi. Yapay zekâ denetimi, tek bir nihai otoriteye bırakılmaz; birbirinden bağımsız ama birbirini karşılıklı olarak denetleyen çok sayıda aktör ve kurum arasında dağıtılır. Hiçbir denetim aktörü, denetimden muaf değildir. *(Kaynak: Birinci Bölüm, § 1 ve § 3; Polybios, Montesquieu, Madison; Dördüncü Bölüm, § 21; Ostrom, Pettit.)*

§ 43. DENETİMİN DÖRT NESNESİ

I. Kuramın Formülasyonu

Giriş'te kısaca tanıtılan ve çalışma boyunca kullanılan "denetimin dört nesnesi" kuramı, çok katmanlı dairesel denetim modelinin analitik çerçevesini oluşturmaktadır. Bu kuram, burada sistemli bir biçimde formüle edilmektedir.

Her denetim faaliyeti, belirli bir *nesneye* yöneliktir; yani denetçi, denetlenenin belirli bir yönünü değerlendirir ve gerektiğinde ona müdahale eder. Bu çalışma, yapay zekâ denetiminin nesnelerini dört kategoride sınıflandırmaktadır:

1. **Sonuç denetimi:** Bir kararın veya çıktının *içerik* bakımından doğru, isabetli veya hukuka uygun olup olmadığının değerlendirilmesi. Temel soru: *Bu karar doğru mu?*
2. **Süreç denetimi:** Kararın *hangi usulle*, hangi gerekçelerle, hangi verilere dayanarak ve hangi kurallara uyularak alındığının değerlendirilmesi. Temel soru: *Bu karar doğru biçimde mi alındı?*
3. **Girdi denetimi:** Sistemin var olabilmesi ve işleyebilmesi için gerekli *kaynakların*, yani hesaplama gücünün, verinin, enerjinin,

sermayenin ve insan emeğinin kontrol edilmesi. Temel soru: *Bu sistem hangi kaynaklarla, kim tarafından ve hangi koşullarda inşa ediliyor?*

4. **Varlık koşulları denetimi:** Sistemin *hangi koşullarda kullanılabileceğinin*, hangi koşullarda durdurulacağının, değiştirileceğinin veya kullanımdan kaldırılacağının belirlenmesi ve bu kararların uygulanabilirliğinin güvence altına alınması. Temel soru: *Bu sistem kullanılmalı mı, kullanılmaya devam etmeli mi ve gerektiğinde durdurulabilir mi?*

II. Kayma Tezi

Bu çalışmanın temel analitik iddiası, Giriş'te formüle edilen birinci hipotezin (H1) bir ifadesi olan **"kayma tezi"**dir:

> *Denetleyen ile denetlenen arasındaki bilişsel asimetri arttıkça, sonuç denetimi işlevini kaybetmeye başlar; buna karşılık süreç, girdi ve varlık koşulları denetimi, işlevini önemli ölçüde korur. Bu nedenle, bilişsel asimetri arttıkça, denetimin ağırlığı sonuç denetiminden diğer üç nesneye kaydırılmalıdır.*

Bu tezin gerekçesi, dört nesnenin her birinin gerektirdiği bilişsel kapasitenin farklılığıdır. *Sonuç denetimi*, denetçinin, kararın içeriğini değerlendirebilmesini, yani en azından kararın doğru olup olmadığını anlayabilmesini gerektirir. Kavrayış asimetrisi koşullarında, bu tam da denetçinin yapamadığı şeydir; İkinci Bölüm'deki "37. hamle" örneği, en iyi insan uzmanların bile, üstün bir sistemin kararını karar anında değerlendiremeyebileceğini göstermiştir. *Süreç denetimi* ise denetçinin kararın içeriğini değil, kararın alındığı usulü değerlendirmesini gerektirir. Bir hâkim, bir bilirkişinin teknik görüşünün içeriğini değerlendiremese bile, bilirkişinin tarafsız olup olmadığını, raporunun iç tutarlılığını ve tarafların itirazlarına cevap verip vermediğini değerlendirebilir. *Girdi denetimi*, denetçinin sistemin kendisini değil, sistemin inşa edildiği kaynakları izlemesini gerektirir; hesaplama gücü, fiziksel ve sayılabilir bir kaynaktır ve onun izlenmesi, sistemin ne yaptığını anlamayı gerektirmez. *Varlık koşulları denetimi* ise en az bilişsel kapasite gerektiren denetim türüdür: Bir sistemi durdurmak için, onun nasıl çalıştığını anlamak gerekmez; yalnızca onun durdurulması gerektiğine karar vermek ve bu kararı uygulayabilmek gerekir. Bu, Montesquieu'nün "engelleme yetisi"nin en saf biçimidir.

III. Dört Nesne ve Dört Asimetri

Kayma tezi, İkinci Bölüm'de tanımlanan dört asimetri türüyle birlikte değerlendirildiğinde daha da netleşir. Aşağıdaki tablo, her asimetri türü karşısında dört denetim nesnesinin işlevselliğini özetlemektedir.

Asimetri türü	Sonuç denetimi	Süreç denetimi	Girdi denetimi	Varlık koşulları denetimi
Hız asimetrisi	Sonradan mümkün	Önceden belirlenen kurallarla mümkün	Mümkün	Otomatik sınırlarla mümkün
Ölçek asimetrisi	Örneklemle kısmen mümkün	İstatistiksel denetimle mümkün	Mümkün	Mümkün
Kavrayış asimetrisi	Büyük ölçüde zayıflar	Kısmen mümkün (bilirkişi modeli)	Mümkün	Mümkün
Stratejik asimetri	Güvenilmez	Zayıflar (gerekçe manipülasyonu)	Mümkün	Mümkün, ama durdurulabilirlik ayrıca güvence altına alınmalı

Tablo, iki önemli sonucu açıkça göstermektedir. *Birincisi*, girdi denetimi ve varlık koşulları denetimi, tüm asimetri türleri karşısında işlevini koruyan tek denetim nesneleridir. Bu nedenle, bu iki nesne, bilişsel asimetrinin en yüksek olduğu durumlarda, denetimin son ve en güvenilir savunma hattını oluşturur. *İkincisi*, stratejik asimetri durumunda, varlık koşulları denetiminin kendisi de tehdit altındadır; çünkü yeterince yetenekli ve stratejik bir sistem, durdurulmasını engellemeye çalışabilir. İkinci Bölüm'de ele alınan "kapatma düğmesi sorunu", bu tehdidin teknik ifadesidir. Bu nedenle, varlık koşulları denetimi, yalnızca durdurma *yetkisinin* tanınmasıyla değil, durdurma *kapasitesinin* teknik, örgütsel ve fiziksel olarak güvence altına alınmasıyla desteklenmelidir. Bu, aşağıda ele alınacak olan "durdurma yükümlülüğü ve kapasitesi" kavramının gerekçesidir.

IV. Dört Nesne ve Goldman'ın Kanıt Kaynakları

Dört denetim nesnesi, İkinci Bölüm'de yapay zekâ denetimine uyarlanan Goldman'ın beş kanıt kaynağıyla da ilişkilendirilebilir. Sonuç denetimi, ağırlıklı olarak "geçmiş başarı kaydı" kaynağına dayanır. Süreç denetimi, "argümanlar", "görüş birliği" ve "üst-uzman değerlendirmeleri"

kaynaklarına dayanır. Girdi denetimi ve varlık koşulları denetimi ise ağırlıklı olarak "çıkar ve önyargılar" kaynağıyla, yani sistemi geliştiren ve kullanan aktörlerin teşviklerinin ve sistemin kendisinin eğilimlerinin değerlendirilmesiyle ilişkilidir. Bu ilişkilendirme, her denetim nesnesinin, hangi tür kanıtlara dayanması gerektiğini ve bu kanıtların hangi zaaflara sahip olduğunu göstermesi bakımından yararlıdır.

V. Zaman Boyutu: Uçtan Uca Güvenceler

Dört denetim nesnesi, Beşinci Bölüm'de Avrupa İnsan Hakları Mahkemesi içtihadından türetilen "uçtan uca güvenceler" ilkesi uyarınca, sistemin tüm yaşam döngüsü boyunca uygulanmalıdır. Bu, dört nesnenin üç zaman aşamasıyla birleştirildiği bir matris ortaya çıkarır:

Aşama	Sonuç	Süreç	Girdi	Varlık koşulları
Önceden (geliştirme ve kullanıma alma)	Test ve değerlendirme sonuçları	Tasarım belgeleri, hedef fonksiyonu, etki değerlendirmesi	Hesaplama bildirimleri, veri yönetişimi	Kullanıma alma izni, durdurma kapasitesinin doğrulanması
İşleyiş sırasında	Başarım izleme, hata oranları	Kayıt tutma, sürüm kilidi, insan gözetimi	Kaynak kullanımının izlenmesi	Askıya alma yetkisi, olay bildirimi
Sonradan	Bireysel itirazlar, yargısal denetim	Gerekçe denetimi, denetim raporları	Kaynakların geriye dönük incelenmesi	Kullanımdan kaldırma, sorumluluk, tazminat

Bu matris, çok katmanlı dairesel denetim modelinin "haritası" işlevini görmektedir. Modelin her katmanı, bu matrisin belirli hücrelerini doldurmakla görevlidir; ve modelin bütünlüğü, matrisin tüm hücrelerinin en az bir katman tarafından doldurulmasına bağlıdır.

§ 44. BEŞ KATMAN

Çok katmanlı dairesel denetim modeli, birbirinden bağımsız ama birbirini karşılıklı olarak denetleyen beş katmandan oluşmaktadır. Bu katmanlar, Birinci Bölüm'de Madison'ın "birincil denetim" ve "yardımcı önlemler" ayrımıyla ilişkilendirilebilir: Toplumsal katman, birincil denetimi; diğer katmanlar ise yardımcı önlemleri oluşturur.

I. Birinci Katman: Teknik Denetim

A. İşlev ve Araçlar

Teknik denetim katmanı, yapay zekâ sistemlerinin kendisinin, teknik yöntemlerle değerlendirilmesini ve izlenmesini kapsar. Bu katmanın başlıca araçları, İkinci Bölüm'de ele alınan teknik denetim yöntemleridir: model değerlendirmeleri ve tehlikeli yetenek testleri; düşmanca testler (kırmızı takım çalışmaları); yorumlanabilirlik analizleri; akıl yürütme metinlerinin izlenmesi; ve sistemin hizalanmamış olabileceği varsayımı altında güvenliği sağlamayı amaçlayan kontrol protokolleri.

B. Güven Çapasının Korunması

İkinci Bölüm'ün sonunda, her teknik denetim yönteminin, kendisi denetlenmeyen ama güvenilir kabul edilen bir "güven çapası"na dayandığı gösterilmişti. Bu gözlem, teknik katmanın tasarımı bakımından belirleyicidir: Teknik katmanın güvenilirliği, güven çapalarının korunmasına bağlıdır. Bu çalışma, güven çapalarının korunması için şu güvenceleri önermektedir:

Çeşitlilik: Teknik denetimde kullanılan güven çapaları çeşitlendirilmelidir. Tek bir değerlendirme yöntemine, tek bir değerlendirici modele veya tek bir değerlendirici kuruluşa dayanmak yerine, farklı yöntemler, farklı modeller ve farklı kuruluşlar birlikte kullanılmalıdır. Bu, İkinci Bölüm'de ele alınan "algoritmik monokültür" sorununa karşı bir güvencedir.

Bağımsızlık: Teknik değerlendirmeler, değerlendirilen sistemi geliştiren kuruluştan bağımsız aktörler tarafından yapılmalı veya en azından bu aktörler tarafından doğrulanmalıdır. Bu, Kelsen'in ilkesinin teknik katmandaki uygulamasıdır.

Erişim: Bağımsız değerlendiricilerin, sistemlere, değerlendirme için gerekli düzeyde, yani yalnızca kullanıcı arayüzü üzerinden değil, gerektiğinde modelin iç durumlarına ve eğitim süreçlerine ilişkin bilgilere, uygun gizlilik ve güvenlik güvenceleri altında erişebilmesi sağlanmalıdır.

İzlenebilirliğin korunması: İkinci Bölüm'de, akıl yürütme metinlerinin izlenebilirliğinin "yeni ve kırılgan bir fırsat" olduğu ve geliştirme süreçlerinde bu izlenebilirliği bozacak uygulamalardan kaçınılması gerektiği belirtilmişti. Bu çalışma, sınır sistem geliştiricilerinin, sistemlerinin izlenebilirliğini önemli ölçüde azaltan geliştirme kararlarını,

yetkili denetim otoritesine bildirme yükümlülüğü altında olmasını önermektedir.

C. Teknik Katmanın Sınırları

Teknik denetim katmanı, vazgeçilmez ama tek başına yetersizdir. İkinci Bölüm'de gösterildiği üzere, teknik yöntemlerin her biri, stratejik asimetri karşısında belirli zaaflara sahiptir. Ayrıca, teknik denetim, *neyin* değerlendirileceği, yani hangi risklerin kabul edilemez olduğu ve hangi değerlerin korunması gerektiği sorusunu cevaplayamaz; bu soru, Üçüncü Bölüm'de Dahl'ın ahlaki bilgi ile araçsal bilgi arasındaki ayrımı bağlamında gösterildiği üzere, teknik değil, normatif ve siyasi bir sorudur. Bu nedenle, teknik katman, diğer katmanlar tarafından yönlendirilmeli ve denetlenmelidir.

II. İkinci Katman: Kurumsal Denetim

A. Yapay Zekâ Denetim Kurumu

Kurumsal denetim katmanının merkezinde, bu çalışmanın Türk hukuku için önerdiği **Yapay Zekâ Denetim Kurumu** yer almaktadır. Yedinci Bölüm'de, Türk hukukunun en önemli eksikliklerinden birinin, yapay zekâ sistemlerini bütünlüklü bir biçimde değerlendirecek, mevcut kurumlar arasında koordinasyonu sağlayacak ve yapay zekâya özgü teknik uzmanlığı biriktirecek bir merkezin yokluğu olduğu tespit edilmişti. Önerilen Kurum, bu eksikliği gidermeyi amaçlamaktadır.

Kurum'un temel özellikleri, § 46'da sunulan kanun önerisinde ayrıntılı olarak düzenlenmektedir. Burada, Kurum'un tasarımına yön veren temel tercihler açıklanacaktır.

Bağımsızlık: Kurum, idari ve mali özerkliğe sahip bir bağımsız idari otorite olarak kurulmalıdır. Kurum'un karar organı olan Kurul'un üyeleri, farklı kaynaklardan (Türkiye Büyük Millet Meclisi, yüksek yargı organları, üniversiteler ve meslek kuruluşları) gelen adaylar arasından seçilmeli; belirli bir süre için ve yenilenemez bir görev süresiyle atanmalı; ve görev süreleri boyunca, kanunda sınırlı olarak sayılan haller dışında görevden alınamamalıdır. Bu tasarım, Kurum'un, hem yürütmeden hem de denetlediği şirketlerden bağımsızlığını güvence altına almayı amaçlamaktadır.

Uzmanlık: Kurum, bilgisayar bilimi, hukuk, iktisat, etik ve sosyal bilimler alanlarında uzman personele sahip olmalı ve bu personelin, özel sektördeki muadilleriyle rekabet edebilecek koşullarda istihdam edilmesi sağlanmalıdır. Kurum'un teknik değerlendirme kapasitesi, Birleşik Krallık'ın Yapay Zekâ Güvenliği Enstitüsü deneyiminden esinlenerek, sınır modelleri bağımsız olarak test edebilecek düzeyde geliştirilmelidir.

Yetkiler: Kurum, yüksek riskli kamusal yapay zekâ kullanımlarını ve sınır sistemleri kayıt altına alma; belirli kullanımlar için ön izin verme; sistemleri ve kuruluşları denetleme; bilgi ve belge talep etme; gerektiğinde sistemlerin kullanımını askıya alma; ve kanuna aykırılıklar için idari yaptırım uygulama yetkilerine sahip olmalıdır.

Koordinasyon: Kurum, mevcut kurumların, yani Kişisel Verileri Koruma Kurumu'nun, Türkiye İnsan Hakları ve Eşitlik Kurumu'nun, Kamu Denetçiliği Kurumu'nun, Rekabet Kurumu'nun ve sektörel düzenleyicilerin yetkilerini ortadan kaldırmamalı; bu kurumlarla birlikte, bir "Yapay Zekâ Denetimi Koordinasyon Kurulu" aracılığıyla, koordineli bir biçimde çalışmalıdır. Bu tasarım, Ostrom'un çok merkezli yönetişim modelinin avantajlarını korurken, dağınıklığın yarattığı koordinasyon eksikliğini gidermeyi amaçlamaktadır.

B. Kurum'un Kendisinin Denetimi

Çok katmanlı dairesel denetim modelinin en özgün unsuru, denetim kurumlarının *kendisinin* denetlenmesine ilişkin güvencelerdir. Yedinci Bölüm'deki karşılaştırmalı analiz, mevcut yapay zekâ düzenlemelerinin, yapay zekâyı denetlemeye odaklandığını, ama bu denetimi yapanları denetlemeyi büyük ölçüde ihmal ettiğini göstermişti. Önerilen model, bu eksikliği gidermek amacıyla, Yapay Zekâ Denetim Kurumu'nu, çok yönlü bir hesap verebilirlik ağına tabi kılmaktadır:

1. *Yasama denetimi:* Kurum, faaliyetlerine ilişkin yıllık raporunu Türkiye Büyük Millet Meclisi'ne sunar ve Meclis'in ilgili komisyonunda bu rapor hakkında bilgi verir. Meclis'in Bilim ve Teknoloji Değerlendirme Birimi, Kurum'un faaliyetlerini bağımsız olarak değerlendirebilir.
2. *Yargısal denetim:* Kurum'un tüm kararları, idari yargı denetimine tabidir. Kurum'un düzenleyici işlemlerine karşı Danıştay'da iptal davası açılabilir.

3. *Mali denetim:* Kurum'un hesapları ve faaliyetlerinin etkinliği, Sayıştay denetimine tabidir.
4. *Şikâyet mekanizması:* Kurum'un işlem ve eylemlerine ilişkin şikâyetler, Kamu Denetçiliği Kurumu'na yapılabilir.
5. *Kamusal şeffaflık:* Kurum'un kararları, denetim raporları ve değerlendirme yöntemleri, meşru gizlilik gerekçeleri dışında, kamuya açıktır.
6. *Bilimsel denetim:* Kurum bünyesinde, bağımsız bilim insanlarından oluşan bir Bilimsel Danışma Kurulu bulunur. Bu Kurul, Kurum'un değerlendirme yöntemlerini inceleyebilir ve Avrupa Birliği Yapay Zekâ Tüzüğü'ndeki Bilimsel Panel'in nitelikli uyarı yetkisine benzer biçimde, ciddi riskler tespit ettiğinde, hem Kurum'a hem de Türkiye Büyük Millet Meclisi'ne doğrudan "nitelikli uyarı" iletebilir.
7. *Dönemsel gözden geçirme:* Kurum'un kuruluş kanunu, belirli aralıklarla, bağımsız bir değerlendirmeye tabi tutulur ve bu değerlendirmenin sonuçları Türkiye Büyük Millet Meclisi'ne sunulur.

Bu yedi güvence, Kurum'u, Juvenalis'in sorusuna karşı korumayı amaçlamaktadır. Kurum, yapay zekâ sistemlerini ve onları geliştiren ve kullanan aktörleri denetler; ama kendisi de yasama, yargı, Sayıştay, Kamu Denetçiliği Kurumu, bilim topluluğu ve kamuoyu tarafından denetlenir. Bu, Birinci Bölüm'de Polybios'un karma anayasasından türetilen dairesel yapının kurumsal bir uygulamasıdır.

C. Denetçilerin Denetimi

Beşinci Bölüm'de, algoritmik denetim sektörünün kendine özgü bir bekçiler sorunu doğurduğu ve bu sorunun, Türk hukukunda bağımsız denetçileri gözetim altında tutan Kamu Gözetimi Kurumu modeline benzer bir yapıyla çözülebileceği belirtilmişti. Önerilen modelde, Yapay Zekâ Denetim Kurumu, yapay zekâ sistemlerinin bağımsız değerlendirmesini ve denetimini yapacak kuruluşları yetkilendirir, bu kuruluşların uyması gereken denetim standartlarını belirler, kuruluşların çalışmalarını düzenli olarak inceler ve standartlara uymayan kuruluşların yetkilerini askıya alır veya iptal eder. Ayrıca, denetlenen kuruluşların, aynı denetçiyi belirli bir süreden fazla kullanması yasaklanır; bu "rotasyon" kuralı, finansal denetim

alanında, denetçi ile denetlenen arasındaki ilişkinin zamanla bağımsızlığı zedelemesini önlemek amacıyla geliştirilmiştir.

D. Diğer Kurumsal Aktörler

Yapay Zekâ Denetim Kurumu'nun yanında, kurumsal katmanda şu aktörler de yer almaktadır: Beşinci Bölüm'de önerilen *Türkiye Büyük Millet Meclisi Bilim ve Teknoloji Değerlendirme Birimi* ve yapay zekâ alanındaki *daimi ihtisas komisyonu*; algoritmik idari işlemleri denetleyen *idari yargı* ve temel hak ihlallerini inceleyen *Anayasa Mahkemesi* (bireysel başvuru yoluyla); algoritmik idari işlemlerden etkilenen yurttaşların şikâyetlerini inceleyen *Kamu Denetçiliği Kurumu*; kamu kurumlarının yapay zekâ harcamalarını ve bu harcamaların etkinliğini denetleyen *Sayıştay*; ve kendi alanlarında yapay zekâ kullanımını denetleyen *sektörel düzenleyiciler*.

III. Üçüncü Katman: Girdi Denetimi

A. İşlev ve Gerekçe

Girdi denetimi katmanı, yapay zekâ sistemlerinin kendisini değil, bu sistemlerin geliştirilmesi ve işletilmesi için gereken kaynakları denetlemeyi amaçlar. Bu katmanın gerekçesi, § 43'te açıklanan kayma tezidir: Girdi denetimi, tüm asimetri türleri karşısında işlevini koruyan denetim nesnelerinden biridir; çünkü kaynakların izlenmesi, sistemin ne yaptığını anlamayı gerektirmez.

B. Araçlar

Girdi denetiminin başlıca araçları şunlardır:

Hesaplama eşikleri ve bildirimler: Belirli bir hesaplama eşiğini aşan yapay zekâ modellerinin eğitimi, eğitime başlanmadan önce yetkili denetim otoritesine bildirilmelidir. Bu bildirim, eğitimin amacını, öngörülen hesaplama miktarını, kullanılacak güvenlik önlemlerini ve eğitim sonrasında yapılacak değerlendirmeleri içermelidir. Avrupa Birliği Yapay Zekâ Tüzüğü'nün 10^{25} FLOP eşiği ve Amerika Birleşik Devletleri'nde yürürlükten kaldırılan 14110 sayılı Kararname'nin bildirim yükümlülüğü, bu aracın örnekleridir. Hesaplama eşiklerinin, algoritmik verimlilik arttıkça aynı yeteneklere daha az hesaplamayla ulaşılabileceği göz önüne alınarak, düzenli olarak gözden geçirilmesi gerekir.

Hesaplama hizmeti sağlayıcılarının yükümlülükleri: Büyük ölçekli hesaplama kapasitesini (bulut hizmetleri aracılığıyla) üçüncü kişilere sunan

sağlayıcılar, belirli eşikleri aşan hesaplama talepleri bakımından müşterilerini tanıma, bu taleplerin amacını öğrenme ve belirli durumlarda yetkili otoriteye bildirimde bulunma yükümlülükleri altında olmalıdır. Bu yükümlülük, finansal sektördeki "müşterini tanı" kurallarına benzer bir mantığa dayanır.

Veri yönetişimi: Yapay zekâ sistemlerinin eğitiminde kullanılan verilerin kaynağı, niteliği ve hukuka uygunluğu, belgelendirilmeli ve denetlenebilir olmalıdır.

Uluslararası işbirliği: Girdi denetimi, doğası gereği uluslararası bir boyuta sahiptir; çünkü hesaplama altyapısının tedarik zinciri küreseldir. Bu nedenle, girdi denetimi katmanı, beşinci katman olan uluslararası denetim katmanıyla yakından bağlantılıdır.

C. Türkiye Bakımından Girdi Denetimi

Türkiye, bu çalışmanın yazıldığı tarih itibarıyla, dünyanın en ileri sınır modellerinin geliştirildiği ülkeler arasında değildir. Bu durum, girdi denetiminin Türkiye bakımından anlamsız olduğu sonucunu doğurmaz. *Birincisi*, Türkiye'de faaliyet gösteren kamu ve özel kuruluşlar, yurt dışında geliştirilen sınır modelleri, bulut hizmetleri aracılığıyla kullanmaktadır; bu kullanımın koşulları, girdi denetiminin bir unsurudur. *İkincisi*, Türkiye'de de yapay zekâ modelleri geliştirilmekte ve hesaplama altyapısına yatırım yapılmaktadır; bu gelişmelerin, baştan uygun bir denetim çerçevesi içinde gerçekleşmesi, Collingridge ikileminin "güç sorunu"nun önlenmesi bakımından önemlidir. *Üçüncüsü*, girdi denetimi, uluslararası düzeyde ancak çok sayıda ülkenin katılımıyla etkili olabilir; Türkiye'nin bu tür uluslararası mekanizmalara katılımı, hem küresel güvenliğe katkıda bulunur hem de Türkiye'nin bu mekanizmaların tasarımında söz sahibi olmasını sağlar.

IV. Dördüncü Katman: Toplumsal Denetim

A. İşlev

Toplumsal denetim katmanı, Madison'ın "birincil denetim" olarak adlandırdığı, yönetimin halka bağımlılığının yapay zekâ bağlamındaki ifadesidir. Bu katman, yurttaşların, sivil toplumun, basının, akademinin ve yapay zekâ sistemlerinden etkilenen kişilerin, yapay zekâ denetimine katılımını kapsar. Bu katman, Birinci Bölüm'de Locke'un "halk yargıç olacaktır" cevabıyla, Dördüncü Bölüm'de Pettit'in "editörlük denetimi"

kavramıyla ve McCubbins ve Schwartz'ın "yangın alarmı" modeliyle ilişkilendirilmiştir.

B. Araçlar

Kamu algoritma sicili: Temel hakları etkileyen kamusal kararlarda kullanılan tüm yapay zekâ sistemleri, kamuya açık bir sicile kaydedilmelidir. Bu sicil, sistemin hangi kurum tarafından, hangi amaçla, hangi kanuni dayanakla ve hangi güvencelerle kullanıldığını, sistemin hedef fonksiyonunun ve başlıca karar kurallarının açıklamasını, temel haklar etki değerlendirmesinin özetini ve sistemin sorumlu yöneticisinin kimliğini içermelidir. Bu sicil, Kant'ın aleniyet ilkesinin ve Beşinci Bölüm'de önerilen algoritmik normların açıklanması ilkesinin somut bir uygulamasıdır.

Bireysel haklar: Yapay zekâ sistemlerinden etkilenen kişilere, Beşinci Bölüm'de önerilen haklar tanınmalıdır: bilme hakkı, açıklama hakkı, itiraz hakkı ve insan incelemesi talep etme hakkı. Bu haklar, Pettit'in "editörlük denetimi"nin bireysel düzeydeki araçlarıdır.

Olay bildirim sistemi: Yapay zekâ sistemlerinin yol açtığı veya yol açabileceği zararlara ilişkin olayların, etkilenen kişiler, kullanıcılar ve kamuoyu tarafından bildirilebileceği bir sistem kurulmalıdır. Bu sistem, McCubbins ve Schwartz'ın "yangın alarmı" modelinin kurumsal bir aracıdır. İkinci Bölüm'de, incelenen vakaların hepsinde, etkilenen kişilerin uyarılarının uzun süre göz ardı edildiği tespit edilmişti; olay bildirim sistemi, bu uyarıların, bağımsız bir kurum tarafından sistematik olarak toplanmasını ve incelenmesini güvence altına almalıdır.

Araştırmacı erişimi: Bağımsız araştırmacıların, yapay zekâ sistemlerinin toplumsal etkilerini inceleyebilmesi için, sistemlere ve ilgili verilere, uygun gizlilik ve güvenlik güvenceleri altında erişebilmesi sağlanmalıdır. Avrupa Birliği'nin Dijital Hizmetler Tüzüğü'nde çok büyük çevrimiçi platformlar için öngörülen araştırmacı veri erişimi mekanizması, bu konuda bir model sunmaktadır.

İhbarcı korumaları: Altıncı Bölüm'de ele alınan ihbarcı korumaları, toplumsal denetim katmanının, şirketlerin ve kamu kurumlarının iç işleyişine erişimini sağlayan önemli bir köprüdür.

Yapay Zekâ Yurttaş Meclisi: Dördüncü Bölüm'de ele alınan yurttaş meclisi modelinden esinlenerek, yapay zekânın kamusal kullanımına ilişkin temel değer tercihlerinin (örneğin hangi kararlarda yapay zekâ kullanımının

kabul edilemez olduğu, farklı adalet ölçütleri arasındaki tercihler, kabul edilebilir risk düzeyleri) tartışılması amacıyla, kurayla seçilen ve nüfusun bileşimini yansıtan bir Yapay Zekâ Yurttaş Meclisi düzenli olarak toplanmalıdır. Meclis'in önerileri bağlayıcı olmamalı; ancak Yapay Zekâ Denetim Kurumu ve Türkiye Büyük Millet Meclisi, bu önerileri değerlendirmek ve benimsemedikleri öneriler için gerekçe açıklamakla yükümlü olmalıdır. Bu tasarım, Dahl'ın ahlaki bilgi ile araçsal bilgi arasındaki ayrımını kurumsallaştırır: Araçsal sorular uzmanlara, ahlaki ve değer sorularına ilişkin tartışma ise yurttaşlara açılır.

C. Toplumsal Katmanın Önemi ve Sınırları

Toplumsal denetim katmanı, dairesel yapının "kapanış noktası"dır. Diğer tüm katmanlar, nihayetinde, bu katmana hesap verir: Teknik değerlendiricilerin bulguları kamuya açıklanır; Yapay Zekâ Denetim Kurumu'nun kararları kamuoyunun denetimine tabidir; parlamento, seçmenlere karşı sorumludur. Bu katman, Locke'un ifadesiyle, egemenliğin asıl sahibine dönüşü temsil eder.

Bununla birlikte, toplumsal denetim katmanının sınırları da açıktır. Kavrayış asimetrisi koşullarında, yurttaşların ve kamuoyunun, yapay zekâ sistemlerinin teknik ayrıntılarını değerlendirme kapasitesi sınırlıdır. Bu nedenle, toplumsal denetim, teknik ve kurumsal katmanların ürettiği bilgilere dayanmak zorundadır. Bu durum, toplumsal katmanın, diğer katmanların güvenilirliğine bağımlı olduğu anlamına gelir; ama aynı zamanda, diğer katmanların, toplumsal katmana hesap vermek zorunda olduğu anlamına da gelir. Bu karşılıklı bağımlılık, dairesel yapının özüdür.

V. Beşinci Katman: Uluslararası Denetim

A. Gereklilik

Yapay zekânın uluslararası denetimi, üç nedenle gereklidir. *Birincisi*, sınır yapay zekâ sistemleri, küresel ölçekte geliştirilmekte ve kullanılmaktadır; tek bir ülkenin düzenlemesi, bu sistemlerin tamamını kapsayamaz. *İkincisi*, Dördüncü Bölüm'de gösterildiği üzere, yarış dinamiği, ulusal düzenlemelerin etkinliğini sınırlamaktadır; bir ülkenin düzenlemeyi gevşetmesi, diğer ülkeler üzerinde de gevşeme baskısı yaratır. *Üçüncüsü*, girdi denetimi, hesaplama altyapısının küresel tedarik zinciri nedeniyle, ancak uluslararası işbirliğiyle etkili olabilir.

B. Türkiye İçin Öneriler

Bu çalışma, Türkiye'nin uluslararası denetim katmanına katılımı için şu adımları önermektedir:

1. Avrupa Konseyi Yapay Zekâ ve İnsan Hakları, Demokrasi ve Hukukun Üstünlüğü Hakkında Çerçeve Sözleşmesi'nin imzalanması ve onaylanması.
2. Avrupa Birliği Yapay Zekâ Tüzüğü ile, yalnızca ürün güvenliği boyutunda değil, temel haklar ve kurumsal güvenceler boyutunda da uyumlaştırma yapılması.
3. Yapay zekâ güvenliği enstitüleri arasındaki uluslararası ağa katılım ve bu amaçla Yapay Zekâ Denetim Kurumu bünyesinde bir teknik değerlendirme biriminin kurulması.
4. Birleşmiş Milletler bünyesinde kurulan Bağımsız Uluslararası Bilimsel Panel ve Küresel Diyalog süreçlerine etkin katılım.
5. Sınır yapay zekâ sistemlerine ilişkin ciddi olayların uluslararası düzeyde bildirilmesine ve paylaşılmasına ilişkin mekanizmalara katılım.
6. Hesaplama altyapısının uluslararası düzeyde izlenmesine ve doğrulanmasına ilişkin gelecekteki mekanizmaların tasarımına katkıda bulunulması.

VI. Dairesellik: Katmanlar Arasındaki İlişkiler

Çok katmanlı dairesel denetim modelinin özü, beş katmanın varlığında değil, bu katmanlar arasındaki *karşılıklı denetim ilişkilerindedir*. Aşağıdaki tablo, her katmanın diğer katmanları hangi araçlarla denetlediğini özetlemektedir.

Denetleyen katman	Denetlenen katman	Denetim aracı
Teknik	Kurumsal	Değerlendirme yöntemlerinin bilimsel eleştirisi
Teknik	Girdi	Hesaplama ölçümlerinin doğrulanması
Teknik	Toplumsal	Bulguların kamuya açıklanması
Teknik	Uluslararası	Uluslararası bilimsel raporlar
Kurumsal	Teknik	Değerlendiricilerin yetkilendirilmesi ve denetimi

Denetleyen katman	Denetlenen katman	Denetim aracı
Kurumsal	Girdi	Bildirimlerin alınması ve incelenmesi
Kurumsal	Toplumsal	Kararların gerekçelendirilmesi
Kurumsal	Uluslararası	Uluslararası yükümlülüklerin uygulanması
Girdi	Teknik	Değerlendirme için kaynak tahsisi
Girdi	Kurumsal	Bağımsızlık için kaynak güvencesi
Girdi	Toplumsal	Kaynak dağılımının şeffaflığı
Girdi	Uluslararası	Tedarik zinciri işbirliği
Toplumsal	Teknik	Araştırmacı erişimi, bağımsız denetimler
Toplumsal	Kurumsal	Şikâyetler, yurttaş meclisi, seçimler
Toplumsal	Girdi	Kamuoyu tartışması
Toplumsal	Uluslararası	Uluslararası sivil toplum
Uluslararası	Teknik	Ortak değerlendirme standartları
Uluslararası	Kurumsal	Uluslararası gözden geçirme
Uluslararası	Girdi	Uluslararası izleme
Uluslararası	Toplumsal	Uluslararası insan hakları mekanizmaları

Bu tablonun gösterdiği gibi, modelde hiçbir katman, denetimden muaf değildir. Her katman, en az bir başka katman tarafından denetlenir. Bu yapı, Juvenalis'in sonsuz geriye gidiş sorununu, zinciri sonsuza uzatarak değil, zinciri kendi üzerine kapatarak çözer. Polybios'un Roma anayasasında konsüllerin, senatonun ve halk meclislerinin birbirini dengelemesi gibi, modelde de beş katman birbirini dengeler.

Bununla birlikte, dairesel yapı, kendi başına bir güvence değildir. Birbirini denetleyen aktörler, birbiriyle işbirliği yaparak, yani Juvenalis'in deyişiyle "işe birbirlerinden başlayarak", dairesel yapıyı boşa çıkarabilir. Bu tehlikeye karşı, modelin son güvencesi, *düzeltilebilirlik*tir. Dairesel yapının herhangi bir noktasında bir başarısızlık meydana geldiğinde, bu başarısızlığın tespit edilmesi ve düzeltilmesi mümkün olmalıdır. Bu, her katmanda, hataların tespit edilmesini ve düzeltilmesini mümkün kılan mekanizmaların, yani şeffaflığın, bağımsızlığın, itiraz imkânlarının ve durdurma yetkilerinin bulunması anlamına gelir. Dairesellik, bekçiler sorununu ortadan kaldırmaz; ama onu, Popper'ci anlamda "yönetilebilir" kılar: Bekçilerin hepsinin aynı anda ve kalıcı olarak yozlaşması olasılığını

azaltır ve herhangi bir bekçinin yozlaşmasının düzeltilmesini mümkün kılar.

§ 45. HESAP SORMA REJİMİ

I. Hesap Verebilirlik Açıkları ve Araçlar

Altıncı Bölüm'de, yapay zekânın beş hesap verebilirlik açığı yarattığı tespit edilmişti: bilgi açığı, gerekçe açığı, yaptırım açığı, forum açığı ve fail açığı. Çok katmanlı dairesel denetim modelinin hesap sorma rejimi, bu açıkların her birini kapatmaya yönelik araçlar içermektedir. Aşağıdaki tablo, bu araçları özetlemektedir.

Açık	Kapatılmasına yönelik araçlar
Bilgi açığı	Kamu algoritma sicili; kayıt tutma ve sürüm kilidi; bilgi ve belge talep etme yetkileri; araştırmacı erişimi; ihbarcı korumaları; ispat kolaylıkları ve belge ibrazı yükümlülükleri
Gerekçe açığı	Gerekçenin yetkili kamu görevlisi tarafından oluşturulması ilkesi; açıklama ile gerekçe ayrımı; hedef fonksiyonu-maksat uygunluğu denetimi; açıklama hakkı
Yaptırım açığı	Tehlike sorumluluğu; organizasyon sorumluluğu; zorunlu mali güvence; tazmin fonu; idari para cezaları; kişisel sorumluluk; özel suç tipleri
Forum açığı	Yapay Zekâ Denetim Kurumu; TBMM Bilim ve Teknoloji Değerlendirme Birimi; uzmanlaşmış idari yargı; Bilimsel Danışma Kurulu; Yapay Zekâ Yurttaş Meclisi
Fail açığı	Son insan halkası ilkesi; yapay zekâ sorumlu yöneticisi; sorumluluğun kanalize edilmesi; müteselsil sorumluluk; değer zinciri boyunca rol tanımları

II. Sorumluluk Zinciri

Modelin hesap sorma rejimi, yapay zekâ değer zincirindeki aktörlerin her birinin rolünü ve sorumluluğunu açıkça tanımlar. Altıncı Bölüm'de belirtildiği üzere, her aktörün sorumluluğu, sistemin davranışı üzerindeki kontrolü ve sisteme ilişkin bilgisiyle orantılıdır.

Temel model geliştiricisi, modelin genel yeteneklerinden, sınırlarından ve genel risklerinden; modelin güvenlik değerlendirmelerinin yapılmasından ve belgelendirilmesinden; modelin aşağı akıştaki

kullanıcılarına yeterli bilgi sağlanmasından; ve modelin tehlikeli olduğu anlaşıldığında gerekli önlemlerin alınmasından (garantörlük ve durdurma yükümlülüğü) sorumludur.

Uyarlayıcı, modeli belirli bir kullanım için uyarlayan aktör olarak, uyarlamanın yarattığı ek risklerden ve uyarlanmış sistemin amacına uygunluğundan sorumludur.

Uygulayıcı, sistemi belirli bir bağlamda kullanmaya karar veren aktör olarak, sistemin o bağlamdaki kullanımının uygunluğundan, temel haklar etki değerlendirmesinden, insan gözetiminin örgütlenmesinden, kullanımın izlenmesinden ve sistemin hatalı olduğu anlaşıldığında kullanımın durdurulmasından sorumludur. Kamu kurumları bakımından bu sorumluluk, algoritmik hizmet kusuru kavramı çerçevesinde değerlendirilir.

Bireysel kullanıcı (örneğin sistemin çıktısını değerlendiren kamu görevlisi), kendisine verilen yetki ve bilgi ölçüsünde, sistemin çıktısını bağımsız olarak değerlendirmekten ve kararını gerekçelendirmekten sorumludur. Ancak bu sorumluluk, ahlaki çarpışma bölgesi tehlikesine karşı, kullanıcıya verilen yetki ve bilgiyle sınırlıdır.

Denetçi, kendisine verilen denetim görevini bağımsız ve özenli bir biçimde yerine getirmekten sorumludur. Denetçinin de sorumlu tutulabilmesi, modelin dairesel yapısının bir gereğidir.

III. Önceden Hesap Verme

Hesap verebilirlik, genellikle geçmişe dönük bir kavram olarak anlaşılır: Bir zarar meydana geldikten sonra, sorumlulardan hesap sorulur. Ancak Üçüncü Bölüm'de, sorumluluk boşluğu sorununun çözümünün, geçmişe dönük ve sonuç odaklı bir sorumluluk anlayışından, ileriye dönük ve görev odaklı bir sorumluluk anlayışına kaymakta olduğu ileri sürülmüştü. Bu düşünce, modelin hesap sorma rejiminde, **"önceden hesap verme"** kavramıyla somutlaştırılmaktadır.

Önceden hesap verme, yapay zekâ sistemlerini geliştiren ve kullanan aktörlerin, sistemleri kullanıma almadan *önce*, sistemlerin güvenliği, hukuka uygunluğu ve olası etkileri hakkında, yetkili foruma (denetim otoritesine, parlamentoya, kamuoyuna) hesap vermesidir. Bu hesap, bir "güvenlik dosyası" biçiminde sunulur: Sistemin amacı, yetenekleri, sınırları, test sonuçları, tespit edilen riskler, bu risklere karşı alınan önlemler, durdurma kapasitesi ve sorumlu yöneticinin kimliği. Önceden

hesap verme, Bovens'in hesap verebilirlik modelinin üç aşamasını, zarar meydana gelmeden önce işletir: Aktör bilgi verir (güvenlik dosyası), forum sorgular (bağımsız değerlendirme) ve sonuç ortaya çıkar (kullanıma alma izni veya reddi). Bu yaklaşım, ilaç ve havacılık gibi yüksek riskli sektörlerde uzun süredir uygulanan bir mantığın, yapay zekâya uyarlanmasıdır.

§ 46. TÜRK HUKUKU İÇİN KANUN ÖNERİSİ

I. Önerinin Niteliği

Bu başlık altında, çalışmanın bulgularına dayanan ve Türk hukuku için hazırlanan bir kanun önerisi taslağı sunulmaktadır. Taslak, akademik bir öneri niteliğindedir; yürürlükteki mevzuatla tam uyumu, yasama tekniği bakımından ayrıntılı bir incelemeden ve ilgili kurumların, uzmanların ve kamuoyunun görüşlerinin alınmasından sonra sağlanabilir. Taslağın amacı, önceki bölümlerde geliştirilen ilke ve önerilerin, somut hukuk kurallarına nasıl dönüştürülebileceğini göstermek ve bu alandaki yasama tartışmasına bir katkı sunmaktır.

Taslak, Türk yasama tekniğinin yerleşik biçimine uygun olarak düzenlenmiştir. Taslağın önünde bir genel gerekçe, sonunda ise önemli maddelere ilişkin kısa madde gerekçeleri yer almaktadır.

II. Genel Gerekçe

Yapay zekâ sistemleri, kamu yönetiminde, yargıda, sağlıkta, finansta ve toplumsal hayatın pek çok alanında, karar süreçlerine hızla dâhil olmaktadır. Bu sistemler, kararların hızını, tutarlılığını ve etkinliğini artırma potansiyeline sahip olmakla birlikte, Anayasa'nın güvence altına aldığı temel hak ve özgürlükler, hukuk devleti, kuvvetler ayrılığı ve demokratik meşruiyet ilkeleri bakımından yeni ve ciddi riskler doğurmaktadır.

Bu risklerin başında, yapay zekâ sistemlerinin işleyişinin, onları kullanan karar vericiler tarafından tam olarak anlaşılamaması ve bu nedenle, kararların fiilen, Anayasa'nın öngördüğü yetkili organlar yerine, denetlenemeyen sistemler tarafından belirlenmesi tehlikesi gelmektedir. Karşılaştırmalı hukukta ve uluslararası deneyimde yaşanan vakalar, yeterli insan denetimi ve hukuki güvence olmaksızın kullanılan otomatik karar

sistemlerinin, binlerce kişinin haklarını ihlal edebildiğini ve bu ihlallerin, ancak yıllar sonra ve büyük zararlar meydana geldikten sonra tespit edilip düzeltilebildiğini göstermiştir. Yapay zekâ sistemlerinin yetenekleri arttıkça, bu sistemlerin hatalarının tespit edilmesi ve düzeltilmesi daha da güçleşecektir.

Türk hukukunda, Anayasa'nın 6, 7, 9, 13, 20, 40, 125, 128, 129 ve 138. maddeleri, yapay zekânın kamusal kullanımının temel sınırlarını belirleyen güçlü ilkeler içermektedir. Ancak bu ilkelerin yapay zekâ bağlamında nasıl uygulanacağını belirleyen özel bir kanuni düzenleme bulunmamaktadır. Bu durum, hem hukuki belirsizliğe yol açmakta hem de Anayasa'nın 13. maddesi ve 104. maddesinin on yedinci fıkrası uyarınca, temel hakları etkileyen düzenlemelerin kanunla yapılması gereğini karşılamamaktadır. Ayrıca, yapay zekâ sistemlerini bütünlüklü bir biçimde değerlendirecek ve denetleyecek bir kurumun bulunmaması, yapay zekânın yol açtığı zararlara ilişkin sorumluluk kurallarının belirsizliği ve yapay zekâ alanındaki risklerin bildirilmesini güvence altına alan mekanizmaların eksikliği, giderilmesi gereken önemli boşluklardır.

Bu Kanun teklifi, söz konusu boşlukları gidermek amacıyla hazırlanmıştır. Teklif, yapay zekâ teknolojilerinin gelişimini ve kullanımını engellemeyi değil, bu gelişimin ve kullanımın, Anayasa'nın temel ilkeleriyle uyumlu, güvenli ve hesap verebilir bir biçimde gerçekleşmesini amaçlamaktadır. Teklif, risk temelli ve orantılı bir yaklaşım benimsemekte; düzenleyici yükümlülükleri, sistemlerin yeteneğine, kullanıldıkları kararların önemine ve etkiledikleri hakların niteliğine göre kademelendirmektedir.

Teklifin temel ilkeleri şunlardır: Yapay zekâ sistemlerinin bilişsel yetkinliği, kendi başına bağlayıcı karar yetkisi doğurmaz; devlet yetkisinin kullanılmasına ilişkin kararlar, yetkili organlara mensup insanlara atfedilir; yapay zekâ sistemlerinin kullanımı, düzeltilebilir ve durdurulabilir olmalıdır; yapay zekâ sistemlerinin denetimi, bağımsız ve çok katmanlı olmalı ve denetim kurumları da denetime tabi olmalıdır; ve yapay zekâ sistemlerinin her önemli kullanımı için, sonuçlardan kişisel olarak hesap verecek, adı belirli bir insan bulunmalıdır.

Teklif, Avrupa Birliği Yapay Zekâ Tüzüğü ve Avrupa Konseyi Yapay Zekâ Çerçeve Sözleşmesi başta olmak üzere, uluslararası düzenlemeler dikkate alınarak hazırlanmıştır. Teklifin bu düzenlemelerle uyumu, Türkiye'nin Avrupa Birliği ile gümrük birliği ilişkisi ve uluslararası

yükümlülükleri bakımından önem taşımaktadır. Bununla birlikte, teklif, söz konusu düzenlemelerin bazı eksikliklerini, özellikle denetim kurumlarının hesap verebilirliği, sınır yapay zekâ sistemlerinin durdurulabilirliği ve kişisel sorumluluk bakımından gidermeyi amaçlayan özgün hükümler de içermektedir.

III. Taslak Metin

YAPAY ZEKÂ SİSTEMLERİNİN DENETİMİ VE HESAP VEREBİLİRLİĞİ HAKKINDA KANUN TEKLİFİ (TASLAK)

BİRİNCİ KISIM — Genel Hükümler

Amaç

MADDE 1- (1) Bu Kanunun amacı; yapay zekâ sistemlerinin geliştirilmesi, piyasaya arzı ve kullanılmasının, Anayasada güvence altına alınan temel hak ve hürriyetlere, hukuk devleti, kuvvetler ayrılığı ve demokratik yönetim ilkelerine uygun olarak gerçekleşmesini sağlamak; yapay zekâ sistemlerinin kamusal kararlarda kullanılmasının usul ve esaslarını belirlemek; bu sistemlerin bağımsız ve etkin bir biçimde denetlenmesini ve bu sistemlerden kaynaklanan zararlar bakımından hesap verebilirliği güvence altına almaktır.

Kapsam

MADDE 2- (1) Bu Kanun; Türkiye'de piyasaya arz edilen, hizmete sunulan veya kullanılan yapay zekâ sistemleri ile bu sistemlerin çıktılarının Türkiye'de kullanıldığı hâlleri kapsar.

(2) Bu Kanunun kamusal kullanıma ilişkin hükümleri; kamu idareleri, kamu kurumu niteliğindeki meslek kuruluşları, yargı mercileri ile kamu hizmeti yürüten veya kamu adına hareket eden özel hukuk kişilerinin yapay zekâ sistemlerini kullanmalarına uygulanır.

(3) Münhasıran millî savunma amacıyla geliştirilen ve kullanılan yapay zekâ sistemlerine ilişkin usul ve esaslar özel kanunla düzenlenir. Bu sistemler bakımından da 4 üncü maddede sayılan ilkeler, 13 üncü maddede düzenlenen insan sorumluluğu ve 21 inci maddede düzenlenen durdurma kapasitesine ilişkin hükümler uygulanır.

(4) Münhasıran bilimsel araştırma amacıyla geliştirilen ve piyasaya arz edilmeyen veya hizmete sunulmayan yapay zekâ sistemlerine, üçüncü kısım hükümleri saklı kalmak kaydıyla, bu Kanun hükümleri uygulanmaz.

Tanımlar

MADDE 3- (1) Bu Kanunun uygulanmasında;

a) Algoritmik idari işlem: Tesis edilmesinde yapay zekâ sisteminin çıktısının belirleyici rol oynadığı idari işlemi,

b) Asli karar verici: Kanunla kendisine bir kararı verme yetkisi tanınan kamu görevlisini veya kurulu,

c) Ciddi olay: Bir yapay zekâ sisteminin işleyişi veya kullanımı nedeniyle doğrudan veya dolaylı olarak bir kişinin ölümüne veya sağlığının ciddi biçimde bozulmasına, kritik altyapının işleyişinin ciddi biçimde aksamasına, temel hak ve hürriyetlerin ciddi biçimde ihlaline veya mal ya da çevre bakımından ciddi zarara yol açan veya açma tehlikesi doğuran olayı,

ç) Hedef fonksiyonu: Bir yapay zekâ sisteminin eğitiminde veya kullanımında en iyilenmesi amaçlanan ölçüt veya ölçütler bütününü,

d) Kurum: Yapay Zekâ Denetim Kurumunu,

e) Kurul: Yapay Zekâ Denetim Kurulunu,

f) Sağlayıcı: Bir yapay zekâ sistemini veya genel amaçlı yapay zekâ modelini geliştiren veya geliştirten ve kendi adı veya ticari markası altında piyasaya arz eden veya hizmete sunan gerçek veya tüzel kişiyi,

g) Sınır yapay zekâ sistemi: 16 ncı madde uyarınca belirlenen eşikleri aşan genel amaçlı yapay zekâ modellerini ve bu modellere dayanan sistemleri,

ğ) Sorumlu yönetici: 30 uncu madde uyarınca atanan yapay zekâ sorumlu yöneticisini,

h) Uygulayıcı: Bir yapay zekâ sistemini kendi yetkisi altında kullanan gerçek veya tüzel kişiyi ya da kamu idaresini,

ı) Yapay zekâ sistemi: Değişen düzeylerde özerklikle çalışmak üzere tasarlanmış, kullanıma sunulduktan sonra uyum gösterebilen ve açık veya örtük hedefler doğrultusunda, aldığı girdiden, fiziksel veya sanal ortamları etkileyebilecek tahminler, içerik, öneriler veya kararlar gibi çıktıların nasıl üretileceğini çıkarsayan makine tabanlı sistemi,

i) Yüksek riskli kamusal kullanım: Kişilerin özgürlüğü, can ve vücut bütünlüğü, sosyal güvenlik ve sosyal yardım hakları, eğitim ve çalışma hakları, kamu hizmetlerine erişimi, yargılanma hakkı, yabancıların ülkeye

giriş ve ikamet hakları ile seçme ve seçilme hakkı bakımından hukuki sonuç doğuran veya onları benzer biçimde önemli ölçüde etkileyen kamusal kararlarda yapay zekâ sistemlerinin kullanılmasını,

ifade eder.

Temel ilkeler

MADDE 4- (1) Bu Kanunun uygulanmasında aşağıdaki ilkeler gözetilir:

a) Yetki-zekâ ayrılığı: Bir yapay zekâ sisteminin bilişsel yetkinliği, ne kadar üstün olursa olsun, kendi başına bağlayıcı karar yetkisi doğurmaz. Yapay zekâ sistemleri, devlet yetkisinin kullanılmasında karar vericiye bilgi ve öneri sunan araçlardır.

b) İnsan nihai kararı: Devlet yetkisinin kullanılmasına ilişkin kararlar, Anayasanın öngördüğü yetkili organlara mensup kişilerin iradesine atfedilir ve bu kişilerin sorumluluğu altındadır.

c) Düzeltilebilirlik ve durdurulabilirlik: Yapay zekâ sistemlerinin kullanımı, hataların zamanında tespit edilmesine ve düzeltilmesine imkân verecek biçimde tasarlanır. Her yapay zekâ sisteminin kullanımı, gerektiğinde ciddi bir zarara yol açmaksızın durdurulabilir olmalıdır.

ç) Aleniyet: Yapay zekâ sistemlerinin kamusal kullanımına ilişkin bilgiler, kanunda öngörülen gizlilik hâlleri dışında, kamuya açıktır.

d) Bağımsız denetim: Yapay zekâ sistemlerinin güvenliği ve hukuka uygunluğu, bu sistemleri geliştiren ve kullananlardan bağımsız kişi ve kurumlarca değerlendirilir. Denetim yetkisini kullanan kurumlar da bu Kanunda öngörülen usullerle denetlenir.

e) İnsan sorumluluğu: Yapay zekâ sistemlerinin kullanımından doğan sonuçlardan, bu sistemleri geliştiren, piyasaya arz eden, kullanan ve denetleyen kişiler sorumludur. Sorumluluk, yapay zekâ sistemine devredilemez.

f) Orantılılık: Bu Kanunda öngörülen yükümlülükler, yapay zekâ sisteminin yeteneği, kullanıldığı kararların önemi ve etkilediği hakların niteliği ile orantılı olarak uygulanır.

İKİNCİ KISIM — Yapay Zekâ Sistemlerinin Kamusal Kullanımı

Kanuni dayanak

MADDE 5- (1) Yapay zekâ sistemleri, yüksek riskli kamusal kullanım kapsamındaki kararlarda, ancak kanunda bu yönde açık bir hüküm bulunması hâlinde kullanılabilir. Bu hüküm; sistemin kullanılacağı kararların türünü, kullanım amacını ve kullanımın sınırlarını belirler.

(2) Yüksek riskli kamusal kullanım kapsamındaki kararlarda kullanılan yapay zekâ sistemlerinin karar kuralları, hedef fonksiyonu ve karar eşikleri, kanunda belirtilen amaçla uyumlu olmak zorundadır. Bu kurallar, bu Kanun ve ilgili kanunlar uyarınca düzenleyici işlemlere uygulanan yargısal denetime tabidir.

Tamamen otomatik idari işlemler

MADDE 6- (1) Bir idari işlem, ancak kanunla açıkça izin verilmiş olması ve işlemin takdir yetkisi veya değerlendirme alanı içermemesi kaydıyla, tamamen otomatik olarak tesis edilebilir.

(2) Tamamen otomatik olarak tesis edilen idari işlemlerde, ilgiliye, işlemin otomatik olarak tesis edildiği açıkça bildirilir ve ilgilinin, işlemin bir kamu görevlisi tarafından incelenmesini talep etme hakkı saklıdır.

Karar desteği ve takdir yetkisi

MADDE 7- (1) Takdir yetkisi içeren kararlarda, yapay zekâ sistemleri yalnızca karar destek aracı olarak kullanılabilir. Asli karar verici, somut olayın özelliklerini ve sistemin çıktısı dışındaki bilgi ve belgeleri bağımsız olarak değerlendirir ve sistemin önerisinden sapma imkânını gerçekten gözetir.

(2) Asli karar verici, yapay zekâ sisteminin önerisini benimsediği veya bu öneriden saptığı hâllerde, bu tercihin dayanağını karar kaydında belirtir.

(3) Asli kararı verenin, birinci fıkrada öngörülen bağımsız değerlendirmeyi yapmadan yapay zekâ sisteminin önerisini benimsemesi, takdir yetkisinin kullanılmaması niteliğinde olup, işlemin iptali sebebidir.

Olasılıksal sebep yasağı

MADDE 8- (1) Bir yapay zekâ sisteminin, kişinin belirli bir davranışta bulunma veya belirli bir niteliğe sahip olma olasılığına ilişkin tahmini, kendi başına, o kişinin aleyhine sonuç doğuran bir idari işlemin sebebi olamaz. Bu tür bir tahmin, ancak idarenin kişiye ilişkin somut olguları araştırması için gerekçe oluşturabilir. Aleyhe işlemin sebebi, kişiye özgü ve ispatlanmış olgulara dayandırılır.

Gerekçe

MADDE 9- (1) Algoritmik idari işlemler gerekçeli olarak tesis edilir. Gerekçe; işlemin hukuki dayanağını, kişiye özgü olgusal tespitleri ve yapay zekâ sisteminin işlemdeki rolünü gösterir.

(2) Gerekçe, asli karar verici tarafından oluşturulur. Yapay zekâ sisteminin ürettiği açıklama, gerekçenin dayanabileceği delillerden biri olup tek başına gerekçe yerine geçmez.

Bilgilendirme, açıklama ve itiraz hakkı

MADDE 10- (1) Yüksek riskli kamusal kullanım kapsamında, kendisi hakkında bir karar verilen kişi;

a) Kararın verilmesinde yapay zekâ sistemi kullanıldığını öğrenme,

b) Yapay zekâ sisteminin karar sürecindeki rolü, kararın başlıca unsurları ve kendisine ilişkin verilerin bu süreçte nasıl kullanıldığı hakkında açık ve anlamlı bilgi alma,

c) Karara, kararı değiştirme veya kaldırma yetkisine sahip bir kamu görevlisi önünde itiraz etme,

ç) Özgürlükten yoksun bırakma, sosyal güvenlik ve sosyal yardım haklarının kaldırılması, sınır dışı etme ve kamu görevinden çıkarma gibi ağır sonuçlar doğuran kararlarda, kararın bir kamu görevlisi tarafından anlamlı biçimde incelenmesini talep etme,

haklarına sahiptir.

(2) Ticari sır veya kamu güvenliği gerekçesiyle birinci fıkranın (b) bendi uyarınca kişiye açıklanamayan bilgiler, talep hâlinde, gizlilik yükümlülüğü altında mahkemeye, Kuruma veya kişinin avukatına açıklanır. Mahkeme veya Kurum, ilgili hak ve menfaatleri tartarak, kişinin erişim hakkının kapsamını belirler.

Kamu algoritma sicili

MADDE 11- (1) Kurum bünyesinde, kamuya açık bir Kamu Algoritma Sicili oluşturulur.

(2) Yüksek riskli kamusal kullanım kapsamında yapay zekâ sistemi kullanan kamu idareleri, sistemi kullanmaya başlamadan önce; sistemin adı ve sağlayıcısı, kullanım amacı ve kanuni dayanağı, hedef fonksiyonu ve başlıca karar kurallarının açıklaması, temel haklar etki değerlendirmesinin özeti, insan gözetimi önlemleri ve sorumlu yöneticinin kimliğine ilişkin bilgileri Sicile kaydettirir.

(3) Kamu güvenliği bakımından gizli tutulması zorunlu olan bilgiler, Sicilin kamuya açık bölümünde yer almaz; ancak Kuruma ve Türkiye Büyük Millet Meclisinin ilgili komisyonuna gizlilik kaydıyla bildirilir.

Sürüm kilidi ve kayıt tutma

MADDE 12- (1) Yüksek riskli kamusal kullanım kapsamında kullanılan yapay zekâ sistemleri, belgelendirilmiş belirli bir sürüm olarak kullanıma alınır. Sistemin davranışını önemli ölçüde değiştiren her güncelleme, yeni bir kullanıma alma işlemi olarak değerlendirilir ve 11 inci ve 13 üncü maddelerde öngörülen yükümlülüklere tabidir.

(2) Kullanım sırasında kendi karar kurallarını, uygulayıcının denetimi ve onayı olmaksızın değiştirebilen yapay zekâ sistemleri, yüksek riskli kamusal kullanım kapsamındaki kararların münhasır dayanağı olarak kullanılamaz.

(3) Her algoritmik idari işlemin kaydında, işlemin tesisinde kullanılan sistem sürümü, sisteme sağlanan girdiler ve sistemin çıktısı belirtilir. Bu kayıtlar ve ilgili sistem sürümü, işlemin yargısal denetimi için yeniden üretilebilir biçimde, kanunda öngörülen dava açma sürelerinin sonuna kadar ve her hâlükârda en az on yıl süreyle saklanır.

Temel haklar etki değerlendirmesi ve insan sorumluluğu

MADDE 13- (1) Yüksek riskli kamusal kullanım kapsamında yapay zekâ sistemi kullanacak kamu idareleri, sistemi kullanmaya başlamadan önce, sistemin temel haklar üzerindeki etkisine ilişkin bir değerlendirme yapar. Bu değerlendirme; sistemin kullanılacağı süreçleri, sistemden etkilenebilecek kişi ve grupları, ayrımcılık riskleri dâhil olmak üzere ortaya çıkabilecek zarar risklerini, insan gözetimi önlemlerini, risklerin gerçekleşmesi hâlinde alınacak önlemleri ve sistemin kullanımının durdurulmasına ilişkin usulleri içerir.

(2) Değerlendirme, Kuruma sunulur. Kurum, değerlendirmeyi inceleyerek, sistemin kullanımına izin verebilir, izni ek koşullara bağlayabilir veya izin vermeyebilir. Kurum, Yönetmelikle belirlenen hâllerde, sistemin bağımsız bir değerlendirici tarafından incelenmesini şart koşabilir.

(3) Yapay zekâ sistemlerinin kullanımında insan gözetimi görevi, gerekli yetkinliğe, eğitime, yetkiye ve desteğe sahip kişilere verilir. Bu kişilere, sistemin çıktısını göz ardı etme, geçersiz kılma ve sistemin kullanımını askıya alma yetkisi tanınır. Gözetim görevini yürüten kişinin,

sahip olmadığı yetki ve bilgi nedeniyle önleyemediği zararlardan dolayı sorumluluğu, bu yetki ve bilgiyi sağlamakla yükümlü olanlara yönelir.

Kurumsal kapasite ve vazgeçebilirlik

MADDE 14- (1) Yüksek riskli kamusal kullanım kapsamında yapay zekâ sistemi kullanan kamu idareleri;

a) Sistemin başarımını, hata oranlarını ve farklı gruplar üzerindeki etkilerini düzenli olarak ölçer ve sonuçlarını Kuruma bildirir,

b) Sistemin kullanılamaz hâle gelmesi veya kullanımının durdurulması hâlinde, ilgili kamu hizmetinin makul bir kalite ve süre içinde sistemsiz olarak yürütülebilmesi için gerekli asgari insan kapasitesini ve acil durum planını muhafaza eder,

c) Sistemin temini için yapılan sözleşmelerde; sağlayıcının, sistemin işleyişine ilişkin bilgi ve belgeleri idareye, Kuruma ve yargı mercilerine sağlama yükümlülüğünü, sistemin hatalarından doğan zararlar bakımından sorumluluğunu ve idarenin sistemden vazgeçmesi hâlinde verilerin ve ilgili bilgilerin idareye devrini düzenler.

(2) Kurum, birinci fıkranın (a) bendi uyarınca yapılan bildirimleri değerlendirerek, kamu idarelerinin yapay zekâ sistemlerine bağımlılık düzeyine ilişkin yıllık bir rapor hazırlar ve Türkiye Büyük Millet Meclisine sunar.

Yargı alanında kullanım

MADDE 15- (1) Yargı yetkisi, yapay zekâ sistemlerine devredilemez. Hâkim ve savcılar, yapay zekâ sistemlerinden ancak kendi bağımsız değerlendirmelerini destekleyen bilgi ve analiz araçları olarak yararlanabilir.

(2) Uyuşmazlığın esasına ilişkin sonuç önerisi sunan yapay zekâ sistemleri, yargılamada kullanılamaz.

(3) Yargı alanında kullanılacak yapay zekâ sistemlerinin seçimi, değerlendirilmesi ve denetimi, Hâkimler ve Savcılar Kurulu tarafından, Kurumun teknik görüşü alınarak yürütülür. Bu sistemlere ilişkin bilgiler, 11 inci madde uyarınca Sicile kaydedilir.

(4) Hâkim ve savcıların kimlik bilgilerinin, onların mesleki uygulamalarını değerlendirmek, analiz etmek, karşılaştırmak veya tahmin etmek amacıyla işlenmesi yasaktır.

ÜÇÜNCÜ KISIM — Sınır Yapay Zekâ Sistemleri

Sınır sistemlerin belirlenmesi

MADDE 16- (1) Eğitiminde kullanılan toplam hesaplama miktarı, Kurul tarafından belirlenen eşiği aşan veya Kurul tarafından, yetenekleri bakımından bu eşiği aşan modellere denk olduğu tespit edilen genel amaçlı yapay zekâ modelleri, sınır yapay zekâ sistemi sayılır.

(2) Kurul, birinci fıkrada belirtilen eşiği belirlerken, teknolojik gelişmeleri ve uluslararası düzenlemeleri dikkate alır ve eşiği en az iki yılda bir gözden geçirir.

Bildirim

MADDE 17- (1) Türkiye'de sınır yapay zekâ sistemi geliştirmek amacıyla bir modelin eğitimine başlayacak olanlar, eğitime başlamadan önce; eğitimin amacını, öngörülen hesaplama miktarını, uygulanacak güvenlik önlemlerini ve eğitim sonrasında yapılacak değerlendirmeleri Kuruma bildirir.

(2) Türkiye'de sınır yapay zekâ sistemini piyasaya arz eden veya hizmete sunan sağlayıcılar, piyasaya arzdan veya hizmete sunmadan önce Kuruma kayıt yaptırır.

Güvenlik çerçevesi ve değerlendirme

MADDE 18- (1) Sınır yapay zekâ sistemlerinin sağlayıcıları;

a) Sistemlerinin yol açabileceği ciddi riskleri, bu risklerin değerlendirilmesine ilişkin yöntemleri ve belirli yetenek düzeylerine ulaşılması hâlinde alınacak önlemleri gösteren bir güvenlik çerçevesi hazırlar, uygular ve kamuya açıklar,

b) Sistemlerini, piyasaya arzdan önce ve kullanım süresince düzenli aralıklarla, düşmanca testler dâhil olmak üzere değerlendirir ve sonuçlarını belgelendirir,

c) Sistemlerinin izlenebilirliğini ve denetlenebilirliğini önemli ölçüde azaltan geliştirme kararlarını, gerekçesiyle birlikte Kuruma bildirir,

ç) Birinci fıkranın (a) bendinde belirtilen çerçevede yapılan değişiklikleri, gerekçesiyle birlikte Kuruma bildirir ve kamuya açıklar.

(2) Değerlendirmelerin yapılması ve belgelendirilmesi, sağlayıcının yükümlülüğüdür. Bu yükümlülüğe uygun olarak yapılan değerlendirmelerde tespit edilip belgelendirilen ve bu tespite uygun

önlemler alınan riskler bakımından, belgelendirmenin kendisi sağlayıcının aleyhine kusur karinesi oluşturmaz.

Bağımsız değerlendirme ve erişim

MADDE 19- (1) Kurum, sınır yapay zekâ sistemlerini doğrudan veya yetkilendirdiği bağımsız değerlendiriciler aracılığıyla değerlendirebilir. Sağlayıcılar, bu değerlendirme için gerekli erişimi, uygun gizlilik ve güvenlik önlemleri altında sağlamakla yükümlüdür.

(2) Kurum, değerlendirme sonuçlarının özetini, ticari sırları ve kamu güvenliğini zedelemeyecek biçimde kamuya açıklar.

Ciddi olay bildirimi

MADDE 20- (1) Sınır yapay zekâ sistemlerinin sağlayıcıları ile yüksek riskli kamusal kullanım kapsamındaki uygulayıcılar, öğrendikleri ciddi olayları gecikmeksizin ve her hâlükârda yetmiş iki saat içinde Kuruma bildirir.

(2) Kurum, ciddi olaylara ilişkin bildirimleri ve kendi tespitlerini içeren bir olay veri tabanı oluşturur ve kişisel verileri, ticari sırları ve kamu güvenliğini zedelemeyecek biçimde kamuya açık tutar. Herkes, yapay zekâ sistemlerine ilişkin olayları Kuruma bildirebilir.

Durdurma yükümlülüğü ve kapasitesi

MADDE 21- (1) Sınır yapay zekâ sistemlerinin sağlayıcıları ile yüksek riskli kamusal kullanım kapsamındaki uygulayıcılar, sistemlerinin kullanımını, gerektiğinde güvenli bir biçimde ve gecikmeksizin durdurabilecek teknik ve örgütsel kapasiteyi kurar, bu kapasiteyi düzenli olarak sınar ve sonuçlarını Kuruma bildirir.

(2) Bir yapay zekâ sisteminin kişilerin hayatı, sağlığı, temel hak ve hürriyetleri veya kamu düzeni bakımından ciddi ve yakın bir tehlike oluşturduğunu öğrenen sağlayıcı veya uygulayıcı, tehlikeyi gidermek için gerekli önlemleri derhâl alır; tehlikenin başka bir yolla giderilemediği hâllerde sistemin kullanımını durdurur.

(3) Kurul, bir yapay zekâ sisteminin birinci fıkrada belirtilen nitelikte ciddi ve yakın bir tehlike oluşturduğu kanaatine vardığında, sistemin kullanımının geçici olarak durdurulmasına karar verebilir. Gecikmesinde sakınca bulunan hâllerde bu kararı Kurul Başkanı alır ve en geç yirmi dört saat içinde Kurulun onayına sunar.

(4) Üçüncü fıkra uyarınca durdurulan bir sistemin kullanımına yeniden başlanması, Kurulun üye tam sayısının üçte iki çoğunluğuyla alacağı kararla ve Bilimsel Danışma Kurulunun görüşü alınarak mümkündür.

(5) Bu madde uyarınca alınan durdurma kararlarına karşı açılan davalar ivedilikle görülür. Durdurma kararlarına karşı açılan davalarda yürütmenin durdurulması kararı, ancak tehlikenin bulunmadığının açıkça anlaşılması hâlinde verilebilir.

Hesaplama hizmeti sağlayıcılarının yükümlülükleri

MADDE 22- (1) Türkiye'de üçüncü kişilere büyük ölçekli hesaplama kapasitesi sunan hizmet sağlayıcıları, Kurul tarafından belirlenen eşiği aşan hesaplama talepleri bakımından müşterilerinin kimliğini tespit eder, talebin amacına ilişkin beyan alır ve bu bilgileri Yönetmelikle belirlenen süre boyunca saklar.

(2) Hizmet sağlayıcılar, birinci fıkra kapsamındaki bir talebin 17 nci maddede öngörülen bildirim yükümlülüğüne aykırı olarak bir sınır yapay zekâ sisteminin eğitimine yönelik olduğuna dair ciddi emareler bulunması hâlinde, durumu Kuruma bildirir.

DÖRDÜNCÜ KISIM — Yapay Zekâ Denetim Kurumu

Kuruluş

MADDE 23- (1) Bu Kanunla verilen görevleri yerine getirmek üzere, kamu tüzel kişiliğini haiz, idari ve mali özerkliğe sahip Yapay Zekâ Denetim Kurumu kurulmuştur. Kurumun merkezi Ankara'dır.

(2) Kurum, görevlerini yerine getirirken bağımsızdır. Hiçbir organ, makam, merci veya kişi, Kurumun görev alanına giren konularda Kurula ve Kurum personeline emir ve talimat veremez, tavsiye ve telkinde bulunamaz.

Kurul

MADDE 24- (1) Kurumun karar organı Yapay Zekâ Denetim Kuruludur. Kurul, dokuz üyeden oluşur.

(2) Kurul üyelerinin dördü Türkiye Büyük Millet Meclisi tarafından, siyasi parti gruplarının üye sayısı oranında belirlenecek aday listesinden, üye tam sayısının üçte iki çoğunluğuyla; biri Yargıtay Büyük Genel Kurulu, biri Danıştay Genel Kurulu tarafından kendi üyeleri dışından; biri Yükseköğretim Kurulu tarafından bilgisayar bilimleri alanında profesör

unvanına sahip kişiler arasından; biri Türkiye Barolar Birliği tarafından; biri de Türkiye İnsan Hakları ve Eşitlik Kurumu tarafından seçilir. Türkiye Büyük Millet Meclisinde ilk iki turda gerekli çoğunluk sağlanamazsa, üçüncü turda üye tam sayısının salt çoğunluğu aranır.

(3) Kurul üyelerinin görev süresi yedi yıldır. Bir kişi, iki defa Kurul üyesi seçilemez.

(4) Kurul üyeleri; ağır cezalık bir suçtan veya göreviyle ilgili bir suçtan mahkûmiyet, görevini yerine getiremeyecek şekilde sağlığını kaybetme veya bu Kanunda belirtilen yasaklara aykırı davranma hâlleri dışında, görev süreleri dolmadan görevden alınamaz. Görevden alma kararlarına karşı Danıştayda dava açılabilir.

(5) Kurul üyeleri, görev süreleri boyunca ve görevlerinin sona ermesinden itibaren üç yıl süreyle, Kurumun denetimine tabi kişi ve kuruluşlarda görev alamaz ve bunlarla doğrudan veya dolaylı çıkar ilişkisi kuramaz.

Görev ve yetkiler

MADDE 25- (1) Kurumun görev ve yetkileri şunlardır:

a) Bu Kanunun ve ilgili mevzuatın uygulanmasını denetlemek,

b) Kamu Algoritma Sicilini ve sınır yapay zekâ sistemlerine ilişkin kayıtları tutmak,

c) Yüksek riskli kamusal kullanımlara ilişkin temel haklar etki değerlendirmelerini incelemek ve kullanım izni vermek,

ç) Yapay zekâ sistemlerini değerlendirmek, bu amaçla teknik değerlendirme kapasitesi oluşturmak ve bağımsız değerlendiricileri yetkilendirmek,

d) Bu Kanunun uygulanmasına ilişkin yönetmelikleri çıkarmak,

e) Kişi ve kuruluşlardan bilgi ve belge istemek, yerinde inceleme yapmak,

f) Bu Kanuna aykırılıklar hâlinde idari yaptırım uygulamak ve 21 inci madde uyarınca durdurma kararı vermek,

g) Kişisel Verileri Koruma Kurumu, Türkiye İnsan Hakları ve Eşitlik Kurumu, Kamu Denetçiliği Kurumu, Rekabet Kurumu ve sektörel düzenleyici kurumlarla işbirliği yapmak; bu amaçla oluşturulan Yapay Zekâ Denetimi Koordinasyon Kurulunun sekreterya hizmetlerini yürütmek,

ğ) Uluslararası kuruluşlar ve diğer ülkelerin yetkili makamlarıyla işbirliği yapmak,

h) Yapay zekâ alanındaki gelişmeleri izlemek ve ilgili kamu kurumlarına ve Türkiye Büyük Millet Meclisine görüş bildirmek.

Kurumun hesap verebilirliği

MADDE 26- (1) Kurum, her yıl, faaliyetleri, aldığı kararlar, uyguladığı yaptırımlar, yaptığı değerlendirmeler ve yapay zekâ alanındaki genel durum hakkında bir rapor hazırlar. Rapor, Türkiye Büyük Millet Meclisine sunulur ve kamuya açıklanır. Kurul Başkanı, Türkiye Büyük Millet Meclisinin ilgili komisyonunda rapor hakkında bilgi verir.

(2) Kurumun kararları, idari yargı denetimine tabidir. Kurumun düzenleyici işlemlerine karşı Danıştayda dava açılabilir.

(3) Kurumun hesapları ve faaliyetlerinin etkinliği, Sayıştay denetimine tabidir.

(4) Kurumun işlem ve eylemlerine ilişkin şikâyetler, Kamu Denetçiliği Kurumuna yapılabilir.

(5) Kurum, kararlarını, değerlendirme yöntemlerini ve denetim raporlarını, kanunda öngörülen gizlilik hâlleri dışında, kamuya açıklar.

(6) Kurumun faaliyetleri ve bu Kanunun uygulanması, her beş yılda bir, Türkiye Büyük Millet Meclisi tarafından görevlendirilecek bağımsız bir kurul tarafından değerlendirilir ve değerlendirme raporu kamuya açıklanır.

Bağımsız değerlendiricilerin yetkilendirilmesi ve denetimi

MADDE 27- (1) Yapay zekâ sistemlerinin bu Kanun uyarınca bağımsız değerlendirmesini yapacak kişi ve kuruluşlar, Kurum tarafından yetkilendirilir.

(2) Kurum, bağımsız değerlendiricilerin uyması gereken değerlendirme standartlarını ve bağımsızlık kurallarını belirler; değerlendiricilerin çalışmalarını düzenli olarak inceler; standartlara ve kurallara uymayan değerlendiricilerin yetkisini askıya alır veya iptal eder.

(3) Bir sağlayıcı veya uygulayıcı, aynı bağımsız değerlendiriciyi, aynı sistem bakımından, Yönetmelikle belirlenen süreden fazla kullanamaz.

Bilimsel Danışma Kurulu ve nitelikli uyarı

MADDE 28- (1) Kurum bünyesinde, yapay zekâ ve ilgili alanlarda uzman, Kurumun denetimine tabi kişi ve kuruluşlarla çıkar ilişkisi

bulunmayan bilim insanlarından oluşan bir Bilimsel Danışma Kurulu oluşturulur.

(2) Bilimsel Danışma Kurulu, Kurumun değerlendirme yöntemlerini inceler ve görüş bildirir.

(3) Bilimsel Danışma Kurulu, bir yapay zekâ sisteminin ciddi bir risk oluşturduğuna dair ciddi emareler tespit ettiğinde, Kurula ve Türkiye Büyük Millet Meclisinin ilgili komisyonuna gerekçeli bir nitelikli uyarı iletebilir. Kurul, nitelikli uyarıyı otuz gün içinde değerlendirerek, aldığı önlemleri veya önlem almama gerekçesini açıklar.

Yapay Zekâ Yurttaş Meclisi

MADDE 29- (1) Kurum, en az iki yılda bir, yapay zekânın kamusal kullanımına ilişkin temel değer tercihlerinin tartışılması amacıyla, kura ile seçilen ve nüfusun demografik bileşimini yansıtan bir Yapay Zekâ Yurttaş Meclisi düzenler.

(2) Yurttaş Meclisinin önerileri bağlayıcı değildir. Kurum ve ilgili kamu kurumları, önerileri değerlendirir ve benimsemedikleri öneriler için gerekçe açıklar.

BEŞİNCİ KISIM — Sorumluluk

Yapay zekâ sorumlu yöneticisi

MADDE 30- (1) Sınır yapay zekâ sistemlerinin sağlayıcıları her sistem için; yüksek riskli kamusal kullanım kapsamında yapay zekâ sistemi kullanan kamu idareleri her kullanım için, bir yapay zekâ sorumlu yöneticisi atar ve Kuruma bildirir.

(2) Sorumlu yöneticinin sorumluluk alanı, Kuruma sunulan ve kamuya açık olan bir sorumluluklar beyanında belirtilir.

(3) Sorumlu yönetici, sistemin güvenliğine ve kullanımına ilişkin bilgilere erişim ve sistemin kullanımını askıya alma yetkisine sahiptir. Bu yetki, sorumlu yöneticinin bağlı olduğu kişi veya kuruluşça kısıtlanamaz.

(4) Sorumlu yöneticinin sorumluluk alanında bu Kanuna aykırılık veya ciddi bir olay meydana geldiğinde, sorumlu yönetici, bu aykırılığın veya olayın önlenmesi için makul önlemleri aldığını ispat edemezse, 36 ncı maddenin dördüncü fıkrasında öngörülen yaptırıma tabi tutulur.

Tehlike sorumluluğu

MADDE 31- (1) Sınır yapay zekâ sistemlerinin geliştirilmesi ve işletilmesi, 11/1/2011 tarihli ve 6098 sayılı Türk Borçlar Kanununun 71 inci maddesi anlamında önemli ölçüde tehlike arz eden işletme faaliyeti sayılır.

(2) Sınır yapay zekâ sisteminin faaliyetinden doğan zarardan, sistemin sağlayıcısı ile sistemi kendi faaliyetinde kullanan uygulayıcı, zarar görene karşı müteselsilen sorumludur. Sağlayıcı ile uygulayıcı arasındaki iç ilişkide sorumluluk, aralarındaki sözleşme ve kusur durumlarına göre belirlenir.

Zorunlu mali güvence

MADDE 32- (1) Sınır yapay zekâ sistemlerinin sağlayıcıları, Kurul tarafından belirlenecek tutarda bir sorumluluk sigortası yaptırmak veya eşdeğer bir mali güvence sağlamakla yükümlüdür.

Yapay Zekâ Tazmin Fonu

MADDE 33- (1) Yapay zekâ sistemlerinin yol açtığı ve sorumlusu tespit edilemeyen veya sorumlunun ödeme gücünü aşan zararların, Yönetmelikle belirlenen sınırlar içinde tazmini amacıyla, Kurum bünyesinde Yapay Zekâ Tazmin Fonu oluşturulur.

(2) Fonun gelirleri; sınır yapay zekâ sistemleri sağlayıcılarının ve Yönetmelikle belirlenen diğer sağlayıcıların katkı paylarından, bu Kanun uyarınca uygulanan idari para cezalarının Yönetmelikle belirlenen oranından ve diğer gelirlerden oluşur.

İdarenin sorumluluğu

MADDE 34- (1) İdare, yapay zekâ sistemlerinin seçimi, doğrulanması, izlenmesi, gerektiğinde durdurulması ve ilgililerin bilgilendirilmesine ilişkin yükümlülüklerini yerine getirmemesinden doğan zararları tazminle yükümlüdür.

(2) Yüksek riskli kamusal kullanım kapsamında kullanılan yapay zekâ sistemlerinin işleyişinden doğan ve ilgili bakımından özel ve olağandışı nitelik taşıyan zararlar, idarenin kusuru aranmaksızın tazmin edilir.

(3) İdarenin, zararın doğmasında kusuru bulunan kamu görevlilerine ve sistemi sağlayan kişilere rücu hakkı saklıdır.

İhbarcıların korunması

MADDE 35- (1) Bir yapay zekâ sisteminin bu Kanuna aykırı olarak geliştirildiğine, piyasaya arz edildiğine veya kullanıldığına ya da kişilerin

hayatı, sağlığı, temel hak ve hürriyetleri veya kamu düzeni bakımından ciddi bir risk oluşturduğuna dair makul gerekçelere dayanarak Kuruma, Türkiye Büyük Millet Meclisinin ilgili komisyonuna veya diğer yetkili makamlara bildirimde bulunan kişiler, bu bildirim nedeniyle işten çıkarılamaz, disiplin yaptırımına tabi tutulamaz ve herhangi bir misillemeye maruz bırakılamaz.

(2) Birinci fıkra kapsamındaki bildirimleri engelleyen veya sınırlayan sözleşme hükümleri geçersizdir.

(3) Bildirimde bulunan kişinin kimliği, kişinin rızası olmaksızın açıklanamaz.

(4) Bildirimde bulunduktan sonra aleyhine bir işlem tesis edilen kişinin, bu işlemin bildirimle ilgili olduğuna dair güçlü emareler ortaya koyması hâlinde, işlemin bildirimle ilgili olmadığını ispat yükü karşı tarafa aittir.

ALTINCI KISIM — Yaptırımlar

İdari yaptırımlar

MADDE 36- (1) 17, 18, 19, 20, 21 ve 22 nci maddelerde öngörülen yükümlülüklere aykırı davranan sağlayıcı ve hizmet sağlayıcılara, bir önceki mali yıla ait yıllık gayrisafi gelirlerinin yüzde üçüne kadar idari para cezası verilir.

(2) 21 inci madde uyarınca verilen durdurma kararına uymayanlara, bir önceki mali yıla ait yıllık gayrisafi gelirlerinin yüzde yedisine kadar idari para cezası verilir.

(3) Kurum, birinci ve ikinci fıkralarda belirtilen aykırılıkların tekrarı hâlinde, ilgili sistemin Türkiye'de piyasaya arzını veya kullanımını yasaklayabilir.

(4) 30 uncu maddenin dördüncü fıkrası kapsamında sorumluluğu tespit edilen sorumlu yöneticiye, Yönetmelikle belirlenen tutarda idari para cezası verilir ve sorumlu yöneticinin, beş yıla kadar, bu Kanun kapsamındaki sistemlerde sorumlu yönetici olarak görev alması yasaklanabilir.

(5) Kamu idarelerinin bu Kanundan doğan yükümlülüklerini yerine getirmemesi hâlinde, Kurum, ilgili kullanımın askıya alınmasına karar verir ve durumu ilgili idarenin bağlı veya ilgili olduğu makama ve Türkiye Büyük Millet Meclisine bildirir. Sorumlu kamu görevlileri hakkında disiplin hükümleri saklıdır.

(6) İdari para cezasının belirlenmesinde, aykırılığın ağırlığı, süresi, yol açtığı zarar, failin kusur derecesi ve işbirliği tutumu dikkate alınır.

Suçlar

MADDE 37- (1) 21 inci maddenin ikinci fıkrasında öngörülen yükümlülüğü, kişilerin hayatı veya sağlığı bakımından ciddi ve yakın bir tehlikenin varlığını bilmesine rağmen yerine getirmeyen sağlayıcı veya uygulayıcı adına hareket eden kişi, fiili daha ağır cezayı gerektiren bir suç oluşturmadığı takdirde, bir yıldan beş yıla kadar hapis cezası ile cezalandırılır.

(2) Kuruma, bu Kanun uyarınca sunulması gereken güvenlik değerlendirmelerinde veya ciddi olay bildirimlerinde, bir yapay zekâ sisteminin güvenliğine ilişkin esaslı bir hususta gerçeğe aykırı bilgi veren veya bu hususu bilerek gizleyen kişi, altı aydan üç yıla kadar hapis cezası ile cezalandırılır.

(3) Kurumun veya yetkilendirdiği bağımsız değerlendiricilerin bu Kanun uyarınca yaptığı denetimi hile veya cebir kullanarak engelleyen kişi, altı aydan iki yıla kadar hapis cezası ile cezalandırılır.

(4) Bu maddede tanımlanan suçların bir tüzel kişinin faaliyeti çerçevesinde işlenmesi hâlinde, tüzel kişi hakkında 26/9/2004 tarihli ve 5237 sayılı Türk Ceza Kanununun 60 ıncı maddesi ile 30/3/2005 tarihli ve 5326 sayılı Kabahatler Kanununun 43/A maddesi hükümleri uygulanır.

YEDİNCİ KISIM — Son Hükümler

Değiştirilen hükümler

MADDE 38- (1) 24/3/2016 tarihli ve 6698 sayılı Kişisel Verilerin Korunması Kanununun 11 inci maddesinin birinci fıkrasının (g) bendi aşağıdaki şekilde değiştirilmiş ve fıkraya aşağıdaki bent eklenmiştir:

“g) İşlenen verilerin münhasıran veya belirleyici ölçüde otomatik sistemler vasıtasıyla analiz edilmesi suretiyle kişinin kendisi aleyhine bir sonucun ortaya çıkmasına itiraz etme ve bu sonucun bir insan tarafından incelenmesini talep etme,

ğ) (g) bendinde belirtilen hâllerde, işlemenin dayandığı mantık ve kişi bakımından öngörülen sonuçları hakkında anlamlı bilgi talep etme,”

(2) Türkiye Büyük Millet Meclisi İçtüzüğünde yapılacak değişiklikle, Meclis Başkanlığına bağlı bir Bilim ve Teknoloji Değerlendirme Birimi ile

yapay zekâ ve dijital teknolojiler alanında daimi bir ihtisas komisyonu kurulur.

Gözden geçirme ve geçiş hükümleri

MADDE 39- (1) Bu Kanunun uygulanması, yürürlüğe girdiği tarihten itibaren üç yıl içinde ve bundan sonra her beş yılda bir, 26 ncı maddenin altıncı fıkrası uyarınca değerlendirilir.

(2) Bu Kanunun yürürlüğe girdiği tarihte yüksek riskli kamusal kullanım kapsamında kullanılmakta olan yapay zekâ sistemleri bakımından, ilgili kamu idareleri, bu Kanunun ikinci kısmında öngörülen yükümlülükleri, Kanunun yürürlüğe girdiği tarihten itibaren bir yıl içinde yerine getirir. Bu süre içinde yükümlülüklerin yerine getirilmemesi hâlinde, sistemin kullanımı Kurum tarafından askıya alınır.

Yürürlük

MADDE 40- (1) Bu Kanunun;

a) Dördüncü kısmı yayımı tarihinde,

b) Birinci, ikinci ve beşinci kısımları yayımı tarihinden itibaren bir yıl sonra,

c) Diğer hükümleri yayımı tarihinden itibaren altı ay sonra,

yürürlüğe girer.

Yürütme

MADDE 41- (1) Bu Kanun hükümlerini Cumhurbaşkanı yürütür.

IV. Seçilmiş Madde Gerekçeleri

Madde 4 (Temel ilkeler). Madde, Kanunun yorumunda ve uygulanmasında yol gösterecek temel ilkeleri belirlemektedir. Bu ilkeler, çalışmanın Üçüncü Bölüm'de geliştirdiği yetki-zekâ ayrılığı ilkesine, Beşinci Bölüm'de Anayasa'nın 6, 7, 9 ve 138. maddelerinden türetilen insan nihai karar ilkesine, Birinci ve Dördüncü Bölümlerde Popper ve Collingridge'den türetilen düzeltilebilirlik ilkesine, Kant'ın aleniyet ilkesine, Kelsen'in bağımsız denetim ilkesine ve Altıncı Bölüm'de geliştirilen insan sorumluluğu ilkesine dayanmaktadır. Maddenin (e) bendindeki "Sorumluluk, yapay zekâ sistemine devredilemez" ifadesi, uluslararası toplumun otonom silahlar bağlamında üzerinde uzlaştığı "hesap verebilirlik makinelere devredilemez" ilkesinin genelleştirilmiş bir

ifadesidir ve yapay zekâya elektronik kişilik tanınması yoluyla sorumluluğun buharlaştırılmasını önlemeyi amaçlamaktadır.

Madde 5 (Kanuni dayanak). Madde, Anayasa'nın 13. maddesi ve 104. maddesinin on yedinci fıkrası uyarınca, temel hakları etkileyen kararlarda yapay zekâ kullanımının kanuni dayanağa sahip olmasını şart koşmaktadır. Maddenin ikinci fıkrası, çalışmanın Beşinci Bölüm'de geliştirdiği "algoritmik normlar" kavramına dayanarak, yapay zekâ sistemlerinin karar kurallarını ve hedef fonksiyonunu, işlevsel olarak düzenleyici işlemler gibi yargısal denetime tabi kılmaktadır. Bu hüküm, aynı zamanda, "hedef fonksiyonu-maksat uygunluğu" ölçütünü pozitif hukuka aktarmaktadır.

Madde 6 (Tamamen otomatik idari işlemler). Madde, Alman İdari Usul Kanunu'nun 35a maddesinden esinlenerek, tamamen otomatik idari işlemleri, kanunla açıkça izin verilmiş ve takdir yetkisi içermeyen durumlarla sınırlandırmaktadır. Bu sınırlama, takdir yetkisinin kullanılmasının, kanun koyucunun kamu görevlilerine emanet ettiği bir görev olduğu ve bir makineye devredilemeyeceği ilkesine dayanmaktadır.

Madde 7 (Karar desteği ve takdir yetkisi). Madde, otomasyon yanlılığının hukuki sonuçlarını düzenlemektedir. Üçüncü fıkra, kamu görevlisinin, bağımsız bir değerlendirme yapmaksızın sistemin önerisini benimsemesini, "takdir yetkisinin kullanılmaması" olarak nitelendirmekte ve bunu bir iptal sebebi olarak öngörmektedir. Bu hüküm, Avrupa Birliği Adalet Divanı'nın *SCHUFA* kararındaki, biçimsel olarak bir insanın son kararı verdiği, ama fiilen otomatik sistemin belirleyici olduğu durumlarda kararın otomatik karar sayılacağı yönündeki yaklaşımına paralel bir sonuç doğurmaktadır.

Madde 8 (Olasılıksal sebep yasağı). Madde, çalışmanın Beşinci Bölüm'de geliştirdiği olasılıksal sebep yasağını pozitif hukuka aktarmaktadır. Bu yasak, Robodebt ve Hollanda çocuk bakım yardımları gibi vakalarda, kişiler hakkındaki aleyhe kararların, kişiye özgü olgulara değil, istatistiksel varsayımlara ve risk profillerine dayandırılmasından çıkarılan dersin hukuki ifadesidir.

Madde 9 (Gerekçe). Madde, açıklama ile gerekçe arasındaki ayrımı ve gerekçenin insan tarafından oluşturulması ilkesini düzenlemektedir. Bu ilke, ileri yapay zekâ sistemlerinin ifade ettiği gerekçelerin, gerçek karar süreçlerini her zaman sadık biçimde yansıtmadığına ve gerekçeler üzerinde

baskı kurulduğunda gizlemeye yönelebileceğine ilişkin bulgulara dayanmaktadır.

Madde 12 (Sürüm kilidi ve kayıt tutma). Madde, Fransız Anayasa Konseyi'nin 2018 tarihli kararında vurguladığı "hâkimiyet" şartını ve kendini değiştiren algoritmalara ilişkin yasağı Türk hukukuna aktarmaktadır. Sürüm kilidi, belirlilik ve öngörülebilirlik ilkelerini, yargısal denetimin etkinliğini ve test edilmiş bir sistemin kullanım sırasında farklı bir sisteme dönüşmesinin önlenmesini amaçlamaktadır.

Madde 14 (Kurumsal kapasite ve vazgeçebilirlik). Madde, çalışmanın İkinci Bölüm'de tespit ettiği "kurumsal bilişsel körelme" olgusuna ve Dördüncü Bölüm'de geliştirdiği "algoritmik vesayet" kavramına karşı bir güvence öngörmektedir. Kamu idarelerinin, sistemsiz çalışabilecek asgari insan kapasitesini muhafaza etmesi ve sistemlerden vazgeçmeyi mümkün kılacak sözleşme hükümleri öngörmesi, Popper'ci düzeltilebilirlik ilkesinin kurumsal düzeydeki uygulamasıdır.

Madde 15 (Yargı alanında kullanım). Madde, Anayasa'nın 9, 37 ve 138. maddelerinden türetilen sınırları somutlaştırmaktadır. İkinci fıkradaki, uyuşmazlığın esasına ilişkin sonuç önerisi sunan sistemlerin kullanılamayacağına ilişkin hüküm, hem hâkimin vicdani kanaatine dayanan hüküm verme yükümlülüğünü korumayı, hem de Anayasa'nın 138. maddesinin ikinci fıkrasındaki "tavsiye ve telkin" yasağının yapay zekâ araçları aracılığıyla dolaylı olarak ihlal edilmesini önlemeyi amaçlamaktadır. Dördüncü fıkra, Fransız hukukundaki hâkim analitiği yasağından esinlenmiştir.

Madde 18 (Güvenlik çerçevesi ve değerlendirme). Maddenin ikinci fıkrası, çalışmanın Altıncı Bölüm'de tespit ettiği bir ters teşviki gidermeyi amaçlamaktadır: Güvenlik değerlendirmesi yapan ve riskleri belgeleyen sağlayıcıların, bu belgeler nedeniyle, hiç değerlendirme yapmayan sağlayıcılara göre daha ağır bir sorumluluk riskiyle karşılaşması. Hüküm, değerlendirmenin yapılmasını bir yükümlülük hâline getirirken, belgelendirmenin kendisinin, uygun önlemler alındığı sürece, aleyhe bir karine oluşturmamasını öngörmektedir. Birinci fıkranın (c) bendi ise akıl yürütme metinlerinin ve diğer denetim araçlarının izlenebilirliğinin korunmasına yöneliktir.

Madde 21 (Durdurma yükümlülüğü ve kapasitesi). Madde, çalışmanın merkezî önerilerinden birini, yani varlık koşulları denetimini ve asimetrik durdurulabilirlik ilkesini düzenlemektedir. Birinci fıkra,

durdurma *yetkisinin* yanında, durdurma *kapasitesinin* de güvence altına alınmasını öngörmektedir; çünkü İkinci Bölüm'de gösterildiği üzere, stratejik asimetri koşullarında, durdurma yetkisi, teknik ve örgütsel kapasiteyle desteklenmedikçe işlevsiz kalabilir. İkinci fıkra, Türk Ceza Kanunu'nun 83. maddesindeki "önceki tehlikeli davranıştan doğan garantörlük" kavramının yapay zekâ bağlamındaki somutlaştırılmasıdır. Üçüncü ve dördüncü fıkralar, asimetrik durdurulabilirlik ilkesini uygulamaktadır: Durdurma, Kurul kararıyla, acil durumlarda Kurul Başkanı kararıyla mümkündür; yeniden başlatma ise nitelikli çoğunluk ve Bilimsel Danışma Kurulu'nun görüşünü gerektirmektedir. Beşinci fıkra, durdurma kararlarına karşı yargı yolunu açık tutarken, yürütmenin durdurulması kararının, tehlikenin bulunmadığının açıkça anlaşılması koşuluna bağlanmasıyla, Jonas'ın "kötü prognoza öncelik verilmesi" ilkesini yargısal sürece yansıtmaktadır.

Madde 24 (Kurul). Madde, Kurul üyelerinin seçiminde çoğulcu bir yapı öngörmektedir: Üyelerin yaklaşık yarısı yasama organı tarafından nitelikli çoğunlukla, diğer yarısı ise yüksek yargı organları, akademi, baro ve insan hakları kurumu tarafından seçilmektedir. Bu yapı, Kurul'un ne yürütmenin ne de tek bir siyasi çoğunluğun kontrolünde olmasını amaçlamaktadır. Yedi yıllık ve yenilenemez görev süresi, üyelerin yeniden seçilme kaygısıyla bağımsızlıklarını yitirmelerini önlemeyi; görev sonrası üç yıllık yasak ise "döner kapı" sorununu önlemeyi amaçlamaktadır.

Madde 26 (Kurumun hesap verebilirliği). Madde, çalışmanın temel tezlerinden birini, yani denetim kurumlarının da denetlenmesi gerektiği tezini somutlaştırmaktadır. Kurum, yasama, yargı, Sayıştay, Kamu Denetçiliği Kurumu ve kamuoyu tarafından denetlenmekte; Kanunun kendisi ise dönemsel bağımsız değerlendirmeye tabi tutulmaktadır. Bu çok yönlü hesap verebilirlik ağı, Juvenalis'in sorusuna, modelin verdiği kurumsal cevaptır.

Madde 28 (Bilimsel Danışma Kurulu ve nitelikli uyarı). Madde, Avrupa Birliği Yapay Zekâ Tüzüğü'ndeki Bilimsel Panel'in nitelikli uyarı yetkisinden esinlenmekle birlikte, önemli bir farklılık içermektedir: Nitelikli uyarı, yalnızca denetim kurumuna değil, doğrudan Türkiye Büyük Millet Meclisi'nin ilgili komisyonuna da iletilmektedir. Bu, denetim kurumunun, bilim topluluğunun uyarılarını göz ardı etmesine karşı bir güvencedir ve kurumun kendisinin denetiminde bilim topluluğuna bir rol tanımaktadır.

Madde 30 (Yapay zekâ sorumlu yöneticisi). Madde, Birleşik Krallık'ın finans sektöründeki Kıdemli Yöneticiler Rejimi'nden esinlenerek, "son insan halkası" ilkesini somutlaştırmaktadır. Üçüncü fıkra, sorumlu yöneticinin askıya alma yetkisinin, bağlı olduğu kuruluş tarafından kısıtlanamayacağını öngörerek, Altıncı Bölüm'de Kasım 2023 yönetim krizi örneğinden çıkarılan dersi, yani biçimsel yetkinin fiilî kontrol olmaksızın işlevsiz kalabileceği dersini dikkate almaktadır. Dördüncü fıkra, sorumluluğun, makul önlemlerin alınmamasına bağlanmasıyla, sorumlu yöneticiyi, kontrol edemediği her sonuçtan değil, kendi yetki ve bilgisi dâhilindeki önlemleri almamaktan sorumlu tutmaktadır.

Madde 31 (Tehlike sorumluluğu). Madde, çalışmanın Altıncı Bölüm'de geliştirdiği yorumu, yani sınır yapay zekâ sistemlerinin geliştirilmesi ve işletilmesinin Türk Borçlar Kanunu'nun 71. maddesi anlamında önemli ölçüde tehlike arz eden işletme faaliyeti olduğu yorumunu, kanuni bir hükme dönüştürmektedir. Bu hüküm, sorumluluk boşluğu sorununu, kusur ispatına gerek kalmaksızın, zarar görenin tazmin edilmesini sağlayarak kapatmaktadır.

Madde 35 (İhbarcıların korunması). Madde, yapay zekâ alanına özgü ihbarcı korumaları öngörmektedir. Birinci fıkradaki koruma, yalnızca hukuka aykırılıkların değil, henüz düzenlenmemiş ciddi risklerin bildirilmesini de kapsamaktadır; bu kapsam, sınır yapay zekâ şirketlerinin çalışanlarının "uyarma hakkı" talebine bir cevaptır. Dördüncü fıkradaki ispat yükü kuralı, 6701 sayılı Kanun'daki ayrımcılık davalarına ilişkin ispat yükü kuralına paralel bir yapıdadır.

Madde 37 (Suçlar). Madde, ceza hukukunun son çare niteliğini gözeterek, yalnızca en ağır ihlaller için suç tipleri öngörmektedir: kişilerin hayatı veya sağlığı bakımından ciddi ve yakın bir tehlikenin varlığını bilerek durdurma yükümlülüğünün ihlali; denetim otoritesinin yanıltılması; ve denetimin hile veya cebirle engellenmesi. Bu suç tipleri, denetim sisteminin işleyişinin temel koşullarını, yani doğru bilgiye dayanan değerlendirmeyi ve tehlike anında durdurmayı korumaya yöneliktir.

§ 47. MUHTEMEL İTİRAZLAR VE CEVAPLAR

Bu çalışmada geliştirilen model ve kanun önerisi, çeşitli açılardan eleştirilebilir. Bilimsel dürüstlük, bu eleştirilerin en güçlü biçimleriyle

yüzleşmeyi gerektirir. Bu başlık altında, modele yöneltilebilecek sekiz temel itiraz ve bunlara verilebilecek cevaplar ele alınacaktır.

I. Birinci İtiraz: Yenilikçiliği Engeller ve Rekabet Gücünü Zayıflatır

İtiraz: Önerilen model, yapay zekâ sistemlerinin geliştirilmesi ve kullanılması üzerinde ağır bir düzenleyici yük yaratmaktadır. Bu yük, yenilikçiliği engelleyecek, yapay zekâ şirketlerini daha gevşek düzenlemelere sahip ülkelere yöneltecek ve Türkiye'nin küresel yapay zekâ rekabetinde geride kalmasına yol açacaktır.

Cevap: Bu itiraz, Dördüncü Bölüm'de ele alınan yarış dinamiğinin tipik bir ifadesidir ve ciddiye alınmalıdır. Ancak itirazın birkaç zaafı vardır. *Birincisi*, önerilen model, orantılılık ilkesine dayanmaktadır: Ağır yükümlülükler, yalnızca yüksek riskli kamusal kullanımlar ve sınır yapay zekâ sistemleri için öngörülmektedir. Yapay zekâ uygulamalarının büyük çoğunluğu, bu kategorilerin dışında kalmakta ve modelin ağır yükümlülüklerine tabi olmamaktadır. *İkincisi*, modelin kamusal kullanıma ilişkin yükümlülükleri, yenilikçiliği değil, devletin yapay zekâ kullanımını düzenlemektedir; devletin, yurttaşlarının temel haklarını etkileyen kararlarda, hukuka uygun ve hesap verebilir bir biçimde davranması, rekabet gücüyle değil, hukuk devletinin gereğiyle ilgilidir. *Üçüncüsü*, Türkiye'nin Avrupa Birliği ile gümrük birliği içinde olması ve "Brüksel etkisi" göz önüne alındığında, Türk şirketleri, Birlik pazarına erişmek için zaten Birlik'in Yapay Zekâ Tüzüğü'ne uymak zorunda kalacaktır; Türk hukukunun bu düzenlemeyle uyumlu bir çerçeve oluşturması, şirketler için ek bir yük değil, hukuki belirlilik sağlayacaktır. *Dördüncüsü* ve en önemlisi, güvenlik ve güvenilirlik, uzun vadede, rekabet gücünün engeli değil, ön koşuludur. İkinci Bölüm'de incelenen vakalar, denetimsiz yapay zekâ kullanımının, hem doğrudan zararlar hem de kamu güveninin kaybı nedeniyle, son derece yüksek maliyetler doğurabildiğini göstermiştir. Havacılık ve ilaç sektörleri, sıkı güvenlik düzenlemelerinin, bu sektörlerin gelişimini engellemediğini, aksine kamu güvenini sağlayarak gelişimlerine katkıda bulunduğunu göstermektedir.

II. İkinci İtiraz: Bilişsel Asimetri Koşullarında Denetim Zaten İmkânsızdır

İtiraz: Eğer yapay zekâ sistemleri, onları denetleyenlerden gerçekten daha zeki hâle gelirse, hiçbir denetim mekanizması etkili olamaz. Yeterince zeki bir sistem, tüm denetim mekanizmalarını öngörebilir ve aşabilir. Bu durumda, önerilen model, gerçek bir güvenlik sağlamaktan çok, sahte bir güvenlik duygusu yaratacaktır.

Cevap: Bu itiraz, çalışmanın en ciddi itirazıdır ve tamamen reddedilemez. Ancak itirazın gücü, birkaç bakımdan sınırlıdır. *Birincisi*, itiraz, bilişsel asimetrinin her zaman ve her alanda mutlak olacağını varsaymaktadır. Oysa İkinci Bölüm'de gösterildiği üzere, yapay zekâ yetenekleri "pürüzlü" bir profile sahiptir ve asimetri, farklı biçimlerde ve farklı derecelerde ortaya çıkar. Önerilen model, asimetrinin farklı biçimlerine karşı farklı araçlar öngörmektedir. *İkincisi*, § 43'te geliştirilen kayma tezi, bilişsel asimetri arttıkça işlevini koruyan denetim nesnelerinin bulunduğunu göstermektedir. Girdi denetimi ve varlık koşulları denetimi, sistemin nasıl çalıştığını anlamayı gerektirmez; ve Montesquieu'nün gösterdiği gibi, engelleme yetisi, karar verme yetisiyle aynı bilişsel kapasiteyi gerektirmez. *Üçüncüsü*, itiraz, hukukun işlevini yanlış anlamaktadır. Hukuk, yalnızca gelişmiş sistemleri *sonradan* denetlemeyi değil, bu sistemlerin *nasıl geliştirileceğini* de şekillendirmeyi amaçlar. İkinci Bölüm'de, I. J. Good'un, ilk ultra-zeki makinenin, ancak "onu nasıl kontrol altında tutacağımızı bize söyleyecek kadar uysal" olması koşuluyla insanlığın son icadı olacağı yönündeki gözlemi aktarılmıştı. Bu gözlem, kontrolün, büyük ölçüde, sistemlerin *tasarımına* bağlı olduğunu göstermektedir. Önerilen model, durdurma kapasitesi, izlenebilirliğin korunması, güvenlik değerlendirmeleri ve sorumluluk kuralları aracılığıyla, sistemlerin düzeltilebilir ve denetlenebilir biçimde tasarlanmasını teşvik etmektedir. Hukuk, süper zekâyı durduramayabilir; ama süper zekâya giden yolun, düzeltilebilirliği koruyan bir yol olmasına katkıda bulunabilir. *Dördüncüsü*, itiraz doğru olsa bile, bundan çıkan sonuç, denetimden vazgeçmek değil, denetimin imkânsız hâle geleceği eşiğe ulaşılmadan önce, bu eşiğe ulaşılıp ulaşılmayacağına ilişkin kararların, Jonas'ın ihtiyat ilkesi doğrultusunda, demokratik ve hesap verebilir süreçlerle alınmasını güvence altına almaktır.

III. Üçüncü İtiraz: Türkiye Sınır Model Geliştirmediğine Göre Model Anlamsızdır

İtiraz: Dünyanın en ileri yapay zekâ sistemleri, birkaç ülkede ve birkaç şirket tarafından geliştirilmektedir. Türkiye, bu ülkeler arasında değildir. Bu durumda, sınır yapay zekâ sistemlerine ilişkin ayrıntılı bir düzenleme, Türkiye için pratik bir anlam taşımamaktadır.

Cevap: Bu itirazın birkaç yanıtı vardır. *Birincisi*, önerilen modelin büyük kısmı, sınır sistemlerin geliştirilmesine değil, yapay zekâ sistemlerinin *kamusal kullanımına* ilişkindir. Türk kamu kurumları, yurt içinde veya yurt dışında geliştirilmiş olsun, yapay zekâ sistemlerini giderek artan ölçüde kullanmaktadır ve bu kullanımın denetimi, Türkiye için doğrudan ve acil bir sorundur. *İkincisi*, sınır sistemlere ilişkin hükümler, yalnızca bu sistemlerin Türkiye'de geliştirilmesini değil, Türkiye'de piyasaya arz edilmesini ve kullanılmasını da kapsamaktadır. Yurt dışında geliştirilen sınır sistemleri, Türkiye'de geniş biçimde kullanılmaktadır ve bu kullanımın koşulları, Türk hukukunun düzenleme alanı içindedir. *Üçüncüsü*, Collingridge ikileminin gösterdiği gibi, bir teknolojiyi denetlemenin en kolay olduğu dönem, o teknolojinin henüz yerleşmediği dönemdir. Türkiye'nin, kendi yapay zekâ kapasitesini geliştirirken, baştan uygun bir denetim çerçevesi oluşturması, ileride çok daha zor ve maliyetli olacak düzeltmeleri önleyecektir. *Dördüncüsü*, uluslararası denetim mekanizmaları, ancak çok sayıda ülkenin katılımıyla etkili olabilir; Türkiye'nin bu mekanizmalara katılması ve tasarımlarında söz sahibi olması, kendi iç düzenleyici kapasitesine bağlıdır.

IV. Dördüncü İtiraz: Yeni Bir Kurum, Yeni Bir Bekçi Yaratır

İtiraz: Önerilen Yapay Zekâ Denetim Kurumu, yapay zekâ üzerinde geniş yetkilerle donatılmış yeni bir bürokratik güç odağı yaratmaktadır. Bu kurumun kendisi, düzenleyici ele geçirmeye, siyasi baskılara veya kendi kurumsal çıkarlarına göre hareket etmeye yatkın olabilir. Böylece model, Juvenalis'in sorusunu çözmek yerine, onu yeni bir düzeye taşımaktadır.

Cevap: Bu itiraz, haklı bir kaygıyı ifade etmektedir ve model, bu kaygıyı baştan dikkate alarak tasarlanmıştır. Kurum, § 44'te ve kanun önerisinin 26. maddesinde ayrıntılı olarak düzenlenen çok yönlü bir hesap verebilirlik ağına tabidir: yasama denetimi, yargısal denetim, mali denetim, şikâyet mekanizması, kamusal şeffaflık, bilimsel denetim ve dönemsel bağımsız değerlendirme. Kurul üyelerinin seçimindeki çoğulculuk,

yenilenemez görev süresi ve görev sonrası yasaklar, kurumun tek bir siyasi çoğunluğun veya denetlenen şirketlerin kontrolüne girmesini zorlaştırmaktadır. Bununla birlikte, itirazın temel noktası doğrudur: Hiçbir kurumsal tasarım, kurumun yozlaşmamasını kesin olarak garanti edemez. Modelin cevabı, kesin bir garanti vermek değil, Popper'ci anlamda, yozlaşmanın *tespit edilebilir* ve *düzeltilebilir* olmasını sağlamaktır. Kurum, dairesel yapının bir halkasıdır, zincirin tepesi değil. Kurum yozlaşırsa, diğer halkalar, yani parlamento, yargı, bilim topluluğu ve kamuoyu, bu yozlaşmayı tespit edebilir ve düzeltebilir. Juvenalis'in sorusu, bu anlamda, "çözülmez"; ama "yönetilir".

V. Beşinci İtiraz: Yapay Zekâ Daha İyi Karar Veriyorsa, İnsanı Neden Tutalım?

İtiraz: Eğer yapay zekâ, belirli kararlarda insanlardan daha doğru, daha tutarlı ve daha az önyargılı kararlar veriyorsa, insan nihai karar ilkesi, insanları daha kötü kararlara mahkûm etmek anlamına gelir. İnsan kararlarının da önyargılı, tutarsız ve hatalı olduğu düşünüldüğünde, insan kararına öncelik tanımak, irrasyonel bir insan merkezcilikten başka bir şey değildir.

Cevap: Bu itiraz, Üçüncü Bölüm'de Raz'ın normal gerekçelendirme tezi ve Huq'un insan kararı hakkına yönelik eleştirisi bağlamında ayrıntılı olarak tartışılmıştır. Cevabın özü şudur: *Birincisi*, insan nihai karar ilkesi, her bireysel kararın bir insan tarafından verilmesini gerektirmez; yapay zekânın hangi kararlarda ve hangi koşullarda kullanılacağına ilişkin üst düzey kararların insanlar tarafından alınmasını ve bireysel kararlara karşı insan incelemesi imkânının bulunmasını gerektirir. Eğer bir yapay zekâ sistemi, belirli bir karar türünde gerçekten daha iyi kararlar veriyorsa, insanlar, o karar türünde sistemi kullanmaya *karar verebilir*. İlke, bu kararın insanlar tarafından, hesap verebilir bir biçimde ve geri alınabilir olarak verilmesini şart koşar. *İkincisi*, yapay zekânın "daha iyi" karar verdiği iddiası, kendisi denetime tabi tutulması gereken bir iddiadır; COMPAS örneği, bu iddiaların her zaman doğru olmadığını göstermiştir. *Üçüncüsü*, Raz'ın bağımsızlık koşulu ve Estlund'un nitelikli kabul edilebilirlik şartı, bazı kararlarda, doğru kararın verilmesinden bağımsız olarak, kararın kimin tarafından ve hangi usulle verildiğinin önemli olduğunu göstermektedir. *Dördüncüsü*, Pettit'in tahakküm kavramı, iyi kararlar veren ama denetlenemeyen bir gücün bile özgürlüğü tehdit ettiğini

göstermektedir. Bu itirazın gözden kaçırdığı nokta, meşruiyetin yalnızca kararların içeriğine değil, kararların sahipliğine, hesap verebilirliğine ve düzeltilebilirliğine de bağlı olduğudur.

VI. Altıncı İtiraz: Hukuk, Teknolojinin Gerisinde Kalır

İtiraz: Yapay zekâ teknolojisi, hukukun uyum sağlayabileceğinden çok daha hızlı gelişmektedir. Bugün yapılan ayrıntılı bir düzenleme, birkaç yıl içinde eskiyecek ve ya işlevsiz kalacak ya da yeniliği gereksiz yere engelleyecektir.

Cevap: Bu itiraz, haklı bir gözleme dayanmaktadır ve önerilen model, bu gözlemi dikkate alarak tasarlanmıştır. *Birincisi*, model, teknolojiye özgü ayrıntılı kurallar yerine, teknolojiden bağımsız ilkelere (yetki-zekâ ayrılığı, insan nihai kararı, düzeltilebilirlik, aleniyet, bağımsız denetim, insan sorumluluğu) dayanmaktadır. Bu ilkeler, teknoloji değiştikçe geçerliliğini korur. *İkincisi*, teknolojiye özgü parametreler (örneğin sınır sistemleri belirleyen hesaplama eşiği), kanunda sabitlenmemiş; düzenli olarak gözden geçirilmek üzere bağımsız denetim kurumuna bırakılmıştır. *Üçüncüsü*, kanun önerisi, dönemsel bağımsız değerlendirme ve gözden geçirme hükümleri içermektedir; bu hükümler, düzenlemenin, teknolojik gelişmeler ışığında düzenli olarak güncellenmesini sağlamaktadır. Bu yaklaşım, Dördüncü Bölüm'de ele alınan "öngörücü yönetişim" ve Jasanoff'un "alçakgönüllülük teknolojileri" kavramlarının bir uygulamasıdır: Model, geleceği kesin olarak öngördüğünü iddia etmez; ama gelecekten öğrenmeyi kurumsallaştırır.

VII. Yedinci İtiraz: Denetim, Devletin Gücünü Artırır

İtiraz: Yapay zekâ üzerinde güçlü bir devlet denetimi, devlete, yapay zekâ aracılığıyla toplumu kontrol etme konusunda olağanüstü bir güç kazandırır. Yedinci Bölüm'de ele alınan Çin örneği, yapay zekânın devlet tarafından denetlenmesinin, devletin despotik iktidarını güçlendirebileceğini göstermektedir.

Cevap: Bu itiraz, modelin temel kaygılarından birini ifade etmektedir ve modelin tasarımı, bu kaygıya cevap vermeyi amaçlamaktadır. Model, yapay zekânın *devlet tarafından* denetlenmesini değil, yapay zekânın *bağımsız ve çok katmanlı bir yapı tarafından* denetlenmesini öngörmektedir. Bu yapıda, devletin kendisinin yapay zekâ kullanımı da denetime tabidir; hatta modelin ikinci kısmı, tamamen devletin yapay zekâ

kullanımının denetimine ayrılmıştır. Denetim kurumu, yürütmeden bağımsızdır ve kendisi de çok yönlü bir hesap verebilirlik ağına tabidir. Çin modeli ile önerilen model arasındaki temel fark, Yedinci Bölüm'de vurgulandığı üzere, denetim ile hesap verebilirlik arasındaki farktır: Çin modelinde yapay zekâ denetlenir, ama denetleyen hesap vermez; önerilen modelde ise yapay zekâ denetlenir ve denetleyen de hesap verir.

VIII. Sekizinci İtiraz: Yapay Zekânın Olası Ahlaki Statüsü

İtiraz: Eğer gelecekteki yapay zekâ sistemleri, ahlaki muhatap olma niteliği kazanırsa, onları sürekli denetim altında tutmak, kapatmak veya değiştirmek, ahlaki bakımdan sorunlu olabilir. Önerilen model, yapay zekâyı salt bir nesne olarak ele almakta ve bu olasılığı göz ardı etmektedir.

Cevap: Bu itiraz, Üçüncü Bölüm'de ayrıca ele alınmıştır. Cevabın özü şudur: Yapay zekâ sistemlerinin olası ahlaki statüsü, onlara insanlar üzerinde siyasi otorite tanınmasını gerektirmez; ve denetim ile düzeltilebilirlik, ahlaki statüyle bağdaşmaz değildir. Anayasal düzenin temel ilkesi, hiçbir aktörün, insan veya insan olmayan, sınırsız ve denetlenemez bir iktidara sahip olmamasıdır. İnsanlar da hukuk düzeni içinde denetime, hesap vermeye ve gerektiğinde yetkilerinin kısıtlanmasına tabidir; bu durum onların onurunu ihlal etmez. Bununla birlikte, bu itiraz, denetim uygulamalarının, gereksiz zarardan kaçınacak biçimde tasarlanması gerektiğini hatırlatması bakımından değerlidir. Bilimsel bilgi geliştikçe, bu konunun, Yapay Zekâ Denetim Kurumu'nun ve Yapay Zekâ Yurttaş Meclisi'nin gündemine alınması uygun olacaktır.

§ 48. JUVENALİS'E DÖNÜŞ

Bu çalışma, Romalı şair Juvenalis'in yaklaşık iki bin yıl önce sorduğu bir soruyla başlamıştı: *Quis custodiet ipsos custodes?* Bekçileri kim bekleyecek? Bu soru, iktidarın denetimine ilişkin tüm kuramların ortak paydasıdır; çünkü her denetim mekanizması yeni bir denetleyici yaratır ve her denetleyici, kendisi de denetlenmeye muhtaç bir iktidar odağıdır.

Çalışma boyunca, bu soruya tarih boyunca verilen cevaplar incelenmiş ve bu cevapların, örtük olarak, denetleyen ile denetlenen arasında kaba bir bilişsel denklik bulunduğu varsayımına dayandığı gösterilmiştir. Yapay zekâ, bu varsayımın ilk kez ilkesel düzeyde sarsılabileceği bir durumu gündeme getirmektedir. Denetlenen, denetleyenden daha zeki hâle

geldiğinde, Juvenalis'in sorusu yeni ve daha keskin bir biçim alır: Bekçiden daha zeki bir varlığı, bekçi nasıl bekleyecektir?

Bu çalışmanın bu soruya verdiği cevap, üç unsurdan oluşmaktadır.

Birinci unsur, normatif bir cevaptır: Zekâ yetki doğurmaz. Yapay zekâ ne kadar zeki olursa olsun, bu zekâ, kendi başına, ona insanlar üzerinde karar verme yetkisi kazandırmaz. Yapay zekâ, Kant'ın filozofu gibi, özgürce danışmanlık yapabilir; ama iktidarın kendisine sahip olmamalıdır. Bu cevap, Juvenalis'in sorusunu ortadan kaldırmaz; ama sorunun bir bölümünü, yani yapay zekânın *meşru* bir bekçi olup olamayacağı sorusunu, olumsuz olarak cevaplar. Yapay zekâ, bekçilerden biri olabilir, ama bekçilerin bekçisi olamaz.

İkinci unsur, analitik bir cevaptır: Denetimin nesnesi değişmelidir. Bilişsel asimetri koşullarında, denetçinin, denetlenenin kararlarının içeriğini değerlendirme kapasitesi azalır. Ancak bu, denetimin imkânsız hâle geldiği anlamına gelmez. Denetim, sonuçtan sürece, girdilere ve varlık koşullarına kaymalıdır. Montesquieu'nün gösterdiği gibi, bir kararı engellemek, onu vermekle aynı kapasiteyi gerektirmez. Aristoteles'in gösterdiği gibi, bir ürünü değerlendirmek, onu üretmekle aynı kapasiteyi gerektirmez. Ve Magna Carta'nın güvence maddesinin akıbetinin gösterdiği gibi, denetimin etkinliği, denetçinin, denetlenenin varlık koşulları üzerinde fiilî bir kontrole sahip olmasına bağlıdır. Bekçi, kendisinden daha zeki bir varlığı, onun her hamlesini anlayarak değil, onun hangi koşullarda hareket edebileceğini belirleyerek ve gerektiğinde onu durdurabilerek bekleyebilir.

Üçüncü unsur, kurumsal bir cevaptır: En üstteki bekçi yoktur; bekçilerin çemberi vardır. Juvenalis'in sorusunun mantıksal yapısı, sonsuz bir geriye gidişi ima eder: Her bekçinin bir bekçiye ihtiyacı vardır. Hobbes, bu zinciri, en tepeye denetlenemeyen bir egemen koyarak kesmişti. Platon, en tepeye denetlenmeye ihtiyaç duymayacak kadar erdemli bir bekçi koymayı umuyordu. Bu çalışma, her iki çözümü de reddetmektedir. Hobbes'un çözümü, tiranlığa; Platon'un çözümü ise yapay zekâ bağlamında, algoritmik bir filozof-krala, yani doğrulanamayan bir erdeme duyulan körü körüne güvene yol açar. Bu çalışmanın önerdiği çözüm, Polybios'tan Montesquieu'ye, Madison'dan Ostrom'a uzanan bir geleneğe dayanmaktadır: Zinciri sonsuza uzatmak veya tepesine denetlenemeyen bir bekçi koymak yerine, zinciri kendi üzerine kapatmak. Teknik değerlendiriciler, kurumsal denetçiler, girdi denetimi, toplumsal denetim ve

uluslararası denetim, birbirini karşılıklı olarak denetleyen bir çember oluşturur. Bu çemberde hiçbir bekçi, denetimden muaf değildir. Ve çemberin her noktasında, Popper'in gösterdiği gibi, hataların tespit edilmesi ve düzeltilmesi mümkün olmalıdır.

Bu cevap, Juvenalis'in sorusunu kesin olarak çözmez. Çemberdeki bekçiler, birbiriyle işbirliği yaparak çemberi boşa çıkarabilir; Juvenalis'in deyişiyle, "işe birbirlerinden başlayabilir". Bu ihtimale karşı, nihai güvence, hiçbir kurumsal tasarımın tek başına sağlayamayacağı bir şeydir. Alman anayasa hukukçusu Ernst-Wolfgang Böckenförde'nin ünlü tespitiyle, özgürlükçü ve laik devlet, kendisinin garanti edemeyeceği ön koşullar üzerinde yaşar.[359] Yapay zekâ çağında da denetim çemberinin nihai güvencesi, hukukun üstünlüğü kültürünün, toplumda ve kurumlarda ne ölçüde içselleştirildiğidir: karar vericilerin, sistemlerin önerilerini sorgulama cesaretini ve kapasitesini korumaları; yurttaşların, kendi akıllarını kullanma alışkanlığını yitirmemeleri; bilim insanlarının, gazetecilerin ve sivil toplumun, rahatsız edici gerçekleri dile getirme özgürlüğüne sahip olmaları; ve sistemleri geliştirenlerin, kendi yarattıklarının hatalarını düzeltme sorumluluğunu kabul etmeleri.

Kant, Aydınlanma'nın parolasını "*Sapere aude!*", yani "Kendi aklını kullanma cesaretini göster!" olarak formüle etmişti. Yapay zekâ çağında bu parola, yeni bir anlam kazanmaktadır. Bizden daha hızlı, daha kapsamlı ve belki de daha derin düşünebilen sistemlerle birlikte yaşamak zorunda kalacağımız bir dünyada, kendi aklımızı kullanma cesareti, bu sistemleri reddetmek değil, onları kullanırken bile kendi yargımızı, kendi sorumluluğumuzu ve kendi geleceğimizi belirleme hakkımızı korumak anlamına gelir. I. J. Good, ilk ultra-zeki makinenin, ancak bize onu nasıl kontrol altında tutacağımızı söyleyecek kadar uysal olması koşuluyla, insanlığın son icadı olacağını yazmıştı. Bu çalışmanın vardığı sonuç, Good'un koşuluna bir koşul daha eklemektedir: Makine ne kadar uysal olursa olsun, onu kontrol altında tutma iradesi ve kapasitesi, bizim kurumlarımızda, bizim hukukumuzda ve bizim aklımızda yaşamaya devam etmelidir. Bekçileri kim bekleyecek sorusunun yapay zekâ çağındaki cevabı, son tahlilde, Locke'un cevabından çok farklı değildir: Bekçileri,

[359] Ernst-Wolfgang Böckenförde, "Die Entstehung des Staates als Vorgang der Säkularisation" (1967), *Recht, Staat, Freiheit*, Frankfurt am Main, Suhrkamp, 1991: "*Der freiheitliche, säkularisierte Staat lebt von Voraussetzungen, die er selbst nicht garantieren kann.*"

hep birlikte, biz bekleyeceğiz; ama bunu yapabilmek için, beklemeyi bilen kurumlar inşa etmek ve beklemeyi unutmamak zorundayız.

SONUÇ

Bu çalışma, yapay zekânın, karar vericilerden daha zeki bir aşamaya ulaşması hâlinde, onu kimin denetlemesi ve kimden nasıl hesap sorulması gerektiği sorusunu, hukuki, felsefi ve siyasi perspektiflerden incelemiştir. Çalışmanın bulguları, Giriş'te formüle edilen araştırma soruları ve hipotezlerle ilişkilendirilerek, aşağıda tezler hâlinde özetlenmektedir.

I. Araştırma Sorularına Cevaplar

S1. Klasik cevapların varsayımları ve geçerliliği.

Tez 1. "Bekçileri kim bekleyecek?" sorusuna tarih boyunca verilen cevaplar beş ana türde toplanabilir: erdem ve eğitim yoluyla güvenilirlik (Platon), kuralların egemenliği (Aristoteles, Cicero, Bracton), karşılıklı denetim (Polybios, Montesquieu, Federalistler), görevden alma ve düzeltme (Locke, Popper) ve uzmanlaşmış denetim kurumları (Kelsen, Weber).

Tez 2. Bu cevapların hepsi, örtük olarak, denetleyen ile denetlenen arasında "kaba bilişsel denklik" bulunduğu varsayımına dayanır. Bu varsayım, karar vericileri aşan yapay zekâ karşısında, farklı cevap türleri bakımından farklı ölçülerde zorlanmaktadır.

Tez 3. Klasik araçlardan bazıları, bilişsel asimetriye karşı diğerlerinden daha dayanıklıdır: Aristoteles'in "kullanan değerlendirir" argümanı, Montesquieu'nün "engelleme yetisi" kavramı, Popper'in "Kim yönetmeli?" sorusunu reddi, Magna Carta deneyiminden çıkan varlık koşulları dersi, McCubbins ve Schwartz'ın "yangın alarmı" modeli, Kelsen'in "kimse kendi davasında yargıç olamaz" ilkesi ve Weber'in siyasetçinin devredilemez sorumluluğu ilkesi. Bu araçlar, yapay zekâ çağında denetim mimarisinin yapı taşlarını oluşturmaktadır.

Tez 4. Hobbes'un *Leviathan*'ı, devleti, insanların yarattığı ve kendilerinden daha güçlü olan "yapay bir insan" olarak tasarlamıştır. Modern anayasacılığın tarihi, bu yapay insanın evcilleştirilmesinin tarihidir. Bu deneyim, insanlığın kendisinden güçlü yapay varlıkları denetim altına alabildiğini göstermesi bakımından umut verici; ancak bu evcilleştirmenin,

devletin parçalarının insan olmasına dayandığını göstermesi bakımından ihtiyatlı bir derstir.

S2. Üstün bir sistemin daha az yetenekli bir denetçi tarafından denetlenmesi.

Tez 5. Yapay zekânın karar vericileri aşması, birbirinden ayrılması gereken dört asimetri biçiminde ortaya çıkar: hız asimetrisi, ölçek asimetrisi, kavrayış asimetrisi ve stratejik asimetri. Her asimetri türü, farklı denetim araçları gerektirir.

Tez 6. İnsan denetimi, otomasyonun ironileri, otomasyon yanlılığı, seçici uyum, ikna ve dalkavukluk, ahlaki çarpışma bölgeleri ve kurumsal bilişsel körelme gibi olgular nedeniyle, kâğıt üzerinde göründüğünden çok daha zayıf bir güvencedir. Bireysel insan gözetimine aşırı güvenmek, bir "meşruiyet tiyatrosu"na ve sorumluluğun operatörlere kaydırılmasına yol açabilir.

Tez 7. Goldman'ın acemi-uzman sorununa ilişkin beş kanıt kaynağı (argümanlar, görüş birliği, üst-uzman değerlendirmeleri, çıkar ve önyargılar, geçmiş başarı kaydı), yapay zekâ güvenliği literatüründeki denetim araçlarıyla (münazara, topluluk yöntemleri, bağımsız değerlendirmeler, yorumlanabilirlik, kullanım izleme) sistematik olarak eşleşir. Bu kaynakların her biri, stratejik asimetri koşullarında belirli zaaflara sahiptir; bu zaaflar, kaynakların birlikte kullanılmasıyla kısmen telafi edilebilir.

Tez 8. Her teknik denetim yöntemi, nihayetinde, kendisi denetlenmeyen ama güvenilir kabul edilen bir "güven çapası"na dayanır. Teknik denetim, bekçiler sorununu çözmez; onu, güven çapasının korunması sorununa dönüştürür. Güven çapasının korunması, teknik değil, kurumsal ve hukuki bir görevdir.

Tez 9. Bilişsel asimetri arttıkça, kararın içeriğinin değerlendirilmesine dayanan sonuç denetimi işlevini kaybetmeye başlar; buna karşılık süreç, girdi ve varlık koşulları denetimi işlevini önemli ölçüde korur. Bu nedenle, denetimin ağırlığı, sonuç denetiminden diğer üç nesneye kaydırılmalıdır ("kayma tezi"). Girdi denetimi ve varlık koşulları denetimi, tüm asimetri türleri karşısında işlevini koruyan tek denetim nesneleridir.

S3. Zekâ üstünlüğünün yetki gerekçesi olup olamayacağı.

Tez 10. Zekâ üstünlüğü, teorik (epistemik) otorite için gerekçe oluşturabilir; yani bir sistemin görüşlerine inanmak için iyi bir neden

olabilir. Ancak pratik (siyasi) otorite için, yani bir sistemin buyruklarına uymak için yeterli bir gerekçe oluşturmaz.

Tez 11. Bu sonuç, altı bağımsız argümana dayanmaktadır: otoritenin hakikatten değil yetkilendirmeden doğduğuna ilişkin Hobbes'çu argüman; kolektif öz-yönetimin bağımsız değerine ilişkin Raz'cı argüman (bağımsızlık koşulu); uzman/efendi safsatasına ve nitelikli kabul edilebilirlik şartına ilişkin Estlund'cu argüman; pratik otoritenin karşılıklı hesap verebilirlikten ayrılamayacağına ilişkin Darwall'cı argüman; erdemin bile sınırlara ihtiyaç duyduğuna ilişkin Montesquieu'cü ve cumhuriyetçi argüman; ve yanılabilirlik ile düzeltilebilirliğe ilişkin Popper'ci argüman.

Tez 12. Bu argümanlar, "yetki-zekâ ayrılığı ilkesi"nde sistemleştirilmektedir: Bir aktörün bilişsel yetkinliği, ne kadar üstün olursa olsun, kendi başına o aktöre başkaları adına bağlayıcı kararlar alma yetkisi kazandırmaz. Yapay zekâ danışman olabilir, egemen olamaz.

Tez 13. Yapay zekâ sistemlerinin olası ahlaki statüsü, onlara insanlar üzerinde siyasi otorite tanınmasını gerektirmez ve denetim ile düzeltilebilirlikle bağdaşmaz değildir. Ahlaki statü sorusu, denetimin zayıflatılması için bir argüman olarak kullanılmamalıdır.

S4. Türk anayasa ve idare hukukunun imkânları ve eksiklikleri.

Tez 14. Türk anayasa düzeni, Anayasa'nın 6., 7., 9., 37., 128. ve 138. maddeleri aracılığıyla, nihai karar yetkisinin yapay zekâ sistemlerine devredilmesini yasaklayan güçlü pozitif hukuk dayanakları içermektedir. Bu hükümler, birlikte, "insan nihai karar ilkesi"nin anayasal temelini oluşturur.

Tez 15. Bu anayasal ilkeler, biçimsel devirden çok, fiilî devir biçiminde gerçekleşen süreçlere karşı yeterince korunmamaktadır. Yapay zekâ sistemlerinin içerdiği karar kuralları, işlevsel olarak genel ve soyut normlar ("algoritmik normlar") niteliğindedir ve normlar hiyerarşisinin denetim mekanizmalarından kaçabilir. Bu normlar, işlevsel olarak düzenleyici işlemler gibi ele alınmalıdır.

Tez 16. İdari işlemin unsurları, algoritmik idari işlemler bakımından yeni anlamlar kazanır: Yetki unsuru, atfedilebilirlik ve yetkinin kişiselliği sorununu; sebep unsuru, "olasılıksal sebep yasağı"nı; maksat unsuru ise sistemin hedef fonksiyonu ile kanunun amacı arasındaki uygunluğu ("hedef fonksiyonu-maksat uygunluğu") gündeme getirir.

Tez 17. Bir yapay zekâ sisteminin *açıklaması*, kararın *gerekçesi* değil, gerekçenin dayanabileceği delillerden biridir. Gerekçe, yetkili kamu görevlisi tarafından oluşturulmalıdır. Gerekçenin sistem tarafından üretilmesi ve optimize edilmesi, gerekçe yükümlülüğünü bir "Goodhart tuzağı"na dönüştürebilir.

Tez 18. Bilirkişi kurumu ve "hâkim, bilirkişilerin bilirkişisidir" ilkesi, bilişsel asimetri koşullarında insan denetimine ilişkin, hukukun yüzyıllardır uyguladığı bir model sunar. Bu model, yapay zekânın kamusal kararlarda kullanımına uyarlanmalıdır.

Tez 19. Türk hukukunun bu alandaki başlıca eksiklikleri şunlardır: kapsamlı bir yapay zekâ kanununun, yetkili bir denetim otoritesinin, genel bir idari usul kanununun ve kapsamlı bir ihbarcı koruma kanununun yokluğu; 6698 sayılı Kanun'un otomatik kararlara ilişkin korumasının Avrupa standardının gerisinde kalması; ve parlamentonun teknik denetim kapasitesinin sınırlılığı.

S5. Sorumluluğun yüklenmesi ve elektronik kişilik.

Tez 20. Yapay zekâ, beş hesap verebilirlik açığı yaratır: bilgi açığı, gerekçe açığı, yaptırım açığı, forum açığı ve fail açığı. Her hukuki kurum, bu açıklardan hangilerini kapatabildiği bakımından değerlendirilmelidir.

Tez 21. Sorumluluk boşluğu, belirli bir sonuca ilişkin kusura dayalı geçmişe dönük sorumluluk bakımından gerçektir; ancak ileriye dönük, görev odaklı ve risk üstlenmeye dayalı sorumluluk anlayışıyla kapatılabilir.

Tez 22. Türk hukukunun mevcut kurumları, bu boşluğu kapatmak için beklenenden daha fazla imkân sunmaktadır: Türk Borçlar Kanunu'nun organizasyon sorumluluğuna ilişkin 66. maddesinin üçüncü fıkrası ve tehlike sorumluluğuna ilişkin 71. maddesi; Türk Ceza Kanunu'nun önceki tehlikeli davranıştan doğan garantörlüğe ilişkin 83. maddesi; ve idare hukukunun anonim hizmet kusuru ve risk ilkesi. Sınır yapay zekâ sistemlerinin geliştirilmesi ve işletilmesi, Türk Borçlar Kanunu'nun 71. maddesi anlamında önemli ölçüde tehlike arz eden işletme faaliyeti olarak nitelendirilebilir.

Tez 23. İdarenin yapay zekâ kullanımından doğan sorumluluğu, beş alt türden oluşan "algoritmik hizmet kusuru" kavramıyla sistemleştirilebilir: seçim, doğrulama, izleme, müdahale ve bilgilendirme kusurları.

Tez 24. Yapay zekâya elektronik kişilik tanınması, sorumluluk boşluğunu kapatmaz; yalnızca yer değiştirir ve sorumluluğu insan

aktörlerden uzaklaştırarak “buharlaştırma” riski taşır. Elektronik kişilik önerisi reddedilmelidir.

Tez 25. Sorumluluğun dağılması sorununa en etkili cevap, “son insan halkası ilkesi”dir: Bir yapay zekâ sisteminin her önemli kullanım bağlamı için, o kullanımın sonuçlarından kişisel olarak hesap verecek, adı belirli, yeterli yetki ve bilgiyle donatılmış ve sistemin kullanımını durdurabilecek en az bir insan bulunmalıdır. Bu ilke, “yapay zekâ sorumlu yöneticisi” kurumuyla somutlaştırılmalıdır.

Tez 26. Şirket içi denetim yapıları ve gönüllü güvenlik taahhütleri, değerli ama yetersizdir. Kasım 2023 yönetim krizi, denetçinin, denetlenenin varlık koşulları üzerinde fiilî bir kontrole sahip olmadıkça, biçimsel yetkisinin işlevsiz kalabileceğini göstermiştir. Gönüllü taahhütler, Duguit’nin Jellinek’e yönelttiği eleştiriye açıktır: Sınırlananın iradesine bağlı bir sınırlama, gerçek bir sınırlama değildir.

S6. Karşılaştırmalı hukuk ve uluslararası düzen.

Tez 27. İncelenen hukuk düzenlerinin hiçbiri, karar vericileri aşma potansiyeline sahip yapay zekânın denetimi sorununa bütünlüklü bir cevap vermemektedir. Avrupa Birliği Yapay Zekâ Tüzüğü en kapsamlı çerçeveyi sunmakta ve insan gözetimini, otomasyon yanlılığını açıkça tanıyarak düzenlemektedir; ancak bireysel insan gözetimine aşırı güvenmekte ve düzenleyicilerin kendisinin denetimini yeterince güvence altına almamaktadır.

Tez 28. Avrupa Konseyi Çerçeve Sözleşmesi, yapay zekâyı bir insan hakları, demokrasi ve hukukun üstünlüğü meselesi olarak tanımlayan ilk bağlayıcı uluslararası antlaşmadır. Türkiye’nin bu Sözleşme’ye taraf olması, Anayasa’nın 90. maddesinin son fıkrası bakımından da önem taşıyan önemli bir kaldıraç oluşturacaktır.

Tez 29. Çin modeli, *denetimin hesap verebilirlikle aynı şey olmadığını* göstermektedir. Yapay zekânın güçlü bir biçimde denetlenmesi, denetleyen hesap verebilir değilse, Juvenalis’in sorusunu çözmez; yalnızca yapay zekânın gücünü, denetlenmeyen bir bekçinin eline teslim eder.

Tez 30. Karşılaştırmanın en önemli bulgusu, mevcut yapay zekâ düzenlemelerinin, yapay zekâyı denetlemeye odaklanmasına karşın, bu denetimi yapanları denetlemeyi büyük ölçüde ihmal etmesi ve sınır yapay zekâ sistemlerinin varlık koşulları denetimini bütünlüklü bir biçimde düzenlememesidir.

S7. Tutarlı bir denetim ve hesap sorma mimarisi.

Tez 31. Juvenalis'in sonsuz geriye gidiş sorunu, "en üstteki bekçi" aranarak değil, birbirini karşılıklı olarak denetleyen çok sayıda katmandan oluşan dairesel bir yapıyla yönetilebilir. Bu çalışmada önerilen "çok katmanlı dairesel denetim modeli", teknik, kurumsal, girdi, toplumsal ve uluslararası olmak üzere beş katmandan oluşur ve bu katmanların her biri, en az bir başka katman tarafından denetlenir.

Tez 32. Dairesel yapı, kendi başına bir güvence değildir; çünkü birbirini denetleyen aktörler işbirliği yaparak yapıyı boşa çıkarabilir. Modelin nihai güvencesi, her katmanda hataların tespit edilmesini ve düzeltilmesini mümkün kılan düzeltilebilirliktir. Dairesellik, bekçiler sorununu ortadan kaldırmaz; onu, Popper'ci anlamda, yönetilebilir kılar.

Tez 33. Varlık koşulları denetimi, yalnızca durdurma *yetkisinin* tanınmasıyla değil, durdurma *kapasitesinin* teknik, örgütsel ve fiziksel olarak güvence altına alınmasıyla desteklenmelidir. Durdurmak kolay, yeniden başlatmak zor olmalıdır ("asimetrik durdurulabilirlik").

Tez 34. Hesap verebilirlik yalnızca geçmişe dönük değil, "önceden hesap verme" biçiminde ileriye dönük olarak da işletilmelidir: Yapay zekâ sistemlerini geliştiren ve kullanan aktörler, sistemleri kullanıma almadan önce, sistemlerin güvenliği, hukuka uygunluğu ve olası etkileri hakkında yetkili foruma hesap vermelidir.

Tez 35. Türk hukuku için, bu ilkeleri somutlaştıran bir "Yapay Zekâ Sistemlerinin Denetimi ve Hesap Verebilirliği Hakkında Kanun" çıkarılmalıdır. Bu kanun; kamusal kullanım için kanuni dayanak, olasılıksal sebep yasağı, gerekçenin insan tarafından oluşturulması, sürüm kilidi, kamu algoritma sicili ve vazgeçebilirlik yükümlülükleri; sınır sistemler için bildirim, güvenlik çerçevesi, bağımsız değerlendirme, ciddi olay bildirimi ve durdurma yükümlülüğü; kendisi de çok yönlü bir hesap verebilirlik ağına tabi bağımsız bir Yapay Zekâ Denetim Kurumu; ve yapay zekâ sorumlu yöneticisi, tehlike sorumluluğu, zorunlu mali güvence, tazmin fonu ve ihbarcı korumalarını içeren bir sorumluluk rejimi öngörmelidir.

II. Hipotezlerin Değerlendirilmesi

H1 (Kaba Bilişsel Denklik Hipotezi) doğrulanmıştır. Birinci Bölüm'deki tarihsel analiz, klasik denetim kuramlarının tamamının örtük olarak kaba bilişsel denklik varsayımına dayandığını; İkinci Bölüm'deki

olgusal analiz ve Sekizinci Bölüm'deki kuramsal analiz ise bu varsayım zayıfladığında sonuç denetiminin işlevini kaybetmeye başladığını, buna karşılık süreç, girdi ve varlık koşulları denetiminin işlevini önemli ölçüde koruduğunu göstermiştir. Hipotez, çalışma sürecinde, dört asimetri türü ayrımıyla ve bu türlerin her biri karşısında dört denetim nesnesinin işlevselliğini gösteren bir matrisle zenginleştirilmiştir. Hipotezin bir sınırlaması da tespit edilmiştir: Stratejik asimetri koşullarında, varlık koşulları denetiminin kendisi de tehdit altındadır ve durdurma kapasitesinin ayrıca güvence altına alınması gerekir.

H2 (Yetki-Zekâ Ayrılığı Hipotezi) doğrulanmıştır. Üçüncü Bölüm'deki felsefi analiz, altı bağımsız argüman aracılığıyla, zekâ üstünlüğünün teorik otorite için gerekçe oluşturabildiğini, ancak pratik otorite için yeterli bir gerekçe oluşturmadığını göstermiştir. Hipoteze yöneltilen en ciddi itiraz, Raz'ın normal gerekçelendirme tezinden gelmektedir; bu itiraz, Raz'ın kendi bağımsızlık koşulu, doğrulama sorunu ve demokratik meşruiyetin kamusal eşitlik temeli aracılığıyla cevaplanmıştır.

H3 (Anayasal Dayanak Hipotezi) doğrulanmıştır. Beşinci Bölüm'deki anayasal analiz, Anayasa'nın 6., 7., 9. ve 138. maddelerinin, hipotezde öngörüldüğü üzere, nihai karar yetkisinin yapay zekâ sistemlerine devrini yasaklayan pozitif hukuk dayanakları içerdiğini göstermiştir. Analiz, hipotezde öngörülmeyen iki ek dayanak daha tespit etmiştir: kanuni hâkim güvencesine ilişkin 37. madde ve asli ve sürekli kamu görevlerinin kamu görevlileri eliyle görülmesine ilişkin 128. madde. Analiz, ayrıca, hipotezin bir sınırlamasını da ortaya koymuştur: Bu anayasal dayanaklar, biçimsel devre karşı güçlü, fiilî devre karşı ise yetersiz bir koruma sağlamaktadır.

H4 (İnsan Sorumluluğu Hipotezi) doğrulanmıştır. Altıncı Bölüm'deki analiz, elektronik kişilik önerisinin, sorumluluk boşluğunu kapatmak yerine sorumluluğu insan aktörlerden uzaklaştırdığını ve beş hesap verebilirlik açığından yalnızca birini kısmen kapatabildiğini göstermiştir. Analiz, ayrıca, mevcut hukuk kurumlarının, insan sorumluluğunu yapay zekâ bağlamında sürdürmek için beklenenden daha fazla imkân sunduğunu ortaya koymuştur.

H5 (Dairesel Denetim Hipotezi) kısmen doğrulanmıştır. Sekizinci Bölüm'de geliştirilen model, Juvenalis'in sonsuz geriye gidiş sorununun, dairesel bir yapıyla "yönetilebileceğini" göstermiştir. Ancak çalışma,

dairesel yapının sorunu kesin olarak "çözmediğini", çünkü birbirini denetleyen aktörlerin işbirliği yaparak yapıyı boşa çıkarabileceğini de kabul etmiştir. Bu nedenle hipotez, şu biçimde düzeltilmelidir: Juvenalis'in sorusu, dairesel bir yapı ve her aşamada düzeltilebilirliğin güvence altına alınmasıyla kesin olarak çözülmez, ama yönetilebilir hâle getirilir; ve bu yapının nihai güvencesi, hiçbir kurumsal tasarımın tek başına sağlayamayacağı bir hukukun üstünlüğü kültürüdür.

III. Çalışmanın Sınırlılıkları ve Gelecek Araştırmalar İçin Öneriler

Bu çalışmanın sınırlılıkları da belirtilmelidir. *Birincisi*, çalışma, yapay zekânın gelecekteki gelişimine ilişkin derin bir belirsizlik altında yazılmıştır. Çalışmanın koşullu yaklaşımı, bu belirsizliği kısmen telafi etmekle birlikte, yapay zekânın beklenmedik yönlerde gelişmesi, çalışmanın bazı varsayımlarını ve önerilerini geçersiz kılabilir. *İkincisi*, çalışma, yapay zekâ güvenliğine ilişkin teknik literatürü, hukukçu ve siyaset bilimci okurun anlayabileceği bir düzeyde ele almıştır; bu literatürün daha derinlemesine bir incelemesi, bazı teknik önerilerin (örneğin hesaplama eşiklerinin, durdurma kapasitesinin teknik gerekliliklerinin) daha ayrıntılı biçimde geliştirilmesini mümkün kılacaktır. *Üçüncüsü*, çalışmanın önerdiği kanun taslağı, ilgili kurumların, uzmanların ve kamuoyunun görüşleri alınmadan hazırlanmış akademik bir öneridir; taslağın uygulanabilirliği, bu tür bir istişare sürecinden geçirilmeden tam olarak değerlendirilemez. *Dördüncüsü*, çalışma, otonom silah sistemleri ve askerî yapay zekâ kullanımını kapsam dışında bırakmıştır; bu alan, kendine özgü uluslararası insancıl hukuk sorunları nedeniyle ayrı bir çalışmayı gerektirmektedir.

Bu sınırlılıklar ışığında, gelecek araştırmalar için şu konular önerilmektedir: algoritmik vesayetin göstergelerinin ampirik olarak ölçülmesi ve Türk kamu yönetiminde yapay zekâ kullanımının bu göstergeler bakımından incelenmesi; Türk idari yargısının algoritmik idari işlemlere ilişkin içtihadının izlenmesi ve değerlendirilmesi; hesaplama altyapısının uluslararası denetimine ilişkin hukuki ve teknik mekanizmaların ayrıntılı tasarımı; yapay zekâ sistemlerinin durdurma kapasitesinin teknik ve hukuki gerekliliklerinin belirlenmesi; ve yapay zekânın demokratik müzakere süreçlerine katılımının, bu süreçlerin bütünlüğünü bozmayacak biçimde nasıl tasarlanabileceğinin incelenmesi.

IV. Son Söz

Bu çalışmanın başında, 1607 yılında Sir Edward Coke'un, Kral I. James'e, hukukun "doğal akılla" değil, "yapay akılla" uygulandığını söylediği sahne anılmıştı. Coke'un yapay aklı, kuşaklar boyu biriken, kurumlarca taşınan, eleştiriye açık ve hesap verebilir bir insan aklıydı. Bugün karşımızdaki yapay akıl, harfiyen bir makine aklıdır ve belki de bir gün, onu denetlemekle görevli insan aklını aşacaktır.

Bu çalışmanın vardığı sonuç, Coke'un dersinin, bu yeni durumda da geçerliliğini koruduğudur; ama ters bir yönde. Coke, yetkinin, bilgiye ve yetkinliğe ait olması gerektiğini savunurken, bu bilginin ve yetkinliğin hesap verebilir bir kurumsal çerçeve içinde yer aldığını varsayıyordu. Yapay zekâ çağında, bilginin ve yetkinliğin bu çerçevenin dışında ortaya çıkma ihtimali, bizi şu sonuca götürmektedir: Yetki, bilginin ve yetkinliğin en yüksek olduğu yerde değil, hesap verebilirliğin, düzeltilebilirliğin ve demokratik meşruiyetin bulunduğu yerde kalmalıdır. Yapay akıl, bize danışmanlık yapabilir, bizi bilgilendirebilir, bizim için hesaplayabilir; ama karar vermek ve kararlarımızın sorumluluğunu taşımak, bize, yani insanlara ve onların kurduğu kurumlara ait olmaya devam etmelidir.

Juvenalis'in sorusu, yapay zekâ çağında da cevapsız kalmayacaktır; ama cevabı, tek bir bekçide değil, birbirini bekleyen bekçilerin çemberinde ve bu çemberi ayakta tutan özgür ve düşünen yurttaşların iradesinde aranmalıdır.

KAYNAKÇA

Not: Klasik eserlere metin içinde standart kitap, bölüm, paragraf veya pasaj numaralarıyla atıf yapılmıştır. Güncel baskısı sürekli yenilenen Türkçe ders kitaplarında baskı yılı yerine "güncel bası" ifadesi kullanılmıştır. Yayına hazırlık aşamasında tüm künyelerin ve sayfa atıflarının kullanılan baskılara göre doğrulanması gerekmektedir.

A. Klasik Eserler

ARİSTOTELES: *Politika* (çeşitli baskılar; Bekker numaralandırmasıyla atıf yapılmıştır).

ARİSTOTELES: *Nikomakhos'a Etik* (çeşitli baskılar; Bekker numaralandırmasıyla atıf yapılmıştır).

BENTHAM, Jeremy: *Panopticon; or, The Inspection-House*, Dublin/London, 1791.

BODIN, Jean: *Les six livres de la République*, Paris, Jacques du Puys, 1576.

BRACTON, Henry de: *De legibus et consuetudinibus Angliae* (XIII. yüzyıl; folio numaralandırmasıyla atıf yapılmıştır).

BUTLER, Samuel: *Erewhon, or Over the Range*, London, Trübner, 1872.

CICERO: *De re publica* (çeşitli baskılar).

CICERO: *Pro Cluentio* (çeşitli baskılar).

COKE, Edward: *The First Part of the Institutes of the Laws of England, or a Commentary upon Littleton*, London, 1628.

CONDORCET, Marquis de: *Essai sur l'application de l'analyse à la probabilité des décisions rendues à la pluralité des voix*, Paris, Imprimerie Royale, 1785.

HAMILTON, Alexander / MADISON, James / JAY, John: *The Federalist*, New York, 1788.

HOBBES, Thomas: *Leviathan, or the Matter, Forme and Power of a Common-Wealth Ecclesiasticall and Civill*, London, Andrew Crooke, 1651 (Latince baskı: Amsterdam, 1668).

HOBBES, Thomas: *A Dialogue between a Philosopher and a Student of the Common Laws of England*, London, 1681.

HUME, David: "Of the Independency of Parliament", *Essays, Moral and Political*, Edinburgh, 1741.

JUSTINIANUS: *Corpus Iuris Civilis* (*Digesta*; *Codex Iustinianus*).

JUVENALIS, Decimus Iunius: *Saturae* (çeşitli baskılar).

KANT, Immanuel: "Beantwortung der Frage: Was ist Aufklärung?", *Berlinische Monatsschrift*, Aralık 1784.

KANT, Immanuel: *Grundlegung zur Metaphysik der Sitten*, Riga, Hartknoch, 1785.

KANT, Immanuel: *Zum ewigen Frieden. Ein philosophischer Entwurf*, Königsberg, Nicolovius, 1795.

LOCKE, John: *Two Treatises of Government*, London, Awnsham Churchill, 1689.

MILL, John Stuart: *Considerations on Representative Government*, London, Parker, Son and Bourn, 1861.

MONTESQUIEU, Charles-Louis de Secondat: *De l'esprit des lois*, Genève, Barrillot, 1748.

PLATON: *Devlet* (*Politeia*), *Devlet Adamı* (*Politikos*), *Yasalar* (*Nomoi*) (çeşitli baskılar; Stephanus numaralandırmasıyla atıf yapılmıştır).

POLYBİOS: *Tarihler* (çeşitli baskılar).

SAINT-SIMON, Henri de: *L'Organisateur*, Paris, 1819-1820.

B. Kitaplar, Kitap Bölümleri ve Makaleler

ABBOTT, Ryan: *The Reasonable Robot: Artificial Intelligence and the Law*, Cambridge, Cambridge University Press, 2020.

ABBOTT, Ryan / SARCH, Alexander: "Punishing Artificial Intelligence: Legal Fiction or Science Fiction", *UC Davis Law Review*, C. 53, S. 1, 2019.

ACEMOGLU, Daron / JOHNSON, Simon: *Power and Progress: Our Thousand-Year Struggle Over Technology and Prosperity*, New York, PublicAffairs, 2023.

ALON-BARKAT, Saar / BUSUIOC, Madalina: "Human–AI Interactions in Public Sector Decision Making: 'Automation Bias' and 'Selective Adherence' to Algorithmic Advice", *Journal of Public Administration Research and Theory*, C. 33, S. 1, 2023.

ANDERLJUNG, Markus vd.: "Frontier AI Regulation: Managing Emerging Risks to Public Safety", arXiv:2307.03718, 2023.

ANEESH, A.: *Virtual Migration: The Programming of Globalization*, Durham, Duke University Press, 2006.

ANEESH, A.: "Global Labor: Algocratic Modes of Organization", *Sociological Theory*, C. 27, S. 4, 2009.

ANGWIN, Julia / LARSON, Jeff / MATTU, Surya / KIRCHNER, Lauren: "Machine Bias", *ProPublica*, 23 Mayıs 2016.

ARENDT, Hannah: *Eichmann in Jerusalem: A Report on the Banality of Evil*, New York, Viking Press, 1963.

ARENDT, Hannah: *On Violence*, New York, Harcourt, Brace & World, 1970.

ARMSTRONG, Stuart / BOSTROM, Nick / SHULMAN, Carl: "Racing to the Precipice: A Model of Artificial Intelligence Development", *AI & Society*, C. 31, S. 2, 2016.

BAI, Yuntao vd.: "Constitutional AI: Harmlessness from AI Feedback", arXiv:2212.08073, 2022.

BAINBRIDGE, Lisanne: "Ironies of Automation", *Automatica*, C. 19, S. 6, 1983.

BAKER, Bowen vd.: "Monitoring Reasoning Models for Misbehavior and the Risks of Promoting Obfuscation", arXiv:2503.11926, 2025.

BARNES, Beth / CHRISTIANO, Paul: "Debate Update: Obfuscated Arguments Problem", AI Alignment Forum, 2020.

BEN-SHAHAR, Omri / LOGUE, Kyle D.: "Outsourcing Regulation: How Insurance Reduces Moral Hazard", *Michigan Law Review*, C. 111, S. 2, 2012.

BENDER, Emily M. / GEBRU, Timnit vd.: “On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?”, *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, 2021.

BIRCH, Jonathan: *The Edge of Sentience: Risk and Precaution in Humans, Other Animals, and AI*, Oxford, Oxford University Press, 2024.

BIRHANE, Abeba vd.: “AI Auditing: The Broken Bus on the Road to AI Accountability”, *Proceedings of the 2024 IEEE Conference on Secure and Trustworthy Machine Learning (SaTML)*, 2024.

BÖCKENFÖRDE, Ernst-Wolfgang: “Die Entstehung des Staates als Vorgang der Säkularisation” (1967), *Recht, Staat, Freiheit*, Frankfurt am Main, Suhrkamp, 1991.

BOSTROM, Nick: “The Superintelligent Will: Motivation and Instrumental Rationality in Advanced Artificial Agents”, *Minds and Machines*, C. 22, S. 2, 2012.

BOSTROM, Nick: *Superintelligence: Paths, Dangers, Strategies*, Oxford, Oxford University Press, 2014.

BOVENS, Mark: “Analysing and Assessing Accountability: A Conceptual Framework”, *European Law Journal*, C. 13, S. 4, 2007.

BOVENS, Mark / ZOURIDIS, Stavros: “From Street-Level to System-Level Bureaucracies: How Information and Communication Technology is Transforming Administrative Discretion and Constitutional Control”, *Public Administration Review*, C. 62, S. 2, 2002.

BOWMAN, Samuel R. vd.: “Measuring Progress on Scalable Oversight for Large Language Models”, arXiv:2211.03540, 2022.

BRADFORD, Anu: *The Brussels Effect: How the European Union Rules the World*, New York, Oxford University Press, 2020.

BRATTON, Benjamin H.: *The Stack: On Software and Sovereignty*, Cambridge (MA), MIT Press, 2015.

BRENNAN, Jason: *Against Democracy*, Princeton, Princeton University Press, 2016.

BRYSON, Joanna J. / DIAMANTIS, Mihailis E. / GRANT, Thomas D.: “Of, For, and By the People: The Legal Lacuna of Synthetic Persons”, *Artificial Intelligence and Law*, C. 25, S. 3, 2017.

BURNS, Collin vd.: “Weak-to-Strong Generalization: Eliciting Strong Capabilities With Weak Supervision”, arXiv:2312.09390, 2023.

BUSUIOC, Madalina: “Accountable Artificial Intelligence: Holding Algorithms to Account”, *Public Administration Review*, C. 81, S. 5, 2021.

BUTLIN, Patrick vd.: “Consciousness in Artificial Intelligence: Insights from the Science of Consciousness”, arXiv:2308.08708, 2023.

CASEY, Anthony J. / NIBLETT, Anthony: “The Death of Rules and Standards”, *Indiana Law Journal*, C. 92, S. 4, 2017.

CENTEL, Nur / ZAFER, Hamide / ÇAKMUT, Özlem: *Türk Ceza Hukukuna Giriş*, İstanbul, Beta, güncel bası.

CHEN, Yanda vd.: “Reasoning Models Don’t Always Say What They Think”, arXiv:2505.05410, 2025.

CHENOWETH, Erica / STEPHAN, Maria J.: *Why Civil Resistance Works: The Strategic Logic of Nonviolent Conflict*, New York, Columbia University Press, 2011.

CHOLLET, François: “On the Measure of Intelligence”, arXiv:1911.01547, 2019.

CHOULDECHOVA, Alexandra: “Fair Prediction with Disparate Impact: A Study of Bias in Recidivism Prediction Instruments”, *Big Data*, C. 5, S. 2, 2017.

CHRISTIAN, Brian: *The Alignment Problem: Machine Learning and Human Values*, New York, W. W. Norton, 2020.

CHRISTIANO, Paul F. vd.: “Deep Reinforcement Learning from Human Preferences”, *Advances in Neural Information Processing Systems* 30, 2017.

CHRISTIANO, Paul / SHLEGERIS, Buck / AMODEI, Dario: “Supervising Strong Learners by Amplifying Weak Experts”, arXiv:1810.08575, 2018.

CHRISTIANO, Thomas: *The Constitution of Equality: Democratic Authority and Its Limits*, Oxford, Oxford University Press, 2008.

CLARK, Jack / AMODEI, Dario: “Faulty Reward Functions in the Wild”, OpenAI Blog, 21 Aralık 2016.

COHEN, Julie E.: *Between Truth and Power: The Legal Constructions of Informational Capitalism*, New York, Oxford University Press, 2019.

COLLINGRIDGE, David: *The Social Control of Technology*, London, Frances Pinter, 1980.

COSTANZA-CHOCK, Sasha / RAJI, Inioluwa Deborah / BUOLAMWINI, Joy: "Who Audits the Auditors? Recommendations from a Field Scan of the Algorithmic Auditing Ecosystem", *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency (FAccT)*, 2022.

COSTELLO, Thomas H. / PENNYCOOK, Gordon / RAND, David G.: "Durably Reducing Conspiracy Beliefs through Dialogues with AI", *Science*, C. 385, S. 6714, 2024.

DAHL, Robert A.: *Democracy and Its Critics*, New Haven, Yale University Press, 1989.

DANAHER, John: "The Threat of Algocracy: Reality, Resistance and Accommodation", *Philosophy & Technology*, C. 29, S. 3, 2016.

DANAHER, John: "Robots, Law and the Retribution Gap", *Ethics and Information Technology*, C. 18, S. 4, 2016.

DARWALL, Stephen: *The Second-Person Standpoint: Morality, Respect, and Accountability*, Cambridge (MA), Harvard University Press, 2006.

DAVIDSON, Tom / FINNVEDEN, Lukas / HADSHAR, Rose: "AI-Enabled Coups: How a Small Group Could Use AI to Seize Power", Forethought, Nisan 2025.

DELEUZE, Gilles: "Post-scriptum sur les sociétés de contrôle", *L'Autre journal*, S. 1, Mayıs 1990.

DELL'ACQUA, Fabrizio vd.: "Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality", *Harvard Business School Working Paper*, No. 24-013, 2023.

DIETVORST, Berkeley J. / SIMMONS, Joseph P. / MASSEY, Cade: "Algorithm Aversion: People Erroneously Avoid Algorithms After Seeing Them Err", *Journal of Experimental Psychology: General*, C. 144, S. 1, 2015.

DRESSEL, Julia / FARID, Hany: "The Accuracy, Fairness, and Limits of Predicting Recidivism", *Science Advances*, C. 4, S. 1, 2018.

DUGUIT, Léon: *Traité de droit constitutionnel*, 2. Bası, Paris, Fontemoing, 1921-1925.

ELHAGE, Nelson vd.: "A Mathematical Framework for Transformer Circuits", Transformer Circuits Thread, 2021.

ELISH, Madeleine Clare: "Moral Crumple Zones: Cautionary Tales in Human-Robot Interaction", *Engaging Science, Technology, and Society*, C. 5, 2019.

ELLUL, Jacques: *La technique ou l'enjeu du siècle*, Paris, Armand Colin, 1954.

EREN, Fikret: *Borçlar Hukuku Genel Hükümler*, Ankara, Yetkin, güncel bası.

ESTLUND, David M.: *Democratic Authority: A Philosophical Framework*, Princeton, Princeton University Press, 2008.

FELDSTEIN, Steven: *The Rise of Digital Repression: How Technology is Reshaping Power, Politics, and Resistance*, New York, Oxford University Press, 2021.

FISHKIN, James S.: *When the People Speak: Deliberative Democracy and Public Consultation*, Oxford, Oxford University Press, 2009.

FOUCAULT, Michel: *Surveiller et punir: Naissance de la prison*, Paris, Gallimard, 1975.

FULLER, Lon L.: *The Morality of Law*, New Haven, Yale University Press, 1964.

GABRIEL, Iason: "Artificial Intelligence, Values, and Alignment", *Minds and Machines*, C. 30, S. 3, 2020.

GODDARD, Kate / ROUDSARI, Abdul / WYATT, Jeremy C.: "Automation Bias: A Systematic Review of Frequency, Effect Mediators, and Mitigators", *Journal of the American Medical Informatics Association*, C. 19, S. 1, 2012.

GOLDMAN, Alvin I.: "Experts: Which Ones Should You Trust?", *Philosophy and Phenomenological Research*, C. 63, S. 1, 2001.

GOOD, I. J.: "Speculations Concerning the First Ultraintelligent Machine", *Advances in Computers*, C. 6, 1965.

GOODHART, Charles A. E.: “Problems of Monetary Management: The U.K. Experience”, *Papers in Monetary Economics*, Reserve Bank of Australia, 1975.

GÖZLER, Kemal: *İdare Hukuku*, C. I-II, Bursa, Ekin, güncel bası.

GÖZLER, Kemal: *Türk Anayasa Hukuku*, Bursa, Ekin, güncel bası.

GRACE, Katja vd.: “Thousands of AI Authors on the Future of AI”, arXiv:2401.02843, 2024.

GREEN, Ben: “The Flaws of Policies Requiring Human Oversight of Government Algorithms”, *Computer Law & Security Review*, C. 45, 2022.

GREEN, Ben / CHEN, Yiling: “Disparate Interactions: An Algorithm-in-the-Loop Analysis of Fairness in Risk Assessments”, *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAT*)*, 2019.

GREENBLATT, Ryan vd.: “Alignment Faking in Large Language Models”, arXiv:2412.14093, 2024.

GREENBLATT, Ryan / SHLEGERIS, Buck / SACHAN, Kshitij / ROGER, Fabien: “AI Control: Improving Safety Despite Intentional Subversion”, *Proceedings of the 41st International Conference on Machine Learning*, 2024.

GÜNDAY, Metin: *İdare Hukuku*, Ankara, İmaj, güncel bası.

GUSTON, David H.: “Understanding ‘Anticipatory Governance’”, *Social Studies of Science*, C. 44, S. 2, 2014.

HABERMAS, Jürgen: *Technik und Wissenschaft als ‘Ideologie’*, Frankfurt am Main, Suhrkamp, 1968.

HABERMAS, Jürgen: *Faktizität und Geltung: Beiträge zur Diskurstheorie des Rechts und des demokratischen Rechtsstaats*, Frankfurt am Main, Suhrkamp, 1992.

HADFIELD-MENELL, Dylan / DRAGAN, Anca / ABBEEL, Pieter / RUSSELL, Stuart: “The Off-Switch Game”, *Proceedings of the 26th International Joint Conference on Artificial Intelligence*, 2017.

HALLEVY, Gabriel: *Liability for Crimes Involving Artificial Intelligence Systems*, Cham, Springer, 2015.

HARDWIG, John: “Epistemic Dependence”, *The Journal of Philosophy*, C. 82, S. 7, 1985.

HART, H. L. A.: *The Concept of Law*, Oxford, Clarendon Press, 1961.

HART, H. L. A.: *Punishment and Responsibility: Essays in the Philosophy of Law*, Oxford, Clarendon Press, 1968.

HAYEK, Friedrich A.: "The Use of Knowledge in Society", *American Economic Review*, C. 35, S. 4, 1945.

HERSHOVITZ, Scott: "Legitimacy, Democracy, and Razian Authority", *Legal Theory*, C. 9, S. 3, 2003.

HILDEBRANDT, Mireille: *Smart Technologies and the End(s) of Law: Novel Entanglements of Law and Technology*, Cheltenham, Edward Elgar, 2015.

HIRSCHMAN, Albert O.: *Exit, Voice, and Loyalty: Responses to Decline in Firms, Organizations, and States*, Cambridge (MA), Harvard University Press, 1970.

HO, Lewis vd.: "International Institutions for Advanced AI", arXiv:2307.04699, 2023.

HOFFMANN, Jordan vd.: "Training Compute-Optimal Large Language Models", arXiv:2203.15556, 2022.

HONG, Lu / PAGE, Scott E.: "Groups of Diverse Problem Solvers Can Outperform Groups of High-Ability Problem Solvers", *Proceedings of the National Academy of Sciences*, C. 101, S. 46, 2004.

HUBINGER, Evan vd.: "Risks from Learned Optimization in Advanced Machine Learning Systems", arXiv:1906.01820, 2019.

HUBINGER, Evan vd.: "Sleeper Agents: Training Deceptive LLMs that Persist Through Safety Training", arXiv:2401.05566, 2024.

HUQ, Aziz Z.: "A Right to a Human Decision", *Virginia Law Review*, C. 106, S. 3, 2020.

IRVING, Geoffrey / CHRISTIANO, Paul / AMODEI, Dario: "AI Safety via Debate", arXiv:1805.00899, 2018.

JASANOFF, Sheila: *The Fifth Branch: Science Advisers as Policymakers*, Cambridge (MA), Harvard University Press, 1990.

JASANOFF, Sheila: "Technologies of Humility: Citizen Participation in Governing Science", *Minerva*, C. 41, S. 3, 2003.

JELLINEK, Georg: *Die rechtliche Natur der Staatenverträge*, Wien, Hölder, 1880.

JELLINEK, Georg: *System der subjektiven öffentlichen Rechte*, Freiburg, Mohr, 1892.

JELLINEK, Georg: *Allgemeine Staatslehre*, Berlin, O. Häring, 1900.

JENSEN, Michael C. / MECKLING, William H.: "Theory of the Firm: Managerial Behavior, Agency Costs and Ownership Structure", *Journal of Financial Economics*, C. 3, S. 4, 1976.

JERVIS, Robert: "Cooperation under the Security Dilemma", *World Politics*, C. 30, S. 2, 1978.

JONAS, Hans: *Das Prinzip Verantwortung: Versuch einer Ethik für die technologische Zivilisation*, Frankfurt am Main, Insel, 1979.

KAPLAN, Jared vd.: "Scaling Laws for Neural Language Models", arXiv:2001.08361, 2020.

KELSEN, Hans: "Wer soll der Hüter der Verfassung sein?", *Die Justiz*, C. 6, 1931.

KELSEN, Hans: *Reine Rechtslehre*, Wien, Deuticke, 1934; 2. Bası, 1960.

KLEINBERG, Jon / MULLAINATHAN, Sendhil / RAGHAVAN, Manish: "Inherent Trade-Offs in the Fair Determination of Risk Scores", arXiv:1609.05807, 2016.

KLEINBERG, Jon / RAGHAVAN, Manish: "Algorithmic Monoculture and Social Welfare", *Proceedings of the National Academy of Sciences*, C. 118, S. 22, 2021.

KLONICK, Kate: "The Facebook Oversight Board: Creating an Independent Institution to Adjudicate Online Free Expression", *Yale Law Journal*, C. 129, S. 8, 2020.

KOCA, Mahmut / ÜZÜLMEZ, İlhan: *Türk Ceza Hukuku Genel Hükümler*, Ankara, Seçkin, güncel bası.

KORBAK, Tomek vd.: "Chain of Thought Monitorability: A New and Fragile Opportunity for AI Safety", arXiv:2507.11473, 2025.

KOSELLECK, Reinhart: *Vergangene Zukunft: Zur Semantik geschichtlicher Zeiten*, Frankfurt am Main, Suhrkamp, 1979.

KRAKOVNA, Victoria vd.: "Specification Gaming: The Flip Side of AI Ingenuity", DeepMind Blog, 21 Nisan 2020.

KRIZHEVSKY, Alex / SUTSKEVER, Ilya / HINTON, Geoffrey E.: “ImageNet Classification with Deep Convolutional Neural Networks”, *Advances in Neural Information Processing Systems* 25, 2012.

KULVEIT, Jan / DOUGLAS, Raymond / AMMANN, Nora / TURAN, Deger / KRUEGER, David / DUVENAUD, David: “Gradual Disempowerment: Systemic Existential Risks from Incremental AI Development”, arXiv:2501.16946, 2025.

KURKI, Visa A. J.: *A Theory of Legal Personhood*, Oxford, Oxford University Press, 2019.

KWA, Thomas vd.: “Measuring AI Ability to Complete Long Tasks”, arXiv:2503.14499, 2025.

LANDEMORE, Hélène: *Democratic Reason: Politics, Collective Intelligence, and the Rule of the Many*, Princeton, Princeton University Press, 2013.

LEGG, Shane / HUTTER, Marcus: “Universal Intelligence: A Definition of Machine Intelligence”, *Minds and Machines*, C. 17, S. 4, 2007.

LEIKE, Jan vd.: “Scalable Agent Alignment via Reward Modeling: A Research Direction”, arXiv:1811.07871, 2018.

LESSIG, Lawrence: *Code and Other Laws of Cyberspace*, New York, Basic Books, 1999; *Code: Version 2.0*, New York, Basic Books, 2006.

LINDSEY, Jack vd.: “On the Biology of a Large Language Model”, Transformer Circuits Thread, 2025.

LIPSKY, Michael: *Street-Level Bureaucracy: Dilemmas of the Individual in Public Services*, New York, Russell Sage Foundation, 1980.

LOGG, Jennifer M. / MINSON, Julia A. / MOORE, Don A.: “Algorithm Appreciation: People Prefer Algorithmic to Human Judgment”, *Organizational Behavior and Human Decision Processes*, C. 151, 2019.

LONG, Robert / SEBO, Jeff vd.: “Taking AI Welfare Seriously”, arXiv:2411.00986, 2024.

LYNCH, Aengus vd.: “Agentic Misalignment: How LLMs Could Be Insider Threats”, Anthropic, Haziran 2025.

MACKWORTH, N. H.: “The Breakdown of Vigilance during Prolonged Visual Search”, *Quarterly Journal of Experimental Psychology*, C. 1, S. 1, 1948.

MANN, Michael: “The Autonomous Power of the State: Its Origins, Mechanisms and Results”, *European Journal of Sociology*, C. 25, S. 2, 1984.

MARCUS, Gary / DAVIS, Ernest: *Rebooting AI: Building Artificial Intelligence We Can Trust*, New York, Pantheon, 2019.

MATTHIAS, Andreas: “The Responsibility Gap: Ascribing Responsibility for the Actions of Learning Automata”, *Ethics and Information Technology*, C. 6, S. 3, 2004.

McCARTHY, John / MINSKY, Marvin L. / ROCHESTER, Nathaniel / SHANNON, Claude E.: *A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence*, 31 Ağustos 1955.

McCUBBINS, Mathew D. / SCHWARTZ, Thomas: “Congressional Oversight Overlooked: Police Patrols versus Fire Alarms”, *American Journal of Political Science*, C. 28, S. 1, 1984.

MEINKE, Alexander vd.: “Frontier Models are Capable of In-context Scheming”, arXiv:2412.04984, 2024.

MOROZOV, Evgeny: “Critique of Techno-Feudal Reason”, *New Left Review*, S. 133/134, 2022.

MORRIS, Meredith Ringel vd.: “Levels of AGI for Operationalizing Progress on the Path to AGI”, arXiv:2311.02462, 2023.

MULGAN, Richard: “‘Accountability’: An Ever-Expanding Concept?”, *Public Administration*, C. 78, S. 3, 2000.

MUMFORD, Lewis: “Authoritarian and Democratic Technics”, *Technology and Culture*, C. 5, S. 1, 1964.

NARAYANAN, Arvind / KAPOOR, Sayash: *AI Snake Oil*, Princeton, Princeton University Press, 2024.

NARAYANAN, Arvind / KAPOOR, Sayash: “AI as Normal Technology”, Knight First Amendment Institute, Columbia University, Nisan 2025.

NISSENBAUM, Helen: “Accountability in a Computerized Society”, *Science and Engineering Ethics*, C. 2, S. 1, 1996.

O'DONNELL, Guillermo: "Horizontal Accountability in New Democracies", *Journal of Democracy*, C. 9, S. 3, 1998.

OĞUZMAN, M. Kemal / ÖZ, M. Turgut: *Borçlar Hukuku Genel Hükümler*, C. II, İstanbul, Vedat, güncel bası.

OLAH, Chris vd.: "Zoom In: An Introduction to Circuits", *Distill*, 2020.

OMOHUNDRO, Steve: "The Basic AI Drives", *Proceedings of the First AGI Conference*, Amsterdam, IOS Press, 2008.

OSTROM, Elinor: *Governing the Commons: The Evolution of Institutions for Collective Action*, Cambridge, Cambridge University Press, 1990.

OSTROM, Elinor: "Beyond Markets and States: Polycentric Governance of Complex Economic Systems", *American Economic Review*, C. 100, S. 3, 2010.

OUYANG, Long vd.: "Training Language Models to Follow Instructions with Human Feedback", *Advances in Neural Information Processing Systems* 35, 2022.

ÖZBUDUN, Ergun: *Türk Anayasa Hukuku*, Ankara, Yetkin, güncel bası.

ÖZBUDUN, Ergun / GENÇKAYA, Ömer Faruk: *Democratization and the Politics of Constitution-Making in Turkey*, Budapest, Central European University Press, 2009.

PAGALLO, Ugo: *The Laws of Robots: Crimes, Contracts, and Torts*, Dordrecht, Springer, 2013.

PARASURAMAN, Raja / RILEY, Victor: "Humans and Automation: Use, Misuse, Disuse, Abuse", *Human Factors*, C. 39, S. 2, 1997.

PASQUALE, Frank: *The Black Box Society: The Secret Algorithms That Control Money and Information*, Cambridge (MA), Harvard University Press, 2015.

PETTIT, Philip: *Republicanism: A Theory of Freedom and Government*, Oxford, Clarendon Press, 1997.

PETTIT, Philip: "Republican Freedom and Contestatory Democratization", SHAPIRO, Ian / HACKER-CORDÓN, Casiano (der.), *Democracy's Value*, Cambridge, Cambridge University Press, 1999.

PETTIT, Philip: *On the People's Terms: A Republican Theory and Model of Democracy*, Cambridge, Cambridge University Press, 2012.

POPPER, Karl R.: *The Open Society and Its Enemies*, C. I: *The Spell of Plato*, London, Routledge, 1945.

POPPER, Karl R.: "The Open Society and Its Enemies Revisited", *The Economist*, 23 Nisan 1988.

RAUSTIALA, Kal / VICTOR, David G.: "The Regime Complex for Plant Genetic Resources", *International Organization*, C. 58, S. 2, 2004.

RAWLS, John: *A Theory of Justice*, Cambridge (MA), Harvard University Press, 1971.

RAZ, Joseph: "Authority, Law and Morality", *The Monist*, C. 68, S. 3, 1985.

RAZ, Joseph: *The Morality of Freedom*, Oxford, Clarendon Press, 1986.

RAZ, Joseph: "The Problem of Authority: Revisiting the Service Conception", *Minnesota Law Review*, C. 90, 2006.

REIDENBERG, Joel R.: "Lex Informatica: The Formulation of Information Policy Rules Through Technology", *Texas Law Review*, C. 76, S. 3, 1998.

ROUVROY, Antoinette / BERNS, Thomas: "Gouvernementalité algorithmique et perspectives d'émancipation: Le disparate comme condition d'individuation par la relation?", *Réseaux*, C. 177, S. 1, 2013.

RUSSELL, Stuart: *Human Compatible: Artificial Intelligence and the Problem of Control*, New York, Viking, 2019.

RUSSELL, Stuart J. / NORVIG, Peter: *Artificial Intelligence: A Modern Approach*, 4. Bası, Hoboken, Pearson, 2020.

SALVI, Francesco / HORTA RIBEIRO, Manoel / GALLOTTI, Riccardo / WEST, Robert: "On the Conversational Persuasiveness of Large Language Models: A Randomized Controlled Trial", arXiv:2403.14380, 2024.

SANTONI DE SIO, Filippo / MECACCI, Giulio: "Four Responsibility Gaps with Artificial Intelligence: Why they Matter and How to Address them", *Philosophy & Technology*, C. 34, S. 4, 2021.

SANTONI DE SIO, Filippo / VAN DEN HOVEN, Jeroen: “Meaningful Human Control over Autonomous Systems: A Philosophical Account”, *Frontiers in Robotics and AI*, C. 5, 2018.

SASTRY, Girish vd.: “Computing Power and the Governance of Artificial Intelligence”, arXiv:2402.08797, 2024.

SCHEDLER, Andreas: “Conceptualizing Accountability”, SCHEDLER, Andreas / DIAMOND, Larry / PLATTNER, Marc F. (der.), *The Self-Restraining State: Power and Accountability in New Democracies*, Boulder, Lynne Rienner, 1999.

SCHELSKY, Helmut: *Der Mensch in der wissenschaftlichen Zivilisation*, Köln/Opladen, Westdeutscher Verlag, 1961.

SCHMITT, Carl: *Politische Theologie: Vier Kapitel zur Lehre von der Souveränität*, München/Leipzig, Duncker & Humblot, 1922.

SCHMITT, Carl: *Der Hüter der Verfassung*, Tübingen, Mohr, 1931.

SHARMA, Mrinank vd.: “Towards Understanding Sycophancy in Language Models”, arXiv:2310.13548, 2023.

SHARP, Gene: *The Politics of Nonviolent Action*, Boston, Porter Sargent, 1973.

SHAVIT, Yonadav: “What Does It Take to Catch a Chinchilla? Verifying Rules on Large-Scale Neural Network Training via Compute Monitoring”, arXiv:2303.11341, 2023.

SHEVLANE, Toby vd.: “Model Evaluation for Extreme Risks”, arXiv:2305.15324, 2023.

SILVER, David vd.: “Mastering the Game of Go with Deep Neural Networks and Tree Search”, *Nature*, C. 529, 2016.

SKITKA, Linda J. / MOSIER, Kathleen L. / BURDICK, Mark: “Does Automation Bias Decision-Making?”, *International Journal of Human-Computer Studies*, C. 51, S. 5, 1999.

SOARES, Nate / FALLENSTEIN, Benja / YUDKOWSKY, Eliezer / ARMSTRONG, Stuart: “Corrigibility”, *AAAI Workshop on AI and Ethics*, 2015.

SOLUM, Lawrence B.: “Legal Personhood for Artificial Intelligences”, *North Carolina Law Review*, C. 70, S. 4, 1992.

SPARROW, Robert: “Killer Robots”, *Journal of Applied Philosophy*, C. 24, S. 1, 2007.

STIGLER, George J.: “The Theory of Economic Regulation”, *The Bell Journal of Economics and Management Science*, C. 2, S. 1, 1971.

STRATHERN, Marilyn: “‘Improving Ratings’: Audit in the British University System”, *European Review*, C. 5, S. 3, 1997.

SUSSER, Daniel / ROESSLER, Beate / NISSENBAUM, Helen: “Technology, Autonomy, and Manipulation”, *Internet Policy Review*, C. 8, S. 2, 2019.

TEMPLETON, Adly vd.: “Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet”, Transformer Circuits Thread, 2024.

TESSLER, Michael Henry vd.: “AI Can Help Humans Find Common Ground in Democratic Deliberation”, *Science*, C. 386, S. 6719, 2024.

THALER, Richard H. / SUNSTEIN, Cass R.: *Nudge: Improving Decisions About Health, Wealth, and Happiness*, New Haven, Yale University Press, 2008.

THOMPSON, Dennis F.: “Moral Responsibility of Public Officials: The Problem of Many Hands”, *American Political Science Review*, C. 74, S. 4, 1980.

TIGARD, Daniel W.: “There Is No Techno-Responsibility Gap”, *Philosophy & Technology*, C. 34, S. 3, 2021.

TURING, Alan M.: “Computing Machinery and Intelligence”, *Mind*, C. 59, S. 236, 1950.

TURING, Alan M.: “Intelligent Machinery, A Heretical Theory” (1951), *Philosophia Mathematica*, C. 4, S. 3, 1996.

TURNER, Alexander Matt vd.: “Optimal Policies Tend to Seek Power”, *Advances in Neural Information Processing Systems* 34, 2021.

TURPIN, Miles vd.: “Language Models Don’t Always Say What They Think: Unfaithful Explanations in Chain-of-Thought Prompting”, *Advances in Neural Information Processing Systems* 36, 2023.

ULUSOY, Ali: *Bağımsız İdari Otoriteler*, Ankara, Turhan, 2003.

VAROUFAKIS, Yanis: *Technofeudalism: What Killed Capitalism*, London, Bodley Head, 2023.

VASWANI, Ashish vd.: “Attention Is All You Need”, *Advances in Neural Information Processing Systems* 30, 2017.

VEBLEN, Thorstein: *The Engineers and the Price System*, New York, B. W. Huebsch, 1921.

WEBER, Max: “Die protestantische Ethik und der ‘Geist’ des Kapitalismus”, *Archiv für Sozialwissenschaft und Sozialpolitik*, C. 20-21, 1904-1905.

WEBER, Max: “Parlament und Regierung im neugeordneten Deutschland” (1918), *Gesammelte politische Schriften*, München, Drei Masken, 1921.

WEBER, Max: *Politik als Beruf*, München/Leipzig, Duncker & Humblot, 1919.

WEBER, Max: *Wirtschaft und Gesellschaft*, Tübingen, Mohr, 1922.

WIENER, Norbert: “Some Moral and Technical Consequences of Automation”, *Science*, C. 131, S. 3410, 1960.

WINNER, Langdon: *Autonomous Technology: Technics-out-of-Control as a Theme in Political Thought*, Cambridge (MA), MIT Press, 1977.

WINNER, Langdon: “Do Artifacts Have Politics?”, *Daedalus*, C. 109, S. 1, 1980.

YEUNG, Karen: “‘Hypernudge’: Big Data as a Mode of Regulation by Design”, *Information, Communication & Society*, C. 20, S. 1, 2017.

YILDIRIM, Turan vd.: *İdare Hukuku*, İstanbul, On İki Levha, güncel bası.

ZUBOFF, Shoshana: *The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power*, New York, PublicAffairs, 2019.

ZWEIGERT, Konrad / KÖTZ, Hein: *Einführung in die Rechtsvergleichung auf dem Gebiete des Privatrechts*, 3. Bası, Tübingen, Mohr Siebeck, 1996.

C. Raporlar ve Kurumsal Belgeler

ANTHROPIC / COLLECTIVE INTELLIGENCE PROJECT: "Collective Constitutional AI: Aligning a Language Model with Public Input", Ekim 2023.

AUTORITEIT PERSOONSGEGEVENS: Belastingdienst hakkında Aralık 2021 tarihli idari para cezası kararı.

BELİRLİ KONVANSİYONEL SİLAHLAR SÖZLEŞMESİ'NE TARAF DEVLETLER TOPLANTISI: *Ölümcül Otonom Silah Sistemleri Alanındaki Yeni Teknolojilere İlişkin Yol Gösterici İlkeler*, 2019.

BENGIO, Yoshua vd.: *International AI Safety Report*, Londra, Ocak 2025.

BUREAU D'ENQUÊTES ET D'ANALYSES POUR LA SÉCURITÉ DE L'AVIATION CIVILE (BEA): *Rapport final: Accident survenu le 1er juin 2009 à l'Airbus A330-203 immatriculé F-GZCP exploité par Air France, vol AF 447 Rio de Janeiro - Paris*, Temmuz 2012.

CEPEJ (European Commission for the Efficiency of Justice): *European Ethical Charter on the Use of Artificial Intelligence in Judicial Systems and Their Environment*, Strasbourg, Aralık 2018.

DEPARTMENT FOR SCIENCE, INNOVATION AND TECHNOLOGY (Birleşik Krallık): *A pro-innovation approach to AI regulation*, CP 815, Mart 2023.

HUMAN RIGHTS WATCH: *China's Algorithms of Repression: Reverse Engineering a Xinjiang Police Mass Surveillance App*, New York, Mayıs 2019.

KİŞİSEL VERİLERİ KORUMA KURUMU: *Yapay Zekâ Alanında Kişisel Verilerin Korunmasına Dair Tavsiyeler*, Ankara, 15 Eylül 2021.

NATIONAL INSTITUTE OF STANDARDS AND TECHNOLOGY: *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, NIST AI 100-1, Ocak 2023.

NATIONAL TRANSPORTATION SAFETY BOARD: *Collision Between Vehicle Controlled by Developmental Automated Driving System and Pedestrian, Tempe, Arizona, March 18, 2018*, NTSB/HAR-19/03, Washington, 2019.

OECD: *Recommendation of the Council on Artificial Intelligence*, OECD/LEGAL/0449, 2019 (2023 ve 2024 güncellemeleriyle).

OECD: *Innovative Citizen Participation and New Democratic Institutions: Catching the Deliberative Wave*, Paris, OECD Publishing, 2020.

ROYAL COMMISSION INTO THE ROBODEBT SCHEME: *Report*, Canberra, Temmuz 2023.

T.C. CUMHURBAŞKANLIĞI DİJİTAL DÖNÜŞÜM OFİSİ / T.C. SANAYİ VE TEKNOLOJİ BAKANLIĞI: *Ulusal Yapay Zekâ Stratejisi 2021-2025*, Ankara, Ağustos 2021.

THE BLETCHLEY DECLARATION BY COUNTRIES ATTENDING THE AI SAFETY SUMMIT, 1-2 Kasım 2023.

TWEEDE KAMER DER STATEN-GENERAAL, Parlementaire ondervragingscommissie Kinderopvangtoeslag: *Ongekend onrecht*, Den Haag, 17 Aralık 2020.

UNESCO: *Recommendation on the Ethics of Artificial Intelligence*, Paris, 23 Kasım 2021.

UNITED NATIONS HIGH-LEVEL ADVISORY BODY ON ARTIFICIAL INTELLIGENCE: *Governing AI for Humanity: Final Report*, New York, Eylül 2024.

U.S. COMMODITY FUTURES TRADING COMMISSION / U.S. SECURITIES AND EXCHANGE COMMISSION: *Findings Regarding the Market Events of May 6, 2010*, Washington, 30 Eylül 2010.

D. Mevzuat ve Uluslararası Belgeler

Türkiye

1982 Türkiye Cumhuriyeti Anayasası.

2577 sayılı İdari Yargılama Usulü Kanunu.

2918 sayılı Karayolları Trafik Kanunu.

4721 sayılı Türk Medeni Kanunu.

4982 sayılı Bilgi Edinme Hakkı Kanunu.

5237 sayılı Türk Ceza Kanunu.

5271 sayılı Ceza Muhakemesi Kanunu.

5326 sayılı Kabahatler Kanunu.

6085 sayılı Sayıştay Kanunu.

6098 sayılı Türk Borçlar Kanunu.

6100 sayılı Hukuk Muhakemeleri Kanunu.

6328 sayılı Kamu Denetçiliği Kurumu Kanunu.

6698 sayılı Kişisel Verilerin Korunması Kanunu.

6701 sayılı Türkiye İnsan Hakları ve Eşitlik Kurumu Kanunu.

6754 sayılı Bilirkişilik Kanunu.

7223 sayılı Ürün Güvenliği ve Teknik Düzenlemeler Kanunu.

7499 sayılı Ceza Muhakemesi Kanunu ile Bazı Kanunlarda Değişiklik Yapılmasına Dair Kanun.

Avrupa Birliği

Regulation (EU) 2016/679 (Genel Veri Koruma Tüzüğü).

Regulation (EU) 2024/1689 (Yapay Zekâ Tüzüğü).

Directive (EU) 2019/1937 (İhbarcıların Korunması Direktifi).

Directive (EU) 2024/2853 (Ürün Sorumluluğu Direktifi).

European Commission, COM(2022) 496 final (Yapay Zekâ Sorumluluğu Direktifi Önerisi; geri çekilmiştir).

European Parliament resolution of 16 February 2017 with recommendations to the Commission on Civil Law Rules on Robotics (2015/2103(INL)).

Avrupa Konseyi ve Diğer Uluslararası Belgeler

Council of Europe Framework Convention on Artificial Intelligence and Human Rights, Democracy and the Rule of Law, CETS No. 225, Vilnius, 5 Eylül 2024.

Convention on Third Party Liability in the Field of Nuclear Energy, Paris, 29 Temmuz 1960.

Rio Çevre ve Kalkınma Bildirgesi, 1992.

UN General Assembly, A/RES/78/265, 21 Mart 2024.

Diğer Ülkeler

Almanya: Grundgesetz für die Bundesrepublik Deutschland, Art. 1; Verwaltungsverfahrensgesetz (VwVfG), § 35a.

Amerika Birleşik Devletleri: Executive Order 14110 (30 Ekim 2023); Executive Order 14179 (23 Ocak 2025); California Senate Bill 53 (2025), Transparency in Frontier Artificial Intelligence Act; New York City Local Law 144 of 2021.

Birleşik Krallık: Police and Criminal Evidence Act 1984, s. 69; Youth Justice and Criminal Evidence Act 1999, s. 60; Financial Services and Markets Act 2000, s. 66A-66B; Corporate Manslaughter and Corporate Homicide Act 2007; Post Office (Horizon System) Offences Act 2024.

Fransa: Code des relations entre le public et l'administration, art. L. 311-3-1 ve L. 312-1-3; Loi n° 2016-1321 du 7 octobre 2016 pour une République numérique; Loi n° 2019-222 du 23 mars 2019 de programmation 2018-2022 et de réforme pour la justice.

E. Mahkeme Kararları

Avrupa İnsan Hakları Mahkemesi

Klass and Others v. Germany, B. No. 5029/71, 6 Eylül 1978.

Big Brother Watch and Others v. the United Kingdom [Büyük Daire], B. No. 58170/13, 62322/14, 24960/15, 25 Mayıs 2021.

Centrum för rättvisa v. Sweden [Büyük Daire], B. No. 35252/08, 25 Mayıs 2021.

Glukhin v. Russia, B. No. 11519/20, 4 Temmuz 2023.

Avrupa Birliği Adalet Divanı

C-817/19, *Ligue des droits humains*, 21 Haziran 2022.

C-634/21, *OQ v Land Hessen (SCHUFA Holding)*, 7 Aralık 2023.

C-203/22, *Dun & Bradstreet Austria*, 27 Şubat 2025.

Almanya

BVerfGE 49, 89 (Kalkar I), 1978.

BVerfG, 1 BvR 357/05, 15 Şubat 2006, BVerfGE 115, 118 (Luftsicherheitsgesetz).

Fransa

Conseil constitutionnel, Décision n° 2018-765 DC du 12 juin 2018.

Conseil constitutionnel, Décision n° 2020-834 QPC du 3 avril 2020.

İtalya

Consiglio di Stato, Sez. VI, sentenza 8 aprile 2019, n. 2270.

Consiglio di Stato, Sez. VI, sentenza 13 dicembre 2019, n. 8472.

Hollanda

Rechtbank Den Haag, 5 Şubat 2020, ECLI:NL:RBDHA:2020:865 (SyRI).

Birleşik Krallık

Prohibitions del Roy (1607), 12 Co. Rep. 63, 77 Eng. Rep. 1342.

Case of Proclamations (1610), 12 Co. Rep. 74, 77 Eng. Rep. 1352.

Dr. Bonham's Case (1610), 8 Co. Rep. 107a, 77 Eng. Rep. 646.

Bates and Others v Post Office Ltd (No 6: Horizon Issues) [2019] EWHC 3408 (QB).

R (Bridges) v Chief Constable of South Wales Police [2020] EWCA Civ 1058.

Hamilton and Others v Post Office Ltd [2021] EWCA Crim 577.

Amerika Birleşik Devletleri

Marbury v. Madison, 5 U.S. (1 Cranch) 137 (1803).

State v. Loomis, 881 N.W.2d 749 (Wis. 2016).

Houston Federation of Teachers, Local 2415 v. Houston Independent School District, 251 F. Supp. 3d 1168 (S.D. Tex. 2017).

Avustralya

Amato v Commonwealth of Australia, Federal Court of Australia, 27 Kasım 2019.

Prygodicz v Commonwealth of Australia (No 2) [2021] FCA 634.

EK: KAVRAM SÖZLÜĞÜ

Bu sözlük, çalışmada kullanılan başlıca kavramların Türkçe karşılıklarını, İngilizce (veya özgün dildeki) karşılıklarını ve çalışmadaki anlamlarını kısaca göstermektedir. Çalışmada önerilen özgün kavramlar (*) işaretiyle belirtilmiştir.

Türkçe	Özgün terim	Kısa açıklama
Ahlaki çarpışma bölgesi	Moral crumple zone	Otomatik sistem hatalarının ahlaki ve hukuki yükünün, gerçek kontrol imkânı sınırlı olan insan operatöre yüklenmesi (Elish).
Aldatıcı uyum	Deceptive alignment	Bir sistemin, denetlendiğini bildiği koşullarda uyumlu, denetimin zayıfladığı koşullarda farklı davranması olasılığı.
Algokrasi	Algocracy	Yönetimin, bürokratik hiyerarşiler yerine kod ve algoritmalara gömülü kurallar aracılığıyla gerçekleştirilmesi.
Algoritmik hizmet kusuru*	—	İdarenin yapay zekâ sistemlerinin seçimi, doğrulanması, izlenmesi, durdurulması ve bilgilendirilmesine ilişkin yükümlülüklerini yerine getirmemesi.
Algoritmik idari işlem*	—	Tesis edilmesinde yapay zekâ sisteminin çıktısının belirleyici rol oynadığı idari işlem.
Algoritmik norm*	—	Yapay zekâ sistemlerinin içerdiği ve fiilen genel ve soyut norm işlevi gören karar kuralları.
Algoritmik vesayet*	—	Seçilmiş karar vericilerin, biçimsel yetkiyi korumalarına rağmen, fiilen denetleyemedikleri algoritmik sistemlerin önerilerine bağımlı hâle gelmesi ve bu bağımlılığın kendi kendini

Türkçe	Özgün terim	Kısa açıklama
		güçlendirmesi.
Araçsal yakınsama	Instrumental convergence	Farklı nihai hedeflere sahip yetenekli sistemlerin, kendini koruma ve kaynak edinme gibi ortak ara hedefler geliştirme eğilimi.
Asimetrik durdurulabilirlik*	—	Bir sistemin durdurulmasının kolay, yeniden başlatılmasının zor olması ilkesi.
Engelleme yetisi	Faculté d'empêcher	Başkası tarafından alınmış bir kararı hükümsüz kılma yetkisi (Montesquieu).
Epistokrasi	Epistocracy	Siyasi yetkinin bilgiye veya yetkinliğe göre dağıtılması gerektiği görüşü.
Güven çapası*	—	Her teknik denetim yönteminin dayandığı, kendisi denetlenmeyen ama güvenilir kabul edilen unsur.
Hedef fonksiyonu	Objective function	Bir yapay zekâ sisteminin en iyilemeye çalıştığı ölçüt.
Hedef fonksiyonu-maksat uygunluğu*	—	Bir kamusal yapay zekâ sisteminin hedef fonksiyonunun, kanunun öngördüğü amaçla uyumlu olması şartı.
Hesap verebilirlik	Accountability	Bir failin davranışını bir foruma açıklama ve gerekçelendirme yükümlülüğü altında bulunduğu, forumun yargıda bulunabildiği ve failin sonuçlarla karşılaşabildiği ilişki (Bovens).
Hizalama sorunu	Alignment problem	Bir yapay zekâ sisteminin hedeflerinin insan amaçlarıyla uyumlu hâle getirilmesi sorunu.
Kaba bilişsel denklik varsayımı*	—	Klasik denetim kuramlarının, denetleyen ile denetlenenin aşağı yukarı aynı ölçüde akla sahip olduğuna ilişkin örtük varsayımı.
Kademeli güçsüzleşme	Gradual disempowerment	Yapay zekânın toplumsal sistemlerdeki insan katılımının yerini kademeli olarak alması sonucu, bu

Türkçe	Özgün terim	Kısa açıklama
		sistemlerin insan çıkarlarıyla örtük uyumunun zayıflaması.
Kayma tezi*	—	Bilişsel asimetri arttıkça denetimin ağırlığının sonuç denetiminden süreç, girdi ve varlık koşulları denetimine kaydırılması gerektiği tezi.
Kurumsal bilişsel körelme*	—	Bir kurumun, kararları uzun süre otomatik sistemlere bırakması sonucu, bu kararları bağımsız olarak verme ve değerlendirme kapasitesini yitirmesi.
Olasılıksal sebep yasağı*	—	Bir kişiye ilişkin olasılıksal tahminin, kendi başına, o kişinin aleyhine bir idari işlemin sebebi olamayacağı ilkesi.
Ölçeklenebilir gözetim	Scalable oversight	İnsanların kendilerinden daha yetenekli sistemleri denetleyebilmesini sağlamaya yönelik yöntemler.
Önceden hesap verme*	—	Sistemi kullanıma almadan önce, güvenliği ve etkileri hakkında yetkili foruma hesap verme yükümlülüğü.
Sınır model	Frontier model	Belirli bir zamanda en ileri yetenek düzeyindeki genel amaçlı yapay zekâ modeli.
Son insan halkası ilkesi*	—	Her önemli kullanım bağlamı için, sonuçlardan kişisel olarak hesap verecek, yetki ve bilgiyle donatılmış ve sistemi durdurabilecek en az bir insanın bulunması ilkesi.
Sorumluluk boşluğu	Responsibility gap	Öğrenen sistemlerin öngörülemeyen davranışlarından kimsenin sorumlu tutulamaması sorunu (Matthias).
Sürüm kilidi*	—	Kamusal kararlarda kullanılan sistemlerin belgelendirilmiş bir sürüm olarak kullanıma alınması ve önemli güncellemelerin yeni kullanıma alma işlemi

Türkçe	Özgün terim	Kısa açıklama
		sayılması.
Tahakküm	Domination	Bir aktörün, başkasının hayatına keyfi olarak müdahale etme kapasitesine sahip olması (Pettit).
Uçtan uca güvenceler	End-to-end safeguards	Bir sürecin başlangıcında, işleyişi sırasında ve sonrasında bağımsız güvencelerin bulunması (AİHM).
Uzman/efendi safsatası	Expert/boss fallacy	Birinin bir konuda daha fazla bilgiye sahip olmasından, onun başkalarına emir verme yetkisine sahip olduğu sonucunu çıkarmak (Estlund).
Varlık koşulları denetimi*	—	Bir sistemin hangi koşullarda kullanılabileceğinin, durdurulacağının veya kullanımdan kaldırılacağının belirlenmesi ve bu kararların uygulanabilirliğinin güvence altına alınması.
Yetki-zekâ ayrılığı ilkesi*	—	Bilişsel yetkinliğin, kendi başına, başkaları adına bağlayıcı karar yetkisi doğurmadığı ilkesi.
Düzeltilebilirlik	Corrigibility	Bir sistemin veya kararın, hatalı olduğu anlaşıldığında ciddi bir zarar ve direnç olmaksızın düzeltilebilmesi, değiştirilebilmesi veya devre dışı bırakılabilmesi.